

So sánh giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML với quy trình đánh giá loại trừ rò rỉ dữ liệu

Dung Van Bui

Trường Đại học Công nghệ Thông tin
Đại học Quốc gia TP. Hồ Chí Minh
TP. Hồ Chí Minh, Việt Nam
dungbv.17@grad.uit.edu.vn

Thai Vu Nguyen

Trường Đại học Giao thông Vận tải
Phân hiệu tại TP. Hồ Chí Minh
TP. Hồ Chí Minh, Việt Nam
nvthai@utc2.edu.vn

Nhut Tri Do

Trường Đại học Công nghệ Thông tin
Đại học Quốc gia TP. Hồ Chí Minh
TP. Hồ Chí Minh, Việt Nam
trinhutdo@uit.edu.vn

Van Du Nguyen

Khoa Công nghệ Thông tin
Trường Đại học Nông Lâm TP. Hồ Chí Minh
TP. Hồ Chí Minh, Việt Nam
nvdu@hcmuaf.edu.vn

Tóm tắt nội dung—Hệ thống phát hiện xâm nhập mạng (IDS) dựa trên học máy thường xử lý hàng trăm đặc trưng luồng mạng, gây tốn kém tính toán và khó triển khai tại biên. Bài báo trình bày một nghiên cứu so sánh có hệ thống bốn chiến lược giảm chiều trên Apache Spark ML, gồm baseline dùng toàn bộ đặc trưng, lựa chọn theo Random Forest Importance, lựa chọn theo SHAP và PCA. Mỗi chiến lược được đánh giá trên tám thuật toán phân loại cùng hai phương pháp kết hợp (ensemble), trên tập CICIDS2017. Khác với phần lớn công trình trước, chúng tôi nhấn mạnh tính chặt chẽ của quy trình đánh giá: (i) loại đặc trưng rò rỉ nhãn `destination_port` và khử các luồng trùng lặp ở mức đặc trưng trước khi chia dữ liệu; (ii) cố định cấu hình so sánh từ trước (a priori) để tránh thiên lệch chọn lọc; (iii) chọn mô hình trên tập kiểm định (validation) tách từ tập huấn luyện, kèm kiểm tra độ ổn định trong-phân-phối và đánh giá tổng quát hoá liên bộ dữ liệu (giữa CICIDS2017 và CSE-CIC-IDS2018); (iv) kiểm định ý nghĩa thống kê bằng kiểm định hoán vị (permutation test) ghép cặp trên nhiều lần lấy mẫu lại dữ liệu, kèm khoảng tin cậy hiệu chỉnh Nadeau-Bengio và độ lớn hiệu ứng; và (v) bổ sung đánh giá đa lớp theo từng loại tấn công. Nghiên cứu nhằm kiểm chứng liệu lựa chọn đặc trưng có giữ được phần lớn hiệu năng phân loại khi giảm khoảng 60% số đặc trưng hay không, và liệu SHAP Top-30 có cân bằng được giữa độ chính xác, khả năng giải thích và chi phí để phù hợp xuất sang thiết bị biên Jetson Orin Nano Super (được triển khai trong một công trình song hành về hệ thống) hay không; các kết quả định lượng được báo cáo ở mục thực nghiệm.

Index Terms—Phát hiện xâm nhập, Apache Spark, Lựa chọn đặc trưng, SHAP, Rò rỉ dữ liệu

I. GIỚI THIỆU

Tấn công mạng ngày càng gia tăng về quy mô và độ tinh vi, đòi hỏi các hệ thống IDS vừa chính xác vừa mở rộng được trên dữ liệu lớn [3], [4]. Học máy đã trở thành hướng chủ đạo cho IDS dựa trên bất thường, nhưng các bộ dữ liệu luồng mạng hiện đại như CICIDS2017 [1] cung cấp gần 80 đặc trưng mỗi luồng, làm tăng chi phí huấn luyện, suy luận và bộ nhớ — đặc biệt nghiêm trọng khi triển khai tại biên. Giảm chiều và lựa

chọn đặc trưng vì vậy là bước then chốt. Tuy nhiên, các chiến lược khác nhau như nhúng, không giám sát hay dựa trên giải thích lại đo “mức quan trọng” theo những cách không tương đương, và chúng hiếm khi được so sánh trên cùng một quy trình (pipeline) phân tán.

Một vấn đề ít được chú ý nhưng nghiêm trọng không kém là *độ tin cậy của quy trình đánh giá*. Nhiều báo cáo trên CICIDS2017 đạt F1 xấp xỉ tuyệt đối ở bài toán nhị phân; điều này thường là dấu hiệu rò rỉ dữ liệu hơn là năng lực mô hình. *Rò rỉ dữ liệu* là tình huống thông tin lã ra không sẵn có ở thời điểm triển khai thực tế lại lọt vào quá trình huấn luyện/đánh giá, khiến điểm số bị thổi phồng và không phản ánh đúng khả năng tổng quát hoá. Các lỗi gán nhãn và trùng lặp luồng trong chính CICIDS2017 đã được ghi nhận và cho thấy ảnh hưởng đáng kể đến kết quả đánh giá [5]. Có hai nguồn rò rỉ phổ biến. Thứ nhất, đặc trưng `destination_port` mã hoá trực tiếp dịch vụ bị tấn công, vì CICIDS2017 sinh các kịch bản tấn công nhằm vào cổng cố định, nên nó trở thành “lối tắt” để mô hình ghi nhớ ánh xạ cổng–nhãn. Thứ hai, các luồng trùng lặp ở mức đặc trưng không bị loại bởi bước loại bỏ trùng lặp hoàn toàn, khiến phép chia ngẫu nhiên đặt cùng một mẫu vào cả tập huấn luyện lẫn tập kiểm tra. Bài báo xử lý cả hai trước khi so sánh phương pháp.

Đóng góp chính. (1) So sánh đồng nhất RF Importance, SHAP và PCA trên cùng tám thuật toán Spark ML và hai ensemble; (2) Tích hợp giải thích bằng SHAP [6] và đối chiếu trực tiếp với RF Importance [7]; (3) Một quy trình đánh giá *loại trừ rò rỉ dữ liệu và có kiểm định thống kê*: loại đặc trưng rò rỉ, loại bỏ trùng lặp mức đặc trưng một cách tất định (nhóm đựng độ nhãn bị loại toàn bộ), chọn mô hình trên tập kiểm định tách từ tập huấn luyện, kiểm định hoán vị ghép cặp (liệt kê chính xác) trên nhiều lần lấy mẫu lại kèm hiệu chỉnh Nadeau-Bengio và effect size; (4) Đánh giá đa lớp theo từng loại tấn công, làm rõ nơi các phương pháp thực sự khác

biệt; (5) Khuyến nghị lựa chọn mô hình *nhận biết ràng buộc biên* (edge-aware): cân nhắc đồng thời F1, số đặc trưng và kích thước mô hình cho Jetson Orin Nano Super.

Phần II trình bày nghiên cứu liên quan; Phần III mô tả phương pháp và quy trình đánh giá; Phần IV báo cáo thí nghiệm; Phần V thảo luận; Phần VI nêu các mối đe dọa đến tính hợp lệ; Phần VII kết luận.

II. NGHIÊN CỨU LIÊN QUAN

Các khảo sát IDS [3], [4], [8] cho thấy cả học máy truyền thống lẫn học sâu được áp dụng rộng rãi trên các bộ chuẩn như CICIDS2017 [1]. Nhiều công trình chỉ tập trung vào một thuật toán đơn lẻ, chẳng hạn học sâu trực tuyến (online) [9] hoặc mạng sâu [10], mà chưa so sánh đồng nhất nhiều chiến lược giảm chiều trên cùng một pipeline phân tán. Apache Spark ML [11], [12] hỗ trợ xử lý quy mô lớn nhưng ít nghiên cứu kết hợp lựa chọn đặc trưng, giải thích mô hình và kiểm định thống kê trong một khung thực nghiệm thống nhất. Các nghiên cứu IDS biên gần đây triển khai mô hình học sâu trên NVIDIA Jetson [13], [14], nhưng thường tập trung vào một mô hình đơn lẻ và độ chính xác, hiếm khi so sánh nhiều chiến lược giảm chiều dưới một quy trình đánh giá loại trừ rõ ràng dữ liệu.

Lựa chọn đặc trưng. Lý thuyết lựa chọn biến [15] phân biệt ba nhóm: lọc (filter), bao (wrapper) và nhúng (embedded). Random Forest Importance [7] (embedded) và PCA [16] (không giám sát) là hai hướng phổ biến cho IDS nhưng đo những đại lượng khác nhau. SHAP [6] cung cấp giải thích cục bộ nhất quán, đã dùng cho IDS [17] nhưng hiếm khi được đối chiếu trực tiếp với RF Importance trên cùng tập huấn luyện Spark.

Trôi khái niệm, bất thường và đánh giá. Sự trôi khái niệm (concept drift) [18] ảnh hưởng độ ổn định IDS theo thời gian; các nghiên cứu bất thường [19]–[22] thường tách bộ lọc khỏi bộ phân loại, trong đó autoencoder cũng được dùng để giảm chiều đặc trưng cho IDS trên thiết bị biên [22]. Tuy nhiên, rõ ràng dữ liệu và kiểm định ý nghĩa thống kê trong so sánh phương pháp ít khi được xử lý tường minh trên CICIDS2017. Bài báo lấp khoảng trống này. Bảng I tóm tắt so sánh.

III. PHƯƠNG PHÁP


A. Tổng quan pipeline Spark ML

Quy trình ngoại tuyến (offline) gồm các bước nối tiếp: làm sạch dữ liệu, loại bỏ trùng lặp, VectorAssembler, StandardScaler, biến đổi giảm chiều (tùy chọn), rồi đến bộ phân loại. Nhãn nhị phân: Benign (0) và Attack (1). Toàn bộ fit của StandardScaler/PCA và việc xếp hạng đặc trưng chỉ dùng tập huấn luyện; tập kiểm tra giữ vai trò tập giữ lại (holdout) cuối cùng.

B. Chuẩn bị dữ liệu loại trừ rõ ràng

Chúng tôi gộp tám file CSV CICIDS2017, chuẩn hoá tên cột, thay giá trị vô cực/thiếu, rồi áp dụng hai bước loại trừ rõ ràng dữ liệu trước khi chia dữ liệu:

- **Loại bỏ đặc trưng gây rò rỉ nhãn.** destination_port (và source_port nếu có) bị loại vì mã hoá trực tiếp dịch vụ mục tiêu của tấn công; giữ lại sẽ cho mô hình ghi nhớ



Hình 1. Quy trình đánh giá loại trừ rõ ràng: từ luồng CICIDS2017 thô đến mô hình đã kiểm định thống kê, sẵn sàng cho thiết bị biên.

Thuật toán 1 Tiền xử lý loại trừ rõ ràng cho CICIDS2017

Đầu vào: các tập CSV $\{F_1, \dots, F_N\}$; tỉ lệ chia $\alpha=0.8$

Đầu ra: $D_{\text{train}}, D_{\text{test}}$ (Parquet)

- 1: $D \leftarrow \bigcup_i F_i$ $\triangleright$ chuẩn hoá tên cột; $\pm\infty \rightarrow \text{NaN}$
- 2: $D \leftarrow \text{DROPDUPLICATES}(D)$; $D \leftarrow \text{DROPNAN}(D)$
- 3: $y_i \leftarrow 0$ nếu $\text{UPPER}(\text{label}_i) = \text{BENIGN}$, ngược lại 1
- 4: $\mathcal{F} \leftarrow$ các cột số $\setminus \{\text{destination_port}, \text{source_port}, \text{protocol}, \text{cột định danh}\}$
- 5: với mọi nhóm g gồm các hàng trùng nhau trên toàn bộ $\mathcal{F}$:
- 6: nếu nhãn trong g mâu thuẫn (Benign lẫn Attack):
- 7: loại toàn bộ nhóm g $\triangleright$ nhãn gốc mâu thuẫn; có ghi log
- 8: ngược lại: giữ đúng một đại diện tắt định của g
- 9: chia $D \rightarrow D_{\text{train}}/D_{\text{test}}$ (α , seed cố định); ghi Parquet

ánh xạ cổng–nhân thay vì học hành vi luồng. Một phân tích loại bỏ (ablation: giữ so với loại cổng) định lượng ảnh hưởng.

- **Loại bỏ trùng lặp ở mức đặc trưng (tắt định).** Ngoài việc khử các bản ghi trùng lặp hoàn toàn, chúng tôi loại các luồng trùng nhau trên toàn bộ cột đặc trưng trước khi chia, ngăn cùng một mẫu xuất hiện ở cả tập huấn luyện và tập kiểm tra. Với các nhóm luồng trùng đặc trưng nhưng *mâu thuẫn nhãn* (Benign và Attack — một lỗi đã biết của CICIDS2017 [5]), toàn bộ nhóm bị loại thay vì giữ lại một hàng tùy ý theo phân mảnh dữ liệu; số nhóm và số hàng bị loại được báo cáo (270 nhóm, 44.260 hàng), bảo đảm kết quả loại bỏ trùng lặp tắt định và tái lập được.

Thuật toán 1 tóm tắt quy trình, và Hình 1 đặt nó trong toàn cảnh quy trình đánh giá. Sau khi xử lý, dữ liệu được chia thành **80% huấn luyện / 20% kiểm tra** (với seed cố định), lưu dưới định dạng Parquet và tái sử dụng xuyên suốt các thí nghiệm. Số đặc trưng dạng số còn lại là 77, và số mẫu sau khi loại bỏ trùng lặp là 1.785.349/447.275 (tổng $\approx 2.232.624$ sau khi loại trùng lặp mức đặc trưng).

Bảng I
SO SÁNH NĂNG LỰC VỚI CÁC NGHIÊN CỨU IDS LIÊN QUAN TRÊN CICIDS2017 VÀ SPARK/EDGE (“—”: KHÔNG ĐỀ CẬP HOẶC KHÔNG BÁO CÁO).

Tài liệu	Bộ dữ liệu	Giảm đặc trưng / khả năng giải thích	Loại trừ rò rỉ	Kiểm định thống kê	Liên bộ dữ liệu	Đa lớp
Khraisat et al. [4]	Nhiều (khảo sát)	Tổng quát	—	—	—	—
Vinayakumar et al. [10]	CICIDS2017	Không	—	—	—	Có
Ferrag et al. [8]	Nhiều	Không	—	—	—	Có
Alrawashdeh & Purdy [9]	NSL-KDD	Không	—	—	—	—
Sarhan et al. [17]	NetFlow (NF-*)	SHAP	—	—	Có	—
Baalaji et al. [13]	IoT-edge	Không	—	—	—	—
Asghar et al. [14]	Nhiều	Metaheuristic	—	—	—	—
Hasan et al. [22]	IIoT	Autoencoder	—	—	—	—
Phương pháp đề xuất	CICIDS2017, CSE-CIC-IDS2018	RF/SHAP/PCA	Có	Có	Có	Có

C. Bộ phân loại và bốn chiến lược giảm chiều

Tám thuật toán: Decision Tree, Logistic Regression, SVM (LinearSVC), Naive Bayes, Random Forest, GBT, XGBoost, MLP; cùng hai ensemble (Hybrid Bagging Top-3 có trọng số và Soft Voting). LightGBM bị loại vì thư viện gốc (native, qua SynapseML) chỉ hỗ trợ x86_64 và không chạy được trên thiết bị biên Jetson Orin Nano Super (ARM64), vốn là mục tiêu triển khai của nghiên cứu; do đó không thể đưa một mô hình LightGBM vào pipeline. Trong họ gradient boosting, XGBoost và GBT đóng vai trò đại diện. Bốn chiến lược: **Baseline** (toàn bộ đặc trưng); **RF Top- K** ($K \in \{20, 30, 40\}$); **SHAP Top- K** ; **PCA** ($k \in \{20, 30, 40\}$). Xếp hạng RF và SHAP chỉ dùng tập huấn luyện; SHAP được tính trên mẫu *phân tầng theo lớp* để cả lưu lượng lành tính (benign) lẫn tấn công đều được đại diện. PCA được cố định ở $k=40$, nhiều hơn so với Top-30 của các phương pháp chọn lọc, vì PCA là một phép *trích xuất*: mỗi thành phần chính là một tổ hợp tuyến tính chỉ mang một phần phương sai, nên cần nhiều thành phần hơn để giữ được phương sai tương đương. Trong dải $\{20, 30, 40\}$, $k=40$ giữ phương sai cao nhất nên là điểm đại diện công bằng nhất cho PCA.

D. Siêu tham số và xử lý mất cân bằng lớp

Siêu tham số (Bảng II) được *cố định từ trước* và dùng chung cho mọi phương pháp giảm chiều, để khác biệt quan sát được phản ánh đúng *phương pháp lựa chọn đặc trưng* chứ không phải việc tinh chỉnh riêng từng mô hình; việc tinh chỉnh siêu tham số được tách thành một giai đoạn riêng (tìm kiếm lưới kết hợp kiểm định chéo) và chỉ áp dụng cho cấu hình được chọn. Các mô hình ngẫu nhiên (RF, GBT, XGBoost, MLP) cố định seed để tái lập. Mất cân bằng lớp được xử lý *đồng nhất*. Mọi mô hình hỗ trợ weightCol, gồm Decision Tree, Logistic Regression, SVM, Naive Bayes, Random Forest và GBT, đều được gán trọng số lớp theo tỷ lệ lành tính/tấn công, tương đương cơ chế scale_pos_weight của XGBoost. Riêng MLP không hỗ trợ trọng số mẫu trong Spark ML nên được huấn luyện không trọng số, như nêu ở phần hạn chế.

E. Thiết kế so sánh hai giai đoạn

Để tránh thiên lệch chọn lọc do thử nhiều cấu hình trên cùng tập kiểm tra, chúng tôi tách *giai đoạn khám phá* (quét K , báo cáo đầy đủ theo từng K) khỏi *giai đoạn xác nhận* (cố định

bốn cấu hình từ trước: Baseline, RF Top-30, SHAP Top-30, PCA $k=40$). Kết luận so sánh dựa trên bốn cấu hình cố định, không chọn cấu hình có F1 cao nhất sau khi đã quan sát kết quả trên tập kiểm tra. Bên trong mỗi cấu hình, *mô hình đại diện* và *cấp phương pháp* đưa vào kiểm định thống kê cũng được chọn theo F1 trên một tập kiểm định (validation, 20% tách từ tập huấn luyện, seed cố định) — tập kiểm tra không tham gia bất kỳ khâu chọn lọc nào.

F. Quy trình đánh giá chặt chẽ

Chỉ số. Accuracy, Precision, Recall, F1, AUC-ROC, AUC-PR; thời gian huấn luyện/dự đoán; kích thước mô hình. Do dữ liệu mất cân bằng, AUC-PR và recall lớp tấn công được ưu tiên hơn accuracy.

Kiểm tra độ ổn định trong-phân-phối. Mô hình đại diện mỗi phương pháp được đánh giá lại trên một mẫu con của tập kiểm tra (không giao với tập huấn luyện). Cần nói rõ: đây chỉ là phép kiểm tra *độ ổn định cùng phân phối* (in-distribution), không phải kiểm thử dịch chuyển phân phối; đánh giá tổng quát hoá thực sự nằm ở thí nghiệm liên bộ dữ liệu (Mục IV).

Kiểm định ý nghĩa thống kê. Hai phương pháp hàng đầu được huấn luyện trên N lần *lấy mẫu lại* độc lập tập huấn luyện/kiểm tra (mặc định $N=6$), và ở mỗi vòng cả hai dùng *cùng một* phép chia để ghép cặp. Nhờ đó, phương sai phản ánh tác động của việc lấy mẫu dữ liệu chứ không chỉ của khởi tạo mô hình. Khoảng tin cậy 95% được tính theo phân phối t ($t_{0.975, N-1}$, không dùng giá trị 1,96); vì các lần lấy mẫu lại chồng lấn dữ liệu huấn luyện, chúng tôi báo cáo *song song* khoảng tin cậy hiệu chỉnh Nadeau-Bengio, với phương sai nhân hệ số $(1/N + n_{\text{test}}/n_{\text{train}})$, và lấy khoảng hiệu chỉnh làm căn cứ kết luận. Ý nghĩa kiểm bằng *permutation test ghép cặp hai phía* trên hiệu F1 từng vòng, *liệt kê chính xác* toàn bộ 2^N hoán vị dấu (với $N=6$ là 64 hoán vị) thay vì lấy mẫu Monte Carlo; do kiểm định hai phía, p nhỏ nhất có thể đạt là $2/2^N$, nên cần $N \geq 6$ để có thể đạt dưới 0,05 (ngược với thiết kế một phép chia cố định / ba seed vốn không vượt qua $p \approx 0,125$). Kèm theo p , chúng tôi báo cáo độ lớn hiệu ứng Cohen’s d ghép cặp: với N nhỏ, một giá trị p không có ý nghĩa tự nó là bằng chứng yếu cho “tương đương”.

Đánh giá đa lớp. Vì phân loại nhị phân trên CICIDS2017 gần như tách hoàn toàn, chúng tôi bổ sung đánh giá *đa lớp theo*

Bảng II
SIÊU THAM SỐ CHÍNH CỦA TÁM BỘ PHÂN LOẠI (CỐ ĐỊNH TỪ TRƯỚC).

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01
Cân bằng lớp: weightCol (6 mô hình) / scale_pos_weight (XGBoost); MLP không trọng số.	

loại tấn công, gồm precision/recall/F1 từng lớp, macro-F1 và ma trận nhầm lẫn. Chính ở đây, các lớp hiểm như Heartbleed, Infiltration, Web Attack và Bot mới bộc lộ khác biệt thực sự giữa các phương pháp.

IV. THÍ NGHIỆM VÀ KẾT QUẢ

A. Thiết lập

CICIDS2017; chia tập huấn luyện/kiểm tra 80/20 sau khi loại trừ rò rỉ dữ liệu (Mục III-B); Apache Spark 3.4.1, Java 17; phần cứng: cụm 2× Jetson Orin Nano Super (8 GB) và một máy chủ điều phối. Mọi script ghi lại cấu hình chạy (seed, biến môi trường, phiên bản thư viện) để đảm bảo tái lập. Toàn bộ mã nguồn, cấu hình và danh sách đặc trưng được công khai tại https://github.com/vuthainguyen1602/Thesis_IDS (nhánh develop); quy trình có thể tái lập trên một máy đơn, không yêu cầu cụm thiết bị biên.

B. Phân tích loại bỏ đặc trưng cổng (ablation)

Bảng III và Hình 2 định lượng ảnh hưởng của destination_port. Sau khi đã loại bỏ trùng lặp luồng, ảnh hưởng riêng của cổng là *nhỏ*: F1 khi giữ cổng là 0,9965 và khi loại cổng là 0,9955 (chênh $\approx 0,001$) — vì tác vụ nhị phân trong-miền gần bão hoà và nguồn rò rỉ chi phối (trùng lặp luồng) đã được xử lý trước; tuy vậy chiều hướng (giữ cổng cho F1/recall cao hơn) vẫn nhất quán với hiện tượng rò rỉ. Mọi kết quả phía sau dùng cấu hình *đã loại cổng*.


Bảng III

ẢNH HƯỞNG CỦA ĐẶC TRƯNG RÒ RỈ DESTINATION_PORT (RANDOM FOREST CỐ ĐỊNH A PRIORI THEO CẤU HÌNH BẢNG II, CỐ TRỌNG SỐ LỚP; NHỊ PHÂN).

Cấu hình	F1	Recall (Attack)	AUC-PR
Giữ cổng	0,9965	0,9988	0,9999
Loại cổng (đề xuất)	0,9955	0,9961	0,9997

C. So sánh bốn phương pháp giảm chiều

Bảng IV tóm tắt mô hình tốt nhất mỗi phương pháp, và Hình 3 trực quan hoá F1 theo từng cặp phương pháp × thuật toán. Thiết kế so sánh nhằm kiểm chứng liệu lựa chọn đặc trưng (RF/SHAP Top-30) có giữ được hiệu năng gần baseline trong khi giảm $\approx 60\%$ số đặc trưng hay không; PCA $k=40$ giảm chiều không giám sát với chi phí giải thích. Toàn bộ giá



Hình 2. Ảnh hưởng của đặc trưng rò rỉ destination_port (Random Forest, nhị phân).

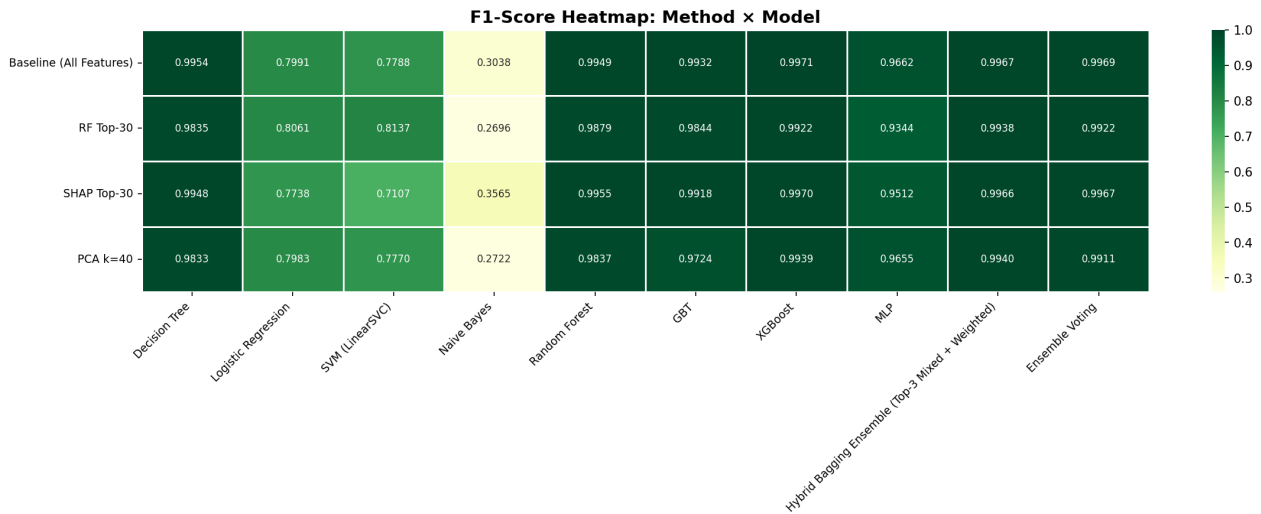
trị định lượng được lấy trực tiếp từ đầu ra của quy trình đã công khai (cross_method_summary.csv).

D. Kiểm định thống kê (lấy mẫu lại ghép cặp)

Bảng V báo cáo F1 trung bình $\pm$ CI 95% (phân phối t) trên $N=6$ lần lấy mẫu lại cho hai phương pháp hàng đầu, kèm p -value permutation test ghép cặp. Kết luận: hai phương pháp khác biệt có ý nghĩa thống kê ở mức sàn ($p \approx 0,031$, Cohen's $d \approx 1,94$) nhưng chênh lệch F1 tuyệt đối rất nhỏ ($\approx 0,0001$) nên *tương đương về mặt thực dụng*.

E. Độ bền vững và đánh giá đa lớp

Trong kiểm tra độ ổn định trong-phân-phối (mẫu con của tập kiểm tra), thứ hạng các phương pháp *giữ nguyên* (XGBoost dẫn đầu ở cả bốn phương pháp); chi tiết tại robustness_holdout_summary.csv. Đánh giá đa lớp (Hình 5, Bảng VI) cho thấy tương phản rõ giữa weighted-F1 ($\approx 0,998$) và macro-F1 ($\approx 0,806$): các lớp đa số đạt F1 cao, trong khi các lớp hiếm như Web Attack (XSS, SQL Injection) và Bot có recall rất thấp (0,03–0,46) — nơi lựa chọn đặc trưng tạo khác biệt rõ nhất. Đọc ma trận nhầm lẫn theo *đích đến* của lỗi cho thấy hai kiểu suy giảm khác nhau. XSS chủ yếu *nhầm loại nhưng vẫn bị phát hiện*: 81/111 mẫu bị gán thành Web Brute Force, nên ở mức nhị phân (triển khai) 76% luồng XSS vẫn bị gán cờ tấn công. Kiểu nguy hiểm là *lọt hẫng thành*




Hình 3. Heatmap F1 theo phương pháp và thuật toán (nhị phân, đã loại cổng).

Bảng IV
TÓM TẮT MÔ HÌNH TỐT NHẤT MỖI PHƯƠNG PHÁP (SỐ LIỆU TỪ CROSS_METHOD_SUMMARY.CSV).

Phương pháp	Mô hình	F1	AUC-PR	Train (s)	Size (MB)
Baseline	XGBoost	0,9971	0,9999	4615,5	2,32
RF Top-30	XGBoost	0,9922	0,9998	1295,1	2,52
SHAP Top-30	XGBoost	0,9970	0,9999	1226,1	0,003 [†]
PCA k=40	XGBoost	0,9939	0,9999	1444,8	3,82

[†]Kích thước thu được bằng cách tuần tự hoá mô hình *trên cụm huấn luyện*; bước lưu mô hình phân tán ghi các phân vùng dữ liệu của rừng cây trên executor đang giữ chúng, nên các giá trị cỡ KB (ở đây 0,003 MB) chỉ bắt được phần metadata cục bộ trên driver và *thấp hơn thực tế*. Vì kích thước ensemble cây phụ thuộc số cây và số nút chứ không phụ thuộc số đặc trưng đầu vào, mô hình XGBoost SHAP Top-30 thực tế tương đương bản RF Top-30 ($\approx 2,5$ MB); bản xuất khẩu đơn nút của pipeline triển khai đo kích thước mô hình một cách tin cậy.



Hình 4. Thời gian huấn luyện và suy luận của mô hình đại diện mỗi phương pháp, đo trên cụm Spark dùng cho huấn luyện (Mục IV); các số đo độ trễ/thông lượng suy luận trên thiết bị biên thuộc phạm vi một công trình song hành về hệ thống (đang gửi phản biện), không thuộc bài này.

Bảng V
ỔN ĐỊNH ĐA LẦN LẤY MẪU VÀ KIỂM ĐỊNH GHÉP CẶP (SỐ LIỆU TỪ STATISTICAL_VALIDITY_MULTISEED.CSV).


Phương pháp	Mô hình	F1 (mean $\pm$ CI95)	p (ghép cặp)
Baseline	XGBoost	0,99734 $\pm$ 0,00007	
SHAP Top-30	XGBoost	0,99720 $\pm$ 0,00009	0,031

Benign: toàn bộ 6 mẫu SQL Injection, 54% Bot (158/290) và 27% Web Brute Force bị dự đoán là lưu lượng bình thường. Ba cơ chế: mất cân bằng cực đoan (6–311 mẫu so với 380 nghìn benign); việc loại *destination_port* ảnh hưởng nặng nhất đến tấn công web — mất “lối tắt” cổng 80, các luồng HTTP ngắn giống duyệt web thường và giống lẫn nhau, nên recall 0,027 là con số trung thực thay cho con số được thổi phồng bởi rò rỉ; và bản chất beaconing C&C của Bot vốn giống lưu lượng nền khi không còn định danh dịch vụ. Điều này trực tiếp gợi hướng xử lý mất cân bằng có chủ đích và đặc trưng thời gian cho beaconing ở nghiên cứu tiếp theo.

Bảng VI
PRECISION/RECALL/F1 THEO LỚP (TRÍCH TỪ PER_CLASS_METRICS.CSV).

Lớp	Support	Precision	Recall	F1
Benign	380.119	0,9981	0,9997	0,9989
DoS Hulk	34.446	0,9990	0,9904	0,9947
PortScan	383	1,0000	0,9530	0,9759
Web Attack – Brute Force	311	0,7346	0,7299	0,7323
Bot	290	1,0000	0,4552	0,6256
Web Attack – XSS	111	1,0000	0,0270	0,0526
Infiltration	12	1,0000	0,6667	0,8000
Web Attack – SQL Injection	6	0,0000	0,0000	0,0000

7 lớp còn lại đều có F1 $\geq 0,96$ — xem *per_class_metrics.csv*
macro-F1 = 0,806 weighted-F1 = 0,998



Hình 5. Ma trận nhầm lẫn đa lớp (chuẩn hoá theo hàng).

F. Tổng quát hoá liên bộ dữ liệu

Để vượt khỏi đánh giá *cùng bộ* (in-domain), chúng tôi huấn luyện trên một bộ dữ liệu và kiểm tra trên bộ *khác bộ*, cross-dataset; và ngược lại trên tập đặc trưng đã loại trừ rõ ràng của hai bộ. Khoảng cách giữa F1 cùng bộ (A→A) và F1 khác bộ (A→B) trong Bảng VII định lượng khả năng *tổng quát hoá* của mô hình đã loại rõ ràng. Đây là một phép thử dịch chuyển phân phối thực sự, khác với holdout cùng phân phối ở trên. Do CSE-CIC-IDS2018 [23] rất lớn (~16 triệu luồng), chúng tôi sử dụng *mẫu phân tầng theo nhãn* (tỉ lệ 0,2, ~3,14 triệu luồng lấy mẫu, còn ~2,39 triệu sau khử trùng lặp mức đặc trưng, seed=42) bảo toàn tỉ lệ các lớp; CICIDS2017 dùng ~2,23 triệu luồng. Các con số mẫu được báo cáo tường minh để bảo đảm tái lập.

Bảng VII
TỔNG QUÁT HOÁ LIÊN BỘ DỮ LIỆU (CICIDS2017 và CSE-CIC-IDS2018, MẪU PHÂN TẦNG SEED=42; SỐ LIỆU TỪ CROSS_DATASET_RESULTS.CSV).

Huấn luyện	Kiểm tra	Loại	F1
CICIDS2017	CICIDS2017	cùng bộ	0,9952
CICIDS2017	CSE-CIC-2018	khác bộ	0,0423
CSE-CIC-2018	CSE-CIC-2018	cùng bộ	0,9245
CSE-CIC-2018	CICIDS2017	khác bộ	0,0535

Tương phản này rất rõ rệt và, theo chúng tôi, là con số trung thực nhất của bài báo: F1 cùng bộ cao ở cả hai chiều (0,9952 và 0,9245) nhưng F1 khác bộ sụp đổ xuống 0,04–0,05, chủ yếu do recall gần bằng không (0,022 và 0,030) trong khi precision chiều 2017 sang 2018 vẫn đạt 0,60 — mô hình *không nhận ra* tấn công của testbed kia chứ không tạo ra cảnh báo sai tràn lan.

Nguyên nhân cụ thể: khác phiên bản CICFlowMeter (thang đo và định nghĩa đặc trưng thay đổi), khác cấu hình mạng/dịch vụ, và bộ công cụ tấn công không giao nhau (HOIC/LOIC-HTTP chỉ có ở 2018). Mức sụp đổ này nhất quán với các nghiên cứu cross-dataset trước đó [24], [25] và củng cố luận điểm trung tâm của bài: điểm số trong-miền gần hoàn hảo — kể cả khi đã loại rõ ràng — không bảo đảm khả năng triển khai dưới dịch chuyển phân phối; đánh giá liên bộ dữ liệu phải là phần bắt buộc của kiểm định IDS, và thích ứng miền (chuẩn hoá theo miền, huấn luyện liên bộ, cập nhật theo drift) là điều kiện tiên quyết cho chuyển giao thực tế.

V. THẢO LUẬN

So sánh phương pháp. Với cặp được kiểm định (Baseline và SHAP Top-30, Bảng V), phép kiểm hoán vị chỉ có ý nghĩa ở đúng ngưỡng sàn của nó ($p \approx 0,031$) trong khi chênh lệch F1 tuyệt đối ($\approx 0,0001$) thấp hơn nhiều so với mức dao động giữa các lần chạy; do đó hai cấu hình được coi là *tương đương về thực tiễn*, và tiêu chí phụ (giải thích, kích thước, ổn định, số đặc trưng) quyết định lựa chọn triển khai. Ngược lại, RF Top-30 kém SHAP Top-30 $\approx 0,005$ F1 dù cùng số đặc trưng. SHAP Top-30 cung cấp giải thích cục bộ nhất quán, lợi thế cho vận hành SOC.

Cầu nối với thiết bị biên. Giảm $\approx 60\%$ số đặc trưng trực tiếp giảm chi phí lắp ráp vector và bộ nhớ mô hình trên Jetson Orin Nano Super. Vì vậy, tiêu chí lựa chọn cần *nhận biết ràng buộc biên*, tức là cân nhắc không chỉ F1 mà cả số đặc trưng, kích thước mô hình và thời gian huấn luyện/dự đoán (Hình 4). Kết quả đo độ trễ và thông lượng (latency/throughput) trên Jetson được trình bày trong một công trình song hành về hệ thống (đang gửi phản biện).

Hạn chế của đánh giá nhị phân. Việc loại cổng và loại bỏ trùng lặp đưa F1 nhị phân về mức thực tế, nhưng phân loại nhị phân vẫn là bài toán tương đối dễ. Chỉ khi đánh giá đa lớp, các điểm yếu ở lớp tấn công hiếm mới bộc lộ, và đây cũng là thước đo phân biệt phương pháp đáng tin cậy hơn.

VI. CÁC MỐI ĐE DỌA ĐẾN TÍNH HỢP LỆ

Hợp lệ nội tại. Xếp hạng RF/SHAP được rút từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại. Cách làm này nhất quán với thiết kế “cấu hình định trước”, nhưng có thể tạo rõ ràng nhẹ ở phần ranking. Re-rank theo từng lần lấy mẫu sẽ chặt chẽ hơn nhưng tốn kém (đặc biệt SHAP); chúng tôi nêu rõ đánh đổi này. Việc chọn Top-3 mô hình thành phần cho ensemble được thực hiện trên một *tập kiểm định (validation)* tách riêng từ tập huấn luyện, nên tập kiểm tra không tham gia vào khâu chọn mô hình; đánh đổi là các mô hình cơ sở huấn luyện trên phần dữ liệu nhỏ hơn sau khi trích tập kiểm định. Ngoài ra, cân bằng lớp được áp đồng nhất cho bảy mô hình (Mục III-D) nhưng *không* cho MLP do Spark ML không hỗ trợ trọng số mẫu cho mô hình này; kết quả MLP vì vậy nên được đọc với lưu ý đó.

Hợp lệ ngoại tại. CICIDS2017 (2017) có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu chuẩn NIDS có những hạn chế chất lượng đã được ghi nhận [26]; cần kiểm chứng trên các bộ mới hơn (CSE-CIC-IDS2018, CIC-IoT). Phép chia

ngẫu nhiên mặc định trộn thời gian; chế độ chia theo thời gian được hỗ trợ để đánh giá sát thực tế hơn. Kết luận tổng quát hoá liên bộ (Mục IV-F) dựa trên *mẫu phân tầng đại diện* của CSE-CIC-IDS2018 (do giới hạn tài nguyên biên), không phải toàn bộ; kích thước mẫu được báo cáo tường minh và việc mở rộng lên toàn bộ là hướng tiếp theo. Mô hình giả định phân bố tấn công xấp xỉ CICIDS2017 và chưa được đánh giá trước lưu lượng cố ý né tránh (adversarial evasion). Ngoài ra, việc loại bỏ trùng lặp ở mức đặc trưng (Mục III-B) tự nó làm thay đổi phân bố lớp giữa lành tính và tấn công, nên cần lưu ý khi diễn giải kết quả.

Hợp lệ thống kê. Cỡ mẫu nhỏ ($N=6$) khiến *độ mạnh* (power) của kiểm định thấp: vì permutation test hai phía, p nhỏ nhất có thể đạt chỉ là $2/2^N$, nên $N=6$ vừa đủ chạm ngưỡng 0,05 và khó phát hiện hiệu ứng nhỏ. Hơn nữa, các lần lấy mẫu lại *chồng lấn* nhau nên vi phạm giả định độc lập của phân phối t ; vì vậy khoảng tin cậy hiệu chỉnh Nadeau–Bengio được báo cáo song song (Mục III-F) và là căn cứ kết luận chính, còn khoảng t chuẩn chỉ mang tính tham chiếu. Một hạn chế còn lại là xếp hạng đặc trưng RF/SHAP được giữ cố định qua các lần lấy mẫu lại (không re-rank theo từng vòng), tạo một mức rò rỉ chọn lọc nhẹ có lợi cho hai nhánh lựa chọn đặc trưng; việc re-rank theo từng vòng (khả thi với RF) là hướng cũng cố tiếp theo, cùng với tăng N kèm cross-validation lồng.

VII. KẾT LUẬN

Bài báo so sánh bốn chiến lược giảm chiều cho IDS trên Spark ML dưới một quy trình đánh giá loại trừ rò rỉ dữ liệu và có kiểm định thống kê. Đóng góp cốt lõi không chỉ là “phương pháp nào tốt nhất” mà còn là *cách đánh giá đáng tin cậy*: loại đặc trưng rò rỉ, loại bỏ trùng lặp mức đặc trưng tất định, chọn mô hình trên tập kiểm định, kiểm định ghép cặp liệt kê chính xác kèm hiệu chỉnh Nadeau–Bengio, đánh giá đa lớp và tổng quát hoá liên bộ giữa CICIDS2017 và CSE-CIC-IDS2018 (Mục IV-F). Hướng phát triển: mở rộng lên toàn bộ CSE-CIC-IDS2018 và các bộ dữ liệu mới hơn (RoEduNet, CIC-IoT), kiểm chứng khả năng chuyển giao của chính tập SHAP Top-30 giữa hai bộ dữ liệu, tối ưu siêu tham số, và triển khai realtime trên edge.

LỜI CẢM ƠN

Nghiên cứu được thực hiện tại Trường Đại học Giao thông Vận tải (Phân hiệu TP.HCM) và Trường Đại học Công nghệ Thông tin, ĐHQG TP.HCM, trong khuôn khổ luận văn tốt nghiệp. Các tác giả không có xung đột lợi ích.

TÀI LIỆU

- [1] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, “Toward generating a new intrusion detection dataset and intrusion traffic characterization,” in *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*, pp. 108–116, 2018.
- [2] C. Nadeau and Y. Bengio, “Inference for the generalization error,” *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.
- [3] M. Ring, S. Wunderlich, D. Gründl, D. Landes, and A. Hotho, “A survey of network-based intrusion detection data sets,” *Computers & Security*, vol. 86, pp. 147–167, 2019.
- [4] A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, “Survey of intrusion detection systems: techniques, datasets and challenges,” *Cybersecurity*, vol. 2, no. 1, pp. 1–22, 2019.
- [5] M. Lanvin, P.-F. Gimenez, Y. Han, F. Majorczyk, L. Mé, and É. Totel, “Errors in the CICIDS2017 dataset and the significant differences in detection performances it makes,” in *Risks and Security of Internet and Systems (CRISIS 2022), Revised Selected Papers*, pp. 18–33, Springer, 2023.
- [6] S. M. Lundberg and S.-I. Lee, “A unified approach to interpreting model predictions,” *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [7] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [8] M. A. Ferrag, L. Maglaras, H. Janicke, J. Jiang, and L. Shu, “Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study,” *Journal of Information Security and Applications*, vol. 50, p. 102419, 2020.
- [9] K. Alrawashdeh and C. Purdy, “Toward an online anomaly intrusion detection system based on deep learning,” in *Proc. 15th IEEE Int. Conf. on Machine Learning and Applications (ICMLA)*, pp. 195–200, 2016.
- [10] R. Vinayakumar, M. Alazab, K. P. Soman, P. Poornachandran, A. Al-Nemrat, and S. Venkatraman, “Deep learning approach for intelligent intrusion detection system,” *IEEE Access*, vol. 7, pp. 41525–41550, 2019.
- [11] M. Zaharia, M. Chowdhury, M. J. Franklin, S. Shenker, and I. Stoica, “Spark: Cluster computing with working sets,” in *Proceedings of the 2nd USENIX Workshop on Hot Topics in Cloud Computing (HotCloud’10)*, 2010.
- [12] X. Meng, J. Bradley, B. Yavuz, E. Sparks, S. Venkataraman, D. Liu, J. Freeman, D. Tsai, M. Amde, S. Owen, D. Xin, R. Xin, M. J. Franklin, R. Zadeh, M. Zaharia, and A. Talwalkar, “MLlib: Machine learning in Apache Spark,” *Journal of Machine Learning Research*, vol. 17, no. 34, pp. 1–7, 2016.
- [13] K. Baalaji *et al.*, “Deep learning-based ensemble stacking for enhanced intrusion detection in IoT-edge platforms,” *Discover Applied Sciences*, vol. 7, p. 928, 2025.
- [14] M. Z. Asghar *et al.*, “HED-ID: an edge-deployable and explainable intrusion detection system optimized via metaheuristic learning,” *Scientific Reports*, vol. 16, p. 2313, 2026.
- [15] I. Guyon and A. Elisseeff, “An introduction to variable and feature selection,” *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003.
- [16] I. T. Jolliffe, *Principal Component Analysis*. Springer Series in Statistics, Springer, 2nd ed., 2002.
- [17] M. Sarhan, S. Layeghy, and M. Portmann, “Evaluating standard feature sets towards increased generalisability and explainability of ml-based network intrusion detection,” *Big Data Research*, vol. 30, p. 100359, 2022.
- [18] J. Gama, I. Zliobaitė, A. Bifet, M. Pechenizkiy, and A. Bouchachia, “A survey on concept drift adaptation,” *ACM Computing Surveys*, vol. 46, no. 4, pp. 1–37, 2014.
- [19] V. Chandola, A. Banerjee, and V. Kumar, “Anomaly detection: A survey,” *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009.
- [20] L. Ruff, J. R. Kauffmann, R. A. Vandermeulen, G. Montavon, W. Samek, M. Kloft, T. G. Dietterich, and K.-R. Müller, “A unifying review of deep and shallow anomaly detection,” *Proceedings of the IEEE*, vol. 109, no. 5, pp. 756–795, 2021.
- [21] M. Lopez-Martin, B. Carro, A. Sanchez-Esguevillas, and J. Lloret, “Conditional variational autoencoder for prediction and feature recovery applied to intrusion detection in iot,” *Sensors*, vol. 17, no. 9, p. 1967, 2017.
- [22] T. Hasan, A. Hossain, M. Q. Ansari, and T. H. Syed, “Enhanced intrusion detection in IIoT networks: A lightweight approach with autoencoder-based feature learning,” 2025. arXiv:2501.15266.
- [23] Canadian Institute for Cybersecurity and Communications Security Establishment, “CSE-CIC-IDS2018 dataset: A collaborative project between the Communications Security Establishment (CSE) and the Canadian Institute for Cybersecurity (CIC).” <https://www.unb.ca/cic/datasets/ids-2018.html>, 2018.
- [24] L. D’hooge, T. Wauters, B. Volckaert, and F. De Turck, “Inter-dataset generalization strength of supervised machine learning methods for intrusion detection,” *Journal of Information Security and Applications*, vol. 54, p. 102564, 2020.
- [25] M. Cantone, C. Marrocco, and A. Bria, “Machine learning in network intrusion detection: A cross-dataset generalization study,” *IEEE Access*, vol. 12, 2024.

- [26] P. Goldschmidt and D. Chudá, “Network intrusion datasets: A survey, limitations, and recommendations,” *Computers & Security*, vol. 156, p. 104510, 2025.