

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá chống rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³

FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Vì sao điểm F1 trên 0,99 chưa chắc đáng tin.

II. QUY TRÌNH ĐÁNH GIÁ

Làm sạch dữ liệu và chặn rò rỉ ở từng bước.

III. KẾT QUẢ VÀ KẾT LUẬN

Sáu kết quả, từ giảm đặc trưng đến chuyển sang mạng khác.

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 trên 0,99 với CICIDS2017: điểm đó có đáng tin không?

Hai câu hỏi

1. Cần cả ≈ 80 đặc trưng không?

Nhiều đặc trưng thì tốn tính toán, khó chạy trên thiết bị biên.

2. Điểm cao có đáng tin không?

Hai dạng rò rỉ dữ liệu làm điểm cao hơn thực tế:

- Cổng đích: mỗi loại tấn công nhắm vào một số cổng cố định, nên **cổng gần như tiết lộ nhãn**.
- Luồng trùng lặp ở cả hai tập: mô hình **đã thấy dữ liệu kiểm tra khi huấn luyện**.

Bài báo này

Sửa quy trình đánh giá *trước*, rồi mới so sánh các phương pháp giảm đặc trưng.


Thông điệp

Đánh giá đúng cách quan trọng không kém *chọn đúng phương pháp*.

1. So sánh **4 phương pháp giảm đặc trưng** (giữ toàn bộ, RF Importance, SHAP, PCA) trên *cùng* 8 thuật toán Spark ML.
2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng đích, bỏ luồng trùng lặp trước khi chia dữ liệu, tập kiểm tra chỉ dùng một lần ở cuối.
3. **Kiểm định thống kê** để kết luận, thay vì chỉ so sánh điểm số.
4. Đánh giá hai khía cạnh mà điểm F1 tổng che khuất: **từng loại tấn công** và **đổi sang bộ dữ liệu khác**.
5. Chọn cấu hình **phù hợp thiết bị biên** Jetson Orin Nano Super.

II. QUY TRÌNH ĐÁNH GIÁ

Quy trình: mỗi bước chặn một đường rò rỉ



- Bỏ cổng đích: mô hình không thể **suy ra loại tấn công từ số cổng**.
- Bỏ trùng lặp *trước* khi chia: không luồng nào ở cả hai tập.
- Xếp hạng đặc trưng chỉ tính trên *tập huấn luyện*.
- Chọn mô hình trên *tập kiểm định* (validation). Tập kiểm tra **chỉ dùng một lần**, ở cuối.
- Siêu tham số **cố định từ trước**, dùng chung cả 4 phương pháp.

Loại bỏ luồng trùng lặp: phải làm đúng cách

- Nhiều luồng **giống hệt nhau** ở mọi đặc trưng → chỉ giữ lại *một* luồng.
- Có những nhóm giống hệt nhau nhưng **nhãn khác nhau** (vừa Benign vừa Attack): lỗi đã biết của CICIDS2017.
- Nhóm như vậy được **bỏ cả nhóm: 270 nhóm, 44.260 luồng**.
- Nếu giữ ngẫu nhiên một luồng thì *mỗi lần chạy cho một bộ dữ liệu khác*. Bỏ cả nhóm thì kết quả tái lập được.

Dữ liệu sau khi làm sạch

Đặc trưng	77
Luồng huấn luyện	1.785.349
Luồng kiểm tra	447.275
CSE-CIC-IDS2018 (lấy mẫu 20%)	≈2,39 triệu

Huấn luyện trên cụm Spark gồm **2 Jetson Orin Nano Super**, máy chủ chỉ điều phối.

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Phương pháp	Số đặc trưng	F1	Huấn luyện (phút)
Toàn bộ	77	0,9971	77
SHAP Top-30	30	0,9970	20
PCA $k=40$	40	0,9939	24
RF Top-30	30	0,9922	22

XGBoost, một lần chạy trên cách chia huấn luyện/kiểm tra gốc.

- SHAP giữ **30/77 đặc trưng**, F1 gần như không đổi, huấn luyện **nhANH gẤP 3,8 lần**.
- Cùng 30 đặc trưng, **SHAP chọn tốt hơn RF**.
- PCA cần 40 thành phần, F1 thấp hơn và **không giải thích được**.

Chọn **SHAP Top-30**: ít đặc trưng, huấn luyện nhanh, giải thích được.

Kết quả 2: cổng đích làm tăng điểm, mức tăng tùy mô hình

Nhóm mô hình	F1 tăng khi giữ cổng
Cây (4 thuật toán)	dưới 0,002
MLP, Naive Bayes	0,005 và 0,011
Tuyến tính (LR, SVM)	khoảng 0,04


Mỗi thuật toán huấn luyện hai lần trên cùng một cách chia dữ liệu:
một lần bỏ cổng đích, một lần giữ.

- **Mô hình cây** hầu như không cần cổng đích.
- **Mô hình tuyến tính** dựa vào cổng đích nhiều: F1 tăng **gấp hơn 20 lần** so với mô hình cây.

Mức rò rỉ đo trên *một* mô hình không suy ra được cho mô hình khác. Mọi kết quả sau đây đều đã bỏ cổng đích.

Kết quả 3: 77 hay 30 đặc trưng, F1 tương đương về mặt thống kê

XGBoost, $N=6$ lần chạy	F1 trung bình
Toàn bộ 77 đặc trưng	0,99734
SHAP Top-30	0,99720
Chênh lệch	$\approx 0,0001$



Phép thống kê	Dùng để làm gì, vì sao chọn	Kết quả
1. CI95 Nadeau–Bengio	Sai số F1. Các lần chạy chung dữ liệu, CI thường hẹp quá.	$\pm 0,00012$ và $\pm 0,00015$
2. Hoán vị ghép cặp	Có khác không? So theo cặp, chính xác với 6 cặp.	$p = 0,031$ (mức nhỏ nhất với 6 cặp): có khác, rất nhỏ. $d \approx 1,94$ lớn do 6 lần chạy rất sát.
3. TOST (tương đương)	Có tương đương không? Phép 2 không trả lời được.	$p = 3,9 \times 10^{-6}$: tương đương

Khác biệt không đáng kể: chọn **SHAP Top-30**, ít đặc trưng, giải thích được.

Kết quả 4: điểm tổng 0,998 che khuất các loại tấn công hiểm

Loại lưu lượng	Số mẫu	Tỉ lệ phát hiện
Benign	380.119	99,97%
DoS Hulk	34.446	99,04%
Web – Brute Force	311	72,99%
Bot	290	45,52%
Web – XSS	111	2,70%
Web – SQL Injection	6	0%

Random Forest, 77 đặc trưng. Tỉ lệ phát hiện = recall.

- F1 chung (weighted): **0,998**.
- F1 trung bình lớp (macro): **0,806**.
- **Nhầm loại, vẫn phát hiện:** **76% XSS** vẫn bị báo là tấn công.
- **Bỏ sót:** cả 6 SQL Injection và **54% Bot** bị xếp vào bình thường.

Lớp càng ít mẫu càng dễ bị bỏ sót, và điểm tổng không phản ánh điều đó.

Kết quả 5: đối sang bộ dữ liệu khác, điểm số giảm mạnh

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,995	1,00
2017 → 2018	0,03–0,30	0,48
2018 → 2018	0,925	0,97
2018 → 2017	0,05	0,19

2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018.

Mô hình **bỏ sót gần hết** tấn công của mạng mới: chỉ phát hiện được khoảng 7% và 3% số tấn công.

F1 chiều 2017 → 2018 qua 18 lần chạy



Cùng mã, cùng dữ liệu mà F1 **rơi vào hai cụm tách biệt**. Một lần chạy **không đủ tin cậy** → báo cả 18 lần và so sánh bằng **AUC-PR**.

Điểm cao trên một bộ dữ liệu **không đảm bảo** hoạt động tốt trên mạng khác.

Kết quả 6: gán nhãn 1% dữ liệu mạng mới rồi huấn luyện lại là đủ

Phương pháp (F1)	2017→2018	2018→2017
Dùng trực tiếp mô hình cũ	0,03–0,30	0,05
Chỉnh phân phối, không nhãn (CORAL)	0	0
Huấn luyện lại, 1% nhãn mạng mới	0,92	0,99
1% đó + toàn bộ dữ liệu cũ	0,80	0,96

- Chỉ chỉnh phân phối, không nhãn: **không hiệu quả**, vì khác biệt nằm ở chính hành vi tấn công.
- Chỉ cần khoảng **19 nghìn luồng có nhãn**.
- Gộp thêm dữ liệu cũ **làm F1 giảm**.

Sang mạng mới cần **thích ứng miền** (domain adaptation). Cách ít tốn kém nhất ở đây: gán nhãn một phần nhỏ lưu lượng của chính mạng đó.

Kết quả chính

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi, *có kiểm định thống kê*.
- Điểm F1 tổng cao **che khuất tấn công hiếm**.
- Đổi bộ dữ liệu thì **điểm giảm mạnh**, và F1 của một lần chạy không đủ tin cậy.
- Mạng mới: **gán nhãn một phần nhỏ dữ liệu** là đủ; căn chỉnh không nhãn thì không.

Bài học

- **Đánh giá đúng cách** quan trọng không kém chọn đúng phương pháp.

Hướng phát triển

- Đo riêng tác động của bước bỏ trùng lặp.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Bộ 30 đặc trưng SHAP có dùng được cho bộ dữ liệu khác?

Xin cảm ơn. Kính mời câu hỏi

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**
- [3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **rò rỉ**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Mach. Learn. 52(3), 2003. **khoảng tin cậy**
- [6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**
- [7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**
- [8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **bộ dữ liệu thứ hai**
- [9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**
- [10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

Slide dự phòng

Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng

Thuật toán (F1)	RF Top-30	SHAP Top-30	Chênh lệch
Random Forest	0,9879	0,9955	+0,008
XGBoost	0,9922	0,9970	+0,005
GBT	0,9844	0,9918	+0,007
Decision Tree	0,9835	0,9948	+0,011


SHAP chọn cho F1 cao hơn RF chọn ở cả bốn thuật toán cây.

Dự phòng: công đích theo từng thuật toán

Thuật toán	Bỏ công đích	Giữ công đích	Chênh lệch
SVM (LinearSVC)	0,7859	0,8274	+0,0415
Logistic Regression	0,7986	0,8381	+0,0395
Naive Bayes	0,2985	0,3093	+0,0108
MLP	0,9660	0,9711	+0,0052
GBT	0,9924	0,9941	+0,0017
Decision Tree	0,9953	0,9966	+0,0014
Random Forest	0,9954	0,9964	+0,0010
XGBoost	0,9972	0,9979	+0,0007

F1 nhị phân, hai lượt trên cùng một cách chia dữ liệu.

Dự phòng: ma trận nhầm lẫn theo từng loại tấn công



Random Forest, toàn bộ 77 đặc trưng. Mỗi hàng chuẩn hóa theo số mẫu thật của lớp đó.

Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 $\pm$ CI95 (t)	CI95 (N-B)
Toàn bộ 77	0,99734 $\pm$ 0,00007	$\pm$ 0,00012
SHAP Top-30	0,99720 $\pm$ 0,00009	$\pm$ 0,00015
hoán vị ghép cặp $p = 0,031$, Cohen's $d \approx 1,94$		
TOST (hai kiểm định một phía)		
Biên tương đương, khai báo trước	$\pm 0,001$ F1	
Sai số dùng để kiểm định	Nadeau-Bengio	
p_{TOST}	$3,9 \times 10^{-6}$	
Biên nhỏ nhất chứng minh được ($\alpha=0,05$)	$\pm 2,3 \times 10^{-4}$	

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ seed ngẫu nhiên.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0,031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau-Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương. TOST kiểm định trực tiếp điều đó.


Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,9953	0,9997
2017 → 2018 (11 lần)	0,029–0,085	0,4778
2017 → 2018 (7 lần)	0,185–0,301	0,4960
2018 → 2018	0,9246	0,9679
2018 → 2017	0,0544 ± 0,0019	0,1926

18 lần chạy cùng mã và dữ liệu (13 seed, trong đó 5 seed chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống, và CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch $|t|=1,3$): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 seed chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần. CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

Dự phòng: heatmap F1, phương pháp × thuật toán




Phân loại nhị phân, đã bỏ cổng đích. 8 thuật toán × 4 phương pháp.

Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trọng số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost. MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó), đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Độ trễ và thông lượng *trên thiết bị biên* thuộc bài hệ thống đi kèm.

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại, nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ dữ liệu không tắt định giữa các lượt chạy, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: mức đóng góp của từng đặc trưng theo SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.