

# Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

---

**Nguyễn Vũ Thái**<sup>1</sup>    Bùi Văn Dũng<sup>2</sup>    Đỗ Trí Nhựt<sup>2</sup>    Nguyễn Văn Dũ<sup>3</sup>

FAIR'2026

<sup>1</sup>Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

<sup>2</sup>Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

<sup>3</sup>Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

# I. VẤN ĐỀ VÀ ĐÓNG GÓP

---

# F1 gần như tuyệt đối trên CICIDS2017: nên nghi ngờ

## Hai câu hỏi

### 1. Có cần đủ $\approx 80$ đặc trưng không?

Nhiều đặc trưng thì tốn tính toán, khó chạy trên thiết bị biên.

### 2. Điểm số cao có đáng tin không?

Hai lỗi phổ biến làm điểm cao giả:

- `destination_port` **lộ luôn loại tấn công.**
- Luồng trùng nhau nằm ở cả tập huấn luyện *lẫn* tập kiểm tra: mô hình **được xem trước đáp án.**

## Bài báo này

Sửa cách đánh giá cho đúng *trước*, rồi mới so sánh các cách giảm đặc trưng.

## Thông điệp


**Đo thế nào** quan trọng ngang với *phương pháp nào thắng*.

1. So sánh **4 cách giảm đặc trưng** (giữ hết, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng, bỏ luồng trùng trước khi chia, không dùng tập kiểm tra để chọn bất cứ thứ gì.
3. **Kiểm định thống kê** thay vì so điểm bằng mắt.
4. Soi những chỗ điểm tổng hay che giấu: **từng loại tấn công**, và khi **đổi sang bộ dữ liệu khác**.
5. Chọn cấu hình **hợp với thiết bị biên** Jetson Orin Nano Super.

## II. QUY TRÌNH ĐÁNH GIÁ

---

## Quy trình: mỗi bước chặn một đường rò rỉ



- Bỏ cổng: mô hình không đoán được **loại tấn công từ số cổng**.
- Bỏ trùng *trước* khi chia: không luồng nào ở cả hai tập.
- Xếp hạng đặc trưng chỉ tính trên *tập huấn luyện*.
- Tập kiểm tra **chỉ dùng một lần**, ở cuối.

## Bỏ luồng trùng, nhưng phải bỏ cho đúng

- Nhiều luồng **giống hệt nhau** ở mọi đặc trưng → chỉ giữ *một* bản.
- Có nhóm giống hệt nhau mà **nhấn lại khác nhau** (vừa Benign vừa Attack) — lỗi đã biết của CICIDS2017.
- Nhóm như vậy **bỏ cả nhóm: 270 nhóm, 44.260 dòng**.
- Nếu giữ ngẫu nhiên một dòng, *mỗi lần chạy ra một bộ dữ liệu khác*. Bỏ cả nhóm thì kết quả luôn như nhau.

---

### Dữ liệu sau khi làm sạch

---

|                  |           |
|------------------|-----------|
| Đặc trưng        | 77        |
| Luồng huấn luyện | 1.785.349 |
| Luồng kiểm tra   | 447.275   |

---

| CSE-CIC-IDS2018 (lấy mẫu 20%) | ≈2,39 triệu |

Huấn luyện trên cụm Spark gồm **2 Jetson Orin Nano Super**; máy chủ chỉ điều phối.

### **III. KẾT QUẢ VÀ KẾT LUẬN**

---

## Kết quả 1: bỏ được 60% đặc trưng mà F1 gần như không đổi

| Cách giảm (XGBoost) | Đặc trưng | F1            | Huấn luyện (s) |
|---------------------|-----------|---------------|----------------|
| Giữ hết             | 77        | 0,9971        | 4615,5         |
| <b>SHAP Top-30</b>  | <b>30</b> | <b>0,9970</b> | <b>1226,1</b>  |
| PCA $k=40$          | 40        | 0,9939        | 1444,8         |
| RF Top-30           | 30        | 0,9922        | 1295,1         |

| Cùng 30 đặc trưng | RF chọn | SHAP chọn | SHAP hơn |
|-------------------|---------|-----------|----------|
| Random Forest     | 0,9879  | 0,9955    | +0,77%   |
| XGBoost           | 0,9922  | 0,9970    | +0,48%   |
| GBT               | 0,9844  | 0,9918    | +0,75%   |
| Decision Tree     | 0,9835  | 0,9948    | +1,15%   |

- SHAP giữ **30/77 đặc trưng**, F1 gần như không đổi, huấn luyện **nhANH gần 4 lần**.
- Cùng 30 đặc trưng, **SHAP chọn tốt hơn RF** ở cả 4 thuật toán cây.
- PCA cần 40 thành phần và **không giải thích được**.

## Kết quả 2: công đích giúp mô hình “ăn gian” nhiều hay ít tùy loại mô hình

| Thuật toán          | Bỏ cổng | Giữ cổng | Chênh          |
|---------------------|---------|----------|----------------|
| SVM (LinearSVC)     | 0,7859  | 0,8274   | <b>+0,0415</b> |
| Logistic Regression | 0,7986  | 0,8381   | <b>+0,0395</b> |
| Naive Bayes         | 0,2985  | 0,3093   | +0,0108        |
| MLP                 | 0,9660  | 0,9711   | +0,0052        |
| GBT                 | 0,9924  | 0,9941   | +0,0017        |
| Decision Tree       | 0,9953  | 0,9966   | +0,0014        |
| Random Forest       | 0,9954  | 0,9964   | +0,0010        |
| XGBoost             | 0,9972  | 0,9979   | +0,0007        |

F1 nhị phân; hai lượt trên cùng một cách chia dữ liệu.

- **Mô hình cây** hầu như không cần cổng: chênh  $\leq 0,002$ .
- **Mô hình tuyến tính** dựa vào cổng nhiều: chênh tới 0,04, **gấp khoảng 40 lần**.

Đo rò rỉ trên *một* mô hình không nói được gì cho mô hình khác. Mọi kết quả sau đều đã bỏ cổng.


## Kết quả 3: giữ hết hay giữ 30 đặc trưng — thực chất như nhau

| XGBoost, 6 lần lặp   | F1 trung bình                      |
|----------------------|------------------------------------|
| Giữ hết 77 đặc trưng | 0,99734                            |
| SHAP Top-30          | 0,99720                            |
| <b>Chênh lệch</b>    | <b><math>\approx 0,0001</math></b> |

- Lặp lại với **6 cách chia dữ liệu khác nhau**, so từng cặp.
- Không chỉ hỏi “có khác không” mà **chứng minh** hai bên tương đương (kiểm định TOST).
- Kết quả: chênh lệch thật **nhỏ hơn 0,00023 F1**.

Hai cấu hình tương đương, nên chọn **SHAP Top-30**: ít đặc trưng hơn và giải thích được.

### Kết quả 4: điểm tổng 0,998 che mất các loại tấn công hiểm



| Loại lưu lượng                 | Số mẫu  | Bắt được                         | F1     |
|--------------------------------|---------|----------------------------------|--------|
| Random Forest, đủ 77 đặc trưng |         |                                  |        |
| Benign                         | 380.119 | 99,97%                           | 0,9989 |
| DoS Hulk                       | 34.446  | 99,04%                           | 0,9947 |
| Web – Brute Force              | 311     | 72,99%                           | 0,7323 |
| Bot                            | 290     | <b>45,52%</b>                    | 0,6256 |
| Web – XSS                      | 111     | <b>2,70%</b>                     | 0,0526 |
| Web – SQL Injection            | 6       | <b>0%</b>                        | 0,0000 |
| F1 có trọng số = 0,998         |         | <b>F1 trung bình lớp = 0,806</b> |        |

- **Nhầm loại nhưng vẫn bắt:** **76% XSS** vẫn bị báo là tấn công.
- **Lọt lưới:** cả 6 SQL Injection, **54% Bot** bị coi là bình thường.

## Kết quả 5: đối sang bộ dữ liệu khác, điểm số sụp

| Huấn luyện → Kiểm tra | F1        | AUC-PR |
|-----------------------|-----------|--------|
| 2017 → 2017           | 0,995     | 1,00   |
| 2017 → 2018           | 0,03–0,30 | 0,48   |
| 2018 → 2018           | 0,925     | 0,97   |
| 2018 → 2017           | 0,05      | 0,19   |

2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018.

Mô hình **bỏ sót gần hết** tấn công của mạng mới: trung bình chỉ bắt được 3–7%.

### F1 chiều 2017 → 2018 qua 18 lần chạy



Cùng mã, cùng dữ liệu mà F1 **rơi vào hai cụm**. Một lần chạy **không đáng tin** → báo cả 18 lần và so bằng **AUC-PR**.

Điểm cao trên một bộ dữ liệu **không đảm bảo** chạy tốt trên mạng khác.

## Kết quả 6: muốn chạy tốt trên mạng mới, hãy gán nhãn một ít dữ liệu của nó

| Cách làm (F1)                       | 2017→2018   | 2018→2017   |
|-------------------------------------|-------------|-------------|
| Không làm gì                        | 0,03–0,30   | 0,05        |
| Chỉnh thang đo (scaler, CORAL)      | <b>0</b>    | <b>0</b>    |
| Học lại với <b>1%</b> nhãn mạng mới | <b>0,92</b> | <b>0,99</b> |
| 1% đó + toàn bộ dữ liệu cũ          | 0,80        | 0,96        |

- Chỉ chỉnh thang đo thì **không đủ**: khác biệt nằm ở chính hành vi tấn công.
- Khoảng **19 nghìn luồng có nhãn** là đủ.
- Thêm dữ liệu cũ vào **còn làm kém đi**.

Chuyển mô hình sang mạng mới cần **thích ứng miễn**; cách rẻ nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

## Những gì đã chỉ ra

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi — *đã kiểm định*.
- Điểm tổng cao **che mất tấn công hiểm**.
- Đổi bộ dữ liệu là **điểm sụp**; F1 của một lần chạy không đáng tin.
- Mạng mới: **gán nhãn một ít dữ liệu** hiệu quả hơn chỉnh thang đo.

## Bài học

- **Đo thế nào** quan trọng ngang với phương pháp nào thắng.

## Hướng tiếp theo

- Đo riêng tác động của bước bỏ luồng trùng.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Tập SHAP Top-30 có dùng được cho bộ khác?

**Xin cảm ơn — kính mời câu hỏi**

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**
- [3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**
- [6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**
- [7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**
- [8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**
- [9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**
- [10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

**Slide dự phòng**

## Dự phòng: chi tiết kiểm định thống kê

| XGBoost                                                 | F1 $\pm$ CI95 ( $t$ )    | CI95 (N-B)    |
|---------------------------------------------------------|--------------------------|---------------|
| Giữ hết                                                 | 0,99734 $\pm$ 0,00007    | $\pm$ 0,00012 |
| SHAP Top-30                                             | 0,99720 $\pm$ 0,00009    | $\pm$ 0,00015 |
| hoán vị ghép cặp $p = 0,031$ ; Cohen's $d \approx 1,94$ |                          |               |
| <b>TOST</b> (hai kiểm định một phía)                    |                          |               |
| Biên tương đương, khai báo trước                        | $\pm 0,001$ F1           |               |
| Sai số dùng để kiểm định                                | Nadeau-Bengio            |               |
| $p_{\text{TOST}}$                                       | $3,9 \times 10^{-6}$     |               |
| Biên nhỏ nhất chứng minh được ( $\alpha=0,05$ )         | $\pm 2,3 \times 10^{-4}$ |               |

- $N=6$  lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, liệt kê đủ  $2^6$  tổ hợp dấu:  $p$  nhỏ nhất là  $2/2^6 \approx 0,031$ , nên  $N \geq 6$  là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của  $t$ , nên dùng CI hiệu chỉnh Nadeau-Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương; TOST kiểm định trực tiếp điều đó.


## Dự phòng: chi tiết liên bộ dữ liệu

| Huấn luyện → Kiểm tra | F1              | AUC-PR |
|-----------------------|-----------------|--------|
| 2017 → 2017           | 0,9953          | 0,9997 |
| 2017 → 2018 (11 lần)  | 0,029–0,085     | 0,4778 |
| 2017 → 2018 (7 lần)   | 0,185–0,301     | 0,4960 |
| 2018 → 2018           | 0,9246          | 0,9679 |
| 2018 → 2017           | 0,0544 ± 0,0019 | 0,1926 |

18 lần chạy cùng mã và dữ liệu (13 hạt giống, 5 hạt giống chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống; CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch  $|t|=1,3$ ): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 hạt giống chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần; CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

# Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhi phân, đã bỏ công. 8 thuật toán × 4 phương pháp.

## Dự phòng: siêu tham số, cố định từ trước

| Mô hình             | Siêu tham số chính                                                   |
|---------------------|----------------------------------------------------------------------|
| Decision Tree       | maxDepth=15, minInstancesPerNode=5, impurity=entropy                 |
| Logistic Regression | maxIter=200, regParam=0.001, L2, threshold=0.5                       |
| SVM (LinearSVC)     | maxIter=200, regParam=0.001                                          |
| Naive Bayes         | gaussian, smoothing=1.0                                              |
| Random Forest       | numTrees=200, maxDepth=15, featureSubset=sqrt                        |
| GBT                 | maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8                |
| XGBoost             | n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8 |
| MLP                 | layers=[d,64,32,2], maxIter=150, stepSize=0.01                       |

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trọng số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost; MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86\_64, còn đích triển khai là ARM64.

# Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Độ trễ và thông lượng *trên thiết bị biên* thuộc bài hệ thống đi kèm.

## Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch  $\leq 7,4 \times 10^{-5}$ , và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.**  $N=6$  cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn  $p$  ở mức  $2/2^N$ , nên  $N=6$  vừa đủ chạm 0,05. Kết luận tương đương không dựa vào  $p$  đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lỏng lẻo với  $N$  lớn hơn là hướng củng cố tiếp theo.

# Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.