

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³

FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như tuyệt đối trên CICIDS2017: cần kiểm chứng

Hai câu hỏi

1. Có cần đủ ≈ 80 đặc trưng không?

Càng nhiều đặc trưng càng tốn tính toán, khó chạy trên thiết bị biên.

2. Điểm cao có đáng tin không?

Hai lỗi khiến điểm cao hơn thực tế:

- Cổng đích: mỗi loại tấn công nhắm vào một số cổng cố định, nên **cổng gần như tiết lộ nhãn**.
- Luồng trùng nhau nằm ở cả tập huấn luyện lẫn tập kiểm tra: mô hình **đã gặp dữ liệu kiểm tra từ trước**.

Bài báo này

Sửa cách đánh giá cho đúng *trước*, rồi mới so sánh các cách giảm đặc trưng.


Thông điệp

Đo thế nào quan trọng không kém *phương pháp nào thắng*.

1. So sánh **4 cách giảm đặc trưng** (giữ hết, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng, bỏ luồng trùng trước khi chia, không dùng tập kiểm tra để chọn bất cứ thứ gì.
3. **Kiểm định thống kê** thay vì chỉ so sánh điểm số.
4. Đánh giá những gì điểm tổng thường che khuất: **từng loại tấn công**, và khi **đổi sang bộ dữ liệu khác**.
5. Chọn cấu hình **hợp với thiết bị biên** Jetson Orin Nano Super.

II. QUY TRÌNH ĐÁNH GIÁ

Quy trình: mỗi bước chặn một đường rò rỉ



- Bỏ cổng: mô hình không suy ra được **loại tấn công từ số cổng**.
- Bỏ trùng *trước* khi chia: không luồng nào ở cả hai tập.
- Xếp hạng đặc trưng chỉ tính trên *tập huấn luyện*.
- Chọn mô hình trên *tập validation*. Tập kiểm tra **chỉ dùng một lần**, ở cuối.
- Siêu tham số **cố định từ trước**, dùng chung cho cả 4 cách.

Bỏ luồng trùng, nhưng phải bỏ cho đúng

- Nhiều luồng **giống hệt nhau** ở mọi đặc trưng → chỉ giữ *một* bản.
- Có nhóm giống hệt nhau mà **nhấn lại khác nhau** (vừa Benign vừa Attack), một lỗi đã biết của CICIDS2017.
- Nhóm như vậy **bỏ cả nhóm: 270 nhóm, 44.260 dòng**.
- Nếu giữ ngẫu nhiên một dòng, *mỗi lần chạy ra một bộ dữ liệu khác*. Bỏ cả nhóm thì kết quả luôn như nhau.

Dữ liệu sau khi làm sạch

Đặc trưng	77
Luồng huấn luyện	1.785.349
Luồng kiểm tra	447.275

| CSE-CIC-IDS2018 (lấy mẫu 20%) | ≈2,39 triệu |

Huấn luyện trên cụm Spark gồm **2 Jetson Orin Nano Super**, máy chủ chỉ điều phối.

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Cách giảm	Đặc trưng	F1	Phút huấn luyện
Giữ hết	77	0,9971	77
SHAP Top-30	30	0,9970	20
PCA $k=40$	40	0,9939	24
RF Top-30	30	0,9922	22

XGBoost, một lần chạy trên cách chia train/test gốc.

- SHAP giữ **30/77 đặc trưng**, F1 gần như không đổi, huấn luyện **nhANH gấp 3,8 lần**.
- Cùng 30 đặc trưng, **SHAP chọn tốt hơn RF**.
- PCA cần 40 thành phần và **không giải thích được**.

Chọn **SHAP Top-30**: ít đặc trưng, huấn luyện nhanh, giải thích được.

Kết quả 2: công đích làm tăng điểm, mức độ tùy mô hình

Nhóm mô hình	F1 tăng khi giữ cổng
Cây (4 thuật toán)	dưới 0,002
MLP, Naive Bayes	0,005 và 0,011
Tuyến tính (LR, SVM)	khoảng 0,04

Mỗi thuật toán huấn luyện hai lần trên cùng một cách chia dữ liệu:
bỏ cổng và giữ cổng.

- **Mô hình cây** hầu như không cần cổng.
- **Mô hình tuyến tính** dựa vào cổng nhiều, **gấp hơn 20 lần** mô hình cây.

Đo rò rỉ trên *một* mô hình không nói được gì cho mô hình khác. Mọi kết quả sau đều đã bỏ cổng.

Kết quả 3: giữ 77 hay 30 đặc trưng thì cũng như nhau

XGBoost	F1 trung bình
Giữ hết 77 đặc trưng	0,99734
SHAP Top-30	0,99720
Chênh lệch	$\approx 0,0001$

Trung bình 6 lần chạy, nên lệch chút ít so với Kết quả 1.

- Lặp lại với **6 cách chia dữ liệu khác nhau**, so từng cặp.
- Không chỉ hỏi “có khác không” mà **chứng minh** hai bên tương đương (kiểm định TOST).
- Kết quả: chênh lệch thật **nhỏ hơn 0,00023 F1**.

Hai cấu hình tương đương, nên chọn **SHAP Top-30**: ít đặc trưng hơn và giải thích được.

Kết quả 4: điểm tổng 0,998 che khuất các loại tấn công hiểm

Loại lưu lượng	Số mẫu	Tỉ lệ phát hiện
Benign	380.119	99,97%
DoS Hulk	34.446	99,04%
Web – Brute Force	311	72,99%
Bot	290	45,52%
Web – XSS	111	2,70%
Web – SQL Injection	6	0%

Random Forest, đủ 77 đặc trưng, phân loại theo từng loại tấn công.

Loại càng ít mẫu thì càng dễ bị bỏ sót, mà điểm tổng không cho thấy điều đó.

- Tính theo số mẫu: F1 = **0,998**.
- Tính đều cho từng loại: F1 = **0,806**.
- **Nhầm loại nhưng vẫn phát hiện: 76% XSS** vẫn bị báo là tấn công.
- **Bỏ sót:** cả 6 SQL Injection và **54% Bot** bị phân loại là bình thường.


Kết quả 5: đối sang bộ dữ liệu khác, điểm số giảm mạnh

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,995	1,00
2017 → 2018	0,03–0,30	0,48
2018 → 2018	0,925	0,97
2018 → 2017	0,05	0,19

2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018.

Mô hình **bỏ sót gần hết** tấn công của mạng mới: chỉ phát hiện được khoảng 7% và 3%.

F1 chiều 2017 → 2018 qua 18 lần chạy



Cùng mã, cùng dữ liệu mà F1 **rơi vào hai cụm**. Một lần chạy **không đủ tin cậy** → báo cả 18 lần và so bằng **AUC-PR**.

Điểm cao trên một bộ dữ liệu **không đảm bảo** hoạt động tốt trên mạng khác.

Kết quả 6: học lại với 1% nhãn của mạng mới là đủ

Cách làm (F1)	2017→2018	2018→2017
Không làm gì	0,03–0,30	0,05
Căn chỉnh không nhãn (CORAL)	0	0
Học lại với 1% nhãn mạng mới	0,92	0,99
1% đó + toàn bộ dữ liệu cũ	0,80	0,96

- Căn chỉnh dữ liệu mà không có nhãn thì **không khắc phục được**: khác biệt nằm ở chính hành vi tấn công.
- Khoảng **19 nghìn luồng có nhãn** là đủ.
- Thêm dữ liệu cũ vào **làm kết quả giảm**.

Chuyển mô hình sang mạng mới cần **thích ứng miễn**. Cách ít tổn kém nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

Những gì đã chỉ ra

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi, *đã kiểm định*.
- Điểm tổng cao **che khuất tấn công hiểm**.
- Đổi bộ dữ liệu thì **điểm giảm mạnh**, và F1 của một lần chạy không đủ tin cậy.
- Mạng mới: **gán nhãn một ít dữ liệu** thì được, căn chỉnh không nhãn thì không.

Bài học

- **Đo thế nào** quan trọng không kém phương pháp nào thắng.

Hướng tiếp theo

- Đo riêng tác động của bước bỏ luồng trùng.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Tập SHAP Top-30 có dùng được cho bộ khác?

Xin cảm ơn. Kính mời câu hỏi

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**
- [3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**
- [6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**
- [7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**
- [8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**
- [9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**
- [10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

Slide dự phòng

Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng

F1	RF chọn	SHAP chọn	Chênh
Random Forest	0,9879	0,9955	+0,008
XGBoost	0,9922	0,9970	+0,005
GBT	0,9844	0,9918	+0,007
Decision Tree	0,9835	0,9948	+0,011


SHAP chọn cho F1 cao hơn RF chọn ở cả bốn thuật toán cây.

Dự phòng: cổng đích theo từng thuật toán

Thuật toán	Bỏ cổng	Giữ cổng	Chênh
SVM (LinearSVC)	0,7859	0,8274	+0,0415
Logistic Regression	0,7986	0,8381	+0,0395
Naive Bayes	0,2985	0,3093	+0,0108
MLP	0,9660	0,9711	+0,0052
GBT	0,9924	0,9941	+0,0017
Decision Tree	0,9953	0,9966	+0,0014
Random Forest	0,9954	0,9964	+0,0010
XGBoost	0,9972	0,9979	+0,0007

F1 nhị phân, hai lượt trên cùng một cách chia dữ liệu.

Dự phòng: ma trận nhầm lẫn theo từng loại tấn công



Random Forest, đủ 77 đặc trưng. Mỗi hàng chuẩn hóa theo số mẫu thật của lớp đó.

Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 $\pm$ CI95 (t)	CI95 (N-B)
Giữ hết	0,99734 $\pm$ 0,00007	$\pm$ 0,00012
SHAP Top-30	0,99720 $\pm$ 0,00009	$\pm$ 0,00015
hoán vị ghép cặp $p = 0,031$, Cohen's $d \approx 1,94$		
TOST (hai kiểm định một phía)		
Biên tương đương, khai báo trước	$\pm 0,001$ F1	
Sai số dùng để kiểm định	Nadeau–Bengio	
p_{TOST}	$3,9 \times 10^{-6}$	
Biên nhỏ nhất chứng minh được ($\alpha=0,05$)	$\pm 2,3 \times 10^{-4}$	

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0,031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau–Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương. TOST kiểm định trực tiếp điều đó.


Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,9953	0,9997
2017 → 2018 (11 lần)	0,029–0,085	0,4778
2017 → 2018 (7 lần)	0,185–0,301	0,4960
2018 → 2018	0,9246	0,9679
2018 → 2017	0,0544 ± 0,0019	0,1926

18 lần chạy cùng mã và dữ liệu (13 hạt giống, 5 hạt giống chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống, và CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch $|t|=1,3$): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 hạt giống chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần. CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhi phân, đã bỏ công. 8 thuật toán × 4 phương pháp.

Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trọng số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost. MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó), đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Độ trễ và thông lượng *trên thiết bị biên* thuộc bài hệ thống đi kèm.

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại, nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.