

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³

FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như tuyệt đối trên CICIDS2017: nên nghi ngờ

Hai câu hỏi

1. Có cần đủ ≈ 80 đặc trưng không?

Nhiều đặc trưng thì tốn tính toán, khó chạy trên thiết bị biên.

2. Điểm số cao có đáng tin không?

Hai lỗi phổ biến làm điểm cao giả:

- `destination_port` **lộ luôn loại tấn công.**
- Luồng trùng nhau nằm ở cả tập huấn luyện *lẫn* tập kiểm tra: mô hình **được xem trước đáp án.**

Bài báo này

Sửa cách đánh giá cho đúng *trước*, rồi mới so sánh các cách giảm đặc trưng.


Thông điệp

Đo thế nào quan trọng ngang với *phương pháp nào thắng*.

1. So sánh **4 cách giảm đặc trưng** (giữ hết, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng, bỏ luồng trùng trước khi chia, không dùng tập kiểm tra để chọn bất cứ thứ gì.
3. **Kiểm định thống kê** thay vì so điểm bằng mắt.
4. Soi những chỗ điểm tổng hay che giấu: **từng loại tấn công**, và khi **đổi sang bộ dữ liệu khác**.
5. Chọn cấu hình **hợp với thiết bị biên** Jetson Orin Nano Super.

II. QUY TRÌNH ĐÁNH GIÁ

Quy trình: mỗi bước chặn một đường rò rỉ



- Bỏ cổng: mô hình không đoán được **loại tấn công từ số cổng**.
- Bỏ trùng *trước* khi chia: không luồng nào ở cả hai tập.
- Xếp hạng đặc trưng chỉ tính trên *tập huấn luyện*.
- Tập kiểm tra **chỉ dùng một lần**, ở cuối.

Bỏ luồng trùng, nhưng phải bỏ cho đúng

- Nhiều luồng **giống hệt nhau** ở mọi đặc trưng → chỉ giữ *một* bản.
- Có nhóm giống hệt nhau mà **nhấn lại khác nhau** (vừa Benign vừa Attack) — lỗi đã biết của CICIDS2017.
- Nhóm như vậy **bỏ cả nhóm: 270 nhóm, 44.260 dòng**.
- Nếu giữ ngẫu nhiên một dòng, *mỗi lần chạy ra một bộ dữ liệu khác*. Bỏ cả nhóm thì kết quả luôn như nhau.

Dữ liệu sau khi làm sạch

Đặc trưng	77
Luồng huấn luyện	1.785.349
Luồng kiểm tra	447.275

| CSE-CIC-IDS2018 (lấy mẫu 20%) | ≈2,39 triệu |

Huấn luyện trên cụm Spark gồm **2 Jetson Orin Nano Super**; máy chủ chỉ điều phối.

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ được 60% đặc trưng mà F1 gần như không đổi

Cách giảm (XGBoost)	Đặc trưng	F1	Huấn luyện (s)
Giữ hết	77	0,9971	4615,5
SHAP Top-30	30	0,9970	1226,1
PCA $k=40$	40	0,9939	1444,8
RF Top-30	30	0,9922	1295,1

Một lần chạy, trên cách chia train/test gốc.

Cùng 30 đặc trưng	RF chọn	SHAP chọn	SHAP hơn
Random Forest	0,9879	0,9955	+0,77%
XGBoost	0,9922	0,9970	+0,48%
GBT	0,9844	0,9918	+0,75%
Decision Tree	0,9835	0,9948	+1,15%

- SHAP giữ **30/77 đặc trưng**, F1 gần như không đổi, huấn luyện **nhANH gần 4 lần**.
- Cùng 30 đặc trưng, **SHAP chọn tốt hơn RF** ở cả 4 thuật toán cây.
- PCA cần 40 thành phần và **không giải thích được**.

Kết quả 2: công đích giúp mô hình “ăn gian” nhiều hay ít tùy loại mô hình

Thuật toán	Bỏ cổng	Giữ cổng	Chênh
SVM (LinearSVC)	0,7859	0,8274	+0,0415
Logistic Regression	0,7986	0,8381	+0,0395
Naive Bayes	0,2985	0,3093	+0,0108
MLP	0,9660	0,9711	+0,0052
GBT	0,9924	0,9941	+0,0017
Decision Tree	0,9953	0,9966	+0,0014
Random Forest	0,9954	0,9964	+0,0010
XGBoost	0,9972	0,9979	+0,0007

F1 nhị phân; hai lượt trên cùng một cách chia dữ liệu.

- **Mô hình cây** hầu như không cần cổng: chênh $\leq 0,002$.
- **Mô hình tuyến tính** dựa vào cổng nhiều: chênh tới 0,04, **gấp khoảng 40 lần**.

Đo rò rỉ trên *một* mô hình không nói được gì cho mô hình khác. Mọi kết quả sau đều đã bỏ cổng.

Kết quả 3: giữ hết hay giữ 30 đặc trưng — thực chất như nhau


XGBoost	F1 trung bình
Giữ hết 77 đặc trưng	0,99734
SHAP Top-30	0,99720
Chênh lệch	$\approx 0,0001$

Trung bình 6 lần chạy, mỗi lần một cách chia train/test khác, nên lệch chút ít so với F1 một lần chạy ở Kết quả 1.

- Lặp lại với **6 cách chia dữ liệu khác nhau**, so từng cặp.
- Không chỉ hỏi “có khác không” mà **chứng minh** hai bên tương đương (kiểm định TOST).
- Kết quả: chênh lệch thật **nhỏ hơn 0,00023 F1**.

Hai cấu hình tương đương, nên chọn **SHAP Top-30**: ít đặc trưng hơn và giải thích được.

Kết quả 4: điểm tổng 0,998 che mất các loại tấn công hiểm



Loại lưu lượng	Số mẫu	Bắt được	F1
Random Forest, đủ 77 đặc trưng			
Benign	380.119	99,97%	0,9989
DoS Hulk	34.446	99,04%	0,9947
Web – Brute Force	311	72,99%	0,7323
Bot	290	45,52%	0,6256
Web – XSS	111	2,70%	0,0526
Web – SQL Injection	6	0%	0,0000
F1 có trọng số = 0,998		F1 trung bình lớp = 0,806	

- **Nhầm loại nhưng vẫn bắt:** 76% XSS vẫn bị báo là tấn công.
- **Lọt lưới:** cả 6 SQL Injection, 54% Bot bị coi là bình thường.

Kết quả 5: đổi sang bộ dữ liệu khác, điểm số sụp

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,995	1,00
2017 → 2018	0,03–0,30	0,48
2018 → 2018	0,925	0,97
2018 → 2017	0,05	0,19

2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018.

Mô hình **bỏ sót gần hết** tấn công của mạng mới: trung bình chỉ bắt được 3–7%.

F1 chiều 2017 → 2018 qua 18 lần chạy



Cùng mã, cùng dữ liệu mà F1 **rơi vào hai cụm**. Một lần chạy **không đáng tin** → báo cả 18 lần và so bằng **AUC-PR**.

Điểm cao trên một bộ dữ liệu **không đảm bảo** chạy tốt trên mạng khác.

Kết quả 6: muốn chạy tốt trên mạng mới, hãy gán nhãn một ít dữ liệu của nó

Cách làm (F1)	2017→2018	2018→2017
Không làm gì	0,03–0,30	0,05
Chỉnh thang đo (scaler, CORAL)	0	0
Học lại với 1% nhãn mạng mới	0,92	0,99
1% đó + toàn bộ dữ liệu cũ	0,80	0,96

- Chỉ chỉnh thang đo thì **không đủ**: khác biệt nằm ở chính hành vi tấn công.
- Khoảng **19 nghìn luồng có nhãn** là đủ.
- Thêm dữ liệu cũ vào **còn làm kém đi**.

Chuyển mô hình sang mạng mới cần **thích ứng miễn**; cách rẻ nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

Những gì đã chỉ ra

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi — *đã kiểm định*.
- Điểm tổng cao **che mất tấn công hiểm**.
- Đổi bộ dữ liệu là **điểm sụp**; F1 của một lần chạy không đáng tin.
- Mạng mới: **gán nhãn một ít dữ liệu** hiệu quả hơn chỉnh thang đo.

Bài học

- **Đo thế nào** quan trọng ngang với phương pháp nào thắng.

Hướng tiếp theo

- Đo riêng tác động của bước bỏ luồng trùng.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Tập SHAP Top-30 có dùng được cho bộ khác?

Xin cảm ơn — kính mời câu hỏi

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**
- [3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**
- [6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**
- [7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**
- [8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**
- [9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**
- [10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

Slide dự phòng

Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 $\pm$ CI95 (t)	CI95 (N-B)
Giữ hết	0,99734 $\pm$ 0,00007	$\pm$ 0,00012
SHAP Top-30	0,99720 $\pm$ 0,00009	$\pm$ 0,00015
hoán vị ghép cặp $p = 0,031$; Cohen's $d \approx 1,94$		
TOST (hai kiểm định một phía)		
Biên tương đương, khai báo trước	$\pm 0,001$ F1	
Sai số dùng để kiểm định	Nadeau–Bengio	
p_{TOST}	$3,9 \times 10^{-6}$	
Biên nhỏ nhất chứng minh được ($\alpha=0,05$)	$\pm 2,3 \times 10^{-4}$	

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0,031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau–Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương; TOST kiểm định trực tiếp điều đó.


Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,9953	0,9997
2017 → 2018 (11 lần)	0,029–0,085	0,4778
2017 → 2018 (7 lần)	0,185–0,301	0,4960
2018 → 2018	0,9246	0,9679
2018 → 2017	0,0544 ± 0,0019	0,1926

18 lần chạy cùng mã và dữ liệu (13 hạt giống, 5 hạt giống chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống; CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch $|t|=1,3$): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 hạt giống chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần; CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhi phân, đã bỏ công. 8 thuật toán × 4 phương pháp.

Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trọng số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost; MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Độ trễ và thông lượng *trên thiết bị biên* thuộc bài hệ thống đi kèm.

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lỏng lẻo với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.