

# Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

---

**Nguyễn Vũ Thái**<sup>1</sup>    Bùi Văn Dũng<sup>2</sup>    Đỗ Trí Nhựt<sup>2</sup>    Nguyễn Văn Dũ<sup>3</sup>

FAIR'2026

<sup>1</sup>Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

<sup>2</sup>Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

<sup>3</sup>Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

# I. VẤN ĐỀ VÀ ĐÓNG GÓP

---

# F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng ngờ

## Hai vấn đề, thường được xét riêng

- **Chi phí.**  $\approx 80$  đặc trưng mỗi luồng.
- **Độ tin cậy.** F1 nhị phân gần hoàn hảo thường báo hiệu **rò rỉ dữ liệu**.

## Hai nguồn rò rỉ cụ thể

1. `destination_port` mã hóa dịch vụ bị tấn công.
2. **Trùng lặp ở mức đặc trưng** sống sót qua khử trùng lặp toàn dòng — cùng một mẫu nằm ở cả tập huấn luyện và tập kiểm tra.

## Bài báo này

So sánh bốn chiến lược giảm chiều trên cùng tám bộ phân loại Spark ML — nhưng trước hết làm cho *quy trình đánh giá* đáng tin đã.

## Đóng góp nằm ở giao thức đo


Không phải “phương pháp nào thắng” mà là **đo thế nào để câu trả lời có ý nghĩa**.

1. **So sánh thống nhất** giữa RF Importance, SHAP và PCA trên cùng 8 thuật toán Spark ML + 2 mô hình tổ hợp, trên CICIDS2017.
2. SHAP được đặt **trực tiếp** cạnh RF Importance trên cùng tập huấn luyện.
3. Quy trình **loại rò rỉ và có kiểm định thống kê**: loại đặc trưng rò rỉ, khử trùng lặp ở mức đặc trưng một cách tất định, chọn mô hình trên tập kiểm định, kiểm định hoán vị ghép cặp liệt kê đầy đủ kèm hiệu chỉnh Nadeau–Bengio.
4. **Đánh giá đa lớp theo từng loại tấn công** — nơi các phương pháp thực sự khác nhau.
5. Khuyến nghị **có tính tới thiết bị biên**: F1 và số đặc trưng và kích thước mô hình, cho Jetson Orin Nano Super (phần triển khai nằm ở một bài hệ thống đi kèm).

## II. QUY TRÌNH LOẠI RỎ RỈ

---

# Quy trình loại rò rỉ



## Mỗi bước chặn một đường rò rỉ

- Loại cổng đích: chặn **đường tắt cổng** → **nhãn**.
- Khử trùng lặp *trước* khi chia: không mẫu nào ở cả hai tập.
- Scaler, PCA, xếp hạng RF/SHAP chỉ *fit* trên tập huấn luyện.
- Chọn mô hình trên tập kiểm định (20% tập huấn luyện): tập kiểm tra **không** tham gia bước chọn nào.

## Thiết kế cố định từ *trước*

- Quét  $K \in \{20, 30, 40\}$  tách khỏi pha xác nhận 4 cấu hình: Cơ sở, RF Top-30, SHAP Top-30, PCA  $k=40$ .

## Chuẩn bị dữ liệu, trước khi chia tập

1. Gộp 8 tập CSV;  $\pm\infty \rightarrow \text{NaN}$ ; bỏ dòng thiếu, dòng trùng.
2. Nhãn: BENIGN  $\rightarrow 0$ , mọi tấn công  $\rightarrow 1$ .
3. Đặc trưng  $\mathcal{F}$ : cột số, *trừ* cổng, giao thức, định danh.
4. Nhóm dòng giống hệt nhau trên  $\mathcal{F}$ : mâu thuẫn nhãn  $\rightarrow$  **loại cả nhóm (270 nhóm, 44.260 dòng)**; còn lại  $\rightarrow$  giữ *một* đại diện tất định.
5. Chia 80/20, hạt giống cố định.

### CICIDS2017 (sau xử lý)

|                       |                     |
|-----------------------|---------------------|
| Đặc trưng số          | 77                  |
| Huấn luyện / kiểm tra | 1.785.349 / 447.275 |
| Tổng                  | 2.232.624           |

### CSE-CIC-IDS2018 (mẫu phân tầng 20%)

|                           |                                 |
|---------------------------|---------------------------------|
| Trước / sau khử trùng lặp | $\sim 3,14$ / $\sim 2,39$ triệu |
|---------------------------|---------------------------------|

- **Hạ tầng:** Spark 3.4.1; 2 $\times$  Jetson Orin Nano Super (8 GB) làm worker, máy chủ *chỉ* làm master.
- **Chỉ số:** ưu tiên **AUC-PR** và **recall tấn công** hơn accuracy vì dữ liệu mất cân bằng.
- Mã nguồn công khai; chạy lại được trên một máy.

### **III. KẾT QUẢ VÀ KẾT LUẬN**

---

## Kết quả 1: bỏ được 60% đặc trưng

| Phương pháp        | Mô hình | F1            | Huấn luyện (s) | Đ.trung   |
|--------------------|---------|---------------|----------------|-----------|
| Cơ sở              | XGBoost | 0,9971        | 4615,5         | 77        |
| <b>SHAP Top-30</b> | XGBoost | <b>0,9970</b> | <b>1226,1</b>  | <b>30</b> |
| PCA $k=40$         | XGBoost | 0,9939        | 1444,8         | 40        |
| RF Top-30          | XGBoost | 0,9922        | 1295,1         | 30        |

Huấn luyện (s): cụm Spark gồm 2× Jetson Orin Nano Super;  
máy chủ chỉ làm master, không chạy executor.

| Thuật toán    | RF Top-30 | SHAP Top-30 | $\Delta$ |
|---------------|-----------|-------------|----------|
| Random Forest | 0,9879    | 0,9955      | +0,77%   |
| XGBoost       | 0,9922    | 0,9970      | +0,48%   |
| GBT           | 0,9844    | 0,9918      | +0,75%   |
| Decision Tree | 0,9835    | 0,9948      | +1,15%   |

- SHAP Top-30 giữ được F1 của cấu hình cơ sở trong khi cắt  **$\approx 60\%$  đặc trưng** và  **$\approx 73\%$  thời gian huấn luyện**.
- Ở cùng số đặc trưng, SHAP thắng RF Importance trên mọi thuật toán dạng cây.
- PCA dùng  $k=40$  vì nó *trích xuất* chứ không *chọn lọc* — mỗi thành phần chỉ mang một phần phương sai. Rẻ hơn cấu hình cơ sở, nhưng không giải thích được.

## Kết quả 2: công đích rò rỉ bao nhiêu tùy họ mô hình

| Thuật toán          | F1 (loại cổng) | F1 (giữ cổng) | $\Delta F1$    |
|---------------------|----------------|---------------|----------------|
| SVM (LinearSVC)     | 0,7859         | 0,8274        | <b>+0,0415</b> |
| Logistic Regression | 0,7986         | 0,8381        | <b>+0,0395</b> |
| Naive Bayes         | 0,2985         | 0,3093        | +0,0108        |
| MLP                 | 0,9660         | 0,9711        | +0,0052        |
| GBT                 | 0,9924         | 0,9941        | +0,0017        |
| Decision Tree       | 0,9953         | 0,9966        | +0,0014        |
| Random Forest       | 0,9954         | 0,9964        | +0,0010        |
| XGBoost             | 0,9972         | 0,9979        | +0,0007        |

Hai lượt trên *cùng* một phép chia, chỉ khác giữ hay loại `destination_port`; bài toán nhị phân.

- **Họ cây** chỉ được lợi +0,0007 đến +0,0017: chúng dừng lại cùng biên quyết định từ thống kê hành vi của luồng.
- **Mô hình tuyến tính** được lợi tới **+0,04**, gấp khoảng 40 lần: chúng bám vào cổng như một định danh dịch vụ.
- Random Forest: F1 0,9964  $\rightarrow$  0,9954, recall tấn công 0,9988  $\rightarrow$  0,9961. Chiều hướng vẫn nhất quán với rò rỉ.
- Tác vụ nhị phân trong-miền đã gần bão hòa sau khử trùng lặp, nên mức chênh ở họ cây nhỏ.

Ablation trên *một* mô hình **không giới hạn được** mức rò rỉ của một lớp mô hình khác. Mọi kết quả sau đều dùng cấu hình đã loại cổng.


## Kết quả 3: kiểm định sự khác biệt, rồi kiểm định sự tương đương

| Phương pháp                                     | Mô hình | F1 (TB $\pm$ CI95)       |
|-------------------------------------------------|---------|--------------------------|
| Cơ sở                                           | XGBoost | 0,99734 $\pm$ 0,00007    |
| SHAP Top-30                                     | XGBoost | 0,99720 $\pm$ 0,00009    |
| hoán vị ghép cặp $p = 0,031$ ; $d \approx 1,94$ |         |                          |
| <b>TOST</b> (hai kiểm định một phía)            |         |                          |
| Biên tương đương, khai báo trước                |         | $\pm 0,001$ F1           |
| Sai số dùng để kiểm định                        |         | Nadeau–Bengio            |
| $p_{\text{TOST}}$                               |         | $3,9 \times 10^{-6}$     |
| Biên nhỏ nhất chứng minh được ( $\alpha=0,05$ ) |         | $\pm 2,3 \times 10^{-4}$ |

- $N=6$  lần *lấy mẫu lại* ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, **liệt kê đủ**  $2^6$  tổ hợp dấu:  $p$  nhỏ nhất là  $2/2^6$ , nên  $N \geq 6$  là *bắt buộc*.
- Lấy mẫu chồng nhau phá vỡ tính độc lập của  $t \rightarrow$  dùng CI **hiệu chỉnh Nadeau–Bengio**.
- $p = 0,031$  nằm ngay sán phân giải, trong khi cách biệt chỉ  $\approx 0,0001$ . Kiểm định ý nghĩa **không** chứng minh được tương đương, nên bài báo kiểm định tương đương *trực tiếp* bằng TOST.

Cơ sở và SHAP Top-30 **tương đương theo nghĩa khẳng định**: chênh lệch thật nhỏ hơn  $2,3 \times 10^{-4}$  F1. Tính giải thích được và chi phí mới quyết định lựa chọn.

## Kết quả 4: F1 nhị phân che giấu các lớp hiếm



| Lớp                 | Số mẫu  | Recall        | F1     |
|---------------------|---------|---------------|--------|
| Benign              | 380.119 | 0,9997        | 0,9989 |
| DoS Hulk            | 34.446  | 0,9904        | 0,9947 |
| Web – Brute Force   | 311     | 0,7299        | 0,7323 |
| Bot                 | 290     | <b>0,4552</b> | 0,6256 |
| Web – XSS           | 111     | <b>0,0270</b> | 0,0526 |
| Web – SQL Injection | 6       | <b>0,0000</b> | 0,0000 |

---

|                     |  |                         |  |
|---------------------|--|-------------------------|--|
| weighted-F1 = 0,998 |  | <b>macro-F1 = 0,806</b> |  |
|---------------------|--|-------------------------|--|

Hai kiểu sai, theo *nơi lỗi rơi vào*:

- **Nhầm loại nhưng vẫn bắt**: 81/111 XSS rơi vào Web Brute Force — **76% vẫn bị gắn cờ** ở mức nhị phân.
- **Lọt vào Benign** (nguy hiểm): cả 6 SQL Injection, **54% Bot** (158/290), 27% Brute Force.

## Kết quả 5: điểm số không sống sót khi đổi testbed

| Huấn luyện → Kiểm tra    | F1                  | AUC-PR |
|--------------------------|---------------------|--------|
| 2017 → 2017 (trong-miền) | 0,9953              | 0,9997 |
| 2017 → 2018 (11 lượt)    | 0,029–0,085         | 0,4778 |
| 2017 → 2018 (7 lượt)     | 0,185–0,301         | 0,4960 |
| 2018 → 2018 (trong-miền) | 0,9246              | 0,9679 |
| 2018 → 2017              | 0,0544 $\pm$ 0,0019 | 0,1926 |

18 lượt cùng mã nguồn và dữ liệu (13 hạt giống, 5 hạt giống chạy hai lần). 2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018.

- AUC-PR sụp **0,9997 → 0,4849** (trung bình 18 lượt) và **0,9679 → 0,1926**. Recall 0,073 / 0,030, precision 0,772 / 0,272: mô hình **bỏ sót** tấn công của testbed kia.
- 2017→2018: F1 có **hai chế độ rời nhau**. Trung bình 0,1276 rơi vào khoảng trống; CI95 của nó chỉ chứa 1/18 lượt.
- 5 hạt giống chạy lại: 2 đổi chế độ. Quá trình fit phân tán quyết định, không phải hạt giống.
- AUC-PR hai chế độ như nhau (Welch  $|t|=1,3$ ): chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau, cả cụm lật cùng lúc.

F1 liên bộ của *một* lượt chỉ cho biết lượt đó rơi vào chế độ nào. Bài báo báo cáo cả phân bố và so sánh bằng **AUC-PR**.

## Kết quả 6: thích ứng miền — cái gì cứu được, cái gì không

| Cách thích ứng              | Nhãn đích | 2017→2018    | 2018→2017    |
|-----------------------------|-----------|--------------|--------------|
| Không thích ứng             | không     | 0,029–0,301  | 0,054        |
| Refit scaler trên miền đích | không     | <b>0,000</b> | <b>0,000</b> |
| CORAL                       | không     | <b>0,000</b> | <b>0,000</b> |
| Chỉ 1% dữ liệu đích         | có        | <b>0,922</b> | <b>0,990</b> |
| Nguồn 1,79 triệu + 1% đích  | có        | 0,803        | 0,961        |

Giá trị là F1. 1% tập huấn luyện của miền đích  $\approx$  19 nghìn luồng (18 nghìn cho chiều ngược lại). Mỗi cách thích ứng được so với lượt không thích ứng của chính nó.

- Refit scaler và CORAL, không nhãn và không huấn luyện lại, đưa F1 về **0** ở cả hai chiều, trong cả 3 lượt. Dịch chuyển nằm ở phân phối có điều kiện, không chỉ ở trung bình và hiệp phương sai.
- CORAL vẫn nâng AUC-PR chiều 2018→2017 (0,179 → 0,250) dù F1 bằng 0: thứ hạng tốt lên, nhưng ngưỡng 0,5 fit trên miền nguồn không còn đúng. Thích ứng phải hiệu chỉnh cả ngưỡng.
- Gán nhãn một ít dữ liệu mạng mới hiệu quả ngay. Gộp thêm dữ liệu nguồn lại **kém hơn** bỏ hẳn nó.

Thích ứng miền là **điều kiện tiên quyết** để chuyển giao, và cách rẻ nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đích.

## Những gì đã chỉ ra

- SHAP Top-30: **≈60% ít đặc trưng**, ≈73% ít thời gian huấn luyện.
- Cơ sở và SHAP Top-30 **tương đương** trong  $\pm 2,3 \times 10^{-4}$  F1 (TOST).
- Rò rỉ cổng: +0,001 với cây, **+0,04** với mô hình tuyến tính.
- **macro-F1 0,806** so với weighted-F1 0,998.
- AUC-PR liên bộ **0,48 / 0,19**; F1 liên bộ có hai chế độ.
- Scaler, CORAL: F1 bằng 0; 1% nhãn đích: **0,92 / 0,99**.

## Đóng góp

- **Đo thể nào cho đáng tin**, quan trọng ngang với phương pháp nào thắng.

## Hướng tiếp theo


- Ablation chính bước khử trùng lặp.
- Toàn bộ CSE-CIC-IDS2018; RoEduNet, CIC-IoT.
- Tập SHAP Top-30 có chuyển được sang bộ khác?
- Tăng  $N$  bằng kiểm định chéo lồng.

**Xin cảm ơn — kính mời câu hỏi**

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**
- [3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**
- [6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**
- [7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**
- [8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**
- [9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**
- [10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

**Slide dự phòng**

# Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhị phân, đã loại cổng. 8 thuật toán × 4 phương pháp.

## Dự phòng: siêu tham số, cố định từ trước

| Mô hình             | Siêu tham số chính                                                   |
|---------------------|----------------------------------------------------------------------|
| Decision Tree       | maxDepth=15, minInstancesPerNode=5, impurity=entropy                 |
| Logistic Regression | maxIter=200, regParam=0.001, L2, threshold=0.5                       |
| SVM (LinearSVC)     | maxIter=200, regParam=0.001                                          |
| Naive Bayes         | gaussian, smoothing=1.0                                              |
| Random Forest       | numTrees=200, maxDepth=15, featureSubset=sqrt                        |
| GBT                 | maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8                |
| XGBoost             | n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8 |
| MLP                 | layers=[d,64,32,2], maxIter=150, stepSize=0.01                       |

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trọng số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost; MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86\_64, còn đích triển khai là ARM64.

# Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Độ trễ và thông lượng *trên thiết bị biên* thuộc bài hệ thống đi kèm.

## Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch  $\leq 7,4 \times 10^{-5}$ , và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.**  $N=6$  cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn  $p$  ở mức  $2/2^N$ , nên  $N=6$  vừa đủ chạm 0,05. Kết luận tương đương không dựa vào  $p$  đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lỏng lẻo với  $N$  lớn hơn là hướng củng cố tiếp theo.

# Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.