

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Vũ Nguyễn Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dư³

FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng ngờ

Hai vấn đề, thường được xét riêng

- **Chi phí.** ≈ 80 đặc trưng mỗi luồng.
- **Độ tin cậy.** F1 nhị phân gần hoàn hảo thường báo hiệu **rò rỉ dữ liệu**.

Hai nguồn rò rỉ cụ thể

1. `destination_port` mã hóa dịch vụ bị tấn công.
2. **Trùng lặp ở mức đặc trưng** sống sót qua khử trùng lặp toàn dòng — cùng một mẫu nằm ở cả tập huấn luyện và tập kiểm tra.

Bài báo này

So sánh bốn chiến lược giảm chiều trên cùng tám bộ phân loại Spark ML — nhưng trước hết làm cho *quy trình đánh giá* đáng tin đã.


Đóng góp nằm ở giao thức đo

Không phải “phương pháp nào thắng” mà là **đo thế nào để câu trả lời có ý nghĩa**.

1. **So sánh thống nhất** giữa RF Importance, SHAP và PCA trên cùng 8 thuật toán Spark ML + 2 mô hình tổ hợp, trên CICIDS2017.
2. SHAP được đặt **trực tiếp** cạnh RF Importance trên cùng tập huấn luyện.
3. Quy trình **loại rò rỉ và có kiểm định thống kê**: loại đặc trưng rò rỉ, khử trùng lặp ở mức đặc trưng một cách tất định, chọn mô hình trên tập kiểm định, kiểm định hoán vị ghép cặp liệt kê đầy đủ kèm hiệu chỉnh Nadeau–Bengio.
4. **Đánh giá đa lớp theo từng loại tấn công** — nơi các phương pháp thực sự khác nhau.
5. Khuyến nghị **có tính tới thiết bị biên**: F1 và số đặc trưng và kích thước mô hình, cho Jetson Orin Nano Super (phần triển khai nằm ở một bài hệ thống đi kèm).

II. QUY TRÌNH LOẠI RỎ RỈ

Quy trình loại rò rỉ



Việc loại bỏ diễn ra *trước* khi chia tập

- Nhóm giống nhau về đặc trưng mà **mâu thuẫn nhãn** bị loại *toàn bộ*: **270 nhóm, 44.260 dòng**.
- Kết quả: 77 đặc trưng, 1,79 / 0,45 triệu luồng.

Thiết kế cố định *từ trước*

- Pha khám phá (quét K) tách khỏi pha xác nhận.
- Siêu tham số dùng chung; tập kiểm tra **không** tham gia bước chọn nào.

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ được 60% đặc trưng

Phương pháp	Mô hình	F1	Huấn luyện (s)	Đ.trung
Cơ sở	XGBoost	0,9971	4615,5	77
SHAP Top-30	XGBoost	0,9970	1226,1	30
PCA $k=40$	XGBoost	0,9939	1444,8	40
RF Top-30	XGBoost	0,9922	1295,1	30

Thuật toán	RF Top-30	SHAP Top-30	Δ
Random Forest	0,9879	0,9955	+0,77%
XGBoost	0,9922	0,9970	+0,48%
GBT	0,9844	0,9918	+0,75%
Decision Tree	0,9835	0,9948	+1,15%

- SHAP Top-30 giữ được F1 của cấu hình cơ sở trong khi cắt **$\approx 60\%$ đặc trưng** và **$\approx 73\%$ thời gian huấn luyện.**
- Ở cùng số đặc trưng, SHAP thắng RF Importance trên mọi thuật toán dạng cây.
- PCA dùng $k=40$ vì nó *trích xuất* chứ không *chọn lọc* — mỗi thành phần chỉ mang một phần phương sai. Rẻ hơn cấu hình cơ sở, nhưng không giải thích được.


Kết quả 2: kiểm định sự khác biệt thay vì khẳng định nó

Phương pháp	Mô hình	F1 (TB $\pm$ CI95)
Cơ sở	XGBoost	0,99734 $\pm$ 0,00007
SHAP Top-30	XGBoost	0,99720 $\pm$ 0,00009
hoán vị ghép cặp $p = 0,031$; $d \approx 1,94$		
Ablation cổng (RF)	F1	Recall (Tấn công)
Giữ cổng	0,9965	0,9988
Loại cổng	0,9955	0,9961

Có ý nghĩa *chỉ ở sát ngưỡng phân giải*, cách biệt $\approx 0,0001$: **tương đương về thực hành**, nên tính giải thích được và chi phí mới quyết định. Trùng lặp mới là nguồn rò rỉ chính, không phải cổng.

- $N=6$ lần *lấy mẫu lại* ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, **liệt kê đủ** 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6$, nên $N \geq 6$ là *bắt buộc*.
- Lấy mẫu chồng nhau phá vỡ tính độc lập của $t \rightarrow$ dùng CI **hiệu chỉnh Nadeau-Bengio**.

Kết quả 3: F1 nhị phân che giấu các lớp hiếm



Lớp	Số mẫu	Recall	F1
Benign	380.119	0,9997	0,9989
DoS Hulk	34.446	0,9904	0,9947
Web – Brute Force	311	0,7299	0,7323
Bot	290	0,4552	0,6256
Web – XSS	111	0,0270	0,0526
Web – SQL Injection	6	0,0000	0,0000

weighted-F1 = 0,998		macro-F1 = 0,806	
---------------------	--	-------------------------	--

Hai kiểu sai, theo *nơi lỗi rơi vào*:

- **Nhầm loại nhưng vẫn bắt**: 81/111 XSS rơi vào Web Brute Force — **76% vẫn bị gắn cờ** ở mức nhị phân.
- **Lọt vào Benign** (nguy hiểm): cả 6 SQL Injection, **54% Bot**, 27% Brute Force.

Kết quả 4: điểm số không sống sót khi đổi testbed

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0,9953	0,9997
2017 → 2018	0,029–0,085 0,185–0,301	0,4849
2018 → 2018	0,9246	0,9679
2018 → 2017	0,0544 $\pm 0,0019$	0,1926

Trung bình 18 lượt; đặc trưng chung đã loại rò rỉ, ~2,39 triệu luồng.

- Trong-miền ổn định cả *hai* chiều — AUC-PR liên bộ **1,00→0,48** và **0,97→0,19**.
- Recall 0,073 / 0,030 (precision 0,772 / 0,272): mô hình **không nhận ra** tấn công của testbed kia.
- 18 lượt, **hai chế độ rời nhau**: 11 lượt 0,029–0,085 và 7 lượt 0,185–0,301, không gì ở giữa; AUC-PR như nhau.
- Nguyên nhân: khác CICFlowMeter, cấu hình mạng, công cụ tấn công.

Điểm số trong-miền gần hoàn hảo, kể cả khi đã loại rò rỉ, **không chứng nhận** khả năng triển khai khi phân phối dịch chuyển.

Những gì đã chỉ ra

- SHAP Top-30 giữ được F1 cơ sở với **$\approx 60\%$ ít đặc trưng hơn.**
- Cơ sở và SHAP Top-30 **tương đương về thực hành.**
- **macro-F1 0,806** so với weighted-F1 0,998.
- AUC-PR liên bộ dữ liệu **sụp xuống 0,48 / 0,19.**

Đóng góp

- **Đo thể nào cho đáng tin**, quan trọng ngang với phương pháp nào thắng.

Hướng tiếp theo


- Toàn bộ CSE-CIC-IDS2018; các bộ mới hơn (RoEduNet, CIC-IoT).
- *Bản thân* tập SHAP Top-30 có chuyển được sang bộ khác?
- Xử lý mất cân bằng có chủ đích; đặc trưng thời gian cho beaconing.

Xin cảm ơn — kính mời câu hỏi

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mẫu huấn luyện**
- [3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**
- [6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**
- [7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**
- [8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**

Slide dự phòng

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhị phân, đã loại cổng. 8 thuật toán × 4 phương pháp.

Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trọng số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost; MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Độ trễ và thông lượng *trên thiết bị biên* thuộc bài hệ thống đi kèm.

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Các lần lấy mẫu chồng nhau, vi phạm tính độc lập của t — vì vậy lấy Nadeau–Bengio làm căn cứ chính. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.