

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

Bảy phút cho một luận điểm duy nhất: trên CICIDS2017, F1 gần như hoàn hảo thường là tính chất của quy trình đánh giá, không phải của mô hình.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─ I. VẤN ĐỀ VÀ ĐÓNG GÓP

I. VẤN ĐỀ VÀ ĐÓNG GÓP

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng ngờ

Hai vấn đề, thường được xét riêng

- **Chi phí.** ≈ 80 đặc trưng mỗi luồng.
- **Độ tin cậy.** F1 nhị phân gần hoàn hảo thường báo hiệu **rò rỉ dữ liệu**.

Hai nguồn rò rỉ cụ thể

1. destination_port mã hóa dịch vụ bị tấn công.
2. **Trùng lặp ở mức đặc trưng** sống sót qua khử trùng lặp toàn dòng — cùng một mẫu nằm ở cả tập huấn luyện và tập kiểm tra.

Bài báo này

So sánh bốn chiến lược giảm chiều trên cùng tám bộ phân loại Spark ML — nhưng trước hết làm cho quy trình đánh giá đáng tin đã.

Đóng góp nằm ở giao thức đo

Không phải “phương pháp nào thắng” mà là **đo thế nào để câu trả lời có ý nghĩa**.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng...

Rò rỉ dữ liệu: thông tin không có lúc triển khai lọt vào huấn luyện hoặc đánh giá. Định vị bài báo là bài về phép đo. Cổng đích cho mô hình một đường tắt từ cổng sang nhãn; 80 đặc trưng thì tốn cả khi huấn luyện, khi suy luận và khi nhồi lên thiết bị biên. Cả hai nguồn rò rỉ đều được loại trước khi chia tập.

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng ngờ

Hai vấn đề, thường được xét riêng

- **Chi phí.** ≈ 80 đặc trưng mỗi luồng.
- **Độ tin cậy.** F1 nhị phân gần hoàn hảo thường báo hiệu **rò rỉ dữ liệu**.

Hai nguồn rò rỉ cụ thể

1. destination_port mã hóa dịch vụ bị tấn công.
2. **Trùng lặp ở mức đặc trưng** sống sót qua khử trùng lặp toàn dòng — cùng một mẫu nằm ở cả tập huấn luyện và tập kiểm tra.

Bài báo này

So sánh bốn chiến lược giảm chiều trên cùng tám bộ phân loại Spark ML — nhưng trước hết làm cho quy trình đánh giá đáng tin đã.

Đóng góp nằm ở giao thức đo

Không phải “phương pháp nào thắng” mà là **đo thế nào để câu trả lời có ý nghĩa**.

- 1. **So sánh thống nhất** giữa RF Importance, SHAP và PCA trên cùng 8 thuật toán Spark ML + 2 mô hình tổ hợp, trên CICIDS2017.
- 2. SHAP được đặt **trực tiếp** cạnh RF Importance trên cùng tập huấn luyện.
- 3. Quy trình **loại rò rỉ và có kiểm định thống kê**: loại đặc trưng rò rỉ, khử trùng lặp ở mức đặc trưng một cách tất định, chọn mô hình trên tập kiểm định, kiểm định hoán vị ghép cặp liệt kê đầy đủ kèm hiệu chỉnh Nadeau–Bengio.
- 4. **Đánh giá đa lớp theo từng loại tấn công** — nơi các phương pháp thực sự khác nhau.
- 5. Khuyến nghị **có tính tới thiết bị biên**: F1 và số đặc trưng và kích thước mô hình, cho Jetson Orin Nano Super (phần triển khai nằm ở một bài hệ thống đi kèm).

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML


I. VẤN ĐỀ VÀ ĐÓNG GÓP

Năm đóng góp; ba, bốn và năm là những thứ ít khi được làm cùng nhau.

Các đóng góp	
1.	So sánh thống nhất giữa RF Importance, SHAP và PCA trên cùng 8 thuật toán Spark ML + 2 mô hình tổ hợp, trên CICIDS2017.
2.	SHAP được đặt trực tiếp cạnh RF Importance trên cùng tập huấn luyện.
3.	Quy trình loại rò rỉ và có kiểm định thống kê : loại đặc trưng rò rỉ, khử trùng lặp ở mức đặc trưng một cách tất định, chọn mô hình trên tập kiểm định, kiểm định hoán vị ghép cặp liệt kê đầy đủ kèm hiệu chỉnh Nadeau–Bengio.
4.	Đánh giá đa lớp theo từng loại tấn công — nơi các phương pháp thực sự khác nhau.
5.	Khuyến nghị có tính tới thiết bị biên : F1 và số đặc trưng và kích thước mô hình, cho Jetson Orin Nano Super (phần triển khai nằm ở một bài hệ thống đi kèm).

II. QUY TRÌNH LOẠI RÒ RỈ

Quy trình loại rò rỉ



Mỗi bước chặn một đường rò rỉ

- Loại cổng đích: chặn **đường tắt cổng** → **nhãn**.
- Khử trùng lặp *trước* khi chia: không mẫu nào ở cả hai tập.
- Scaler, PCA, xếp hạng RF/SHAP chỉ *fit* trên tập huấn luyện.
- Chọn mô hình trên tập kiểm định (20% tập huấn luyện): tập kiểm tra **không** tham gia bước chọn nào.

Thiết kế cố định từ trước

- Quét $K \in \{20, 30, 40\}$ tách khỏi pha xác nhận 4 cấu hình: Cơ sở, RF Top-30, SHAP Top-30, PCA $k=40$.


2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH LOẠI RÒ RỈ

Quy trình loại rò rỉ

Đi từ trên xuống, mỗi khối đỏ là một chỗ rò rỉ bị chặn. Không cấu hình nào được chọn theo F1 trên tập kiểm tra. Siêu tham số dùng chung cho mọi phương pháp, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh.



Khử trùng lặp tất định và thiết lập thực nghiệm

Chuẩn bị dữ liệu, trước khi chia tập

- 1. Gộp 8 tập CSV; $\pm\infty \rightarrow \text{NaN}$; bỏ dòng thiếu, dòng trùng.
- 2. Nhãn: BENIGN $\rightarrow 0$, mọi tấn công $\rightarrow 1$.
- 3. Đặc trưng $\mathcal{F}$: cột số, *trừ* cổng, giao thức, định danh.
- 4. Nhóm dòng giống hệt nhau trên $\mathcal{F}$: mâu thuẫn nhãn $\rightarrow$ **loại cả nhóm (270 nhóm, 44.260 dòng)**; còn lại $\rightarrow$ giữ *một* đại diện tất định.
- 5. Chia 80/20, hạt giống cố định.

CICIDS2017 (gộp 8 tập)			
Đặc trưng số	77		
Huấn luyện / kiểm tra	1.785.340 / 447.275		
Tổng	2.232.614		
CSE-CIC-IDS2018 (mẫu phân tầng 20%)			
Trước / sau khử trùng lặp	2.114 / 2.339 triệu		

- **Hạ tầng:** Spark 3.4.1; 2 $\times$ Jetson Orin Nano Super (8 GB) làm worker, máy chủ *chỉ* làm master.
- **Chỉ số:** ưu tiên **AUC-PR** và **recall tấn công** hơn accuracy vì dữ liệu mất cân bằng.
- Mã nguồn công khai; chạy lại được trên một máy.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH LOẠI RÒ RĨ

Khử trùng lặp tất định và thiết lập thực nghiệm

Chỗ nhiều người làm sai là nhóm mâu thuẫn nhãn: giữ ngẫu nhiên một dòng thì nhãn phụ thuộc cách Spark chia phân vùng, mỗi lần chạy ra một bộ dữ liệu khác; loại cả nhóm thì kết quả tất định. Lỗi nhãn này của CICIDS2017 đã được Lanvin et al. ghi nhận. Cột bị loại cụ thể là destination_port, source_port, protocol và các cột định danh. Thời gian huấn luyện ở các slide sau là thời gian trên hai Jetson, không phải trên máy chủ.

Khử trùng lặp tất định và thiết lập thực nghiệm	
Chuẩn bị dữ liệu, trước khi chia tập	CICIDS2017 (gộp 8 tập)
	Đặc trưng số 77
	Huấn luyện / kiểm tra 1.785.340 / 447.275
	Tổng 2.232.614
	CSE-CIC-IDS2018 (mẫu phân tầng 20%)
Trước / sau khử trùng lặp	2.114 / 2.339 triệu
■ Hạ tầng: Spark 3.4.1; 2 $\times$ Jetson Orin Nano Super (8 GB) làm worker, máy chủ <i>chỉ</i> làm master.	
■ Chỉ số: ưu tiên AUC-PR và recall tấn công hơn accuracy vì dữ liệu mất cân bằng.	
■ Mã nguồn công khai; chạy lại được trên một máy.	

III. KẾT QUẢ VÀ KẾT LUẬN

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng
trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ được 60% đặc trưng

Phương pháp	Mô hình	F1	Huấn luyện (s)	Điểm
Cơ sở	XGBoost	0.9971	4615.5	77
SHAP Top-30	XGBoost	0,9970	1226,1	30
PCA k=40	XGBoost	0.9939	1444.8	40
RF Top-30	XGBoost	0.9922	1295.1	30

Huấn luyện (s): cụm Spark gồm 2x Jetson Orin Nano Super, máy chủ chỉ làm master, không chạy executor.

Thuật toán	RF Top-30	SHAP Top-30	Δ
Random Forest	0.9879	0.9955	+0,77%
XGBoost	0.9922	0.9970	+0,48%
GBT	0.9844	0.9918	+0,75%
Decision Tree	0.9835	0.9948	+1,15%

- SHAP Top-30 giữ được F1 của cấu hình cơ sở trong khi cắt **≈60% đặc trưng** và **≈73% thời gian huấn luyện**.
- Ở cùng số đặc trưng, SHAP thắng RF Importance trên mọi thuật toán dạng cây.
- PCA dùng *k=40* vì nó *trích xuất* chứ không *chọn lọc* — mỗi thành phần chỉ mang một phần phương sai. Rẻ hơn cấu hình cơ sở, nhưng không giải thích được.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ được 60% đặc trưng

Hai bảng, một thông điệp: SHAP Top-30 là điểm vận hành. Cùng độ chính xác, ít hơn 60 phần trăm đặc trưng, và giải thích được — điều quan trọng với phân tích viên SOC và với thiết bị biên ở phía sau.

Kết quả 1: bỏ được 60% đặc trưng				
Phương pháp	Mô hình	F1	Huấn luyện (s)	Điểm
Cơ sở	XGBoost	0.9971	4615.5	77
SHAP Top-30	XGBoost	0,9970	1226,1	30
PCA k=40	XGBoost	0.9939	1444.8	40
RF Top-30	XGBoost	0.9922	1295.1	30
Huấn luyện (s): cụm Spark gồm 2x Jetson Orin Nano Super, máy chủ chỉ làm master, không chạy executor.				
Thuật toán	RF Top-30	SHAP Top-30	Δ	
Random Forest	0.9879	0.9955	+0,77%	
XGBoost	0.9922	0.9970	+0,48%	
GBT	0.9844	0.9918	+0,75%	
Decision Tree	0.9835	0.9948	+1,15%	

- SHAP Top-30 giữ được F1 của cấu hình cơ sở trong khi cắt **≈60% đặc trưng** và **≈73% thời gian huấn luyện**.
- Ở cùng số đặc trưng, SHAP thắng RF Importance trên mọi thuật toán dạng cây.
- PCA dùng *k=40* vì nó *trích xuất* chứ không *chọn lọc* — mỗi thành phần chỉ mang một phần phương sai. Rẻ hơn cấu hình cơ sở, nhưng không giải thích được.

Kết quả 2: cổng đích rò rỉ bao nhiêu tùy họ mô hình

Thuật toán	F1 loại công	F1 gói công	$\Delta F1$
Linear SVM	0.7459	0.7274	+0,0415
Logistic Regression	0.7086	0.6791	+0,0395
Naive Bayes	0.2995	0.1999	+0,0109
MLP	0.9889	0.9719	+0,0059
GBT	0.9929	0.9941	-0,0007
Decision Tree	0.9853	0.9865	-0,0014
Random Forest	0.9954	0.9964	-0,0010
XGBoost	0.9972	0.9972	-0,0002

Hai lượt trên cùng một phép chia, chỉ khác giữ hay loại destination_port: bài toán nhị phân

Ablation trên *một* mô hình **không giới hạn được** mức rò rỉ của một lớp mô hình khác. Mọi kết quả sau đều dùng cấu hình đã loại cổng.

- **Họ cây** chỉ được lợi +0,0007 đến +0,0017: chúng dựng lại cùng biên quyết định từ thống kê hành vi của luồng.
- **Mô hình tuyến tính** được lợi tới **+0,04**, gấp khoảng 40 lần: chúng bám vào cổng như một định danh dịch vụ.
- Random Forest: F1 0,9964 → 0,9954, recall tấn công 0,9988 → 0,9961. Chiều hướng vẫn nhất quán với rò rỉ.
- Tác vụ nhị phân trong-miền đã gần bão hòa sau khử trùng lặp, nên mức chênh ở họ cây nhỏ.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 2: cổng đích rò rỉ bao nhiêu tùy họ mô hình

Bài bản nộp chỉ đo trên Random Forest; bản camera-ready chạy cả tám thuật toán theo góp ý phản biện. Con số 0,001 là đặc tính của họ cây, không phải của bộ dữ liệu.


Thuật toán	F1 loại công	F1 gói công	$\Delta F1$
GBM (ensemble)	0.7889	0.8274	-0,0485
Logistic Regression	0.7886	0.8281	-0,0395
Naive Bayes	0.2985	0.2999	-0,0109
MLP	0.9889	0.9719	-0,0202
GBT	0.9929	0.9941	-0,0017
Decision Tree	0.9853	0.9865	-0,0014
Random Forest	0.9954	0.9964	-0,0010
XGBoost	0.9972	0.9972	-0,0002

Hai lượt trên cùng một phép chia, chỉ khác giữ hay loại destination_port: bài toán nhị phân.

- Họ cây chỉ được lợi +0,0007 đến +0,0017: chúng dựng lại cùng biên quyết định từ thống kê hành vi của luồng.
- **Mô hình tuyến tính** được lợi tới **+0,04**, gấp khoảng 40 lần: chúng bám vào cổng như một định danh dịch vụ.
- Random Forest: F1 0,9964 → 0,9954, recall tấn công 0,9988 → 0,9961. Chiều hướng vẫn nhất quán với rò rỉ.
- Tác vụ nhị phân trong-miền đã gần bão hòa sau khử trùng lặp, nên mức chênh ở họ cây nhỏ.

Ablation trên một mô hình **không giới hạn được** mức rò rỉ của một lớp mô hình khác. Mọi kết quả sau đều dùng cấu hình đã loại cổng.

Kết quả 4: F1 nhị phân che giấu các lớp hiếm



Lớp	Số mẫu	Recall	F1
Benign	380.119	0,9997	0,9989
DoS Hulk	34.446	0,9904	0,9947
Web – Brute Force	311	0,7299	0,7323
Bot	290	0,4552	0,6256
Web – XSS	111	0,0270	0,0526
Web – SQL Injection	6	0,0000	0,0000
weighted-F1 = 0,998		macro-F1 = 0,806	

Hai kiểu sai, theo nơi lỗi rơi vào:

- **Nhầm loại nhưng vẫn bắt:** 81/111 XSS rơi vào Web Brute Force — **76% vẫn bị gắn cờ** ở mức nhị phân.
- **Lọt vào Benign** (nguy hiểm): cả 6 SQL Injection, **54% Bot** (158/290), 27% Brute Force.


2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 4: F1 nhị phân che giấu các lớp hiếm

Weighted F1 0,998 so với macro F1 0,806. Ba nguyên nhân: mất cân bằng cực độ, 6–311 mẫu so với 380 nghìn Benign; không còn đường tắt cổng 80 thì luồng HTTP ngắn của tấn công web trông như lướt web thường; beaconing của Bot C&C giống lưu lượng nền khi mất định danh dịch vụ. Recall 0,027 của XSS ở đây thay cho một con số từng bị rò rỉ thổi phồng. Hai lớp không có trên bảng: PortScan F1 0,976 và Infiltration F1 0,800 (12 mẫu). Bảy lớp còn lại, gồm cả Heartbleed, đều đạt F1 từ 0,95 trở lên.



Kết quả 5: điểm số không sống sót khi đổi testbed

Hình thức	Nhiệm vụ	F1	AUC-PR
2017	2017 (trong-miền)	0,9953	0,9997
2017	2018 (11 lượt)	0,029–0,085	0,4778
2017	2018 (7 lượt)	0,185–0,301	0,4960
2018	2018 (trong-miền)	0,9246	0,9679
2018	2017	0,0544	0,1926

18 lượt cùng mã nguồn và dữ liệu 1/3 hạt giống, 5 hạt giống chạy hai lần, 2017 « CICIDS2017 » 2018 « CSE-CIC-IDS2018

- AUC-PR sụp **0,9997 → 0,4849** (trung bình 18 lượt) và **0,9679 → 0,1926**. Recall 0,073 / 0,030, precision 0,772 / 0,272: mô hình **bỏ sót** tấn công của testbed kia.
- 2017→2018: F1 có **hai chế độ rời nhau**. Trung bình 0,1276 rơi vào khoảng trống; CI95 của nó chỉ chứa 1/18 lượt.
- 5 hạt giống chạy lại: 2 đổi chế độ. Quá trình fit phân tán quyết định, không phải hạt giống.
- AUC-PR hai chế độ như nhau (Welch $|t|=1,3$): chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau, cả cụm lật cùng lúc.

F1 liên bộ của *một* lượt chỉ cho biết lượt đó rơi vào chế độ nào. Bài báo báo cáo cả phân bố và so sánh bằng **AUC-PR**.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 5: điểm số không sống sót khi đổi testbed

Nguyên nhân dịch chuyển: khác phiên bản CICFlowMeter nên thang đo đặc trưng đổi, khác cấu hình mạng, khác công cụ tấn công (HOIC/LOIC-HTTP chỉ có ở 2018). Trong 5 hạt giống chạy hai lần, 3 giữ nguyên chế độ và 2 đổi chế độ. Không làm nhẹ con số này. Bản nộp ban đầu báo một con số F1 duy nhất; lặp lại thí nghiệm cho thấy con số đó không tái lập được giữa các lượt, nên bản camera-ready báo hai chế độ. Kết luận không đổi, thậm chí chắc hơn: lượt tốt nhất trong 18 lượt cũng chỉ đạt F1 0,30 so với 0,9953 trong-miền.

Hình thức	Nhiệm vụ	F1	AUC-PR
2017	2017 (trong-miền)	0,9953	0,9997
2017	2018 (11 lượt)	0,029–0,085	0,4778
2017	2018 (7 lượt)	0,185–0,301	0,4960
2018	2018 (trong-miền)	0,9246	0,9679
2018	2017	0,0544	0,1926

18 lượt cùng mã nguồn và dữ liệu 1/3 hạt giống, 5 hạt giống chạy hai lần, 2017 « CICIDS2017, 2018 « CSE-CIC-IDS2018

F1 liên bộ của một lượt chỉ cho biết lượt đó rơi vào chế độ nào. Bài báo báo cáo cả phân bố và so sánh bằng **AUC-PR**.

- AUC-PR sụp **0,9997 → 0,4849** (trung bình 18 lượt) và **0,9679 → 0,1926**. Recall 0,073 / 0,030, precision 0,772 / 0,272: mô hình **bỏ sót** tấn công của testbed kia.
- 2017→2018: F1 có **hai chế độ rời nhau**. Trung bình 0,1276 rơi vào khoảng trống; CI95 của nó chỉ chứa 1/18 lượt.
- 5 hạt giống chạy lại: 2 đổi chế độ. Quá trình fit phân tán quyết định, không phải hạt giống.
- AUC-PR hai chế độ như nhau (Welch $|t|=1,3$): chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau, cả cụm lật cùng lúc.

Kết quả 6: thích ứng miền — cái gì cứu được, cái gì không

Cách thích ứng	Nhân diện	2018→2017	2018→2017
Không thích ứng	Không	0,000	0,000
Refit scaler trên miền đích	Không	0,000	0,000
CORAL	Không	0,000	0,000
Chỉ 1% dữ liệu đích	Có	0,922	0,990
Ngẫu nhiên 1.7% miền → 1% đích	Có	0,925	0,991

Giá trị là F1. 1% tập huấn luyện của miền đích → 13 nghìn lượng (13 nghìn cho chiều ngược lại). Mỗi cách thích ứng được so với lượt không thích ứng của chính nó.

- Refit scaler và CORAL, không nhân và không huấn luyện lại, đưa F1 về 0 ở cả hai chiều, trong cả 3 lượt. Dịch chuyển nằm ở phân phối có điều kiện, không chỉ ở trung bình và hiệp phương sai.
- CORAL vẫn nâng AUC-PR chiều 2018→2017 (0,179 → 0,250) dù F1 bằng 0: thứ hạng tốt lên, nhưng ngưỡng 0,5 fit trên miền nguồn không còn đúng. Thích ứng phải hiệu chỉnh cả ngưỡng.
- Gán nhãn một ít dữ liệu mạng mới hiệu quả ngay. Gộp thêm dữ liệu nguồn lại **kém hơn** bỏ hẳn nó.

Thích ứng miền là **điều kiện tiên quyết** để chuyển giao, và cách rẻ nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đích.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 6: thích ứng miền — cái gì cứu được, cái gì không

Hai baseline không giám sát được thêm theo góp ý phản biện, và cả hai đều thất bại về F1. Bài học không phải là thích ứng vô ích, mà là nắn lại thang đo đặc trưng thôi thì chưa đủ.

Kết quả 6: thích ứng miền — cái gì cứu được, cái gì không

Cách thích ứng	Nhân diện	2018→2017	2018→2017
Không thích ứng	Không	0,000	0,000
Refit scaler trên miền đích	Không	0,000	0,000
CORAL	Không	0,000	0,000
Chỉ 1% dữ liệu đích	Có	0,922	0,990
Ngẫu nhiên 1.7% miền → 1% đích	Có	0,925	0,991

Giá trị là F1. 1% tập huấn luyện của miền đích → 13 nghìn lượng (13 nghìn cho chiều ngược lại). Mỗi cách thích ứng được so với lượt không thích ứng của chính nó.

Thích ứng miền là **điều kiện tiên quyết** để chuyển giao, và cách rẻ nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đích.

Sun, Feng & Saenko, Return of frustratingly easy domain adaptation, AAAI 2016.

- Refit scaler và CORAL, không nhân và không huấn luyện lại, đưa F1 về 0 ở cả hai chiều, trong cả 3 lượt. Dịch chuyển nằm ở phân phối có điều kiện, không chỉ ở trung bình và hiệp phương sai.
- CORAL vẫn nâng AUC-PR chiều 2018→2017 (0,179 → 0,250) dù F1 bằng 0: thứ hạng tốt lên, nhưng ngưỡng 0,5 fit trên miền nguồn không còn đúng. Thích ứng phải hiệu chỉnh cả ngưỡng.
- Gán nhãn một ít dữ liệu mạng mới hiệu quả ngay. Gộp thêm dữ liệu nguồn lại **kém hơn** bỏ hẳn nó.

Những gì đã chỉ ra

- SHAP Top-30: **≈60% ít đặc trưng**, ≈73% ít thời gian huấn luyện.
- Cơ sở và SHAP Top-30 **tương đương** trong $\pm 2,3 \times 10^{-4}$ F1 (TOST).
- Rò rỉ cổng: +0,001 với cây, **+0,04** với mô hình tuyến tính.
- **macro-F1 0,806** so với weighted-F1 0,998.
- AUC-PR liên bộ **0,48 / 0,19**; F1 liên bộ có hai chế độ.
- Scaler, CORAL: F1 bằng 0; 1% nhãn đích: **0,92 / 0,99**.

Xin cảm ơn — kính mời câu hỏi

Đóng góp

- **Đo thể nào cho đáng tin**, quan trọng ngang với phương pháp nào thắng.
- Ablation chính bước khử trùng lặp.
- Toàn bộ CSE-CIC-IDS2018; RoEduNet, CIC-IoT.
- Tập SHAP Top-30 có chuyển được sang bộ khác?
- Tăng N bằng kiểm định chéo lồng.

Hướng tiếp theo

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết bằng giao thức đo, không kết bằng bảng xếp hạng.

Kết luận

Những gì đã chỉ ra

- SHAP Top-30: **≈60% ít đặc trưng**, ≈73% ít thời gian huấn luyện.
- Cơ sở và SHAP Top-30 **tương đương** trong $\pm 2,3 \times 10^{-4}$ F1 (TOST).
- Rò rỉ cổng: +0,001 với cây, **+0,04** với mô hình tuyến tính.
- **macro-F1 0,806** so với weighted-F1 0,998.
- AUC-PR liên bộ **0,48 / 0,19**; F1 liên bộ có hai chế độ.
- Scaler, CORAL: F1 bằng 0; 1% nhãn đích: **0,92 / 0,99**.

Đóng góp

- **Đo thể nào cho đáng tin**, quan trọng ngang với phương pháp nào thắng.

Hướng tiếp theo

- Ablation chính bước khử trùng lặp.
- Toàn bộ CSE-CIC-IDS2018; RoEduNet, CIC-IoT.
- Tập SHAP Top-30 có chuyển được sang bộ khác?
- Tăng N bằng kiểm định chéo lồng.

Xin cảm ơn — kính mời câu hỏi

[1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**

[2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**

[3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**

[4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**

[5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**

[6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**

[7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**

[8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**

[9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**

[10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Tài liệu tham khảo chính

Không trình bày — để trên màn hình trong lúc nhận câu hỏi, nên nguồn luôn hiện sẵn nếu khán giả hỏi. Danh sách đầy đủ nằm trong bài báo.

Tài liệu tham khảo chính		
[1]	Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. ICISSP 2018.	CICIDS2017
[2]	Lanvin, M. et al. Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes. CRiSIS 2022.	mâu thuẫn nhãn
[3]	Arp, D. et al. Dos and Don'ts of Machine Learning in Computer Security. USENIX Security 2022.	bẫy rò rỉ
[4]	Lundberg, S. M. & Lee, S.-I. A unified approach to interpreting model predictions. NeurIPS 2017.	SHAP
[5]	Nadeau, C. & Bengio, Y. Inference for the Generalization Error. Machine Learning 52(3), 2003.	CI hiệu chỉnh
[6]	D'hooge, L. et al. Inter-dataset generalization strength of supervised machine learning methods for intrusion detection. J. Information Security and Applications 54, 2020.	liên bộ dữ liệu
[7]	Zaharia, M. et al. Spark: Cluster computing with working sets. HotCloud 2010.	Spark ML
[8]	CIC & CSE. CSE-CIC-IDS2018 dataset. 2018.	đích liên bộ dữ liệu
[9]	Schuirmann, D. J. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987.	TOST
[10]	Sun, B., Feng, J. & Saenko, K. Return of frustratingly easy domain adaptation. AAAI 2016.	CORAL


Slide dự phòng

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập
mạng trên Apache Spark ML

Slide dự phòng

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhi phân, đã loại công, 8 thuật toán × 4 phương pháp.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán



Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01


Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, scale_pos_weight cho XGBoost; MLP không có trong số (Spark ML không hỗ trợ trong số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại; thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: siêu tham số, cố định từ trước

Dự phòng: siêu tham số, cố định từ trước	
Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01
Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, scale_pos_weight cho XGBoost; MLP không có trong số (Spark ML không hỗ trợ trong số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại; thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.	

Dự phòng: chi phí huấn luyện và suy luận




Đo trên cụm huấn luyện Spark. Đồ trẻ và thông lượng trên thiết bị biên thuộc bài hệ thống đi kèm.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi phí huấn luyện và suy luận

Dự phòng: chi phí huấn luyện và suy luận



Đo trên cụm huấn luyện Spark. Đồ trẻ và thông lượng trên thiết bị biên thuộc bài hệ thống đi kèm.

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

2026-09-29


Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên mẫu phân tầng theo lớp để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.

2026-09-29

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: quy kết đặc trưng bằng SHAP

