

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

Nói: Kính chào quý thầy cô và các anh chị. Tôi là Nguyễn Vũ Thái, xin trình bày bài báo về giảm đặc trưng cho phát hiện xâm nhập mạng trên Spark ML. Cả bài xoay quanh một ý: trên CICIDS2017, F1 gần như tuyệt đối thường nói về cách đánh giá nhiều hơn là về mô hình.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng
trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

I. VẤN ĐỀ VÀ ĐÓNG GÓP

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như tuyệt đối trên CICIDS2017: cần kiểm chứng

Hai câu hỏi

1. Có cần đủ ~80 đặc trưng không?

Càng nhiều đặc trưng càng tốn tính toán, khó chạy trên thiết bị biên.

2. Điểm cao có đáng tin không?

Hai lỗi khiến điểm cao hơn thực tế:

- Cổng đích: mỗi loại tấn công nhắm vào một số cổng cố định, nên **cổng gần như tiết lộ nhãn**.
- Luồng trùng nhau nằm ở cả tập huấn luyện lẫn tập kiểm tra: mô hình **đã gặp dữ liệu kiểm tra từ trước**.

Bài báo này

Sửa cách đánh giá cho đúng *trước*, rồi mới so sánh các cách giảm đặc trưng.

Thông điệp

Đo thế nào quan trọng không kém *phương pháp nào thắng*.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Nói: Bài báo xuất phát từ hai câu hỏi. Thứ nhất, mỗi luồng mạng có khoảng 80 đặc trưng, có cần dùng hết không, vì càng nhiều thì càng tốn và càng khó chạy trên thiết bị biên. Thứ hai, rất nhiều bài đạt F1 trên 0,99 với bộ dữ liệu này, điểm đó có đáng tin không. Có hai lỗi khiến điểm cao hơn thực tế. Một là cổng đích: trong bộ dữ liệu, mỗi loại tấn công nhắm vào một số cổng cố định, nên cổng gần như tiết lộ nhãn. Hai là luồng trùng nhau nằm ở cả tập huấn luyện lẫn tập kiểm tra, mô hình xem như đã gặp dữ liệu kiểm tra từ trước. Vì vậy chúng tôi sửa cách đánh giá trước, rồi mới so sánh các cách giảm đặc trưng.

Nếu bị hỏi: Rò rỉ dữ liệu là khi thông tin không có lúc triển khai lọt vào huấn luyện hoặc đánh giá. Cột cổng đích trong dữ liệu là `destination_port`.

F1 gần như tuyệt đối trên CICIDS2017: cần kiểm chứng	
Hai câu hỏi	Bài báo này
1. Có cần đủ ~80 đặc trưng không? Càng nhiều đặc trưng càng tốn tính toán, khó chạy trên thiết bị biên.	Sửa cách đánh giá cho đúng trước, rồi mới so sánh các cách giảm đặc trưng.
2. Điểm cao có đáng tin không? Hai lỗi khiến điểm cao hơn thực tế: □ Cổng đích: mỗi loại tấn công nhắm vào một số cổng cố định, nên cổng gần như tiết lộ nhãn. □ Luồng trùng nhau nằm ở cả tập huấn luyện lẫn tập kiểm tra: mô hình đã gặp dữ liệu kiểm tra từ trước.	Thông điệp Đo thế nào quan trọng không kém phương pháp nào thắng.

- 1. So sánh **4 cách giảm đặc trưng** (giữ hết, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
- 2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng, bỏ luồng trùng trước khi chia, không dùng tập kiểm tra để chọn bất cứ thứ gì.
- 3. **Kiểm định thống kê** thay vì chỉ so sánh điểm số.
- 4. Đánh giá những gì điểm tổng thường che khuất: **từng loại tấn công**, và khi **đổi sang bộ dữ liệu khác**.
- 5. Chọn cấu hình **hợp với thiết bị biên** Jetson Orin Nano Super.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Nói: Bài báo có năm đóng góp. Một, so sánh bốn cách giảm đặc trưng trên cùng tám thuật toán, cùng một quy trình. Hai, quy trình đánh giá chống rò rỉ. Ba, dùng kiểm định thống kê để kết luận, không chỉ so sánh điểm số. Bốn, đánh giá những gì điểm tổng thường che khuất: từng loại tấn công, và khi đổi sang bộ dữ liệu khác. Năm, chọn cấu hình hợp với thiết bị biên. Điểm đáng nói là mục hai đến bốn ít khi được làm cùng nhau trong các bài về CICIDS2017.

- Các đóng góp
- 1. So sánh **4 cách giảm đặc trưng** (giữ hết, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
 - 2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng, bỏ luồng trùng trước khi chia, không dùng tập kiểm tra để chọn bất cứ thứ gì.
 - 3. **Kiểm định thống kê** thay vì chỉ so sánh điểm số.
 - 4. Đánh giá những gì điểm tổng thường che khuất: **từng loại tấn công**, và khi **đổi sang bộ dữ liệu khác**.
 - 5. Chọn cấu hình **hợp với thiết bị biên** Jetson Orin Nano Super.

2026-10-02


Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─ II. QUY TRÌNH ĐÁNH GIÁ

II. QUY TRÌNH ĐÁNH GIÁ

II. QUY TRÌNH ĐÁNH GIÁ

Quy trình: mỗi bước chặn một đường rò rỉ



- Bỏ cổng: mô hình không suy ra được **loại tấn công từ số cổng**.
- Bỏ trùng *trước* khi chia: không luồng nào ở cả hai tập.
- Xếp hạng đặc trưng chỉ tính trên *tập huấn luyện*.
- Chọn mô hình trên *tập validation*. Tập kiểm tra **chỉ dùng một lần**, ở cuối.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH ĐÁNH GIÁ

Nói: Đây là quy trình, đi từ trên xuống. Hai khối đỏ là chỗ chặn rò rỉ. Trước khi chia dữ liệu, chúng tôi bỏ cổng và bỏ luồng trùng, nên không luồng nào nằm ở cả hai tập. Sau đó áp dụng bốn cách giảm đặc trưng, huấn luyện tám thuật toán. Bảng xếp hạng đặc trưng chỉ tính trên tập huấn luyện. Chọn mô hình thì dùng tập validation. Tập kiểm tra chỉ dùng một lần, ở cuối. Cuối cùng, cấu hình SHAP 30 đặc trưng được đưa xuống thiết bị biên.

Nếu bị hỏi: Tập validation tách 20% từ tập huấn luyện. Bốn cấu hình so sánh được cố định từ trước (giữ hết, RF Top-30, SHAP Top-30, PCA $k=40$), siêu tham số dùng chung, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh.



Bỏ luồng trùng, nhưng phải bỏ cho đúng

- Nhiều luồng **giống hệt nhau** ở mọi đặc trưng → chỉ giữ *một* bản.
- Có nhóm giống hệt nhau mà **nhãn lại khác nhau** (vừa Benign vừa Attack), một lỗi đã biết của CICIDS2017.
- Nhóm như vậy **bỏ cả nhóm: 270 nhóm, 44.260 dòng**.
- Nếu giữ ngẫu nhiên một dòng, *mỗi lần chạy ra một bộ dữ liệu khác*. Bỏ cả nhóm thì kết quả luôn như nhau.

Dữ liệu sau khi làm sạch	
Đặc trưng	77
Luồng huấn luyện	1.785.340
Luồng kiểm tra	447.275
CSE-CIC-IDS2018 lấy mẫu 20%	12.34 triệu
Huấn luyện trên cụm Spark gồm 2 Jetson Orin Nano Super máy chủ chỉ điều phối	

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH ĐÁNH GIÁ

Nói: Bỏ luồng trùng nghe đơn giản nhưng dễ làm sai. Những luồng giống hệt nhau ở mọi đặc trưng thì chỉ giữ một bản. Nhưng có những nhóm giống hệt nhau mà nhãn lại khác nhau, vừa bình thường vừa tấn công. Đây là lỗi đã biết của CICIDS2017. Với nhóm như vậy chúng tôi bỏ cả nhóm: 270 nhóm, hơn 44 nghìn dòng. Lý do là nếu giữ ngẫu nhiên một dòng thì mỗi lần chạy ra một bộ dữ liệu khác. Sau khi làm sạch còn 77 đặc trưng, khoảng 1,8 triệu luồng huấn luyện và 450 nghìn luồng kiểm tra.

Nếu bị hỏi: Cột bị bỏ: destination_port, source_port, protocol và các cột định danh. Lỗi nhãn mâu thuẫn đã được Lanvin et al. ghi nhận. CSE-CIC-IDS2018 lấy mẫu phân tầng 20%, được 3,14 triệu luồng, còn 2,39 triệu sau khi bỏ trùng. Spark 3.4.1. Máy chủ chỉ làm master, không chạy executor, nên thời gian huấn luyện là thời gian trên hai Jetson.

Bỏ luồng trùng, nhưng phải bỏ cho đúng	
Dữ liệu sau khi làm sạch	
Đặc trưng	77
Luồng huấn luyện	1.785.340
Luồng kiểm tra	447.275
CSE-CIC-IDS2018 lấy mẫu 20%	12.34 triệu
Huấn luyện trên cụm Spark gồm 2 Jetson Orin Nano Super, máy chủ chỉ điều phối	

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─ III. KẾT QUẢ VÀ KẾT LUẬN

III. KẾT QUẢ VÀ KẾT LUẬN

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Cách giảm	Đặc trưng	F1	Phút huấn luyện
Giữ hết	77	0,9971	77
SHAP Top-30	30	0,9970	20
PCA k=40	40	0,9939	24
RF Top-30	30	0,9922	22

XGBoost, một lần chạy trên cách chọn train/test gốc.

- SHAP giữ 30/77 đặc trưng, F1 gần như không đổi, huấn luyện nhanh gấp 3,8 lần.
- Cùng 30 đặc trưng, SHAP chọn tốt hơn RF.
- PCA cần 40 thành phần và không giải thích được.

Chọn SHAP Top-30: ít đặc trưng, huấn luyện nhanh, giải thích được.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Nói: Kết quả đầu tiên. Bảng này là XGBoost với bốn cách giảm đặc trưng. Giữ hết 77 đặc trưng thì F1 là 0,9971. SHAP chỉ giữ 30 đặc trưng mà F1 vẫn 0,9970, và thời gian huấn luyện giảm từ 77 phút xuống 20 phút, tức nhanh gấp 3,8 lần. Cùng chọn 30 đặc trưng thì SHAP cho F1 cao hơn RF, 0,9970 so với 0,9922. PCA thì cần 40 thành phần, điểm thấp hơn, và không giải thích được. Vậy SHAP Top-30 là cấu hình chúng tôi chọn.

Nếu bị hỏi: SHAP hơn RF ở cả bốn thuật toán cây, xem slide dự phòng. Thời gian huấn luyện chính xác là 4615,5 s và 1226,1 s, giảm khoảng 73%. PCA dùng k=40 vì nó trích xuất chứ không chọn lọc: mỗi thành phần chỉ mang một phần phương sai.

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Cách giảm	Đặc trưng	F1	Phút huấn luyện
Giữ hết	77	0,9971	77
SHAP Top-30	30	0,9970	20
PCA k=40	40	0,9939	24
RF Top-30	30	0,9922	22

XGBoost, một lần chạy trên cách chia train/test gốc.

Chọn SHAP Top-30: ít đặc trưng, huấn luyện nhanh, giải thích được.

- SHAP giữ 30/77 đặc trưng, F1 gần như không đổi, huấn luyện nhanh gấp 3,8 lần.
- Cùng 30 đặc trưng, SHAP chọn tốt hơn RF.
- PCA cần 40 thành phần và không giải thích được.

Kết quả 2: cổng đích làm tăng điểm, mức độ tùy mô hình

Nhóm mô hình	F1 tăng khi giữ cổng
Cây (4 thuật toán)	dưới 0,002
MLP, Naive Bayes	0,005 và 0,011
Tuyến tính (LR, SVM)	khoảng 0,04

Mỗi thuật toán huấn luyện hai lần trên cùng một cách chia dữ liệu: bỏ cổng và giữ cổng.

- **Mô hình cây** hầu như không cần cổng.
- **Mô hình tuyến tính** dựa vào cổng nhiều, **gấp hơn 20 lần** mô hình cây.

Đo rò rỉ trên *một* mô hình không nói được gì cho mô hình khác. Mọi kết quả sau đều đã bỏ cổng.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 2: cổng đích làm tăng điểm, mức độ tùy mô hình

Nói: Kết quả thứ hai: cổng đích làm tăng điểm đến mức nào. Mỗi thuật toán được huấn luyện hai lần, một lần bỏ cổng và một lần giữ cổng. Với bốn mô hình cây, giữ cổng chỉ tăng F1 chưa tới 0,002. Với hai mô hình tuyến tính thì tăng khoảng 0,04, tức gấp hơn 20 lần. Bài học là đo rò rỉ trên một mô hình thì không nói được gì cho mô hình khác. Từ đây trở đi, mọi kết quả đều đã bỏ cổng.

Nếu bị hỏi: Số từng thuật toán ở slide dự phòng. Mô hình cây dựng lại được cùng ranh giới từ thống kê hành vi của luồng. Mô hình tuyến tính không làm được, nên dựa vào cổng như một định danh dịch vụ. Bản nộp ban đầu chỉ đo trên Random Forest (0,9964 so với 0,9954). Bản camera-ready đo cả tám thuật toán theo góp ý phản biện.

Kết quả 2: cổng đích làm tăng điểm, mức độ tùy mô hình		■ Mô hình cây hầu như không cần cổng. ■ Mô hình tuyến tính dựa vào cổng nhiều, gấp hơn 20 lần mô hình cây.
Nhóm mô hình	F1 tăng khi giữ cổng	
Cây (4 thuật toán)	dưới 0,002	
MLP, Naive Bayes	0,005 và 0,011	
Tuyến tính (LR, SVM)	khoảng 0,04	
Mỗi thuật toán huấn luyện hai lần trên cùng một cách chia dữ liệu: bỏ cổng và giữ cổng.		
Đo rò rỉ trên một mô hình không nói được gì cho mô hình khác. Mọi kết quả sau đều đã bỏ cổng.		

Kết quả 3: giữ 77 hay 30 đặc trưng thì cũng như nhau

XGBoost	F1 trung bình
Giữ hết 77 đặc trưng	0,99734
SHAP Top-30	0,99720
Chênh lệch	0,0001

Trung bình 6 lần chạy, nên lệch chút ít so với kết quả 1.

- Lặp lại với **6 cách chia dữ liệu khác nhau**, so từng cặp.
- Không chỉ hỏi “có khác không” mà **chứng minh** hai bên tương đương (kiểm định TOST).
- Kết quả: chênh lệch thật **nhỏ hơn 0,00023 F1**.

Hai cấu hình tương đương, nên chọn **SHAP Top-30**: ít đặc trưng hơn và giải thích được.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 3: giữ 77 hay 30 đặc trưng thì cũng như nhau

Nói: Ở kết quả 1, hai con số 0,9971 và 0,9970 chỉ là một lần chạy. Để chắc chắn, chúng tôi lặp lại với sáu cách chia dữ liệu khác nhau, mỗi lần cả hai cấu hình dùng cùng một cách chia. F1 trung bình chênh nhau khoảng 0,0001. Chúng tôi không dừng ở câu hỏi hai bên có khác nhau không, mà kiểm định trực tiếp rằng hai bên tương đương, bằng kiểm định TOST. Kết quả là chênh lệch thật nhỏ hơn 0,00023 F1. Vì hai bên tương đương, chúng tôi chọn SHAP Top-30: ít đặc trưng hơn và giải thích được.

Nếu bị hỏi: TOST ở mức ý nghĩa 5%. Kiểm định hoán vị ghép cặp liệt kê đủ 2^6 tổ hợp dấu cho $p = 0,031$, đúng sànp phân giải $2/2^6$, Cohen’s $d \approx 1,94$. Một p như vậy không chứng minh được tương đương, nên dùng TOST với biên $\pm 0,001$ F1 khai báo trước, trên sai số hiệu chỉnh Nadeau–Bengio: $p_{\text{TOST}} = 3,9 \times 10^{-6}$, biên nhỏ nhất chứng minh được là $\pm 2,3 \times 10^{-4}$. Xem slide dự phòng.

Kết quả 3: giữ 77 hay 30 đặc trưng thì cũng như nhau

XGBoost	F1 trung bình
Giữ hết 77 đặc trưng	0,99734
SHAP Top-30	0,99720
Chênh lệch	<0,0001

Trung bình 6 lần chạy, nên lệch chút ít so với Kết quả 1.

- Lặp lại với 6 cách chia dữ liệu khác nhau, so từng cặp.
- Không chỉ hỏi “có khác không” mà **chứng minh** hai bên tương đương (kiểm định TOST).
- Kết quả: chênh lệch thật **nhỏ hơn 0,00023 F1**.

Hai cấu hình tương đương, nên chọn **SHAP Top-30**: ít đặc trưng hơn và giải thích được.


Kết quả 5: đổi sang bộ dữ liệu khác, điểm số giảm mạnh

Huấn luyện	Kiểm tra	F1	AUC-PR
2017 → 2017		0,995	1,00
2017 → 2018		0,03–0,30	0,48
2018 → 2018		0,925	0,97
2018 → 2017		0,05	0,19
2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018			

Mô hình **bỏ sót gần hết** tấn công của mạng mới, chỉ phát hiện được khoảng 7% và 3%.

Điểm cao trên một bộ dữ liệu **không đảm bảo** hoạt động tốt trên mạng khác.

F1 chiều 2017 → 2018 qua 18 lần chạy



Cùng mã, cùng dữ liệu mà F1 **rơi vào hai cụm**. Một lần chạy **không đủ tin cậy** báo cả 18 lần và so bằng **AUC-PR**

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 5: đổi sang bộ dữ liệu khác, điểm số giảm mạnh

Nói: Đây là kết quả quan trọng nhất. Huấn luyện và kiểm tra trên cùng một bộ thì F1 là 0,995. Nhưng huấn luyện trên bộ 2017 rồi kiểm tra trên bộ 2018 thì F1 chỉ còn từ 0,03 đến 0,30. Chiều ngược lại còn 0,05. Mô hình bỏ sót gần hết tấn công của mạng mới. Hình bên phải cho thấy thêm một điều. Chúng tôi chạy 18 lần, cùng mã, cùng dữ liệu, và F1 rơi vào hai cụm tách hẳn nhau: 11 lần thấp, 7 lần cao, không lần nào ở giữa. Vì vậy báo một lần chạy là không đủ tin cậy. Chúng tôi báo cả 18 lần, và so sánh bằng AUC-PR.

Nếu bị hỏi: AUC-PR không phụ thuộc ngưỡng, giảm từ 0,9997 xuống 0,4849 (trung bình 18 lần) và từ 0,9679 xuống 0,1926. Recall 0,073 / 0,030, precision 0,772 / 0,272: mô hình bỏ sót chứ không cảnh báo tràn lan. Hai cụm có AUC-PR như nhau (Welch $|t| = 1,3$): thứ hạng không đổi, chỉ có ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau. Năm hạt giống chạy lại, hai lần đổi cụm. Nguyên nhân dịch chuyển: khác phiên bản CICFlowMeter, cấu hình mạng, công cụ tấn công. Xem slide dự phòng.



Kết quả 6: học lại với 1% nhãn của mạng mới là đủ

Cách làm (F1)	2017 → 2018	2018 → 2017
Không làm gì	0,03-0,30	0,05
Căn chỉnh không nhãn (CORAL)	0	0
Học lại với 1% nhãn mạng mới	0,92	0,99
1% đó + toàn bộ dữ liệu cũ	0,80	0,96

- Căn chỉnh dữ liệu mà không có nhãn thì **không khắc phục được**: khác biệt nằm ở chính hành vi tấn công.
- Khoảng **19 nghìn luồng có nhãn** là đủ.
- Thêm dữ liệu cũ vào **làm kết quả giảm**.

Chuyển mô hình sang mạng mới cần **thích ứng miễn**. Cách ít tổn kém nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 6: học lại với 1% nhãn của mạng mới là đủ.

Nói: Vậy làm gì để mô hình hoạt động được trên mạng mới? Chúng tôi thử hai hướng. Hướng thứ nhất không cần nhãn: căn chỉnh lại dữ liệu của mạng mới cho giống dữ liệu cũ. Kết quả là F1 về 0 ở cả hai chiều. Hướng thứ hai: gán nhãn 1% dữ liệu của mạng mới, khoảng 19 nghìn luồng, rồi học lại. F1 lên 0,92 và 0,99. Một điểm đáng chú ý: gộp thêm toàn bộ dữ liệu cũ vào thì kết quả lại giảm. Tức là muốn chuyển mô hình sang mạng mới, cách ít tổn kém nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

Nếu bị hỏi: Refit scaler và CORAL không cần nhãn, không huấn luyện lại, và cho F1 bằng 0 ở cả hai chiều, trong cả 3 lần chạy: dịch chuyển nằm ở phân phối có điều kiện, không chỉ ở trung bình và hiệp phương sai. CORAL vẫn nâng AUC-PR chiều 2018→2017 từ 0,179 lên 0,250: thứ hạng tốt lên nhưng ngưỡng 0,5 học từ dữ liệu cũ không còn đúng, nên thích ứng phải chỉnh cả ngưỡng. 1% là 19.276 luồng (chiều ngược lại 18.011).

Kết quả 6: học lại với 1% nhãn của mạng mới là đủ

Cách làm (F1)	2017 → 2018	2018 → 2017
Không làm gì	0,03-0,30	0,05
Căn chỉnh không nhãn (CORAL)	0	0
Học lại với 1% nhãn mạng mới	0,92	0,99
1% đó + toàn bộ dữ liệu cũ	0,80	0,96

- Căn chỉnh dữ liệu mà không có nhãn thì **không khắc phục được**: khác biệt nằm ở chính hành vi tấn công.
- Khoảng **19 nghìn luồng có nhãn** là đủ.
- Thêm dữ liệu cũ vào **làm kết quả giảm**.

Chuyển mô hình sang mạng mới cần **thích ứng miễn**. Cách ít tổn kém nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

Những gì đã chỉ ra

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi, *đã kiểm định*.
- Điểm tổng cao **che khuất tấn công hiểm**.
- Đổi bộ dữ liệu thì **điểm giảm mạnh**, và F1 của một lần chạy không đủ tin cậy.
- Mạng mới: **gán nhãn một ít dữ liệu** thì được, căn chỉnh không nhãn thì không.

Bài học

- **Đo thể nào** quan trọng không kém phương pháp nào thắng.

Hướng tiếp theo

- Đo riêng tác động của bước bỏ luồng trùng.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Tập SHAP Top-30 có dùng được cho bộ khác?

Xin cảm ơn. Kính mời câu hỏi

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Nói: Tóm lại có bốn điều. Một, bỏ được 60% đặc trưng mà F1 không đổi, và điều này đã được kiểm định. Hai, điểm tổng cao che khuất các loại tấn công hiểm. Ba, đổi bộ dữ liệu thì điểm giảm mạnh, và F1 của một lần chạy không đủ tin cậy. Bốn, với mạng mới, gán nhãn một ít dữ liệu thì được, căn chỉnh không nhãn thì không. Bài học chung: đo thể nào quan trọng không kém phương pháp nào thắng. Xin cảm ơn quý thầy cô, kính mời câu hỏi.

Nếu bị hỏi: Các bộ mới hơn: RoEduNet, CIC-IoT. Tăng số lần lặp bằng kiểm định chéo lồng cũng là hướng củng cố.

Kết luận	
Những gì đã chỉ ra	Bài học
■ Bỏ 60% đặc trưng (SHAP Top-30) mà F1 không đổi, <i>đã kiểm định</i>. ■ Điểm tổng cao che khuất tấn công hiểm. ■ Đổi bộ dữ liệu thì điểm giảm mạnh, và F1 của một lần chạy không đủ tin cậy. ■ Mạng mới: gán nhãn một ít dữ liệu thì được, căn chỉnh không nhãn thì không.	■ Đo thể nào quan trọng không kém phương pháp nào thắng. Hướng tiếp theo ■ Đo riêng tác động của bước bỏ luồng trùng. ■ Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn. ■ Tập SHAP Top-30 có dùng được cho bộ khác?
Xin cảm ơn. Kính mời câu hỏi	

[1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**

[2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**

[3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**

[4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**

[5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**

[6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**

[7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**

[8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**

[9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**

[10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Tài liệu tham khảo chính

Không trình bày. Để trên màn hình trong lúc nhận câu hỏi, nên nguồn luôn hiện sẵn nếu khán giả hỏi. Danh sách đầy đủ nằm trong bài báo.

Tài liệu tham khảo chính		
[1]	Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. ICISSP 2018.	CICIDS2017
[2]	Lanvin, M. et al. Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes. CRiSIS 2022.	mâu thuẫn nhãn
[3]	Arp, D. et al. Dos and Don'ts of Machine Learning in Computer Security. USENIX Security 2022.	bẫy rò rỉ
[4]	Lundberg, S. M. & Lee, S.-I. A unified approach to interpreting model predictions. NeurIPS 2017.	SHAP
[5]	Nadeau, C. & Bengio, Y. Inference for the Generalization Error. Machine Learning 52(3), 2003.	CI hiệu chỉnh
[6]	D'hooge, L. et al. Inter-dataset generalization strength of supervised machine learning methods for intrusion detection. J. Information Security and Applications 54, 2020.	liên bộ dữ liệu
[7]	Zaharia, M. et al. Spark: Cluster computing with working sets. HotCloud 2010.	Spark ML
[8]	CIC & CSE. CSE-CIC-IDS2018 dataset. 2018.	đích liên bộ dữ liệu
[9]	Schuirmann, D. J. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987.	TOST
[10]	Sun, B., Feng, J. & Saenko, K. Return of frustratingly easy domain adaptation. AAAI 2016.	CORAL

Slide dự phòng

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập
mạng trên Apache Spark ML

Slide dự phòng

Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng

F1	RF chọn	SHAP chọn	Chênh
Random Forest	0,9879	0,9955	+ 0,008
XGBoost	0,9922	0,9970	+ 0,005
GBT	0,9844	0,9918	+ 0,007
Decision Tree	0,9835	0,9948	+ 0,011

SHAP chọn cho F1 cao hơn RF chọn ở cả bốn thuật toán cây.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─ Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng

F1	RF chọn	SHAP chọn	Chênh
Random Forest	0,9879	0,9955	+ 0,008
XGBoost	0,9922	0,9970	+ 0,005
GBT	0,9844	0,9918	+ 0,007
Decision Tree	0,9835	0,9948	+ 0,011

SHAP chọn cho F1 cao hơn RF chọn ở cả bốn thuật toán cây.

Dự phòng: cổng đích theo từng thuật toán

Thuật toán	Bỏ cổng	Giữ cổng	Chênh
SVM (LinearSVC)	0,7859	0,8274	+0,0415
Logistic Regression	0,7986	0,8381	+0,0395
Naive Bayes	0,2985	0,3093	+0,0108
MLP	0,9660	0,9711	+0,0052
GBT	0,9924	0,9941	+0,0017
Decision Tree	0,9953	0,9966	+0,0014
Random Forest	0,9954	0,9964	+0,0010
XGBoost	0,9972	0,9979	+0,0007

F1 nhị phân, hai lượt trên cùng một cách chia dữ liệu.


2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─ Dự phòng: cổng đích theo từng thuật toán


Dự phòng: cổng đích theo từng thuật toán			
Thuật toán	Bỏ cổng	Giữ cổng	Chênh
SVM (LinearSVC)	0,7859	0,8274	-0,0415
Logistic Regression	0,7986	0,8381	-0,0395
Naive Bayes	0,2985	0,3093	-0,0108
MLP	0,9660	0,9711	-0,0052
GBT	0,9924	0,9941	-0,0017
Decision Tree	0,9953	0,9966	-0,0014
Random Forest	0,9954	0,9964	-0,0010
XGBoost	0,9972	0,9979	-0,0007
F1 nhị phân, hai lượt trên cùng một cách chia dữ liệu.			

Dự phòng: ma trận nhầm lẫn theo từng loại tấn công



Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

—Dự phòng: ma trận nhằm lẫn theo từng loại tấn công



Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 ± CI95 (t)	CI95 (N=6)
Giữ hết	0.99734 ± 0.00007	± 0.00012
SHAP Top-30	0.99720 ± 0.00009	± 0.00015
hoán vị ghép cặp $p = 0.031$, Cohen's $d = 1.94$		

TOST (kiểm định một phía)		
Biến tương đương, khả báo trước	0.001 F1	
Sai số dùng để kiểm định	Nadeau-Bengio	
Phạm vi	0.3×10^{-4}	
Biến nhỏ nhất chứng minh được ($\alpha = 0.05$)	$\pm 2.3 \times 10^{-5}$	

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0,031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau–Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương. TOST kiểm định trực tiếp điều đó.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi tiết kiểm định thống kê

Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 ± CI95 (t)	CI95 (N=6)
Giữ hết	0.99734 ± 0.00007	± 0.00012
SHAP Top-30	0.99720 ± 0.00009	± 0.00015
hoán vị ghép cặp $p = 0.031$, Cohen's $d = 1.94$		

TOST (kiểm định một phía)

Biến tương đương, khả báo trước

0.001 F1

Sai số dùng để kiểm định

Nadeau-Bengio

Phạm vi

0.3×10^{-4}

Biến nhỏ nhất chứng minh được ($\alpha = 0.05$)

$\pm 2.3 \times 10^{-5}$

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0.031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau–Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương. TOST kiểm định trực tiếp điều đó.

Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0.9953	0.9997
2017 → 2018 (11 lần)	0.029-0.085	0.4778
2017 → 2018 (7 lần)	0.185-0.301	0.4960
2018 → 2018	0.9246	0.9679
2018 → 2017	0.0544 ± 0.0019	0.1926

18 lần chạy cùng mã và dữ liệu (13 hạt giống, 5 hạt giống chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống, và CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch $|t|=1,3$): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 hạt giống chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần. CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi tiết liên bộ dữ liệu


Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0.9953	0.9997
2017 → 2018 (11 lần)	0.029-0.085	0.4778
2017 → 2018 (7 lần)	0.185-0.301	0.4960
2018 → 2018	0.9246	0.9679
2018 → 2017	0.0544 ± 0.0019	0.1926

18 lần chạy cùng mã và dữ liệu (13 hạt giống, 5 hạt giống chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống, và CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch $|t|=1,3$): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 hạt giống chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần. CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhị phân, đã bỏ công, 3 thuật toán × 4 phương pháp

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán



Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01


Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost. MLP không có trong số (Spark ML không hỗ trợ trong số mẫu cho nó), đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy với_64, còn đích triển khai là ARM64.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: siêu tham số, cố định từ trước

Dự phòng: siêu tham số, cố định từ trước	
Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01
Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, <code>scale_pos_weight</code> cho XGBoost. MLP không có trong số (Spark ML không hỗ trợ trong số mẫu cho nó), đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy với_64, còn đích triển khai là ARM64.	

Dự phòng: chi phí huấn luyện và suy luận



Đo trên cụm huấn luyện Spark. Đồ trẻ và thông lượng trên thiết bị biên thuộc bài hệ thống đi kèm.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi phí huấn luyện và suy luận

Dự phòng: chi phí huấn luyện và suy luận



Đo trên cụm huấn luyện Spark. Đồ trẻ và thông lượng trên thiết bị biên thuộc bài hệ thống đi kèm.

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại, nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

2026-10-02


Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại, nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ không tắt định giữa các lượt, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên mẫu phân tầng theo lớp để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.

2026-10-02

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: quy kết đặc trưng bằng SHAP

