

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá loại rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

Bảy phút cho một luận điểm duy nhất: trên CICIDS2017, F1 gần như hoàn hảo thường là tính chất của quy trình đánh giá, không phải của mô hình.

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─ I. VẤN ĐỀ VÀ ĐÓNG GÓP

I. VẤN ĐỀ VÀ ĐÓNG GÓP

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng ngờ

Hai vấn đề, thường được xét riêng

- **Chi phí.** ≈ 80 đặc trưng mỗi luồng.
- **Độ tin cậy.** F1 nhị phân gần hoàn hảo thường báo hiệu **rò rỉ dữ liệu**.

Hai nguồn rò rỉ cụ thể

1. destination_port mã hóa dịch vụ bị tấn công.
2. **Trùng lặp ở mức đặc trưng** sống sót qua khử trùng lặp toàn dòng — cùng một mẫu nằm ở cả tập huấn luyện và tập kiểm tra.

Bài báo này

So sánh bốn chiến lược giảm chiều trên cùng tám bộ phân loại Spark ML — nhưng trước hết làm cho quy trình đánh giá đáng tin đã.

Đóng góp nằm ở giao thức đo

Không phải “phương pháp nào thắng” mà là **đo thế nào để câu trả lời có ý nghĩa**.

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng...

Định vị bài báo là bài về phép đo. Cổng đích cho mô hình một đường tắt từ cổng sang nhãn; 80 đặc trưng thì tốn cả khi huấn luyện, khi suy luận và khi nhồi lên thiết bị biên. Cả hai nguồn rò rỉ đều được loại trước khi chia tập.

F1 gần như hoàn hảo trên CICIDS2017 là một dấu hiệu đáng ngờ

Hai vấn đề, thường được xét riêng

- **Chi phí.** ≈ 80 đặc trưng mỗi luồng.
- **Độ tin cậy.** F1 nhị phân gần hoàn hảo thường báo hiệu **rò rỉ dữ liệu**.

Hai nguồn rò rỉ cụ thể

1. destination_port mã hóa dịch vụ bị tấn công.
2. **Trùng lặp ở mức đặc trưng** sống sót qua khử trùng lặp toàn dòng — cùng một mẫu nằm ở cả tập huấn luyện và tập kiểm tra.

Bài báo này

So sánh bốn chiến lược giảm chiều trên cùng tám bộ phân loại Spark ML — nhưng trước hết làm cho quy trình đánh giá đáng tin đã.

Đóng góp nằm ở giao thức đo

Không phải “phương pháp nào thắng” mà là **đo thế nào để câu trả lời có ý nghĩa**.

- 1. **So sánh thống nhất** giữa RF Importance, SHAP và PCA trên cùng 8 thuật toán Spark ML + 2 mô hình tổ hợp, trên CICIDS2017.
- 2. SHAP được đặt **trực tiếp** cạnh RF Importance trên cùng tập huấn luyện.
- 3. Quy trình **loại rò rỉ và có kiểm định thống kê**: loại đặc trưng rò rỉ, khử trùng lặp ở mức đặc trưng một cách tắt định, chọn mô hình trên tập kiểm định, kiểm định hoán vị ghép cặp liệt kê đầy đủ kèm hiệu chỉnh Nadeau–Bengio.
- 4. **Đánh giá đa lớp theo từng loại tấn công** — nơi các phương pháp thực sự khác nhau.
- 5. Khuyến nghị **có tính tới thiết bị biên**: F1 và số đặc trưng và kích thước mô hình, cho Jetson Orin Nano Super (phần triển khai nằm ở một bài hệ thống đi kèm).

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Năm đóng góp; ba, bốn và năm là những thứ ít khi được làm cùng nhau.

Các đóng góp	
1.	So sánh thống nhất giữa RF Importance, SHAP và PCA trên cùng 8 thuật toán Spark ML + 2 mô hình tổ hợp, trên CICIDS2017.
2.	SHAP được đặt trực tiếp cạnh RF Importance trên cùng tập huấn luyện.
3.	Quy trình loại rò rỉ và có kiểm định thống kê : loại đặc trưng rò rỉ, khử trùng lặp ở mức đặc trưng một cách tắt định, chọn mô hình trên tập kiểm định, kiểm định hoán vị ghép cặp liệt kê đầy đủ kèm hiệu chỉnh Nadeau–Bengio.
4.	Đánh giá đa lớp theo từng loại tấn công — nơi các phương pháp thực sự khác nhau.
5.	Khuyến nghị có tính tới thiết bị biên : F1 và số đặc trưng và kích thước mô hình, cho Jetson Orin Nano Super (phần triển khai nằm ở một bài hệ thống đi kèm).

2026-09-27


Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng
trên Apache Spark ML

└ II. QUY TRÌNH LOẠI RÒ RỈ

II. QUY TRÌNH LOẠI RÒ RỈ

II. QUY TRÌNH LOẠI RÒ RỈ

Quy trình loại rò rỉ



Việc loại bỏ diễn ra *trước* khi chia tập

- Nhóm giống nhau về đặc trưng mà **mâu thuẫn nhãn** bị loại *toàn bộ*: **270 nhóm, 44.260 dòng**.
- Kết quả: 77 đặc trưng, 1,79 / 0,45 triệu luồng.

Thiết kế cố định *từ trước*

- Pha khám phá (quét *K*) tách khỏi pha xác nhận.
- Siêu tham số dùng chung; tập kiểm tra **không** tham gia bước chọn nào.


2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH LOẠI RÒ RỈ

Quy trình loại rò rỉ

Khử trùng lặp tất định là chỗ nhiều người làm sai. Nhóm mâu thuẫn nhãn bị loại trọn gói, nên kết quả không phụ thuộc vào cách Spark chia phân vùng.



III. KẾT QUẢ VÀ KẾT LUẬN

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ được 60% đặc trưng

Phương pháp	Mô hình	F1	Huấn luyện (s)	Điểm
Cơ sở	XGBoost	0.9971	4615.5	77
SHAP Top-30	XGBoost	0,9970	1226,1	30
PCA k=40	XGBoost	0.9939	1444.8	40
RF Top-30	XGBoost	0.9922	1295.1	30

Thuật toán	RF Top-30	SHAP Top-30	Δ
Random Forest	0.9879	0.9955	+0,77%
XGBoost	0.9922	0.9970	+0,48%
GBT	0.9844	0.9918	+0,75%
Decision Tree	0.9835	0.9948	+1,15%

- SHAP Top-30 giữ được F1 của cấu hình cơ sở trong khi cắt **≈60% đặc trưng** và **≈73% thời gian huấn luyện**.
- Ở cùng số đặc trưng, SHAP thắng RF Importance trên mọi thuật toán dạng cây.
- PCA dùng *k=40* vì nó *trích xuất* chứ không *chọn lọc* — mỗi thành phần chỉ mang một phần phương sai. Rẻ hơn cấu hình cơ sở, nhưng không giải thích được.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ được 60% đặc trưng

Hai bảng, một thông điệp: SHAP Top-30 là điểm vận hành. Cùng độ chính xác, ít hơn 60 phần trăm đặc trưng, và giải thích được — điều quan trọng với phân tích viên SOC và với thiết bị biên ở phía sau.

Kết quả 1: bỏ được 60% đặc trưng

Phương pháp	Mô hình	F1	Huấn luyện (s)	Điểm
Cơ sở	XGBoost	0.9971	4615.5	77
SHAP Top-30	XGBoost	0,9970	1226,1	30
PCA k=40	XGBoost	0.9939	1444.8	40
RF Top-30	XGBoost	0.9922	1295.1	30

Thuật toán	RF Top-30	SHAP Top-30	Δ
Random Forest	0.9879	0.9955	+0,77%
XGBoost	0.9922	0.9970	+0,48%
GBT	0.9844	0.9918	+0,75%
Decision Tree	0.9835	0.9948	+1,15%

- SHAP Top-30 giữ được F1 của cấu hình cơ sở trong khi cắt **≈60% đặc trưng** và **≈73% thời gian huấn luyện**.
- Ở cùng số đặc trưng, SHAP thắng RF Importance trên mọi thuật toán dạng cây.
- PCA dùng *k=40* vì nó *trích xuất* chứ không *chọn lọc* — mỗi thành phần chỉ mang một phần phương sai. Rẻ hơn cấu hình cơ sở, nhưng không giải thích được.

Kết quả 2: kiểm định sự khác biệt thay vì khẳng định nó

Phương pháp	Mô hình	F1 (TB ± CI95)
Cơ sở	XGBoost	0.99734 ± 0.00007
SHAP Top-30	XGBoost	0.99720 ± 0.00009
hoán vị ghép cặp $p = 0.031$; $d = 1.94$		
Ablation công (RF)	F1	Recall (Tần công)
Giữ công	0.9955	0.9988
Loại công	0.9955	0.9961

Có ý nghĩa *chỉ ở sát ngưỡng phân giải*, cách biệt $\approx 0,0001$: **tương đương về thực hành**, nên tính giải thích được và chi phí mới quyết định. Trùng lặp mới là nguồn rò rỉ chính, không phải công.

Nadeau & Bengio, *Inference for the Generalization Error*, Machine Learning 52(3), 2003.

- $N=6$ lần *lấy mẫu lại* ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, **liệt kê đủ** 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6$, nên $N \geq 6$ là *bắt buộc*.
- Lấy mẫu chồng nhau phá vỡ tính độc lập của $t \rightarrow$ dùng CI **hiệu chỉnh Nadeau–Bengio**.

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN


Kết quả 2: kiểm định sự khác biệt thay vì khẳng định nó

Phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ khởi tạo mô hình. Kiểm định là hai phía, và các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t . p nhỏ nhưng hiệu ứng tuyệt đối rất nhỏ: nói thẳng rằng ta coi hai phương pháp là tương đương chứ không tuyên bố ai thắng.

Kết quả 2: kiểm định sự khác biệt thay vì khẳng định nó		
Phương pháp	Mô hình	F1 (TB ± CI95)
Cơ sở	XGBoost	0.99734 ± 0.00007
SHAP Top-30	XGBoost	0.99720 ± 0.00009
hoán vị ghép cặp $p = 0.031$; $d = 1.94$		
Ablation công (RF)	F1	Recall (Tần công)
Giữ công	0.9955	0.9988
Loại công	0.9955	0.9961
Có ý nghĩa chỉ ở sát ngưỡng phân giải, cách biệt $\approx 0,0001$: tương đương về thực hành , nên tính giải thích được và chi phí mới quyết định. Trùng lặp mới là nguồn rò rỉ chính, không phải công.		
Nadeau & Bengio, <i>Inference for the Generalization Error</i> , Machine Learning 52(3), 2003.		

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ hạt giống.
- Hoán vị hai phía, **liệt kê đủ** 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6$, nên $N \geq 6$ là bắt buộc.
- Lấy mẫu chồng nhau phá vỡ tính độc lập của $t \rightarrow$ dùng CI hiệu chỉnh Nadeau–Bengio.

Kết quả 3: F1 nhị phân che giấu các lớp hiểm



Lớp	Số mẫu	Recall	F1
Benign	380.119	0,9997	0,9989
DoS Hulk	34.446	0,9904	0,9947
Web – Brute Force	311	0,7299	0,7323
Bot	290	0,4552	0,6256
Web – XSS	111	0,0270	0,0526
Web – SQL Injection	6	0,0000	0,0000
weighted-F1 = 0,998		macro-F1 = 0,806	

- **Nhằm loại nhưng vẫn bắt:** 81/111 XSS rơi vào Web Brute Force — **76% vẫn bị gắn cờ** ở mức nhị phân.
- **Lọt vào Benign** (nguy hiểm): cả 6 SQL Injection, **54% Bot**, 27% Brute Force.


2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

1/Đặt $a = 0$, Γ_1 chỉ nhận cho dấu, các lân hiếm

Weighted F1 0,998 so với macro F1 0,806. Ba nguyên nhân: mất cân bằng cực độ; loại cổng đích ảnh hưởng nặng nhất tới tấn công web, vì không còn đường tắt cổng 80 thì các luồng HTTP ngắn trông như lướt web bình thường, nên recall 0,027 báo ở đây thay cho một con số từng bị rò rỉ thổi phồng; và hành vi beaconing của Bot C&C giống lưu lượng nền.



Kết quả 4: điểm số không sống sót khi đổi testbed

Kiểm định	Hiện tại	Trước
2017 - 2017	0,9953	0,9997
2017 - 2018	0,029-0,085 0,185-0,301	0,4849
2018 - 2018	0,9246	0,9679
2018 - 2017	0,0544	0,1926

Trung bình 18 lượt, đặc trưng chung đã loại rõ r, ~2,39 triệu lượt.

- Trong-miền ổn định cả hai chiều — AUC-PR liên bộ 1,00→0,48 và 0,97→0,19.
- Recall 0,073 / 0,030 (precision 0,772 / 0,272): mô hình không nhận ra tấn công của testbed kia.
- 18 lượt, hai chế độ rời nhau: 11 lượt 0,029-0,085 và 7 lượt 0,185-0,301, không gì ở giữa; AUC-PR như nhau.
- Nguyên nhân: khác CICFlowMeter, cấu hình mạng, công cụ tấn công.

Điểm số trong-miền gần hoàn hảo, kể cả khi đã loại rõ r, không chứng nhận khả năng triển khai khi phân phối dịch chuyển.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

2026-09-27

Kết quả 4: điểm số không sống sót khi đổi testbed

Không làm nhẹ con số này. Trong-miền 0,99, liên bộ AUC-PR 0,48 / 0,19. Nếu bị hỏi vì sao khoảng F1 rộng: ở mức recall này, cụm luồng tấn công miền đích nằm sát ngưỡng 0,5 nên cả cụm lật cùng lúc, tạo ra hai chế độ; vì vậy báo cáo theo nhiều lượt và xét theo AUC-PR. Thống nhất với các nghiên cứu liên bộ dữ liệu trước đó, và là lý do khiến thích ứng miền là điều kiện tiên quyết chứ không phải thứ có thì tốt.

Kết quả 4: điểm số không sống sót khi đổi testbed			
Thời gian	Hiện tại	Trước	AUC-PR
2017 - 2017	0,9953	0,9997	
2017 - 2018	0,029-0,085 0,185-0,301	0,4849	
2018 - 2018	0,9246	0,9679	
2018 - 2017	0,0544	0,1926	
Trung bình 18 lượt, đặc trưng chung đã loại rõ r, ~2,39 triệu lượt.			

- Trong-miền ổn định cả hai chiều — AUC-PR liên bộ 1,00-0,48 và 0,97-0,19.
- Recall 0,073 / 0,030 (precision 0,772 / 0,272): mô hình không nhận ra tấn công của testbed kia.
- 18 lượt, hai chế độ rời nhau: 11 lượt 0,029-0,085 và 7 lượt 0,185-0,301, không gì ở giữa; AUC-PR như nhau.
- Nguyên nhân: khác CICFlowMeter, cấu hình mạng, công cụ tấn công.

Điểm số trong-miền gần hoàn hảo, kể cả khi đã loại rõ r, không chứng nhận khả năng triển khai khi phân phối dịch chuyển.

Những gì đã chỉ ra

- SHAP Top-30 giữ được F1 cơ sở với **≈60% ít đặc trưng hơn**.
- Cơ sở và SHAP Top-30 **tương đương về thực hành**.
- **macro-F1 0,806** so với weighted-F1 0,998.
- AUC-PR liên bộ dữ liệu **sụp xuống 0,48 / 0,19**.

Đóng góp

- **Đo thể nào cho đáng tin**, quan trọng ngang với phương pháp nào thắng.

Hướng tiếp theo

- Toàn bộ CSE-CIC-IDS2018; các bộ mới hơn (RoEduNet, CIC-IoT).
- *Bản thân* tập SHAP Top-30 có chuyển được sang bộ khác?
- Xử lý mất cân bằng có chủ đích; đặc trưng thời gian cho beaconing.

Xin cảm ơn — kính mời câu hỏi

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết bằng giao thức đo, không kết bằng bảng xếp hạng.

Kết luận

Những gì đã chỉ ra

- SHAP Top-30 giữ được F1 cơ sở với **≈60% ít đặc trưng hơn**.
- Cơ sở và SHAP Top-30 **tương đương về thực hành**.
- **macro-F1 0,806** so với weighted-F1 0,998.
- AUC-PR liên bộ dữ liệu **sụp xuống 0,48 / 0,19**.

Đóng góp

- **Đo thể nào cho đáng tin**, quan trọng ngang với phương pháp nào thắng.

Hướng tiếp theo

- Toàn bộ CSE-CIC-IDS2018; các bộ mới hơn (RoEduNet, CIC-IoT).
- Bản thân tập SHAP Top-30 có chuyển được sang bộ khác?
- Xử lý mất cân bằng có chủ đích; đặc trưng thời gian cho beaconing.

Xin cảm ơn — kính mời câu hỏi

[1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**

[2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mẫu thuẫn nhãn**

[3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **bẫy rò rỉ**

[4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**

[5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Machine Learning 52(3), 2003. **CI hiệu chỉnh**

[6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**

[7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**

[8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **đích liên bộ dữ liệu**

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Tài liệu tham khảo chính

Không trình bày — để trên màn hình trong lúc nhận câu hỏi, nên nguồn luôn hiện sẵn nếu khán giả hỏi. Danh sách đầy đủ nằm trong bài báo.

Tài liệu tham khảo chính		
[1]	Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. ICISSP 2018.	CICIDS2017
[2]	Lanvin, M. et al. Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes. CRiSIS 2022.	mẫu thuẫn nhãn
[3]	Arp, D. et al. Dos and Don'ts of Machine Learning in Computer Security. USENIX Security 2022.	bẫy rò rỉ
[4]	Lundberg, S. M. & Lee, S.-I. A unified approach to interpreting model predictions. NeurIPS 2017.	SHAP
[5]	Nadeau, C. & Bengio, Y. Inference for the Generalization Error. Machine Learning 52(3), 2003.	CI hiệu chỉnh
[6]	D'hooge, L. et al. Inter-dataset generalization strength of supervised machine learning methods for intrusion detection. J. Information Security and Applications 54, 2020.	liên bộ dữ liệu
[7]	Zaharia, M. et al. Spark: Cluster computing with working sets. HotCloud 2010.	Spark ML
[8]	CIC & CSE. CSE-CIC-IDS2018 dataset. 2018.	đích liên bộ dữ liệu


Slide dự phòng

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập
mạng trên Apache Spark ML

Slide dự phòng

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán




Nhi phân, đã loại công, 8 thuật toán × 4 phương pháp.

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: bản đồ nhiệt F1, phương pháp × thuật toán



Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01


Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, scale_pos_weight cho XGBoost; MLP không có trong số (Spark ML không hỗ trợ trong số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại; thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: siêu tham số, cố định từ trước

Dự phòng: siêu tham số, cố định từ trước	
Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01
Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, scale_pos_weight cho XGBoost; MLP không có trong số (Spark ML không hỗ trợ trong số mẫu cho nó) — đã nêu trong phần hạn chế. LightGBM bị loại; thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.	

Dự phòng: chi phí huấn luyện và suy luận



Đo trên cụm huấn luyện Spark. Đồ trẻ và thông lượng trên thiết bị biên thuộc bài hệ thống đi kèm.

2026-09-27

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi phí huấn luyện và suy luận



Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Các lần lấy mẫu chồng nhau, vi phạm tính độc lập của t — vì vậy lấy Nadeau–Bengio làm căn cứ chính. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

2026-09-27


Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└ Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại — nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Các lần lấy mẫu chồng nhau, vi phạm tính độc lập của t — vì vậy lấy Nadeau–Bengio làm căn cứ chính. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: quy kết đặc trưng bằng SHAP



SHAP được tính trên mẫu phân tầng theo lớp để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.

Giảm chiều và chọn lọc đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: quy kết đặc trưng bằng SHAP

