

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá chống rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

...với quy trình đánh giá chống rò rỉ dữ liệu

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³
FAIR'2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

Nói: Kính chào quý thầy cô và các anh chị. Tôi là Nguyễn Vũ Thái, xin trình bày bài báo về giảm đặc trưng cho phát hiện xâm nhập mạng trên Spark ML. Cả bài xoay quanh một ý: trên CICIDS2017, điểm F1 gần 1 thường phản ánh cách đánh giá hơn là chất lượng mô hình.

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Vì sao điểm F1 trên 0,99 chưa chắc đáng tin.

II. QUY TRÌNH ĐÁNH GIÁ

Làm sạch dữ liệu và chặn rò rỉ ở từng bước.

III. KẾT QUẢ VÀ KẾT LUẬN

Sáu kết quả, từ giảm đặc trưng đến chuyển sang mạng khác.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─Nội dung trình bày

Nói: Bài trình bày gồm ba phần: vấn đề và đóng góp, quy trình đánh giá, rồi sáu kết quả và kết luận. Phần kết quả chiếm nhiều thời gian nhất.

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Vì sao điểm F1 trên 0,99 chưa chắc đáng tin.

II. QUY TRÌNH ĐÁNH GIÁ

Làm sạch dữ liệu và chặn rò rỉ ở từng bước.

III. KẾT QUẢ VÀ KẾT LUẬN

Sáu kết quả, từ giảm đặc trưng đến chuyển sang mạng khác.

I. VẤN ĐỀ VÀ ĐÓNG GÓP

F1 trên 0,99 với CICIDS2017: điểm đó có đáng tin không?

Hai câu hỏi

1. Cần cả ~80 đặc trưng không?

Nhiều đặc trưng thì tốn tính toán, khó chạy trên thiết bị biên.

2. Điểm cao có đáng tin không?

Hai dạng rò rỉ dữ liệu làm điểm cao hơn thực tế:

- Cổng đích: mỗi loại tấn công nhắm vào một số cổng cố định, nên **cổng gần như tiết lộ nhãn**.
- Luồng trùng lặp ở cả hai tập: mô hình **đã thấy dữ liệu kiểm tra khi huấn luyện**.

Bài báo này

Sửa quy trình đánh giá *trước*, rồi mới so sánh các phương pháp giảm đặc trưng.

Thông điệp

Đánh giá đúng cách quan trọng không kém *chọn đúng phương pháp*.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Nói: Bài báo xuất phát từ hai câu hỏi. Thứ nhất, mỗi luồng mạng có khoảng 80 đặc trưng, có cần dùng hết không, vì càng nhiều thì càng tốn và càng khó chạy trên thiết bị biên. Thứ hai, rất nhiều bài đạt F1 trên 0,99 với bộ dữ liệu này, điểm đó có đáng tin không. Có hai dạng rò rỉ dữ liệu khiến điểm cao hơn thực tế. Rò rỉ dữ liệu, nói đơn giản, là mô hình được biết trước thứ mà khi triển khai thật nó không có. Một là cổng đích: trong bộ dữ liệu, mỗi loại tấn công nhắm vào một số cổng cố định, nên cổng gần như tiết lộ nhãn. Hai là luồng trùng nhau nằm ở cả tập huấn luyện lẫn tập kiểm tra, mô hình xem như đã thấy dữ liệu kiểm tra từ lúc huấn luyện. Vì vậy chúng tôi sửa quy trình đánh giá trước, rồi mới so sánh các phương pháp giảm đặc trưng.

Nếu bị hỏi: Rò rỉ dữ liệu là khi thông tin không có lúc triển khai lọt vào huấn luyện hoặc đánh giá. Cột cổng đích trong dữ liệu là destination_port.

Hai câu hỏi

1. Cần cả ~80 đặc trưng không?

Nhiều đặc trưng thì tốn tính toán, khó chạy trên thiết bị biên.

2. Điểm cao có đáng tin không?

Hai dạng rò rỉ dữ liệu làm điểm cao hơn thực tế:

- Cổng đích: mỗi loại tấn công nhắm vào một số cổng cố định, nên **cổng gần như tiết lộ nhãn**.
- Luồng trùng lặp ở cả hai tập: mô hình **đã thấy dữ liệu kiểm tra khi huấn luyện**.

Bài báo này

Sửa quy trình đánh giá trước, rồi mới so sánh các phương pháp giảm đặc trưng.

Thông điệp

Đánh giá đúng cách quan trọng không kém chọn đúng phương pháp.

- 1. So sánh **4 phương pháp giảm đặc trưng** (giữ toàn bộ, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
- 2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng đích, bỏ luồng trùng lặp trước khi chia dữ liệu, tập kiểm tra chỉ dùng một lần ở cuối.
- 3. **Kiểm định thống kê** để kết luận, thay vì chỉ so sánh điểm số.
- 4. Đánh giá hai khía cạnh mà điểm F1 tổng che khuất: **từng loại tấn công** và **đổi sang bộ dữ liệu khác**.
- 5. Chọn cấu hình **phù hợp thiết bị biên** Jetson Orin Nano Super.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML


I. VẤN ĐỀ VÀ ĐÓNG GÓP

Nói: Bài báo có năm đóng góp. Một, so sánh bốn phương pháp giảm đặc trưng trên cùng tám thuật toán, cùng một quy trình. Hai, quy trình đánh giá chống rò rỉ. Ba, dùng kiểm định thống kê để kết luận, không chỉ so sánh điểm số. Bốn, đánh giá những gì điểm tổng thường che khuất: từng loại tấn công, và khi đổi sang bộ dữ liệu khác. Năm, chọn cấu hình phù hợp thiết bị biên. Điểm mới là mục hai đến bốn ít khi được làm cùng nhau trong các bài về CICIDS2017.

- 1. So sánh **4 phương pháp giảm đặc trưng** (giữ toàn bộ, RF Importance, SHAP, PCA) trên cùng 8 thuật toán Spark ML.
- 2. **Quy trình đánh giá chống rò rỉ**: bỏ cổng đích, bỏ luồng trùng lặp trước khi chia dữ liệu, tập kiểm tra chỉ dùng một lần ở cuối.
- 3. **Kiểm định thống kê** để kết luận, thay vì chỉ so sánh điểm số.
- 4. Đánh giá hai khía cạnh mà điểm F1 tổng che khuất: **từng loại tấn công** và **đổi sang bộ dữ liệu khác**.
- 5. Chọn cấu hình **phù hợp thiết bị biên** Jetson Orin Nano Super.

II. QUY TRÌNH ĐÁNH GIÁ

Quy trình: mỗi bước chặn một đường rò rỉ



- Bỏ cổng đích: mô hình không thể **suy ra loại tấn công từ số cổng**.
- Bỏ trùng lặp *trước* khi chia: không luồng nào ở cả hai tập.
- Xếp hạng đặc trưng chỉ tính trên *tập huấn luyện*.
- Chọn mô hình trên *tập kiểm định* (validation). Tập kiểm tra **chỉ dùng một lần**, ở cuối.
- Siêu tham số **cố định từ trước**, dùng chung cả 4 phương pháp.

2026-10-08


Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH ĐÁNH GIÁ

Quy trình: mỗi bước chặn một đường rò rỉ

Nói: Đây là quy trình, đi từ trên xuống. Hai khối đỏ là hai bước chặn rò rỉ. Trước khi chia dữ liệu, chúng tôi bỏ cổng và bỏ luồng trùng, nên không luồng nào nằm ở cả hai tập. Sau đó áp dụng bốn phương pháp giảm đặc trưng, huấn luyện tám thuật toán. Bảng xếp hạng đặc trưng chỉ tính trên tập huấn luyện. Chọn mô hình thì dùng tập kiểm định, tức tập validation tách từ tập huấn luyện. Tập kiểm tra chỉ dùng một lần, ở cuối. Siêu tham số được cố định từ trước và dùng chung cho cả bốn phương pháp, nên khác biệt là do phương pháp chứ không do tinh chỉnh. Cuối cùng, cấu hình SHAP 30 đặc trưng được đưa xuống thiết bị biên.

Nếu bị hỏi: Tập kiểm định tách 20% từ tập huấn luyện. Bốn cấu hình so sánh được cố định từ trước (toàn bộ 77, RF Top-30, SHAP Top-30, PCA $k=40$), siêu tham số dùng chung, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh.



Loại bỏ luồng trùng lặp: phải làm đúng cách

- Nhiều luồng **giống hệt nhau** ở mọi đặc trưng → chỉ giữ lại *một* luồng.
- Có những nhóm giống hệt nhau nhưng **nhãn khác nhau** (vừa Benign vừa Attack): lỗi đã biết của CICIDS2017.
- Nhóm như vậy được **bỏ cả nhóm: 270 nhóm, 44.260 luồng**.
- Nếu giữ ngẫu nhiên một luồng thì *mỗi lần chạy cho một bộ dữ liệu khác*. Bỏ cả nhóm thì kết quả tái lập được.

Dữ liệu sau khi làm sạch	
Đặc trưng	77
Luồng huấn luyện	1,785,349
Luồng kiểm tra	447,275
CSE-CIC-IDS2018 lấy mẫu 20%	3,239,624

Huấn luyện trên cum Spark gồm **2 Jetson Orin Nano Super** máy chủ chỉ điều phối

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

II. QUY TRÌNH ĐÁNH GIÁ

Nói: Bỏ luồng trùng nghe đơn giản nhưng dễ làm sai. Những luồng giống hệt nhau ở mọi đặc trưng thì chỉ giữ một bản. Nhưng có những nhóm giống hệt nhau mà nhãn lại khác nhau, vừa bình thường vừa tấn công. Đây là lỗi đã biết của CICIDS2017. Với nhóm như vậy chúng tôi bỏ cả nhóm: 270 nhóm, hơn 44 nghìn luồng. Lý do là nếu giữ ngẫu nhiên một luồng thì mỗi lần chạy ra một bộ dữ liệu khác. Sau khi làm sạch còn 77 đặc trưng, khoảng 1,8 triệu luồng huấn luyện và 450 nghìn luồng kiểm tra.

Nếu bị hỏi: Cột bị bỏ: destination_port, source_port, protocol và các cột định danh. Lỗi nhãn mâu thuẫn đã được Lanvin et al. ghi nhận. CSE-CIC-IDS2018 lấy mẫu phân tầng 20%, được 3,14 triệu luồng, còn 2,39 triệu sau khi bỏ trùng. Spark 3.4.1. Máy chủ chỉ làm master, không chạy executor, nên thời gian huấn luyện là thời gian trên hai Jetson.

Loại bỏ luồng trùng lặp: phải làm đúng cách

- Nhiều luồng giống hệt nhau ở mọi đặc trưng → chỉ giữ lại một luồng.
- Có những nhóm giống hệt nhau nhưng nhãn khác nhau (vừa Benign vừa Attack): lỗi đã biết của CICIDS2017.
- Nhóm như vậy được bỏ cả nhóm: 270 nhóm, 44.260 luồng.
- Nếu giữ ngẫu nhiên một luồng thì mỗi lần chạy cho một bộ dữ liệu khác. Bỏ cả nhóm thì kết quả tái lập được.

Dữ liệu sau khi làm sạch	
Đặc trưng	77
Luồng huấn luyện	1,785,349
Luồng kiểm tra	447,275
CSE-CIC-IDS2018 (lấy mẫu 20%)	3,239,624

Huấn luyện trên cụm Spark gồm 2 Jetson Orin Nano Super, máy chủ chỉ điều phối.

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Phương pháp	Số đặc trưng	F1	Huấn luyện (phút)
Toàn bộ	77	0,9971	77
SHAP Top-30	30	0,9970	20
PCA k=40	40	0,9939	24
RF Top-30	30	0,9922	22

XGBoost, một lần chạy trên cách chia huấn luyện/kiểm tra gốc.

- SHAP giữ **30/77 đặc trưng**, F1 gần như không đổi, huấn luyện **nhANH GIẤP 3,8 lần**.
- Cùng 30 đặc trưng, **SHAP chọn tốt hơn RF**.
- PCA cần 40 thành phần, F1 thấp hơn và **không giải thích được**.

Chọn **SHAP Top-30**: ít đặc trưng, huấn luyện nhanh, giải thích được.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: bỏ 60% đặc trưng, F1 gần như không đổi

Nói: Kết quả đầu tiên. Bảng này là XGBoost với bốn phương pháp giảm đặc trưng. Dùng toàn bộ 77 đặc trưng thì F1 là 0,9971. SHAP chỉ giữ 30 đặc trưng mà F1 vẫn 0,9970, và thời gian huấn luyện giảm từ 77 phút xuống 20 phút, tức nhanh gấp 3,8 lần. Cùng chọn 30 đặc trưng thì SHAP cho F1 cao hơn RF, 0,9970 so với 0,9922. PCA thì cần 40 thành phần, điểm thấp hơn, và không giải thích được. Vậy SHAP Top-30 là cấu hình chúng tôi chọn.

Nếu bị hỏi: SHAP hơn RF ở cả bốn thuật toán cây, xem slide dự phòng. Thời gian huấn luyện chính xác là 4615,5 s và 1226,1 s, giảm khoảng 73%. PCA dùng k=40 vì nó trích xuất chứ không chọn lọc: mỗi thành phần chỉ mang một phần phương sai.

Phương pháp	Số đặc trưng	F1	Huấn luyện (phút)
Toàn bộ	77	0,9971	77
SHAP Top-30	30	0,9970	20
PCA k=40	40	0,9939	24
RF Top-30	30	0,9922	22

XGBoost, một lần chạy trên cách chia huấn luyện/kiểm tra gốc.

- SHAP giữ 30/77 đặc trưng, F1 gần như không đổi, huấn luyện nhanh gấp 3,8 lần.
- Cùng 30 đặc trưng, SHAP chọn tốt hơn RF.
- PCA cần 40 thành phần, F1 thấp hơn và không giải thích được.

Chọn SHAP Top-30: ít đặc trưng, huấn luyện nhanh, giải thích được.

Kết quả 2: cổng đích làm tăng điểm, mức tăng tùy mô hình

Nhóm mô hình	F1 tăng khi giữ cổng
Cây (4 thuật toán)	dưới 0,002
MLP, Naive Bayes	0,005 và 0,011
Tuyến tính (LR, SVM)	khoảng 0,04

Mỗi thuật toán huấn luyện hai lần trên cùng một cách chia dữ liệu: một lần bỏ cổng đích, một lần giữ.

Mức rò rỉ đo trên *một* mô hình không suy ra được cho mô hình khác. Mọi kết quả sau đây đều đã bỏ cổng đích.

- **Mô hình cây** hầu như không cần cổng đích.
- **Mô hình tuyến tính** dựa vào cổng đích nhiều: F1 tăng **gấp hơn 20 lần** so với mô hình cây.

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Nói: Kết quả thứ hai: cổng đích làm tăng điểm đến mức nào. Mỗi thuật toán được huấn luyện hai lần, một lần bỏ cổng và một lần giữ cổng. Với bốn mô hình cây, giữ cổng chỉ tăng F1 chưa tới 0,002. Với hai mô hình tuyến tính thì tăng khoảng 0,04, tức gấp hơn 20 lần. Bài học là đo rò rỉ trên một mô hình thì không suy ra được cho mô hình khác. Từ đây trở đi, mọi kết quả đều đã bỏ cổng.

Nếu bị hỏi: Số từng thuật toán ở slide dự phòng. Mô hình cây dựng lại được cùng ranh giới từ thống kê hành vi của luồng. Mô hình tuyến tính không làm được, nên dựa vào cổng như một định danh dịch vụ. Bản nộp ban đầu chỉ đo trên Random Forest (0,9964 so với 0,9954). Bản camera-ready đo cả tám thuật toán theo góp ý phản biện.

Kết quả 2: cổng đích làm tăng điểm, mức tăng tùy mô hình		Mô hình cây hầu như không cần cổng đích. Mô hình tuyến tính dựa vào cổng đích nhiều: F1 tăng gấp hơn 20 lần so với mô hình cây.
Nhóm mô hình	F1 tăng khi giữ cổng	
Cây (4 thuật toán)	dưới 0,002	
MLP, Naive Bayes	0,005 và 0,011	
Tuyến tính (LR, SVM)	khoảng 0,04	
Mỗi thuật toán huấn luyện hai lần trên cùng một cách chia dữ liệu: một lần bỏ cổng đích, một lần giữ.		
Mức rò rỉ đo trên một mô hình không suy ra được cho mô hình khác. Mọi kết quả sau đây đều đã bỏ cổng đích.		

2026-10-08

Kết quả 3: 77 hay 30 đặc trưng, F1 tương đương về mặt thống kê

SHAP Top-30	F1 trung bình
SHAP Top-30	0,9970
SHAP Top-30	0,9971
Chênh lệch	0,0001
Kiểm định hoán vị ghép cặp	$p = 0,031$
Kiểm định tương đương TOST	$p = 3,9 \times 10^{-6}$

Trung bình 6 lần chạy, nên khác nhẹ so với
kết quả 1 (một lần chạy)

Kiểm định hoán vị ghép cặp: hai bên có khác nhau
không?

- Chọn vì: 6 lần chạy, hai bên dùng chung cách chia
nên so theo cặp; tính chính xác với chỉ 6 cặp.
- $p = 0,031 < 0,05$: có khác, nhưng chỉ $\approx 0,0001$ F1.

TOST: chênh lệch có nằm trong $\pm 0,001$ F1 (chọn trước)
không?

- Chọn vì: kiểm định trên không chứng minh được
hai bên *giống nhau*.
- $p = 3,9 \times 10^{-6}$: tương đương, chênh lệch **dưới
0,00023 F1**.

Khác biệt không đáng kể: chọn **SHAP Top-30**, ít đặc trưng, giải thích được.

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng
trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 3: 77 hay 30 đặc trưng, F1 tương đương về mặt

Nói: Ở kết quả 1, hai con số 0,9971 và 0,9970 chỉ là một lần chạy. Để chắc chắn, chúng tôi lặp lại với sáu cách chia dữ liệu khác nhau, mỗi lần cả hai cấu hình dùng cùng một cách chia. F1 trung bình chênh nhau khoảng 0,0001. Chúng tôi dùng hai kiểm định. Kiểm định hoán vị ghép cặp hỏi hai bên có khác nhau không; nó so từng cặp và tính chính xác được với chỉ sáu cặp. Kết quả p bằng 0,031, tức là có khác biệt, nhưng khác biệt chỉ khoảng 0,0001 F1. Kiểm định này không trả lời được câu hai bên có giống nhau không, nên chúng tôi dùng thêm kiểm định tương đương TOST, với biên cộng trừ 0,001 F1 chọn trước khi chạy. p bằng 3,9 nhân 10 mũ trừ 6, nên hai bên tương đương, chênh lệch thực sự nhỏ hơn 0,00023 F1. Vì vậy chúng tôi chọn SHAP Top-30: ít đặc trưng hơn và giải thích được.

Nếu bị hỏi: $p = 0,031$ là đúng sà phân giải $2/2^6$ của kiểm định hoán vị hai phía liệt kê đủ 2^6 tổ hợp dấu, nên cần $N \geq 6$. Cohen's $d \approx 1,94$ lớn vì phương sai giữa các lần chạy rất nhỏ, không phải vì chênh lệch lớn. TOST dùng sai số hiệu chỉnh Nadeau–Bengio vì các lần lấy mẫu chồng nhau; biên nhỏ nhất chứng minh được ở $\alpha = 0,05$ là $\pm 2,3 \times 10^{-4}$. Xem

Kết quả 3: 77 hay 30 đặc trưng, F1 tương đương về mặt thống kê	
SHAP Top-30	F1 trung bình
SHAP Top-30	0,9970
SHAP Top-30	0,9971
Chênh lệch	0,0001
Kiểm định hoán vị ghép cặp	$p = 0,031$
Kiểm định tương đương TOST	$p = 3,9 \times 10^{-6}$
Trung bình 6 lần chạy, nên khác nhẹ so với kết quả 1 (một lần chạy)	
Khác biệt không đáng kể: chọn SHAP Top-30 , ít đặc trưng, giải thích được.	

Kiểm định hoán vị ghép cặp: hai bên có khác nhau
không?

- Chọn vì: 6 lần chạy, hai bên dùng chung cách chia
nên so theo cặp; tính chính xác với chỉ 6 cặp.
- $p = 0,031 < 0,05$: có khác, nhưng chỉ $\approx 0,0001$ F1.

TOST: chênh lệch có nằm trong $\pm 0,001$ F1 (chọn trước)
không?

- Chọn vì: kiểm định trên không chứng minh được
hai bên giống nhau.
- $p = 3,9 \times 10^{-6}$: tương đương, chênh lệch **dưới
0,00023 F1**.

Kết quả 4: điểm tổng 0,998 che khuất các loại tấn công hiểm

Loại lưu lượng	Số mẫu	Tỉ lệ phát hiện
Benign	380.119	99,97%
DoS Hulk	34.446	99,04%
Web – Brute Force	311	72,99%
Bot	290	45,52%
Web – XSS	111	2,70%
Web – SQL Injection	6	0%

Random Forest, 77 đặc trưng, Tỉ lệ phát hiện = recall

Lớp càng ít mẫu càng dễ bị bỏ sót, và điểm tổng không phản ánh điều đó.

- F1 chung (weighted): **0,998**.
- F1 trung bình lớp (macro): **0,806**.
- **Nhầm loại, vẫn phát hiện:** **76% XSS** vẫn bị báo là tấn công.
- **Bỏ sót:** cả 6 SQL Injection và **54% Bot** bị xếp vào bình thường.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Nói: Đến đây mới chỉ hỏi có tấn công hay không. Khi hỏi là loại tấn công nào thì kết quả khác hẳn. Điểm tổng vẫn là 0,998, nhưng nếu tính trung bình đều cho từng lớp thì chỉ còn 0,806. Lý do là các lớp hiếm. Bot chỉ phát hiện được 46%. XSS gần 3%. SQL Injection có 6 mẫu, không phát hiện được mẫu nào. Có hai kiểu sai cần phân biệt. Kiểu ít nghiêm trọng là nhầm loại nhưng vẫn phát hiện: 76% XSS vẫn bị báo là tấn công. Kiểu nghiêm trọng là bỏ sót: cả 6 SQL Injection và 54% Bot bị phân loại là bình thường.

Nếu bị hỏi: Tỉ lệ phát hiện là recall. Mô hình là Random Forest dùng đủ 77 đặc trưng. So sánh các cách giảm đặc trưng ở chế độ đa lớp là hướng tiếp theo. 0,998 là weighted-F1, 0,806 là macro-F1. Ma trận nhầm lẫn ở slide dự phòng. XSS: 81/111 mẫu bị dự đoán là Web Brute Force. Bot 158/290 và 27% Brute Force bị dự đoán là Benign. Nguyên nhân có thể: mất cân bằng cực độ (6–311 mẫu so với 380 nghìn Benign), bỏ cổng rồi thì luồng HTTP ngắn của tấn công web giống lưu lượng duyệt web thông thường, và Bot C&C giống lưu lượng an ninh.

Kết quả 4: điểm tổng 0,998 che khuất các loại tấn công hiểm			
Loại lưu lượng	Số mẫu	Tỉ lệ phát hiện	
Benign	380.119	99,97%	■ F1 chung (weighted): 0,998 .
DoS Hulk	34.446	99,04%	■ F1 trung bình lớp (macro): 0,806 .
Web – Brute Force	311	72,99%	■ Nhầm loại, vẫn phát hiện: 76% XSS vẫn bị báo là tấn công.
Bot	290	45,52%	■ Bỏ sót: cả 6 SQL Injection và 54% Bot bị xếp vào bình thường.
Web – XSS	111	2,70%	
Web – SQL Injection	6	0%	
Random Forest, 77 đặc trưng, Tỉ lệ phát hiện = recall.			
Lớp càng ít mẫu càng dễ bị bỏ sót, và điểm tổng không phản ánh điều đó.			

Kết quả 5: đổi sang bộ dữ liệu khác, điểm số giảm mạnh


Huấn luyện	Kiểm tra	F1	AUC-PR
2017 → 2017		0,995	1,00
2017 → 2018		0,03–0,30	0,48
2018 → 2018		0,925	0,97
2018 → 2017		0,05	0,19

2017 → CICIDS2017 2017 → 2018 → CSE-CIC-IDS2018

Mô hình **bỏ sót gần hết** tấn công của mạng mới, chỉ phát hiện được khoảng 7% và 3% số tấn công.

Điểm cao trên một bộ dữ liệu **không đảm bảo** hoạt động tốt trên mạng khác.

F1 chiều 2017 → 2018 qua 18 lần chạy



Cùng mã, cùng dữ liệu mà F1 **rơi vào hai cụm tách biệt**. Một lần chạy **không đủ tin cậy** báo cả 18 lần và so sánh bằng **AUC-PR**



2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Nói: Đây là kết quả quan trọng nhất. Huấn luyện và kiểm tra trên cùng một bộ thì F1 là 0,995. Nhưng huấn luyện trên bộ 2017 rồi kiểm tra trên bộ 2018 thì F1 chỉ còn từ 0,03 đến 0,30. Chiều ngược lại còn 0,05. Mô hình bỏ sót gần hết tấn công của mạng mới. Hình bên phải cho thấy thêm một điều. Chúng tôi chạy 18 lần, cùng mã, cùng dữ liệu, và F1 rơi vào hai cụm tách hẳn nhau: 11 lần thấp, 7 lần cao, không lần nào ở giữa. Vì vậy báo một lần chạy là không đủ tin cậy. Chúng tôi báo cả 18 lần, và so sánh thêm bằng AUC-PR, là điểm xếp hạng không phụ thuộc ngưỡng, nên ổn định hơn F1.

Nếu bị hỏi: AUC-PR không phụ thuộc ngưỡng, giảm từ 0,9997 xuống 0,4849 (trung bình 18 lần) và từ 0,9679 xuống 0,1926. Recall 0,073 / 0,030, precision 0,772 / 0,272: mô hình bỏ sót chứ không báo động giả nhiều. Hai cụm có AUC-PR như nhau (Welch $|t| = 1,3$): thứ hạng không đổi, chỉ có ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau. Năm seed chạy lại, hai lần đổi cụm. Nguyên nhân dịch chuyển: khác phiên bản CICFlowMeter, cấu hình mạng, công cụ tấn công. Xem slide dự phòng

Kết quả 6: gán nhãn 1% dữ liệu mạng mới rồi huấn luyện lại là đủ

Phương pháp F1	2017 → 2018	2018 → 2017
Dùng trực tiếp mô hình cũ	0,23	0,05
Chỉ chỉnh phân phối, không nhãn (CORAL)	0	0
Huấn luyện lại, 1% nhãn mạng mới	0,92	0,99
1% cũ + toàn bộ dữ liệu cũ	0,92	0,99

- Chỉ chỉnh phân phối, không nhãn: **không hiệu quả**, vì khác biệt nằm ở chính hành vi tấn công.
- Chỉ cần khoảng **19 nghìn luồng có nhãn**.
- Gộp thêm dữ liệu cũ **làm F1 giảm**.

Sang mạng mới cần **thích ứng miền** (domain adaptation). Cách ít tổn kém nhất ở đây: gán nhãn một phần nhỏ lưu lượng của chính mạng đó.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Nói: Vậy làm gì để mô hình hoạt động được trên mạng mới? Chúng tôi thử hai hướng. Hướng thứ nhất không cần nhãn: chỉ chỉnh phân phối dữ liệu của mạng mới cho giống dữ liệu cũ, gọi là căn chỉnh, ở đây dùng CORAL. Kết quả là F1 về 0 ở cả hai chiều. Hướng thứ hai: gán nhãn 1% dữ liệu của mạng mới, khoảng 19 nghìn luồng, rồi huấn luyện lại. F1 lên 0,92 và 0,99. Một điểm đáng chú ý: gộp thêm toàn bộ dữ liệu cũ vào thì kết quả lại giảm. Tức là muốn chuyển mô hình sang mạng mới, cách ít tổn kém nhất ở đây là gán nhãn một ít lưu lượng của chính mạng đó.

Nếu bị hỏi: Refit scaler và CORAL không cần nhãn, không huấn luyện lại, và cho F1 bằng 0 ở cả hai chiều, trong cả 3 lần chạy: dịch chuyển nằm ở phân phối có điều kiện, không chỉ ở trung bình và hiệp phương sai. CORAL vẫn nâng AUC-PR chiều 2018→2017 từ 0,179 lên 0,250: thứ hạng tốt lên nhưng ngưỡng 0,5 học từ dữ liệu cũ không còn đúng, nên thích ứng phải chỉnh cả ngưỡng. 1% là 19.276 luồng (chiều ngược lại 18.011).

Kết quả 6: gán nhãn 1% dữ liệu mạng mới rồi huấn luyện lại là đủ			
Phương pháp F1	2017 → 2018	2018 → 2017	
Dùng trực tiếp mô hình cũ	0,23 → 0,30	0,05	
Chỉ chỉnh phân phối, không nhãn (CORAL)	0	0	Chỉ chỉnh phân phối, không nhãn: không hiệu quả , vì khác biệt nằm ở chính hành vi tấn công.
Huấn luyện lại, 1% nhãn mạng mới	0,92	0,99	Chỉ cần khoảng 19 nghìn luồng có nhãn .
1% cũ + toàn bộ dữ liệu cũ	0,80	0,88	Gộp thêm dữ liệu cũ làm F1 giảm .

Sang mạng mới cần **thích ứng miền** (domain adaptation). Cách ít tổn kém nhất ở đây: gán nhãn một phần nhỏ lưu lượng của chính mạng đó.

Kết quả chính

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi, có *kiểm định thống kê*.
- Điểm F1 tổng cao **che khuất tấn công hiểm**.
- Đổi bộ dữ liệu thì **điểm giảm mạnh**, và F1 của một lần chạy không đủ tin cậy.
- Mạng mới: **gán nhãn một phần nhỏ dữ liệu** là đủ; căn chỉnh không nhãn thì không.

Bài học

- **Đánh giá đúng cách** quan trọng không kém chọn đúng phương pháp.

Hướng phát triển

- Đo riêng tác động của bước bỏ trùng lặp.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Bộ 30 đặc trưng SHAP có dùng được cho bộ dữ liệu khác?

Xin cảm ơn. Kính mời câu hỏi

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Nói: Tóm lại có bốn điều. Một, bỏ được 60% đặc trưng mà F1 không đổi, và điều này đã được kiểm định. Hai, điểm tổng cao che khuất các loại tấn công hiểm. Ba, đổi bộ dữ liệu thì điểm giảm mạnh, và F1 của một lần chạy không đủ tin cậy. Bốn, với mạng mới, gán nhãn một phần nhỏ dữ liệu là đủ, còn căn chỉnh không nhãn thì không. Bài học chung: đánh giá đúng cách quan trọng không kém chọn đúng phương pháp. Xin cảm ơn quý thầy cô, kính mời câu hỏi.

Nếu bị hỏi: Các bộ mới hơn: RoEduNet, CIC-IoT. Tăng số lần lặp bằng kiểm định chéo lồng cũng là hướng củng cố.

Kết luận

Kết quả chính

- Bỏ **60% đặc trưng** (SHAP Top-30) mà F1 không đổi, có *kiểm định thống kê*.
- Điểm F1 tổng cao **che khuất tấn công hiểm**.
- Đổi bộ dữ liệu thì **điểm giảm mạnh**, và F1 của một lần chạy không đủ tin cậy.
- Mạng mới: **gán nhãn một phần nhỏ dữ liệu** là đủ; căn chỉnh không nhãn thì không.

Bài học

- **Đánh giá đúng cách** quan trọng không kém chọn đúng phương pháp.

Hướng phát triển

- Đo riêng tác động của bước bỏ trùng lặp.
- Toàn bộ CSE-CIC-IDS2018 và các bộ mới hơn.
- Bộ 30 đặc trưng SHAP có dùng được cho bộ dữ liệu khác?

Xin cảm ơn. Kính mời câu hỏi

[1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**

[2] Lanvin, M. et al. *Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes*. CRiSIS 2022. **mâu thuẫn nhãn**

[3] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **rò rỉ**

[4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**

[5] Nadeau, C. & Bengio, Y. *Inference for the Generalization Error*. Mach. Learn. 52(3), 2003. **khoảng tin cậy**

[6] D'hooge, L. et al. *Inter-dataset generalization strength of supervised machine learning methods for intrusion detection*. J. Information Security and Applications 54, 2020. **liên bộ dữ liệu**

[7] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark ML**

[8] CIC & CSE. *CSE-CIC-IDS2018 dataset*. 2018. **bộ dữ liệu thứ hai**

[9] Schuirmann, D. J. *A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability*. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987. **TOST**

[10] Sun, B., Feng, J. & Saenko, K. *Return of frustratingly easy domain adaptation*. AAAI 2016. **CORAL**

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

III. KẾT QUẢ VÀ KẾT LUẬN

Không trình bày. Để trên màn hình trong lúc nhận câu hỏi, nên nguồn luôn hiện sẵn nếu khán giả hỏi. Danh sách đầy đủ nằm trong bài báo.

Tài liệu tham khảo chính	
[1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. Toward generating a new intrusion detection dataset and intrusion traffic characterization. ICISSP 2018.	CICIDS2017
[2] Lanvin, M. et al. Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes. CRiSIS 2022.	mâu thuẫn nhãn
[3] Arp, D. et al. Dos and Don'ts of Machine Learning in Computer Security. USENIX Security 2022.	rò rỉ
[4] Lundberg, S.M. & Lee, S.-I. A unified approach to interpreting model predictions. NeurIPS 2017.	SHAP
[5] Nadeau, C. & Bengio, Y. Inference for the Generalization Error. Mach. Learn. 52(3), 2003.	khoảng tin cậy
[6] D'hooge, L. et al. Inter-dataset generalization strength of supervised machine learning methods for intrusion detection. J. Information Security and Applications 54, 2020.	liên bộ dữ liệu
[7] Zaharia, M. et al. Spark: Cluster computing with working sets. HotCloud 2010.	Spark ML
[8] CIC & CSE. CSE-CIC-IDS2018 dataset. 2018.	bộ dữ liệu thứ hai
[9] Schuirmann, D. J. A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability. J. Pharmacokinetics and Biopharmaceutics 15(6), 1987.	TOST
[10] Sun, B., Feng, J. & Saenko, K. Return of frustratingly easy domain adaptation. AAAI 2016.	CORAL

Slide dự phòng

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập
mạng trên Apache Spark ML

Slide dự phòng

Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng

Thuật toán (F1)	RF Top-30	SHAP Top-30	Chênh lệch
Random Forest	0,9879	0,9955	+0,008
XGBoost	0,9922	0,9970	+0,005
GBT	0,9844	0,9918	+0,007
Decision Tree	0,9835	0,9948	+0,011

SHAP chọn cho F1 cao hơn RF chọn ở cả bốn thuật toán cây.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng

Dự phòng: RF và SHAP khi cùng chọn 30 đặc trưng			
Thuật toán (F1)	RF Top-30	SHAP Top-30	Chênh lệch
Random Forest	0,9879	0,9955	-0,008
XGBoost	0,9922	0,9970	-0,005
GBT	0,9844	0,9918	-0,007
Decision Tree	0,9835	0,9948	-0,011
SHAP chọn cho F1 cao hơn RF chọn ở cả bốn thuật toán cây.			

Dự phòng: cổng đích theo từng thuật toán

Thuật toán	Bỏ cổng đích	Giữ cổng đích	Chênh lệch
SVM (LinearSVC)	0.7859	0.8274	+0,0415
Logistic Regression	0.7986	0.8381	+0,0395
Naive Bayes	0.2985	0.3093	+0.0108
MLP	0.9660	0.9711	+0.0052
GBT	0.9924	0.9941	+0.0017
Decision Tree	0.9953	0.9966	+0.0014
Random Forest	0.9954	0.9964	+0.0010
XGBoost	0.9972	0.9979	+0.0007

F1 nhị phân, hai lượt trên cùng một cách chia dữ liệu.

Dự phòng

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML


Dự phòng: cổng đích theo từng thuật toán

Dự phòng: cổng đích theo từng thuật toán

Thuật toán	Bỏ cổng đích	Giữ cổng đích	Chênh lệch
SVM (LinearSVC)	0.7859	0.8274	+0,0415
Logistic Regression	0.7986	0.8381	+0,0395
Naive Bayes	0.2985	0.3093	+0.0108
MLP	0.9660	0.9711	+0.0052
GBT	0.9924	0.9941	+0.0017
Decision Tree	0.9953	0.9966	+0.0014
Random Forest	0.9954	0.9964	+0.0010
XGBoost	0.9972	0.9979	+0.0007

F1 nhị phân, hai lượt trên cùng một cách chia dữ liệu.

Dự phòng: ma trận nhầm lẫn theo từng loại tấn công




Dự phòng

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

- ↳ Dự phòng: ma trận nhầm lẫn theo từng loại tấn công



Random Forest, toàn bộ 77 đặc trưng. Mỗi hàng chuẩn hóa theo số mẫu thật của lớp đó.

Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 ± CI95 (t)	CI95 (N-B)
Tập bộ 77	0.99734 ± 0.00007	± 0.00012
SHAP Top-30	0.99720 ± 0.00009	± 0.00015
hoán vị ghép cặp $p = 0.031$, Cohen's $d = 1.94$		

TOST (ai kiểm định một phía)		
Đến tương đương, khai báo trước		0.001 F1
Sai số dùng để kiểm định		Nadeau-Bengio
P_{null}		2.8×10^{-6}
Đến nhỏ nhất chứng minh được ($\alpha=0.05$)		$\pm 2.3 \times 10^{-6}$

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ seed ngẫu nhiên.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0,031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau–Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương. TOST kiểm định trực tiếp điều đó.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi tiết kiểm định thống kê

Dự phòng: chi tiết kiểm định thống kê

XGBoost	F1 ± CI95 (t)	CI95 (N-B)
Tập bộ 77	0.99734 ± 0.00007	± 0.00012
SHAP Top-30	0.99720 ± 0.00009	± 0.00015
hoán vị ghép cặp $p = 0.031$, Cohen's $d = 1.94$		

TOST (ai kiểm định một phía)		
Đến tương đương, khai báo trước		0.001 F1
Sai số dùng để kiểm định		Nadeau-Bengio
P_{null}		2.8×10^{-6}
Đến nhỏ nhất chứng minh được ($\alpha=0.05$)		$\pm 2.3 \times 10^{-6}$

- $N=6$ lần lấy mẫu lại ghép cặp: phương sai phản ánh việc lấy mẫu dữ liệu, không chỉ seed ngẫu nhiên.
- Hoán vị hai phía, liệt kê đủ 2^6 tổ hợp dấu: p nhỏ nhất là $2/2^6 \approx 0.031$, nên $N \geq 6$ là bắt buộc.
- Các lần lấy mẫu chồng nhau phá vỡ tính độc lập của t , nên dùng CI hiệu chỉnh Nadeau–Bengio.
- Kiểm định ý nghĩa không chứng minh được tương đương. TOST kiểm định trực tiếp điều đó.

Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0.9953	0.9997
2017 → 2018 (11 lần)	0.029-0.085	0.4778
2017 → 2018 (7 lần)	0.185-0.301	0.4960
2018 → 2018	0.9246	0.9679
2018 → 2017	0.0544 ± 0.0019	0.1926

18 lần chạy cùng mã và dữ liệu (13 seed, trong đó 5 seed chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống, và CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch |t|=1,3): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 seed chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần. CORAL nâng AUC-PR 2018→2017 từ 0,179 lên 0,250.

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi tiết liên bộ dữ liệu


Dự phòng: chi tiết liên bộ dữ liệu

Huấn luyện → Kiểm tra	F1	AUC-PR
2017 → 2017	0.9953	0.9997
2017 → 2018 (11 lần)	0.029-0.085	0.4778
2017 → 2018 (7 lần)	0.185-0.301	0.4960
2018 → 2018	0.9246	0.9679
2018 → 2017	0.0544 ± 0.0019	0.1926

18 lần chạy cùng mã và dữ liệu (13 seed, trong đó 5 seed chạy hai lần).

- Trung bình F1 0,1276 rơi vào khoảng trống, và CI95 của nó chỉ chứa 1/18 lần chạy.
- AUC-PR hai cụm không khác nhau (Welch |t|=1,3): thứ hạng không đổi, chỉ ngưỡng 0,5 cắt qua một cụm luồng gần giống nhau.
- 5 seed chạy lại: 3 giữ cụm, 2 đổi cụm.
- Refit scaler, CORAL: F1 bằng 0 trong cả 3 lần. CORAL nâng AUC-PR 2018 → 2017 từ 0,179 lên 0,250.

Dự phòng: heatmap F1, phương pháp × thuật toán




Phân loại nhị phân, đã bỏ cổng dịch, 8 thuật toán × 4 phương pháp.

Dự phòng

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: heatmap F1, phương pháp × thuật toán



Dự phòng: siêu tham số, cố định từ trước

Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01

Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh *phương pháp* chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số lớp cho 6 mô hình, `scale_pos_weight` cho XGBoost. MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó, đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.

Dự phòng


2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─Dự phòng: siêu tham số, cố định từ trước

Dự phòng: siêu tham số, cố định từ trước	
Mô hình	Siêu tham số chính
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01
Dùng chung cho mọi phương pháp giảm chiều, nên khác biệt phản ánh phương pháp chứ không phải việc tinh chỉnh riêng từng mô hình. Trong số tập cho 6 mô hình, <code>scale_pos_weight</code> cho XGBoost. MLP không có trọng số (Spark ML không hỗ trợ trọng số mẫu cho nó, đã nêu trong phần hạn chế. LightGBM bị loại: thư viện gốc qua SynapseML chỉ chạy x86_64, còn đích triển khai là ARM64.	

Dự phòng: chi phí huấn luyện và suy luận



Đo trên cụm huấn luyện Spark. Đồ trẻ và thông lượng trên thiết bị biên thuộc bài hệ thống đi kèm.

Dự phòng

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: chi phí huấn luyện và suy luận



Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại, nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên *mẫu phân tầng* của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ dữ liệu không tắt định giữa các lượt chạy, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

2026-10-08


Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

└─Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

Dự phòng: các yếu tố ảnh hưởng tính hợp lệ

- **Nội tại.** Xếp hạng RF/SHAP lấy từ tập huấn luyện gốc và giữ cố định qua các lần lấy mẫu lại, nhất quán với thiết kế cố định từ trước, nhưng có thể gây rò rỉ nhẹ ở phần xếp hạng. Xếp hạng lại trong hai trong sáu lần lấy mẫu chỉ làm F1 lệch $\leq 7,4 \times 10^{-5}$, và 25–26/30 đặc trưng vẫn được chọn lại. MLP mang hạn chế không có trọng số lớp.
- **Ngoại tại.** CICIDS2017 có thể không phản ánh lưu lượng hiện tại, và các bộ dữ liệu NIDS chuẩn đều có hạn chế chất lượng đã ghi nhận. Kết luận liên bộ dữ liệu dựa trên mẫu phân tầng của CSE-CIC-IDS2018, chưa phải toàn bộ. Chưa kiểm thử lưu lượng né tránh. Bản thân việc khử trùng lặp cũng làm thay đổi phân bố benign/attack.
- **Thống kê.** $N=6$ cho kiểm định hoán vị *power* thấp: liệt kê đầy đủ hai phía chặn p ở mức $2/2^N$, nên $N=6$ vừa đủ chạm 0,05. Kết luận tương đương không dựa vào p đó mà dựa vào TOST, trên cùng sai số Nadeau–Bengio đã tính đến việc các lần lấy mẫu chồng nhau. F1 liên bộ dữ liệu không tắt định giữa các lượt chạy, nên được báo trên 18 lượt. Kiểm định chéo lồng với N lớn hơn là hướng củng cố tiếp theo.

Dự phòng: mức đóng góp của từng đặc trưng theo SHAP



SHAP được tính trên *mẫu phân tầng theo lớp* để cả lưu lượng bình thường và lưu lượng tấn công đều có mặt trong bảng xếp hạng.

Dự phòng

2026-10-08

Giảm chiều và lựa chọn đặc trưng cho phát hiện xâm nhập mạng trên Apache Spark ML

Dự phòng: mức đóng góp của từng đặc trưng theo SHAP

