

I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC CŨNG NGH THŨNG TIN
KHOA KHOA HC VỊ K THUT MỖY TỒNH



BŨI VN DNG

LUN VN THC S

PHÒT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO
MT MNG IoT

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THC S NGỊNH CŨNG NGH THŨNG TIN

TP. H CHỜ MINH, 2026

**I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC CŨNG NGH THŨNG TIN
KHOA KHOA HC VỊ K THUT MỖY TỜNH**



BŨI VN DNG 220201014

LUN VN THC S

**PHỜT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO
MT MNG IoT**

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THC S NGHỊNH CŨNG NGH THŨNG TIN

GING VIỎN HNG DN

TS. NGUYN VN D

TS. TRỜ NHT

TP. H CHỜ MINH, 2026

THŨNG TIN HI NG BO V LUN VN THC S

Hi ng chm lun vn thc s, thịnh lp theo Quy t nh s ngiy ca Hiu
trng Trng i hc Cũg ngh Thũg tin.

1. Ch tch:

2. Th kỳ:

3. y viốn:

L I C M N

Li u ti3n, tui xin gi li cm n ch3n thnh n quỳ thy cũ ca Trng i hc Cũng Ngh Thũng Tin, i hc Quc gia Thnh Ph H Chờ Minh 3 tn t3nh ch dy, giúp tui tip thu c nhieu kin thc quỳ b3u trong sut thi gian hc tp ti trng, cng nh to iu kin thun li cho tui thc hin lun vn ngy. K3nh chũc thy cũ luũn di d3o sc kho vị gt h3i c nhieu thnh cũng trong tng lai.

c bit, tui xin ch3n thnh cm n thy TS. Nguy3n Vn D vị TS. Trờ Nht 3 tn t3nh giúp , hng dn, cung cp cho tui nhng kin thc, k nng cn thit thc hin nghi3n cu vị hoị3n thnh t3i ngy.

Mc dũ 3 c gng trong qu3 trnh nghi3n cu, do kin thc cũn hn ch n3n vn cũn nhieu thi3u sút. V3 vy, tui rt mong nhn c s úng gúp ý ca Quỳ Thy Cũ t3i ca tui c hoị3n thnh hn.

Tui xin ch3n thnh cm n!

Búi Vn Dng

TÓM TẮT

Sự phát triển nhanh chóng của Internet of Things (IoT) đã mang lại nhiều tin tức trong các lĩnh vực như nông nghiệp, công nghiệp, y tế và giao thông. Tuy nhiên, cũng vì sự phát triển này lại nguy cơ nguy cơ gia tăng và các mối đe dọa an ninh mạng, đặc biệt là khi các thiết bị IoT thông dụng tồn tại nguồn thông tin về vị trí và hoạt động của chúng. Trong bối cảnh này, Intrusion Detection Systems (IDS) cần xem xét một giải pháp quan trọng nhằm phát hiện và ngăn chặn các hành vi tấn công bất thường vào hệ thống mạng IoT.

Lưu ý rằng việc tập trung nghiên cứu, thiết kế và triển khai một hệ thống IDS dựa trên nền tảng xử lý dữ liệu lớn Apache Spark. Spark có khả năng xử lý dữ liệu phân tán, tốc độ cao và hiệu quả xử lý toàn bộ dữ liệu thông qua thư viện MLlib. Hệ thống có ý định nhằm phát hiện các hành vi xâm nhập trong dữ liệu mạng IoT thông qua việc áp dụng các mô hình học máy truyền thống, các mô hình học tập và các mô hình học sâu MLP (cũng như autoencoder đóng vai trò trong phát hiện bất thường thông tin ẩn).

Trong quá trình thực hiện, lưu ý rằng tin nhắn phân tán của dữ liệu mạng IoT, là các vị trí xử lý dữ liệu và việc tập trung dữ liệu cũng khai thác CICIDS2017, sau đó tin nhắn huấn luyện mô hình, đánh giá hiệu quả hệ thống theo các chỉ số chính xác (Accuracy), precision, recall và F1-score, và ghi lại thời gian huấn luyện và thời gian thực thi mô hình. Quá trình đánh giá áp dụng quy trình loại bỏ dữ liệu (loại các trường dữ liệu nhiễu, loại bỏ trùng lặp các trường) nhằm bảo vệ tính riêng tư và bảo mật mô hình. Bên cạnh đó, hệ thống cũng kiểm tra hiệu năng trong mỗi trường xử lý phân tán (proof-of-concept trên các thiết bị biên) nhằm khảo sát khả năng mở rộng và khả năng triển khai thực tế.

Để cụ thể hơn về việc loại bỏ dữ liệu, là các trường SHAP Top-30 giá trị hiệu năng gần nhất với mô hình y trong khi giảm khoảng 60% số các trường: Random Forest đạt F1 0,9955 và mô hình học tập Hybrid Bagging đạt F1 0,9966 trên CICIDS2017; các khối bit gia tăng phép kiểm tra bằng kiểm tra hoàn toàn và ghép cặp vị trí không tin cậy hiệu chỉnh Nadeau–Bengio. Trên các thiết bị Jetson Orin Nano Super, kiến trúc tổng pipeline (các phát hiện bất thường + bộ phân loại PySpark) nóng thông tin phân quyền từ 2,6 đến 62,5 lần/giây (gấp ≈ 24 lần) và thời gian xử lý trung bình 13 ms, trong đó cũng đạt 95,8% lưu lượng băng thông trước khi gửi suy luận Spark. Khả năng xử lý phân tán cũng kiểm tra các mô hình học sâu khởi đầu (proof-of-concept) trên các thiết bị biên, thay vì không như quy mô dữ liệu lớn thực tế. Lưu ý rằng chúng tôi giúp phần việc xây dựng quy trình phát hiện xâm nhập theo thời gian thực mà không cần phải chờ đợi nghiên cứu tìm kiếm trong việc kết hợp học máy và các nền tảng xử lý dữ liệu lớn và bảo mật hệ thống IoT.

MC LC

Thông tin hi ng bo v lun vn	i
Li cm n	ii
Tóm tt	iii
Mc lc	iv
Danh mc còc bng	vii
Danh mc còc hnh v vị th	ix
Danh mc t vit tt	xi
Chng 1. M u	1
1.1 Lý do chn tị	1
1.2 Còc nghiõn cu liõn quan	1
1.3 Mc tiõu, i tng vị phm vi nghiõn cu	3
1.3.1 Mc tiõu nghiõn cu	3
1.3.2 i tng nghiõn cu	4
1.3.3 Phm vi nghiõn cu	4
1.3.4 Còu hi nghiõn cu	5
1.4 Phng phòp nghiõn cu	5
1.5 Còc úng gúp chõnh ca tị	6
1.6 Cũng trõnh ang chun b cũng b	7
1.7 Cu trũc ca lun vn	7
Chng 2. C s lý thuyt	9
2.1 Tng quan v IoT	9
2.2 H thng phòt hìn xóm nhp (IDS)	9
2.3 Apache Spark vị x lý d liu ln	10
2.3.1 D liu ln	10
2.3.2 Còc thnh phn ca Apache Spark	11
2.3.3 Kin trũc ca Apache Spark	13

2.4	Hc mỳ trong phòt hìn xỏm nhp	13
2.4.1	Mt s thut toỏn hc mỳ	14
2.4.2	Mt s thut toỏn hc t hp	18
Chng 3.	Phng phỏp thc hìn	21
3.1	Thu thp d liu vị tin x lý	21
3.2	La chn c trng vị gim chiu d liu	25
3.3	Hun luy n mũ hnh	27
3.3.1	Hun luy n còc mũ hnh c s	27
3.3.2	Còc phng phỏp Ensemble Learning	28
a)	Òp dng Voting	28
b)	Òp dng Bagging	30
3.4	ònh giò mũ hnh	32
3.5	Ti u húa tham s vị hun luy n mũ hnh	34
3.6	Trin khai biổn	36
Chng 4.	Thc nghim, ònh giò vị tho lun	37
4.1	Mũ trng thc nghim	37
4.2	Kt qu thc nghim	38
4.2.1	Kch bn 1: ònh giò hiu nng c s (Baseline)	40
4.2.2	Kch bn 2: So sònh chin lc gim chiu d liu	40
4.2.3	Kch bn 3: Ti u húa tham s	41
4.2.4	Phón tồch kh nng gii thờch vị SHapley Additive exPlanations (SHAP)	42
4.2.5	Phón tồch rò r d liu (data leakage)	43
4.2.6	Phón tồch hiu nng h thng	44
4.2.7	Kim nh ý ngha thng kổ	44
4.2.8	Kim tra n nh trong-phón-phi	45
4.2.8.1	Tng quòt húa liổn b d liu	46
4.2.9	ònh giò a lp theo loi tn cũg	47
4.3	Thc nghim vị ònh giò hiu nng mũ hnh trổn Jetson Orin Nano Super	51
4.3.1	Còc cũg c s dng trong h thng	51
4.3.2	Mũ hnh h thng xut	53
4.3.3	La chn mũ hnh cho thit b biổn	55
4.3.4	Kt qu hun luy n còc mũ hnh ng viổn trổn cm Spark	59

4.3.5	Kt qu o hieu nng (benchmark) trồn Jetson Orin Nano Super	60
4.3.6	So sòn engine suy lun: chi phờ ca vic ng nht stack	60
4.3.7	Kt qu ba ch trin khai phón tòn	61
4.3.8	Phón tồch vị la chn mũ hnh	63
4.4	Tho lun vị So sòn tng hp	64
Chng 5.	Kt lun vị hng phòt trin	65
5.1	Nhng úng gúp chờnh ca lun vn	65
5.2	Hn ch ca tị	65
5.3	Hng phòt trin trong tng lai	67
Ph lc A.	Cũng trnh ang chun b cũng b	69
	Tị liu tham kho	76

DANH MỤC CỜC BNG

3.1	Mũ t b d liu CICIDS2017	22
3.2	Mũ t b d liu CSE-CIC-IDS2018 (dững cho thờ ngihm liễn b d liu)	22
3.3	Tòm b phón loi c s c s dng trong pipeline	27
3.4	Cờc phng phòp hc t hp (ensemble) s dng trong lun vn	28
3.5	Cờc tiũ chờ ònh giò mũ hnh	32
3.6	Ma trn nhm ln ca mũ hnh phòt hin xóm nhp	33
3.7	Thũng s phn cng thit b biễn	36
4.1	Tham s ti u ca cõc mũ hnh hc mỳy	39
4.2	Kt qu hiu nng phón lp kch bn Baseline (toịn b c trng s, ≈ 78 trc khi loi cng) .	40
4.3	So sòn hiu nng tt nht ca cõc phng phòp la chn c trng vị gim chiu	41
4.4	So sòn hiu nng la chn c trng: Random Forest (RF) Importance vs SHapley Additive exPlanations (SHAP) Importance (Top-30)	41
4.5	Kt qu hiu nng phón lp kch bn Ti u húa tham s	42
4.6	Phón tồch loi b (ablation) rừ r: nh hng ca c trng destination_port (Random Forest c nh a priori: numTrees=200, maxDepth=15, cú trng s lp; nh phón)	43
4.7	So sòn thi gian x lý vị kờch thc mũ hnh kch bn Baseline	44
4.8	n nh qua nhieu ln ly mu vị kim nh gổp cp (t statistical_valid- ity_multiseed.csv)	45
4.9	Kim tra n nh trong-phón-phi trởn mu con tp kim tra (t robustness_- holdout_summary.csv)	45
4.10	Tng quòt húa liễn b d liu gia CICIDS2017 vị CSE-CIC-IDS2018 (CSE- CIC-IDS2018: mu phón tng seed=42; t cross_dataset_results.csv) 46	
4.11	Hiu nng theo tng lp tn cũg (t per_class_metrics.csv)	48
4.12	im vn hnh ca cng bt thng khi quỏt quantile trởn tp kim nh benign (10% benign train, seed=42; t gate_operating_points.csv). FPR óy lị t l lung benign b cng chuy n nhm sang b phón loi, khũng phi FPR ca toịn h thng.	55
4.13	Kt qu hun luy n cõc mũ hnh ng viễn cho trin khai biễn (SHAP Top-30) . .	59
4.14	So sòn hiu nng trin khai trởn Jetson Orin Nano Super	60

4.15	Chi phí suy luận một nút trở về cứng mẫu hình/c trung (Spark vs sklearn vs ONNX), o trở về nút phân loại trong cứng iu kin bo mch (batch 10; nng lng lệ phn <i>hot ng</i> , ò tr <i>idle</i>)	61
4.16	So sánh ba ch trình khai phân tòn trở về cm 2 Jetson Orin Nano Super	61

DANH MỤC CỜ HÌNH VÀ VỊ TH

2.1	Mũ hình 5V ca d liu ln [31]	11
2.2	Cờ thịnh phn ca Apache Spark [33]	12
2.3	S kin trúc h thng Apache Spark [32]	13
3.1	Quy trình tng th hun luyn, ònh giò vị trin khai mũ hình xut	21
3.2	S phón chia d liu CICIDS2017. Sau tin x lý vị loi tr r (Thut toàn 4), d liu c chia 80/20 thịnh train/test (<code>seed=42</code>); tp test c gi li, ch đứng cũng b kt qu cui. Trong tp train li tòch 80/20 thịnh base-train (hun luyn, vị <i>fit</i> cờ phõp bin i StandardScaler/PCA cứng vic xp hng c trng) vị validation (chn Top-3 mũ hình thịnh phn vị cp phng phõp a vjo kim nh). Riõng ngng cng bt thng c chn trõn 10% lu lng benign ca tp train (<code>seed=42</code>). Tp test khõng tham gia bt k khõu la chn njo.	25
4.1	Cm hun luyn phón tòn Apache Spark Standalone: MacBook gi vai trù <i>master</i> iu phi (khõng chy executor), hai Jetson Orin Nano Super lị <i>worker/executor</i> thc thi tõnh tõn; d liu Parquet c phón vũng vị ng b sang c hai nũt, kt qu c gom v qua shuffle/collect.	38
4.2	Top 30 c trng quan trng theo giò tr trung bõnh tuyt i SHAP ca mũ hình XGBoost (XGB)	49
4.3	Biu SHAP Summary (beeswarm): phón b vị hng tòc ng ca tng c trng	50
4.4	Ma trn nhm ln a lp theo loi tn cũng (chun hóa theo hịng)	50
4.5	Kin trúc h thng phòt hin xõm nhp phón tòn thi gian thc trõn cm 2 Jetson Orin Nano Super	53
4.6	Giao din terminal khi pipeline IDS hot ng trõn hai node Jetson Orin Nano Super: (a) node cng lc bt thng vị (b) node phón loi PySpark	56
4.7	Dashboard Grafana giòm sòt hiu nng IDS theo thi gian thc	57
4.8	Email cnh bào tn cũng c gi qua Mailtrap trong mũi trng kim th (nh chp t giai on th nghim sm ca h thng; mũ-un cnh bào vị nh dng thõng ip gi nguyõn khi trin khai trõn cm Jetson)	57
4.9	Dashboard Grafana hin th chi tit cờ cuc tn cũng c phòt hin vị phón loi theo thi gian	58

4.10	Dashboard Grafana tỉ thí im tỉ nh ca ch tách pipeline: nút cng (jetson-nano-1) ch s dng khong 5 % CPU trong khi nút phón loi PySpark (jetson-nano-2) t tỉ 91 %	58
4.11	Thũng bào cnh bào tn cũg c gi qua Slack Incoming Webhook (nh chp t giai on th nghi m; nh dng thũng ip gi nguỷn khi trin khai trở cm Jetson)	59
4.12	Thũng lng vị tr p95 ca bn cu hnh (mt nút c s + ba ch phón tòn) trở cm 2 Jetson	62
4.13	So sòn hiu nng ba mũ hnh trở Jetson Orin Nano Super	63
4.14	Biu radar th hin s ònh i (trade-off) gia còc mũ hnh trở thit b biổn	64

DANH MỤC T VIẾT TẮT

AC	accuracy
BD	Big Data
CNN	Convolutional Neural Network
CV	Cross-Validation
DT	Decision Trees
EL	Ensemble Learning
FS	F1-score
GBT	Gradient Boosted Trees
GS	Grid Search
IDS	Intrusion Detection Systems
IoT	Internet of Things
kNN	k-Nearest Neighbors
LGBM	LightGBM
LR	Logistic Regression
LSTM	Long Short-Term Memory
ML	Machine Learning
MLP	Multilayer Perceptron
NB	Naive Bayes
PCA	Principal Component Analysis
PR	precision
RE	recall
RF	Random Forest
RFI	Random Forest Importance
RNN	Recurrent Neural Network
SCP	Secure Copy Protocol
SHAP	SHapley Additive exPlanations
SVM	Support Vector Machine
XGB	XGBoost

Chng 1. M U

1.1 Lý do chn tii

Trong k nguyên ca Còch mng Cũng nghip 4.0, IoT ang phòt trin nhanh vị c ng dng rng ròi trong nhieu lnh vc nh nhậi thũng minh, y t, giao thũng, cũng nghip thũng minh,... S bứng n v s lng thit b IoT dn n s gia tng òng k v lu lng vị loi hnh d liu truyn trong mng. Tuy nhiên, còc thit b IoT thng cú kh nng x lý hn ch vị thi u còc c ch bo mt mn, khin chũng tr thnh mc tiều d b tn cũng bi tin tc.

i phú vì còc mi e đa an ninh mng, còc h thng phòt hin xóm nhp (IDS) ang c nghiỏn cu vị phòt trin rng ròi. c bit, trong nhng nm gn óy, vic kt hp hc mỳy (Machine Learning (ML)) vị còc nn tng x lý d liu ln giúp h thng nóng cao chỏnh xỏc phòt hin vị thờch nghi tt hn vì mủi trng mng thay i liỏn tc. Cn lu ý rng b phón loi chỏnh trong lun vn lý mủi hnh hc cú giỏm sỏt trỏn CICIDS2017 nỏn ch phòt hin c còc h tn cũng ỏ bit; kh nng phòt hin hnh vi bt thng cha tng thy (nu cú) n t cng phòt hin bt thng (anomaly gate) hc khũng giỏm sỏt, ch khũng phi t b phón loi. Tuy nhiên, phn ln còc nghiỏn cu hin nay tp trung vớo vic xỏy dng mủi hnh hc mỳy trỏn tp d liu tnh, dung lng nh vị hun luy n goi tuyn (offline).

Trong khi ú, mng IoT hin i sinh ra lng d liu rt ln, liỏn tc theo thi gian thc ùi hi còc h thng IDS cú kh nng x lý d liu ln (Big Data (BD)) hieu qu, cú th hot ng trong mủi trng phón tòn vị thi gian thc.

Apache Spark lị mt nn tng x lý d liu ln, vị kh nng x lý song song, phón tòn vị d dng tỏch hp vị th vin hc mỳy Spark MLlib lị mt gii phỏp tìm nng xỏy dng h thng IDS hin i ỏp ng yỏu cu v quy mủ vị thi gian thc trong mủi trng IoT.

1.2 Còc nghiỏn cu liỏn quan

Trong nhng nm gn óy, còc h thng phòt hin xóm nhp (Intrusion Detection System – IDS) đa trỏn hc mỳy vị hc sỏu ỏ thu hũt nhieu s quan tótm ca cng ng nghiỏn cu nhm nóng cao chỏnh xỏc vị kh nng thờch ng trc còc hnh thc tn cũng mng ngậi cựng tinh vị [1, 2, 3]. Nhieu cũng trớnh tp trung khai thờc còc kin trức hc sỏu nh autoencoder, mng tỏch chp (Convolutional Neural Network (CNN)) vị mng n-ron hi quy (Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM)) t ng trỏch xut c trng vị phòt hin bt thng trong lu lng mng. Tuy nhiên, phn ln còc nghiỏn cu hin nay vn c trin khai trong mủi trng n mỳy, x lý d liu tnh vị quy mủ tng i nh, vị cha tỏch hp còc nn tng x lý d liu ln nh Apache Spark hay Hadoop

nhm òp ng yểu cu v kh nng m rng vị x lý thi gian thc trong còc h thng mng hin i.

Mt s nghiỏn cu ò xut còc mũ hnh IDS hc sỏu da trỏn còc kin trũc nh autoencoder, CNN v LSTM nhm nỏng cao kh nng hc c trng vị phòt hin xỏm nhp mng. Còc mũ hnh nỳ c ònh giò trỏn còc tp d liu chun nh NSL-KDD, CIC-DDoS2019 v CICIDS2017, cho thy hieu qu cao trong vic phòt hin bt thng. Tuy nhiỏn, quò trỏnh hun luyn vị ònh giò vn ch yu c thc hin trong mũ trng cc b vị theo c ch x lý theo lũ (batch) [4, 5]. Tng t, còc mũ hnh lai da trỏn LSTM (chng hn CNN-LSTM, hay LSTM c ti u húa siỏu tham s) cho bỳ toỏn phòt hin bt thng trong mng cng t c kt qu kh quan, nhng vn trin khai trỏn nn tng n nũt (single-node) vị cha khai thỏc c kh nng m rng ca còc h thng Big Data [6, 7]. Gn óy, mt s nghiỏn cu ò trin khai IDS hc mỳy trc tip trỏn phn cng biỏn NVIDIA Jetson [8, 9], hay trỏn mũ trng biỏn mũ phng rỳng buc tỳ nguyỏn [10], nhng vn quy mũ n nũt vị cha tỏch hp c ch x lý lung phỏn tòn.

Bỏn cnh còc phng phỏp hc sỏu, còc k thut hc mỳy truyn thng nh Support Vector Machine (Support Vector Machine (SVM)), k-Nearest Neighbors (k-Nearest Neighbors (kNN)) v Decision Tree vn c s dng rng rỏi trong còc h thng IDS. Mt s nghiỏn cu ò tin hnh so sỏnh hieu nng ca còc mũ hnh nỳ trỏn còc b d liu ph bin nh NSL-KDD v UNSW-NB15, qua ú ch ra rng còc phng phỏp hc mỳy truyn thng cú tim nng ng dng thc tin cao. Tuy nhiỏn, còc mũ hnh nỳ ch yu hot ng ch offline, x lý d liu theo tng t vị cha òp ng c yểu cu v x lý d liu liỏn tc trong mũ trng mng ng [11]. Ngoỳ ra, mt s cũng trỏnh so sỏnh nhiu mũ hnh hc mỳy vị hc sỏu cho IDS, ghi nhn còc mũ hnh da trỏn cỳ nh Random Forest cho kt qu tt trỏn còc b d liu ln, nhng toỏn b thc nghiỏm vn c thc hin trỏn mt mỳy n [12].

Ngoỳ còc kin trũc nỏu trỏn, nhiu mũ hnh hc sỏu khỏc nh CNN, RNN v còc mũ hnh lai CNN-LSTM cng ò c nghiỏn cu vị ònh giò cho bỳ toỏn phòt hin xỏm nhp mng. Còc nghiỏn cu nỳ cho thy kh nng ci thỳn òng k chỏnh xỏc so vị còc phng phỏp truyn thng khi th nghiỏm trỏn còc b d liu nh CICIDS2018. Tuy nhiỏn, phn ln còc mũ hnh vn thiu kh nng trin khai trong mũ trng thi gian thc vị cha tn dng c sc mnh ca còc nn tng x lý d liu ln [13].

Trong bi cnh Internet of Vehicles (IoV), mt s nghiỏn cu ò xut còc h thng IDS da trỏn hc mỳy vị hc sỏu nhm bo v còc mng phng tin thũng minh. Còc phng phỏp nỳ bao gm vic s dng còc mũ hnh da trỏn cỳ (tree-based), còc h thng phòt hin xỏm nhp a tng, cng nh còc mũ hnh ensemble ci thỳn chỏnh xỏc phòt hin tn cũng. Mc dũ t c kt qu kh quan trỏn còc b d liu th nghiỏm, còc h thng nỳ vn ch yu c hun luyn vị ònh giò trong mũ trng ngoi tuyn, x lý d liu theo batch vị cha tỏch hp còc nn tng x lý d liu ln hoc c ch x lý d liu theo lung [14, 15, 16].

Bổn cnh ú, mt s hng tip cn gn óy ã nghiõn cu vic òp dng hc bõn giõm sòt, hc liõn kt (federated learning) vï hc tng dn (incremental/active learning) cho bïi toànn IDS nhm nõng cao kh nng thờch ng ca mĩ hõnh vï bo v quyn riõng t d liu. Cõc phng phõp nïy cho phõp phõn tòn quõ trõnh hun luyn trõn nhiu nũt hoc thit b IoT khõc nhau. Tuy nhiõn, d liu vn ch yu c x lý theo tng t, thiu c ch x lý lung t p trung vï cha khai thờc y kh nng m rng cng nh song song húa ca cõc nn tng Big Data [17, 18, 19, 20, 21].

T tng quan cõc cõng trõnh nghiõn cu nõu trõn, cú th nhn thy rng phn ln cõc h thng IDS hin ti vn hot ng trong mĩi trng ngoi tuyn, cha h tr x lý d liu liõn tc theo thi gian thc vï cha tn dng c kh nng m rng ca cõc nn tng x lý d liu ln. Do ú, lun vn nïy hng n vic tõch hp cõc mĩ hõnh hc mỳy da trõn nn tng Apache Spark nhm xõy dng mt h thng phõt hin xõm nhp cú kh nng x lý d liu ln, h tr thi gian thc vï òp dng hïu qu trong mĩi trng mng IoT hin i.

1.3 Mc tiõu, i tng vï phm vi nghiõn cu

1.3.1 Mc tiõu nghiõn cu

Mc tiõu ca tị PHÒT HIN XÕM NHP (IDS) DA TRÕN APACHE SPARK CHO BO MT MNG IoT lị xõy dng mt h thng phõt hin xõm nhp cú kh nng phõn thờch vï phõt hin cõc hïnh vi bt thng hoc tn cõng mng trong mĩi trng IoT bng cõch kt hp cõc mĩ hõnh hc mỳy vi nn tng x lý d liu ln Apache Spark nhm t c:

- Phõt hin hïu qu cõc dng tn cõng mng ph bin (nh DoS, probing, brute-force) trõn cõc tp d liu hin i nh CICIDS2017.
- Thit k vï trin khai pipeline x lý d liu phõn tòn vï song song s dng Apache Spark, bao gm cõc bc: tin x lý d liu, thờch xut c trng, hun luyn mĩ hõnh vï phõt hin thi gian thc.
- Kho sòt hïu nng h thng, hng ti kh nng m rng, tr thp vï tõnh linh hot; kim chng kh nng x lý phõn tòn mc minh chng khõì nim (proof-of-concept) trõn cm thit b biõn, lịm tin cho vic trin khai trõn cõc h thng ln hoc mng IoT nhiu thit b.
- So sõnh vï ònh giõ cõc mĩ hõnh hc mỳy ph bin nh Decision Tree, Support Vector Machine, Logistic Regression, Naive Bayes (NB), Random Forest, Gradient Boosted Trees (GBT), XGBoost (XGB), Multilayer Perceptron (MLP) vï cõc thut toànn hc t hp (ensemble) trong mĩi trng x lý phõn tòn, t ú chn ra mĩ hõnh phứ hp nht.
- Òp dng quy trõnh ònh giõ cht ch, loi tr rừ r d liu (loi c trng rừ r nhõn, loi b trng lp mc c trng, kim nh ý ngha thng kõ) nhm m bo kt qu phn ònh ỹng nng lc mĩ hõnh.

- xut gii phòp the tin giúpp phòt hin tn cũng nhanh chúng vị chònh xóc trong còc h thng mng hin i cú yóu cu x lý d liu ln vị lión tc.

1.3.2 i tng nghiỏn cu

tị nịy tp trung nghiỏn cu vị trin khai phng phòp phòt hin xóm nhp trong lnh vc bo mt mng IoT bng còch tn dng sc mnh ca nn tng x lý d liu ln Apache Spark. Vì s phòt trin nhanh chúng ca còc thit b IoT, vn m bo an toịn vị bo mt cho h thng ngiỵ cịng tr nỏn cp thit, c bit lị trong vic phòt hin còc hịnh vi bt thng hoc tn cũng mng tim n.

Apache Spark, vị kh nng x lý d liu phón tòn vị tc tồnh toòn cao, cho phỏp x lý khi lng ln d liu sinh ra t còc thit b IoT trong thi gian thc. Trong khuỷn kh nghiỏn cu nịy, lun vn s dng còc tồnh nng ca Spark nh x lý lung d liu (streaming), hc mỳy phón tòn (MLlib) vị phón tồch d liu quy mũ ln xóy dng mũ hỏnh phòt hin xóm nhp hiu qu. Qua ú, tị khũng ch xut mt gii phòp k thut cú tồnh ng dng cao mị cùn gúp phn nỏng cao hiu qu bo mt cho còc h thng IoT trong thc tin.

1.3.3 Phm vi nghiỏn cu

tị tp trung vịo vic nghiỏn cu vị ỏp dng còc k thut phón tồch d liu ln nhm phòt hin xóm nhp trong h thng mng IoT vị mc ỏch lị khai thỏc nhng im mnh ca nn tng Apache Spark x lý vị phón tồch d liu hiu qu. C th, phm vi nghiỏn cu bao gm:

- **D liu u vịo:** D liu c s dng lị tp d liu cũng khai CICIDS2017.
- **Cũng ngh s dng:** S dng Apache Spark lịm nn tng x lý d liu ln, c bit tp trung vịo còc thịnh phn nh Spark Core, Spark SQL, Spark Streaming vị Spark MLlib h tr tin x lý d liu, hun luy n mũ hỏnh hc mỳy vị phòt hin xóm nhp theo thi gian thc.
- **Phng phòp phòt hin xóm nhp:** Ỏp dng còc thut toòn hc mỳy c trin khai vị tị u húa trong mũ trng Spark m bo kh nng m ng vị hiu nng cao.
- **Mũ trng trin khai:** Th ngim h thng trỏn mt mũ trng gị lp mng IoT vị b d liu mũ phng cũng khai (CICIDS2017) nhm ònh giỏ kh nng phòt hin xóm nhp.

Lu ý v phm vi d liu. Cn nhn mnh rng CICIDS2017 lị b d liu lu lng mng doanh ngiipy mũ phng, khũng cha lu lng c thứ IoT (vở d còc giao thc MQTT, CoAP) hay thit b IoT thc. Tồnh cht “IoT” ca tị do ú nm *kch bn trin khai*: toịn b pipeline suy lun c thit k, tị u vị o c trỏn thit b biỏn tị nguyỏn hn ch (NVIDIA Jetson Orin Nano Super), lp thit b úng vai

trừ gateway/biến trong kin trúc IoT ba tng — thay vớ bn cht lu lng ca d liu hun luyn. CICIDS2017 c chn vớ lị b chun cũng khai, c cng ng s dng rng rãi, cú nhõn chỉ tit vị bao ph còc h tn cũng (DoS/DDoS, brute-force, web attack, botnet) cng xut hin ph bin trong còc mng IoT; còc ngun li ca b d liu nịy ò c nghiõn cu k, cho phõp òp dng quy trõnh loi tr rù r mt còch cú cn c. Vic kim chng trõn còc b d liu IoT chuyõn bit (Bot-IoT, TON_IoT, CIC-IoT-2023) c xòc nh lị hng phòt trin tip theo (Chng 5).

Mũ hõnh mĩ e da (threat model). Lun vn gi nh k tn cũng nm bốn trong hoc biõn mng IoT vị tởm còch nõ trõnh phòt hin; phm vi bo v giĩ hn vic phòt hin còc tn cũng ò bit theo kiu CICIDS2017, di dng phón loi nh phón Benign/Attack. Còc kch bn i khõng ch ng (adversarial/evasion) nhm c ý ònh la mũ hõnh nm ngoịi phm vi ònh giò ca lun vn.

1.3.4 Cúu hi nghiõn cu

Lun vn c nh hng bi ba cúu hi nghiõn cu:

- **RQ1:** Vic gim chiu/la chn c trng (RF Importance, SHapley Additive exPlanations (SHAP), Principal Component Analysis (PCA)) cú gi c hieu nng phòt hin gn vi mc đứng toịn b c trng hay khũng, khi s c trng gim hn 60%?
- **RQ2:** Còc mũ hõnh hc t hp (Ensemble Learning (EL)) cú mang li li th òng k so vi mũ hõnh n tt nht hay khũng, khi khòc bit c kim chng bng kim nh thng kỏ thay vớ so sònh mt ln o?
- **RQ3:** Mt pipeline IDS da trõn Spark cú kh thi v thũng lng, tr vị nng lng khi trin khai phón tòn trõn cm thit b biõn tị nguyõn hn ch (Jetson Orin Nano Super) hay khũng?

1.4 Phng phòp nghiõn cu

- **Thu thp, phón tỏch, x lý d liu:** S dng tp d liu CICIDS2017, t ú tin hịnh phón tỏch, x lý vị trc quan húa d liu.
- **Nghiõn cu v phng phòp tĩ u húa siỏu tham s, còc phng phòp gim chiu d liu:** Nghiõn cu còc phng phòp gim chiu d liu nh PCA, SHAP vị Random Forest Importance nhm gim nhieu vị tng chõnh xòc, ng thi tĩ u húa siỏu tham s thũng qua tởm kim li (Grid Search) vị kim nh chỏo (cross-validation) giũp nỏng cao hieu nng mũ hõnh. Còc bc nịy c trin khai trõn nn tng Apache Spark nhm m bo kh nng x lý d liu ln hieu qu vị m rng.

- **Nghiên cứu vị xuất mô hình học máy, học sâu (MLP; vị mô autoencoder lịm cng phôt hìn bt thng), học tập phôt hìn xóm nhp s dng Spark Machine Learning:** S dng nhieu thut toàn khòc nhau nh Decision Tree, Support Vector Machine, Logistic Regression, NB, Random Forest, GBT, XGB, MLP vị còc thut toàn học tập (ensemble) xóy dng mô hình nhm so sònh, ònh giò mô hình cú hieu nng tt nht.
- **Thực nghiệm vị ònh giò hieu nng mô hình trởc cm Jetson Orin Nano Super:** Xóy dng mô h thng phôt hìn xóm nhp mng IDS *phón tòn* trin khai trởc cm hai thit b biổn Jetson Orin Nano Super (cng phôt hìn bt thng trởc mô nửt, b phón loi PySpark trởc nửt cùn li) nhm ònh giò kh nng hot ng trong mủi trng tị nguyổn hn ch. H thng c thit k theo kin trúc x lý d liu thi gian thc, tn dng Apache Kafka cho c ch truyն tị thũng ip, Spark Streaming cho x lý lung d liu, PostgreSQL qun lý d liu, InfluxDB lu tr ch s hieu nng theo thi gian, Grafana trc quan hóa vị Mailtrap phc v kim th c ch cnh bòa qua email.

1.5 Còc ứng gúp chờnh ca tị

- **xuất gii phòp ng dng Apache Spark trong phôt hìn xóm nhp cho h thng mng IoT:** tị ò xóy dng mô mô hình phôt hìn xóm nhp đa trởc nn tng x lý d liu ln Apache Spark, tn dng kh nng x lý phón tòn vị thi gian thc ca Spark, hng tị òp ng yổu cu v hieu nng vị tòngh m rng trong mủi trng IoT cú khi lng d liu ln vị bin i liổn tc; kh nng x lý phón tòn c kim chng mc minh chng khòl nim (proof-of-concept) trởc cm thit b biổn.
- **Xóy dng quy trnh x lý vị phôt hìn xóm nhp toịn đin trởc d liu IoT:** T bc tin x lý d liu, trỏch xuất c trng, hun luyն mô hình ònh giò kt qu, tị ò thit k vị hìn thc mô quy trnh phôt hìn xóm nhp hoịn chnh cú th òp dng cho còc h thng thc t.
- **ng dng vị ònh giò còc thut toàn học máy trong mủi trng phón tòn:** tị trin khai vị so sònh hieu qu ca mô s thut toàn học máy vị mô hình học sâu MLP trởc nn tng Apache Spark MLlib (ngoị ra mô autoencoder c đứg lịm cng phôt hìn bt thng tng biổn), qua ú lịm rử u im vị hn ch ca tng mô hình trong vic x lý d liu IoT.
- **ònh giò hieu nng h thng trong mủi trng x lý phón tòn:** Khũng ch ònh giò chờnh xòc ca mô hình, tị cùn phón tòch hieu nng x lý (thi gian thc thi, kh nng m rng) ca h thng nhm kho sòt tòngh kh thi ca gii phòp; vic kim chng c thc hìn mc minh chng khòl

nim (proof-of-concept) trốn cm thit b biến vì b d liu CICIDS2017, lịm c s cho vic m rng quy mũ v sau.

- **Quy trình ònh giò loi tr rừ r d liu vị cú kim nh thng kổ:** tị nhn din vị loi b còc ngun rừ r d liu thng gp trốn CICIDS2017 (c trng `destination_port` rừ r nhõn, trúng lp lung mc c trng), ng thi òp dng kim nh ì ngha thng kổ, giúp kt qu phn ònh ững nng lc mũ hnh thay vớ còc con s b thi phng.

1.6 Cũng trnh ang chun b cũng b

Mt phn kt qu ca lun vn c phòt trin thnh hai bn tho khoa hc (vit chung vì Nguyn V Thòi, Trờ Nht vị TS. Nguyn Vn D), hin ang c hoịn thìn gi ng (cha np ti thi im hoịn thnh lun vn):

1. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.
2. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Distributed Real-Time Intrusion Detection System on a Jetson Orin Nano Super Edge Cluster using Kafka and PySpark,” Symposium on Information and Communication Technology (SOICT), 2026.

1.7 Cu trũc ca lun vn

Lun vn vì tị “PHÒT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO MT MNG IoT” c trnh bịy bao gm 5 chng. Ni dung tóm tt tng chng c trnh bịy nh sau:

- **Chng 1: M u:** Trnh bịy tng quan v bi cnh vị lý do chn tị, mc tiõu nghiõn cu, phm vi nghiõn cu, cõu hi nghiõn cu vị phng phòp tip cn. Ngoịi ra, chng nịy cng nõu rũ ì ngha thc tin vị khoa hc ca tị, cng nh b cc tng th ca lun vn.
- **Chng 2: C s lý thuyt:** Trnh bịy còc khòl nim c bn vị nn tng lý thuyt phc v cho tị, bao gm tng quan v mng IoT, còc l hng vị mi e da bo mt, phng phòp phòt hin xóm nhp (IDS), vị kin thc liõn quan n Apache Spark. Ngoịi ra, chng nịy cng phón tồch còc thut toòn hc mỳy thng c s dng phòt hin xóm nhp.

- **Chng 3: Phng phòp thc hin:** Trnh bỳ chi tit còc bc xóy dng h thng phòt hin xóm nhp, bao gm thu thp vỹ tin x lý d liu, thit k kin trũc h thng s dng Apache Spark, la chn vỹ trin khai còc thut toòn hc mòy, cũng quy trnh hun lun vỹ ònh giò mũ hõnh.
- **Chng 4: Thc nghim, ònh giò vỹ tho lun:** Trnh bỳ kt qu thc nghim trõn b d liu thc t hoc mũ phng, ònh giò hũu nng ca còc mũ hõnh ò trin khai theo còc tiõu chõ nh chõnh xòc, Recall, F1-score, kòch thc ca mũ hõnh vỹ thi gian x lý. ng thi, chng nỹ cng phón tòch, so sònh vỹ tho lun v còc kt qu t c nhm lĩm rũ hũu qu ca phng phòp xut.
- **Chng 5: Kt lun vỹ hng phòt trin:** Tng kt nhng kt qu chõnh mĩ tĩ t c, nõu bt nhng úng gúp chõnh, ng thi ch ra nhng hn ch cùn tn ti vỹ xut còc hng phòt trin trong tng lai, nh vỹc tòch hp còc mũ hõnh hc sỏu hoc trin khai h thng trõn nn tng òm mỏy nõng cao tòngh kh dng vỹ kh nng m rng.

Chng 2. C S LÝ THUYT

Chng nỳ trnh bỳ còc nn tng lý thuyt liỏn quan n ỳ, bao gm tng quan v Internet vn vt (IoT), còc mi e đa an ninh trong h thng IoT, v ỳ vai trũ ca h thng phòt hin xỏm nhp (IDS). Bỏn cnh ỳ, trong chng nỳ, lun vn cng gii thiu kin trũc v ỳ kh nng ca Apache Spark trong x lý d liu ln, còc k thut hc mỳy ng dng trong phòt hin xỏm nhp v ỳ còch Spark MLlib h tr xỏy dng mũ hnh hc mỳy phỏn tòn. (Còc nghiỏn cu liỏn quan v ỳ khong trng nghiỏn cu ỏ c kho sỏt Chng 1.)

2.1 Tng quan v IoT

Internet of Things (IoT) l ỳ mng li còc thit b vt lý c tồch hp cm bin, phn mm v ỳ kh nng kt ni mng, cho phỏp thu thp v ỳ trao i d liu qua Internet [22]. IoT bao gm còc thit b nh cm bin mũ trng, thit b gia dng thũng minh v ỳ phng tin giao thũng to ra khi lng d liu ln v ỳ c im a dng, tc cao v ỳ yỏu cu x lý thi gian thc. Theo bờo bờo Cisco Annual Internet Report (2018–2023), tng s thit b ni mng to ỳn cu c d bờo t khong 29,3 t v ỳo nm 2023, trong ỳ khong mt na l ỳ kt ni mỳy-vi-mỳy (M2M/IoT), nhn minh tm quan trng ca bo mt trong lnh vc nỳ [23]. Kin trũc IoT thng c chia thnh ba tng:

- **Tng cm bin (Perception Layer):** Thu thp d liu t cm bin v ỳ thit b.
- **Tng mng (Network Layer):** Truyn ti d liu qua còc giao thc nh MQTT, CoAP hoc HTTP.
- **Tng ng dng (Application Layer):** Phỏn tồch d liu cụng cp dch v [24].

Tuy nhiỏn, còc thit b IoT thng cú t ỳ nguyỏn hn ch (b nh, nng lng, kh nng tòngh tòn), dn n thỏch thc trong vic trin khai còc gii phỏp bo mt truyn thng. Còc mi e đa nh tn cũng t chỉ dch v (DDoS), tn cũng gi mo v ỳ khai thờc l hng giao thc ùi hi còc gii phỏp bo mt tiỏn tin nh IDS [25].

2.2 H thng phòt hin xỏm nhp (IDS)

H thng phòt hin xỏm nhp (IDS) giỏm sỏt v ỳ phỏn tồch hot ng mng hoc h thng phòt hin còc hnh vi bt thng hoc òng ng, nhm bo v h thng khi còc cuc tn cũng mng [26]. IDS ỳng vai trũ quan trng trong vic m bo tòngh bo mt, to ỳn vn v ỳ sn sụng ca h thng IoT. IDS c phỏn loi nh sau:

Da trổn v trỏ trìn khai:

- **Network-based IDS (NIDS):** Giỏm sỏt lu lng mng phỏt hin cỏc mu tn cũg.
- **Host-based IDS (HIDS):** Tp trung vọ hot ng ca mt thit b c th.

Da trổn phng phỏp phỏt hin:

- **Signature-based IDS:** S dng cỏc mu tn cũg ỏ bit, hiu qu vi cỏc mi e da quen thuc nhng hn ch vi cỏc tn cũg mi.
- **Anomaly-based IDS:** Phỏt hin hnh vi bt thng da trổn mũ hnh hot ng bnh thng, phứ hp vi cỏc cuc tn cũg cha bit [27, 28]; cỏc b phỏt hin da trổn hc sỏu nh autoencoder [29] hay mng nim tin sỏu (Deep Belief Network) [30] li mt hng ph bin ca nhúm nọy.
- **Hybrid IDS:** Kt hp c hai phng phỏp tng chỏnh xỏc [26].

Trong IoT, IDS phi x lý khi lng d liu ln vọ ỏp ng yỏu cu thi gian thc, ng thi phứ hp vi tọt nguyỏn hn ch ca thit b. Cỏc gii phỏp IDS da trổn d liu ln vọ hc mọy, nh s dng Apache Spark, li hng i tim nng gii quyỏt cỏc thỏch thc nọy [25].

2.3 Apache Spark vọ x lý d liu ln


2.3.1 D liu ln

D liu ln (*Big Data*) li mt thut ng c s dng mũ t tp hp d liu cú quy mũ ln, phc tp vọ a dng, bao gm d liu cú cu trức, d liu khũng cú cu trức vọ d liu bòn cu trức n mc khũng th x lý hiu qu bng cỏc cũg c vọ phng phỏp trun thng.

Ngọy nay, kỏch thc ca cỏc tp d liu cú th c coi li d liu ln dao ng t **terabyte**, **petabyte** n **exabyte**. Khỏi nim v d liu ln s ph thuc vọ ngnh cũg nghip, cỏch d liu c s dng, lng d liu lch s liỏn quan vọ nhieu c im khỏc.

D liu ln thng c nhn đin thũg qua nm c im ct lủi: **Khi lng** (*Volume*), **Tc** (*Velocity*), **Tỏnh a dng** (*Variety*), **Tỏnh xỏc thc** (*Veracity*) vọ **Giỏ tr** (*Value*) (Hỏnh 2.1). ỏy li nhng yu t quan trng giứp phỏn bit d liu ln vi cỏc loi d liu thũg thng, phn ỏnh quy mũ, tc phỏt sinh, s phong phứ v nh dng, tin cy vọ tim nng khai thỏc thũg tin t d liu.

- **Khi lng (Volume):** cp n quy mũ d liu cc ln.
- **Tc (Velocity):** Tc d liu c to ra, trun ti vọ x lý.



Hành 2.1. Mũ hình 5V ca d liu ln [31]

- **Tồnh a dng (Variety):** Ngun vị nh dng d liu a dng nh vn bn, hnh nh, video, v.v.
- **Tồnh xóc thc (Veracity):** Mc òng tin cy vị cht lng ca d liu.
- **Giò tr (Value):** Tim nng khai thóc thũng tin hu òch t d liu.


D liu sinh ra t còc thit b IoT c xem lị mt trong nhng ngun to ra d liu ln (BD) quan trng vị phòt trin nhanh chóng hin nay. Vì hịng t thit b cm bin, mỳ mỳc, thit b eo tay vị phng tin kt ni Internet, lng d liu c to ra mĩ ngỳy rt ln, a dng v nh dng vị tc phòt sinh liỏn tc theo thi gian thc. D liu IoT mang y còc c im ca d liu ln nh: khi lng (volume) ln, tc (velocity) cao, tồnh a dng (variety) v loi d liu, mc xóc thc (veracity) khũng ng u vị tim nng mang li giò tr (value) ln nu c khai thóc hiu qu. Chờnh vớ vy, d liu IoT khũng ch lị mt phn ca d liu ln mị cùn úng vai trò quan trng trong vic thũc y nhu cu phòt trin còc nn tng x lý d liu ln hin i.

2.3.2 Còc thnh phn ca Apache Spark

Trong nhng nm gn óy, còc nn tng x lý d liu ln nh Apache Spark ò thu hũt s quan tòm rng rồi t cng ng nghiỏn cu vị cũng nghiip. Apache Spark lị mt h thng x lý d liu phón tòn quy mũ ln, cú kh nng thc thi nhanh còc tỳc v trởn còc cm d liu ln. So vị Hadoop MapReduce, Spark cú th t tc x lý nhanh hn khong 100 ln trong mt s trng hp nh vị kh nng x lý trong b nh (*in-memory processing*) [32, 33].

Bổn cnh ú, Spark cung cp giao đin lp trnh linh hot thng qua ccc API h tr nhiu ngũn ng ph bin nh Java, Scala, Python v R, giúp vic phòt trin v trin khai ng dng tr nnn thun tin hn.

Apache Spark bao gm nhiu thnh phn chõnh to thnh mt h sinh thoi hoĩn chnh, h tr a dng ccc tcc v phõn tcc d liu nh x lý d liu theo lũ (batch), truy vn SQL, phõn tcc lung d liu thi gian thc, hc mỳy v x lý th (Hõnh 2.2).



Hõnh 2.2. Ccc thnh phn ca Apache Spark [33]


Apache Spark bao gm nhiu thnh phn ct lõi, mĩ thnh phn m nhn mt chc nng c th trong quõ trnh x lý d liu ln:

- **Spark Core:** Thnh phn trung tmm ca Spark, chu trõch nhim qun lý b nh, lp lch, x lý li, phõn phi tcc v v giao tip v ccc h thng lu tr. Nũ cung cp ccc API cp cao cho Java, Scala, Python v R, giúp n gin hĩa vic x lý phõn tcc.
- **MLlib:** Th vin hc mỳy tcc hp sn trong Spark [34], h tr hun luyt v trin khai ccc mĩ hõnh hc mỳy trõn quy mĩ ln. MLlib cung cp ccc thut toàn nh phõn loi, hi quy, phõn cm, khai thcc mu v lc cng tcc.
- **Spark Streaming:** Cũng c x lý d liu thi gian thc bng cõch chia lung d liu thnh ccc lũ nh x lý tng t nh d liu theo lũ. Cũng c nịy cho phõp s dng li mĩ ngun v h tr nhiu ngun d liu nh Kafka, Flume, Twitter, HDFS.
- **Spark SQL:** Thnh phn truy vn d liu phõn tcc, h tr ngũn ng SQL tiõ chun v HiveQL v hũ sut cao nh ti u hĩa Catalyst v nh dng ct. Nũ h tr nhiu ngun d liu nh JSON, Hive, Parquet, JDBC, MongoDB, Cassandra.

- **GraphX**: Th vin x lý th phón tòn, h tr biu din, chuyn i vị phón tồch d liu th. GraphX i kóm vi còc thut toòn th ph bin nh PageRank, Connected Components vị nhiu thut toòn phón tồch khòc.

2.3.3 Kin trũc ca Apache Spark

Kin trũc ca Apache Spark c xóy dng theo mĩ hnh masterworker trổn nn tng x lý phón tòn. Thnh phn trung tóm lị **Spark Driver**, chu tròch nhim iu phi quò trnh thc thi ng dng, bao gm vic lỏn lch, phón phi tồc v vị giòm sòt tin trnh. Driver xóy dng mt th phi chu trnh cú hng (DAG – Directed Acyclic Graph) xòc nh lung thc thi cũng vic; tng quan kin trũc master–worker c minh ha Hnh 2.3.



Hnh 2.3. S kin trũc h thng Apache Spark [32]

Còc tồc v c phón phi ti còc **Worker Nodes**, ni cha còc **Executor** tin trnh thc thi thc t. Mi Executor chu tròch nhim thc thi còc tồc v (task) vị lu tr d liu trong b nh hoc a nu cn. Spark s dng **Cluster Manager** (nh YARN, Mesos hoc Standalone) qn lý tị nguỷn trổn cm. D liu c lu tr trổn còc h thng nh HDFS, S3, hoc còc c s d liu quan h.

2.4 Hc mỳ trong phòt hìn xóm nhp

Hc mỳ (ML) ò tr thnh mt cũng c thit yu trong vic phòt hìn còc mu tn cũng vị hnh vi bt thng trong lu lng mng IoT, nh kh nng t ng hc vị thờch ng t d liu lch s [35]. Còc k thut hc mỳ ph bin bao gm:

- **Hc cú giòm sòt (Supervised Learning)**: S dng d liu ò c gòn nhõn hun luyt mĩ hnh phón loi. Mt s thut toòn in hnh gm Random Forest (RF), SVM vị Mng n–ron nhón to (Neural Networks).

- **Hc khũng giòm sòt (Unsupervised Learning):** Ớp dng cho còc tónh hung khũng cú nhõn, tp trung vọ vic phòt hin còc mu bt thng. K-Means lị mt thut toòn ph bin trong nhúm nịy.
- **Hc tng cng (Reinforcement Learning):** Mũ hnh hc đa trổn phn hi t mũi trng nhm tí u hóa hnh vi hoc quy t nh ca h thng theo thí gian; hng nịy khũng thuc phm vi thc nghim ca lun vn vı ch c nõu hoịn chnh bc tranh phón loi.

Trong bı cnh mng IoT, hc mọy c ng dng rng rổi phón tồch lu lng d liu vı nhn đın còc loi tn cũng nh DDoS, botnet hay gı mo gúi tin. Chng hn, Koroniotis vı cng s (2019) xóy dng b d liu Bot-IoT vı bừa cồ còc mũ hnh hc mọy, hc sỏu t chồnh xỏc gn tuyt i khi phòt hin còc tn cũng DoS/DDoS trong mũi trng IoT [36]. Tuy nhıỏn, còc kt qu gn nh tuyt i (xp x 100%) trổn còc tp d liu cũng khai cn c xem xỏt thn trng, vớ chũng thng lị du hıu ca rừ r d liu (data leakage) hn lị nng lc thc s ca mũ hnh. Rừ r d liu lị tónh hung trong ú thũng tin l ra khũng sn cú thí im trin khai thc t lı lt vọ quồ trnh hun luy n hoc ònh giồ, khin im s b thí phng vı khũng phn ònh ỹng kh nng tng quồ hóa ca mũ hnh. Lun vn nịy nhn đın vı x lý vn ú mt còch tng minh Chng 4.

Tuy nhıỏn, vic ng dng hc mọy trong h thng IoT vn cùn gp nhıu thồch thc vớ yỏu cu x lý theo thí gian thc vı hn ch v tịi nguyỏn tồnh toòn. Vic tồch hp hc mọy vı còc nn tng x lý d liu ln nh Apache Spark mang lı lı th òng k, gıũp x lý khi lng d liu ln vı tc cao vı h tr trin khai còc thut toòn hc mọy hıu qu trong mũi trng phón tòn.

2.4.1 Mt s thut toòn hc mọy

- **Cóy quy t nh (Decision Trees (DT))** lị mt trong nhng thut toòn hc mọy cú giòm sòt ph bin, c Ớp dng rng rổi trong còc bị toòn phón loi. Cu trũc c bn ca mt cóy quy t nh bao gm ba thnh phn chồnh: **nũt gc**, **nũt quy t nh** vı **nũt lò**. Cóy quy t nh cú u im lị d hıu, d đın gıi, cú th trc quan hóa vı khũng yỏu cu gı nh v phón phi d liu. Tuy nhıỏn, DT cng d b quồ khp (*overfitting*) nu khũng chn c còc tham s hp lý hoc x lý trổn d liu nhıu [37].
- **Rng ngu nhıỏn (RF)** lị mt thut toòn hc mọy c s dng ph bin trong c hai bị toòn phón loi vı hi quy. óy lị mt k thut hc t hp (*ensemble learning*) đa trổn vic xóy dng vı tng hp nhıu cóy quy t nh c lp nhm nõng cao chồnh xỏc vı n nh ca mũ hnh. Thut toòn hot ng bng còch to ra nhıu cóy quy t nh trổn còc tp con khồc nhau c chn ngu nhıỏn t tp d liu hun luy n. Mı cóy c xóy dng đa trổn mt mu bootstrap (lý mu cú hoịn lı), ng

thi ti mi nũt chia, mt tp con ngu nhiõn ca cõc c trng c chn tõm im chia tt nht, thay vớ s dng toịn b c trng nh trong cõy quy t nh trun thng [38].

Kt qu cui cõng c xõc nh bng cõch:

- ◊ Trong bñ toòn phõn loi: ly kt qu theo nguyõn tc a s phiu (*majority voting*) t cõc cõy.
- ◊ Trong bñ toòn hi quy: ly giò tr trung bõnh t cõc d oòn ca tng cõy.

Vic kt hp nhiu cõy giũp RF gim thiu hin tng quõ khp (*overfitting*) vn lĩ mt nhc im thng gp ca cõc cõy quy t nh n l. Khi s lng cõy trong rng tng lõn, hiu nng d oòn ca mĩ hõnh cú xu hõng n nh vĩ ci thĩn hn.

- **Hi quy logistic (Logistic Regression (LR))** lĩ mt phõng phõp thng kõ c giĩ thiu bi David Cox vĩa cui thp niõn 1950. óy lĩ mt k thut hc mỳy cú giõm sõt thng c s dng giĩ quy t cõc bñ toòn phõn loi nh phõn, trong ú bin u ra (phn hi) lĩ mt bin nh tõnh, nhn giò tr 0 hoc 1. Mĩ hõnh hi quy logistic cho phõp c tõnh xõc sut xy ra ca mt s kin c th da trõn mt hoc nhiu bin u vĩa (c lp). Mt trong nhõng im mnh ca phõng phõp nĩy lĩ kh nng xõc nh mc nh hõng ca tng yu t n xõc sut xut hin ca kt qu, giũp cõc nhĩ phõn tõch hiu rĩ hn mi quan h gia bin u vĩa vĩa u ra [39].

V mt toòn hc, hĩm hi quy logistic c biu ãn ãi dõg tuyn tõnh nh sau:

$$z_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_n x_{i,n} \quad (2.1)$$

Trong ú:

- ◊ $x_{i,j}$ lĩ giò tr ca bin c lp th j ti quan sõt th i
- ◊ β_0 lĩ h s chn (bias), β_j lĩ h s hi quy ng vĩ bin x_j
- ◊ z_i lĩ u ra tuyn tõnh trc khi a qua hĩm kõch hot (sigmoid)

Sau ú, xõc sut xy ra ca s kin c tõnh thũng qua hĩm logistic (sigmoid):

$$P(Y_i = 1 \mid \mathbf{x}_i) = \frac{1}{1 + e^{-z_i}} \quad (2.2)$$

Trong quõ trõnh hun luyn, mĩ hõnh tõm cõc h s β_j ti u sao cho hĩm mt mõt (cross-entropy loss) c ti thiu hĩa.

- **GBT** là mt phng phòp *boosting* (kt hp tun t còc mĩ hnh hc yu; lu ý phón bit vì “hc tng cng” – reinforcement learning) s dng còc cóy quyét nh nh mĩ hnh hc yu (weak learners). Ý tng chònh ca boosting là xóy dng mt mĩ hnh mn bng còch kt hp nhiu mĩ hnh hc yu c hun luyt theo trnh t tun t. mĩ bc, thut toà c gng gim thiu li ca mĩ hnh trc bng còch hc t phn d (residual) hoc gradient ca hịm mt mọt [40]. Quò trnh hun luyt GBT gm còc bc:

- ◇ Bt u vì mt mĩ hnh d oòn ban u (thng là giò tr trung bnh vì bị toà hi quy).
- ◇ Tònh toà sai s cùn li gia nhõn thc vị d oòn.
- ◇ Hun luyt mt cóy quyét nh d oòn phn d.
- ◇ Cp nht mĩ hnh tng bng còch cng mĩ hnh hin ti vì mĩ hnh mi nhõn vì mt h s hc η (learning rate).

Gi s $F_0(x)$ là mĩ hnh khi to ban u, mĩ hnh tng ti bc m c cp nht theo cūng thc:

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \quad (2.3)$$

Trong ú:

- ◇ $h_m(x)$ là cóy quyét nh th m hc theo gradient ca hịm mt mọt.
 - ◇ η là h s hc (learning rate), thng $\eta \in (0, 1)$.
- **LightGBM (LGBM)** là mt framework trin khai thut toà GBT, c phòt trin nhm ti u hóa tc hun luyt vị kh nng m rng trỏn còc tp d liu ln [41], vì cūng s cp nht boosting theo gradient ò trnh bị mc GBT phòr trỏn. Khòc vì GBT truyt thng, LGBM s dng c ch phòt trin cóy theo hng leaf-wise thay vớ level-wise, ng thi òp dng thut toà histogram-based splitting vị k thut Gradient-based One-Side Sampling (GOSS) nhm gim chi phò tòn toà vị tng tc hun luyt. Tuy nhĩn, LGBM *khũng* c a vớ b thut toà so sòn thc nghim vớ lý do tng thờch phn cng trnh bị Chng 3; XGBoost vị GBT i din cho h gradient boosting.
- **NB** là mt phng phòp phón loi xòc sut đa trỏn nh lý Bayes vì gi nh c lp cú iu kin gia còc c trng [42]. Mc dứ gi nh nị thng khũng hoịt toị ỹng trong thc t, mĩ hnh vn cho hiu qu tt trong nhiu bị toà phón loi d liu nhiu chiu.

Theo nh lý Bayes:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)} \quad (2.4)$$

Vì giả nh c lp gia còc c trng:

$$P(x|y) = \prod_{i=1}^n P(x_i|y) \quad (2.5)$$

Mũ hnh la chn lp cú xòc sut hu nghim ln nht:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y) \quad (2.6)$$

u im ca NB lị n gin, tc hun luyt nhanh vı phư hp vı d liu kòch thc ln; tuy nhiõn, hn ch chònh nm gi nh c lp gia còc c trng.

- **Support Vector Machine (SVM)** lị mt thut toàn hc cú giòm sòt c xut bi Cortes vı Vapnik [43], nhm tòm siỏu phng ti u phón tòch d liu vı khong còch biỏn (margin) ln nht.

Trong trng hp d liu tuyen tòn, bựi toàn ti u c biu din nh sau:

$$\min_{w,b} \frac{1}{2} ||w||^2 \quad (2.7)$$

vı iu kin:

$$y_i(w \cdot x_i + b) \geq 1 \quad (2.8)$$

Trong trng hp d liu khũng tuyen tòn, SVM s dng k thut *kernel trick* ònh x d liu sang khũng gian nhiu chiu hn, cho phỏp phón tòch tuyen tòn trong khũng gian mi. Nh c ch ti u húa cht ch, SVM thng t hiu nng cao trong còc bựi toàn phón loi vı d liu nhiu chiu.

- **Multilayer Perceptron - MLP** lị mt mũ hnh hc sỏu c bn gm nhiu lp n, cú kh nng mũ hnh húa còc mi quan h phi tuyen gia còc c trng [44].

Mi n-ron trong mng thc hìn phỏp bin i tuyen tòn:

$$z = w^T x + b \quad (2.9)$$

- **Voting:** Vì bị toàn phần lỗi, mô hình con bị phiếu cho một lớp vì lớp có số phiếu cao nhất sẽ ra quyết định (a số phiếu học trung bình xấp xỉ). Các bước của voting có mô tả chi tiết Thuật toán 1.
- **Boosting:** Huấn luyện các mô hình tuần tự, trong đó mô hình mới tập trung vào các mẫu mà mô hình trước đã đoán sai (ví dụ: GBT, AdaBoost, XGB). Các bước của boosting có mô tả chi tiết Thuật toán 2.
- **Bagging (Bootstrap Aggregating):** Huấn luyện nhiều mô hình trên các tập con ngẫu nhiên (lấy mẫu có hoàn lại) của tập dữ liệu gốc, sau đó tổng hợp kết quả đoán (ví dụ: Random Forest). Các bước của bagging có mô tả chi tiết Thuật toán 3.

EL có thể được sử dụng trong các hệ thống phát hiện xâm nhập (IDS) với các phần tử học dựa trên dữ liệu phức tạp, vì việc kết hợp nhiều mô hình có thể giúp tăng khả năng phát hiện các gói tin bất thường mà mô hình đơn lẻ có thể bỏ sót.

Thuật toán 1. Voting: Kết hợp đoán từ nhiều mô hình phần lỗi

u vào:

- Tập huấn luyện $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- Tập mô hình phần lỗi có số $M_1, M_2, \dots, M_K$
- Kiểu voting: HARD hoặc SOFT

u ra: Nhãn đoán cuối cùng y_{vote} cho im dữ liệu x

```

1: Khi to: danh sách  $S = \{\}$  ▷ Lu đoán học xấp xỉ
2: if voting = HARD then
3:   for  $j = 1$  to  $K$  do
4:      $y_j \leftarrow M_j(x)$  ▷ D đoán nhãn của mô hình thứ  $j$ 
5:     Thêm  $y_j$  vào  $S$ 
6:   end for
7:    $y_{\text{vote}} \leftarrow$  nhãn xuất hiện nhiều nhất trong  $S$ 
8: else if voting = SOFT then
9:   Khi nào xấp xỉ tng  $P_{\text{sum}}[c] = 0, \forall c \in \{1, \dots, C\}$ 
10:  for  $j = 1$  to  $K$  do
11:    Ly xấp xỉ  $P_j(y = c | x)$  t mô hình  $M_j$ 
12:    for mỗi  $c = 1$  to  $C$  do
13:       $P_{\text{sum}}[c] \leftarrow P_{\text{sum}}[c] + P_j(y = c | x)$ 
14:    end for
15:  end for
16:   $y_{\text{vote}} \leftarrow \arg \max_c P_{\text{sum}}[c]$ 
17: end if
18: return  $y_{\text{vote}}$ 

```

Thut toàn 2. Boosting: Kt hp tun t còc mũ hnh hc yu

u vïo:

- Tp d liu hun luyt $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- S lng vùng lp (mũ hnh yu): T

u ra: Mũ hnh boosting $F_T(x)$

- 1: **Khi to:** $F_0(x) \leftarrow 0$ ▷ Mũ hnh khi u cú th lị 0 hoc d oòn trung bnh
 - 2: **for** $t = 1$ to T **do**
 - 3: Tõnh gi-phn-d (pseudo-residuals) theo gradient óm ca hịm mt môt: $r_i^{(t)} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{t-1}}$ ▷ Vi mt môt bnh phng (hì quy), rĩt gn thnh $y_i - F_{t-1}(x_i)$;
vi phón loi dũng log-loss
 - 4: Hun luyt mũ hnh yu $h_t(x)$ trở còc gi-phn-d $r_i^{(t)}$
 - 5: Cp nht mũ hnh: $F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$
 - 6: **end for**
 - 7: **return** $F_T(x)$
-

Thut toàn 3. Bagging: Bootstrap Aggregating

u vïo:


- Tp hun luyt $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (tng quòt: C lp)
- S lng mũ hnh c s: K

u ra: D oòn cui cũng y_{bag} cho mt im d liu x

- 1: **Khi to:** Danh sòch mũ hnh $M_1, M_2, \dots, M_K$
 - 2: **for** $k = 1$ to K **do**
 - 3: To mu bootstrap $\mathcal{D}^{(k)}$ t $\mathcal{D}$ (ly mu ngu nhiõn cú hoịn li)
 - 4: Hun luyt mũ hnh $M_k \leftarrow \text{Train}(\mathcal{D}^{(k)})$
 - 5: **end for**
 - 6: **Khi to:** Danh sòch d oòn $Y = \{\}$
 - 7: **for** $k = 1$ to K **do**
 - 8: Thc hìn d oòn $y_k \leftarrow M_k(x)$
 - 9: Thõm y_k vïo Y
 - 10: **end for**
 - 11: Tõnh $y_{\text{bag}} \leftarrow \text{Voting}(Y)$ ▷ Hard voting hoc trung bnh xòc sut nu dũng soft
 - 12: **return** y_{bag}
-

Chng 3. PHNG PHÒP THC HIN

Trong chng nỳ, lun vn s trnh bỳ phng phòp xut xóy dng mũ hnh phòt hin xóm nhp da trỏn Apache Spark cho bo mt mng IoT. Quò trnh thc hin bao gm 6 bc chònh, c th hin qua Hnh 3.1: (1) Thu thp d liu v tin x lý; (2) Xóy dng c trng v la chn c trng; (3) Hun luyt mũ hnh; (4) ònh giò mũ hnh; (5) Ti u sióu tham s; v (6) Trin khai bióu thi gian thc. Còc bc (1)(5) c lp li tng ng v tng phng phòp la chn c trng (Random Forest Importance (RFI), SHAP, PCA), sau ú la chn mũ hnh tt nht trin khai trỏn thit b bióu.



Hnh 3.1. Quy trnh tng th hun luyt, ònh giò v trin khai mũ hnh xut

3.1 Thu thp d liu v tin x lý

Trong nghióu cu nỳ, tp d liu c s dng l CICIDS2017 c phòt hnh bi Vin An ninh mng Canada (CIC). Tp d liu nỳ c xóy dng nhm mũ phng lu lng mng thc t kt hp v nhieu loi tn cũng mng hin i, phc v cho vic hun luyt v ònh giò còc mũ hnh phòt hin xóm nhp. Tp d liu CICIDS2017 tp trung vò còc kch bn tn cũng n l trong mũi trng kim soót. Cn lu ý rng còc b d liu phòt hin xóm nhp mng cũng khai — bao gm CICIDS2017 — cú nhng gii hn ò c kho sòt mt còch h thng (li gòn nhón, to tóe khi sinh lu lng, v kh nng tng quòt hóa hn ch) [47]; óy lý lỳ do lun vn òp dng quy trnh loi tr rừ r bc tin x lý v b sung ònh giò lión b d liu Chng 4. Thũng tin chi tit v tp d liu c trnh bỳ trong Bng 3.1.

Bng 3.1. Mũ t b d liu CICIDS2017

Thuc tởnh	Giờ tr
T chc phòt hnh	Canadian Institute for Cybersecurity (CIC)
Thi gian phòt hnh	2017
Giao thc mng	HTTP, HTTPS, FTP, SSH, DNS, ...
S lng bn ghi (CSV)	Hn 2.8 triu bn ghi
Thi gian thu thp	03/07/2017 07/07/2017
Loi tn cũng mũ phng	DoS, DDoS, PortScan, Brute-force, Infiltration, Botnet, ...
S loi nhõn	15 (1 nhõn bõnh thng + 14 loi tn cũng)
nh dng d liu	CSV
Mc ờch	Phòt hnh xỏm nhp mng trong mũi trng thc t gi lp
Ngun d liu	[48]

Bổn cnh CICIDS2017 (b d liu chõnh cho toỏn b cõc thờ nghim), lun vn s dng thỏm **CSE-CIC-IDS2018** cho thờ nghim *tng quỏt húa liỏn b d liu* (Mc 4.2.8.1): hun luyỏn trỏn mt b, kim tra trỏn b kia vớ ngỏc li. ỏy lớ b k nhim ca CICIDS2017, do CIC phi hp vi C quan An ninh Truyỏn thũng Canada (CSE) thu thp trỏn h tng AWS quy mũ ln hn nhiu; c trng lung c trỏch bng CICFlowMeter phiỏn bn mi hn nỏn tỏn ct c ònh x v danh mc tỏn ct chun ca CICIDS2017 qua bng bờ danh tng minh trong mỗ ngun. Thũng tin chỉ tit Bng 3.2.

Bng 3.2. Mũ t b d liu CSE-CIC-IDS2018 (dứng cho thờ nghim liỏn b d liu)

Thuc tởnh	Giờ tr
T chc phòt hnh	CIC phi hp CSE (Communications Security Establishment)
Thi gian phòt hnh	2018
H tng thu thp	Testbed trỏn AWS (~450 mỳy nn nhỏn, 50 mỳy tn cũng)
S lng bn ghi (CSV)	~16,2 triu lung (10 tp CSV theo ngỳy)
Thi gian thu thp	14/02/2018 – 02/03/2018
Loi tn cũng mũ phng	DDoS (HOIC, LOIC-HTTP/UDP), DoS (Hulk, GoldenEye, Slowloris, SlowHTTPTest), Bot, Brute-force (SSH, FTP, Web, XSS), SQL Injection, Infiltration
S loi nhõn	15 (1 nhõn bõnh thng + 14 loi tn cũng)
Phỏn b nh phỏn (sau lỳm sch)	~13,35 triu Benign / ~2,35 triu Attack
Phn đứng trong lun vn	Mu phỏn tng theo nhõn 20% (seed=42), cùn ~2,39 triu lung sau kh trỏng lp mc c trng
nh dng d liu	CSV (CICFlowMeter v3; tỏn ct ònh x v chun CICIDS2017)
Ngun d liu	[49]

Tin x lý d liu Vic tin x lý d liu nhm loi b nhieu, giò tr ngoi l vị giò tr b thiu c thc hin trc khi a d liu vjo hun luyn mĩ hnh. Còc k thut c òp dng gm chun hóa tổn ct, cn chnh lc gia còc tp, thay th giò tr vũ cng, loi b bn ghi trng lp/thiu, vị gòn nhõn nh phón (BENIGN = 0, Attack = 1).

Bổn cnh ú, bo m kt qu ònh giò phn ònh ững nng lc mĩ hnh, lun vn òp dng thõm hai bc *loi tr rừ r d liu* (loi cm by “data snooping” c xem li ph bin nht ca hc mỳy trong an ninh [50]) ngay trong giai on tin x lý, trc khi phón chia tp: (i) **loi c trng rừ r nhõn** destination_port (vị source_port nu cú) vớ trong CICIDS2017, mi loi tn cũng c sinh nhm vjo nhng cng dch v c nh nỏn cng òch gn nh mĩ hóa trc tip nhõn, khin mĩ hnh “ghi nh” ònh x cng-nhõn thay vớ hc hnh vi lung (ct protocol cng c loi vi lý do tng t: óy li bin phón loi cú òt mc giò tr, tng quan mn nh vi cng dch v nỏn mang cng nguy c “li tt” nh danh dch v thay vớ hnh vi); vị (ii) **loi b trng lp mc c trng theo c ch tt nh** còc lung c gom nhúm theo tojñ b vector c trng; vị nhúm cú nhõn nht quòn, gi li ững mt i ðin; vị nhúm trng c trng nhng *móu thun nhõn* (cng vector c trng, nhõn va Benign va Attack, mt li gòn nhõn õ c ghi nhn ca CICIDS2017 [51]), *tojñ b nhúm b loi* vớ khũng th xòc nh nhõn ững, thay vớ gi li mt hng tũy ý theo phón mn nh d liu (vn khũng tòi lp c gia còc ln chy); s nhúm vị s hng xung t nhõn c ghi log tng mn nh (270 nhúm, 44.260 hng). C ch nỳy trõnh vic cũng mt mu xut hin c tp hun luyn ln kim tra khi phón chia ngu nhõn. i vị tp d liu CICIDS2017, quò trõnh tin x lý d liu c th hin chi tit Thut toàn 4. Cn tha nhn rng bc loi b trng lp mc c trng lĩm thay i *phón b lp*: do còc lung benign trng lp nhieu hn nỏn b loi nhieu hn, khin t l benign/attack sau khi x lý khòc vị t l ban u; vớ vy phón b lp trc vị sau khi loi trng lp c bõo còc tng mn nh bo m mn nh bch.

Phón chia tp d liu

Tp d liu CICIDS2017 c phón chia theo t l 80/20 cho hun luyn vị kim tra bng phõp chia ngu nhõn (random split) vị seed c nh (=42) m bo tòi lp. Còc ch s hiu nng c **cũng b trõn tp kim tra** (tp gi li cui cũng, khũng tham gia hun luyn, xp hng c trng hay tinh chnh siỏu tham s); kt qu trõn tp hun luyn ch c ðứng chn oòn hin tng quò khp (overfitting) hoc thiu khp (underfitting). òng lu ý, StandardScaler, PCA vị vic xp hng c trng (RF Importance, SHAP) u c *fit ch trõn tp hun luyn* D_{train} ri *transform* lỏn tp kim tra, nhm trõnh rừ r thũng tin t tp kim tra vjo quò trõnh hun luyn. Riỏng vic **chn Top-3 mĩ hnh thnh phn** cho còc ensemble (cng nh vic chn mĩ hnh i ðin mi phng phỏp vị cp phng phỏp a vjo kim nh thng kỏ, Chng 4) c thc hin trõn mt *tp kim nh (validation)* tỏch t tp hun luyn (theo t l 80/20, seed=42, còc mĩ hnh c s hun luyn trõn phn cũn li); nh vy tp kim tra hojñ tojñ khũng

Thut toàon 4. Thut toàon Tin x lý D liu CICIDS2017

u vò: Tp N tp CSV t b d liu CICIDS2017: $\{F_1, F_2, \dots, F_N\}$

T l phón chia hun luy/kim tra $\alpha = 0.8$


u ra: Tp hun luy D_{train} vò tp kim tra D_{test} nh dng Parquet

```

1: Bc 1: Gp d liu t nhieu tp CSV
2:  $D \leftarrow \emptyset$ 
3: for  $i = 1$  to  $N$  do
4:   c tp  $F_i$  thnh DataFrame  $df_i$  vò lc suy lun t ng
5:   CLEANCOLUMNAMES( $df_i$ )    ▷ Chun hóa tởn ct: xúa khong trng, chuyn ch thng
6:   HANDLEINFINITYVALUES( $df_i$ )    ▷ Thay th  $\pm\infty$  bng giò tr NaN
7:   if  $D = \emptyset$  then
8:      $\mathcal{S} \leftarrow \text{Schema}(df_i)$     ▷ Lu lc chun t tp u tởn
9:      $D \leftarrow df_i$ 
10:  else
11:    ALIGNSCHEMA( $df_i, \mathcal{S}$ )    ▷ Cn chnh lc v chun  $\mathcal{S}$ 
12:     $D \leftarrow D \cup df_i$     ▷ Gp theo tởn ct (unionByName)
13:  end if
14: end for
15: Bc 2: Lm sch d liu
16:  $D \leftarrow \text{RemoveDuplicates}(D)$     ▷ Loi b còc bn ghi trng lp hoìn toìn (gìng ht trỏn mĩ ct)
17:  $D \leftarrow \text{RemoveNulls}(D)$     ▷ Loi b còc bn ghi cha giò tr null/NaN
18: Bc 3: To nhõn nh phón
19:  $\forall (x_i, \text{label}_i) \in D : y_i \leftarrow \begin{cases} 0 & \text{nu label}_i = \text{"BENIGN"} \\ 1 & \text{ngc li (Attack)} \end{cases}$ 
    → Hai bc loi tr rừ r d liu (data leakage): Bc 4 vò Bc 4b
20: Bc 4 [loi rừ r – I]: Xòc nh còc c trng s (õ loi tr rừ r)
21:  $\mathcal{C}_{\text{exclude}} \leftarrow \{\text{label, label\_binary, source\_ip, destination\_ip, flow\_id, timestamp, protocol,}$ 
     $\text{destination\_port, source\_port}\}$     ▷ Loi b c trng góy rừ r nhõn
22:  $\mathcal{F} \leftarrow \{c \in \text{columns}(D) \mid c \notin \mathcal{C}_{\text{exclude}} \wedge \text{dtype}(c) \in \{\text{double, float, int, bigint}\}\}$ 
23: Bc 4b [loi rừ r – II]: Loi b trng lp mc c trng (tt nh)
24:  $G \leftarrow \text{GroupBy}(D, \mathcal{F})$     ▷ Gom nhúm theo toìn b vector c trng
25: for mĩ nhúm  $g \in G$  do
26:   if  $|\{y_i : (x_i, y_i) \in g\}| > 1$  then    ▷ Nhúm móu thun nhõn (Benign ln Attack)
27:     Loi toìn b nhúm  $g$  khi  $D$ ; ghi log s nhúm/hìng xung t
28:   else
29:     Gi li ửng mĩ i din ca  $g$  (th t tt nh theo nhõn)
30:   end if
31: end for
32: Bc 5: Phón chia vò lu tr
33:  $D_{\text{train}}, D_{\text{test}} \leftarrow \text{RandomSplit}(D, [\alpha, 1 - \alpha], \text{seed} = 42)$ 
34: Lu  $D_{\text{train}}, D_{\text{test}}$  dĩ nh dng Parquet
35: return  $D_{\text{train}}, D_{\text{test}}$ 

```

tham gia vò khóu la chn mĩ hnh, khỗp kờn nguy c rừ r chn lc. Toịn b quy trnh phón chia c minh ha Hnh 3.2.



Hnh 3.2. S phón chia d liu CICIDS2017. Sau tin x lý vò loi tr rừ r (Thut toỏn 4), d liu c chia 80/20 thnh train/test ($seed=42$); tp test c gi li, ch đứg cũng b kt qu cui. Trong tp train li tòch 80/20 thnh base-train (hun luyn, vò *fit* còc phỗp bin i StandardScaler/PCA cũng vic xp hng c trng) vò validation (chn Top-3 mĩ hnh thnh phn vò cp phng phỏp a vò kim nh). Riỏng ngng cng bt thng c chn trỏn 10% lu lng benign ca tp train ($seed=42$). Tp test khũng tham gia bt k khóu la chn nỏ.

3.2 La chn c trng vò gim chiu d liu

Trong quỏ trnh tin x lý d liu cho bị toỏn phỏt hin xỏm nhp mng, la chn c trng bao gm **chn c trng vò trỏch xut c trng** lỳ mt bc quan trng nhm gim chiu d liu, loi b nhng c trng khũng cn thit, vò ci thn hiu nng ca mĩ hnh hc mỳy [52]. D liu s c gom vò vector c trng bng VectorAssembler (khong 78 c trng s trc khi loi cng; s c trng chỏnh xỏc sau khi loi destination_port/source_port lỳ 77) vò c chun húa bng StandardScaler (chun húa Z-score). Ba phng phỏp c s dng trong lun vn lỳ RF, SHAP vò PCA.

- a) **Principal Component Analysis (PCA)**: Lỳ phng phỏp gim chiu d liu khũng giỏm sỏt, nhm bin i tp c trng ban u thnh mt tp còc thnh phn chỏnh (principal components) mi khũng tng quan tuyt tỏnh vò nhau vò gi li phn ln phng sai ca d liu. PCA thc hin bng cỏch tỏnh ma trn hip phng sai vò tỏm còc vector riỏng (eigenvectors) tng ng vò còc giỏ tr riỏng (eigenvalues). Cỏc thnh phn chỏnh c xỏc nh bng cỏch gii bị toỏn:

$$Cv = \lambda v \quad (3.1)$$

Trong ú:

- C lỳ ma trn hip phng sai ca d liu.
- v lỳ vector riỏng (principal component).

- λ lị giờ tr riống, biu th lng phng sai c gii thờch.

Còc thịnh phn chờnh cú giờ tr riống ln nht s c la chn to thịnh khũng gian c trng mi vì s chiu thp hn nhng vn gi c phn ln thũng tin ca d liu. óy lị phng phòp c s dng ph bin trong phón tồch d liu a bin vị hc mỳy gim chiu, loi b nhiu vị trc quan hóa d liu [53].

- b) **SHapley Additive exPlanations (SHAP)**: Lị phng phòp gii thờch mũ hnh đa trồn lý thuyt trù chi, dứng o lng mc úng gúp ca tng c trng vộ d oòn ca mũ hnh. SHAP tồnh giờ tr Shapley cho mi c trng bng còch xỏt trung bnh úng gúp biổn ca c trng ú trồn tt c còc tp con cú th:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)] \quad (3.2)$$

Trong ú:

- F lị tp tt c còc c trng.
- S lị tp con ca còc c trng khũng cha i .
- $f(S)$ lị giờ tr d oòn ca mũ hnh khi ch s dng tp c trng S .
- ϕ_i lị mc úng gúp ca c trng i vộ kt qu d oòn.

Còc c trng cú giờ tr SHAP ln (theo ln tuyt i) c xem lị cú nh hng quan trng hn n quytnh ca mũ hnh. Phng phòp nịy c ng dng rng rỏi trong gii thờch mũ hnh phc tp nh XGBoost, Random Forest, vị mng n-ron [54].

- c) **Random Forest Feature Importance**: Thut toòn RF cú kh nng ònh giờ tm quan trng ca tng c trng đa trồn mc úng gúp vộ vic gim bt thun (impurity) ti còc nũt phón chia ca cóy quytnh. quan trng $I(f_j)$ ca c trng f_j c tồnh nh sau:

$$I(f_j) = \frac{1}{T} \sum_{t=1}^T \sum_{n \in N_t(f_j)} \Delta i(n) \quad (3.3)$$

Trong ú:

- T lị s lng cóy trong rng.
- $N_t(f_j)$ lị tp còc nũt trong cóy t s dng c trng f_j phón chia.
- $\Delta i(n)$ lị lng gim bt thun (vờ d: Gini hoc Entropy) ti nũt n .

Còc c trng cú quan trng cao hn s c u tiõn la chn a vïo mĩ hnh hun luyn. Sau khi hun luyn mĩ hnh RF, còc c trng cú giò tr quan trng thp hn mt ngng nh trc s b loi b, gi li nhng c trng cú nh hng ln n vic phón loi.

3.3 Hun luyn mĩ hnh

3.3.1 Hun luyn còc mĩ hnh c s

Tòm thut toøn phón loi cú giòm sòt c hun luyn c lp trõn tp c trng ò qua bc xóy dng vï la chn c trng. Bng 3.3 lit kổ còc thut toøn cng thũng tin chi tit v bin th vï phng phòp hc.

Bng 3.3. Tòm b phón loi c s c s dng trong pipeline

Thut toøn	Bin th / Ghi chũ	Phng phòp hc
Decision Tree	CART	Phón chia quy theo Gini / Entropy
Logistic Regression	Chun hóa L2	Ti u hịm mt môt logistic
Linear SVM	SVC tuyn tồnh	Ti a hóa biõn phón loi
Naive Bayes	Phón phi Gaussian	c lng xóc sut hu nhim
Random Forest	Bagging	T hp cóy quy nh ngu nhĩõn
GBT	Gradient Boosting	Ti thiu hóa hịm mt môt theo gradient
XGBoost	Gradient Boosting ti u	Regularised Gradient Boosting
MLP	Mng n-rõn nhón to	Lan truyn ngc (Backpropagation)

òng lu ý, LightGBM (mt th vin gradient boosting ph bin) *khũng* c a vïo danh sòch trõn vớ th vin gc (native, thũng qua SynapseML) ch h tr kin trũc x86_64, khũng chy c trõn thit b biõn Jetson Orin Nano Super (ARM64), vn lĩ mc tiõu trin khai ca nghiõn cu; XGBoost vĩ GBT ò i din y cho h gradient boosting.

X lý mt cón bng lp. Do t l Benign/Attack lch nhau òng k, sòu mĩ hnh MLlib (Decision Tree, Logistic Regression, Linear SVC, Random Forest, GBT, Naive Bayes) c hun luyn vĩ trng s lp (`weightCol`) t theo t l nghch ca tn sut lp benign/attack; XGBoost dũng tham s `scale_pos_weight` vĩ vai trũ tng ng. Riõng MLP lĩ ngoi l khũng òp trng s lp do API `MultilayerPerceptronClassifier` ca Spark MLlib khũng h tr `weightCol`.

Sau khi hun luyn, tòm mĩ hnh c xp hng theo chiu gim dn ca F1-Score trõn tp kim nh (validation, tồch t tp hun luyn, xem mc Phón chia tp d liu) xóc nh top-3 mĩ hnh tt nht phc v bc kt hp ensemble tip theo; tp kim tra hoịn toịn khũng c s dng bc chn mĩ hnh nĩy nhm trõnh rũ r chn lc (selection leakage).

3.3.2 Còc phng phòp Ensemble Learning

Bng 3.4. Còc phng phòp hc t hp (ensemble) s dng trong lun vn

Phng phòp	Mũ t chỉ tit
Hybrid Bagging	Top-3 mũ hnh kt hp theo s (3-2-2) sub-samples vì <i>Weighted Soft Voting</i> d oòn xòc sut cú trng s
Soft Voting	Trung bnh xòc sut Top-3 mũ hnh theo F1-Score Nhõn <i>Attack</i> nu xòc sut trung bnh $\geq 0,5$

a) Òp dng Voting

Sau khi hoịn tt giai on hun luy n mũ hnh, lun vn tin hnh xóy dng mũ hnh ensemble da trõn k thut Voting nóng cao chõnh xòc vị tõnh n nh ca h thng phón loi; hai phng phòp t hp c s dng c túm tt trong Bng 3.4. C th, ba mũ hnh phón loi nh phón cú ch s F1-Score cao nh t giai on trc s c la chn tham gia vò quò trõnh ensemble.

Mi mũ hnh trong tp c chn s a ra d oòn c lp cho tng mu trong tp kim tra. Còc d oòn nìy sau ú c tng hp thũng qua c ch bu chn. Trong trng hp Soft Voting, xòc sut d oòn lp *Attack* ca còc mũ hnh thnh phn c ly trung bnh; mu c gòn nhõn *Attack* nu xòc sut trung bnh t t 0,5 tr lỏn, ngc li c gòn nhõn *Benign*.

Vic òp dng k thut Voting cho phỏp khai thỏc s a dng gia còc mũ hnh hc c s, t ú gim sai s do thiỏn lch ca tng mũ hnh riỏng l vị ci thfin kh nng tng quòt húa trõn d liu cha tng thy. Nh c ch kt hp nìy, h thng cú th nóng cao hiu nng tng th trong vic phòt hin vị phón loi chõnh xòc còc hnh vì xóm nhp mng. Quy trõnh chỉ tit c trõnh bỳ trong Thut toà 5.

Thut toòn 5. Thut toòn Soft Voting Ensemble

u vjo: Tp d liu hun luy n $D = \{(x_i, y_i)\}_{i=1}^n$ vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$
 Tp kim nh D_{val} (tòch t D , đ $\acute{u}$ ng xp hng vị chn m $\ddot{u}$ h $\acute{o}$ nh th $\acute{i}$ nh ph $\acute{n}$)
 Tp d liu kim tra $D_{\text{test}} = \{(x_j)\}_{j=1}^m$
 Tp K thut toòn hc c s khòc loi $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

u ra: Nh $\acute{o}$ n d oòn cui c $\acute{u}$ ng $y_{\text{vote}} \in \{0, 1\}$ cho m $\acute{i}$ mu

- 1: **Bc 1: Hun luy n vị ònh giò K m $\ddot{u}$ h $\acute{o}$ nh c s**
- 2: **for** $k = 1$ to K **do**
- 3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Hun luy n tr $\acute{o$ n ph $\acute{n}$ train l $\acute{u}$ i, tòch khi D_{val}
- 4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ T $\acute{o}$ nh im F1 tr $\acute{o$ n tp kim nh (validation), kh $\acute{u}$ ng chm tp kim tra
- 5: **end for**
- 6: **Bc 2: Chn Top-3 m $\ddot{u}$ h $\acute{o}$ nh cú F1 cao nh t**
- 7: Sp xp $\{M_1, \dots, M_K\}$ theo F_k gim dn
- 8: Chn 3 m $\ddot{u}$ h $\acute{o}$ nh tt nh t : $\mathcal{S} = \{M^{(1)}, M^{(2)}, M^{(3)}\}$ vi $F^{(1)} \geq F^{(2)} \geq F^{(3)}$
- 9: **Bc 3: Thu thp xòc sut d oòn t 3 m $\ddot{u}$ h $\acute{o}$ nh c chn**
- 10: **for** m $\acute{i}$ mu $x_j \in D_{\text{test}}$ **do**
- 11: **for** m $\acute{i}$ $M^{(s)} \in \mathcal{S}$, $s = 1, 2, 3$ **do**
- 12: $p_s^{(j)} \leftarrow P^{(s)}(y = 1 \mid x_j)$ ▷ Xòc sut lp Attack t m $\ddot{u}$ h $\acute{o}$ nh $M^{(s)}$
- 13: **end for**
- 14: **end for**
- 15: **Bc 4: Kt hp bng bu chn mm (Soft Voting)**
- 16: **for** m $\acute{i}$ mu $x_j \in D_{\text{test}}$ **do**
- 17: $\bar{p}_j \leftarrow \frac{1}{3} \sum_{s=1}^3 p_s^{(j)}$ ▷ Trung b $\acute{o}$ nh xòc sut lp Attack
- 18: **if** $\bar{p}_j \geq 0.5$ **then**
- 19: $y_{\text{vote}}^{(j)} \leftarrow 1$ ▷ D oòn: Attack
- 20: **else**
- 21: $y_{\text{vote}}^{(j)} \leftarrow 0$ ▷ D oòn: Benign
- 22: **end if**
- 23: **end for**
- 24: **return** $\{y_{\text{vote}}^{(j)}\}_{j=1}^m$

b) Òp dng Bagging

khai thòc hieu qu sc mn h ca k thut hc t hp Bagging, lun vn xut xóy dng mt mĩ hnh ensemble lai (Hybrid Bagging Ensemble) da trón còc mĩ hnh c s cú hieu nng cao nht (õ hun luyn vị xp hng bc trc). C th, thay vớ ch s dng mt mĩ hnh n l, quy trnh bt u bng vic hun luyn vị ònh giò K thut toòn hc c s trón tp d liu hun luyn D . Hieu nng ca tng mĩ hnh c o lng thng qua ch s F1-Score, t ú la chn ba mĩ hnh cú kt qu tt nht a vïo giai on kt hp.

Sau khi xòc nh Top-3 mĩ hnh, phng phòp Bagging c òp dng theo phón b s bn sao (3, 2, 2). i vì mi mĩ hnh trong ba mĩ hnh c chn, nhiu tp d liu bootstrap c to ra bng còch ly mu ngu nhĩn cú hoĩn li t tp hun luyn ban u. Trón mi tp bootstrap nìy, mt bn sao ca mĩ hnh tng ng c hun luyn c lp, to thnh còc *b hc c s* (*base learners*) trong ensemble. Mi base learner c gòn trng s t l vì F1-Score ca mĩ hnh gc nhm phn ònh mc tin cy tng i ca nú trong quò trnh tng hp. Vic phón b bt i xng (3, 2, 2), tc cp nhiu bn sao bootstrap hn cho mĩ hnh hng cao, lị mt la chn thit k thc nghim nhm thĩn ensemble v phòra còc b hc mn h hn trong khi vn gi tòn h a dng t ba thut toòn khòc loi; óy lị mt heuristic, khũng phi kt qu ca tì u hóa lý thuyt, vị còc t l khòc (chng hn 3-3-3) cú th c kho sòt trong nghiõn cu tip theo.

Trong giai on d oòn, toĩn b còc mĩ hnh trong ensemble a ra phón phi xòc sut d oòn cho mu u vïo mi. Kt qu cui cĩng c xòc nh thũng qua c ch Soft Voting cú trng s, trong ú xòc sut ca tng lp c tòn h bng tng cú trng s ca còc xòc sut thnh phn. Nhõn d oòn cui cĩng c chn lị lp cú xòc sut tng hp ln nht.

Còch tip cn nìy cho phỏp gim phng sai ca còc mĩ hnh c s nh c ch ly mu bootstrap, ng thi duy trớ kh nng hc biu ãn ca tng thut toòn riõng l. Vic kt hp chn lc còc mĩ hnh cú hieu nng cao nht trc khi òp dng Bagging giữp tì u hóa c chònh xòc vị tòn h n nh ca h thng. Chi tit quy trnh c trnh bñy trong Thut toòn 6.

Thut toàon 6. Thut toàon Hybrid Bagging Ensemble Learning

u vò: Tp d liu hun luy n $D = \{(x_i, y_i)\}_{i=1}^n$ vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (BENIGN = 0, Attack = 1)

 Tp kim nh D_{val} (tòch t D , dúng xp hng vị chn Top-3)

 Tp K thut toàon hc c s $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

 Phón b s bn sao $\mathbf{r} = (r_1, r_2, r_3) = (3, 2, 2)$

u ra: Nhón d oòn cui cúng $y_{\text{bag}} \in \{0, 1\}$

1: **Bc 1: Hun luy n vị ònh giò K mữ hnh c s**

2: **for** $k = 1$ to K **do**

3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Hun luy n trón phn train lủi, tòch khi D_{val}

4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tònh im F1 trón tp kim nh (validation), khũng chm tp kim tra

5: **end for**

6: **Bc 2: Chn Top-3 mữ hnh cú F1 cao nh**

7: Sp xp $\{M_1, \dots, M_K\}$ theo F_k gim dn

8: Chn 3 mữ hnh tt nh: $M^{(1)}, M^{(2)}, M^{(3)}$ vi $F^{(1)} \geq F^{(2)} \geq F^{(3)}$

9: **Bc 3: To ensemble theo phón b 3-2-2**

10: $\mathcal{E} \leftarrow \emptyset$ ▷ Tp ensemble gm 7 mữ hnh

11: **for** $j = 1$ to 3 **do**

12: **for** $i = 1$ to r_j **do**

13: To tp bootstrap $D_{j,i}$ bng còch ly ngu nhĩn n mu t $D \setminus D_{\text{val}}$ **cú hoị li**

14: $h_{j,i} \leftarrow \text{Train}(\mathcal{L}^{(j)}, D_{j,i})$ ▷ Hun luy n bn sao th i ca mữ hnh hng j

15: Gòn trng s $w_{j,i} \leftarrow F^{(j)}$ ▷ Trng s da trón F1-Score

16: Thỏm $(h_{j,i}, w_{j,i})$ vò $\mathcal{E}$

17: **end for**

18: **end for**

19: Chun húa trng s: $w_{j,i} \leftarrow \frac{w_{j,i}}{\sum_{(h,w) \in \mathcal{E}} w}$

20: **Bc 4: D oòn cho mu mĩ x (Soft Voting cú trng s)**

21: $T \leftarrow |\mathcal{E}| = 7$

▷ Tng s mữ hnh trong ensemble

22: **for** mĩ $(h_t, w_t) \in \mathcal{E}$, $t = 1, \dots, T$ **do**

23: $\mathbf{p}_t \leftarrow h_t(x)$

▷ Ly vector xòc sut d oòn

24: **end for**

25: Tònh xòc sut cú trng s: $\bar{p}(c | x) = \sum_{t=1}^T w_t \cdot P_t(c | x), \quad \forall c \in \{0, 1\}$

26: $y_{\text{bag}} \leftarrow \arg \max_{c \in \{0,1\}} \bar{p}(c | x)$

27: **return** y_{bag}

3.4 ònh giò mĩ hnh

Mĩ mĩ hnh (c s vị ensemble) c ònh giò toịn din trồn bn chiu:

Bng 3.5. Còc tiỏu chừ ònh giò mĩ hnh

Tiỏu chừ	Mĩ t
chờnh xỏc (Accuracy)	T l d oòn ỹng trồn toịn b mu kim tra
Precision	T l cnh bở ỹng trong tng s cnh bở c phỏt ra
Recall	T l phỏt hin ỹng trong tng s mu tn cũng thc t
F1-Score	Trung bnh iu hủa ca Precision vị Recall
Area Under the Curve Receiver Operating Characteristic	Din tồch dĩ ng cong ROC o hủu nng phỏn bit lp
Area Under the Curve PR	Din tồch dĩ ng cong Precision-Recall
Chi phở tồnh toòn	Thi gian hun luy, thi gian d oòn vị kỏch thc mĩ hnh
Kh nng gii thờch (Explainable Artificial Intelligence)	Biu SHAP: summary plot, bar chart vị waterfall plot

Hủu nng ca mĩ hnh c ònh giò thũng qua còc ch s phỏn loi ph bin nh Accuracy, Precision, Recall vị F1-Score, kt hp vị phỏn tồch ng cong AUC (ROC vị PR), chi phở tồnh toòn (thi gian hun luy vị suy lun), cng nh kh nng gii thờch ca mĩ hnh (vở dĩ: biu tng quan SHAP); còc tiỏu chừ ònh giò c tng hp trong Bng 3.5. kim chng mĩ hnh phỏt hin xỏm nhp, tp dĩ liu kim tra c s dng nhm ònh giò kh nng tng quỏt hủa ca mĩ hnh õ hun luy, trong ú kt qu dĩ oòn c i chiu vị nhõn thc t vị o lng bng còc thc o ònh giò. Còc ch s nh accuracy (AC), precision (PR), recall (RE), F1-score (FS) c tồnh toòn theo còc cũng thc (3.4), (3.5), (3.6) vị (3.7). Nhng kt qu nỳy lĩ c s quan trng so sỏnh gia còc phng phỏp la chn c trng vị la chn mĩ hnh phứ hp cho trin khai thc t.

$$\text{Accuracy (AC)} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.4)$$

$$\text{Precision (PR)} = \frac{TP}{TP + FP} \quad (3.5)$$

$$\text{Recall (RE)} = \frac{TP}{TP + FN} \quad (3.6)$$

$$F1\text{-Score (FS)} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.7)$$

Còc i lng TP, FP, FN, TN đứng trong còc cũng thc trỏn c minh ha qua ma trn nhm ln Bng 3.6.

Bng 3.6. Ma trn nhm ln ca mũ hnh phòt hin xóm nhp

	D oàn: Positive	D oàn: Negative
Thc t: Positive	TP (True Positive)	FN (False Negative)
Thc t: Negative	FP (False Positive)	TN (True Negative)

Trong ú, TP (True Positive) l s lng lu lng mng hoc phiỏn kt ni thc s l t n cũng v i c h thng IDS phòt hin ửng l i xóm nhp. TN (True Negative) l nhng lu lng bớnh thng (khũng phi t n cũng) v i c mũ hnh phỏn loi chớnh xỏc l i hp l. FP (False Positive) l còc lu lng bớnh thng nhng b h thng nhn din nhm l i t n cũng. Ngc li, FN (False Negative) l nhng cuc t n cũng thc s xy ra nhng khũng c h thng phòt hin v i b phỏn loi nhm l i lu lng bớnh thng.

3.5 Tí u hóa tham s vị hun luyn mĩ hnh

Trong quò trnh xóy dng mĩ hnh hc mỳ, vic la chn còc siỏu tham s (hyperparameters) phứ hp li mt yu t quan trng nh hng n hiu nng ca mĩ hnh. tí u hóa còc siỏu tham s nỳ, phng phòp **Tỏm kim theo li** (Grid Search (GS)) kt hp vi **Cross-Validation (CV)** ỏ c s dng trong mũ trng phón tòn ca Apache Spark. Còc mĩ hnh phón loi c hun luyn vị so sòngh gm: Decision Tree, Logistic Regression, Linear SVC, Naive Bayes, Random Forest, GBT, XGBoost vị MLP; sau ú xp hng theo F1-Score chn Top-3 mĩ hnh cho còc phng phòp ensemble.

- **GS**: Li phng phòp th nghim tt c còc t hp cú th ca còc siỏu tham s c nh ngha trc. Vở d, vị mt mĩ hnh Random Forest, còc tham s cú th bao gm s lng cóy (numTrees), sỏu ti a (maxDepth), vị chin lc chn tp con c trng ti mi nũt (featureSubsetStrategy). Spark MLlib h tr i tng ParamGridBuilder xóy dng li còc tham s.
- **CV**: Li phng phòp ònh giò mĩ hnh bng còch chia d liu hun luyn thnh k phn, sau ú hun luyn vị ònh giò mĩ hnh k ln, mi ln s dng mt phn khỏc nhau lỳm d liu kim tra vị còc phn cùn li lỳm d liu hun luyn. Trong Spark, i tng CrossValidator c s dng thc hìn quy trnh nỳ.

Quy trnh tí u hóa c thc hìn nh sau:

1. Xóy dng pipeline gm còc bc tin x lý d liu (vở d: chun hóa, bin i c trng) vị mĩ hnh hc mỳ.
2. S dng ParamGridBuilder nh ngha tp li còc siỏu tham s cn tỏm kim.
3. Khi to CrossValidator vị pipeline, li còc tham s, vị b ònh giò hiu nng (vở d: BinaryClassificationEvaluator).
4. Hun luyn mĩ hnh bng còch gỳ phng thc fit() ca CrossValidator trởn tp d liu hun luyn.
5. Chn mĩ hnh tt nht da trởn im ònh giò trung bnh trởn còc folds.

Vở d on mỗ s dng Spark MLlib:

```
from pyspark.ml.classification import RandomForestClassifier
from pyspark.ml.evaluation import BinaryClassificationEvaluator
```

```
from pyspark.ml.tuning import CrossValidator, ParamGridBuilder
from pyspark.ml import Pipeline

rf = RandomForestClassifier(labelCol="label", featuresCol="
    features")

pipeline = Pipeline(stages=[rf])

paramGrid = ParamGridBuilder() \
    .addGrid(rf.numTrees, [10, 20, 50]) \
    .addGrid(rf.maxDepth, [5, 10, 15]) \
    .build()

evaluator = BinaryClassificationEvaluator(labelCol="label",
    metricName="areaUnderPR")

cv = CrossValidator(estimator=pipeline,
                    estimatorParamMaps=paramGrid,
                    evaluator=evaluator,
                    numFolds=5)

cvModel = cv.fit(trainingData)
```

Quy trnh nỳ giúp m bo la chn c t hp siu tham s ti u, ng thi giúp ti u thi gian hun lun.
Spark giúp tng tc quò trnh nỳ nh kh nng x lý phón tòn vị song song hóa trón cm mỳ.

3.6 Trin khai biễn

Mũ hnh tt nht sau ònh giò c úng gúi thnh `PipelineModel` vị trin khai trởn mt cm hai thit b biễn NVIDIA Jetson Orin Nano Super (CPU ARM 64-bit + GPU NVIDIA), tòch vai trò: Jetson #1 chy cng phòt hìn bt thng (autoencoder) lc lu lng bnh thng, Jetson #2 chy b phón loi PySpark trởn còc lung nghi vn. Mũ hnh sau khi hun luyt trởn cm c chuyn sang thit b biễn bng Secure Copy Protocol (SCP). Quy trnh suy lun thi gian thc theo chui: Kafka Consumer nhn d liu mng (topic `ids-network-flow`), cng bt thng chuyn tip lung nghi vn sang `ids-suspicious-flow`, PySpark Streaming (micro-batch) x lý vị trỏch xut c trng, kt qu d òn ghi vño PostgreSQL phc v trc quan hóa trởn Grafana vị kỏch hot cnh bòa khi phòt hìn bt thng. H thng h tr ba ch : tòch pipeline (pipeline split), m rng theo chiu ngang (horizontal scaling) vị cm Spark (Spark cluster). Thũng s phn cng chi tit ca thit b biễn c trnh bñ trong Bng 3.7.

Bng 3.7. Thũng s phn cng thit b biễn

Thuc tỏnh	Giò tr
Nn tng	NVIDIA Jetson Orin Nano Super Developer Kit (×2)
CPU	6 nhón Arm Cortex-A78AE, 1,7 GHz
GPU	NVIDIA Ampere, 1024 nhón CUDA + 32 Tensor Core
RAM	8 GB LPDDR5 (102 GB/s)
Lu tr	SSD NVMe 256 GB
Hiu nng AI	ti ~67 TOPS (khung 25 W)
H iu hnh	Ubuntu (NVIDIA JetPack / L4T)
Vai trò	Worker hun luyt (Spark) & thit b suy lun biễn

Chng 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Trong chng nìy, lun vn trnh bñ kt qu t c khi òp dng k thut la chn c trng hun luyn còc mũ hnh hc mỳy. Bỏn cnh ú, quy trnh tinh chnh siỏu tham s bng tỏm kim li kt hp kim nh chỏo (cross-validation) cng c trnh bñ, cũng vi ònh giỏ kt qu thc nghim khi òp dng còc thut toỏn hc mỳy nh SVM, LR, NB, RF, DT, GBT, XGB v i MLP c trong trng hp cú v i khũng s dng k thut gim chiu d liu. Ngoi ra, lun vn cng xỏc nh v i trnh bñ còc giỏ tr tham s ti u cho tng thut toỏn thũng qua phng phỏp tỏm kim theo li kt hp vi kim nh chỏo (cross-validation). Da trỏn còc kt qu thu c, lun vn s l i m rỏ vn liu vic gim chiu d liu cú thc s cn thit hay khũng. Cui cũng, lun vn ònh giỏ h iu qu ca còc mũ hnh EL, sau ú so sỏnh vi còc thut toỏn hc mỳy truy n thng, t ú tr li cúu hi: *L iu cú nỏn s dng EL so vi còc mũ hnh hc mỳy truy n thng khi l i m vic vi d liu IoT hay khũng?*


4.1 Mũ trng thc nghim

Vic hun luyn mũ hnh c thc hin trỏn mt cm **Apache Spark Standalone** phỏn tỏn gm mt mỳy ch v i **hai thit b biỏn NVIDIA Jetson Orin Nano Super Developer Kit**. i m ònh cũũ y l i cũng mt cp Jetson va úng vai trũ *worker* ca cm Spark trong pha hun luyn, va l i thit b *tr i khai* trong pha suy lun thi gian thc (Hnh 4.5), giũp kim chng tỏnh kh thi ca to i n b pipeline trỏn ỹng phn cng mc tiỏu.

- **Mỳy ch (Spark master):** mỳy tỏnh xỏch tay MacBook Air, vi x lý Apple M3, RAM 16 GB, macOS Sonoma 14.3; m nhn iu phi cm (master), tin x lý d liu thũ (t CSV sang Parquet) v i chy h tng Docker (Kafka, PostgreSQL, InfluxDB, Grafana).
- **Hai nũt worker:** **NVIDIA Jetson Orin Nano Super Developer Kit**; cu hnh chi tit (CPU/GPU/RAM/lu tr) nỏu ti Bng 3.7, Chng 3; h iu hnh Ubuntu (NVIDIA JetPack/L4T). Jetson #1 ng thi chy tin trnh *driver* ca Spark (driver l i tin trnh iu kh i n g dng, khỏc vi vai trũ *master* iu phi cm ca MacBook).
- **Phn mm:** Python 3, Apache Spark / PySpark 3.4.1, MLlib; cu hnh cm tiỏu biu: `executor.memory=3 GB, executor.cores=4, driver.memory=3 GB, shuffle-file.partitions=32`; m i Jetson c cp 8 GB swap trỏn NVMe trỏnh tr i n b nh khi cao i m (xem `cluster/spark_cluster.env`, `cluster/setup_swap_jetson.sh`).

Cộc thut toàn hc mỳ, phng phỏp gim chiu vị cộc bc ònh giò u c trin khai bng PySpark vị thc thi phón tòn trỏn hai nũt Jetson; tp d liu Parquet c ng b sang c hai worker trc khi hun luyn. Kin trũc cm hun luyn phón tòn (gm vai trũ *master* iu phi trỏn MacBook vị hai *worker/executor* trỏn Jetson) c minh ha Hỡnh 4.1. Cn phón bit rũ vị Hỡnh 4.5 (pha suy lun): cũng mt cp Jetson nhng pha hun luyn úng vai trũ worker ca cm Spark, cùn pha suy lun úng vai trũ cng lc (gate) vị b phón loi.

Cn nhn mn nhng mỳ ch MacBook *ch m nhn* vai trũ *master* iu phi cm cũng tin x lý vị h tng dch v, mị *khũng* tham gia tỡnh toàn hun luyn (khũng chy *executor*). La chn nịy lị cú ch ờch: toịn b s liu hiu nng c bõo cõo nhm phn ònh trung thc kh nng *hun luyn phón tòn ngay trỏn phn cng biõn* Jetson, ũng vị mc tiõu ct lũi ca lun vn. Nu a MacBook (vị x lý Apple M3, mn nh òng k) vị ọ lịm nũt tỡnh toàn, phn ln khi lng cũng vic s dn v mỳ ch, góy mt cón bng ti (hin tng *straggler*) vị lịm sai lch cộc phỏp o thi gian/thũng lng, khin kt qu khũng cùn phn ònh ũng nng lc ca cm biõn. Vớ vỵ, cm o c c gi *ng nht* gm hai nũt Jetson; mỳ ch ch c dũng phỏt trin vị kim th nhanh trong giai on xóy dng pipeline.



Hỡnh 4.1. Cm hun luyn phón tòn Apache Spark Standalone: MacBook gi vai trũ *master* iu phi (khũng chy *executor*), hai Jetson Orin Nano Super lị *worker/executor* thc thi tỡnh toàn; d liu Parquet c phón vũng vị ng b sang c hai nũt, kt qu c gom v qua shuffle/collect.

4.2 Kt qu thc nghi

Bng 4.1 tũm tt thit lp tham s ca cộc mũ hỡnh hc mỳ c s dng trong nghiõn cu nịy. Trong ú, XGB vị MLP c tnh chnh bng Grid Search kt hp kim nh chõo (Kch bn 3); cộc mũ hỡnh cùn

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

li đứng b tham s c nh t trc, la chn da trồn còc nghiỏn cu gn óy vị thc nghi m s b, nhm bo m khỏc bit quan sỏt c gia còc phng phỏp gim chiu phn ònh ỳng phng phỏp thay vớ mc tnh chnh riỏng tng mũ hnh.

Bng 4.1. Tham s ti u ca còc mũ hnh hc mỳy

Mũ hnh	Tham s	Giỏ tr	Ý ngha/Mũ t
Decision Tree	maxDepth	15	Bt còc mu tn cỳng phc tp.
	impurity	entropy	Tiỏu chỏ chĩa nhỏnh ti u.
	minInstancesPerNode	5	S mu ti thiủ ti mi nũt lỏ.
Logistic Reg.	maxIter	200	m bo hi t trồn tp d liủ ln.
	regParam	0,001	Kim sỏt mc iủ chun (regularization).
	elasticNetParam threshold	0,0 0,5	S dng Ridge (L2) n nh hn. Ngng quyỏt nh nh phỏn.
SVM (LinearSVC)	maxIter	200	S ln lp ti u hũa biỏn.
	regParam	0,001	Tham s iủ chun biỏn quyỏt nh.
NB	modelType smoothing	gaussian 1,0	Phứ hp cho c trng liỏn tc. Lỳm mt Laplace.
Random Forest	numTrees	200	m bo n nh kt qu.
	maxDepth	15	Chiu sỏu ti a ca cỏy rng.
	featureSubsetStrategy	sqrt	Chn c trng ngu nhiỏn mi nũt.
GBT	maxIter	150	S vũng boosting ti a.
	maxDepth	6	Chiu sỏu ca cỏc cỏy yu.
	stepSize	0,05	Tc hc (learning rate) ca boosting.
	subsamplingRate	0,8	T l lý mu d liủ mi vũng boosting.
XGB	n_estimators	300	S lng cỏy boost trong mũ hnh.
	max_depth	8	Chiu sỏu ti a mi cỏy.
	learning_rate	0,05	Kim sỏt mc hc ca cỏy mi.
	subsample	0,8	T l lý mu d liủ mi cỏy.
	colsample_bytree	0,8	T l lý mu c trng mi cỏy.
MLP	layers	[d, 64, 32, 2]	Mng n-ron 2 lp n (d = s c trng u vủ).
	maxIter	150	S vũng lp hun luyủ ti a.
	stepSize	0,01	Tc hc ca mng n-ron.

4.2.1 Kch bn 1: ònh giò hui nng c s (Baseline)

Trong kch bn này, toin b tp c trng s (khong 78 c trng trc khi loi cng; s chõnh xõc sau khi loi `destination_port/source_port` lĩ 77) c a vĩa mĩ hõnh mĩ cha qua bt k bc la chn c trng hay gim chiu nĩa. Mc tiõu lĩ thĩt lp mt mc hui nng tham chiu cho cõc th nghĩm tĩp theo.

Kt qu hui nng ca cõc thut toin ML n l vĩ phng phõp Ensemble c trõnh bĩy trong Bng 4.2.

Bng 4.2. Kt qu hui nng phõn lp kch bn Baseline (toin b c trng s, ≈ 78 trc khi loi cng)

Thut toin	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9986	0,9925	0,9983	0,9954	0,9994	0,9988
Logistic Regression	0,9288	0,6937	0,9422	0,7991	0,9859	0,9509
SVM (LinearSVC)	0,9199	0,6650	0,9395	0,7788	0,9843	0,9485
NB	0,3163	0,1793	0,9933	0,3038	0,8829	0,6364
Random Forest	0,9985	0,9939	0,9960	0,9949	0,9999	0,9997
GBT	0,9980	0,9900	0,9965	0,9932	0,9998	0,9991
XGB	0,9991	0,9950	0,9993	0,9971	1,0000	0,9999
MLP	0,9900	0,9844	0,9487	0,9662	0,9984	0,9936
Hybrid Bagging	0,9990	0,9950	0,9984	0,9967	1,0000	0,9999
Soft Voting	0,9991	0,9952	0,9985	0,9969	1,0000	0,9999

Vĩ cu hõnh õ loi tr rừ r d liũ, nhũm mĩ hõnh da trõn cõy (Random Forest, XGB, GBT) c k vng dn u, vĩ F1 thp hn mc gn-tuyt-i ca cõc cu hõnh cú rừ r vĩ phn ònh ỹng khũ thc ca bĩ toin; kt lun “mĩ hõnh nĩa tt nht” ch c a ra khi chõnh lch vt khong tin cy (xem mc kim nh thng kõ). Do d liũ mt cõn bng mn, AUC-PR vĩ recall trõn lp tn cũng c u tiõn hn Accuracy khi din gĩi, vĩ Accuracy cú th gĩa lc quan gi to (mt mĩ hõnh luĩn oĩn lp benign chim a s vn t Accuracy cao).

4.2.2 Kch bn 2: So sõnh chin lc gim chiu d liũ

Chũng tũĩ thc hĩn so sõnh 3 chin lc chõnh nhm gim s lng c trng nhng vn m bo hui nng:

1. **RF Feature Importance:** Trõch xut 30 c trng cú im s quan trng cao nht t Random Forest.
2. **SHAP Importance:** S dng giò tr Shapley t mĩ hõnh XGB chn ra 30 c trng cú nh hng ln nht.
3. **PCA (k=40):** Gim chiu d liũ t khũng gian c trng gc (≈ 78 chiu trc khi loi cng) xung 40 thĩnh phn chõnh.

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Lu ý rng PCA đứng $k = 40$ — nhieu hn 30 c trng ca RF/SHAP, vớ óy lị phỏp *trờch xut* ch khũng phi *chn lc*: mi thnh phn chờnh ch lị mt t hp tyn tờnh mang mt phn phng sai, nỏn cn nhieu thnh phn hn gi lng thũng tin (phng sai tờch ly) tng ng vi tp 30 c trng gc. Trong di quỏt chung $\{20, 30, 40\}$, $k = 40$ lị mc gi phng sai cao nht, nỏn lị im vn hnh i din cũng bng nht cho PCA; ỏp $k = 30$ s lịm PCA mt thỏm phng sai vị bt li khi so sỏnh.

Bng 4.3 tũm tt s khỏc bit gia còc phng phỏp. Mũ hnh i din (ct *Mũ hnh tt nht*) ca mi phng phỏp c chn theo F1 trỏn tp kim nh (validation) tỏch t tp hun luy; tp kim tra khũng tham gia khỏu chn lc nỳy. Mc tiỏu lị kim chng gi thuyt: la chn c trng (RF/SHAP Top-30) gi c hieu nng gn vi baseline trong khi gim hn 60% s c trng, qua ú phứ hp cho trin khai biỏn.

Bng 4.3. So sỏnh hieu nng tt nht ca còc phng phỏp la chn c trng vị gim chiu

Phng phỏp	S c trng	Mũ hnh tt nht	F1-Score	Hun luy (s)	Dung lng (MB)
Baseline (Toịn b)	77	XGB	0,9971	4615,5	2,32
RF Importance	30	XGB	0,9922	1295,1	2,52
SHAP Importance	30	XGB	0,9970	1226,1	0,003 [†]
PCA (k=40)	40	XGB	0,9939	1444,8	3,82

Baseline đứng toịn b 77 c trng s (≈ 78 trc khi loi cng). [†]Kỏch the o bng còch tun t húa mũ hnh *trỏn cm hun luy phỏn tòn*: bc lu mũ hnh phỏn tòn ghi còc phỏn vũng d liu rng cớ trỏn executor ang gi chũng, nỏn giờ tr c KB ch bt c metadata cc b trỏn driver vị *thp hn the t*. Vớ dung lng ensemble cớ ph thuc s cớ vị s nũt (khũng ph thuc s c trng u vị), mũ hnh XGB SHAP Top-30 the t tng ng bn RF Top-30 ($\approx 2,5$ MB). Cng vớ vy, tp c trng rũt gn cú th cho mũ hnh *ln hn* baseline mt chũt (2,52 so vi 2,32 MB): ỏt ng viỏn tỏch hn khin cớ cn nhieu nũt hn t cũng tnh khit. Phỏp o tin cy lị bn mũ hnh xut ra ch n nũt ca pipeline trin khai (Mc kt qu biỏn).

Ngoii ra, s so sỏnh trc tip gia hai phng phỏp la chn c trng đa trỏn quan trng ca RF vị SHAP c trnh bỳ chi tit trong Bng 4.4.

Bng 4.4. So sỏnh hieu nng la chn c trng: RF Importance vs SHAP Importance (Top-30)

Thut toỏn	F1 (RF Top-30)	F1 (SHAP Top-30)	Chỏnh lch (%)
Random Forest	0,9879	0,9955	+0,77
XGB	0,9922	0,9970	+0,48
GBT	0,9844	0,9918	+0,75
Decision Tree	0,9835	0,9948	+1,15

4.2.3 Kch bn 3: Ti u húa tham s

Sau khi chn c b c trng ti u t SHAP, bn mũ hnh Spark ML gc (Random Forest, Decision Tree, GBT, Logistic Regression) c tnh chnh tham s thũng qua Grid Search kt hp Cross-validation trỏn tp c trng SHAP Top-30; còc mũ hnh cũn li (XGB, MLP, SVM, NB) gi

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

nguồn b tham s c nh Bng 4.1 (xem lý do u mc). Vic tinh chnh giúp còc mữ hnh cóy t F1 quanh mc 0,995 (Bng 4.5); mc ci thín so vì cu hnh c nh lĩ nh do bị toản nh phón trong-min ò gn bão hòa, phú hp vì nhn nh mc kim nh thng kỏ.

Kt qu hiu nng ca phng phòp Ti u hóa tham s c trnh bịy trong Bng 4.5.

Bng 4.5. Kt qu hiu nng phón lp kch bn Ti u hóa tham s

Thut toản	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9987	0,9977	0,9936	0,9957	0,9994	0,9980
Logistic Regression	0,9541	0,9787	0,7094	0,8226	0,9749	0,9371
SVM (LinearSVC)	gi cu hnh c nh (xem Bng 4.2)					
NB	gi cu hnh c nh (xem Bng 4.2)					
Random Forest	0,9986	0,9985	0,9922	0,9953	0,9999	0,9997
GBT	0,9985	0,9979	0,9924	0,9951	0,9999	0,9993
XGB	gi cu hnh c nh (xem Bng 4.2)					
MLP	gi cu hnh c nh (xem Bng 4.2)					
Hybrid Bagging	0,9986	0,9956	0,9949	0,9953	0,9999	0,9998
Soft Voting	0,9988	0,9985	0,9932	0,9958	1,0000	0,9998

4.2.4 Phón tồch kh nng gii thờch vì SHAP

Tồnh gii thờch (explainability) lĩ mt thính phn thit yu trong h thng IDS, nhm cung cp c s cho vic xóy dng nim tin vị h tr vn hnh thc t. Trong nghiỏn cu nịy, phng phòp SHAP (SHapley Additive exPlanations) c s dng phón tồch mc quan trng ca tng c trng i vì quyt nh phón loi ca mữ hnh XGB.

Hnh 4.2 xp hng 30 c trng quan trng nht theo giò tr trung bnh tuyt i ca SHAP (mean |SHAP|): thanh cịng dịi, c trng cịng nh hng ln n quyt nh phón loi xỏt trỏn toịn b mu. trỏnh rừ r, giò tr SHAP c tồnh trỏn mt *mu phón tng theo lp ly t tp hun luyn* (khũng phi tp kim tra); mu nịy c bin i qua ỹng b chun hóa (StandardScaler) ò fit trỏn tp hun luyn trc khi tồnh SHAP, bo m khũng gian u vọ ca phỏp gii thờch trúng khp vì khũng gian u vọ mị mữ hnh ò hc.

B sung cho xp hng tng th, Hnh 4.3 trnh bịy biu SHAP Summary dng beeswarm: mĩ im i din cho mt quan sỏt; trc hoịnh th hín giò tr SHAP (dng y d oỏn v lp tn cũng, óm y v lp bnh thng); mịu sc biu din giò tr c trng t thp n cao. phón tòn theo trc hoịnh phn ònh mc nh hng ca c trng, tp trung th hín tồnh n nh ca tỏc ng.

Bổn cnh ú, giò tr trung bnh tuyt i ca SHAP (mean |SHAP|) c dứng xp hng mc quan

trng tng th. Trón tp c trng ò loi tr rù r, còc c trng cú mean|SHAP| ln nht l: bwd_packet_length_std, init_win_bytes_backward, init_win_bytes_forward v bwd_packet_length_mean.

Còc c trng nh init_win_bytes_forward, init_win_bytes_backward (kòch thc ca s TCP giai on khi to) v bwd_packet_length_std, packet_length_std (s bin thiỏn ãi gúi tin) phn ònh c tòn phón phi lu lng l còc tòn hiu mng cú ý ngha, khũng ph thuc vò nh danh dch v. Vic loi destination_port buc mũ hnh ãa vò còc c trng hnh vi nỳ thay vò ghi nh ònh x cng → nhõn.

4.2.5 Phón tồch rù r ã liu (data leakage)

c trng destination_port l mt ngun rù r nhõn ò c ghi nhn trón CICIDS2017 [55]: mi loi tn cũng c sinh nhm vò nhng cng dch v c nh nõn cng òch tng quan mn nhõn, khin mũ hnh ã “ghi nh” ònh x cng-nhõn thay vò hc hnh vi lung (Engelen v cng s cho thy b phón loi cú th t chõnh xõc cao ch ãa vò cng òch). nh lng nh hng, lun vn thc hnh phón tồch loi b (ablation) gi/loi cng vi cũng mt cu hnh Random Forest c nh (Bng 4.6). iu òng lu ý l vi bị toàn nh phón trong-min, sau khi ò loi trng lp lung mc c trng, nh hng riỏng ca destination_port lỏn F1 ch cũn nh (chõnh khong 0,001 im F1), bi tồc v nh phón trón CICIDS2017 vn gn mc bõo hũa vò ngun rù r chi phi (còc lung trng lp) ò c x lý trc bng bc loi b trng lp. iu nỳ khũng cú ngha rù r vũ hi: giò tr ca quy trõnh loi-tr-rù-r th hnh rũ nh ònh giò ã lp vi còc lp tn cũng him (Mc 4.2.9) v tng quòt hóa liỏn b ã liu (Mc 4.2.8.1), ni còc “li tt” rù r khũng cũn giúp mũ hnh. Pipeline loi b c destination_port ln source_port; phón tồch ablation tp trung vò destination_port vò óy l cng chi phi.

Bng 4.6. Phón tồch loi b (ablation) rù r: nh hng ca c trng destination_port (Random Forest c nh a priori: numTrees=200, maxDepth=15, cú trng s lp; nh phón)

Cu hnh	F1	Recall (Attack)	AUC-PR
Gi destination_port (rù r)	0,9965	0,9988	0,9999
Loi destination_port (xut)	0,9955	0,9961	0,9997

C hai lt ãng cũng mt cu hnh Random Forest c nh t trc (200 cóy, sỏu 15, trng s lp, khp Bng 4.1) cũ lp ỹng nh hng ca c trng rù r. Mc chõnh lch F1 gia hai hnh phn ònh phn hiu nng b thi phng do c trng rù r; óy mc chõnh nh vò ò loi trng lp trc vò tồc v nh phón gn bõo hũa, nhng chiu hng (gi cng cho F1/recall cao hn) vn nht quòn vi hnh tng rù r. Mi kt qu khỏc trong lun vn ãng cu hnh ò loi cng.

4.2.6 Phón tồch hiu nng h thng

Bổn cnh chồnh xóc, hiu nng h thng v thi gian vị tị nguyổn lị yu t then cht cho vic trin khai thc t. Kt qu trong Bng 4.7 cho thy:

Bng 4.7. So sònh thi gian x lý vị kồch thc mữ hnh kch bn Baseline

Thut toòn	Hun luyn (s)	D oòn (s)	Kồch thc (MB)
Decision Tree	33,4	6,1	0,0004
Logistic Regression	49,2	5,4	0,009
SVM (LinearSVC)	224,3	5,4	0,002
NB	8,2	5,2	0,012
Random Forest	610,3	18,6	3,69
GBT	1346,8	8,9	0,92
XGB	4615,5	9,0	2,32
MLP	314,7	8,0	0,0004
Hybrid Bagging	11934,5	36,4	7,24
Soft Voting	–	25,6	–

- **Thi gian hun luyn:** Còc mữ hnh Gradient Boosting (GBT, XGB) cú thi gian hun luyn dị nht nhng t kt qu phón loi cao.
- **Thi gian d bèo:** XGB cú thi gian d bèo nhanh (khong 9 gióy cho toịn tp kim tra), Random Forest chm hn (khong 19 gióy); c hai phứ hp cho giòm sòt theo lữ gn thi gian thc.
- **Kồch thc mữ hnh:** còc mữ hnh cóy chim dung lng ln hn hn mữ hnh tuyt tồnh (LR, SVM, NB ch vị KB); RF khong 3,7 MB vị ensemble Hybrid Bagging ln nht (~7,2 MB) do gp nhieu b hc c s. *Lu ý: kồch thc c o bng còch tun t hóa (serialize) PipelineModel ca Spark ra a; giò tr nịy cú th bin thiổn theo còch phón mnh/partition khi lu nỏn ch mang tồnh tham kho tng i, khũng đứg lịm tiổu chờ quyut nh la chn mữ hnh.*

4.2.7 Kim nh ý ngha thng kỏ

Do còc con s F1 gia nhng phng phòp/thut toòn hịng u rt sòt nhau, lun vn khũng kt lun “mữ hnh tt nht” ch da trổn mt ln o. Mữ hnh i đin ca mi phng phòp, cng nh *cp phng phòp dn u c* a vịo kim nh, u c chn theo F1 trổn tp kim nh (validation, 20% tồch t tp hun luyn, seed=42); tp kim tra khũng tham gia khou chn lc. Hai phng phòp nịy sau ú c hun luyn li trổn N ln *ly mu li* tp hun luyn/kim tra (mc nh $N=6$, gỏp cp trổn cúg mt phỏp chia mi vùg), tồnh

F1 trung bình k m hai loi kh ng tin c y 95%: kh ng tin c y t th ng th ng v i kh ng tin c y h u ch nh *Nadeau–Bengio* [56], trong   ph ng sai nh n h s $(1/N + n_{\text{test}}/n_{\text{train}})$ b t t ng quan gia c c ln ly mu li ch ng ln; kh ng Nadeau–Bengio c  d ng l m c n c  kt lun ch  nh.   ngha th ng k  c  kim b ng *permutation test g  p cp hai ph ra*, lit k   y to n b $2^N = 64$ ho n v i du (kim nh ch  nh x c, kh ng xp x Monte Carlo), do   p nh nh t kh  d  l  $2/64 \approx 0,031$; ln h u ng c  b o c o b ng Cohen’s d g  p cp (B ng 4.8). Kt lun: ch  nh l ch F1 gia Baseline v i SHAP Top-30 c    ngha th ng k  mc s n ($p \approx 0,031$, $d \approx 1,94$), nh ng kh c bit tuy t i t nh ($\approx 0,0001$ im F1) n  n hai ph ng ph p *t ng ng v  mt th c d ng*; khi   ti u ch   ph  (kh  n ng g i th  ch, k  ch th c, chi ph   bi  n) mi l  c n c  la ch n. C n tha nh n r ng v  $N=6$, kim nh c  *lc th ng k   th p*; v  v y mt gi  tr p kh  ng c    ngha t  n  ch l  b ng ch ng y  cho “t ng ng”, v i kt lun c  c n c  ng thi v i kh ng tin c y Nadeau–Bengio v i Cohen’s d ; t ng N (k  m kim nh ch  o lng) l  h ng c ng c  tip theo.

B ng 4.8.  n nh qua nh u ln ly mu v i kim nh g  p cp (t `statistical_validity_multiseed.csv`)

Ph�ng ph�p	M�� h�nh	F1 (mean $\pm$ CI95 t)	CI95 Nadeau–Bengio	p (g��p cp)	Cohen’s d
Baseline (to�n b)	XGB	0,99734 $\pm$ 0,00007	[0,99722; 0,99746]	0,031	1,94
SHAP Top-30	XGB	0,99720 $\pm$ 0,00009	[0,99705; 0,99735]		

4.2.8 Kim tra  n nh trong-ph n-phi

M   h nh i  din ca mi ph ng ph p c   nh gi  li tr  n mt mu con ca tp kim tra (kh  ng giao v i tp hun lu n; B ng 4.9). C n n  i r  :  y ch  l  ph  p kim tra *n nh c  ng ph  n phi* (in-distribution), kh  ng phi kim th ch chu n ph  n phi;  nh gi  t ng qu  t h  a th c s  nm th  r ngh m li  n b  d  li u (Mc 4.2.8.1).

B ng 4.9. Kim tra  n nh trong-ph  n-phi tr  n mu con tp kim tra (t `robustness_holdout_summary.csv`)

Ph�ng ph�p	M�� h�nh	F1 (holdout)	AUC-PR
Baseline	XGB	0,9971	0,9999
RF Top-30	XGB	0,9921	0,9998
SHAP Top-30	XGB	0,9969	0,9999
PCA	XGB	0,9939	0,9998

4.2.8.1 Tng quòt hóa liỏn b d liu

ònh giò trỏn tp gi li trỏn li phỏp th *cứng b* (in-domain, cứng phỏn phi). kim chng kh nng *tng quòt hóa* the s, mũ hỏnh c hun luyn trỏn mt b d liu vị kim tra trỏn b *khỏc* (ònh giò *khỏc b*, cross-dataset; vị ngc li) trỏn tp c trng ỏ loi tr rừ r *chung* ca hai b. Do hai b d liu t tỏn ct khỏc nhau (CSE-CIC-IDS2018 đứg tỏn vit tt kiu CICFlowMeter v3), tỏn ct ca CSE-CIC-IDS2018 c ònh x v tỏn chun ca CICIDS2017 qua mt bng bờ danh (alias) tng minh trong mỗ ngun; danh sỏch c trng chung sau ònh x c lu ti `common_features.txt` bo m tòi lp. Mũ hỏnh đứg cho thờ nghim li Random Forest cú trng s lp (`weightCol`), nht quòn vị c ch x lý mt cón bng Chng 3. Khong còch gia F1 cứng b vị F1 khỏc b (Bng 4.10) nh lng mc suy gim khi gp dch chuyn phỏn phi, mt thc o n nh cht ch hn holdout cứng phỏn phi.

Do CSE-CIC-IDS2018 [49] cú quy mũ rt ln (~16 triu lung, ~6 GB), vt kh nng x lý thoi mòi ca thit b biỏn Jetson (8 GB), thờ nghim nỳ đứg *mu phỏn tng theo nhỏn* ca CSE-CIC-IDS2018 (t l 0,2, ~3,14 triu lung ly mu, cùn ~2,39 triu sau kh trứg lp mc c trng, `seed=42`, cũg tc `IDS_SAMPLE_FRAC`) nhm bo toỏn t l còc lp trong khi va vị phn cng; CICIDS2017 đứg ~2,23 triu lung. Toỏn b quy trỏnh tin x lý vị cn chnh CSE-CIC-IDS2018 cho thờ nghim liỏn b d liu c trỏnh bịy Thut toỏn 7; còc bc loi tr rừ r (giao c trng chung khũng cha cng/IP, kh trứg lp mc c trng) hoỏn toỏn nht quòn vị quy trỏnh cho CICIDS2017 (Thut toỏn 4). Còc con s mu c bờo còo tng minh bo m tởnh tòi lp; vic m rng liỏn toỏn b CSE-CIC-IDS2018 li hng phỏt trin tip theo.

Bng 4.10. Tng quòt hóa liỏn b d liu gia CICIDS2017 vị CSE-CIC-IDS2018 (CSE-CIC-IDS2018: mu phỏn tng `seed=42`; t `cross_dataset_results.csv`)

Hun luyn	Kim tra	Loi	F1
CICIDS2017	CICIDS2017	cứng b	0,9952
CICIDS2017	CSE-CIC-IDS2018	khỏc b	0,0423
CSE-CIC-IDS2018	CSE-CIC-IDS2018	cứng b	0,9245
CSE-CIC-IDS2018	CICIDS2017	khỏc b	0,0535

Đin gii. Kt qu cho thy mt tng phn rử rt vị *trung thc*: F1 cứng b rt cao c hai chiu (0,9952 vị 0,9245) nhng F1 khỏc b gim mnh xung 0,04–0,05, ch yu do recall gn bng khũng (0,022 vị 0,030) trong khi precision chiu 2017 sang 2018 vn t 0,596, tc mũ hỏnh gn nh khũng nhn ra tn cũg ca b d liu kia, ch khũng to ra cnh bờo sai trỏn lan. Nguyỏn nhón li *dch chuyn phỏn phi c trng* gia hai testbed: khỏc phỏn bn CICFlowMeter (thang o vị còch tởnh mt s c trng thay i), khỏc h tng mng vị cu hỏnh dch v, khỏc t hp loi tn cũg (HOIC/LOIC-HTTP ca 2018 khũng cú trong 2017). S st gim nỳ nht quòn vị còc nghiỏn cu cross-dataset trỏn

Thut toàn 7. Tin x lý vị cn chnh CSE-CIC-IDS2018 cho ònh giò liồn b d liu

- u vjo:** Tp tp CSV ca CSE-CIC-IDS2018; lc tổnn ct chun ca CICIDS2017 $\mathcal{S}_{2017}$;
 bng bờ danh tổnn ct $\mathcal{A}$ ($2018 \rightarrow 2017$); t l ly mu $r = 0.2$; $seed = 42$
- u ra:** B d liu D_{2018} trồn tp c trng chung ã loi rừ r $\mathcal{F}_{\text{chung}}$, sn sng cho thờ nghim khòc b
- 1: **Bc 1: Np vị lịm sch** (gng Thut toàn 4)
 - 2: c còc tp CSV; CLEANCOLUMN NAMES; HANDLEINFINITYVALUES; loi null vị bn ghi trúng lp hoịn toịn
 - 3: **Bc 2: Cn chnh tổnn ct**
 - 4: $\forall c \in \text{columns}(D) : c \leftarrow \mathcal{A}(c)$ $\triangleright$ ònh x tổnn ct CICFlowMeter v3 v tổnn chun ca CICIDS2017
 - 5: **Bc 3: To nhõn nh phón (khũng phón bit hoa/thng)**
 - 6: $y_i \leftarrow 0$ nu LOWER(label_i) = “benign”, ngc li $y_i \leftarrow 1$ $\triangleright$ 2018 ghi “Benign”; so khp khũng phón bit hoa/thng
 $\rightarrow$ **Loi tr rừ r d liu: Bc 4 vị Bc 6**
 - 7: **Bc 4 [loi rừ r – I]: Giao c trng chung, ã loi tr rừ r**
 - 8: $\mathcal{F}_{\text{chung}} \leftarrow (\mathcal{F}_{2017} \cap \mathcal{F}_{2018}) \setminus \mathcal{C}_{\text{exclude}}$ $\triangleright \mathcal{C}_{\text{exclude}}$: destination_port, source_port, protocol, IP, timestamp, flow_id
 - 9: Lu $\mathcal{F}_{\text{chung}}$ vjo common_features.txt $\triangleright$ c nh cho c hai chiu hun luy n/kim tra
 - 10: **Bc 5: Ly mu phón tng theo nhõn**
 - 11: $D \leftarrow \text{STRATIFIEDSAMPLE}(D, r, seed = 42)$ $\triangleright$ bo toịn t l lp; cùn $\sim 3,14$ triu lung
 - 12: **Bc 6 [loi rừ r – II]: Loi trúng lp mc c trng** (tt nh, nh Bc 4b ca Thut toàn 4)
 - 13: Gom nhúm theo $\mathcal{F}_{\text{chung}}$; loi toịn b nhúm mầu thun nhõn; gi ững mt i din ca mi nhúm nht quòn $\triangleright$ cùn $\sim 2,39$ triu lung
 - 14: **return** D_{2018} trồn tp c trng $\mathcal{F}_{\text{chung}}$
-

IDS da trồn c trng lung [57, 58, 59], vị chõnh lị lun c mnh nht ca lun vn: *con s trong-min gn hoịn ho (k c khi ã loi rừ r) khũng bo m kh nng trin khai sang mui trng khòc*; ònh giò liồn b d liu phi lị mt phn bt buc ca quy trõnh kim nh IDS [47], vị còc hng thờch ng min (chun húa theo min, hun luy n liồn b, cp nht theo drift) lị iu kin tiõn quy t cho trin khai thc t.

4.2.9 ònh giò a lp theo loi tn cũng


Phón loi nh phón (Benign/Attack) trồn CICIDS2017 vn d tòch; bc l im yu thc s, lun vn b sung ònh giò a lp theo tng loi tn cũng gc (precision/recall/F1 tng lp, macro-F1, weighted-F1 vị ma trn nhm ln), gm lp Benign vị 14 loi tn cũng ca CICIDS2017. Kt qu cho thy tng phn rt rủ gia hai ch s tng hp: *weighted-F1* $\approx 0,998$ (b chỉ phi bi còc lp a s) nhng *macro-F1* $\approx 0,806$, chõnh lị bng chng cho thy chõnh xòc nh phón gn hoịn ho ã *che giu* nng lc phòt hin kổm còc lp him. C th, còc lp a s (Benign, DoS Hulk, DDoS, PortScan) t F1 rt cao ($\geq 0,97$), trong khi còc lp cc him suy gim nghiõm trng: Web Attack – XSS recall ch 0,027, Web Attack – SQL Injection F1 = 0 (ch 6 mu), Bot recall 0,46. óy lị ni khòc bit gia còc phng phòp la chn c trng th hin rủ nht vị cng lị hng cn ci thìn (x lý mt cón bng, tng cng d liu lp him). Kt qu chỉ tit theo tng lp c trõnh bịy trong Bng 4.11, vị ma trn nhm ln a lp tng ng c

minh ha Hnh 4.4.


Bng 4.11. Hiu nng theo tng lp tn cũg (t per_class_metrics.csv)

Lp	Support	Precision	Recall	F1
Benign	380.119	0,9981	0,9997	0,9989
DoS Hulk	34.446	0,9990	0,9904	0,9947
DDoS	25.694	0,9996	0,9992	0,9994
DoS GoldenEye	2.020	1,0000	0,9757	0,9877
FTP-Patator	1.147	0,9965	0,9965	0,9965
DoS slowloris	1.068	0,9953	0,9925	0,9939
DoS Slowhttptest	1.023	0,9286	0,9912	0,9589
SSH-Patator	642	1,0000	0,9346	0,9662
PortScan	383	1,0000	0,9530	0,9759
Web Attack – Brute Force	311	0,7346	0,7299	0,7323
Bot	290	1,0000	0,4552	0,6256
Web Attack – XSS	111	1,0000	0,0270	0,0526
Infiltration	12	1,0000	0,6667	0,8000
Web Attack – SQL Injection	6	0,0000	0,0000	0,0000
Heartbleed	3	1,0000	1,0000	1,0000
macro-F1 / weighted-F1			0,806 / 0,998	


Phón tồch hng nhm ln gia còc lp him. c ma trn nhm ln theo òch n ca còc d oòn sai cho thy còc lp him suy gim theo hai kiu khòc nhau. Kiu th nht lĩ *nhm loi nhng vn b phòt hin*: 81/111 mu Web Attack – XSS b gòn thịnh Web Attack – Brute Force, tc bị toàn nh phón trin khai trổn biổn, còc lung nĩy vn b gn c tn cũg (76% XSS vn b chn), ch sai khóu nh danh loi. Kiu th hai nguy him hn: *lt hn thịnh Benign*: toĩn b 6/6 mu SQL Injection, 158/290 mu Bot (54%) vĩ 84/311 mu Web Brute Force b d oòn lĩ lu lng bnh thng. Ba c ch gĩi thỏch hin tng nĩy: (i) *mt cón bng cc oan* (6–311 mu so vĩ 380.119 mu Benign) khĩn còc lp him gn nh khũng cú vũng quy t nh riổng; (ii) *vic loi destination_port* nh hng nng nht n nhúm tn cũg web: khi mt “lĩ tĩ” cng 80, còc lung HTTP tn cũg (request/response ngn) cú c trng hĩnh vĩ rt gn lu lng duy t web thng vĩ gn ln nhau; giò tr recall 0,027 ca XSS lĩ con s *trung thc* thay cho con s p nh rừ r; (iii) *Bot ln Benign do bn cht*: còc lung beaconing C&C nh, u n, gĩng lu lng nn khi khũng cùn nh danh cng/dch v. Nhn đĩn nĩy nh hng trc tip cho hng phòt trin: x lĩ mt cón bng cú ch òch (tng cng/oversampling lp him), b sung c trng chui thi gian cho hĩnh vĩ beaconing, vĩ kim chng liổn b d liu (Mc 4.2.8.1).



Hình 4.2. Top 30 c trưng quan trng theo giờ tr trung bình tuyệt i SHAP ca mĩ hnh XGB



Hnh 4.3. Biu SHAP Summary (beeswarm): phn b vị hng tnc ng ca tng c trng



Hnh 4.4. Ma trn nhm ln a lp theo loi tn cũg (chun hóa theo hng)

4.3 Thc nghim vị ònh giò hiu nng mũ hnh trón Jetson Orin Nano Super

Trong phn này, lun vn xut xóy dng mt h thng phòt hin xóm nhp mng IDS *phón tồn* trin khai trón mt cm **hai thít b biể NVIDIA Jetson Orin Nano Super** [60] nhm ònh giò kh nng hot ng trong mũi trng tị nguyể hn ch; óy lị hng tip cn in toồn biể a phón tồch v gn ngun d liu gim bng thũng vị thi gian phn hi [61, 62], trong khi còc nghiể cu IDS biể trc óy ch yu ònh giò suy lun n nũt [63]. H thng c thít k theo kin trũc x lý d liu thi gian thc hai tng: mt *cng phòt hin bt thng* (anomaly gate) bng autoencoder nh lc bt lu lng bnh thng trón Jetson #1, vị mt *b phón loi* PySpark PipelineModel ch x lý còc lung nghi vn trón Jetson #2. H tng trung tóm (Apache Kafka cho trun ti thũng ip, PostgreSQL qun lý d liu, InfluxDB lu ch s hiu nng theo thi gian, Grafana trc quan hóa vị Mailtrap kim th cnh bõ qua email) chy trón mt mỳ ch iu phi.

NVIDIA Jetson Orin Nano Super lị mt mỳ tồnh nhũng (single-board computer) tồch hp CPU kin trũc ARM 64-bit vị GPU NVIDIA, h tr tng tc suy lun hc mỳ ngay tị biể; cu hnh chỉ tít õ nõu tị Bng 3.7 (Chng 3) vị mc Mũi trng thc nghim. Do hn ch v tị nguyể tồnh toồn so vị mỳ ch trun thng, vic trin khai trón Jetson Orin Nano Super cho phỏp ònh giò kh nng tị u hóa mũ hnh vị hiu nng suy lun trong iu kin phn cng nhũng (edge computing).

Mũ hnh cú hiu nng tị u c xỏc nh phn ònh giò hiu nng phón lp phõa trón s c tồch hp v iõ pipeline x lý nhm thc hin nhim v phòt hin vị phón loi lu lng mng thnh hai nhũm: *Benign* vị *Attack*. Còc ch s ònh giò bao gm chõnh xỏc (Accuracy), Precision, Recall, F1-Score, thi gian d oòn trung bnh cho mi mu, thũng lng x lý (throughput) vị mc tiểu th tị nguyể h thng (CPU, RAM). Kt qu thc nghim cho phỏp phón tồch tồnh kh thi ca vic trin khai h thng IDS da trón hc mỳ trong mũi trng thít b biể cú tị nguyể gii hn.

4.3.1 Còc cũng c s dng trong h thng

Trong h thng phòt hin xóm nhp mng IDS c xut, ngoi còc cũng ngh x lý d liu ln õ trõnh bị Chng 2, lun vn s dng thỏm mt s cũng c vị nn tng mỗ ngun m nhm h tr trun ti d liu, lu tr, giõm sỏt hiu nng vị cnh bõ theo thi gian thc. C th:


- **Apache Kafka** [64] – Lị nn tng trun ti thũng ip phón tồn (distributed event streaming platform), c s dng tip nhn vị phón phi d liu lung theo c ch publish-subscribe. Trong h thng, Kafka úg vai trũ trung gian gia ngun d liu (CICIDS2017 c mũ phng bng Python script) vị thít b Jetson Orin Nano Super, m bõ kh nng trun ti bt ng b, chu lị vị m rng linh hot.

- **Apache Spark Streaming** – Lì thịnh phn x lý d liu lung thi gian thc. Spark Streaming nhn d liu t Kafka Consumer, thc hin còc bc tin x lý c trng vị chuyn d liu n mĩ hnh hc mỳ ò c hun luyn thc hin suy lun.
- **PostgreSQL** – Lì h qun tr c s d liu quan h mĩ ngun m cú n nh vị kh nng m rng cao. Trong h thng, PostgreSQL c s dng lu tr kt qu d oàn, thũng tin cnh bào vị còc bn ghi phc v bào cò tng hp.
- **InfluxDB** – Lì c s d liu chui thi gian (Time-Series Database), ti u cho vic lu tr vị truy vn còc ch s theo thi gian. H thng s dng InfluxDB ghi nhn còc thũng s hieu nng nh thi gian suy lun, mc s dng CPU, b nh vị thũng lng x lý.
- **Grafana** – Lì nn tng trc quan húa d liu mĩ ngun m, cho phõp xóy dng còc dashboard theo thi gian thc. Grafana kt ni vị InfluxDB vị PostgreSQL hin th tnh trng hot ng ca h thng IDS cng nh thng kổ còc s kin tn cũg.
- **Mailtrap** – Lì cũg c kim th email trong mĩ trng gi lp. Trong giai on thc nghim, Mailtrap c s dng kim tra c ch gi cnh bào khi h thng phòt hin lu lng mng bt thng trc khi trin khai mĩ trng thc t.

Vic tồch hp còc cũg ngh trổn giũp h thng m bo kh nng x lý d liu thi gian thc, lu tr an toìn, giòm sòt hieu nng liổn tc vị kờch hot cnh bào kp thi khi phòt hin hnh vị xóm nhp.

4.3.2 Mũ hnh h thng xut

H thng phòt hìn xóm nhp c thit k theo kin trũc x lý d liu lung nh minh ha Hnh 4.5. Lung x lý tng th bao gm còc bc sau:



Hnh 4.5. Kin trũc h thng phòt hìn xóm nhp phón tòn thi gian thc trũn cm 2 Jetson Orin Nano Super

1. **Ngun d liu:** D liu t b CICIDS2017 c mũ phng theo thi gian thc thng qua mt Python script vị gi vị Kafka Producer trón topic `ids-network-flow`.
2. **Cng phòt hin bt thng (Jetson #1):** Jetson #1 m nhn vai trò `anomaly_gate`: mt autoencoder nh (hun luyn ch trón lu lng bnh thng) tòngh sai s tòi to (reconstruction error) cho tng lung. Còc lung cú sai s di ngng c coi lị bnh thng vị *c lc b*; ch còc lung *ngghi vn* mi c chuyn tip sang topic `ids-suspicious-flow`. C ch nịy gim òng k khi lng phi a vị suy lun Spark.
3. **B phón loi (Jetson #2):** Jetson #2 m nhn vai trò `classifier`: ti mũ hnh PySpark `PipelineModel` (vị tp c trng SHAP Top-30 ò chn) vị phón loi còc lung ngghi vn thnh *Benign* hoc *Attack*. Vector *u* vị khi trin khai gm 29 c trng: trong Top-30 theo xp hng SHAP cú `destination_port`, nhng c trng nịy b loi khi mũ hnh xut ra trin khai vớ lị kỏnh rừ r nhõn trón CICIDS2017 (Mc 4.2.5), nht quòn vị giao thc chng rừ r pha hun luyn.
4. **Ghi nhn hiu nng:** Mi nũt ghi nhn thi gian d oòn/mu, mc s dng CPU/RAM/nhit vị thng lng (gn nhõn theo `EDGE_NODE_ID`); còc ch s c lu vị InfluxDB.
5. **Lu tr vị cnh bõo:** Kt qu d oòn vị s kin tn cũng c lu vị PostgreSQL; khi phòt hin lu lng bt thng, h thng kỏch hot cnh bõo qua Email/Webhook (Mailtrap, Slack trong mũi trng kim th) t mt nũt chõnh c ch nh trõnh trng lp.
6. **Trc quan húa vị giõm sòt:** Grafana truy xut d liu t InfluxDB vị PostgreSQL xóy dng dashboard theo thi gian thc, giõm sòt trng thòi h thng vị thng kỏ còc s kin tn cũng.

Ba ch trin khai phón tòn. Cm hai Jetson h tr ba ch , la chn theo rịng buc ti vị tr:

- **Ch A – Pipeline split** (khuy n gh): Jetson #1 = cng bt thng (anomaly gate), Jetson #2 = b phón loi (classifier) (nh mũ t trón), giúp gim ti Spark nh lc lu lng bnh thng sm.
- **Ch B – M rng theo chiu ngang (Horizontal scaling):** c hai Jetson chy pipeline y trong cũng mt nhúm tiõu th (consumer group) ca Kafka nhm tng thng lng.
- **Ch C – Spark cluster:** mỳy ch MacBook lịm Spark master, hai Jetson lịm worker, phón tòn suy lun Spark trón cm. Nht quòn vị nguỷn tc mc Mũi trng thc nghim, MacBook ch m nhn iu phi (master), khũng chy executor; toịn b tòngh toòn suy lun vn nm trón hai Jetson.

Kin trức nịy m bo tồnh mữ-un, tồch bit còc thịn phn x lý, ng thi phứ hp vi mữ hnh trìn khai phón tòn trổn còc thit b biổn cú tị nguyổn hn ch nh Jetson Orin Nano Super.

c t cng bt thng (operating point). Cng autoencoder lị mt b lc *i u chnh c* ch khũng phi mt im c nh: nỏng ngng giũp gim ti (offload) nriu lu lng bnh thng hn khi Spark (tng t l b qua ti cng, gate-skip) nhng cú th gim recall trổn lp tn cũng. Ngng ca cng c chn theo phón v (quantile) ca sai s tòi to tồnh trổn mt *tp kim nh benign*, gm 10% tồch t phn lu lng bnh thng ca tp hun luy (seed=42); tp kim tra khũng tham gia vic chn ngng, trồnh rừ r kiu “ngng oracle”. Bng 4.12 trỏnh bịy ng ònh i gia recall vị mc gim ti (recall–offload) khi quốtt còc mc quantile trổn tp kim nh nịy; im vn hnh c chn theo ngón sòch tr/ chờnh xòc ca trìn khai.

Bng 4.12. im vn hnh ca cng bt thng khi quốtt quantile trổn tp kim nh benign (10% benign train, seed=42; t gate_operating_points.csv). FPR óy lị t l lung benign b cng chuy n nhm sang b phón loi, khũng phi FPR ca toin h thng.

Quantile (validation)	Ngng	Recall (Attack)	FPR	T l b qua ti cng (%)
0,90	0,0023	0,7589	0,1003	80,08
0,95	0,0052	0,7552	0,0506	84,36
0,99	0,0192	0,7420	0,0101	88,00
0,995	0,0317	0,7229	0,0053	88,70

4.3.3 La chn mữ hnh cho thit b biổn

Trìn khai trổn thit b biổn t ra còc rịng buc v tị nguyổn: RAM 8 GB chia s gia CPU vị GPU (trong ú PySpark JVM chim mt phn òng k), CPU ARM, cứng rịng buc v nhit /bng thũng ti biổn. Cng cn nhn mn nhng vic chn Apache Spark trổn Jetson 8 GB phi chu chi phờ JVM/Spark òng k; Spark c dứng óy nhm *nht quòn* vi pha hun luy phón tòn, ch khũng nhm ti u tr suy lun trổn mt nữt; chi phờ ònh i nịy c nh lng qua so sònh vi scikit-learn vị ONNX Runtime mc 4.3.6, cùn tng tc bng TensorRT lị hng nghiổn cu tng lai. Ba mữ hnh i din cho ba th nghim khòc nhau c chn ònh giò:

1. **Decision Tree** – Mữ hnh cóy n l, i din cho còch tip cn n gin nht.
2. **GBT (Gradient-Boosted Trees)** – i din cho phng phòp Boosting, s dng nriu cóy yu kt hp tun t.
3. **Random Forest** – i din cho phng phòp Bagging, s dng ensemble 200 cóy song song.

C ba mữ hnh u c hun luy trổn tp SHAP Top-30 c trng vị trìn khai di dng PySpark PipelineModel.

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

```
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.50 +  
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (729.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.0 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.1 C  
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.2 C  
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.4 C  
[MONITOR:jetson-nano-1] CPU: 17.0% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.7 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.5 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (730.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.8 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (730.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.8 C  
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.6 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.6 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 17.2% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.1 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.2 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.1 C  
[MONITOR:jetson-nano-1] CPU: 17.6% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.3 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.1MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.2 C
```

(a) Jetson #1 (jetson-nano-1): cng phòt hìn bt thng, giồm sòt tị nguyễn theo node


```
thainguyenvu -- bvdung@ubuntu: ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 -- 208x63  
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.50 ... +  
[MONITOR:jetson-nano-2] CPU: 72.4% | MEM: 58.6% (4196.6MB) | Throughput: 6.88 rps | Latency: 3.833ms | Attacks: 32  
Temp: 56.7 C  
[Stage 984:] (0 + 0) / 63  
[MONITOR:jetson-nano-2] CPU: 17.6% | MEM: 49.6% (3512.9MB) | Throughput: 6.07 rps | Latency: 3.968ms | Attacks: 32  
Temp: 56.2 C  
[MONITOR:jetson-nano-2] CPU: 17.3% | MEM: 57.5% (4111.6MB) | Throughput: 6.04 rps | Latency: 4.472ms | Attacks: 32  
Temp: 56.1 C  
[Stage 1889:] (0 + 6) / 63  
[MONITOR:jetson-nano-2] CPU: 97.7% | MEM: 54.7% (3980.9MB) | Throughput: 3.83 rps | Latency: 4.514ms | Attacks: 16  
Temp: 57.3 C  
[MONITOR:jetson-nano-2] CPU: 21.4% | MEM: 46.7% (3290.8MB) | Throughput: 6.88 rps | Latency: 4.334ms | Attacks: 32  
Temp: 56.2 C  
[MONITOR:jetson-nano-2] CPU: 67.8% | MEM: 55.0% (3927.6MB) | Throughput: 6.06 rps | Latency: 3.638ms | Attacks: 32  
Temp: 56.7 C  
[Stage 1847:] (0 + 6) / 63  
[MONITOR:jetson-nano-2] CPU: 68.2% | MEM: 58.9% (3611.9MB) | Throughput: 6.00 rps | Latency: 4.156ms | Attacks: 32  
Temp: 57.0 C  
[MONITOR:jetson-nano-2] CPU: 16.9% | MEM: 59.6% (4274.3MB) | Throughput: 6.88 rps | Latency: 4.483ms | Attacks: 32  
Temp: 55.9 C  
[jetson-nano-2 2,488] Batch: 187ms | Attacks: 2373/2488 | Avg: 9.7ms  
[MONITOR:jetson-nano-2] CPU: 85.5% | MEM: 49.1% (3474.6MB) | Throughput: 6.88 rps | Latency: 3.256ms | Attacks: 32  
Temp: 56.5 C  
[Stage 1886:] (0 + 0) / 63  
[MONITOR:jetson-nano-2] CPU: 66.6% | MEM: 51.7% (3673.5MB) | Throughput: 3.04 rps | Latency: 3.737ms | Attacks: 16  
Temp: 56.9 C  
[MONITOR:jetson-nano-2] CPU: 28.7% | MEM: 56.8% (4882.1MB) | Throughput: 6.88 rps | Latency: 4.399ms | Attacks: 32  
Temp: 56.1 C  
[MONITOR:jetson-nano-2] CPU: 74.4% | MEM: 54.8% (3988.1MB) | Throughput: 6.88 rps | Latency: 3.923ms | Attacks: 32  
Temp: 55.9 C  
[MONITOR:jetson-nano-2] CPU: 34.2% | MEM: 56.8% (4863.8MB) | Throughput: 5.88 rps | Latency: 4.574ms | Attacks: 31  
Temp: 56.8 C  
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 55.8% (3924.2MB) | Throughput: 6.88 rps | Latency: 4.42ms | Attacks: 32  
Temp: 56.1 C  
[Stage 1149:] (1 + 5) / 63  
[MONITOR:jetson-nano-2] CPU: 98.8% | MEM: 59.1% (4234.9MB) | Throughput: 3.04 rps | Latency: 3.157ms | Attacks: 16  
Temp: 57.2 C  
[MONITOR:jetson-nano-2] CPU: 16.8% | MEM: 52.5% (3733.5MB) | Throughput: 6.88 rps | Latency: 3.994ms | Attacks: 32  
Temp: 55.9 C  
[MONITOR:jetson-nano-2] CPU: 18.8% | MEM: 57.8% (4877.7MB) | Throughput: 5.98 rps | Latency: 4.577ms | Attacks: 31  
Temp: 56.1 C  
[Stage 1187:] (0 + 6) / 63  
[MONITOR:jetson-nano-2] CPU: 45.8% | MEM: 68.6% (4351.7MB) | Throughput: 5.98 rps | Latency: 4.121ms | Attacks: 31  
Temp: 56.7 C  
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 52.7% (3758.8MB) | Throughput: 5.99 rps | Latency: 3.338ms | Attacks: 31  
Temp: 55.9 C  
[Stage 1212:] (3 + 3) / 63
```

(b) Jetson #2 (jetson-nano-2): b phón loi PySpark, thng lng ~6 lung/giớy, tr suy lun ~4 ms, m tn cũng theo lữ


Hình 4.6. Giao din terminal khi pipeline IDS hot ng trở hai node Jetson Orin Nano Super:
(a) node cng lc bt thng vị (b) node phón loi PySpark




Hình 4.7. Dashboard Grafana ghiem sùt hieu nng IDS theo thi gian thc




Hình 4.8. Email cnh bõo tn cũng c gi qua Mailtrap trong mũi trng kim th (nh chp t giai on th nghim sm ca h thng; mũ-un cnh bõo vị nh dng thũng ip gi nguõn khi trin khai trõn cm Jetson)



Hình 4.9. Dashboard Grafana hin th chỉ tit còc cuc tn cũng c phòt hin vị phón loi theo thì gian



Hình 4.10. Dashboard Grafana ti thì im ti nh ca ch tòch pipeline: nửt cng (jetson-nano-1) ch s dng khong 5 % CPU trong khi nửt phón loi PySpark (jetson-nano-2) t ti 91 %



Hình 4.11. Thông báo nh báo tn cũng c gi qua Slack Incoming Webhook (nh chp t giai on th nghim sm; nh dng thng ip gi nguyễn khi trin khai trở cm Jetson)

Hình 4.6 minh ha giao din terminal thc t khi pipeline IDS ang x lý d liu trở Jetson Orin Nano Super, bao gm thng tin v thng lng, tr vị s lng tn cũng phòt hin c. Hai dashboard Grafana (Hình 4.7 vị Hình 4.9) cho phỏp giòm sòt hieu nng h thng vị chỉ tit còc cuc tn cũng theo thi gian thc. Hình 4.10 ghi li thi im ti nh, cho thy rủ s phón b ti lch c trng ca ch tòch pipeline: nũt cng ch s dng khong 5 % CPU trong khi nũt phón loi PySpark t ti 91 %, xòc nhn b phón loi lị thịnh phn chim tị nguyễn ch o vị lị cn c cho còc phón tòch nng lng–thũng lng phn sau. Khi phòt hin tn cũng, h thng t ng gi cnh bào qua nhieu kỏnh: email thũng qua Mailtrap SMTP (Hình 4.8) vị tin nhn Slack (Hình 4.11).

4.3.4 Kt qu hun luyt còc mũ hỏnh ng viỏn trở cm Spark

Bng 4.13 trỏnh bọy kt qu hun luyt vị ònh giò ba mũ hỏnh ng viỏn trở cm Spark (mũ t mc Mũi trng thc nghim) trc khi trin khai xung thit b biỏn.

Bng 4.13. Kt qu hun luyt còc mũ hỏnh ng viỏn cho trin khai biỏn (SHAP Top-30)

Mũ hỏnh	F1-Score	Accuracy	Thi gian hun luyt (s)	Kỏch thc (MB)
Decision Tree	0,9814	0,9943	24,4	0,046
GBT	0,9753	0,9925	341,8	0,865
Random Forest	0,9826	0,9947	687,3	4,427

V tiỏu chỏ nhn bit rịng buc biỏn (edge-aware), Decision Tree cú kỏch thc mũ hỏnh nh nht (0,046 MB), nh hn Random Forest khong 96 ln vị thi gian hun luyt nhanh hn khong 28 ln; F1/Accuracy cn c cón nhc cựng còc ch s chỉ phỏ nịy chn mũ hỏnh trin khai. (Còc mũ

hình ng viồn biể c hun luyn trổn mu con phón tng khi xut va b nh mt nũt, nỏn F1 thp hn chũt ờt so vi kt qu hun luyn phón tòn y Bng 4.3; chờnh xỏc chờnh thc ly t pha hun luyn y .)

4.3.5 Kt qu o hiu nng (benchmark) trổn Jetson Orin Nano Super

Bng 4.14 trờnh bỳ kt qu o hiu nng (benchmark) thc t trổn Jetson Orin Nano Super. Mi cu hnh c o lp li 5 ln; trc mi ca s o cú giai on khi ng (warm-up) bng chờnh lu lng tht lỳm nũng JVM/JIT, vị d liu warm-up b loi khi ca s o; kt qu bõo cõo lỳ trung bõnh $\pm$ lch chun qua cõc ln chy. Hai loi tr c ghi nhn: (i) *tr suy lun* (tin x lý + d õn) trổn tng nũt, vị (ii) *tr u cui* (t thi im producer gĩ n khi cú phõn quyit) tõnh t nhõn thi gian ca producer; giò tr tuyt i ca loi (ii) ch cú ý ngha khi cõc mỳy ng b ng h NTP. Cõc phón v tr (p50/p95/p99) c tõnh mc tng ln chy t *log thũ theo tng lung* trong ỹng ca s ti; vi cm nhiu nũt, p95 bõo cõo lỳ p95 ca nũt xu nht (khũng ly phón v ca cõc giò tr trung bõnh theo nũt).

Bng 4.14. So sõnh hiu nng trin khai trổn Jetson Orin Nano Super

Mũ hnh	Thũng lng (mu/giõy)	tr suy lun (ms) p50 / p95 / p99	CPU (%)	RAM (%)	Kõch thc (MB)
Decision Tree	22,0	441 / 537 / –	46,4	21,9	0,046
GBT	24,3	414 / 439 / –	40,9	24,0	0,865
Random Forest	26,8	378 / 397 / –	35,2	27,5	4,427

4.3.6 So sõnh engine suy lun: chi phõ ca vic ng nht stack

Lun vn trin khai mũ hnh dĩ dng PipelineModel ca Spark *ng nht vi pha hun luyn phón tòn*: cũng mt stack va hun luyn trổn cm va suy lun trổn thĩt b. *nh lng chi phõ ònh i ca s ng nht nỳ*, lun vn o li *cũng mt* mũ hnh Random Forest (cũng siõu tham s) trổn *cũng tp c trng SHAP õ chn* trin khai nhng qua cõc engine nh hn ch mt nũt: scikit-learn (CPU, khũng JVM) vị ONNX Runtime (CPU execution provider; Bng 4.15, sinh t benchmark_engines.py). Vớ cũng thut toõn vị c trng nỏn chờnh xỏc tng ng; phõp so sõnh tp trung vĩa *chi phõ suy lun*. (C ba dũng ca Bng 4.15 c o li trong *cũng mt phiõn* trổn cũng trng thõi bo mch so sõnh cũng bng, nỏn dũng PySpark chõnh lch nh so vi Bng 4.14 o phiõn trc: 22,6 so vi 26,8 lung/giõy, do khõc phiõn o vị xung CPU.) Kt qu o (Bng 4.15) cho thy stack JVM/Spark chu chi phõ suy lun cao hn õng k so vi scikit-learn trổn bo mch ARM 8 GB: thũng lng thp hn khõng 9 ln, tr p95 cao hn khõng 11 ln, t l RAM gn gp ỹi vị nng lng mĩ suy lun cao hn khõng 25 ln. Biõn dch cũng mũ hnh rng ngu nhiõn sang ONNX

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Runtime cùn ni rng khong còch nịy òng k: $\approx 7\,900$ lung/gióy vì p95 1,1 ms, tc gp ≈ 348 ln thũng lng ca Spark ò trin khai, mc nng lng ch $\approx 2\%$ so vì scikit-learn; vic nõu rử iu nịy lị c s cho hng phòt trin *xut mữ hơnh sang ONNX/TensorRT suy lun* trong khi vn gị Spark cho hun luyn (vic tòch hp phiổn ONNX vịo pipeline streaming vị khai thòc GPU qua TensorRT thuc hng phòt trin).

Bng 4.15. Chi phờ suy lun mt nửt trổn cững mữ hơnh/c trng (Spark vs sklearn vs ONNX), o trổn nửt phón loi trong cững iu kin bo mch (batch 10; nng lng lị phn *hot ng*, ò tr *idle*)

Engine	Thũng lng (lung/gióy)	tr p95 (ms)	RAM (%)	Nng lng /suy lun (mJ)
PySpark (trin khai)	22,6	532	24,3	71,6
scikit-learn	204,4	49,8	13,3	2,91
ONNX Runtime	7870,8	1,1	15,7	0,06

4.3.7 Kt qu ba ch trin khai phón tòn


Ngoi vic so sònh còc mữ hơnh trổn mt nửt, lun vn ònh giò ba ch trin khai phón tòn trổn cm hai Jetson Orin Nano Super (Bng 4.16). Ch s chònh gm thũng lng, tr p95 (ms), t l b qua ti cng (gate-skip: % lu lng bõnh thng c cng lc khi suy lun Spark) vị F1 trổn lp tn cững. *Thũng lng* c nh ngha lị s *phòn quyt cui cững* ghi vịo PostgreSQL trổn gióy (mt lung nhn phòn quyt hoc ti cng (nu b b qua lị benign) hoc ti b phón loi), khũng cng dn u ra ca hai tng trờnh m trũng lung c chuyñ tip ch pipeline split.

Bng 4.16. So sònh ba ch trin khai phón tòn trổn cm 2 Jetson Orin Nano Super

Ch	Thũng lng (lung/gióy)	tr p95 (ms)	B qua ti cng (%)	Nng lng /suy lun (mJ)	F1 (Attack)
Mt nửt (single)	2,60 $\pm$ 0,41	12,3 $\pm$ 3,0	(ni tuyñ)	2490	†
A: Pipeline split	62,5 $\pm$ 0,6	13,1 $\pm$ 2,6	95,8	178	†
B: Horizontal scaling	5,9 $\pm$ 1,4	21,6 $\pm$ 19,2	(ni tuyñ)	2250	†
C: Spark cluster	90,0 $\pm$ 25,6	23,9 $\pm$ 17,8	97,9	119	†

Phòt lị CICIDS2017 100 lung/gióy; trung bõnh $\pm$ lch chun trổn ≥ 3 ln lp; p95 tờnh t log thũ tng lung (nửt xu nht). “(ni tuyñ)”: vai trờ *full*, cng chy trong cững tin trờnh vị còc lung b b qua vn c ghi phòn quyt nõn khũng cú t l b qua riổng. †: cht lng phòt hìn khũng ph thuc ch (còc ch đũng cững mt mữ hơnh xut ra); F1 lp tn cững ngoi tuyñ xem Bng 4.6.

Kt qu thc o (Hơnh 4.12) cho thy: ch *pipeline split* tòch cng khi b phón loi Spark giúp thũng lng phòn quyt tng t 2,6 lỏn 62,5 lung/gióy (gp ≈ 24 ln) vì p95 gn nh khũng i, nh cng lc 95,8% lu lng bõnh thng vị khũng cùn b Spark chn vùng x lị. *M rng theo chiu ngang* ch tng xp x gp ửi mt nửt (5,9 so vì 2,6) vớ mi nửt vn chy trn b phón loi Spark trong tin trờnh.




Hình 4.12. Thũng lng vị tr p95 ca bn cu hnh (mt nút c s + ba ch phón tòn) trón cm 2 Jetson

Spark cluster (cng + b phón loi ni cm Spark standalone) t thũng lng trung bnh cao nht (90,0) nhng dao ng ln gia còc ln chy (± 26) vị ph thuc thỏm nút ch (master) trón mỳ iu phi, nỏn pipeline split vn lị khuyn ngh mc nh. *Nng lng mi suy lun* o bng *tegrastats* (nn idle 30 gióy trc mi ca s ti; ch hai nút cng cũng sut c hai bo mch): mc ti 100 lung/gióy, phn cũng sut *hot ng* (õ tr idle) nm di ngng nhiu ly mu ($< 0,15$ W mi nút), do ú bng bõo cõo nng lng *toin bo mch* trón mi phõn quyit, tc thc o mc dịn tri cũng sut bo mch theo thũng lng cp trin khai (khũng phi chi phõ rĩng ca mũ hnh): cõc ch dũng cng (A, C) dịn tri cũng sut hai bo mch trón s phõn quyit ln gp 24–35 ln, gim nng lng mi phõn quyit t $\approx 2,5$ J xung 0,12–0,18 J.

4.3.8 Phón tồch vị la chn mĩ hnh

Hnh 4.13 minh ha trc quan s khòc bit gia ba mĩ hnh v thũng lng, tr vị mc s dng RAM trón Jetson Orin Nano Super.



Hnh 4.13. So sòn hiệu nng ba mĩ hnh trón Jetson Orin Nano Super

Kt qu benchmark cho th y s ònh i rủ rìng gia còc ch s:


- **Random Forest** t thũng lng cao nht (26,8 mu/giý) nh Spark ti u hóa song song trón nhiu cóy, nhng s dng RAM nhiu nht (27,5%) vị kòch thc mĩ hnh ln nht ($\approx 4,4$ MB).
- **GBT** cú hiệu nng trung bnh tt c còc ch s, úng vai trò cu ni gia Decision Tree vị Random Forest.
- **Decision Tree** cú F1-Score 0,9948 (SHAP Top-30, ngoi tyn), s dng RAM thp nht (21,9%), vị mĩ hnh cú kòch thc rt nh ($\approx 0,05$ MB). Mc dù thũng lng thp nht (22,0 mu/giý), giò tr nìy vn òp ng yóu cu giòm sòt thì gian thc cho mng quy mĩ va vị nh.

Hnh 4.14 th hin s ònh i a chiu gia còc tiỏu chờ la chn mĩ hnh. Decision Tree chim u th hai tiỏu chờ quan trng nht cho thit b biỏn: RAM thp vị kòch thc mĩ hnh nh.

Decision Tree c chn lĩm mĩ hnh trin khai chònh trón thit b biỏn đa trón ba tiỏu chờ:

1. **Cht lng phòt hin:** F1-Score 0,9948 – vì tp c trng SHAP Top-30 ò c la chn (õ loi tr rừ r), mt cóy quy t nh n l vn nm bt c còc mu phón loi, ch kỏm Random Forest 0,0007 im F1.
2. **Hiu qu tị nguyỏn:** Ch s dng 21,9% RAM, gim òp lc lớn garbage collector ca JVM vị m bo tòn n nh lóu dị trón thit b gii hn tị nguyỏn.
3. **Tòn kh chuyn:** Kòch thc mĩ hnh $\approx 0,05$ MB cho phỏp trin khai trón còc thit b IoT cú b nh hn ch hn.

Đánh đổi giữa các mô hình trên Jetson Orin Nano Super
(chuẩn hoá min-max, càng ra ngoài càng tốt)



Hình 4.14. Biểu đồ radar thể hiện sự đánh đổi (trade-off) giữa các mô hình trên thiết bị

4.4 Tho luận vị So sánh tng hp

Kết quả thực nghiệm cho thấy việc kết hợp là cần thiết để đạt được SHAP và phương pháp ensemble (Hybrid Bagging) là một hướng tiếp cận phù hợp cho hệ thống IDS trên bộ dữ liệu CICIDS2017. Dữ liệu hình ảnh được lọc bỏ để giảm thiểu nhiễu, giúp đạt được F1-Score 0,9966 (Hybrid Bagging, SHAP Top-30) trong thí nghiệm thực nghiệm. Việc lựa chọn vị trí dung lượng lưu trữ, phù hợp với việc phân tích dữ liệu.

Cụ thể, khi triển khai trên thiết bị Jetson Orin Nano Super, Decision Tree và SHAP Top-30 có thể đạt được F1-Score 0,9948 ngoại tuyến (bỏ qua việc lọc bỏ; bộ mô hình xuất ra kết quả, huấn luyện trên mẫu phân tích 20%, t 0,981), tổng lượng 22,0 MB/giây, vị trí dung lượng 21,9% RAM. Các số liệu này cho thấy rằng việc phân tích dữ liệu thực tế của việc triển khai hệ thống IDS đã trở nên dễ dàng hơn và việc phân tích dữ liệu thực tế cũng có thể được thực hiện một cách an toàn và hiệu quả.

Chng 5. KT LUN VỊ HNG PHÒT TRIN

Trong chng nỳ, lun vn s trnh bỳ nhng kt qu mỳ lun vn ã t c so vĩ mc tiõu c t ra t ban u khi bt u the hin. Bõn cnh ú, lun vn cng trnh bỳ nhng hn ch vĩa ra hng phòt trin trong tng lai ca nghiõn cu.

5.1 Nhng úng gúp chõnh ca lun vn

Sau khi the hin lun vn vĩ tĩ “*Phòt hin xõm nhp (IDS) da trõn Apache Spark cho bo mt mng IoT*”, lun vn ã t c mt s kt qu chõnh tng ng vĩ cõc mc tiõu ra ban u:

- **Xõy dng nn tng x lý d liu ln:** xut vị trin khai thnh cõng h thng IDS trõn nn tng Apache Spark. Gii phõp nỳ tn dng kh nng tõnh tõn song song x lý cõc lung d liu mng t mũ trng IoT, hng ti kh nng m rng trong vic giõm sõt bo mt; kh nng x lý phõn tõn c kim chng mc minh chng khõì nim (proof-of-concept) trõn cm thit b biõn.
- **Ci thĩn hĩu nng phòt hin vĩ mũ hõnh hc t hp:** Phòt trin mũ hõnh Hybrid Bagging Ensemble kt hp Top-3 thut tõn cú F1 cao nht trõn tp kim nh (xõc nh chng thec nghiĩm, khõĩng c nh trc). Di quy trnh ònh giõ loi tr rừ r d liu, mũ hõnh t F1-score 0,9966 vĩ c so sõnh vĩ cõc mũ hõnh n l kõm kim nh ý ngha thng kõ khõng nh khõc bit (nu cú) lĩ òng k.
- **ònh giõ trung thec, loi tr rừ r d liu:** Nhn din vị x lý cõc ngun rừ r thng gp trõn CICIDS2017 (c trng `destination_port` rừ r nhõn vị trũng lp lung mc c trng), ng thi nh lng mc thi phng hĩu nng do rừ r giũp kt qu phn ònh ỹng nng lc thec ca mũ hõnh.
- **Ti u hĩa vị Gii thờch mũ hõnh:** ng dng k thut SHAP la chn cõc c trng quan trng nht, giũp gim s lng c trng (khõng 60%) mĩ vn gi nguyõn hĩu nng phõn loi: di cu hõnh loi tr rừ r d liu, Random Forest vĩ SHAP Top-30 t F1 0,9955, tng ng cu hõnh dũng toĩn b c trng (0,9949). ng thi, SHAP cung cp kh nng gii thờch chi tit v quyĩt nh ca mũ hõnh, tng cng tin cy vị kh nng ng dng thec t.

5.2 Hn ch ca tĩ

Mc dũ ã t c cõc kt qu nõu trõn, lun vn vn cùn mt s hn ch cn c khc phc trong cõc giai õn tip theo:

- **Phm vi phón loi:** H thng trin khai chõnh đa trõn bị toàn phón loi nh phón (Tn cũng so vì Bõnh thng); lun vn õ b sung ònh giò a lp theo tng loi tn cũng (Mc 4.2.9) phón tồch im yu cõc lp him, nhng vic xõy dng mt b phón loi a lp hoịn chnh cho trin khai thi gian thc vn lị hng phòt trin tip theo.
- **Mũ trng trin khai:** H thng c hun luyn phón tòn trõn cm Spark gm mỳy ch Mac vì hai nũt Jetson Orin Nano Super Developer Kit (8 GB), vị chõnh hai thit b nịy cng c dũng trin khai, o hìu nng thc t pha suy lun; tuy nhiõn vic kim chng trõn h tng mng IoT thc t vì hịng nghõn thit b u cui vị lu lng trc tuy n vn lị thõch thc cn thc hìn.
- **Phm vi b d liu:** Lun vn õ thit lp quy trõnh ònh giò tng quòt hóa liõn b d liu (hun luyn trõn mt b, kim tra trõn b khõc, Mc 4.2.8.1) trõn cp CICIDS2017 vị CSE-CIC-IDS2018; vic m rng sang nhìu b mĩ hn (CIC-IoT, RoEduNet) cng c kt lun v tng quòt hóa vn lị hng tip theo.
- **Quy trõnh chn mũ hõnh thịn phn cho ensemble:** Top-3 mũ hõnh thịn phn c la chn đa trõn F1-Score o trõn mt *tp kim nh (validation)* tồch riõng t tp hun luyn, nõn tp kim tra hoịn toịn khũng tham gia vộ khỏu chn mũ hõnh. ònh i ca cõch lịm nịy lị cõc mũ hõnh c s c hun luyn trõn phn d liu nh hn (sau khi trõch ra tp kim nh), vị vic xp hng c trng RF/SHAP vn c rũt t tp hun luyn gc vị gi c nh xp hng li theo tng ln lị mu li s cht ch hn nhng tn kõm hn.
- **Quy mũ d liu vị phn cng biõn:** Khõa cnh x lị phón tòn mĩ c kim chng mc minh chng khõì nim (proof-of-concept) trõn cm hai thit b Jetson (8 GB) vì khi lng d liu c vị triu lung ca CICIDS2017, ch cha phi quy mũ d liu ln thc th (terabyte tr lõn) hay trõn cm tõnh toàn nhìu nũt mnh; vic ònh giò kh nng m rng quy mũ ln hn vn lị hng tip theo.
- **Gi nh phng phòp lun:** Tp gi li (holdout) dũng kim tra n nh thc cht cũng phón phi vị tp kim tra (in-distribution), nõn vic ònh giò tng quòt hóa thc s phi đa vộ thờ nghim khõc b (cross-dataset, Mc 4.2.8.1); ngoị ra, s Hybrid Bagging (3, 2, 2) cú trng s theo F1 lị mt heuristic thiõn v cõc b hc mnh, khũng phi bagging gim phng sai kinh in.
- **Cha ònh giò trc lu lng i khõng:** H thng cha c kim th trc cõc tn cũng i khõng/nõ trõnh (adversarial/evasion) vị gi nh phón b tn cũng xp x CICIDS2017; do ú bn vng trc k tn cũng c ý ònh la mũ hõnh vn lị cõu hi m.

- **Trn recall do cng bt thng vị mc hoịi thin ca h tng:** Vic t cng phòt hin bt thng (anomaly gate) trc b phón loi to mt trn cng cho recall: còc tn cũng b cng b sút (false-negative ca cng) s b loi trc khi ti b phón loi, óy lị mt rì ro an ninh ch khũng ch lị ònh i ti; bốn cnh ú, h tng i kòm (Kafka, Grafana, PostgreSQL, InfluxDB...) hin mi mc minh chng khòì nim trong phùng lab, cha bt c ch xòc thc vị mỗ hóa.

5.3 Hng phòt trin trong tng lai

Da trổn nhng kt qu ò t c vị nhn ãin còc hn ch hin cú, lun vn xut mt s hng phòt trin trong tng lai, mi hng tng ng vị mt hn ch ò nõu:

- **Nóng cp kh nng nhn ãin a lp:** M rng mỗ hnh cú th phón loi chỉ tit còc loi tn cũng ph bin trong mng IoT nh DoS/DDoS, Botnet (Mirai), Infiltration vị Heartbleed, tin ti b phón loi a lp hoịi chnh cho trin khai thi gian thc.
- **Ci thin nhỹ cho còc lp tn cũng him:** Phón tòch hng nhm ln gia còc lp (Mc 4.2.9) cho thy còc lp him suy gim theo hai kiu: nhm loi trong cùng h (XSS b nhn thnh Brute Force) vị lt hn thnh Benign (SQL Injection, 54% Bot). Bn hng khc phc tng ng: (i) *x lý mt cón bng cú ch òch* pha hun luyñ a lp: undersampling lp Benign, oversampling/SMOTE [65] cho lp him (òp dng *sau* khi chia tp trònh rù r), hoc gp còc bin th cùng h (gp ba bin th Web Attack thnh mt lp) i mn nh danh ly recall; (ii) *iũ chnh thut toòn:* trng s lp cho bịi a lp, focal loss [66] vị XGBoost, vị h ngng quyñ nh theo lp (chp nhn thỏm false positive lp him vớ vị IDS, bõo nhm r hn b sút); (iii) *kin trũc phón tng:* tn dng chònh thit k cng hai tng ca tịi: tng nh phón trổn biỏn gi recall tng, cùn b nh danh loi hun luyñ *ch trổn còc lung tn cũng* (khũng phi cnh tranh vị 380 nghón mu Benign) vị cú th hun luyñ li ngoi tuyñ vị cón bng lp mị khũng ng h thng ang chy; (iv) *c trng chui thi gian theo host* (chu k kt ni lp, entropy kòch thc gúi qua ca s trt), nhm tr ỹng bnh ca hnh vị beaconing C&C khin 54% Bot lt li, vn khũng th hin hnh qua thng kỏ tng lung c lp.
- **Kim chng trổn b d liũ IoT chuyỏn bit:** ònh giò quy trỏnh trổn còc b d liũ cha lu lng IoT thc th (Bot-IoT, TON_IoT, CIC-IoT-2023) vị m rng thờ nghim liỏn b d liũ lỏn toịn b CSE-CIC-IDS2018, nhm thu hp khong còch gia phm vị “IoT” ca tịi vị d liũ CICIDS2017 hin ãứng.
- **Ti u suy lun biỏn bng ONNX/TensorRT:** Tòch hp phiỏn suy lun ONNX vịo pipeline streaming vị tng tc bng TensorRT trổn GPU Jetson gim chi phò JVM/Spark pha suy

lun (trong khi vn gi Spark cho hun luyn phón tòn): kt qu o ngoi tuyn Bng 4.15 cho thy cng mũ hnh rng ngu nhĩn chy qua ONNX Runtime t thũng lng gp ≈ 348 ln bn PySpark ò trin khai, xóc nhn d a rt ln ca hng nịy; ng thi o tr u cui y (t Kafka n phòn quy t ri ghi c s d liu).

- **Cng c kim nh thng kổ:** Tng s ln ly mu li N (kổm kim nh chổo lng) vị xp hng li c trng RF/SHAP theo tng ln ly mu li loi nt phn rừ r chn lc cùn sút ca vic gi c nh bng xp hng c trng.
- **bn vng trc tn cũng i khòng:** ònh giò vị gia c h thng trc lu lng nõ trnh (adversarial/evasion), c bit lị hai b mt tn cũng mi do cng bt thng to ra: gi dng lu lng bnh thng vt cng vị c ý to sai s tòi to cao dn ti lổn nũt phón loi.
- **Cng c h tng vn hnh:** Bt xóc thc vị mĩ hóa (TLS/SASL) cho Kafka, PostgreSQL, InfluxDB; b sung c ch tòi hiu chnh ngng cng bt thng theo lu lng trc tuyn; vị trin khai th nghim trổn nn tng òm mý lai nóg tnh kh dng.
- **Tòch hp hc mỳ trc tuyn (Online Learning):** Nghiỏn cu còc gii phòp cp nht tham s mũ hnh theo thi gian thc (real-time stream processing) mị khũng cn hun luyn li toịn b d liu, giũp h thng thờch ng nhanh vì còc bin th tn cũng mi vị hin tng trũi khòl nìm (concept drift) [67].

Ph 1c A. CŨNG TRŒNH ANG CHUN B CŨNG B

Phn n1y lit k1c c1c bn tho khoa hc li1n quan n 1t1 lun vn (v1t chung vi Nguy1n V Th1i, Tr1 Nh1 v1 TS. Nguy1n Vn D), hin ang c ho1n th1n gi ng:

1. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.
2. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Distributed Real-Time Intrusion Detection System on a Jetson Orin Nano Super Edge Cluster using Kafka and PySpark,” Symposium on Information and Communication Technology (SOICT), 2026.

TÌ LIU THAM KHO

- [1] Ansam Khraisat, Iqbal Gondal, Peter Vamplew, và Joarder Kamruzzaman. “Survey of intrusion detection systems: techniques, datasets and challenges”. In: *Cybersecurity 2.1* (2019), pp. 1–22.
- [2] Mohamed Amine Ferrag, Leandros Maglaras, Helge Janicke, Jianhua Jiang, và Lei Shu. “Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study”. In: *Journal of Information Security and Applications* 50 (2020), p. 102419.
- [3] R Vinayakumar, Mamoun Alazab, K P Soman, Prabaharan Poornachandran, Ameer Al-Nemrat, và Sitalakshmi Venkatraman. “Deep learning approach for intelligent intrusion detection system”. In: *IEEE Access* 7 (2019), pp. 41525–41550.
- [4] Amardeep Singh và Julian Jang-Jaccard. *Autoencoder-based Unsupervised Intrusion Detection using Multi-Scale Convolutional Recurrent Networks*. 2022. arXiv: [2204.03779](https://arxiv.org/abs/2204.03779) [cs.CR].
- [5] Pengfei Sun, Pengju Liu, Qi Li, Chenxi Liu, Xiangling Lu, Ruochen Hao, và Jinpeng Chen. “DL-IDS: Extracting features using CNN-LSTM hybrid network for intrusion detection system”. In: *Security and Communication Networks* 2020 (2020), p. 8890306. DOI: [10.1155/2020/8890306](https://doi.org/10.1155/2020/8890306).
- [6] N. Dash, S. Chakravarty, A. K. Rath, và còc cng s. “An optimized LSTM-based deep learning model for anomaly network intrusion detection”. In: *Scientific Reports* 15 (2025), p. 1554. DOI: [10.1038/s41598-025-85248-z](https://doi.org/10.1038/s41598-025-85248-z).
- [7] Sukhvinder Singh Bamber, Aditya Vardhan Reddy Katkuri, Shubham Sharma, và Mohit Angurala. “A hybrid CNN-LSTM approach for intelligent cyber intrusion detection system”. In: *Computers & Security* 148 (2024), p. 104146. DOI: [10.1016/j.cose.2024.104146](https://doi.org/10.1016/j.cose.2024.104146).
- [8] Tasnimul Hasan, Abrar Hossain, Mufakir Qamar Ansari, và Talha Hussain Syed. *Enhanced Intrusion Detection in IIoT Networks: A Lightweight Approach with Autoencoder-Based Feature Learning*. arXiv:2501.15266. 2025.
- [9] K. Baalaji và còc cng s. “Deep learning-based ensemble stacking for enhanced intrusion detection in IoT-edge platforms”. In: *Discover Applied Sciences* 7 (2025), p. 928. DOI: [10.1007/s42452-025-06871-z](https://doi.org/10.1007/s42452-025-06871-z).

- [10] Muhammad Zubair Asghar và cộng sự. “HED-ID: an edge-deployable and explainable intrusion detection system optimized via metaheuristic learning”. In: *Scientific Reports* 16 (2026), p. 2313. DOI: [10.1038/s41598-025-32183-8](https://doi.org/10.1038/s41598-025-32183-8).
- [11] İlhan Firat Kilincer, Fatih Ertam, và Abdulkadir Sengur. “Machine learning methods for cyber security intrusion detection: Datasets and comparative study”. In: *Computer Networks* 188 (2021), p. 107840. DOI: [10.1016/j.comnet.2021.107840](https://doi.org/10.1016/j.comnet.2021.107840).
- [12] M. Al Lail, A. Garcia, và S. Olivo. “Machine learning for network intrusion detection—A comparative study”. In: *Future Internet* 15.7 (2023), p. 243. DOI: [10.3390/fi15070243](https://doi.org/10.3390/fi15070243).
- [13] Yung-Chung Wang, Yi-Chun Hwang, Han-Xuan Chen, và Shu-Ming Tseng. “Network Anomaly Intrusion Detection Based on Deep Learning Approach”. In: *Sensors* 23.4 (2023), p. 2171. DOI: [10.3390/s23042171](https://doi.org/10.3390/s23042171).
- [14] L. Yang, A. Moubayed, I. Hamieh, và A. Shami. “Tree-Based Intelligent Intrusion Detection System in Internet of Vehicles”. In: *2019 IEEE Global Communications Conference (GLOBECOM)*. 2019, pp. 1–6. DOI: [10.1109/GLOBECOM38437.2019.9013892](https://doi.org/10.1109/GLOBECOM38437.2019.9013892).
- [15] L. Yang, A. Moubayed, và A. Shami. “MTH-IDS: A Multi-Tiered Hybrid Intrusion Detection System for Internet of Vehicles”. In: *IEEE Internet of Things Journal* 9.1 (2022), pp. 616–632. DOI: [10.1109/JIOT.2021.3084796](https://doi.org/10.1109/JIOT.2021.3084796).
- [16] L. Yang, A. Shami, G. Stevens, và S. DeRusett. “LCCDE: A Decision-Based Ensemble Framework for Intrusion Detection in The Internet of Vehicles”. In: *2022 IEEE Global Communications Conference (GLOBECOM)*. 2022, pp. 1–6. DOI: [10.1109/GLOBECOM48099.2022.10001280](https://doi.org/10.1109/GLOBECOM48099.2022.10001280).
- [17] R. Baidar, S. Maric, và R. Abbas. *Hybrid deep learning–federated learning powered intrusion detection system for IoT/5G advanced edge computing network*. <https://arxiv.org/abs/2509.15555>. arXiv. 2025.
- [18] B. Williams và L. Qian. “Semi-supervised learning for intrusion detection in large computer networks”. In: *Applied Sciences* 15.11 (2025), p. 5930. DOI: [10.3390/app15115930](https://doi.org/10.3390/app15115930).

- [19] N. Albanbay, Y. Tursynbek, K. Graffi, R. Uskenbayeva, Z. Kalpeyeva, Z. Abilkaiyr, và Y. Ayapov. “Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study”. In: *Journal of Sensor and Actuator Networks* 14.4 (2025), p. 78. DOI: [10.3390/jsan14040078](https://doi.org/10.3390/jsan14040078).
- [20] Thien Duc Nguyen, Samuel Marchal, Markus Miettinen, Hossein Fereidooni, N. Asokan, và Ahmad-Reza Sadeghi. “D²IoT: A Federated Self-learning Anomaly Detection System for IoT”. In: *2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS)*. 2019, pp. 756–767. DOI: [10.1109/ICDCS.2019.00080](https://doi.org/10.1109/ICDCS.2019.00080).
- [21] Lynda Boukela, Gongxuan Zhang, Mõziane Yacoub, và còc cng s. “A Near-Autonomous and Incremental Intrusion Detection System Through Active Learning of Known and Unknown Attacks”. In: *2021 International Conference on Security, Pattern Analysis, and Cybernetics (SPAC)*. 2021, pp. 374–379. DOI: [10.1109/SPAC53836.2021.9539947](https://doi.org/10.1109/SPAC53836.2021.9539947).
- [22] L. Atzori, A. Iera, và G. Morabito. “The Internet of Things: A survey”. In: *Computer Networks* 54.15 (2010), pp. 2787–2805. DOI: [10.1016/j.comnet.2010.05.010](https://doi.org/10.1016/j.comnet.2010.05.010).
- [23] Cisco. *Cisco annual Internet report (20182023)*. <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>. 2023.
- [24] R. Khan, S. U. Khan, R. Zaheer, và S. Khan. “Future Internet: The Internet of Things architecture, possible applications and key challenges”. In: *Proceedings of the 10th International Conference on Frontiers of Information Technology (FIT)*. 2012, pp. 257–260. DOI: [10.1109/FIT.2012.53](https://doi.org/10.1109/FIT.2012.53).
- [25] H. HaddadPajouh, A. Dehghantanha, R. M. Parizi, M. Aledhari, và H. Karimipour. “A survey on Internet of Things security: Requirements, challenges, and solutions”. In: *Internet of Things* 14 (2021), p. 100129. DOI: [10.1016/j.iot.2020.100129](https://doi.org/10.1016/j.iot.2020.100129).
- [26] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin, và K.-Y. Tung. “Intrusion detection system: A comprehensive review”. In: *Journal of Network and Computer Applications* 36.1 (2013), pp. 16–24. DOI: [10.1016/j.jnca.2012.09.004](https://doi.org/10.1016/j.jnca.2012.09.004).

- [27] Varun Chandola, Arindam Banerjee, và Vipin Kumar. “Anomaly detection: A survey”. In: *ACM Computing Surveys* 41.3 (2009), pp. 1–58. DOI: [10.1145/1541880.1541882](https://doi.org/10.1145/1541880.1541882).
- [28] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, và Klaus-Robert Müller. “A unifying review of deep and shallow anomaly detection”. In: *Proceedings of the IEEE* 109.5 (2021), pp. 756–795.
- [29] Manuel Lopez-Martin, Belen Carro, Antonio Sanchez-Esguevillas, và Jaime Lloret. “Conditional Variational Autoencoder for Prediction and Feature Recovery Applied to Intrusion Detection in IoT”. In: *Sensors* 17.9 (2017), p. 1967. DOI: [10.3390/s17091967](https://doi.org/10.3390/s17091967).
- [30] Khaled Alrawashdeh và Carla Purdy. “Toward an online anomaly intrusion detection system based on deep learning”. In: *Proc. 15th IEEE Int. Conf. on Machine Learning and Applications (ICMLA)*. 2016, pp. 195–200. DOI: [10.1109/ICMLA.2016.0040](https://doi.org/10.1109/ICMLA.2016.0040).
- [31] L. Husamaldin và N. Saeed. “Big Data Analytics Correlation Taxonomy”. In: *Information* 11.1 (2020), p. 17. DOI: [10.3390/info11010017](https://doi.org/10.3390/info11010017).
- [32] Matei Zaharia, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, Josh Rosen, Shivaram Venkataraman, Michael J. Franklin, Ali Ghodsi, Joseph Gonzalez, Scott Shenker, và Ion Stoica. “Apache Spark: A Unified Engine for Big Data Processing”. In: *Communications of the ACM* 59.11 (2016), pp. 56–65. DOI: [10.1145/2934664](https://doi.org/10.1145/2934664).
- [33] H. Karau, A. Konwinski, P. Wendell, và M. Zaharia. *Learning Spark: Lightning-fast big data analysis*. O’Reilly Media, 2015.
- [34] Xiangrui Meng, Joseph Bradley, Burak Yavuz, Evan Sparks, Shivaram Venkataraman, Davies Liu, Jeremy Freeman, DB Tsai, Manish Amde, Sean Owen, Doris Xin, Reynold Xin, Michael J. Franklin, Reza Zadeh, Matei Zaharia, và Ameet Talwalkar. “MLlib: Machine Learning in Apache Spark”. In: *Journal of Machine Learning Research* 17.34 (2016), pp. 1–7.
- [35] A. L. Buczak và E. Guven. “A survey of data mining and machine learning methods for cyber security intrusion detection”. In: *IEEE Communications Surveys & Tutorials* 18.2 (2016), pp. 1153–1176. DOI: [10.1109/COMST.2015.2494502](https://doi.org/10.1109/COMST.2015.2494502).

- [36] N. Koroniotis, N. Moustafa, E. Sitnikova, và B. Turnbull. “Towards the development of realistic botnet dataset in the Internet of Things for network forensic analytics: Bot-IoT dataset”. In: *Future Generation Computer Systems* 100 (2019), pp. 779–796. DOI: [10.1016/j.future.2019.05.041](https://doi.org/10.1016/j.future.2019.05.041).
- [37] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [38] Leo Breiman. “Random Forests”. In: *Machine Learning* 45.1 (2001), pp. 5–32.
- [39] D. R. Cox. “The regression analysis of binary sequences”. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 20.2 (1958), pp. 215–242.
- [40] Jerome H. Friedman. “Greedy function approximation: A gradient boosting machine”. In: *Annals of Statistics* 29.5 (2001), pp. 1189–1232.
- [41] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, và Tie-Yan Liu. “LightGBM: A highly efficient gradient boosting decision tree”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 3149–3157.
- [42] Andrew McCallum và Kamal Nigam. “A comparison of event models for naive Bayes text classification”. In: *AAAI Workshop on Learning for Text Categorization*. 1998.
- [43] Corinna Cortes và Vladimir Vapnik. “Support-vector networks”. In: *Machine learning* 20.3 (1995), pp. 273–297.
- [44] David E Rumelhart, Geoffrey E Hinton, và Ronald J Williams. “Learning representations by back-propagating errors”. In: *Nature* 323 (1986), pp. 533–536.
- [45] Tianqi Chen và Carlos Guestrin. “XGBoost: A scalable tree boosting system”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794.
- [46] Zhi-Hua Zhou. *Ensemble Methods: Foundations and Algorithms*. Chapman và Hall/CRC, 2012.
- [47] Patrik Goldschmidt và Daniela Chudò. “Network intrusion datasets: A survey, limitations, and recommendations”. In: *Computers & Security* 156 (2025), p. 104510.
- [48] Iman Sharafaldin, Arash Habibi Lashkari, và Ali A Ghorbani. “Toward generating a new intrusion detection dataset and intrusion traffic characterization”. In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*. 2018, pp. 108–116.

- [49] Canadian Institute for Cybersecurity and Communications Security Establishment. *CSE-CIC-IDS2018 dataset: A collaborative project between the Communications Security Establishment (CSE) and the Canadian Institute for Cybersecurity (CIC)*. <https://www.unb.ca/cic/datasets/ids-2018.html>. 2018.
- [50] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, và Konrad Rieck. “Dos and Don’ts of Machine Learning in Computer Security”. In: *31st USENIX Security Symposium (USENIX Security 22)*. 2022, pp. 3971–3988.
- [51] Maxime Lanvin, Pierre-François Gimenez, Yufei Han, Frédéric Majorczyk, Ludovic Mũ, và Õric Totel. “Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes”. In: *Risks and Security of Internet and Systems (CRiSIS 2022), Revised Selected Papers*. Springer, 2023, pp. 18–33. DOI: [10.1007/978-3-031-31108-6_2](https://doi.org/10.1007/978-3-031-31108-6_2).
- [52] Isabelle Guyon và Andrõ Elisseeff. “An introduction to variable and feature selection”. In: *Journal of Machine Learning Research* 3 (2003), pp. 1157–1182.
- [53] Ian T. Jolliffe. *Principal Component Analysis*. 2nd ed. Springer Series in Statistics. Springer, 2002. DOI: [10.1007/b98835](https://doi.org/10.1007/b98835).
- [54] Scott M. Lundberg và Su-In Lee. “A Unified Approach to Interpreting Model Predictions”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017, pp. 4765–4774.
- [55] Gints Engelen, Vera Rimmer, và Wouter Joosen. “Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study”. In: *2021 IEEE Security and Privacy Workshops (SPW)*. 2021, pp. 7–12. DOI: [10.1109/SPW53761.2021.00009](https://doi.org/10.1109/SPW53761.2021.00009).
- [56] Claude Nadeau và Yoshua Bengio. “Inference for the Generalization Error”. In: *Machine Learning* 52.3 (2003), pp. 239–281.
- [57] Laurens D’hooge, Tim Wauters, Bruno Volckaert, và Filip De Turck. “Inter-dataset generalization strength of supervised machine learning methods for intrusion detection”. In: *Journal of Information Security and Applications* 54 (2020), p. 102564.
- [58] Marta Cantone, Claudio Marrocco, và Alessandro Bria. “Machine Learning in Network Intrusion Detection: A Cross-Dataset Generalization Study”. In: *IEEE Access* 12 (2024).

- [59] Mohanad Sarhan, Siamak Layeghy, và Marius Portmann. “Evaluating standard feature sets towards increased generalisability and explainability of ML-based network intrusion detection”. In: *Big Data Research* 30 (2022), p. 100359. DOI: [10.1016/j.bdr.2022.100359](https://doi.org/10.1016/j.bdr.2022.100359).
- [60] NVIDIA Corporation. *Jetson Orin Nano Super Developer Kit*. <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-orin/nano-super-developer-kit/>. 2024.
- [61] Weisong Shi, Jie Cao, Quan Zhang, Youhuizi Li, và Lanyu Xu. “Edge computing: Vision and challenges”. In: *IEEE Internet of Things Journal* 3.5 (2016), pp. 637–646. DOI: [10.1109/JIOT.2016.2579198](https://doi.org/10.1109/JIOT.2016.2579198).
- [62] Salam Hamdan, Moussa Ayyash, và Sufyan Almajali. “Edge-Computing Architectures for Internet of Things Applications: A Survey”. In: *Sensors* 20.22 (2020), p. 6441. DOI: [10.3390/s20226441](https://doi.org/10.3390/s20226441).
- [63] Alessandro Sforzin, F lix G mez M rmol, Mauro Conti, và Jens-Matthias Bohli. “RPiDS: Raspberry Pi IDS — A Fruitful Intrusion Detection System for IoT”. In: *Proc. Int. IEEE Conf. on Ubiquitous Intelligence & Computing (UIC/ATC/ScalCom)*. 2016, pp. 440–448. DOI: [10.1109/UIC-ATC-ScalCom-CBDCoM-IoP-SmartWorld.2016.0080](https://doi.org/10.1109/UIC-ATC-ScalCom-CBDCoM-IoP-SmartWorld.2016.0080).
- [64] Jay Kreps, Neha Narkhede, và Jun Rao. “Kafka: a Distributed Messaging System for Log Processing”. In: *Proceedings of the NetDB Workshop*. 2011.
- [65] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, và W. Philip Kegelmeyer. “SMOTE: Synthetic Minority Over-sampling Technique”. In: *Journal of Artificial Intelligence Research* 16 (2002), pp. 321–357.
- [66] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, và Piotr Doll r. “Focal Loss for Dense Object Detection”. In: *IEEE International Conference on Computer Vision (ICCV)*. 2017, pp. 2980–2988.
- [67] Jo o Gama, Andr  liobait, Albert Bifet, Mykola Pechenizkiy, và Abdelhamid Bouchachia. “A survey on concept drift adaptation”. In: *ACM Computing Surveys* 46.4 (2014), pp. 1–37.