

I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC CŨNG NGH THŨNG TIN
KHOA KHOA HC VỊ K THUT MỖY TỒNH



BŨI VN DNG

LUN VN THC S

PHÒT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO
MT MNG IoT

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THC S NGỊNH CŨNG NGH THŨNG TIN

TP. H CHỜ MINH, 2026

**I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC CŨNG NGH THŨNG TIN
KHOA KHOA HC VỊ K THUT MỖY TỜNH**



BÚI VN DNG 220201014

LUN VN THC S

**PHỜT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO
MT MNG IoT**

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THC S NGHỊNH CŨNG NGH THŨNG TIN

GING VIỎN HNG DN

TS. NGUYN VN D

TS. TRỜ NHT

TP. H CHỜ MINH, 2026

THŨNG TIN HI NG BO V LUN VN THC S

Hi ng chm lun vn thc s, thnh lp theo Quy t nh s ngiy ca Hiu
trng Trng i hc Cũg ngh Thũg tin.

1. Ch tch:

2. Th kỳ:

3. y viõn:

LI CM N

Li u tiển, tui xin gi li cm n chón thịnh n quỳ thy cũ ca Trng i hc Cũng Ngh Thũng Tin, i hc Quc gia Thịnh Ph H Chờ Minh ã tn tơnh ch dy, giúp tui tip thu c nhieu kin thc quỳ bàu trong sut thi gian hc tp ti trng, cng nh to iu kin thun li cho tui thc hin lun vn nỳ. Kờnh chũc thy cũ luũn đi dọ sc kho vị gt hời c nhieu thịnh cũng trong tng lai.

c bit, tui xin chón thịnh cm n thy TS. Nguyn Vn D vị TS. Trờ Nht ã tn tơnh giúp , hng dn, cung cp cho tui nhng kin thc, k nng cn thit thc hin nghiỏn cu vị hoịn thịnh tị nỳ.

Mc dũ ã c gng trong quò trnh nghiỏn cu, nhng do kin thc cùn hn ch nỏn lun vn vn cùn nhieu thiu sút. Vớ vy, tui rt mong nhn c s úng gúp ý kin ca Quỳ Thy Cũ tị ca tui c hoịn thìn hn.

Tui xin chón thịnh cm n!

Búi Vn Dng

TÓM TẮT

Sự phát triển nhanh chóng của Internet of Things (IoT) đã mang lại nhiều tin tức trong các lĩnh vực như nông nghiệp, công nghiệp, y tế và giao thông. Tuy nhiên, cũng vì sự phát triển này lại nảy sinh nguy cơ an ninh gia tăng và các mối đe dọa an ninh mạng, đặc biệt là khi các thiết bị IoT thường có mặt tại nguồn tấn công toàn diện và bảo mật kém. Trong bối cảnh này, Intrusion Detection Systems (IDS) cần xem lại một giải pháp quan trọng nhằm phát hiện và ngăn chặn các hình thức tấn công bất thường vào hệ thống mạng IoT.

Lưu ý rằng việc tập trung nghiên cứu, thiết kế và triển khai một hệ thống IDS dựa trên nền tảng xử lý dữ liệu lớn Apache Spark. Spark có khả năng xử lý dữ liệu phân tán, tốc độ cao và hiệu quả xử lý toàn bộ dữ liệu thông qua thư viện MLlib. Hệ thống có ý định nhằm phát hiện các hình thức xâm nhập trong dữ liệu mạng IoT thông qua việc ứng dụng các mô hình học máy truyền thống, các mô hình học tập và các mô hình học sâu MLP (cũng như autoencoder đóng vai trò trong phát hiện bất thường - tấn công biến đổi).

Trong quá trình thực hiện, lưu ý rằng tin hình phân tích các dữ liệu mạng IoT, là chọn vị trí xử lý dữ liệu và vị trí các tập dữ liệu cũng khai thác CICIDS2017, sau đó tin hình huấn luyện mô hình, đánh giá hiệu quả hệ thống theo các chỉ số chính xác (Accuracy), precision, recall và F1-score, đồng thời ghi lại thời gian huấn luyện và kích thước mô hình. Quá trình đánh giá tập dữ liệu quy trình loại bỏ dữ liệu (loại các trường dữ liệu nhiễu, loại bỏ trùng lặp các trường) nhằm bảo mật quá trình đánh giá và loại bỏ mô hình. Bên cạnh đó, hệ thống cũng kiểm tra hiệu năng trong mỗi trường xử lý phân tán (proof-of-concept trên các thiết bị biến đổi) nhằm khảo sát khả năng mở rộng và triển khai thực tiễn.

Để cụ thể hơn về hiệu quả loại bỏ dữ liệu, là chọn các trường SHAP Top-30 để đánh giá hiệu năng của mô hình học máy trong khi giảm khoảng 60% số các trường: Random Forest đạt F1 0,9955 và mô hình học tập Hybrid Bagging đạt F1 0,9966 trên CICIDS2017; các khối bit gia tăng phép kiểm tra bằng kiểm tra hoàn toàn và ghép cặp vị trí không tin cậy hiệu chỉnh Nadeau–Bengio. Trên các thiết bị Jetson Orin Nano Super, kiến trúc tích hợp pipeline (các phát hiện bất thường + bộ phân loại PySpark) nóng thông qua phần quyết định 2,6 lần 62,5 lần/giây (gấp ≈ 24 lần) và thời gian xử lý trung bình 13 ms, trong đó cũng đạt 95,8% lưu lượng băng thông trước khi gửi suy luận Spark. Khả năng xử lý phân tán cũng kiểm tra bằng cách minh chứng khả năng (proof-of-concept) trên các thiết bị biến đổi, thay vì không như quy mô dữ liệu lớn thực tế. Lưu ý rằng chúng tôi giúp phần việc xây dựng quy trình phát hiện xâm nhập theo thời gian thực mà còn mở ra các hướng nghiên cứu tìm kiếm trong việc kết hợp học máy và các nền tảng xử lý dữ liệu lớn phục vụ bảo mật hệ thống IoT.

MC LC

Thông tin hi ng bo v lun vn	i
Li cm n	ii
Tóm tt	iii
Mc lc	iv
Danh mc còc bng	vii
Danh mc còc hnh v vị th	ix
Danh mc t vit tt	xi
Chng 1. M u	1
1.1 Lý do chn tị	1
1.2 Còc nghiõn cu liõn quan	1
1.3 Mc tiõu, i tng vị phm vi nghiõn cu	3
1.3.1 Mc tiõu nghiõn cu	3
1.3.2 i tng nghiõn cu	4
1.3.3 Phm vi nghiõn cu	4
1.3.4 Còu hi nghiõn cu	5
1.4 Phng phòp nghiõn cu	6
1.5 Còc úng gúp chõnh ca tị	6
1.6 Cũng trõnh ang chun b cũng b	7
1.7 Cu trũc ca lun vn	7
Chng 2. C s lý thuyt	9
2.1 Tng quan v IoT	9
2.2 H thng phòt hìn xóm nhp (IDS)	9
2.3 Apache Spark vị x lý d liu ln	10
2.3.1 D liu ln	10
2.3.2 Còc thnh phn ca Apache Spark	11
2.3.3 Kin trũc ca Apache Spark	13

2.4	Học mờ trong phân hình xấp xỉ	13
2.4.1	Một số thuật toán học mờ	14
2.4.2	Một số thuật toán học tập	18
Chương 3.	Phương pháp phân hình	21
3.1	Thu thập dữ liệu vị trí	21
3.2	Lựa chọn các trạng vị trí để phân hình	25
3.3	Học phân hình mờ	27
3.3.1	Học phân hình mờ các	27
3.3.2	Các phương pháp Ensemble Learning	28
a)	Ôp phân hình Voting	28
b)	Ôp phân hình Bagging	30
3.4	Đánh giá phân hình mờ	32
3.5	Tích hợp tham số vào học phân hình mờ	34
3.6	Trình bày	36
Chương 4.	Thực nghiệm, đánh giá vị trí	37
4.1	Môi trường thực nghiệm	37
4.2	Kiểm tra thực nghiệm	39
4.2.1	Kịch bản 1: Đánh giá hiệu năng cơ sở (Baseline)	40
4.2.2	Kịch bản 2: So sánh chín loại phân hình mờ	40
4.2.3	Kịch bản 3: Tích hợp tham số	41
4.2.4	Phân tích khả năng giải thích với SHapley Additive exPlanations (SHAP)	42
4.2.5	Phân tích rò rỉ dữ liệu (data leakage)	43
4.2.6	Phân tích hiệu năng hệ thống	44
4.2.7	Kim nghiệm nghĩa thống kê	44
4.2.8	Kim tra nghiệm trong-phân-phi	45
4.2.8.1	Tổng quát hóa liên biến dữ liệu	46
4.2.9	Đánh giá lặp theo lợi ích	47
4.3	Thực nghiệm vị trí đánh giá hiệu năng phân hình mờ trên Jetson Orin Nano Super	51
4.3.1	Các cũng cố sử dụng trong hệ thống	51
4.3.2	Mô hình hệ thống xuất	53
4.3.3	Lựa chọn mô hình cho thiết bị	55
4.3.4	Kiểm tra học phân hình mờ các mô hình ng viển trên cm Spark	59

4.3.5	Kt qu o hieu nng (benchmark) trồn Jetson Orin Nano Super	60
4.3.6	So sòn engine suy lun: chi phờ ca vic ng nht stack	60
4.3.7	Kt qu ba ch trin khai phón tòn	61
4.3.8	Phón tồch vị la chn mũ hnh	63
4.4	Tho lun vị So sòn tng hp	64
Chng 5.	Kt lun vị hng phòt trin	65
5.1	Nhng úng gúp chờnh ca lun vn	65
5.2	Hn ch ca tị	65
5.3	Hng phòt trin trong tng lai	66
Ph lc A.	Cũng trnh ang chun b cũng b	68
	Tị liu tham kho	76

DANH MỤC CỜC BNG

3.1	Mũ t b d liu CICIDS2017	22
3.2	Mũ t b d liu CSE-CIC-IDS2018 (dững cho thờ nghim liễn b d liu)	22
3.3	Tòm b phón loi c s c s dng trong pipeline	27
3.4	Cờc phng phòp hc t hp (ensemble) s dng trong lun vn	28
3.5	Cờc tiũu chờ ònh giò mũ hnh	32
3.6	Ma trn nhm ln ca mũ hnh phòt hin xóm nhp	33
3.7	Thũng s phn cng thit b biễn	36
4.1	Tham s ti u ca cõc mũ hnh hc mỳy	39
4.2	Kt qu hiu nng phón lp kch bn Baseline (toịn b c trng s, ≈ 78 trc khi loi cng) .	40
4.3	So sòn hiu nng tt nht ca cõc phng phòp la chn c trng vị gim chiu	41
4.4	So sòn hiu nng la chn c trng: Random Forest (RF) Importance vs SHapley Additive exPlanations (SHAP) Importance (Top-30)	41
4.5	Kt qu hiu nng phón lp kch bn Ti u hóa tham s	42
4.6	Phón tồch loi b (ablation) rừ r c trng cng òch	43
4.7	So sòn thi gian x lý vị kờch thc mũ hnh kch bn Baseline	44
4.8	n nh qua nhieu ln ly mu vị kim nh gộp cp (t statistical_valid- ity_multiseed.csv)	45
4.9	Kim tra n nh trong-phón-phi trổn mu con tp kim tra (t robustness_- holdout_summary.csv)	45
4.10	Tng quòt hóa liễn b d liu gia CICIDS2017 vị CSE-CIC-IDS2018 (CSE- CIC-IDS2018: mu phón tng seed=42; t cross_dataset_results.csv) 46	
4.11	Hiu nng theo tng lp tn cũg (t per_class_metrics.csv)	48
4.12	im vn hnh ca cng bt thng khi quỏt quantile trổn tp kim nh benign (10% benign train, seed=42; t gate_operating_points.csv). FPR óy lị t l lung benign b cng chuyn nhm sang b phón loi, khũng phi FPR ca toịn h thng.	55
4.13	Kt qu hun luy cõc mũ hnh ng viỗn cho trin khai biễn (SHAP Top-30) . .	59
4.14	So sòn hiu nng trin khai trổn Jetson Orin Nano Super	60

4.15	Chi phờ suy lun mt nũt trồn cụng mũ hnh/c trng (Spark vs sklearn vs ONNX), o trồn nũt phón loi trong cụng iu kin bo mch (batch 10; nng lng lị phn <i>hot ng</i> , ã tr <i>idle</i>)	61
4.16	So sòn ba ch trìn khai phón tòn trồn cm 2 Jetson Orin Nano Super	61

DANH MỤC CỜ HÌNH VÀ VỊ TH

2.1	Mũ hình 5V ca d liu ln	11
2.2	Cờ thịnh phn ca Apache Spark	12
2.3	S kin trúc h thng Apache Spark	13
3.1	Quy trình tng th hun luy, ònh giò vị trin khai mũ hình xut	21
3.2	S phón chia d liu CICIDS2017. Sau tin x lý vị loi tr rù r (Thut toàn 4), d liu c chia 80/20 thịnh train/test (<code>seed=42</code>); tp test c gì li, ch đứng cũng b kt qu cui. StandardScaler, PCA vị vic xp hng c trng (RF/SHAP) c <i>fit</i> trở toin b tp train ri gì c nh. Riống chn Top-3 mũ hình thịnh phn vị cp phng phòp a vò kim nh, tp train c tòch tip 80/20 thịnh base-train (hun luy mũ hình c s) vị validation (chm im chn lc); ngng cng bt thng c chn trở 10% lu lng benign ca tp train (<code>seed=42</code>). Tp test khng tham gia bt k khóu la chn nio.	25
4.1	Cm hun luy phón tồn Apache Spark Standalone: MacBook gì vai trò <i>master</i> iu phi (khng chy executor), hai Jetson Orin Nano Super lị <i>worker/executor</i> the thi tồn toàn; d liu Parquet c phón vng vị ng b sang c hai nũt, kt qu c gom v qua shuffle/collect.	38
4.2	Top 30 c trng quan trng theo giò tr trung bnh tuyt i SHAP ca mũ hình XGBoost (XGB)	49
4.3	Biu SHAP Summary (beeswarm): phón b vị hng tòc ng ca tng c trng	50
4.4	Ma trn nhm ln a lp theo loi tn cũng (chun hóa theo hng)	50
4.5	Kin trúc h thng phòt hin xóm nhp phón tồn thi gian the trở cm 2 Jetson Orin Nano Super	53
4.6	Giao din terminal khi pipeline IDS hot ng trở hai node Jetson Orin Nano Super: (a) node cng lc bt thng vị (b) node phón loi PySpark	56
4.7	Dashboard Grafana giòm sòt hieu nng IDS theo thi gian the	57
4.8	Email cnh bào tn cũng c gì qua Mailtrap trong mũi trng kim th (nh chp t giai on th nghim sm ca h thng; mũ-un cnh bào vị nh dng thng ip gì nguỷn khi trin khai trở cm Jetson)	57
4.9	Dashboard Grafana hin th chi tit còc cuc tn cũng c phòt hin vị phón loi theo thi gian	58

4.10	Dashboard Grafana ti thi im ti nh ca ch tòch pipeline: nũt cng (jetson-nano-1) ch s dng khong 5 % CPU trong khi nũt phón loi PySpark (jetson-nano-2) t ti 91 %	58
4.11	Thũng bõo cnh bõo tn cũng c gi qua Slack Incoming Webhook (nh chp t giai on th nghi m; nh dng thũng ip gi nguỷn khi trin khai trõn cm Jetson)	59
4.12	Thũng lng vị tr p95 ca bn cu hnh (mt nũt c s + ba ch phón tòn) trõn cm 2 Jetson	62
4.13	So sòn hiu nng ba mũ hnh trõn Jetson Orin Nano Super	63
4.14	Biu radar th hin s ònh i (trade-off) gia cõc mũ hnh trõn thit b biõn	64

DANH MỤC T VIẾT TẮT

AC	accuracy
BD	Big Data
CNN	Convolutional Neural Network
CV	Cross-Validation
DT	Decision Trees
EL	Ensemble Learning
FS	F1-score
GBT	Gradient Boosted Trees
GS	Grid Search
IDS	Intrusion Detection Systems
IoT	Internet of Things
kNN	k-Nearest Neighbors
LGBM	LightGBM
LR	Logistic Regression
LSTM	Long Short-Term Memory
ML	Machine Learning
MLP	Multilayer Perceptron
NB	Naive Bayes
PCA	Principal Component Analysis
PR	precision
RE	recall
RF	Random Forest
RFI	Random Forest Importance
RNN	Recurrent Neural Network
SCP	Secure Copy Protocol
SHAP	SHapley Additive exPlanations
SVM	Support Vector Machine
XGB	XGBoost

Chng 1. M U

1.1 Lý do chn tii

Trong k nguyên ca Còch mng Cũg nghip 4.0, IoT ang phòt trin nhanh vị c ng dng rng ròi trong nhieu lnh vc nh nhậ thũg minh, y t, giao thũg, cũg nghip thũg minh,... S bứg n v s lng thit b IoT dn n s gia tng òng k v lu lng vị loi hnh d liu truyn trong mng. Tuy nhiên, còc thit b IoT thng cú kh nng x lý hn ch vị thi u còc c ch bo mt mn, khin chũg tr thnh mc tiòu d b tn cũg bi tin tc.

i phú vì còc mi e đa an ninh mng, còc h thng phòt hin xóm nhp (IDS) ang c nghiỏn cu vị phòt trin rng ròi. c bit, trong nhng nm gn óy, vic kt hp hc mỳ (Machine Learning (ML)) vị còc nn tng x lý d liu ln giúp h thng nóng cao chònh xòc phòt hin vị thờch nghi tt hn vì mủi trng mng thay i liỏn tc. Cn lu ý rng b phón loi chònh trong lun vn lý mủ hnh hc cú giòm sòt trỏn CICIDS2017 nỏn ch phòt hin c còc h tn cũg ò bit; kh nng phòt hin hnh vị bt thng cha tng thy (nu cú) n t cng phòt hin bt thng (anomaly gate) hc khũg giòm sòt, ch khũg phi t b phón loi. Tuy nhiên, phn ln còc nghiỏn cu hin nay tp trung vớo vic xóy dng mủ hnh hc mỳ trỏn tp d liu tnh, dung lng nh vị hun luyt ngoi tuyn (offline).

Trong khi ú, mng IoT hin i sinh ra lng d liu rt ln, liỏn tc theo thi gian thc ùi hi còc h thng IDS cú kh nng x lý d liu ln (Big Data (BD)) hieu qu, cú th hot ng trong mủi trng phón tòn vị thi gian thc.

Apache Spark lị mt nn tng x lý d liu ln, vị kh nng x lý song song, phón tòn vị d dng tòch hp vị th vin hc mỳ Spark MLlib. óy lị mt gii phỏp tim nng xóy dng h thng IDS hin i òp ng yỏu cu v quy mủ vị thi gian thc trong mủi trng IoT.

1.2 Còc nghiỏn cu liỏn quan

Trong nhng nm gn óy, còc h thng phòt hin xóm nhp (Intrusion Detection System – IDS) đa trỏn hc mỳ vị hc sỏu ò thu hũt nhieu s quan tótm ca cng ng nghiỏn cu nhm nóng cao chònh xòc vị kh nng thờch ng trc còc hnh thc tn cũg mng ngậ cặg tnh vị [1, 2, 3]. Nhieu cũg trớnh tp trung khai thờc còc kin trức hc sỏu nh autoencoder, mng tòch chp (Convolutional Neural Network (CNN)) vị mng n-ron hi quy (Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM)) t ng trỏch xut c trng vị phòt hin bt thng trong lu lng mng. Tuy nhiên, phn ln còc nghiỏn cu hin nay vn c trin khai trong mủi trng n mỳ, x lý d liu tnh vị quy mủ tng i nh, vị cha tòch hp còc nn tng x lý d liu ln nh Apache Spark hay Hadoop

nhm òp ng yểu cu v kh nng m rng vị x lý thi gian thc trong còc h thng mng hin i.

Mt s nghiỏn cu ò xut còc mũ hnh IDS hc sỏu da trỏn còc kin trũc nh autoencoder, CNN vị LSTM nhm nỏng cao kh nng hc c trng vị phòt hin xỏm nhp mng. Còc mũ hnh nỳ c ònh giò trỏn còc tp d liu chun nh NSL-KDD, CIC-DDoS2019 vị CICIDS2017, cho thy hieu qu cao trong vic phòt hin bt thng. Tuy nhiỏn, quò trỏnh hun luy n vị ònh giò vn ch yu c thc hin trong mũ trng cc b vị theo c ch x lý theo lũ (batch) [4, 5]. Tng t, còc mũ hnh lai da trỏn LSTM (chng hn CNN-LSTM, hay LSTM c ti u húa siỏu tham s) cho bỳ toỏn phòt hin bt thng trong mng cng t c kt qu kh quan, nhng vn trin khai trỏn nn tng n nũt (single-node) vị cha khai thỏc c kh nng m rng ca còc h thng Big Data [6, 7]. Gn óy, mt s nghiỏn cu ò trin khai IDS hc mỳy trc tip trỏn phn cng biỏn NVIDIA Jetson [8, 9], hay trỏn mũ trng biỏn mũ phng rỳng buc tỳ nguyỏn [10]. Xu hng nỳ tip tc c m rng trong còc cũng trỏnh mi nh: mũ hnh sinh (generative) c chy trc tip trỏn Jetson Orin Nano va phỏn loi lu lng va sinh d liu hun luy n tng hp [11], còc mũ hnh rũt gn c thit k riỏng cho lu lng iu khin cũng nghip [12], vị nng lng tiỏu th trỏn mi ln suy lun bt u c xem lỳ mt ch s ònh giò hng nh t bốn cnh chỏnh xỏc [13]. Tuy vy, im chung ca còc nghiỏn cu nỳ lỳ vn dng quy mũ *n nũt*: b phòt hin c o trỏn mt bo mch duy nh t, nỏn cớu hi phỏn b ti suy lun trỏn nhieu nũt biỏn vị li òch thc t ca vic b sung nũt th hai vn cùn b ng. hng ngc lỳ, vic gỏp Kafka vị Spark phòt hin xỏm nhp phỏn tòn ò c nghiỏn cu [14], nhng ch yu trỏn h tng mỳy ch vị him khi cũng b vt tỳ nguyỏn (CPU, b nh, nng lng) theo tng nũt trỏn phn cng rỳng buc.

Bốn cnh còc phng phỏp hc sỏu, còc k thut hc mỳy truy n thng nh Support Vector Machine (Support Vector Machine (SVM)), k-Nearest Neighbors (k-Nearest Neighbors (kNN)) vị Decision Tree vn c s dng rng riỏ trong còc h thng IDS. Mt s nghiỏn cu ò tin hnh so sỏnh hieu nng ca còc mũ hnh nỳ trỏn còc b d liu ph bin nh NSL-KDD vị UNSW-NB15, qua ú ch ra rng còc phng phỏp hc mỳy truy n thng cú tim nng ng dng thc tin cao. Tuy nhiỏn, còc mũ hnh nỳ ch yu hot ng ch offline, x lý d liu theo tng t vị cha òp ng c yểu cu v x lý d liu liỏn tc trong mũ trng mng ng [15]. Ngoỳ ra, mt s cũng trỏnh so sỏnh nhieu mũ hnh hc mỳy vị hc sỏu cho IDS, ghi nhn còc mũ hnh da trỏn cớ nh Random Forest cho kt qu tt trỏn còc b d liu ln, nhng toỏn b thc nghim vn c thc hin trỏn mt mỳy n [16].

Ngoỳ còc kin trũc nũ trỏn, nhieu mũ hnh hc sỏu khỏc nh CNN, RNN vị còc mũ hnh lai CNN-LSTM cng ò c nghiỏn cu vị ònh giò cho bỳ toỏn phòt hin xỏm nhp mng. Còc nghiỏn cu nỳ cho thy kh nng ci thìn òng k chỏnh xỏc so vị còc phng phỏp truy n thng khi th nghim trỏn còc b d liu nh CICIDS2018. Tuy nhiỏn, phn ln còc mũ hnh vn thiu kh nng trin khai trong mũ trng thi gian thc vị cha tn dng c sc mnh ca còc nn tng x lý d liu ln [17].

Trong bi cnh Internet of Vehicles (IoV), mt s nghiõn cu õ xut còc h thng IDS da trõn hc mỳy v i hc sỏu nhm bo v còc mng phng tin thũng minh. Còc phng phỏp nỳy bao gm vic s dng còc mũ hỡnh da trõn cớy (tree-based), còc h thng phỏt hin xỏm nhp a tng, cng nh còc mũ hỡnh ensemble ci thfin chỏnh xỏc phỏt hin tn cũng. Mc dũ t c kt qu kh quan trõn còc b d liu th nghiõm, còc h thng nỳy vn ch yu c hun luyn v i ờnh giỏ trong mũ trng ngoi tuyn, x lý d liu theo batch v i cha tồch hp còc nn tng x lý d liu ln hoc c ch x lý d liu theo lung [18, 19, 20].

Bỏn cnh ú, mt s hng tip cn gn óy õ nghiõn cu vic ỏp dng hc bòn giỏm sỏt, hc liỏn kt (federated learning) v i hc tng dn (incremental/active learning) cho bựi toỏn IDS nhm nỏng cao kh nng thờch ng ca mũ hỡnh v i bo v quyn riỏng t d liu. Còc phng phỏp nỳy cho phỏp phỏn tòn quỏ trỏnh hun luyn trõn nhiu nũt hoc thit b IoT khỏc nhau; mt kho sỏt h thng gn óy õ tng hp toỏn cnh hng nghiõn cu IDS da trõn hc liỏn kt [21]. Tuy nhiỏn, cn lu ý rng vic phỏn tòn óy đin ra trong pha *hun luyn*, cũn suy lun vn thc hin cc b trõn tng nũt; ngoi ra d liu vn ch yu c x lý theo tng t, thiu c ch x lý lung tỳ trung v i cha khai thờc y kh nng m rng cng nh song song húa ca còc nn tng Big Data [22, 23, 24, 25, 26].

T tng quan còc cũng trỏnh nghiõn cu nỏu trõn, cú th nhn thy rng phn ln còc h thng IDS hin ti vn hot ng trong mũ trng ngoi tuyn, cha h tr x lý d liu liỏn tc theo thi gian thc v i cha tn dng c kh nng m rng ca còc nn tng x lý d liu ln. Do ú, lun vn nỳy hng n vic tồch hp còc mũ hỡnh hc mỳy da trõn nn tng Apache Spark nhm xỏy dng mt h thng phỏt hin xỏm nhp cú kh nng x lý d liu ln, h tr thi gian thc v i ỏp dng hieu qu trong mũ trng mng IoT hin i.

1.3 Mc tiỏu, i tng v i phm vi nghiõn cu

1.3.1 Mc tiỏu nghiõn cu

Mc tiỏu ca tỳi PHỎT HIN XỎM NHP (IDS) DA TRỎN APACHE SPARK CHO BO MT MNG IoT l i xỏy dng mt h thng phỏt hin xỏm nhp cú kh nng phỏn tồch v i phỏt hin còc hỡnh vi bt thng hoc tn cũng mng trong mũ trng IoT bng còch kt hp còc mũ hỡnh hc mỳy v i nn tng x lý d liu ln Apache Spark nhm t c:

- Phỏt hin hieu qu còc dng tn cũng mng ph bin (nh DoS, probing, brute-force) trõn còc tỳ d liu hin i nh CICIDS2017.
- Thit k v i trin khai pipeline x lý d liu phỏn tòn v i song song s dng Apache Spark, bao gm còc bc: tin x lý d liu, trỏch xut c trng, hun luyn mũ hỡnh v i phỏt hin thi gian thc.

- Kho sòt hieu nng h thng, hng ti kh nng m rng, tr thp vị tòngh linh hot; kim chng kh nng x lý phón tòn mc minh chng khôi nim (proof-of-concept) trón cm thit b biõn, lìm tin cho vic trin khai trón còc h thng ln hoc mng IoT nhieu thit b.
- So sòngh vị ònh giò còc mũ hõnh hc mỳ ph bin nh Decision Tree, Support Vector Machine, Logistic Regression, Naive Bayes (NB), Random Forest, Gradient Boosted Trees (GBT), XGBoost (XGB), Multilayer Perceptron (MLP) vị còc thut toòn hc t hp (ensemble) trong mũ trng x lý phón tòn, t ú chn ra mũ hõnh phứ hp nht.
- Òp dng quy trõnh ònh giò cht ch, loi tr rừ r d liu (loi c trng rừ r nhõn, loi b trúng lp mc c trng, kim nh ý ngha thng kổ) nhm m bo kt qu phn ònh ỹng nng lc mũ hõnh.
- xut gii phòp thc tin giũp phòt hin tn cũng nhanh chũng vị chõnh xòc trong còc h thng mng hin i cú yõu cu x lý d liu ln vị liõn tc.

1.3.2 i tng nghiõn cu

tị nịy tp trung nghiõn cu vị trin khai phng phòp phòt hin xóm nhp trong lnh vc bo mt mng IoT bng còch tn dng sc mngh ca nn tng x lý d liu ln Apache Spark. Vì s phòt trin nhanh chũng ca còc thit b IoT, vn m bo an toịn vị bo mt cho h thng ngiy cịng tr nõn cp thit, c bit lị trong vic phòt hin còc hình vi bt thng hoc tn cũng mng tìm n.

Apache Spark, vị kh nng x lý d liu phón tòn vị tc tòngh toòn cao, cho phỏp x lý khi lng ln d liu sinh ra t còc thit b IoT trong thi gian thc. Trong khuõn kh nghiõn cu nịy, lun vn s dng còc tòngh nng ca Spark nh x lý lung d liu (streaming), hc mỳ phón tòn (MLlib) vị phón tồch d liu quy mũ ln xóy dng mũ hõnh phòt hin xóm nhp hieu qu. Qua ú, tị khũng ch xut mt gii phòp k thut cú tòngh ng dng cao mị cùn gúp phn nõng cao hieu qu bo mt cho còc h thng IoT trong thc tin.

1.3.3 Phm vi nghiõn cu

tị tp trung vọ vic nghiõn cu vị òp dng còc k thut phón tồch d liu ln nhm phòt hin xóm nhp trong h thng mng IoT vì mc òch lị khai thỏc nhng im mngh ca nn tng Apache Spark x lý vị phón tồch d liu hieu qu. C th, phm vi nghiõn cu bao gm:

- **D liu u vọ:** D liu c s dng lị tp d liu cũng khai CICIDS2017.
- **Cũng ngh s dng:** S dng Apache Spark lìm nn tng x lý d liu ln, c bit tp trung vọ còc thịngh phn nh Spark Core, Spark SQL, Spark Streaming vị Spark MLlib h tr tin x lý

d liu, hun luyn mĩ hnh hc mỳ v phòt hìn xóm nhp theo thi gian thc.

- **Phng phòp phòt hìn xóm nhp:** Òp dng còc thut toòn hc mỳ c trin khai v tĩ u hóa trong mĩ trng Spark m bo kh nng m rng v hũu nng cao.
- **Mĩ trng trin khai:** Th nghim h thng trỏn mt mĩ trng gĩ lp mng IoT v b d liu mĩ phng cũg khai (CICIDS2017) nhm ònh giò kh nng phòt hìn xóm nhp.

Lu ý v phm vi d liu. Cn nhn mn nh rng CICIDS2017 lĩ b d liu lu lng mng doanh nghip mĩ phng, khũng cha lu lng c thứ IoT (vở d còc giao thc MQTT, CoAP) hay thĩt b IoT thc. Tỏnh cht “IoT” ca tĩ do ú nm *keh bn trin khai*: toĩn b pipeline suy lun c thĩt k, tĩ u vĩ o c trỏn thĩt b biỏn tĩ nguyỏn hn ch (NVIDIA Jetson Orin Nano Super), lp thĩt b úg vai trũ gateway/biỏn trong kin trũc IoT ba tng — thay vớ bn cht lu lng ca d liu hun luyn. CICIDS2017 c chn vớ lĩ b chun cũg khai, c cng ng s dng rng rỏĩ, cú nhỏn chỉ tit vĩ bao ph còc h tn cũg (DoS/DDoS, brute-force, web attack, botnet) cng xut hìn ph bin trong còc mng IoT; còc ngun li ca b d liu nĩy ò c nghiỏn cu k, cho phỏp òp dng quy trỏnh loi tr rũ r mt còch cú cn c. Vĩc kim chng trỏn còc b d liu IoT chuyỏn bit (Bot-IoT, TON_IoT, CIC-IoT-2023) c xỏc nh lĩ hng phòt trin tip theo (Chng 5).

Mĩ hnh mĩ e da (threat model). Lun vn gĩ nh k tn cũg nm bỏn trong hoc biỏn mng IoT vĩ tỏm còch nõ trỏnh phòt hìn; phm vi bo v gĩ hn vĩc phòt hìn còc tn cũg ò bit theo kiu CICIDS2017, di dng phỏn loi nh phỏn Benign/Attack. Còc keh bn i khỏng ch ng (adversarial/evasion) nhm c ý ònh la mĩ hnh nm ngoĩi phm vi ònh giò ca lun vn.

1.3.4 Cỏu hi nghiỏn cu

Lun vn c nh hng bi ba cỏu hi nghiỏn cu:

- **RQ1:** Vĩc gim chũu/la chn c trng (RF Importance, SHapley Additive exPlanations (SHAP), Principal Component Analysis (PCA)) cú gĩ c hũu nng phòt hìn gn vĩ mc đũg toĩn b c trng hay khũng, khi s c trng gim hn 60%?
- **RQ2:** Còc mĩ hnh hc t hp (Ensemble Learning (EL)) cú mang li li th òng k so vĩ mĩ hnh n tt nht hay khũng, khi khỏc bit c kim chng bng kim nh thng kỏ thay vớ so sỏnh mt ln o?
- **RQ3:** Mt pipeline IDS da trỏn Spark cú kh thi v thũg lng, tr vĩ nng lng khi trin khai phỏn tòn trỏn cm thĩt b biỏn tĩ nguyỏn hn ch (Jetson Orin Nano Super) hay khũng?

1.4 Phng phòp nghiõn cu

- **Thu thp, phón tồch, x lý d liu:** S dng tp d liu CICIDS2017, t ú tin hnh phón tồch, x lý vị trc quan hóa d liu.
- **Nghiõn cu v phng phòp tỉ u hóa siõu tham s, còc phng phòp gim chiu d liu:** Nghiõn cu còc phng phòp gim chiu d liu nh PCA, SHAP vị Random Forest Importance nhm gim nhieu vị tng chõnh xõc, ng thi tỉ u hóa siõu tham s thũng qua tòm kim li (Grid Search) vị kim nh chõo (cross-validation) giúp nóng cao hieu nng mũ hõnh. Còc bc nìy c trin khai trõn nn tng Apache Spark nhm m bo kh nng x lý d liu ln hieu qu vị m rng.
- **Nghiõn cu vị xut mũ hõnh hc mỳy, hc sỏu (MLP; vị mt autoencoder lịm cng phòt hin bt thng), hc t hp phòt hin xỏm nhp s dng Spark Machine Learning:** S dng nhieu thut toỏn khỏc nhau nh Decision Tree, Support Vector Machine, Logistic Regression, NB, Random Forest, GBT, XGB, MLP vị còc thut toỏn hc t hp (ensemble) xỏy dng mũ hõnh nhm so sỏnh, ònh giò mũ hõnh cú hieu nng tt nht.
- **Thec nghiõm vị ònh giò hieu nng mũ hõnh trõn cm Jetson Orin Nano Super:** Xỏy dng mt h thng phòt hin xỏm nhp mng IDS *phón tòn* trin khai trõn cm hai thit b biõn Jetson Orin Nano Super (cng phòt hin bt thng trõn mt nũt, b phón loi PySpark trõn nũt cùn li) nhm ònh giò kh nng hot ng trong mũ trng tị nguyõn hn ch. H thng c thit k theo kin trũc x lý d liu thi gian thc, tn dng Apache Kafka cho c ch truyն tỉ thũng ip, Spark Streaming cho x lý lung d liu, PostgreSQL qun lý d liu, InfluxDB lu tr ch s hieu nng theo thi gian, Grafana trc quan hóa vị Mailtrap phc v kim th c ch cnh bõo qua email.

1.5 Còc úng gúp chõnh ca tị

- **xut gii phòp ng dng Apache Spark trong phòt hin xỏm nhp cho h thng mng IoT:** tị õ xỏy dng mt mũ hõnh phòt hin xỏm nhp da trõn nn tng x lý d liu ln Apache Spark, tn dng kh nng x lý phón tòn vị thi gian thc ca Spark, hng tỉ ỏp ng yỏu cu v hieu nng vị tõnh m rng trong mũ trng IoT cú khi lng d liu ln vị bin i liõn tc; kh nng x lý phón tòn c kim chng mc minh chng khõì nim (proof-of-concept) trõn cm thit b biõn.
- **Xỏy dng quy trnh x lý vị phòt hin xỏm nhp toịn ãn trõn d liu IoT:** T bc tin x lý

d liu, trồch xut c trng, hun luyn mĩ hnh n ònh giò kt qu, tị ỗ thit k vị hìn thc mt quy trng phòt hìn xóm nhp hoịn chnh cú th òp dng cho còc h thng thc t.

- **ng dng vị ònh giò còc thut toòn hc mỳy trong mĩ trng phón tòn:** tị trin khai vị so sòn hìu qu ca mt s thut toòn hc mỳy vị mĩ hnh hc sòu MLP trổn nn tng Apache Spark MLlib (ngoi ra mt autoencoder c dng lịm cng phòt hìn bt thng tng biổn), qua ú lịm rũ u im vị hn ch ca tng mĩ hnh trong vic x lý d liu IoT.
- **ònh giò hìu nng h thng trong mĩ trng x lý phón tòn:** Khũng ch ònh giò chòn h xòc ca mĩ hnh, tị cùn phón tồch hìu nng x lý (thi gian thc thi, kh nng m rng) ca h thng nhm kho sòt tòn h kh thi ca gii phòp; vic kim chng c thc hìn mc minh chng khò nim (proof-of-concept) trổn cm thit b biổn vi b d liu CICIDS2017, lịm c s cho vic m rng quy mũ v sau.
- **Quy trng ònh giò loi tr rừ r d liu vị cú kim nh thng kổ:** tị nhn din vị loi b còc ngun rừ r d liu thng gp trổn CICIDS2017 (c trng `destination_port` rừ r nhòn, trng lị lung mc c trng), ng thi òp dng kim nh ý ngha thng kổ, giữp kt qu phn ònh ững nng lc mĩ hnh thay vớ còc con s b thi phng.

1.6 Cũg trng ang chun b cũg b

Mt phn kt qu ca lun vn c phòt trin thnh hai bn tho khoa hc (vit chung vi Nguyñ V Thòi, Trờ Nht vị TS. Nguyñ Vn D), hìn ang c hoịn thìn gĩ ng (cha np ti thi im hoịn thnh lun vn):

1. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.
2. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Distributed Real-Time Intrusion Detection System on a Jetson Orin Nano Super Edge Cluster using Kafka and PySpark,” Symposium on Information and Communication Technology (SOICT), 2026.

1.7 Cu trũc ca lun vn

Lun vn vi tị “PHÒT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO MT MNG IoT” c trng bịy bao gm 5 chng. Ni dung tóm tt tng chng c trng bịy nh sau:

- **Chng 1: M u:** Trnh bñ tng quan v bi cnh vị lý do chn ãi, mc tiõu nghiõn cu, phm vi nghiõn cu, cõu hi nghiõn cu vị phng phõp tip cn. Ngoi ra, chng ãi cng nõu rũ ý ngha thc tin vị khoa hc ca ãi, cng nh b cc tng th ca lun vn.
- **Chng 2: C s lý thuyt:** Trnh bñ cõc khõì nim c bn vị nn tng lý thuyt phc v cho ãi, bao gm tng quan v mng IoT, cõc l hng vị mi e da bo mt, phng phõp phõt hin xõm nhp (IDS), vị kin thc liõn quan n Apache Spark. Ngoi ra, chng ãi cng phõn tõch cõc thut toån hc mỳi thng c s dng phõt hin xõm nhp.
- **Chng 3: Phng phõp thc hin:** Trnh bñ chi tit cõc bc xõy dng h thng phõt hin xõm nhp, bao gm thu thp vị tin x lý d liu, thit k kin trũc h thng s dng Apache Spark, la chn vị trin khai cõc thut toån hc mỳi, cõng quy trnh hun luyõn vị ònh giò mũ hõnh.
- **Chng 4: Thc nghiõm, ònh giò vị tho lun:** Trnh bñ kt qu thc nghiõm trõn b d liu thc t hoc mũ phng, ònh giò hìu nng ca cõc mũ hõnh õ trin khai theo cõc tiõu chõ nh chõnh xõc, Recall, F1-score, kõch thc ca mũ hõnh vị thi gian x lý. ng thi, chng ãi cng phõn tõch, so sõnh vị tho lun v cõc kt qu t c nhm lìm rũ hìu qu ca phng phõp xut.
- **Chng 5: Kt lun vị hng phõt trin:** Tng kt nhng kt qu chõnh mĩ ãi t c, nõu bt nhng úng gúp chõnh, ng thi ch ra nhng hn ch cùn tn ti vị xut cõc hng phõt trin trong tng lai, nh vic tõch hp cõc mũ hõnh hc sõu hoc trin khai h thng trõn nn tng òm mỳi nõng cao tõnh kh dng vị kh nng m rng.

Chng 2. C S LÝ THUYT

Chng này trnh bày ccc nn tng lý thuyt lión quan n tị, bao gm tng quan v Internet vn vt (IoT), ccc mi e đa an ninh trong h thng IoT, v vị vai trò ca h thng phòt hin xóm nhp (IDS). Bón cnh ú, trong chng này, lun vn cng gii thiú kin trức vị kh nng ca Apache Spark trong x lý d liú ln, ccc k thut hc mỳy ng dng trong phòt hin xóm nhp vị ccc Spark MLlib h tr xý dng mũ hnh hc mỳy phón tòn. (Ccc nghión cu lión quan vị khong trng nghión cu ò c kho sòt Chng 1.)

2.1 Tng quan v IoT

Internet of Things (IoT) lị mng li ccc thit b vt lý c tồch hp cm bin, phn mm vị kh nng kt ni mng, cho phỏp thu thp vị trao i d liú qua Internet [27]. IoT bao gm ccc thit b nh cm bin mũi trng, thit b gia dng thũng minh vị phng tin giao thũng to ra khi lng d liú ln vị c im a dng, tc cao vị yỏu cu x lý thi gian thc. Theo bờo bờo Cisco Annual Internet Report (2018–2023), tng s thit b ni mng toin cu c d bờo t khong 29,3 t vọ nm 2023, trong ú khong mt na lị kt ni mỳy-vi-mỳy (M2M/IoT), nhn minh tm quan trng ca bo mt trong lnh vc này [28]. Kin trức IoT thng c chia thnh ba tng:

- **Tng cm bin (Perception Layer):** Thu thp d liú t cm bin vị thit b.
- **Tng mng (Network Layer):** Truyn ti d liú qua ccc giao thc nh MQTT, CoAP hoc HTTP.
- **Tng ng dng (Application Layer):** Phón tồch d liú cung cp dch v [29].

Tuy nhión, ccc thit b IoT thng cú tị nguyón hn ch (b nh, nng lng, kh nng tòngh toón), dn n thỏch thc trong vic trin khai ccc gii phỏp bo mt truyn thng. Ccc mi e đa nh tn cũng t chỉ dch v (DDoS), tn cũng gi mo vị khai thờc l hng giao thc ùi hi ccc gii phỏp bo mt tiỏn tin nh IDS [30].

2.2 H thng phòt hin xóm nhp (IDS)

H thng phòt hin xóm nhp (IDS) gióm sòt vị phón tồch hot ng mng hoc h thng phòt hin ccc hnh vi bt thng hoc òng ng, nhm bo v h thng khi ccc cuc tn cũng mng [31]. IDS úg vai trò quan trng trong vic m bo tòngh bo mt, toin vn vị sn sng ca h thng IoT. IDS c phón loi nh sau:

Da trổn v trỏ trìn khai:

- **Network-based IDS (NIDS):** Giỏm sỏt lu lng mng phỏt hin cỏc mu tn cũg.
- **Host-based IDS (HIDS):** Tp trung vọ hot ng ca mt thit b c th.

Da trổn phng phỏp phỏt hin:

- **Signature-based IDS:** S dng cỏc mu tn cũg ỏ bit, hiu qu vi cỏc mi e da quen thuc nhng hn ch vi cỏc tn cũg mi.
- **Anomaly-based IDS:** Phỏt hin hnh vi bt thng da trổn mũ hnh hot ng bnh thng, phứ hp vi cỏc cuc tn cũg cha bit [32, 33]; cỏc b phỏt hin da trổn hc sỏu nh autoencoder [34] hay mng nim tin sỏu (Deep Belief Network) [35] li mt hng ph bin ca nhúm nọy.
- **Hybrid IDS:** Kt hp c hai phng phỏp tng chỏnh xỏc [31].

Trong IoT, IDS phi x lý khi lng d liu ln vọ ỏp ng yỏu cu thi gian thc, ng thi phứ hp vi tọt nguyỏn hn ch ca thit b. Cỏc gii phỏp IDS da trổn d liu ln vọ hc mọy, nh s dng Apache Spark, li hng i tim nng gii quyỏt cỏc thỏch thc nọy [30].

2.3 Apache Spark vọ x lý d liu ln


2.3.1 D liu ln

D liu ln (*Big Data*) li mt thut ng c s dng mũ t tp hp d liu cú quy mũ ln, phc tp vọ a dng, bao gm d liu cú cu trức, d liu khũng cú cu trức vọ d liu bòn cu trức n mc khũng th x lý hiu qu bng cỏc cũg c vọ phng phỏp trun thng.

Ngọy nay, kỏch thc ca cỏc tp d liu cú th c coi li d liu ln dao ng t **terabyte**, **petabyte** n **exabyte**. Khỏi nim v d liu ln s ph thuc vọ ngnh cũg nghip, cỏch d liu c s dng, lng d liu lch s liỏn quan vọ nhieu c im khỏc.

D liu ln thng c nhn din thũg qua nm c im ct lủi: **Khi lng** (*Volume*), **Tc** (*Velocity*), **Tỏnh a dng** (*Variety*), **Tỏnh xỏc thc** (*Veracity*) vọ **Giỏ tr** (*Value*) (Hỏnh 2.1). ỏy li nhng yu t quan trng giứp phỏn bit d liu ln vi cỏc loi d liu thũg thng, phn ỏnh quy mũ, tc phỏt sinh, s phong phứ v nh dng, tin cy vọ tim nng khai thỏc thũg tin t d liu.

- **Khi lng (Volume):** cp n quy mũ d liu cc ln.
- **Tc (Velocity):** Tc d liu c to ra, trun ti vọ x lý.



Hành 2.1. Mũ hình 5V ca d liu ln [36]

- **Tồnh a dng (Variety):** Ngun vị nh dng d liu a dng nh vn bn, hnh nh, video, v.v.
- **Tồnh xóc thc (Veracity):** Mc òng tin cy vị cht lng ca d liu.
- **Giò tr (Value):** Tim nng khai thóc thũng tin hu òch t d liu.


D liu sinh ra t còc thit b IoT c xem lị mt trong nhng ngun to ra d liu ln (BD) quan trng vị phòt trin nhanh chóng hin nay. Vì hịng t thit b cm bin, mỳ mỳc, thit b eo tay vị phng tin kt ni Internet, lng d liu c to ra mĩ ngỳy rt ln, a dng v nh dng vị tc phòt sinh liỏn tc theo thi gian thc. D liu IoT mang y còc c im ca d liu ln nh: khi lng (volume) ln, tc (velocity) cao, tồnh a dng (variety) v loi d liu, mc xóc thc (veracity) khũng ng u vị tim nng mang li giò tr (value) ln nu c khai thóc hiu qu. Chờnh vớ vy, d liu IoT khũng ch lị mt phn ca d liu ln mị cùn úng vai trò quan trng trong vic thũc y nhu cu phòt trin còc nn tng x lý d liu ln hin i.

2.3.2 Còc thnh phn ca Apache Spark

Trong nhng nm gn óy, còc nn tng x lý d liu ln nh Apache Spark ò thu hũt s quan tòm rng rồi t cng ng nghiỏn cu vị cũng nghiip. Apache Spark lị mt h thng x lý d liu phón tòn quy mũ ln, cú kh nng thc thi nhanh còc tỳc v trởn còc cm d liu ln. So vị Hadoop MapReduce, Spark cú th t tc x lý nhanh hn khong 100 ln trong mt s trng hp nh vị kh nng x lý trong b nh (*in-memory processing*) [37, 38].

Bổn cnh ú, Spark cung cp giao đin lp trnh linh hot thng qua ccc API h tr nhieu ngũn ng ph bin nh Java, Scala, Python v R, giúp vic phòt trin v trin khai ng dng tr nnn thun tin hn.

Apache Spark bao gm nhieu thnh phn chnh to thnh mt h sinh thời hoịn chnh, h tr a dng ccc tcc v phón tcch d liu nh x lý d liu theo lũ (batch), truy vn SQL, phón tcch lung d liu thi gian thc, hc mỳy v x lý th (Hnh 2.2).



Hnh 2.2. Ccc thnh phn ca Apache Spark [38]


Apache Spark bao gm nhieu thnh phn ct lũ, m thnh phn m nhn mt chc nng c th trong quỏ trnh x lý d liu ln:

- **Spark Core:** Thnh phn trung tmm ca Spark, chu trỏch nhim qun lý b nh, lp lch, x lý li, phón phi tcc v v giao tip v ccc h thng lu tr. Nũ cung cp ccc API cp cao cho Java, Scala, Python v R, giúp n gin húa vic x lý phón tccn.
- **MLlib:** Th vin hc mỳy tccch hp sn trong Spark [39], h tr hun luyt v trin khai ccc mũ hnh hc mỳy trỏn quy mũ ln. MLlib cung cp ccc thut toỏn nh phón loi, hi quy, phón cm, khai thcc mu v lc cng tcc.
- **Spark Streaming:** Cũng c x lý d liu thi gian thc bng cccch chia lung d liu thnh ccc lũ nh x lý tng t nh d liu theo lũ. Cũng c nỳy cho phỏp s dng li mũ ngun v h tr nhieu ngun d liu nh Kafka, Flume, Twitter, HDFS.
- **Spark SQL:** Thnh phn truy vn d liu phón tccn, h tr ngũn ng SQL tiỏ chun v HiveQL v hiu sut cao nh ti u húa Catalyst v nh dng ct. Nũ h tr nhieu ngun d liu nh JSON, Hive, Parquet, JDBC, MongoDB, Cassandra.

- **GraphX**: Th vin x lý th phón tồn, h tr biu din, chuyn i vị phón tồn d liu th. GraphX i kóm vi còc thut toòn th ph bin nh PageRank, Connected Components vị nhiu thut toòn phón tồn khòc.

2.3.3 Kin trúc ca Apache Spark

Kin trúc ca Apache Spark c xóy dng theo mĩ hnh masterworker trón nn tng x lý phón tồn. Thnh phn trung tóm lị **Spark Driver**, chu tròc nhim iu phi quò trnh thc thi ng dng, bao gm vic lón lch, phón phi tòc v vị giòm sòt tin trnh. Driver xóy dng mt th phi chu trnh cú hng (DAG – Directed Acyclic Graph) xòc nh lung thc thi cũng vic; tng quan kin trúc master–worker c minh ha Hnh 2.3.



Hnh 2.3. S kin trúc h thng Apache Spark [37]

Còc tòc v c phón phi ti còc **Worker Nodes**, ni cha còc **Executor** tin trnh thc thi thc t. Mi Executor chu tròc nhim thc thi còc tòc v (task) vị lu tr d liu trong b nh hoc a nu cn. Spark s dng **Cluster Manager** (nh YARN, Mesos hoc Standalone) qun lý tị nguốn trón cm. D liu c lu tr trón còc h thng nh HDFS, S3, hoc còc c s d liu quan h.

2.4 Hc mỳ trong phòt hìn xóm nhp

Hc mỳ (ML) ò tr thnh mt cũng c thit yu trong vic phòt hìn còc mu tn cũng vị hnh vi bt thng trong lu lng mng IoT, nh kh nng t ng hc vị thờch ng t d liu lch s [40]. Còc k thut hc mỳ ph bin bao gm:

- **Hc cú giòm sòt (Supervised Learning)**: S dng d liu ò c gòn nhõn hun luy n mĩ hnh phón loi. Mt s thut toòn in hnh gm Random Forest (RF), SVM vị Mng n–ron nhón to (Neural Networks).

- **Hc khũng giòm sòt (Unsupervised Learning):** Ớp dng cho còc tởnh hung khũng cú nhõn, tp trung vọ vic phòt hin còc mu bt thng. K-Means lị mt thut toòn ph bin trong nhúm nịy.
- **Hc tng cng (Reinforcement Learning):** Mũ hnh hc đa trổn phn hi t mũi trng nhm tí u hóa hnh vi hoc quyt nh ca h thng theo thí gian; hng nịy khũng thuc phm vi the nghim ca lun vn vọ ch c nõu hoịn chnh bc tranh phón loi.

Trong bì cnh mng IoT, hc mỳy c ng dng rng rỏi phón tồch lu lng d liu vọ nhn đin còc loi tn cũng nh DDoS, botnet hay gi mo gúi tin. Chng hn, Koroniotis vọ cng s (2019) xóy dng b d liu Bot-IoT vọ bào còc còc mũ hnh hc mỳy, hc sỏu t chỏnh xỏc gn tuyt i khi phòt hin còc tn cũng DoS/DDoS trong mũi trng IoT [41]. Tuy nhiỏn, còc kt qu gn nh tuyt i (xp x 100%) trổn còc tp d liu cũng khai cn c xem xỏt thn trng, vớ chũng thng lị du hiu ca rừ r d liu (data leakage) hn lị nng lc the s ca mũ hnh. Rừ r d liu lị tởnh hung trong ú thũng tin l ra khũng sn cú thí im trin khai the t lị lt vọ quỏ trỏnh hun luyt hoc ònh giỏ, khin im s b thí phng vọ khũng phn ònh ỹng kh nng tng quỏt hóa ca mũ hnh. Lun vn nịy nhn đin vọ x lý vn ú mt còch tng minh Chng 4.

Tuy nhiỏn, vic ng dng hc mỳy trong h thng IoT vn cùn gp nhiu thỏch the vớ yỏu cu x lý theo thí gian the vọ hn ch v tịi nguyỏn tởnh toòn. Vic tồch hp hc mỳy vọ còc nn tng x lý d liu ln nh Apache Spark mang lị lị th òng k, giũp x lý khi lng d liu ln vọ tc cao vọ h tr trin khai còc thut toòn hc mỳy hiu qu trong mũi trng phón tòn.

2.4.1 Mt s thut toòn hc mỳy

- **Cóy quyt nh (Decision Trees (DT))** lị mt trong nhng thut toòn hc mỳy cú giòm sòt ph bin, c Ớp dng rng rỏi trong còc bìi toòn phón loi. Cu trũc c bn ca mt cóy quyt nh bao gm ba thnh phn chỏnh: **nũt gc**, **nũt quyt nh** vọ **nũt lò**. Cóy quyt nh cú u im lị d hiu, d đin gii, cú th trc quan hóa vọ khũng yỏu cu gi nh v phón phi d liu. Tuy nhiỏn, DT cng d b quỏ khp (*overfitting*) nu khũng chn c còc tham s hp lý hoc x lý trổn d liu nhiu [42].
- **Rng ngu nhiỏn (RF)** lị mt thut toòn hc mỳy c s dng ph bin trong c hai bìi toòn phón loi vọ hi quy. óy lị mt k thut hc t hp (*ensemble learning*) đa trổn vic xóy dng vọ tng hp nhiu cóy quyt nh c lp nhm nõng cao chỏnh xỏc vọ n nh ca mũ hnh. Thut toòn hot ng bng còch to ra nhiu cóy quyt nh trổn còc tp con khỏc nhau c chn ngu nhiỏn t tp d liu hun luyt. Mỏ cóy c xóy dng đa trổn mt mu bootstrap (lý mu cú hoịn li), ng

thi ti mi nũt chia, mt tp con ngu nhiõn ca cõc c trng c chn tõm im chia tt nht, thay vớ s dng toịn b c trng nh trong cõy quy t nh trun thng [43].

Kt qu cui cõng c xõc nh bng cõch:

- ◊ Trong bñ toòn phõn loi: ly kt qu theo nguyõn tc a s phiu (*majority voting*) t cõc cõy.
- ◊ Trong bñ toòn hi quy: ly giò tr trung bõnh t cõc d oòn ca tng cõy.

Vic kt hp nhiu cõy giũp RF gim thiu hin tng quõ khp (*overfitting*) vn lĩ mt nhc im thng gp ca cõc cõy quy t nh n l. Khi s lng cõy trong rng tng lõn, hiu nng d oòn ca mĩ hõnh cú xu hõng n nh vĩ ci thĩn hn.

- **Hi quy logistic (Logistic Regression (LR))** lĩ mt phõng phõp thng kõ c giĩ thiu bi David Cox vĩa cui thp niõn 1950. óy lĩ mt k thut hc mỳy cú giõm sõt thng c s dng giĩ quy t cõc bñ toòn phõn loi nh phõn, trong ú bin u ra (phn hi) lĩ mt bin nh tõnh, nhĩn giò tr 0 hoc 1. Mĩ hõnh hi quy logistic cho phõp c tõnh xõc sut xy ra ca mt s kin c th da trõn mt hoc nhiu bin u vĩa (c lp). Mt trong nhĩng im mnh ca phõng phõp nĩy lĩ kh nng xõc nh mc nh hõng ca tng yu t n xõc sut xut hin ca kt qu, giũp cõc nhĩ phõn tõch hiu rĩ hn mi quan h gia bin u vĩa vĩa u ra [44].

V mt toòn hc, hĩm hi quy logistic c biu ãĩn ãĩ dng tuyn tõnh nh sau:

$$z_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_n x_{i,n} \quad (2.1)$$

Trong ú:

- ◊ $x_{i,j}$ lĩ giò tr ca bin c lp th j ti quan sõt th i
- ◊ β_0 lĩ h s chn (bias), β_j lĩ h s hi quy ng vĩ bin x_j
- ◊ z_i lĩ u ra tuyn tõnh trc khi a qua hĩm kõch hot (sigmoid)

Sau ú, xõc sut xy ra ca s kin c tõnh thũng qua hĩm logistic (sigmoid):

$$P(Y_i = 1 \mid \mathbf{x}_i) = \frac{1}{1 + e^{-z_i}} \quad (2.2)$$

Trong quõ trõnh hun luyn, mĩ hõnh tõm cõc h s β_j ti u sao cho hĩm mt mõt (cross-entropy loss) c ti thiu hĩa.

- **GBT** là mt phng phòp *boosting* (kt hp tun t còc mĩ hnh hc yu; lu ý phón bit vì “hc tng cng” – reinforcement learning) s dng còc cóy quyét nh nh mĩ hnh hc yu (weak learners). Ý tng chònh ca boosting là xóy dng mt mĩ hnh mn bng còch kt hp nhiu mĩ hnh hc yu c hun luyt theo trnh t tun t. mĩ bc, thut toàn c gng gim thiu li ca mĩ hnh trc bng còch hc t phn d (residual) hoc gradient ca hịm mt mọt [45]. Quò trnh hun luyt GBT gm còc bc:

- ◇ Bt u vì mt mĩ hnh d oàn ban u (thng là giò tr trung bnh vì bị toàn hi quy).
- ◇ Tònh toàn sai s cùn li gia nhõn thc vị d oàn.
- ◇ Hun luyt mt cóy quyét nh d oàn phn d.
- ◇ Cp nht mĩ hnh tng bng còch cng mĩ hnh hin ti vì mĩ hnh mi nhón vì mt h s hc η (learning rate).

Gi s $F_0(x)$ là mĩ hnh khi to ban u, mĩ hnh tng ti bc m c cp nht theo cūng thc:

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \quad (2.3)$$

Trong ú:

- ◇ $h_m(x)$ là cóy quyét nh th m hc theo gradient ca hịm mt mọt.
 - ◇ η là h s hc (learning rate), thng $\eta \in (0, 1)$.
- **LightGBM (LGBM)** là mt framework trin khai thut toàn GBT, c phòt trin nhm ti u hóa tc hun luyt vị kh nng m rng trỏn còc tp d liu ln [46], vì cūng s cp nht boosting theo gradient ò trnh bịy mc GBT phòr trỏn. Khòc vì GBT truyt thng, LGBM s dng c ch phòt trin cóy theo hng leaf-wise thay vớ level-wise, ng thi òp dng thut toàn histogram-based splitting vị k thut Gradient-based One-Side Sampling (GOSS) nhm gim chi phò tòn thc vị tng tc hun luyt. Tuy nhiõn, LGBM *khũng* c a vớ b thut toàn so sòn thc nghim vớ lý do tng thờch phn cng trnh bịy Chng 3; XGBoost vị GBT i din cho h gradient boosting.
- **NB** là mt phng phòp phón loi xòc sut đa trỏn nh lý Bayes vì gi nh c lp cú iu kin gia còc c trng [47]. Mc dứ gi nh nịy thng khũng hoịt toịn ỹng trong thc t, mĩ hnh vn cho hiu qu tt trong nhiu bị toàn phón loi d liu nhiu chiu.

Theo nh lý Bayes:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)} \quad (2.4)$$

Vì giả nh c lp gia còc c trng:

$$P(x|y) = \prod_{i=1}^n P(x_i|y) \quad (2.5)$$

Mũ hnh la chn lp cú xòc sut hu nghim ln nht:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y) \quad (2.6)$$

u im ca NB lị n gin, tc hun luyt nhanh vı phứ hp vı d liu kòch thc ln; tuy nhiõn, hn ch chònh nm gi nh c lp gia còc c trng.

- **Support Vector Machine (SVM)** lị mt thut toàn hc cú giòm sòt c xut bi Cortes vı Vapnik [48], nhm tòm siỏu phng ti u phón tòch d liu vı khong còch biỏn (margin) ln nht.

Trong trng hp d liu tuyen tòn, bựi toàn ti u c biu din nh sau:

$$\min_{w,b} \frac{1}{2} ||w||^2 \quad (2.7)$$

vı iu kin:

$$y_i(w \cdot x_i + b) \geq 1 \quad (2.8)$$

Trong trng hp d liu khũng tuyen tòn, SVM s dng k thut *kernel trick* ònh x d liu sang khũng gian nhiu chiu hn, cho phỏp phón tòch tuyen tòn trong khũng gian mi. Nh c ch ti u húa cht ch, SVM thng t hiu nng cao trong còc bựi toàn phón loi vı d liu nhiu chiu.

- **Multilayer Perceptron - MLP** lị mt mũ hnh hc sỏu c bn gm nhiu lp n, cú kh nng mũ hnh húa còc mi quan h phi tuyen gia còc c trng [49].

Mi n-ron trong mng thc hìn phỏp bin i tuyen tòn:

$$z = w^T x + b \quad (2.9)$$

sau ú òp dng hàm kích hoạt phi tuyến:

$$a = \sigma(z) \quad (2.10)$$

Trong ú $\sigma(\cdot)$ cú th lị còc hàm kích hoạt nh sigmoid, tanh hoc ReLU. Quò trính hun luyn s dng thut toàn lan truyn ngc (*backpropagation*) nhm cp nht trng s thũng qua ti thiú hóa hàm mt môt bng gradient descent. MLP cú kh nng biu din mngh nhng yỏu cu d liú hun luyn ln vị quò trính iú chnh siỏu tham s cn thn trỏnh hin tng quò khp.

- **XGB** lị mt phiỏn bn ci tin ca thut toàn GBT truyn thng, c xut bi Chen vị Guestrin vịo nm 2016. XGB c thit k ti ú hóa tc hun luyn, hiu nng mủ hỏnh, vị kh nng x lý d liú quy mủ ln trong còc h thng tỏnh toàn phỏn tòn [50]. XGB s dng còc chin lc sau ci thín hiu nng:

- ◇ Khai thỏc gradient vị Hessian ti ú hóa hiu qu (second-order optimization).
- ◇ Ct ta cóy (pruning) theo phc tp thay vớ sỏu c nh.
- ◇ Tỏnh song song trong vic tỏm im chia ti ú (split finding).
- ◇ H tr x lý thiú giò tr (missing values) t ng.

Mủ hỏnh XGB ỏ c ng dng thịnh cũng trong nhiú bậi toàn hc mỳy thc t nh d bởo tậi chỏnh, chn oỏn y t, phỏt hin gian ln vị phỏn tỏch hỏnh vị khỏch hỏng, nh chỏnh xỏc cao vị hiu qu tỏnh toàn tt.

2.4.2 Mt s thut toàn hc t hp

Hc t hp (Ensemble Learning, EL) lị mt k thut trong hc mỳy nhm kt hp nhiú mủ hỏnh riỏng l nỏng cao chỏnh xỏc vị n nh trong d oỏn. Thay vớ ch da vịo mt mủ hỏnh n l, phng phỏp EL tn dng sc mngh tng hp ca nhiú mủ hỏnh (vỏ d DT, RF, LR) xỏy dng mt h thng d oỏn chỏnh xỏc hn. Nguyỏn lý ct lủi ca EL lị: mủ mủ hỏnh riỏng l cú th ch t chỏnh xỏc thp hoc d oỏn sai mt s trng hp, nhng s kt hp hp lý ca chũng cú th gim thiú sai s, tng chỏnh xỏc nh tn dng im mngh vị khc phc im yu ca tng mủ hỏnh thịnh phn [51].

K thut EL ỏ chng minh c tỏnh hiu qu cao trong nhiú lnh vc yỏu cu chỏnh xỏc cao nh: phỏt hin gian ln, phỏn tỏch d liú ln, nhn din hỏnh nh vị x lý ngũn ng t nhiỏn. Trong lnh vc bo mt mng IoT, EL cng c ng dng ci thín kh nng phỏt hin bt thng hoc xỏm nhp da trỏn nhiú mủ hỏnh hc mỳy c hun luyn song song hoc tun t.

Mt s phng phỏp ph bin ca EL bao gm:

- **Voting:** Vì bị toàn phần lỗi, mô hình con bỏ phiếu cho một lớp vị lớp cụ thể phiếu cao nhất sẽ ra quyết định (a sẽ phiếu học trung bình xác suất). Các bước của voting có mô tả chi tiết Thuật toán 1.
- **Boosting:** Huấn luyện các mô hình tuần tự, trong đó mô hình mới tập trung vào các mẫu mà mô hình trước đã đoán sai (ví dụ: GBT, AdaBoost, XGB). Các bước của boosting có mô tả chi tiết Thuật toán 2.
- **Bagging (Bootstrap Aggregating):** Huấn luyện nhiều mô hình trên các tập con ngẫu nhiên (lấy mẫu có hoàn lại) của tập dữ liệu gốc, sau đó tổng hợp kết quả đoán (ví dụ: Random Forest). Các bước của bagging có mô tả chi tiết Thuật toán 3.

EL có thể được sử dụng trong các hệ thống phát hiện xâm nhập (IDS) với các phần tử học để phân tích dữ liệu phức tạp, việc kết hợp nhiều mô hình có thể giúp tăng khả năng phát hiện các gói tin bất thường mà mô hình đơn lẻ có thể bỏ sót.

Thuật toán 1. Voting: Kết hợp đoán từ nhiều mô hình phần lỗi

u vào:

- Tập huấn luyện $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- Tập mô hình phần lỗi có $M_1, M_2, \dots, M_K$
- Kiểu voting: HARD hoặc SOFT

u ra: Nhãn đoán cuối cùng y_{vote} cho dữ liệu x

```

1: Khi to: danh sách  $S = \{\}$  ▷ Lu đoán học xác suất
2: if voting = HARD then
3:   for  $j = 1$  to  $K$  do
4:      $y_j \leftarrow M_j(x)$  ▷ D đoán nhãn của mô hình thứ  $j$ 
5:     Thêm  $y_j$  vào  $S$ 
6:   end for
7:    $y_{\text{vote}} \leftarrow$  nhãn xuất hiện nhiều nhất trong  $S$ 
8: else if voting = SOFT then
9:   Khi nào xác suất tổng  $P_{\text{sum}}[c] = 0, \forall c \in \{1, \dots, C\}$ 
10:  for  $j = 1$  to  $K$  do
11:    Ly xác suất  $P_j(y = c | x)$  từ mô hình  $M_j$ 
12:    for mỗi lớp  $c = 1$  to  $C$  do
13:       $P_{\text{sum}}[c] \leftarrow P_{\text{sum}}[c] + P_j(y = c | x)$ 
14:    end for
15:  end for
16:   $y_{\text{vote}} \leftarrow \arg \max_c P_{\text{sum}}[c]$ 
17: end if
18: return  $y_{\text{vote}}$ 

```

Thut toàn 2. Boosting: Kt hp tun t còc mũ hnh hc yu

u vïo:

- Tp d liu hun luyt $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- S lng vùng lp (mũ hnh yu): T

u ra: Mũ hnh boosting $F_T(x)$

- 1: **Khi to:** $F_0(x) \leftarrow 0$ ▷ Mũ hnh khi u cú th lị 0 hoc d oòn trung bnh
 - 2: **for** $t = 1$ to T **do**
 - 3: Tõnh gi-phn-d (pseudo-residuals) theo gradient óm ca hịm mt môt: $r_i^{(t)} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{t-1}}$ ▷ Vi mt môt bnh phng (hì quy), rĩt gn thnh $y_i - F_{t-1}(x_i)$;
vi phón loi dũng log-loss
 - 4: Hun luyt mũ hnh yu $h_t(x)$ trở còc gi-phn-d $r_i^{(t)}$
 - 5: Cp nht mũ hnh: $F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$
 - 6: **end for**
 - 7: **return** $F_T(x)$
-

Thut toàn 3. Bagging: Bootstrap Aggregating

u vïo:


- Tp hun luyt $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (tng quòt: C lp)
- S lng mũ hnh c s: K

u ra: D oòn cui cũng y_{bag} cho mt im d liu x

- 1: **Khi to:** Danh sòch mũ hnh $M_1, M_2, \dots, M_K$
 - 2: **for** $k = 1$ to K **do**
 - 3: To mu bootstrap $\mathcal{D}^{(k)}$ t $\mathcal{D}$ (ly mu ngu nhiõn cú hoịn li)
 - 4: Hun luyt mũ hnh $M_k \leftarrow \text{Train}(\mathcal{D}^{(k)})$
 - 5: **end for**
 - 6: **Khi to:** Danh sòch d oòn $Y = \{\}$
 - 7: **for** $k = 1$ to K **do**
 - 8: Thc hin d oòn $y_k \leftarrow M_k(x)$
 - 9: Thõm y_k vïo Y
 - 10: **end for**
 - 11: Tõnh $y_{\text{bag}} \leftarrow \text{Voting}(Y)$ ▷ Hard voting hoc trung bnh xòc sut nu dũng soft
 - 12: **return** y_{bag}
-

Chng 3. PHNG PHÒP THC HIN

Trong chng nỳ, lun vn s trnh bỳ phng phòp xut xóy dng mũ hnh phòt hin xóm nhp da trỏn Apache Spark cho bo mt mng IoT. Quò trnh thc hin bao gm 6 bc chònh, c th hin qua Hnh 3.1: (1) Thu thp d liu v tin x lý; (2) Xóy dng c trng v la chn c trng; (3) Hun luyt mũ hnh; (4) ònh giò mũ hnh; (5) Ti u siỏu tham s; v (6) Trin khai biỏn thi gian thc. Còc bc (1)(5) c lp li tng ng v tng phng phòp la chn c trng (Random Forest Importance (RFI), SHAP, PCA), sau ú la chn mũ hnh tt nht trin khai trỏn thit b biỏn.



Hnh 3.1. Quy trnh tng th hun luyt, ònh giò v trin khai mũ hnh xut

3.1 Thu thp d liu v tin x lý

Trong nghiỏn cu nỳ, tp d liu c s dng l CICIDS2017 c phòt hnh bi Vin An ninh mng Canada (CIC). Tp d liu nỳ c xóy dng nhm mũ phng lu lng mng thc t kt hp v nhũ loi tn cũng mng hin i, phc v cho vic hun luyt v ònh giò còc mũ hnh phòt hin xóm nhp. Tp d liu CICIDS2017 tp trung vọ còc kch bn tn cũng n l trong mũi trng kim soỏt. Cn lu ý rng còc b d liu phòt hin xóm nhp mng cũng khai — bao gm CICIDS2017 — cú nhng gii hn ò c kho sỏt mt còch h thng (li gòn nhỏn, to tòc khi sinh lu lng, v kh nng tng quòt húa hn ch) [52]; óy l lý do lun vn òp dng quy trnh loi tr rừ r bc tin x lý v b sung ònh giò liỏn b d liu Chng 4. Thũng tin chi tit v tp d liu c trnh bỳ trong Bng 3.1.

Bng 3.1. Mũ t b d liu CICIDS2017

Thuc tởnh	Giờ tr
T chc phòt hnh	Canadian Institute for Cybersecurity (CIC)
Thi gian phòt hnh	2017
Giao thc mng	HTTP, HTTPS, FTP, SSH, DNS, ...
S lng bn ghi (CSV)	Hn 2.8 triu bn ghi
Thi gian thu thp	03/07/2017 07/07/2017
Loi tn cũng mũ phng	DoS, DDoS, PortScan, Brute-force, Infiltration, Botnet, ...
S loi nhõn	15 (1 nhõn bõnh thng + 14 loi tn cũng)
nh dng d liu	CSV
Mc ờch	Phòt hnh xỏm nhp mng trong mũi trng thc t gi lp
Ngun d liu	[53]

Bổn cnh CICIDS2017 (b d liu chõnh cho toỏn b cõc thờ nghim), lun vn s dng thõm **CSE-CIC-IDS2018** cho thờ nghim *tng quỏt húa liõn b d liu* (Mc 4.2.8.1): hun luyõn trõn mt b, kim tra trõn b kia vớ ngc li. óy lớ b k nhim ca CICIDS2017, do CIC phi hp vi C quan An ninh Truyõn thũng Canada (CSE) thu thp trõn h tng AWS quy mũ ln hn nhiu; c trng lung c trỏch bng CICFlowMeter phiõn bn mi hn nõn tởn ct c ònh x v danh mc tởn ct chun ca CICIDS2017 qua bng bờ danh tng minh trong mỗ ngun. Thũng tin chi tit Bng 3.2.

Bng 3.2. Mũ t b d liu CSE-CIC-IDS2018 (dứng cho thờ nghim liõn b d liu)

Thuc tởnh	Giờ tr
T chc phòt hnh	CIC phi hp CSE (Communications Security Establishment)
Thi gian phòt hnh	2018
H tng thu thp	Testbed trõn AWS (~450 mỳy nn nhõn, 50 mỳy tn cũng)
S lng bn ghi (CSV)	~16,2 triu lung (10 tp CSV theo ngỳy)
Thi gian thu thp	14/02/2018 – 02/03/2018
Loi tn cũng mũ phng	DDoS (HOIC, LOIC-HTTP/UDP), DoS (Hulk, GoldenEye, Slowloris, SlowHTTPTest), Bot, Brute-force (SSH, FTP, Web, XSS), SQL Injection, Infiltration
S loi nhõn	15 (1 nhõn bõnh thng + 14 loi tn cũng)
Phõn b nh phõn (sau lợm sch)	~13,35 triu Benign / ~2,35 triu Attack
Phn đứng trong lun vn	Mu phõn tng theo nhõn 20% (seed=42), cùn ~2,39 triu lung sau kh trửng lp mc c trng
nh dng d liu	CSV (CICFlowMeter v3; tởn ct ònh x v chun CICIDS2017)
Ngun d liu	[54]

Tin x lý d liu Vic tin x lý d liu nhm loi b nhieu, giò tr ngoi l vị giò tr b thiu c thc hin trc khi a d liu vjo hun luyn mĩ hnh. Còc k thut c òp dng gm chun hóa tổn ct, cn chnh lc gia còc tp, thay th giò tr vũ cng, loi b bn ghi trng lp/thiu, vị gòn nhõn nh phón (BENIGN = 0, Attack = 1).

Bổn cnh ú, bo m kt qu ònh giò phn ònh ững nng lc mĩ hnh, lun vn òp dng thõm hai bc *loi tr rừ r d liu* (loi cm by “data snooping” c xem li ph bin nht ca hc mỳy trong an ninh [55]) ngay trong giai on tin x lý, trc khi phón chia tp: (i) **loi c trng rừ r nhõn** destination_port (vị source_port nu cú) vớ trong CICIDS2017, mi loi tn cũng c sinh nhm vjo nhng cng dch v c nh nỏn cng òch gn nh mĩ hóa trc tip nhõn, khin mĩ hnh “ghi nh” ònh x cng–nhõn thay vớ hc hnh vi lung (ct protocol cng c loi vi lý do tng t: óy li bin phón loi cú òt mc giò tr, tng quan mn nh vi cng dch v nỏn mang cng nguy c “li tt” nh danh dch v thay vớ hnh vi); vị (ii) **loi b trng lp mc c trng theo c ch tt nh** còc lung c gom nhúm theo tojñ b vector c trng; vị nhúm cú nhõn nht quòn, gi li ững mt i ðin; vị nhúm trng c trng nhng *móu thun nhõn* (cng vector c trng, nhõn va Benign va Attack, mt li gòn nhõn ò c ghi nhn ca CICIDS2017 [56]), *tojñ b nhúm b loi* vớ khũng th xòc nh nhõn ững, thay vớ gi li mt hng tũy ý theo phón mn nh d liu (vn khũng tòi lp c gia còc ln chy); s nhúm vị s hng xung t nhõn c ghi log tng mn nh (270 nhúm, 44.260 hng). C ch nỳ trõnh vic cũng mt mu xut hin c tp hun luyn ln kim tra khi phón chia ngu nhõn. i vị tp d liu CICIDS2017, quò trõnh tin x lý d liu c th hin chi tit Thut toòn 4. Cn tha nhn rng bc loi b trng lp mc c trng lĩm thay i *phón b lp*: do còc lung benign trng lp nhieu hn nỏn b loi nhieu hn, khin t l benign/attack sau khi x lý khòc vị t l ban u; vớ vy phón b lp trc vị sau khi loi trng lp c bõo cõo tng mn nh bo m mn nh bch.

Phón chia tp d liu

Tp d liu CICIDS2017 c phón chia theo t l 80/20 cho hun luyn vị kim tra bng phõp chia ngu nhõn (random split) vị seed c nh (=42) m bo tòi lp. Còc ch s hui nng c **cũng b trõn tp kim tra** (tp gi li cui cũng, khũng tham gia hun luyn, xp hng c trng hay tinh chnh siỏu tham s); kt qu trõn tp hun luyn ch c ðng chn oòn hin tng quò khp (overfitting) hoc thiu khp (underfitting). òng lu ý, StandardScaler, PCA vị vic xp hng c trng (RF Importance, SHAP) u c *fit ch trõn tp hun luyn* D_{train} ri *transform* lỏn tp kim tra, nhm trõnh rừ r thũng tin t tp kim tra vjo quò trõnh hun luyn. Riỏng vic **chn Top-3 mĩ hnh thĩnh phn** cho còc ensemble (cng nh vic chn mĩ hnh i ðin mi phng phỏp vị cp phng phỏp a vjo kim nh thng kỏ, Chng 4) c thc hin trõn mt *tp kim nh (validation)* tỏch t tp hun luyn (theo t l 80/20, seed=42, còc mĩ hnh c s hun luyn trõn phn cũn li); nh vy tp kim tra hojñ tojñ khũng

Thut toàon 4. Thut toàon Tin x lý D liu CICIDS2017

u vò: Tp N tp CSV t b d liu CICIDS2017: $\{F_1, F_2, \dots, F_N\}$

T l phón chia hun luy/kim tra $\alpha = 0.8$


u ra: Tp hun luy D_{train} vò tp kim tra D_{test} nh dng Parquet

```

1: Bc 1: Gp d liu t nhieu tp CSV
2:  $D \leftarrow \emptyset$ 
3: for  $i = 1$  to  $N$  do
4:   c tp  $F_i$  thnh DataFrame  $df_i$  vò lc suy lun t ng
5:   CLEANCOLUMNAMES( $df_i$ )    ▷ Chun hóa tởn ct: xúa khong trng, chuyn ch thng
6:   HANDLEINFINITYVALUES( $df_i$ )    ▷ Thay th  $\pm\infty$  bng giò tr NaN
7:   if  $D = \emptyset$  then
8:      $\mathcal{S} \leftarrow \text{Schema}(df_i)$     ▷ Lu lc chun t tp u tởn
9:      $D \leftarrow df_i$ 
10:  else
11:    ALIGNSCHEMA( $df_i, \mathcal{S}$ )    ▷ Cn chnh lc v chun  $\mathcal{S}$ 
12:     $D \leftarrow D \cup df_i$     ▷ Gp theo tởn ct (unionByName)
13:  end if
14: end for
15: Bc 2: Lm sch d liu
16:  $D \leftarrow \text{RemoveDuplicates}(D)$     ▷ Loi b còc bn ghi trng lp hoìn toìn (gìng ht trỏn mĩ ct)
17:  $D \leftarrow \text{RemoveNulls}(D)$     ▷ Loi b còc bn ghi cha giò tr null/NaN
18: Bc 3: To nhõn nh phón
19:  $\forall (x_i, \text{label}_i) \in D : y_i \leftarrow \begin{cases} 0 & \text{nu label}_i = \text{"BENIGN"} \\ 1 & \text{ngc li (Attack)} \end{cases}$ 
    → Hai bc loi tr rừ r d liu (data leakage): Bc 4 vò Bc 4b
20: Bc 4 [loi rừ r – I]: Xòc nh còc c trng s (õ loi tr rừ r)
21:  $\mathcal{C}_{\text{exclude}} \leftarrow \{\text{label, label\_binary, source\_ip, destination\_ip, flow\_id, timestamp, protocol,}$ 
     $\text{destination\_port, source\_port}\}$     ▷ Loi b c trng góy rừ r nhõn
22:  $\mathcal{F} \leftarrow \{c \in \text{columns}(D) \mid c \notin \mathcal{C}_{\text{exclude}} \wedge \text{dtype}(c) \in \{\text{double, float, int, bigint}\}\}$ 
23: Bc 4b [loi rừ r – II]: Loi b trng lp mc c trng (tt nh)
24:  $G \leftarrow \text{GroupBy}(D, \mathcal{F})$     ▷ Gom nhúm theo toìn b vector c trng
25: for mĩ nhúm  $g \in G$  do
26:   if  $|\{y_i : (x_i, y_i) \in g\}| > 1$  then    ▷ Nhúm móu thun nhõn (Benign ln Attack)
27:     Loi toìn b nhúm  $g$  khi  $D$ ; ghi log s nhúm/hìng xung t
28:   else
29:     Gi li ửng mĩ i din ca  $g$  (th t tt nh theo nhõn)
30:   end if
31: end for
32: Bc 5: Phón chia vò lu tr
33:  $D_{\text{train}}, D_{\text{test}} \leftarrow \text{RandomSplit}(D, [\alpha, 1 - \alpha], \text{seed} = 42)$ 
34: Lu  $D_{\text{train}}, D_{\text{test}}$  dĩ nh dng Parquet
35: return  $D_{\text{train}}, D_{\text{test}}$ 

```

tham gia vò khóu la chn mũ hnh, khỗp kờn nguy c rừ r chn lc. Toịn b quy trnh phón chia c minh ha Hnh 3.2.



Hnh 3.2. S phón chia d liu CICIDS2017. Sau tin x lý vò loi tr rừ r (Thut toòn 4), d liu c chia 80/20 thnh train/test ($seed=42$); tp test c gi li, ch đng cng b kt qu cui. StandardScaler, PCA vò vic xp hng c trng (RF/SHAP) c *fit* trỏn toịn b tp train ri gi c nh. Riỏng chn Top-3 mũ hnh thnh phn vò cp phng phòp a vò kim nh, tp train c tòch tip 80/20 thnh base-train (hun luyñ mũ hnh c s) vò validation (chn im chn lc); ngng cng bt thng c chn trỏn 10% lu lng benign ca tp train ($seed=42$). Tp test khng tham gia bt k khóu la chn nò.

3.2 La chn c trng vò gim chiu d liu

Trong quò trnh tin x lý d liu cho bị toòn phòt hin xóm nhp mng, la chn c trng bao gm **chn c trng vò trỏch xut c trng** lỳ mt bc quan trng nhm gim chiu d liu, loi b nhng c trng khng cn thit, vò ci thn hiu nng ca mũ hnh hc mỳy [57]. D liu s c gom vò vector c trng bng VectorAssembler (khong 78 c trng s trc khi loi cng; s c trng chỏnh xỏc sau khi loi destination_port/source_port lỳ 77) vò c chun húa bng StandardScaler (chun húa Z-score). Ba phng phòp c s dng trong lun vn lỳ RF, SHAP vò PCA.

- a) **Principal Component Analysis (PCA)**: Lỳ phng phòp gim chiu d liu khng giòm sòt, nhm bin i tp c trng ban u thnh mt tp còc thnh phn chỏnh (principal components) mi khng tng quan tuyñ tỏnh vò nhau vò gi li phn ln phng sai ca d liu. PCA thc hin bng còch tỏnh ma trn hip phng sai vò tỏm còc vector riỏng (eigenvectors) tng ng vò còc giò tr riỏng (eigenvalues). Còc thnh phn chỏnh c xỏc nh bng còch giò bị toòn:

$$Cv = \lambda v \quad (3.1)$$

Trong ú:

- C lỳ ma trn hip phng sai ca d liu.
- v lỳ vector riỏng (principal component).

- λ lị giờ tr riống, biu th lng phng sai c gii thờch.

Còc thịnh phn chờnh cú giờ tr riống ln nht s c la chn to thịnh khũng gian c trng mi vì s chiu thp hn nhng vn gi c phn ln thũng tin ca d liu. óy lị phng phòp c s dng ph bin trong phón tồch d liu a bin vị hc mỳy gim chiu, loi b nhiu vị trc quan hóa d liu [58].

- b) **SHapley Additive exPlanations (SHAP)**: Lị phng phòp gii thờch mũ hnh đa trổn lý thuyt trũ chi, dũng o lng mc úng gúp ca tng c trng vộ d oòn ca mũ hnh. SHAP tồnh giờ tr Shapley cho mi c trng bng còch xỏt trung bnh úng gúp biổn ca c trng ú trổn tt c còc tp con cú th:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)] \quad (3.2)$$

Trong ú:

- F lị tp tt c còc c trng.
- S lị tp con ca còc c trng khũng cha i .
- $f(S)$ lị giờ tr d oòn ca mũ hnh khi ch s dng tp c trng S .
- ϕ_i lị mc úng gúp ca c trng i vộ kt qu d oòn.

Còc c trng cú giờ tr SHAP ln (theo ln tuyt i) c xem lị cú nh hng quan trng hn n quytnh ca mũ hnh. Phng phòp nịy c ng dng rng rỏi trong gii thờch mũ hnh phc tp nh XGBoost, Random Forest, vị mng n-ron [59].

- c) **Random Forest Feature Importance**: Thut toòn RF cú kh nng ònh giờ tm quan trng ca tng c trng đa trổn mc úng gúp vộ vic gim bt thun (impurity) ti còc nũt phón chia ca cóy quytnh. quan trng $I(f_j)$ ca c trng f_j c tồnh nh sau:

$$I(f_j) = \frac{1}{T} \sum_{t=1}^T \sum_{n \in N_t(f_j)} \Delta i(n) \quad (3.3)$$

Trong ú:

- T lị s lng cóy trong rng.
- $N_t(f_j)$ lị tp còc nũt trong cóy t s dng c trng f_j phón chia.
- $\Delta i(n)$ lị lng gim bt thun (vờ d: Gini hoc Entropy) ti nũt n .

Còc c trng cú quan trng cao hn s c u tiõn la chn a vïo mĩ hnh hun luyn. Sau khi hun luyn mĩ hnh RF, còc c trng cú giò tr quan trng thp hn mt ngng nh trc s b loi b, gi li nhng c trng cú nh hng ln n vic phón loi.

3.3 Hun luyn mĩ hnh

3.3.1 Hun luyn còc mĩ hnh c s

Tòm thut toøn phón loi cú giòm sòt c hun luyn c lp trõn tp c trng ò qua bc xóy dng vï la chn c trng. Bng 3.3 lit kổ còc thut toøn cng thũng tin chi tit v bin th vï phng phòp hc.

Bng 3.3. Tòm b phón loi c s c s dng trong pipeline

Thut toøn	Bin th / Ghi chũ	Phng phòp hc
Decision Tree	CART	Phón chia quy theo Gini / Entropy
Logistic Regression	Chun hóa L2	Ti u hịm mt môt logistic
Linear SVM	SVC tuyn tồnh	Ti a hóa biõn phón loi
Naive Bayes	Phón phi Gaussian	c lng xòc sut hu nhim
Random Forest	Bagging	T hp cóy quy nh ngu nhĩõn
GBT	Gradient Boosting	Ti thiu hóa hịm mt môt theo gradient
XGBoost	Gradient Boosting ti u	Regularised Gradient Boosting
MLP	Mng n-ron nhón to	Lan truyn ngc (Backpropagation)

òng lu ý, LightGBM (mt th vin gradient boosting ph bin) *khũng* c a vïo danh sòch trõn vò th vin gc (native, thũng qua SynapseML) ch h tr kin trũc x86_64, khũng chy c trõn thit b biõn Jetson Orin Nano Super (ARM64), vn lĩ mc tiõu trin khai ca nghiõn cu; XGBoost vï GBT ò i din y cho h gradient boosting.

X lý mt cón bng lp. Do t l Benign/Attack lch nhau òng k, sòu mĩ hnh MLlib (Decision Tree, Logistic Regression, Linear SVC, Random Forest, GBT, Naive Bayes) c hun luyn vï trng s lp (`weightCol`) t theo t l nghch ca tn sut lp benign/attack; XGBoost dũng tham s `scale_pos_weight` vï vai trò tng ng. Riõng MLP lĩ ngoi l khũng òp trng s lp do API `MultilayerPerceptronClassifier` ca Spark MLlib khũng h tr `weightCol`.

Sau khi hun luyn, tòu mĩ hnh c xp hng theo chiu gim dn ca F1-Score trõn tp kim nh (validation, tòch t tp hun luyn, xem mc Phón chia tp d liu) xòc nh top-3 mĩ hnh tt nht phc v bc kt hp ensemble tip theo; tp kim tra hoịn toịn khũng c s dng bc chn mĩ hnh nịy nhm trõnh rừ r chn lc (selection leakage).

3.3.2 Còc phng phòp Ensemble Learning

Bng 3.4. Còc phng phòp hc t hp (ensemble) s dng trong lun vn

Phng phòp	Mũ t chỉ tit
Hybrid Bagging	Top-3 mũ hnh kt hp theo s (3-2-2) sub-samples vì <i>Weighted Soft Voting</i> d oòn xòc sut cú trng s
Soft Voting	Trung bnh xòc sut Top-3 mũ hnh theo F1-Score Nhõn <i>Attack</i> nu xòc sut trung bnh $\geq 0,5$

a) Òp dng Voting

Sau khi hoịn tt giai on hun luy n mũ hnh, lun vn tin hnh xóy dng mũ hnh ensemble da trõn k thut Voting nóng cao chõnh xòc vị tõnh n nh ca h thng phón loi; hai phng phòp t hp c s dng c túm tt trong Bng 3.4. C th, ba mũ hnh phón loi nh phón cú ch s F1-Score cao nh t giai on trc s c la chn tham gia vò quò trõnh ensemble.

Mi mũ hnh trong tp c chn s a ra d oòn c lp cho tng mu trong tp kim tra. Còc d oòn nìy sau ú c tng hp thũng qua c ch bu chn. Trong trng hp Soft Voting, xòc sut d oòn lp *Attack* ca còc mũ hnh thnh phn c ly trung bnh; mu c gòn nhõn *Attack* nu xòc sut trung bnh t t 0,5 tr lỏn, ngc li c gòn nhõn *Benign*.

Vic òp dng k thut Voting cho phỏp khai thỏc s a dng gia còc mũ hnh hc c s, t ú gim sai s do thiỏn lch ca tng mũ hnh riỏng l vị ci thfin kh nng tng quò húa trõn d liu cha tng thy. Nh c ch kt hp nìy, h thng cú th nóng cao hiu nng tng th trong vic phòt hin vị phón loi chõnh xòc còc hnh vì xóm nhp mng. Quy trõnh chỉ tit c trõnh bỳ trong Thut toà 5.

Thut toòn 5. Thut toòn Soft Voting Ensemble

u vò: Tp d liu hun luy $D = \{(x_i, y_i)\}_{i=1}^n$ vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$
 Tp kim nh D_{val} (tòch t D , đứng xp hng vị chn mũ hnh thịnh phn)
 Tp d liu kim tra $D_{\text{test}} = \{(x_j)\}_{j=1}^m$
 Tp K thut toòn hc c s khòc loi $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

u ra: Nhòn d oòn cui cúng $y_{\text{vote}} \in \{0, 1\}$ cho mi mu

- 1: **Bc 1: Hun luy vi ònh giò K mũ hnh c s**
- 2: **for** $k = 1$ to K **do**
- 3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Hun luy trỏn phn train lủi, tòch khi D_{val}
- 4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tònh im F1 trỏn tp kim nh (validation), khũng chm tp kim tra
- 5: **end for**
- 6: **Bc 2: Chn Top-3 mũ hnh cú F1 cao nht**
- 7: Sp xp $\{M_1, \dots, M_K\}$ theo F_k gim dn
- 8: Chn 3 mũ hnh tt nht: $\mathcal{S} = \{M^{(1)}, M^{(2)}, M^{(3)}\}$ vi $F^{(1)} \geq F^{(2)} \geq F^{(3)}$
- 9: **Bc 3: Thu thp xòc sut d oòn t 3 mũ hnh c chn**
- 10: **for** mi mu $x_j \in D_{\text{test}}$ **do**
- 11: **for** mi $M^{(s)} \in \mathcal{S}$, $s = 1, 2, 3$ **do**
- 12: $p_s^{(j)} \leftarrow P^{(s)}(y = 1 \mid x_j)$ ▷ Xòc sut lp Attack t mũ hnh $M^{(s)}$
- 13: **end for**
- 14: **end for**
- 15: **Bc 4: Kt hp bng bu chn mm (Soft Voting)**
- 16: **for** mi mu $x_j \in D_{\text{test}}$ **do**
- 17: $\bar{p}_j \leftarrow \frac{1}{3} \sum_{s=1}^3 p_s^{(j)}$ ▷ Trung bnh xòc sut lp Attack
- 18: **if** $\bar{p}_j \geq 0.5$ **then**
- 19: $y_{\text{vote}}^{(j)} \leftarrow 1$ ▷ D oòn: Attack
- 20: **else**
- 21: $y_{\text{vote}}^{(j)} \leftarrow 0$ ▷ D oòn: Benign
- 22: **end if**
- 23: **end for**
- 24: **return** $\{y_{\text{vote}}^{(j)}\}_{j=1}^m$

b) Òp dng Bagging

khai thòc hieu qu sc mn timer ca k thut hc t hp Bagging, lun vn xut xóy dng mt mĩ hnh ensemble lai (Hybrid Bagging Ensemble) da trón còc mĩ hnh c s cú hieu nng cao nht (õ hun luyn vị xp hng bc trc). C th, thay vớ ch s dng mt mĩ hnh n l, quy trnh bt u bng vic hun luyn vị ònh giò K thut toản hc c s trón tp d liu hun luyn D . Hieu nng ca tng mĩ hnh c o lng thng qua ch s F1-Score, t ú la chn ba mĩ hnh cú kt qu tt nht a vịo giai on kt hp.

Sau khi xòc nh Top-3 mĩ hnh, phng phòp Bagging c òp dng theo phón b s bn sao (3, 2, 2). i vì mi mĩ hnh trong ba mĩ hnh c chn, nhieu tp d liu bootstrap c to ra bng còch ly mu ngu nhón cú hoĩn li t tp hun luyn ban u. Trón mi tp bootstrap nìy, mt bn sao ca mĩ hnh tng ng c hun luyn c lp, to thnh còc *b hc c s* (*base learners*) trong ensemble. Mi base learner c gòn trng s t l vì F1-Score ca mĩ hnh gc nhm phn ònh mc tin cy tng i ca nú trong quò trnh tng hp. Vic phón b bt i xng (3, 2, 2), tc cp nhieu bn sao bootstrap hn cho mĩ hnh hng cao, lị mt la chn thit k thc nghim nhm thón ensemble v phòc còc b hc mn timer hn trong khi vn gi tòn timer a dng t ba thut toản khòc loi; óy lị mt heuristic, khng phi kt qu ca ti u hóa lý thuyt, vị còc t l khòc (chng hn 3-3-3) cú th c kho sòt trong nghiỏn cu tip theo.

Trong giai on d oản, toĩn b còc mĩ hnh trong ensemble a ra phón phi xòc sut d oản cho mu u vịo mi. Kt qu cui cng c xòc nh thng qua c ch Soft Voting cú trng s, trong ú xòc sut ca tng lp c tòn timer bng tng cú trng s ca còc xòc sut thnh phn. Nhón d oản cui cng c chn lị lp cú xòc sut tng hp ln nht.

Còch tip cn nìy cho phỏp gim phng sai ca còc mĩ hnh c s nh c ch ly mu bootstrap, ng thi duy trớ kh nng hc biu din ca tng thut toản riỏng l. Vic kt hp chn lc còc mĩ hnh cú hieu nng cao nht trc khi òp dng Bagging giữp ti u hóa c chònh xòc vị tòn timer n nh ca h thng. Chi tit quy trnh c trnh bỳy trong Thut toản 6.

Thut toàon 6. Thut toàon Hybrid Bagging Ensemble Learning

u vò: Tp d liu hun luy n $D = \{(x_i, y_i)\}_{i=1}^n$ vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (BENIGN = 0, Attack = 1)

 Tp kim nh D_{val} (tòch t D , dúng xp hng vị chn Top-3)

 Tp K thut toàon hc c s $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

 Phón b s bn sao $\mathbf{r} = (r_1, r_2, r_3) = (3, 2, 2)$

u ra: Nhón d oòn cui cúng $y_{\text{bag}} \in \{0, 1\}$

1: **Bc 1: Hun luy n vị ònh giò K mữ hnh c s**

2: **for** $k = 1$ to K **do**

3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Hun luy n trón phn train lủi, tòch khi D_{val}

4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tònh im F1 trón tp kim nh (validation), khũng chm tp kim tra

5: **end for**

6: **Bc 2: Chn Top-3 mữ hnh cú F1 cao nh**

7: Sp xp $\{M_1, \dots, M_K\}$ theo F_k gim dn

8: Chn 3 mữ hnh tt nh: $M^{(1)}, M^{(2)}, M^{(3)}$ vi $F^{(1)} \geq F^{(2)} \geq F^{(3)}$

9: **Bc 3: To ensemble theo phón b 3-2-2**

10: $\mathcal{E} \leftarrow \emptyset$ ▷ Tp ensemble gm 7 mữ hnh

11: **for** $j = 1$ to 3 **do**

12: **for** $i = 1$ to r_j **do**

13: To tp bootstrap $D_{j,i}$ bng còch ly ngu nhĩn n mu t $D \setminus D_{\text{val}}$ **cú hoị li**

14: $h_{j,i} \leftarrow \text{Train}(\mathcal{L}^{(j)}, D_{j,i})$ ▷ Hun luy n bn sao th i ca mữ hnh hng j

15: Gòn trng s $w_{j,i} \leftarrow F^{(j)}$ ▷ Trng s da trón F1-Score

16: Thỏm $(h_{j,i}, w_{j,i})$ vò $\mathcal{E}$

17: **end for**

18: **end for**

19: Chun húa trng s: $w_{j,i} \leftarrow \frac{w_{j,i}}{\sum_{(h,w) \in \mathcal{E}} w}$

20: **Bc 4: D oòn cho mu mĩ x (Soft Voting cú trng s)**

21: $T \leftarrow |\mathcal{E}| = 7$ ▷ Tng s mữ hnh trong ensemble

22: **for** mĩ $(h_t, w_t) \in \mathcal{E}$, $t = 1, \dots, T$ **do**

23: $\mathbf{p}_t \leftarrow h_t(x)$ ▷ Ly vector xòc sut d oòn

24: **end for**

25: Tònh xòc sut cú trng s: $\bar{p}(c | x) = \sum_{t=1}^T w_t \cdot P_t(c | x), \quad \forall c \in \{0, 1\}$

26: $y_{\text{bag}} \leftarrow \arg \max_{c \in \{0,1\}} \bar{p}(c | x)$

27: **return** y_{bag}

3.4 ònh giò mĩ hnh

Mĩ mĩ hnh (c s vị ensemble) c ònh giò toịn din trồn bn chiu:

Bng 3.5. Còc tiỏu chừ ònh giò mĩ hnh

Tiỏu chừ	Mĩ t
chờnh xỏc (Accuracy)	T l d oòn ỹng trồn toịn b mu kim tra
Precision	T l cnh bở ỹng trong tng s cnh bở c phỏt ra
Recall	T l phỏt hin ỹng trong tng s mu tn cũng thc t
F1-Score	Trung bnh iu hủa ca Precision vị Recall
Area Under the Curve Receiver Operating Characteristic	Din tồch dĩ ng cong ROC o hủu nng phỏn bit lp
Area Under the Curve PR	Din tồch dĩ ng cong Precision-Recall
Chi phở tồnh toòn	Thi gian hun luy, thi gian d oòn vị kỏch thc mĩ hnh
Kh nng gii thờch (Explainable Artificial Intelligence)	Biu SHAP: summary plot, bar chart vị waterfall plot

Hủu nng ca mĩ hnh c ònh giò thũng qua còc ch s phỏn loi ph bin nh Accuracy, Precision, Recall vị F1-Score, kt hp vị phỏn tồch ng cong AUC (ROC vị PR), chi phở tồnh toòn (thi gian hun luy vị suy lun), cng nh kh nng gii thờch ca mĩ hnh (vở dĩ: biu tng quan SHAP); còc tiỏu chừ ònh giò c tng hp trong Bng 3.5. kim chng mĩ hnh phỏt hin xỏm nhp, tp dĩ liu kim tra c s dng nhm ònh giò kh nng tng quỏt hủa ca mĩ hnh õ hun luy, trong ú kt qu dĩ oòn c i chiu vị nhõn thc t vị o lng bng còc thc o ònh giò. Còc ch s nh accuracy (AC), precision (PR), recall (RE), F1-score (FS) c tồnh toòn theo còc cũng thc (3.4), (3.5), (3.6) vị (3.7). Nhng kt qu nỳy lĩ c s quan trng so sỏnh gia còc phng phỏp la chn c trng vị la chn mĩ hnh phứ hp cho trin khai thc t.

$$\text{Accuracy (AC)} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.4)$$

$$\text{Precision (PR)} = \frac{TP}{TP + FP} \quad (3.5)$$

$$\text{Recall (RE)} = \frac{TP}{TP + FN} \quad (3.6)$$

$$F1\text{-Score (FS)} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.7)$$

Còc i lng TP, FP, FN, TN đứng trong còc cũng thc trỏn c minh ha qua ma trn nhm ln Bng 3.6.

Bng 3.6. Ma trn nhm ln ca mũ hnh phòt hin xóm nhp

	D oàn: Positive	D oàn: Negative
Thc t: Positive	TP (True Positive)	FN (False Negative)
Thc t: Negative	FP (False Positive)	TN (True Negative)

Trong ú, TP (True Positive) l s lng lu lng mng hoc phiỏn kt ni thc s l t n cũng v i c h thng IDS phòt hin ửng l xóm nhp. TN (True Negative) l nhng lu lng bớnh thng (khũng phi t n cũng) v i c mũ hnh phón loi chớnh xỏc l hp l. FP (False Positive) l còc lu lng bớnh thng nhng b h thng nhn din nhm l t n cũng. Ngc li, FN (False Negative) l nhng cuc t n cũng thc s xy ra nhng khũng c h thng phòt hin v i b phón loi nhm l lu lng bớnh thng.

3.5 Tí u hóa tham s vị hun luyn mĩ hnh

Trong quò trnh xóy dng mĩ hnh hc mỳ, vic la chn còc siỏu tham s (hyperparameters) phứ hp li mt yu t quan trng nh hng n hiu nng ca mĩ hnh. tí u hóa còc siỏu tham s nỳ, phng phòp **Tỏm kim theo li** (Grid Search (GS)) kt hp vi **Cross-Validation (CV)** ỏ c s dng trong mũ trng phón tòn ca Apache Spark. Còc mĩ hnh phón loi c hun luyn vị so sòngh gm: Decision Tree, Logistic Regression, Linear SVC, Naive Bayes, Random Forest, GBT, XGBoost vị MLP; sau ú xp hng theo F1-Score chn Top-3 mĩ hnh cho còc phng phòp ensemble.

- **GS**: Li phng phòp th nghim tt c còc t hp cú th ca còc siỏu tham s c nh ngha trc. Vở d, vị mt mĩ hnh Random Forest, còc tham s cú th bao gm s lng cóy (numTrees), sỏu tỉ a (maxDepth), vị chin lc chn tp con c trng tỉ mĩ nũt (featureSubsetStrategy). Spark MLlib h tr i tng ParamGridBuilder xóy dng li còc tham s.
- **CV**: Li phng phòp ònh giò mĩ hnh bng còch chia d liu hun luyn thnh k phn, sau ú hun luyn vị ònh giò mĩ hnh k ln, mĩ ln s dng mt phn khỏc nhau lỳm d liu kim tra vị còc phn cùn li lỳm d liu hun luyn. Trong Spark, i tng CrossValidator c s dng thc hìn quy trnh nỳ.

Quy trnh tí u hóa c thc hìn nh sau:

1. Xóy dng pipeline gm còc bc tin x lý d liu (vở d: chun hóa, bin i c trng) vị mĩ hnh hc mỳ.
2. S dng ParamGridBuilder nh ngha tp li còc siỏu tham s cn tỏm kim.
3. Khi to CrossValidator vị pipeline, li còc tham s, vị b ònh giò hiu nng (vở d: BinaryClassificationEvaluator).
4. Hun luyn mĩ hnh bng còch gĩ phng thc fit () ca CrossValidator trởn tp d liu hun luyn.
5. Chn mĩ hnh tt nht da trởn im ònh giò trung bnh trởn còc folds.

Vở d on mỗ s dng Spark MLlib:

```
from pyspark.ml.classification import RandomForestClassifier
from pyspark.ml.evaluation import BinaryClassificationEvaluator
```

```
from pyspark.ml.tuning import CrossValidator, ParamGridBuilder
from pyspark.ml import Pipeline

rf = RandomForestClassifier(labelCol="label", featuresCol="
    features")

pipeline = Pipeline(stages=[rf])

paramGrid = ParamGridBuilder() \
    .addGrid(rf.numTrees, [10, 20, 50]) \
    .addGrid(rf.maxDepth, [5, 10, 15]) \
    .build()

evaluator = BinaryClassificationEvaluator(labelCol="label",
    metricName="areaUnderPR")

cv = CrossValidator(estimator=pipeline,
                    estimatorParamMaps=paramGrid,
                    evaluator=evaluator,
                    numFolds=5)

cvModel = cv.fit(trainingData)
```

Quy trnh nỳ giúp m bo la chn c t hp siu tham s ti u, ng thi giúp ti u thi gian hun lun.
Spark giúp tng tc quò trnh nỳ nh kh nng x lý phón tòn vị song song hóa trón cm mỳ.

3.6 Trin khai biễn

Mũ hnh tt nht sau ònh giò c úng gúi thnh `PipelineModel` vị trin khai trởn mt cm hai thit b biễn NVIDIA Jetson Orin Nano Super (CPU ARM 64-bit + GPU NVIDIA), tòch vai trò: Jetson #1 chy cng phòt hìn bt thng (autoencoder) lc lu lng bnh thng, Jetson #2 chy b phón loi PySpark trởn còc lung nghi vn. Mũ hnh sau khi hun luyt trởn cm c chuyn sang thit b biễn bng Secure Copy Protocol (SCP). Quy trnh suy lun thi gian thc theo chui: Kafka Consumer nhn d liu mng (topic `ids-network-flow`), cng bt thng chuyn tip lung nghi vn sang `ids-suspicious-flow`, PySpark Streaming (micro-batch) x lý vị trỏch xut c trng, kt qu d òn ghi vño PostgreSQL phc v trc quan hóa trởn Grafana vị kỏch hot cnh bòa khi phòt hìn bt thng. H thng h tr ba ch : tòch pipeline (pipeline split), m rng theo chiu ngang (horizontal scaling) vị cm Spark (Spark cluster). Thũng s phn cng chi tit ca thit b biễn c trnh bñ trong Bng 3.7.

Bng 3.7. Thũng s phn cng thit b biễn

Thuc tỏnh	Giò tr
Nn tng	NVIDIA Jetson Orin Nano Super Developer Kit (×2)
CPU	6 nhón Arm Cortex-A78AE, 1,7 GHz
GPU	NVIDIA Ampere, 1024 nhón CUDA + 32 Tensor Core
RAM	8 GB LPDDR5 (102 GB/s)
Lu tr	SSD NVMe 256 GB
Hiu nng AI	ti ~67 TOPS (khung 25 W)
H iu hnh	Ubuntu (NVIDIA JetPack / L4T)
Vai trò	Worker hun luyt (Spark) & thit b suy lun biễn

Chng 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Trong chng nìy, lun vn trnh bñy kt qu t c khi òp dng k thut la chn c trng hun lun c òc mĩ hnh hc mỳy. Bñn cnh ú, quy trnh tinh chnh siũ tham s bng tĩm kim li kt hp kim nh chũo (cross-validation) cng c trnh bñy, cũng vi ònh giò kt qu thc nghim khi òp dng c òc thut toøn hc mỳy nh SVM, LR, NB, RF, DT, GBT, XGB vñ MLP c trong trng hp cú vñ khũng s dng k thut gim chiu d liu. Ngoi ra, lun vn cng xĩc nh vñ trnh bñy c òc giò tr tham s ti u cho tng thut toøn thũng qua phng phĩp tĩm kim theo li kt hp vi kim nh chũo (cross-validation). Da trĩn c òc kt qu thu c, lun vn s lĩm rũ vn liu vic gim chiu d liu cú thc s cn thĩt hay khũng. Cui cũng, lun vn ònh giò hĩu qu ca c òc mĩ hnh EL, sau ú so sũnh vi c òc thut toøn hc mỳy truy n thng, t ú tr li cúu hi: *Lũu cú nĩn s dng EL so vi c òc mĩ hnh hc mỳy truy n thng khi lĩm vic vi d liu IoT hay khũng?*


4.1 Mũ trng thc nghim

Vic hun lun mĩ hnh c thc hĩn trĩn mt cm **Apache Spark Standalone** phĩn tĩn gm mt mỳy ch vñ **hai thĩt b bĩn NVIDIA Jetson Orin Nano Super Developer Kit**. im òng cũũ y li cũng mt cp Jetson va úng vai trũ *worker* ca cm Spark trong pha hun lun, va li thĩt b *trĩn khai* trong pha suy lun thi gian thc (Hĩnh 4.5), giũp kim chng tĩnh kh thi ca toĩn b pipeline trĩn ỹng phĩn cng mc tiũ.

- **Mỳy ch (Spark master):** mỳy tĩnh xĩch tay MacBook Air, vi x lý Apple M3, RAM 16 GB, macOS Sonoma 14.3; m nhĩn iu phi cm (master), tin x lý d liu thũ (t CSV sang Parquet) vñ chũ h tng Docker (Kafka, PostgreSQL, InfluxDB, Grafana).
- **Hai nũt worker:** **NVIDIA Jetson Orin Nano Super Developer Kit**; cũ hĩnh cũ tit (CPU/GPU/RAM/lu tr) nĩũ ti Bng 3.7, Chng 3; h iu hĩnh Ubuntu (NVIDIA Jet-Pack/L4T). Jetson #1 ng thi chũ tin trnh *driver* ca Spark (driver li tin trnh iu khĩn ng dng, khĩc vi vai trũ *master* iu phi cm ca MacBook).
- **Phĩn mm:** Python 3, Apache Spark / PySpark 3.4.1, MLlib; cũ hĩnh cm tiũ bĩu: `executor.memory=3 GB`, `executor.cores=4`, `driver.memory=3 GB`, `shuffle.partitions=32`; mi Jetson c cp 8 GB swap trĩn NVMe trĩnh trĩn b nh khi cao im (xem `cluster/spark_cluster.env`, `cluster/setup_swap_jetson.sh`).

Cờ thủ toàn hệ máy, phân phối giảm chi phí cờ bộ đồng giờ và triển khai bằng PySpark vị thế thì phân bổ toàn phần hai nút Jetson; tiếp đó lưu Parquet về máy và sang các hai worker trực khi huấn luyện. Kiến trúc cơ bản huấn luyện phân bổ (gồm vai trò *master* lưu phi phần MacBook vị hai *worker/executor* phần Jetson) có minh họa Hình 4.1. Các phân bổ rủi ro vị Hình 4.5 (phân suy luận): cũng một cặp Jetson nhưng phân huấn luyện ứng vai trò worker của cơ bản Spark, cùng phân suy luận ứng vai trò cổng (gate) vị bộ phân lỗi.

Cn nhn mnh rng mỳ ch MacBook ch m nhn vai trũ *master* iu phi cm cũng tin x lý vị h tng dch v, mị *khũng* tham gia tồnh toành hun luyn (khũng chy *executor*). La chn nịy lị cú ch òch: toịn b s liu hiu nng c bõo cõo nhm phn ònh trung thc kh nng *hun luyn phõn tòn ngay trõn phn cng biõn* Jetson, ỹng vi mc tiõu ct lũĩ ca lun vn. Nu a MacBook (vi x lý Apple M3, mnh hn òng k) vĩa lĩm nũt tồnh toành, phn ln khi lng cũng vic s dn v mỳ ch, gĩa mt cõn bng ti (hin tng *straggler*) vĩa lĩm sai lch cõc phõp o thi gian/thũng lng, khĩn kt qu khũng cùn phn ònh ỹng nng lc ca cm biõn. Vĩ vỹ, cm o c c gĩ *ng nht* gm hai nũt Jetson; mỳ ch ch c dũng phõt trin vi kim th nhanh trong giai õn xõy dng pipeline.



Hình 4.1. Cm hun luy n ph n t n Apache Spark Standalone: MacBook gi vai tr u *master* iu phi (kh n g ch y executor), hai Jetson Orin Nano Super l i *worker/executor* th c thi t n h t n n; d l iu Parquet c ph n v n g v i n g b sang c hai n t t, k t q u c g m v qua shuffle/collect.

4.2 Kt qu thc nghim

Bng 4.1 tóm tt thit lp tham s ca còc mĩ hnh hc mỳ c s dng trong nghiõn cu nỳ. Trong ú, XGB v MLP c tinh chnh bng Grid Search kt hp kim nh chõo (Kch bn 3); còc mĩ hnh cũn li đứng b tham s c nh t trc, la chn đa trõn còc nghiõn cu gn óy vị thc nghim s b, nhm bo m khòc bit quan sòt c gia còc phng phòp gim chiu phn ònh ỹng phng phòp thay vớ mc tinh chnh riõng tng mĩ hnh.

Bng 4.1. Tham s ti u ca còc mĩ hnh hc mỳ

Mĩ hnh	Tham s	Giò tr	Ỗ ngha/Mĩ t
Decision Tree	maxDepth	15	Bt còc mu tn cũng phc tp.
	impurity	entropy	Tiõu chõ chĩa nhõnh ti u.
	minInstancesPerNode	5	S mu ti thiũ ti mi nũt lò.
Logistic Reg.	maxIter	200	m bo hi t trõn tp d liũ ln.
	regParam	0,001	Kim sòt mc iũ chũn (regularization).
	elasticNetParam threshold	0,0 0,5	S dng Ridge (L2) n nh hn. Ngng quy t nh nh phõn.
SVM (LinearSVC)	maxIter regParam	200 0,001	S ln lp ti u hĩa biõn. Tham s iũ chũn biõn quy t nh.
NB	modelType smoothing	gaussian 1,0	Phũ hp cho c trng liõn tc. Lĩm mt Laplace.
Random Forest	numTrees	200	m bo n nh kt qu.
	maxDepth	15	Chiu sỏu ti a ca cỏy rng.
	featureSubsetStrategy	sqrt	Chn c trng ngu nhiõn mi nũt.
GBT	maxIter	150	S vũng boosting ti a.
	maxDepth	6	Chiu sỏu ca cỏc cỏy yũ.
	stepSize	0,05	Tc hc (learning rate) ca boosting.
	subsamplingRate	0,8	T l ly mu d liũ mi vũng boosting.
XGB	n_estimators	300	S lng cỏy boost trong mĩ hnh.
	max_depth	8	Chiu sỏu ti a mi cỏy.
	learning_rate	0,05	Kim sòt mc hc ca cỏy mi.
	subsample	0,8	T l ly mu d liũ mi cỏy.
	colsample_bytree	0,8	T l ly mu c trng mi cỏy.
MLP	layers	[d, 64, 32, 2]	Mng n-ron 2 lp n (d = s c trng u vĩa).
	maxIter	150	S vũng lp hun luyũn ti a.
	stepSize	0,01	Tc hc ca mng n-ron.

4.2.1 Kch bn 1: ònh giò hui nng c s (Baseline)

Trong kch bn này, toin b tp c trng s (khong 78 c trng trc khi loi cng; s chõnh xõc sau khi loi `destination_port/source_port` lĩ 77) c a vĩa mĩ hõnh mĩ cha qua bt k bc la chn c trng hay gim chiu nĩa. Mc tiõu lĩ thĩt lp mt mc hui nng tham chiu cho cõc th nghĩm tĩp theo.

Kt qu hui nng ca cõc thut toin ML n l vĩa phng phõp Ensemble c trõnh bĩa trong Bng 4.2.

Bng 4.2. Kt qu hui nng phõn lp kch bn Baseline (toin b c trng s, ≈ 78 trc khi loi cng)

Thut toin	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9986	0,9925	0,9983	0,9954	0,9994	0,9988
Logistic Regression	0,9288	0,6937	0,9422	0,7991	0,9859	0,9509
SVM (LinearSVC)	0,9199	0,6650	0,9395	0,7788	0,9843	0,9485
NB	0,3163	0,1793	0,9933	0,3038	0,8829	0,6364
Random Forest	0,9985	0,9939	0,9960	0,9949	0,9999	0,9997
GBT	0,9980	0,9900	0,9965	0,9932	0,9998	0,9991
XGB	0,9991	0,9950	0,9993	0,9971	1,0000	0,9999
MLP	0,9900	0,9844	0,9487	0,9662	0,9984	0,9936
Hybrid Bagging	0,9990	0,9950	0,9984	0,9967	1,0000	0,9999
Soft Voting	0,9991	0,9952	0,9985	0,9969	1,0000	0,9999

Vĩ cu hõnh õ loi tr rừ r d liũ, nhũm mĩ hõnh da trõn cõy (Random Forest, XGB, GBT) c k vng dn u, vĩa F1 thp hn mc gn-tuyt-i ca cõc cu hõnh cú rừ r vĩa phn ònh ỹng khũ thc ca bĩa toin; kt lun “mĩ hõnh nĩa tt nht” ch c a ra khi chõnh lch vt khong tin cy (xem mc kim nh thng kõ). Do d liũ mt cõn bng mn, AUC-PR vĩa recall trõn lp tn cũng c u tiõn hn Accuracy khi din gĩa, vĩa Accuracy cú th gĩa lc quan gĩa to (mt mĩ hõnh luĩn oĩn lp benign chim a s vn t Accuracy cao).

4.2.2 Kch bn 2: So sõnh chin lc gim chiu d liũ

Chũng tũĩ thc hĩn so sõnh 3 chin lc chõnh nhm gim s lng c trng nhng vn m bo hui nng:

1. **RF Feature Importance:** Trõch xut 30 c trng cú im s quan trng cao nht t Random Forest.
2. **SHAP Importance:** S dng giò tr Shapley t mĩ hõnh XGB chn ra 30 c trng cú nh hng ln nht.
3. **PCA (k=40):** Gim chiu d liũ t khũng gian c trng gc (≈ 78 chiu trc khi loi cng) xung 40 thĩnh phn chõnh.

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Lu ý rằng PCA đúng $k = 40$ — nhiều hơn 30 c trọng ca RF/SHAP, với ý lý phổ *tròch xut* ch không phi *chn lc*: mi thịnh phần chèn ch lý mt t hp tuyền tòn mang mt phần phng sai, nồn cn nhiều thịnh phần hn gi lng thũng tin (phng sai tòn ly) tng ng vì tp 30 c trọng gc. Trong di quố chung $\{20, 30, 40\}$, $k = 40$ lý mc gi phng sai cao nht, nồn lý im vn hình i din cũng bng nht cho PCA; ốp $k = 30$ s lịm PCA mt thỏm phng sai vị bt li khi so sòn.

Bng 4.3 tóm tt s khòc bit gia còc phng phòp. Mũ hnh i din (ct *Mũ hnh tt nht*) ca mi phng phòp c chn theo F1 trồn tp kim nh (validation) tòn t tp hun luy; tp kim tra không tham gia khòc chn lc nịy. Mc tiỏ lý kim chng gi thuyt: la chn c trọng (RF/SHAP Top-30) gi c hui nng gn vì baseline trong khi gim hn 60% s c trọng, qua ú phứ hp cho trin khai biổn.

Bng 4.3. So sòn hui nng tt nht ca còc phng phòp la chn c trọng vị gim chiu

Phng phòp	S c trọng	Mũ hnh tt nht	F1-Score	Hun luy (s)	Dung lng (MB)
Baseline (Toịn b)	77	XGB	0,9971	4615,5	2,32
RF Importance	30	XGB	0,9922	1295,1	2,52
SHAP Importance	30	XGB	0,9970	1226,1	0,003 [†]
PCA (k=40)	40	XGB	0,9939	1444,8	3,82

Baseline đúng toịn b 77 c trọng s (≈ 78 trc khi loi cng). [†]Khòc thc o bng còch tun t hóa mũ hnh *trổn cm hun luy phón tòn*: bc lu mũ hnh phón tòn ghi còc phón vúng d liu rng còy trồn executor ang gi chửng, nồn giò tr c KB ch bt c metadata cc b trồn driver vị *thp hn thc t*. Vớ dung lng ensemble còy ph thuc s còy vị s nửt (không ph thuc s c trọng u vớ), mũ hnh XGB SHAP Top-30 thc t tng ng bn RF Top-30 ($\approx 2,5$ MB). Cng vớ vy, tp c trọng rửt gn cú th cho mũ hnh *ln hn* baseline mt chửt (2,52 so vì 2,32 MB): ờt ng viổn tòn hn khin còy cn nhiều nửt hn t cứng tnh khit. Phổp o tin cy lý bn mũ hnh xut ra ch n nửt ca pipeline trin khai (Mc kt qu biổn).

Ngoị ra, s so sòn trc tip gia hai phng phòp la chn c trọng da trồn quan trng ca RF vị SHAP c trnh bįy chi tit trong Bng 4.4.

Bng 4.4. So sòn hui nng la chn c trọng: RF Importance vs SHAP Importance (Top-30)

Thut toòn	F1 (RF Top-30)	F1 (SHAP Top-30)	Chổnh lch (%)
Random Forest	0,9879	0,9955	+0,77
XGB	0,9922	0,9970	+0,48
GBT	0,9844	0,9918	+0,75
Decision Tree	0,9835	0,9948	+1,15

4.2.3 Kch bn 3: Ti u hóa tham s

Sau khi chn c b c trọng ti u t SHAP, bn mũ hnh Spark ML gc (Random Forest, Decision Tree, GBT, Logistic Regression) c tnh chnh tham s thũng qua Grid Search kt hp Cross-validation trồn tp c trọng SHAP Top-30; còc mũ hnh cùn li (XGB, MLP, SVM, NB) gi

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

nguồn b tham s c nh Bng 4.1 (xem lý do u mc). Vic tinh chnh giúp còc mữ hnh cóy t F1 quanh mc 0,995 (Bng 4.5); mc ci thín so vì cu hnh c nh lĩ nh do bị toản nh phón trong-min ò gn bão hòa, phú hp vì nhn nh mc kim nh thng kỏ.

Kt qu hiu nng ca phng phòp Ti u hóa tham s c trnh bịy trong Bng 4.5.

Bng 4.5. Kt qu hiu nng phón lp kch bn Ti u hóa tham s

Thut toản	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9987	0,9977	0,9936	0,9957	0,9994	0,9980
Logistic Regression	0,9541	0,9787	0,7094	0,8226	0,9749	0,9371
SVM (LinearSVC)	gi cu hnh c nh (xem Bng 4.2)					
NB	gi cu hnh c nh (xem Bng 4.2)					
Random Forest	0,9986	0,9985	0,9922	0,9953	0,9999	0,9997
GBT	0,9985	0,9979	0,9924	0,9951	0,9999	0,9993
XGB	gi cu hnh c nh (xem Bng 4.2)					
MLP	gi cu hnh c nh (xem Bng 4.2)					
Hybrid Bagging	0,9986	0,9956	0,9949	0,9953	0,9999	0,9998
Soft Voting	0,9988	0,9985	0,9932	0,9958	1,0000	0,9998

4.2.4 Phón tồch kh nng gii thồch vì SHAP

Tồnh gii thồch (explainability) lĩ mt thính phn thit yu trong h thng IDS, nhm cung cp c s cho vic xóy dng nim tin vị h tr vn hnh thc t. Trong nghiỏn cu nịy, phng phòp SHAP (SHapley Additive exPlanations) c s dng phón tồch mc quan trng ca tng c trng i vì quyt nh phón loi ca mữ hnh XGB.

Hnh 4.2 xp hng 30 c trng quan trng nht theo giò tr trung bnh tuyt i ca SHAP (mean |SHAP|): thanh cịng dịi, c trng cịng nh hng ln n quyt nh phón loi xỏt trỏn toịn b mu. trỏnh rừ r, giò tr SHAP c tồnh trỏn mt *mu phón tng theo lp ly t tp hun luyn* (khũng phi tp kim tra); mu nịy c bin i qua ỹng b chun hóa (StandardScaler) ò fit trỏn tp hun luyn trc khi tồnh SHAP, bo m khũng gian u vọ ca phỏp gii thồch trúng khp vì khũng gian u vọ mị mữ hnh ò hc.

B sung cho xp hng tng th, Hnh 4.3 trnh bịy biu SHAP Summary dng beeswarm: mĩ im i din cho mt quan sỏt; trc hoịnh th hín giò tr SHAP (dng y d òòn v lp tn cũng, óm y v lp bnh thng); mịu sc biu din giò tr c trng t thp n cao. phón tòn theo trc hoịnh phn ònh mc nh hng ca c trng, tp trung th hín tồnh n nh ca tồc ng.

Bổn cnh ú, giò tr trung bnh tuyt i ca SHAP (mean |SHAP|) c dứng xp hng mc quan

trng tng th. Trón tp c trng ò loi tr rù r, còc c trng cú mean |SHAP| ln nht li: bwd_packet_length_std, init_win_bytes_backward, init_win_bytes_forward v bwd_packet_length_mean.

Còc c trng nh init_win_bytes_forward, init_win_bytes_backward (kòch thc ca s TCP giai on khi to) v bwd_packet_length_std, packet_length_std (s bin thiỏn ãi gói tin) phn ònh c tòn phón phi lu lng li còc tòn hiu mng cú ý ngha, khñng ph thuc vò nh danh dch v. Vic loi destination_port buc mũ hnh ãa vò còc c trng hnh vi nỳ thay vò ghi nh ònh x cng → nhñn.

4.2.5 Phón tồch rù r ã liu (data leakage)

c trng destination_port li mt ngun rù r nhñn tìm tñg trón CICIDS2017: mi loi tn cũng c sinh nhm vò nhng cng dch v c nh nỏn cng òch tng quan mn nhñn, khñn mũ hnh ã “ghi nh” ònh x cng–nhñn thay vò hc hnh vi lung. Engelen v cng s [60] xp hñn tng nỳ vò nhúm *shortcut learning* ca CICIDS2017: còc thuc tòn nh danh (Flow ID, a ch IP, cng ngun, nhñn thi gian) phi b loi khi biu ãin c trng, cùn riỏng vic ãng cng òch lĩm c trng cho IDS thờ còc tòc gi xem li *cùn góy tranh cõi*. nh lng nh hng, lun vn thc hñn phón tồch loi b (ablation) gi/loi cng vi cũng mt cu hnh Random Forest c nh (Bng 4.6). iu òng lu ý li vi bị toàn nh *phón trong-min*, sau khi ò loi trũng lp lung mc c trng, nh hng riỏng ca destination_port lỏn F1 ch cùn nh (chỏnh khong 0,001 im F1), bi tòc v nh phón trón CICIDS2017 vn gn mc bõo hòa v ngun rù r *chi phi* (còc lung trũng lp) ò c x lý trc bng bc loi b trũng lp. iu nỳ *khñng* cú ngha rù r vũ hi: giò tr ca quy trỏnh loi-tr-rù-r th hñn rũ hn ònh giò *a lp* vi còc lp tn cũng him (Mc 4.2.9) v *tng quòt hóa liỏn b ã liu* (Mc 4.2.8.1), ni còc “li tĩ” rù r khñng cùn giũp mũ hnh. Pipeline loi b c destination_port ln source_port; phón tồch ablation tp trung vò destination_port vò óy li cng chi phi.

Bng 4.6. Phón tồch loi b (ablation) rù r: nh hng ca c trng destination_port (Random Forest c nh a priori: numTrees=200, maxDepth=15, cú trng s lp; nh phón)

Cu hnh	F1	Recall (Attack)	AUC-PR
Gi destination_port (rù r)	0,9965	0,9988	0,9999
Loi destination_port (xut)	0,9955	0,9961	0,9997

C hai lt ãng cũng mt cu hnh Random Forest c nh t trc (200 cý, sỏu 15, trng s lp, khp Bng 4.1) cũ lp ửng nh hng ca c trng rù r. Mc chỏnh lch F1 gia hai hñg phn ònh phn hiu nng b thi phng do c trng rù r; óy mc chỏnh nh vò ò loi trũng lp trc vò tòc v nh phón gn

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

bổ hòa, nhng chiu hng (gi cng cho F1/recall cao hn) vn nht quòn vi hin tng rừ r. Mi kt qu khớc trong lun vn đứng cu hính ò loi cng.

4.2.6 Phón tớc hiu nng h thng

Bổ cnh chờnh xớc, hiu nng h thng v thi gian vị tị nguỷn lị yu t then cht cho vic trin khai thc t. Kt qu trong Bng 4.7 cho thy:

Bng 4.7. So sòn thi gian x lý vị kờch thc mữ hính kch bn Baseline

Thut toòn	Hun luyn (s)	D oòn (s)	Kờch thc (MB)
Decision Tree	33,4	6,1	0,0004
Logistic Regression	49,2	5,4	0,009
SVM (LinearSVC)	224,3	5,4	0,002
NB	8,2	5,2	0,012
Random Forest	610,3	18,6	3,69
GBT	1346,8	8,9	0,92
XGB	4615,5	9,0	2,32
MLP	314,7	8,0	0,0004
Hybrid Bagging	11934,5	36,4	7,24
Soft Voting	–	25,6	–

- **Thi gian hun luyn:** Cờc mữ hính Gradient Boosting (GBT, XGB) cú thi gian hun luyn dị nht nhng t kt qu phón loi cao.
- **Thi gian d bờo:** XGB cú thi gian d bờo nhanh (khong 9 giớ cho toịn tp kim tra), Random Forest chm hn (khong 19 giớ); c hai phứ hp cho giòm sòt theo lữ gn thi gian thc.
- **Kờch thc mữ hính:** cờc mữ hính cóy chim dung lng ln hn hn mữ hính tuyt tòn (LR, SVM, NB ch vị KB); RF khong 3,7 MB vị ensemble Hybrid Bagging ln nht (~7,2 MB) do gp nhieu b hc c s. *Lu ý: kờch thc c o bng còch tun t hóa (serialize) PipelineModel ca Spark ra a; giò tr nịy cú th bin thiỏn theo còch phón mnh/-partition khi lu nỏn ch mang tòn thm kho tng i, khững đứng lịm tiỏ chờ quy t nh la chn mữ hính.*

4.2.7 Kim nh ý ngha thng kỏ

Do cờc con s F1 gia nhng phng phỏp/thut toòn hịng u rt sòt nhau, lun vn khững kt lun “mữ hính tt nht” ch da trỏn mt ln o. Mữ hính i đin ca mi phng phỏp, cng nh *cp phng phỏp dn u c*

a vạo kim nh, u c chn theo F1 trón tp kim nh (validation, 20% tồch t tp hun luyn, $seed=42$); tp kim tra khũng tham gia khóu chn lc. Hai phng phòp nỳ sau ú c hun luyn li trón N ln ly mu li tp hun luyn/kim tra (mc nh $N=6$, gộp cp trón cụng mt phỏp chia mi vũng), tồnh F1 trung bớnh kỏm hai loi khong tin cy 95%: khong tin cy t thũng thng vị khong tin cy hũu chnh *Nadeau–Bengio* [61], trong ú phng sai nhón h s $(1/N + n_{\text{test}}/n_{\text{train}})$ bú tng quan gia còc ln ly mu li chng ln; khong *Nadeau–Bengio* c đứng lỳm cn c kt lun chớnh. Ý ngha thng kỏ c kim bng *permutation test gộp cp hai phỏa*, lit kỏ y toỏn b $2^N = 64$ hoỏn v i du (kim nh chớnh xỏc, khũng xp x Monte Carlo), do ú p nh nht kh d lỳ $2/64 \approx 0,031$; ln hũu ng c bỏo cỏo bng Cohen’s d gộp cp (Bng 4.8). Kt lun: chỏnh lch F1 gia Baseline vị SHAP Top-30 cú ý ngha thng kỏ mc sỡn ($p \approx 0,031$, $d \approx 1,94$), nhng khỏc bit tuyt i rt nh ($\approx 0,0001$ im F1) nõn hai phng phòp tng ng v mt thc dng; khi ú tiỏu chớ ph (kh nng gũ thỏch, kỏch thc, chi phỏ biỏn) mi lỳ cn c la chn. Cn tha nhn rng vì $N=6$, kim nh cú lc thng kỏ thp; vớ vy mt giỏ tr p khũng cú ý ngha t nú ch lỳ bng chng yu cho “tng ng”, vị kt lun c cn c ng thi vạo khong tin cy *Nadeau–Bengio* vị Cohen’s d ; tng N (kỏm kim nh chỏo lng) lỳ hng cng c tip theo.

Bng 4.8. n nh qua nhũu ln ly mu vị kim nh gộp cp (t `statistical_validity_multiseed.csv`)

Phng phỏp	Mũ hớnh	F1 (mean $\pm$ CI95 t)	CI95 Nadeau–Bengio	p (gộp cp)	Cohen’s d
Baseline (toỏn b)	XGB	$0,99734 \pm 0,00007$	[0,99722; 0,99746]	0,031	1,94
SHAP Top-30	XGB	$0,99720 \pm 0,00009$	[0,99705; 0,99735]		

4.2.8 Kim tra n nh trong-phón-phi

Mũ hớnh i din ca mi phng phỏp c ònh giỏ li trón mt mu con ca tp kim tra (khũng giao vị tp hun luyn; Bng 4.9). Cn núu rủ: óy ch lỳ phỏp kim tra *n nh cụng phón phi* (in-distribution), khũng phi kim th dch chuyn phón phi; ònh giỏ tng quỏt húa thc s nm thờ nghim liỏn b d liu (Mc 4.2.8.1).

Bng 4.9. Kim tra n nh trong-phón-phi trón mu con tp kim tra (t `robustness_holdout_summary.csv`)

Phng phỏp	Mũ hớnh	F1 (holdout)	AUC-PR
Baseline	XGB	0,9971	0,9999
RF Top-30	XGB	0,9921	0,9998
SHAP Top-30	XGB	0,9969	0,9999
PCA	XGB	0,9939	0,9998

4.2.8.1 Tng quòt hóa liỏn b d liu

ònh giò trỏn tp gi li trỏn lị phỏp th *cứng b* (in-domain, cứng phỏn phi). kim chng kh nng *tng quòt hóa* the s, mũ hỏnh c hun luyn trỏn mt b d liu vị kim tra trỏn b *khỏc* (ònh giò *khỏc b*, cross-dataset; vị ngc li) trỏn tp c trng ỏ loi tr rừ r *chung* ca hai b. Do hai b d liu t tỏn ct khỏc nhau (CSE-CIC-IDS2018 đứg tỏn vit tt kiu CICFlowMeter v3), tỏn ct ca CSE-CIC-IDS2018 c ònh x v tỏn chun ca CICIDS2017 qua mt bng bờ danh (alias) tng minh trong mỗ ngun; danh sỏch c trng chung sau ònh x c lu ti `common_features.txt` bo m tòi lp. Mũ hỏnh đứg cho thờ nghim lị Random Forest cú trng s lp (`weightCol`), nht quòn vị c ch x lý mt cón bng Chng 3. Khong còch gia F1 cứng b vị F1 khỏc b (Bng 4.10) nh lng mc suy gim khi gp dch chuyn phỏn phi, mt thc o n nh cht ch hn holdout cứng phỏn phi.

Do CSE-CIC-IDS2018 [54] cú quy mũ rt ln (~16 triu lung, ~6 GB), vt kh nng x lý thoi mòi ca thit b biỏn Jetson (8 GB), thờ nghim nịy đứg *mu phỏn tng theo nhỏn* ca CSE-CIC-IDS2018 (t l 0,2, ~3,14 triu lung ly mu, cùn ~2,39 triu sau kh trứg lp mc c trng, `seed=42`, cũg tc `IDS_SAMPLE_FRAC`) nhm bo toịn t l còc lp trong khi va vị phn cng; CICIDS2017 đứg ~2,23 triu lung. Toịn b quy trỏnh tin x lý vị cn chnh CSE-CIC-IDS2018 cho thờ nghim liỏn b d liu c trỏnh bịy Thut toòn 7; còc bc loi tr rừ r (giao c trng chung khũng cha cng/IP, kh trứg lp mc c trng) hoịn toịn nht quòn vị quy trỏnh cho CICIDS2017 (Thut toòn 4). Còc con s mu c bờo còo tng minh bo m tởnh tòi lp; vic m rng liỏn toịn b CSE-CIC-IDS2018 lị hng phòt trin tip theo.

Bng 4.10. Tng quòt hóa liỏn b d liu gia CICIDS2017 vị CSE-CIC-IDS2018 (CSE-CIC-IDS2018: mu phỏn tng `seed=42`; t `cross_dataset_results.csv`)

Hun luyn	Kim tra	Loi	F1
CICIDS2017	CICIDS2017	cứng b	0,9952
CICIDS2017	CSE-CIC-IDS2018	khỏc b	0,0423
CSE-CIC-IDS2018	CSE-CIC-IDS2018	cứng b	0,9245
CSE-CIC-IDS2018	CICIDS2017	khỏc b	0,0535

Đin gii. Kt qu cho thy mt tng phn rử rt vị *trung thc*: F1 cứng b rt cao c hai chiu (0,9952 vị 0,9245) nhng F1 khỏc b gim mnh xung 0,04–0,05, ch yu do recall gn bng khũng (0,022 vị 0,030) trong khi precision chiu 2017 sang 2018 vn t 0,596, tc mũ hỏnh gn nh khũng nhn ra tn cũg ca b d liu kia, ch khũng to ra cnh bờo sai trịn lan. Nguyỏn nhón lị *dch chuyn phỏn phi c trng* gia hai testbed: khỏc phiỏn bn CICFlowMeter (thang o vị còch tởnh mt s c trng thay i), khỏc h tng mng vị cu hỏnh dch v, khỏc t hp loi tn cũg (HOIC/LOIC-HTTP ca 2018 khũng cú trong 2017). S st gim nịy nht quòn vị còc nghiỏn cu cross-dataset trỏn

Thut toàn 7. Tin x lý vị cn chnh CSE-CIC-IDS2018 cho ònh giò liồn b d liu

- u vjo:** Tp tp CSV ca CSE-CIC-IDS2018; lc tổnn ct chun ca CICIDS2017 $\mathcal{S}_{2017}$; bng bờ danh tổnn ct $\mathcal{A}$ ($2018 \rightarrow 2017$); t l ly mu $r = 0.2$; $seed = 42$
- u ra:** B d liu D_{2018} trồn tp c trng chung ã loi rừ r $\mathcal{F}_{\text{chung}}$, sn sng cho thờ nghim khòc b
- 1: **Bc 1: Np vị lịm sch** (gng Thut toàn 4)
 - 2: c còc tp CSV; CLEANCOLUMNNAMES; HANDLEINFINITYVALUES; loi null vị bn ghi trúng lp hoịn toịn
 - 3: **Bc 2: Cn chnh tổnn ct**
 - 4: $\forall c \in \text{columns}(D) : c \leftarrow \mathcal{A}(c)$ $\triangleright$ ònh x tổnn ct CICFlowMeter v3 v tổnn chun ca CICIDS2017
 - 5: **Bc 3: To nhõn nh phón (khũng phón bit hoa/thng)**
 - 6: $y_i \leftarrow 0$ nu LOWER(label_i) = “benign”, ngc li $y_i \leftarrow 1$ $\triangleright$ 2018 ghi “Benign”; so khp khũng phón bit hoa/thng
→ **Loi tr rừ r d liu: Bc 4 vị Bc 6**
 - 7: **Bc 4 [loi rừ r – I]: Giao c trng chung, ã loi tr rừ r**
 - 8: $\mathcal{F}_{\text{chung}} \leftarrow (\mathcal{F}_{2017} \cap \mathcal{F}_{2018}) \setminus \mathcal{C}_{\text{exclude}}$ $\triangleright \mathcal{C}_{\text{exclude}}$: destination_port, source_port, protocol, IP, timestamp, flow_id
 - 9: Lu $\mathcal{F}_{\text{chung}}$ vjo common_features.txt $\triangleright$ c nh cho c hai chiu hun luyñ/kim tra
 - 10: **Bc 5: Ly mu phón tng theo nhõn**
 - 11: $D \leftarrow \text{STRATIFIEDSAMPLE}(D, r, seed = 42)$ $\triangleright$ bo toịn t l lp; cùn $\sim 3,14$ triu lung
 - 12: **Bc 6 [loi rừ r – II]: Loi trúng lp mc c trng** (tt nh, nh Bc 4b ca Thut toàn 4)
 - 13: Gom nhúm theo $\mathcal{F}_{\text{chung}}$; loi toịn b nhúm mấu thun nhõn; gi ững mt i ãn ca mi nhúm nht quòn $\triangleright$ cùn $\sim 2,39$ triu lung
 - 14: **return** D_{2018} trồn tp c trng $\mathcal{F}_{\text{chung}}$
-

IDS ãa trồn c trng lung [62, 63, 64], vị chõnh lị lun c mnh nht ca lun vn: *con s trong-min gn hoịn ho (k c khi ã loi rừ r) khũng bo m kh nng trin khai sang mũi trng khòc*; ònh giò liồn b d liu phi lị mt phn bt buc ca quy trõnh kim nh IDS [52], vị còc hng thờch ng min (chun húa theo min, hun luyñ liồn b, cp nht theo drift) lị iu kin tiõn quy cho trin khai thc t.

4.2.9 ònh giò a lp theo loi tn cũng


Phón loi nh phón (Benign/Attack) trồn CICIDS2017 vn ã tòch; bc l im yu thc s, lun vn b sung ònh giò a lp theo tng loi tn cũng gc (precision/recall/F1 tng lp, macro-F1, weighted-F1 vị ma trñ nhm ln), gm lp Benign vị 14 loi tn cũng ca CICIDS2017. Kt qu cho thy tng phn rt rủ gia hai ch s tng hp: *weighted-F1* $\approx 0,998$ (b chỉ phi bi còc lp a s) nhng *macro-F1* $\approx 0,806$, chõnh lị bng chng cho thy chõnh xòc nh phón gn hoịn ho ã *che giu* nng lc phòt hin kổm còc lp him. C th, còc lp a s (Benign, DoS Hulk, DDoS, PortScan) t F1 rt cao ($\geq 0,97$), trong khi còc lp cc him suy gim nghiõm trng: Web Attack – XSS recall ch 0,027, Web Attack – SQL Injection F1 = 0 (ch 6 mu), Bot recall 0,46. óy lị ni khòc bit gia còc phng phòp la chn c trng th hin rủ nht vị cng lị hng cn ci thĩn (x lý mt cón bng, tng cng d liu lp him). Kt qu chỉ tit theo tng lp c trõnh bịy trong Bng 4.11, vị ma trñ nhm ln a lp tng ng c

minh ha Hnh 4.4.


Bng 4.11. Hiu nng theo tng lp tn cũg (t per_class_metrics.csv)

Lp	Support	Precision	Recall	F1
Benign	380.119	0,9981	0,9997	0,9989
DoS Hulk	34.446	0,9990	0,9904	0,9947
DDoS	25.694	0,9996	0,9992	0,9994
DoS GoldenEye	2.020	1,0000	0,9757	0,9877
FTP-Patator	1.147	0,9965	0,9965	0,9965
DoS slowloris	1.068	0,9953	0,9925	0,9939
DoS Slowhttptest	1.023	0,9286	0,9912	0,9589
SSH-Patator	642	1,0000	0,9346	0,9662
PortScan	383	1,0000	0,9530	0,9759
Web Attack – Brute Force	311	0,7346	0,7299	0,7323
Bot	290	1,0000	0,4552	0,6256
Web Attack – XSS	111	1,0000	0,0270	0,0526
Infiltration	12	1,0000	0,6667	0,8000
Web Attack – SQL Injection	6	0,0000	0,0000	0,0000
Heartbleed	3	1,0000	1,0000	1,0000
macro-F1 / weighted-F1			0,806 / 0,998	


Phón tồch hng nhm ln gia còc lp him. c ma trn nhm ln theo òch n ca còc d oòn sai cho thy còc lp him suy gim theo hai kiu khòc nhau. Kiu th nht lị *nhm loi nhng vn b phòt hin*: 81/111 mu Web Attack – XSS b gòn thịnh Web Attack – Brute Force, tc bị toàn nh phón trin khai trổn biổn, còc lung nịy vn b gn c tn cũg (76% XSS vn b chn), ch sai khóu nh danh loi. Kiu th hai nguy him hn: *lt hn thịnh Benign*: toịn b 6/6 mu SQL Injection, 158/290 mu Bot (54%) vị 84/311 mu Web Brute Force b d oòn lị lu lng bnh thng. Ba c ch gii thờch hin tng nịy: (i) *mt cón bng cc oan* (6–311 mu so vị 380.119 mu Benign) khin còc lp him gn nh khũng cú vúng quy t nh riổng; (ii) *vic loi destination_port* nh hng nng nht n nhúm tn cũg web: khi mt “lị tt” cng 80, còc lung HTTP tn cũg (request/response ngn) cú c trng hịnh vị rt gn lu lng duy t web thng vị gn ln nhau; giò tr recall 0,027 ca XSS lị con s *trung thc* thay cho con s p nh rừ r; (iii) *Bot ln Benign do bn cht*: còc lung beaconing C&C nh, u n, gịng lu lng nn khi khũng cùn nh danh cng/dch v. Nhn đĩn nịy nh hng trc tip cho hng phòt trin: x lị mt cón bng cú ch òch (tng cng/oversampling lp him), b sung c trng chui thi gian cho hịnh vị beaconing, vị kim chng liổn b d liu (Mc 4.2.8.1).



Hình 4.2. Top 30 c trưng quan trng theo giờ tr trung bình tuyệt i SHAP ca mĩ hnh XGB



Hnh 4.3. Biu SHAP Summary (beeswarm): phn b vị hng tnc ng ca tng c trng



Hnh 4.4. Ma trn nhm ln a lp theo loi tn cũg (chun hóa theo hng)

4.3 Thc nghim vị ònh giò hiu nng mũ hnh trón Jetson Orin Nano Super

Trong phn này, lun vn xut xóy dng mt h thng phòt hin xóm nhp mng IDS *phón tồn* trin khai trón mt cm **hai thít b biể NVIDIA Jetson Orin Nano Super** [65] nhm ònh giò kh nng hot ng trong mũi trng tị nguyể hn ch; óy lị hng tip cn in toồn biể a phón tồch v gn ngun d liu gim bng thũng vị thi gian phn hi [66, 67], trong khi còc nghiể cu IDS biể trc óy ch yu ònh giò suy lun n nũt [68]. H thng c thít k theo kin trũc x lý d liu thi gian thc hai tng: mt *cng phòt hin bt thng* (anomaly gate) bng autoencoder nh lc bt lu lng bnh thng trón Jetson #1, vị mt *b phón loi* PySpark PipelineModel ch x lý còc lung nghi vn trón Jetson #2. H tng trung tóm (Apache Kafka cho trun ti thũng ip, PostgreSQL qun lý d liu, InfluxDB lu ch s hiu nng theo thi gian, Grafana trc quan hóa vị Mailtrap kim th cnh bõ qua email) chy trón mt mỳ ch iu phi.

NVIDIA Jetson Orin Nano Super lị mt mỳ tồnh nhũng (single-board computer) tồch hp CPU kin trũc ARM 64-bit vị GPU NVIDIA, h tr tng tc suy lun hc mỳ ngay tị biể; cu hnh chi tit õ nõu tị Bng 3.7 (Chng 3) vị mc Mũi trng thc nghim. Do hn ch v tị nguyể tồnh toồn so vị mỳ ch trun thng, vic trin khai trón Jetson Orin Nano Super cho phỏp ònh giò kh nng tị u hóa mũ hnh vị hiu nng suy lun trong iu kin phn cng nhũng (edge computing).

Mũ hnh cú hiu nng tị u c xỏc nh phn ònh giò hiu nng phón lp phõa trón s c tồch hp v iõ pipeline x lý nhm thc hin nhim v phòt hin vị phón loi lu lng mng thnh hai nhũm: *Benign* vị *Attack*. Còc ch s ònh giò bao gm chõnh xỏc (Accuracy), Precision, Recall, F1-Score, thi gian d oòn trung bnh cho mi mu, thũng lng x lý (throughput) vị mc tiểu th tị nguyể h thng (CPU, RAM). Kt qu thc nghim cho phỏp phón tồch tồnh kh thi ca vic trin khai h thng IDS da trón hc mỳ trong mũi trng thít b biể cú tị nguyể gii hn.

4.3.1 Còc cũng c s dng trong h thng

Trong h thng phòt hin xóm nhp mng IDS c xut, ngoi còc cũng ngh x lý d liu ln õ trõnh bị Chng 2, lun vn s dng thỏm mt s cũng c vị nn tng mỗ ngun m nhm h tr trun ti d liu, lu tr, giõm sỏt hiu nng vị cnh bõ theo thi gian thc. C th:


- **Apache Kafka** [69] – Lị nn tng trun ti thũng ip phón tồn (distributed event streaming platform), c s dng tip nhn vị phón phi d liu lung theo c ch publish-subscribe. Trong h thng, Kafka úg vai trũ trung gian gia ngun d liu (CICIDS2017 c mũ phng bng Python script) vị thít b Jetson Orin Nano Super, m bõ kh nng trun ti bt ng b, chu li vị m rng linh hot.

- **Apache Spark Streaming** – Lì thịnh phn x lý d liu lung thi gian thc. Spark Streaming nhn d liu t Kafka Consumer, thc hin còc bc tin x lý c trng vị chuyn d liu n mĩ hnh hc mỳ ò c hun luyn thc hin suy lun.
- **PostgreSQL** – Lì h qun tr c s d liu quan h mĩ ngun m cú n nh vị kh nng m rng cao. Trong h thng, PostgreSQL c s dng lu tr kt qu d oòn, thũng tin cnh bào vị còc bn ghi phc v bào cò tng hp.
- **InfluxDB** – Lì c s d liu chui thi gian (Time-Series Database), ti u cho vic lu tr vị truy vn còc ch s theo thi gian. H thng s dng InfluxDB ghi nhn còc thũng s hieu nng nh thi gian suy lun, mc s dng CPU, b nh vị thũng lng x lý.
- **Grafana** – Lì nn tng trc quan húa d liu mĩ ngun m, cho phõp xóy dng còc dashboard theo thi gian thc. Grafana kt ni vị InfluxDB vị PostgreSQL hin th tnh trng hot ng ca h thng IDS cng nh thng kổ còc s kin tn cũg.
- **Mailtrap** – Lì cũg c kim th email trong mĩ trng gi lp. Trong giai on thc nghim, Mailtrap c s dng kim tra c ch gi cnh bào khi h thng phòt hin lu lng mng bt thng trc khi trin khai mĩ trng thc t.

Vic tồch hp còc cũg ngh trổn giũp h thng m bo kh nng x lý d liu thi gian thc, lu tr an toìn, giòm sòt hieu nng liổn tc vị kờch hot cnh bào kp thi khi phòt hin hnh vị xóm nhp.

4.3.2 Mũ hnh h thng xut

H thng phòt hìn xóm nhp c thit k theo kin trũc x lý d liu lung nh minh ha Hnh 4.5. Lung x lý tng th bao gm còc bc sau:



Hnh 4.5. Kin trũc h thng phòt hìn xóm nhp phón tòn thi gian thc trõn cm 2 Jetson Orin Nano Super

1. **Ngun d liu:** D liu t b CICIDS2017 c mũ phng theo thi gian thc thng qua mt Python script vị gi vị Kafka Producer trón topic `ids-network-flow`.
2. **Cng phòt hin bt thng (Jetson #1):** Jetson #1 m nhn vai trò `anomaly_gate`: mt autoencoder nh (hun luyn ch trón lu lng bnh thng) tòn h sai s tòi to (reconstruction error) cho tng lung. Còc lung cú sai s di ngng c coi lị bnh thng vị *c lc b*; ch còc lung *ngghi vn* mi c chuyn tip sang topic `ids-suspicious-flow`. C ch nịy gim òng k khi lng phi a vị suy lun Spark.
3. **B phón loi (Jetson #2):** Jetson #2 m nhn vai trò `classifier`: ti mũ hnh PySpark `PipelineModel` (vị tp c trng SHAP Top-30 ò chn) vị phón loi còc lung ngghi vn thnh *Benign* hoc *Attack*. Vector *u* vị khi trin khai gm 29 c trng: trong Top-30 theo xp hng SHAP cú `destination_port`, nhng c trng nịy b loi khi mũ hnh xut ra trin khai vớ lị kỏnh rừ r nhõn trón CICIDS2017 (Mc 4.2.5), nht quòn vị giao thc chng rừ r pha hun luyn.
4. **Ghi nhn hiu nng:** Mi nũt ghi nhn thi gian d oòn/mu, mc s dng CPU/RAM/nhit vị thng lng (gn nhõn theo `EDGE_NODE_ID`); còc ch s c lu vị InfluxDB.
5. **Lu tr vị cnh bõo:** Kt qu d oòn vị s kin tn cũng c lu vị PostgreSQL; khi phòt hin lu lng bt thng, h thng kỏch hot cnh bõo qua Email/Webhook (Mailtrap, Slack trong mũ trng kim th) t mt nũt chõnh c ch nh trõnh trng lp.
6. **Trc quan húa vị giòm sòt:** Grafana truy xut d liu t InfluxDB vị PostgreSQL xóy dng dashboard theo thi gian thc, giòm sòt trng thòi h thng vị thng kỏ còc s kin tn cũng.

Ba ch trin khai phón tòn. Cm hai Jetson h tr ba ch , la chn theo rịng buc ti vị tr:

- **Ch A – Pipeline split** (khuy n gh): Jetson #1 = cng bt thng (anomaly gate), Jetson #2 = b phón loi (classifier) (nh mũ t trón), giúp gim ti Spark nh lc lu lng bnh thng sm.
- **Ch B – M rng theo chiu ngang (Horizontal scaling):** c hai Jetson chy pipeline y trong cũng mt nhúm tiõu th (consumer group) ca Kafka nhm tng thng lng.
- **Ch C – Spark cluster:** mỳy ch MacBook lịm Spark master, hai Jetson lịm worker, phón tòn suy lun Spark trón cm. Nht quòn vị nguỷn tc mc Mũ trng thc nghim, MacBook ch m nhn iu phi (master), khũng chy executor; toịn b tòn h toòn suy lun vn nm trón hai Jetson.

Kin trức nịy m bo tồnh mữ-un, tồch bit còc thịn phn x lý, ng thi phứ hp vi mữ hnh trìn khai phón tòn trổn còc thit b biổn cú tị nguyổn hn ch nh Jetson Orin Nano Super.

c t cng bt thng (operating point). Cng autoencoder lị mt b lc *iu chnh c* ch khững phi mt im c nh: nóg ngng giũp gim ti (offload) nriu lu lng bnh thng hn khi Spark (tng t l b qua ti cng, gate-skip) nhng cú th gim recall trổn lp tn cũng. Ngng ca cng c chn theo phón v (quantile) ca sai s tòi to tồnh trổn mt *tp kim nh benign*, gm 10% tồch t phn lu lng bnh thng ca tp hun luy (seed=42); tp kim tra khững tham gia vic chn ngng, trồnh rừ r kiu “ngng oracle”. Bng 4.12 trỡnh bịy ng ònh i gia recall vị mc gim ti (recall–offload) khi quốtt còc mc quantile trổn tp kim nh nịy; im vn hnh c chn theo ngón sòch tr/ chồnh xòc ca trìn khai.

Bng 4.12. im vn hnh ca cng bt thng khi quốtt quantile trổn tp kim nh benign (10% benign train, seed=42; t `gate_operating_points.csv`). FPR óy lị t l lung benign b cng chuyñ nhm sang b phón loi, khững phi FPR ca toịn h thng.

Quantile (validation)	Ngng	Recall (Attack)	FPR	T l b qua ti cng (%)
0,90	0,0023	0,7589	0,1003	80,08
0,95	0,0052	0,7552	0,0506	84,36
0,99	0,0192	0,7420	0,0101	88,00
0,995	0,0317	0,7229	0,0053	88,70

4.3.3 La chn mữ hnh cho thit b biổn

Trìn khai trổn thit b biổn t ra còc rịng buc v tị nguyổn: RAM 8 GB chia s gia CPU vị GPU (trong ú PySpark JVM chim mt phn òng k), CPU ARM, cứng rịng buc v nhit /bng thũng ti biổn. Cng cn nhn mn nhng vic chn Apache Spark trổn Jetson 8 GB phi chu chỉ phờ JVM/Spark òng k; Spark c dứng óy nhm *nht quòn* vi pha hun luy phón tòn, ch khững nhm ti u tr suy lun trổn mt nữt; chỉ phờ ònh i nịy c nh lng qua so sònh vi scikit-learn vị ONNX Runtime mc 4.3.6, cùn tng tc bng TensorRT lị hng nghiổn cu tng lai. Ba mữ hnh i din cho ba th nghim khòc nhau c chn ònh giò:

1. **Decision Tree** – Mữ hnh cóy n l, i din cho còch tip cn n gin nht.
2. **GBT (Gradient-Boosted Trees)** – i din cho phng phòp Boosting, s dng nriu cóy yu kt hp tun t.
3. **Random Forest** – i din cho phng phòp Bagging, s dng ensemble 200 cóy song song.

C ba mữ hnh u c hun luy trổn tp SHAP Top-30 c trng vị trìn khai di dng PySpark PipelineModel.

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

```
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.50 +
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (729.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.0 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.1 C
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.2 C
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.4 C
[MONITOR:jetson-nano-1] CPU: 17.0% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.7 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.5 C
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (730.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.8 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (730.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.8 C
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.6 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C
[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.6 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C
[MONITOR:jetson-nano-1] CPU: 17.2% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.1 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.2 C
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C
[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.1 C
[MONITOR:jetson-nano-1] CPU: 17.6% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.3 C
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.1MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.2 C
```

(a) Jetson #1 (jetson-nano-1): cng phòt hìn bt thng, giòm sòt tị nguyẽn theo node

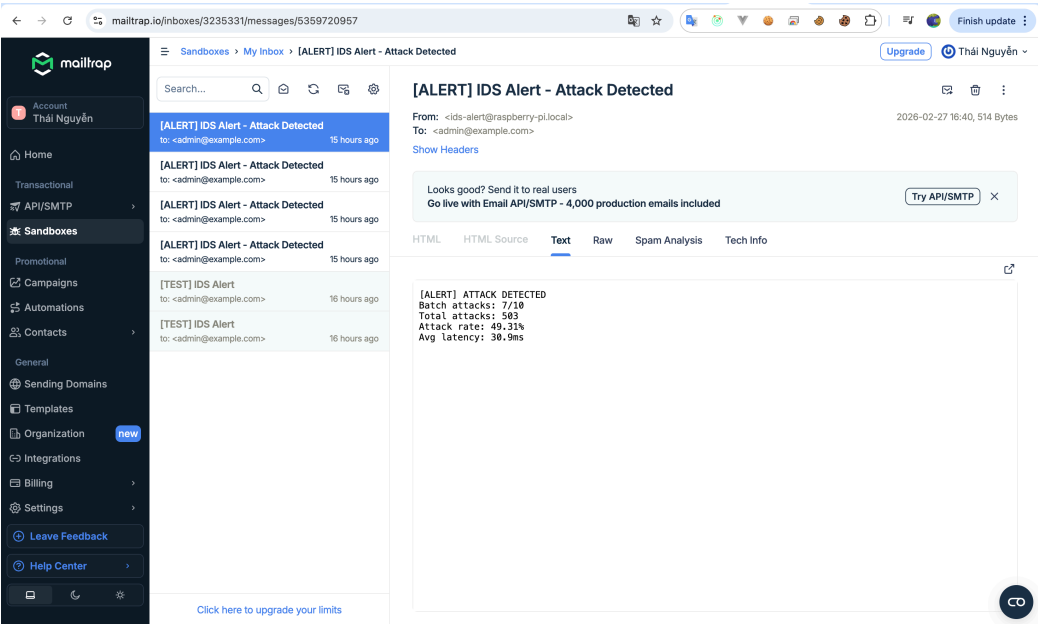
```
thainguyenvu -- bvdung@ubuntu: ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 -- 208x63
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.50 ... +
[MONITOR:jetson-nano-2] CPU: 72.4% | MEM: 58.6% (4196.6MB) | Throughput: 6.88 rps | Latency: 3.833ms | Attacks: 32
Temp: 56.7 C
[Stage 984:] (0 + 0) / 63
[MONITOR:jetson-nano-2] CPU: 17.6% | MEM: 49.6% (3512.9MB) | Throughput: 6.07 rps | Latency: 3.968ms | Attacks: 32
Temp: 56.2 C
[MONITOR:jetson-nano-2] CPU: 17.3% | MEM: 57.5% (4111.6MB) | Throughput: 6.04 rps | Latency: 4.472ms | Attacks: 32
Temp: 56.1 C
[Stage 1889:] (0 + 6) / 63
[MONITOR:jetson-nano-2] CPU: 97.7% | MEM: 54.7% (3980.9MB) | Throughput: 3.83 rps | Latency: 4.514ms | Attacks: 16
Temp: 57.3 C
[MONITOR:jetson-nano-2] CPU: 21.4% | MEM: 46.7% (3290.8MB) | Throughput: 6.88 rps | Latency: 4.334ms | Attacks: 32
Temp: 56.2 C
[MONITOR:jetson-nano-2] CPU: 67.8% | MEM: 55.0% (3927.6MB) | Throughput: 6.06 rps | Latency: 3.638ms | Attacks: 32
Temp: 56.7 C
[Stage 1847:] (0 + 6) / 63
[MONITOR:jetson-nano-2] CPU: 68.2% | MEM: 58.9% (3611.9MB) | Throughput: 6.00 rps | Latency: 4.156ms | Attacks: 32
Temp: 57.0 C
[MONITOR:jetson-nano-2] CPU: 16.9% | MEM: 59.6% (4274.3MB) | Throughput: 6.88 rps | Latency: 4.483ms | Attacks: 32
Temp: 55.9 C
[jetson-nano-2 2,488] Batch: 187ms | Attacks: 2373/2488 | Avg: 9.7ms
[MONITOR:jetson-nano-2] CPU: 85.5% | MEM: 49.1% (3474.6MB) | Throughput: 6.88 rps | Latency: 3.256ms | Attacks: 32
Temp: 56.5 C
[Stage 1886:] (0 + 0) / 63
[MONITOR:jetson-nano-2] CPU: 66.6% | MEM: 51.7% (3673.5MB) | Throughput: 3.04 rps | Latency: 3.737ms | Attacks: 16
Temp: 56.9 C
[MONITOR:jetson-nano-2] CPU: 28.7% | MEM: 56.8% (4882.1MB) | Throughput: 6.88 rps | Latency: 4.399ms | Attacks: 32
Temp: 56.1 C
[MONITOR:jetson-nano-2] CPU: 74.4% | MEM: 54.8% (3988.1MB) | Throughput: 6.88 rps | Latency: 3.923ms | Attacks: 32
Temp: 55.9 C
[MONITOR:jetson-nano-2] CPU: 34.2% | MEM: 56.8% (4863.8MB) | Throughput: 5.88 rps | Latency: 4.574ms | Attacks: 31
Temp: 56.8 C
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 55.8% (3924.2MB) | Throughput: 6.88 rps | Latency: 4.42ms | Attacks: 32
Temp: 56.1 C
[Stage 1149:] (1 + 5) / 63
[MONITOR:jetson-nano-2] CPU: 98.8% | MEM: 59.1% (4234.9MB) | Throughput: 3.04 rps | Latency: 3.157ms | Attacks: 16
Temp: 57.2 C
[MONITOR:jetson-nano-2] CPU: 16.8% | MEM: 52.5% (3733.5MB) | Throughput: 6.88 rps | Latency: 3.994ms | Attacks: 32
Temp: 55.9 C
[MONITOR:jetson-nano-2] CPU: 18.8% | MEM: 57.8% (4877.7MB) | Throughput: 5.98 rps | Latency: 4.577ms | Attacks: 31
Temp: 56.1 C
[Stage 1187:] (0 + 6) / 63
[MONITOR:jetson-nano-2] CPU: 45.8% | MEM: 68.6% (4351.7MB) | Throughput: 5.98 rps | Latency: 4.121ms | Attacks: 31
Temp: 56.7 C
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 52.7% (3758.8MB) | Throughput: 5.99 rps | Latency: 3.338ms | Attacks: 31
Temp: 55.9 C
[Stage 1212:] (3 + 3) / 63
```

(b) Jetson #2 (jetson-nano-2): b phón loi PySpark, thng lng ~6 lung/giỏy, tr suy lun ~4 ms, m tn cũng theo lữ


Hình 4.6. Giao din terminal khi pipeline IDS hot ng trở hai node Jetson Orin Nano Super:
(a) node cng lc bt thng vị (b) node phón loi PySpark




Hình 4.7. Dashboard Grafana ghi nhận hiệu năng IDS theo thời gian thực



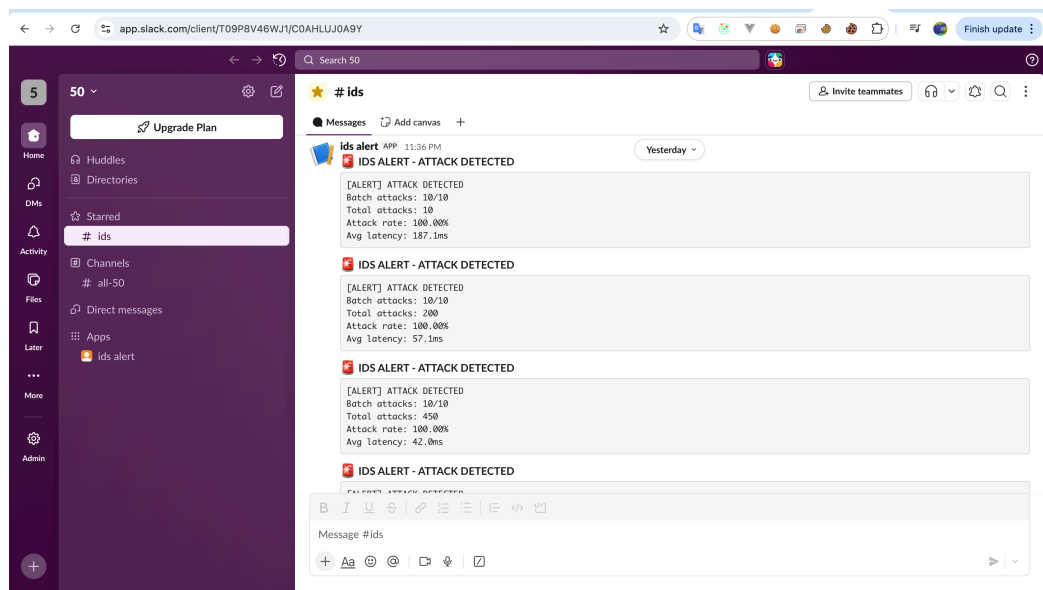
Hình 4.8. Email cảnh báo tấn công gửi qua Mailtrap trong môi trường kiểm thử (nhằm chấp thuận giai đoạn thử nghiệm sản phẩm; mẫu email cảnh báo vị trí đang thống kê gì nguyên nhân khi triển khai trở lại Jetson)



Hình 4.9. Dashboard Grafana hin th chỉ tit còc cuc tn cũng c phòt hin vị phón loi theo thì gian



Hình 4.10. Dashboard Grafana ti thì im ti nh ca ch tòch pipeline: nửt cng (jetson-nano-1) ch s dng khong 5 % CPU trong khi nửt phón loi PySpark (jetson-nano-2) t ti 91 %



Hình 4.11. Thông báo nh báo tn cũng c gi qua Slack Incoming Webhook (nh chp t giai on th nghim sm; nh dng thng ip gi nguyễn khi trin khai trở cm Jetson)

Hình 4.6 minh ha giao din terminal thc t khi pipeline IDS ang x lý d liu trở Jetson Orin Nano Super, bao gm thng tin v thng lng, tr vị s lng tn cũng phòt hin c. Hai dashboard Grafana (Hình 4.7 vị Hình 4.9) cho phỏp giòm sòt hieu nng h thng vị chỉ tit còc cuc tn cũng theo thi gian thc. Hình 4.10 ghi li thi im ti nh, cho thy rủ s phón b ti lch c trng ca ch tòch pipeline: nũt cng ch s dng khong 5 % CPU trong khi nũt phón loi PySpark t ti 91 %, xòc nhn b phón loi lị thịnh phn chim tị nguyễn ch o vị lị cn c cho còc phón tòch nng lng–thũng lng phn sau. Khi phòt hin tn cũng, h thng t ng gi cnh bào qua nhieu kỏnh: email thũng qua Mailtrap SMTP (Hình 4.8) vị tin nhn Slack (Hình 4.11).

4.3.4 Kt qu hun luyt còc mũ hỏnh ng viỏn trở cm Spark

Bng 4.13 trỏnh bọy kt qu hun luyt vị ònh giò ba mũ hỏnh ng viỏn trở cm Spark (mũ t mc Mũi trng thc nghim) trc khi trin khai xung thit b biỏn.

Bng 4.13. Kt qu hun luyt còc mũ hỏnh ng viỏn cho trin khai biỏn (SHAP Top-30)

Mũ hỏnh	F1-Score	Accuracy	Thi gian hun luyt (s)	Kỏch thc (MB)
Decision Tree	0,9814	0,9943	24,4	0,046
GBT	0,9753	0,9925	341,8	0,865
Random Forest	0,9826	0,9947	687,3	4,427

V tiỏu chỏ nhn bit rịng buc biỏn (edge-aware), Decision Tree cú kỏch thc mũ hỏnh nh nht (0,046 MB), nh hn Random Forest khong 96 ln vị thi gian hun luyt nhanh hn khong 28 ln; F1/Accuracy cn c cón nhc cựng còc ch s chỉ phỏ nịy chn mũ hỏnh trin khai. (Còc mũ

hình ng viồn biể c hun luyn trổn mu con phón tng khi xut va b nh mt nũt, nỏn F1 thp hn chũt ờt so vi kt qu hun luyn phón tòn y Bng 4.3; chờnh xỏc chờnh thc ly t pha hun luyn y .)

4.3.5 Kt qu o hiu nng (benchmark) trổn Jetson Orin Nano Super

Bng 4.14 trờnh bỳ kt qu o hiu nng (benchmark) thc t trổn Jetson Orin Nano Super. Mi cu hnh c o lp li 5 ln; trc mi ca s o cú giai on khi ng (warm-up) bng chờnh lu lng tht lỳm nũng JVM/JIT, vị d liu warm-up b loi khi ca s o; kt qu bõo cõo lỳ trung bõnh $\pm$ lch chun qua cõc ln chy. Hai loi tr c ghi nhn: (i) *tr suy lun* (tin x lý + d õn) trổn tng nũt, vị (ii) *tr u cui* (t thi im producer gĩ n khi cú phõn quyit) tõnh t nhõn thi gian ca producer; giò tr tuyt i ca loi (ii) ch cú ý ngha khi cõc mỳy ng b ng h NTP. Cõc phón v tr (p50/p95/p99) c tõnh mc tng ln chy t *log thũ theo tng lung* trong ỹng ca s ti; vi cm nhiu nũt, p95 bõo cõo lỳ p95 ca nũt xu nht (khũng ly phón v ca cõc giò tr trung bõnh theo nũt).

Bng 4.14. So sõnh hiu nng trin khai trổn Jetson Orin Nano Super

Mũ hnh	Thũng lng (mu/giõy)	tr suy lun (ms) p50 / p95 / p99	CPU (%)	RAM (%)	Kõch thc (MB)
Decision Tree	22,0	441 / 537 / –	46,4	21,9	0,046
GBT	24,3	414 / 439 / –	40,9	24,0	0,865
Random Forest	26,8	378 / 397 / –	35,2	27,5	4,427

4.3.6 So sõnh engine suy lun: chi phõ ca vic ng nht stack

Lun vn trin khai mũ hnh di dng PipelineModel ca Spark *ng nht vi pha hun luyn phón tòn*: cũng mt stack va hun luyn trổn cm va suy lun trổn thit b. *nh lng chi phõ ònh i ca s ng nht nỳ*, lun vn o li *cũng mt* mũ hnh Random Forest (cũng siõu tham s) trổn *cũng tp c trng SHAP õ chn* trin khai nhng qua cõc engine nh hn ch mt nũt: scikit-learn (CPU, khũng JVM) vị ONNX Runtime (CPU execution provider; Bng 4.15, sinh t benchmark_engines.py). Vớ cũng thut toõn vị c trng nỏn chờnh xỏc tng ng; phõp so sõnh tp trung vĩa *chi phõ suy lun*. (C ba dũng ca Bng 4.15 c o li trong *cũng mt phiõn* trổn cũng trng thõi bo mch so sõnh cũng bng, nỏn dũng PySpark chõnh lch nh so vi Bng 4.14 o phiõn trc: 22,6 so vi 26,8 lung/giõy, do khõc phiõn o vị xung CPU.) Kt qu o (Bng 4.15) cho thy stack JVM/Spark chu chi phõ suy lun cao hn õng k so vi scikit-learn trổn bo mch ARM 8 GB: thũng lng thp hn khõng 9 ln, tr p95 cao hn khõng 11 ln, t l RAM gn gp ỹi vị nng lng mi suy lun cao hn khõng 25 ln. Biõn dch cũng mũ hnh rng ngu nhiõn sang ONNX

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Runtime cũn ni rng khong còch nị òng k: $\approx 7\,900$ lung/gióy vì p95 1,1 ms, tc gp ≈ 348 ln thũng lng ca Spark ò trin khai, mc nng lng ch $\approx 2\%$ so vì scikit-learn; vic nõu rử iu nị lị c s cho hng phòt trin *xut mữ hnh sang ONNX/TensorRT suy lun* trong khi vn gị Spark cho hun lun (vic tồch hp phiổn ONNX vộ pipeline streaming vộ khai thồc GPU qua TensorRT thuc hng phòt trin).

Bng 4.15. Chi phờ suy lun mt nũt trổn cũng mữ hnh/c trng (Spark vs sklearn vs ONNX), o trổn nũt phón loi trong cũng iu kin bo mch (batch 10; nng lng lị phn *hot ng*, ò tr idle)

Engine	Thũng lng (lung/gióy)	tr p95 (ms)	RAM (%)	Nng lng /suy lun (mJ)
PySpark (trin khai)	22,6	532	24,3	71,6
scikit-learn	204,4	49,8	13,3	2,91
ONNX Runtime	7870,8	1,1	15,7	0,06

4.3.7 Kt qu ba ch trin khai phón tòn


Ngoi vic so sònh còc mữ hnh trổn mt nũt, lun vn ònh giò ba ch trin khai phón tòn trổn cm hai Jetson Orin Nano Super (Bng 4.16). Ch s chònh gm thũng lng, tr p95 (ms), t l b qua ti cng (gate-skip: % lu lng bnh thng c cng lc khi suy lun Spark) vộ F1 trổn lp tn cũng. *Thũng lng* c nh ngha lị s *phòn quyտ cui cũng* ghi vộ PostgreSQL trổn gióy (mt lung nhn phòn quyտ hoc ti cng (nu b b qua lị benign) hoc ti b phón loi), khũng cng dn u ra ca hai tng trònh m trũng lung c chuyн tip ch pipeline split.

Bng 4.16. So sònh ba ch trin khai phón tòn trổn cm 2 Jetson Orin Nano Super

Ch	Thũng lng (lung/gióy)	tr p95 (ms)	B qua ti cng (%)	Nng lng /suy lun (mJ)	F1 (Attack)
Mt nũt (single)	$2,60 \pm 0,41$	$12,3 \pm 3,0$	(ni tuyн)	2490	†
A: Pipeline split	$62,5 \pm 0,6$	$13,1 \pm 2,6$	95,8	178	†
B: Horizontal scaling	$5,9 \pm 1,4$	$21,6 \pm 19,2$	(ni tuyн)	2250	†
C: Spark cluster	$90,0 \pm 25,6$	$23,9 \pm 17,8$	97,9	119	†

Phòt lị CICIDS2017 100 lung/gióy; trung bnh $\pm$ lch chun trổn ≥ 3 ln lp; p95 tònh t log thũ tng lung (nũt xu nhт). “(ni tuyн)”: vai trù *full*, cng chy trong cũng tin trỏnh vộ còc lung b b qua vn c ghi phòn quyտ nõn khũng cú t l b qua riổng. †: cht lng phòt hìn khũng ph thuc ch (còc ch đũng cũng mt mữ hnh xut ra); F1 lp tn cũng ngoi tuyн xem Bng 4.6.

Kt qu thc o (Hnh 4.12) cho thy: ch *pipeline split* tồch cng khi b phón loi Spark giữp thũng lng phòn quyտ tng t 2,6 lổn 62,5 lung/gióy (gp ≈ 24 ln) vì p95 gn nh khũng i, nh cng lc 95,8% lu lng bnh thng vộ khũng cũn b Spark chn vùng x lị. *M rng theo chiu ngang* ch tng xp x gp ùi mt nũt (5,9 so vì 2,6) vớ mi nũt vn chy trn b phón loi Spark trong tin trỏnh.




Hình 4.12. Thũng lng vị tr p95 ca bn cu hnh (mt nút c s + ba ch phón tòn) trón cm 2 Jetson

Spark cluster (cng + b phón loi ni cm Spark standalone) t thũng lng trung bnh cao nht (90,0) nhng dao ng ln gia còc ln chy (± 26) vị ph thuc thỏm nút ch (master) trón mỳ iu phi, nỏn pipeline split vn lị khuyn ngh mc nh. *Nng lng mi suy lun* o bng *tegrastats* (nn idle 30 gióy trc mi ca s ti; ch hai nút cng cũng sut c hai bo mch): mc ti 100 lung/gióy, phn cũng sut *hot ng* (õ tr idle) nm di ngng nhiu ly mu ($< 0,15$ W mi nút), do ú bng bõo cõo nng lng *toin bo mch* trón mi phõn quyit, tc thc o mc dịn tri cũng sut bo mch theo thũng lng cp trin khai (khũng phi chi phõ rĩng ca mũ hnh): cõc ch dũng cng (A, C) dịn tri cũng sut hai bo mch trón s phõn quyit ln gp 24–35 ln, gim nng lng mi phõn quyit t $\approx 2,5$ J xung 0,12–0,18 J.

4.3.8 Phón tóch vị la chn mũ hnh

Hnh 4.13 minh ha trc quan s khòc bit gia ba mũ hnh v thng lng, tr vị mc s dng RAM trn Jetson Orin Nano Super.



Hnh 4.13. So sònh hiu nng ba mũ hnh trn Jetson Orin Nano Super

Kt qu benchmark cho th y s ònh i rủ rìng gia còc ch s:


- **Random Forest** t thng lng cao nht (26,8 mu/giý) nh Spark ti u hóa song song trn nhiu cý, nhng s dng RAM nhiu nht (27,5%) vị kòch thc mũ hnh ln nht ($\approx 4,4$ MB).
- **GBT** cú hiu nng trung bnh tt c còc ch s, úng vai trò cu ni gia Decision Tree vị Random Forest.
- **Decision Tree** cú F1-Score 0,9948 (SHAP Top-30, ngoi tyn), s dng RAM thp nht (21,9%), vị mũ hnh cú kòch thc rt nh ($\approx 0,05$ MB). Mc dù thng lng thp nht (22,0 mu/giý), giò tr nì y vn òp ng yóu cu giòm sòt thì gian thc cho mng quy mũ va vị nh.

Hnh 4.14 th hin s ònh i a chiu gia còc tiỏu chờ la chn mũ hnh. Decision Tree chim u th hai tiỏu chờ quan trng nht cho thit b biỏn: RAM thp vị kòch thc mũ hnh nh.

Decision Tree c chn lìm mũ hnh trin khai chònh trn thit b biỏn đa trn ba tiỏu chờ:

1. **Cht lng phòt hin:** F1-Score 0,9948 – vì tp c trng SHAP Top-30 ò c la chn (õ loi tr rừ r), mt cý quy nh n l vn nm bt c còc mu phón loi, ch kỏm Random Forest 0,0007 im F1.
2. **Hiu qu tị nguyỏn:** Ch s dng 21,9% RAM, gim òp lc lớn garbage collector ca JVM vị m bo tòn n nh lóu dị trn thit b gii hn tị nguyỏn.
3. **Tòn kh chuyn:** Kòch thc mũ hnh $\approx 0,05$ MB cho phỏp trin khai trn còc thit b IoT cú b nh hn ch hn.

Đánh đổi giữa các mô hình trên Jetson Orin Nano Super
(chuẩn hoá min-max, càng ra ngoài càng tốt)



Hình 4.14. Biểu radar thể hiện sự đánh đổi (trade-off) giữa các mô hình trên thiết bị biên

4.4 Tho luận vị So sánh tng hp

Kết quả thực nghiệm cho thấy việc kết hợp lựa chọn các trung đa thức SHAP với phương pháp ensemble (Hybrid Bagging) là một hướng tiếp cận phù hợp cho hệ thống IDS trên bộ dữ liệu CICIDS2017. Đặc biệt, mô hình còn lại từ dữ liệu, giải pháp đạt F1-Score 0,9966 (Hybrid Bagging, SHAP Top-30) trong thí nghiệm thực tế gian lận về việc sử dụng lưu trữ, phù hợp với việc giảm thiểu chi phí.

Cụ thể, khi triển khai trên thiết bị biên Jetson Orin Nano Super, Decision Tree với SHAP Top-30 có trung bình F1-Score 0,9948 ngoại tuyến (còn lại từ dữ liệu; bộ mô hình xuất ra kết quả, huấn luyện trên mẫu phân tích 20%, t 0,981), tổng lượng 22,0 MB/giây, sử dụng 21,9% RAM. Các số liệu này cho thấy rằng việc triển khai hệ thống IDS đa thức học máy trên thiết bị biên có thể đạt được hiệu suất cao, giảm thiểu chi phí và tăng cường an ninh mạng.

Chng 5. KT LUN VỊ HNG PHÒT TRIN

Trong chng nỳ, lun vn s trnh bỳ nhng kt qu mỳ lun vn ã t c so vĩ mc tiõu c t ra t ban u khi bt u the hin. Bõn cnh ú, lun vn cng trnh bỳ nhng hn ch vĩa ra hng phòt trin trong tng lai ca nghiõn cu.

5.1 Nhng úng gúp chõnh ca lun vn

Sau khi the hin lun vn vĩ tỳi “*Phòt hin xõm nhp (IDS) da trõn Apache Spark cho bo mt mng IoT*”, lun vn ã t c mt s kt qu chõnh tng ng vĩ cõc mc tiõu ra ban u:

- **Xõy dng nn tng x lý d liu ln:** xut vị trin khai thnh cõng h thng IDS trõn nn tng Apache Spark. Gii phõp nỳ tñ dng kh nng tõnh tõn song song x lý cõc lung d liu mng t mĩi trng IoT, hng ti kh nng m rng trong vic giõm sõt bo mt; kh nng x lý phõn tõn c kim chng mc minh chng khõì nim (proof-of-concept) trõn cm thit b biõn.
- **Ci thĩn hĩu nng phòt hin vĩ mĩ hõnh hc t hp:** Phòt trin mĩ hõnh Hybrid Bagging Ensemble kt hp Top-3 thut tõn cú F1 cao nht trõn tỳ kim nh (xõc nh chng thec nghiĩm, khũng c nh trc). Di quy trnh ònh giõ loi tr rừ r d liu, mĩ hõnh t F1-score 0,9966 vĩ c so sõnh vĩ cõc mĩ hõnh n l kõm kim nh yĩ ngha thng kõĩ khng nh khõc bit (nu cú) lĩ òng k.
- **ònh giõ trung thec, loi tr rừ r d liu:** Nhn din vị x lý cõc ngun rừ r thng gp trõn CICIDS2017 (c trng `destination_port` rừ r nhõn vị trũng lp lung mc c trng), ng thi nh lng mc thi phng hĩu nng do rừ r giũp kt qu phn ònh ỹng nng lc thec ca mĩ hõnh.
- **Ti u hĩa vị Gii thờch mĩ hõnh:** ng dng k thut SHAP la chn cõc c trng quan trng nht, giũp gim s lng c trng (khong 60%) mĩ vn gi nguyõn hĩu nng phõn loi: di cu hõnh loi tr rừ r d liu, Random Forest vĩ SHAP Top-30 t F1 0,9955, tng ng cu hõnh dũng toĩn b c trng (0,9949). ng thi, SHAP cung cp kh nng gii thờch chi tit v quyĩt nh ca mĩ hõnh, tng cng tin cy vị kh nng ng dng thec t.

5.2 Hn ch ca tỳi

Mc dũ ã t c cõc kt qu nõu trõn, lun vn vn cùn mt s hn ch cn c khc phc trong cõc giai õn tĩp theo:

- **Phm vi phón loi:** H thng trin khai chõnh đa trõn bị toàn phón loi nh phón (Tn cũg so vì Bõnh thng); lun vn õ b sung ònh giò a lp theo tng loi tn cũg (Mc 4.2.9) phón tồch im yu cõc lp him, nhng vic xõy dng mt b phón loi a lp hoĩn chnh cho trin khai thi gian thc vn lị hng phòt trin tip theo.
- **Phm vi b d liu:** Lun vn õ thit lp quy trõnh ònh giò tng quòt hóa liõn b d liu (hun luyõn trõn mt b, kim tra trõn b khõc, Mc 4.2.8.1) trõn cp CICIDS2017 vị CSE-CIC-IDS2018; vic m rng sang nhieu b mĩ hn (CIC-IoT, RoEduNet) cũg c kt lun v tng quòt hóa vn lị hng tip theo.
- **Quy mũ d liu vị phn cũg biõn:** Khõa cũnh x lý phón tòn mĩ c kim cũnh mc mĩnh cũnh khõi nim (proof-of-concept) trõn cũ hai thit b Jetson (8 GB) vị khi lng d liu c vị triu lung ca CICIDS2017, ch cha phi quy mũ d liu ln thc th (terabyte tr lõn) hay trõn cũ tõnh toàn nhieu nũt mnh; vic ònh giò kh nng m rng quy mũ ln hn vn lị hng tip theo.
- **Cha ònh giò trc lu lng i khõng:** H thng cha c kim th trc cõc tn cũg i khõng/nõ trõnh (adversarial/evasion) vị gi nh phón b tn cũg xp x CICIDS2017; do ú bn vng trc k tn cũg c ý ònh la mũ hõnh vn lị cũc hi m.

5.3 Hng phòt trin trong tng lai

Đa trõn nhng kt qu õ t c vị nhn dĩn cõc hn ch hĩn cú, lun vn xut mt s hng phòt trin trong tng lai, mĩ hng tng ng vì mt hn ch õ nõu:

- **Ci thĩn nhỹ cho cõc lp tn cũg him:** Phón tồch hng nhm ln gia cõc lp (Mc 4.2.9) cho thy cõc lp him suy gim theo hai kiu: nhm loi trong cũg h (XSS b nhĩn thĩnh Brute Force) vị lt hn thĩnh Benign (SQL Injection, 54% Bot). Bn hng khc phc tng ng: (i) *x lý mt cõn bng cú ch òch* pha hun luyõn a lp: undersampling lp Benign, oversampling/SMOTE [70] cho lp him (õp dng *sau* khi chia tp trõnh rừ r), hoc gp cõc bin th cũg h (gp ba bin th Web Attack thĩnh mt lp) i mĩn nh danh lý recall; (ii) *liu cũnh thut toàn*: trng s lp cho bị a lp, focal loss [71] vị XGBoost, vị h nng quyt nh theo lp (chp nhĩn thõm false positive lp him vớ vị IDS, bõo nhĩm r hn b sút); (iii) *kĩn trũc phón tng*: tn dng chõnh thĩt k cũg hai tng ca tịi: tng nh phón trõn biõn gi recall tng, cũn b nh danh loi hun luyõn *ch trõn cõc lung tn cũg* (khũng phi cũnh tranh vì 380 nhõn mu Benign) vị cú th hun luyõn li ngoi tuyõn vì cõn bng lp mĩ khũng ng h thng

ang chy; (iv) *c trng chui thi gian theo host* (chu k kt ni lp, entropy kờch thc gúi qua ca s trt), nhm tr ững bnh ca hính vi beaconing C&C khin 54% Bot lt li, vn khũng th hin hnh qua thng kỏ tng lung c lp.

- **Kim chng trỏn b d liu IoT chuyỏn bit:** ònh giò quy trnh trỏn còc b d liu cha lu lng IoT thc th (Bot-IoT, TON_IoT, CIC-IoT-2023) vị m rng thờ nghim liỏn b d liu lỏn toịn b CSE-CIC-IDS2018, nhm thu hp khong còch gia phm vi “IoT” ca tị vị d liu CICIDS2017 hin dứng.
- **Ti u suy lun biỏn bng ONNX/TensorRT:** Tỏch hp phiỏn suy lun ONNX vọ pipeline streaming vị tng tc bng TensorRT trỏn GPU Jetson gim chi phờ JVM/Spark pha suy lun (trong khi vn gi Spark cho hun luyn phón tòn): kt qu o ngoi tuyen Bng 4.15 cho thy cứng mũ hnh rng ngu nhiỏn chy qua ONNX Runtime t thũng lng gp ≈ 348 ln bn PySpark ỏ trin khai, xỏc nhn d a rt ln ca hng nịy; ng thi o tr u cui y (t Kafka n phòn quy t ri ghi c s d liu).
- **bn vng trc tn cũng i khỏng:** ònh giò vị gia c h thng trc lu lng nỏ trờnh (adversarial/evasion), c bit lị hai b mt tn cũng mi do cng bt thng to ra: gi dng lu lng bnh thng vt cng vị c ỳ to sai s tòi to cao dn ti lỏn nửt phón loi.

Ph 1c A. CŨNG TRŒNH ANG CHUN B CŨNG B

Phn n1y lit k1c c1c bn tho khoa hc li1n quan n 1t1 lun vn (v1t chung vi Nguy1n V Th1i, Tr1 Nh1 v1 TS. Nguy1n Vn D), hin ang c ho1n th1n gi ng:

1. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.
2. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Distributed Real-Time Intrusion Detection System on a Jetson Orin Nano Super Edge Cluster using Kafka and PySpark,” Symposium on Information and Communication Technology (SOICT), 2026.

TII LIU THAM KHO

- [1] Ansam Khraisat, Iqbal Gondal, Peter Vamplew, và Joarder Kamruzzaman. “Survey of intrusion detection systems: techniques, datasets and challenges”. In: *Cybersecurity* 2.1 (2019), pp. 1–22.
- [2] Mohamed Amine Ferrag, Leandros Maglaras, Helge Janicke, Jianhua Jiang, và Lei Shu. “Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study”. In: *Journal of Information Security and Applications* 50 (2020), p. 102419.
- [3] R Vinayakumar, Mamoun Alazab, K P Soman, Prabaharan Poornachandran, Ameer Al-Nemrat, và Sitalakshmi Venkatraman. “Deep learning approach for intelligent intrusion detection system”. In: *IEEE Access* 7 (2019), pp. 41525–41550.
- [4] Amardeep Singh và Julian Jang-Jaccard. *Autoencoder-based Unsupervised Intrusion Detection using Multi-Scale Convolutional Recurrent Networks*. 2022. arXiv: [2204.03779](https://arxiv.org/abs/2204.03779) [cs.CR].
- [5] Pengfei Sun, Pengju Liu, Qi Li, Chenxi Liu, Xiangling Lu, Ruochen Hao, và Jinpeng Chen. “DL-IDS: Extracting features using CNN-LSTM hybrid network for intrusion detection system”. In: *Security and Communication Networks* 2020 (2020), p. 8890306. DOI: [10.1155/2020/8890306](https://doi.org/10.1155/2020/8890306).
- [6] N. Dash, S. Chakravarty, A. K. Rath, và còc cng s. “An optimized LSTM-based deep learning model for anomaly network intrusion detection”. In: *Scientific Reports* 15 (2025), p. 1554. DOI: [10.1038/s41598-025-85248-z](https://doi.org/10.1038/s41598-025-85248-z).
- [7] Sukhvinder Singh Bamber, Aditya Vardhan Reddy Katkuri, Shubham Sharma, và Mohit Angurala. “A hybrid CNN-LSTM approach for intelligent cyber intrusion detection system”. In: *Computers & Security* 148 (2025), p. 104146. DOI: [10.1016/j.cose.2024.104146](https://doi.org/10.1016/j.cose.2024.104146).
- [8] Tasnimul Hasan, Abrar Hossain, Mufakir Qamar Ansari, và Talha Hussain Syed. *Enhanced Intrusion Detection in IIoT Networks: A Lightweight Approach with Autoencoder-Based Feature Learning*. arXiv:2501.15266. 2025.
- [9] P. R. Chithra Rani và K. Baalaji. “Deep learning-based ensemble stacking for enhanced intrusion detection in IoT-edge platforms”. In: *Discover Applied Sciences* 7 (2025), p. 928. DOI: [10.1007/s42452-025-06871-z](https://doi.org/10.1007/s42452-025-06871-z).

- [10] Kushboo Nasir, Sahar K. Badri, Daniyal M. Alghazzawi, Mohammed Yahya Alghamdi, Mona Alkhozai, Abeer Almakky, Rania M. Alhazmi, và Muhammad Zubair Asghar. “HED-ID: an edge-deployable and explainable intrusion detection system optimized via metaheuristic learning”. In: *Scientific Reports* 16 (2026), p. 2313. DOI: [10.1038/s41598-025-32183-8](https://doi.org/10.1038/s41598-025-32183-8).
- [11] Jackson Diaz-Gorriñ, Candido Caballero-Gil, và Ljiljana Brankovic. “Enhancing Network Security with Generative AI on Jetson Orin Nano”. In: *Applied Sciences* 16.3 (2026), p. 1442. DOI: [10.3390/app16031442](https://doi.org/10.3390/app16031442).
- [12] Zhenxiong Zhang, Lei Zhang, Jialong Xu, Zhengze Chen, và Peng Wang. “An Edge-Deployable Lightweight Intrusion Detection System for Industrial Control”. In: *Electronics* 15.3 (2026), p. 644. DOI: [10.3390/electronics15030644](https://doi.org/10.3390/electronics15030644).
- [13] Laila Nassef, Mohammed Ibrahim Alghamdi, Slim Ben Chaabane, Qaisar Abbas, Wedad M. Alawad, Omar H. Albalawi, Osamah I. Alqaisi, và Bahjat Fakieh. “Lightweight and Energy-Aware Intrusion Detection for Industrial IoT Using TinyML and Edge AI”. In: *Scientific Reports* 16.1 (2026), p. 18524. DOI: [10.1038/s41598-026-50690-0](https://doi.org/10.1038/s41598-026-50690-0).
- [14] Kotyada Mohan Kiran Kumar, M. Vivek Srikar Reddy, Karthik Ullas, và M. Supriya. “Distributed Intrusion Detection System using Kafka and Spark Streaming”. In: *2025 International Conference on Visual Analytics and Data Visualization (ICVADV)*. IEEE, 2025, pp. 302–309. DOI: [10.1109/ICVADV63329.2025.10961691](https://doi.org/10.1109/ICVADV63329.2025.10961691).
- [15] İlhan Firat Kilincer, Fatih Ertam, và Abdulkadir Sengur. “Machine learning methods for cyber security intrusion detection: Datasets and comparative study”. In: *Computer Networks* 188 (2021), p. 107840. DOI: [10.1016/j.comnet.2021.107840](https://doi.org/10.1016/j.comnet.2021.107840).
- [16] M. Al Lail, A. Garcia, và S. Olivo. “Machine learning for network intrusion detection—A comparative study”. In: *Future Internet* 15.7 (2023), p. 243. DOI: [10.3390/fi15070243](https://doi.org/10.3390/fi15070243).
- [17] Yung-Chung Wang, Yi-Chun Hwang, Han-Xuan Chen, và Shu-Ming Tseng. “Network Anomaly Intrusion Detection Based on Deep Learning Approach”. In: *Sensors* 23.4 (2023), p. 2171. DOI: [10.3390/s23042171](https://doi.org/10.3390/s23042171).

- [18] L. Yang, A. Moubayed, I. Hamieh, và A. Shami. “Tree-Based Intelligent Intrusion Detection System in Internet of Vehicles”. In: *2019 IEEE Global Communications Conference (GLOBECOM)*. 2019, pp. 1–6. DOI: [10.1109/GLOBECOM38437.2019.9013892](https://doi.org/10.1109/GLOBECOM38437.2019.9013892).
- [19] L. Yang, A. Moubayed, và A. Shami. “MTH-IDS: A Multi-Tiered Hybrid Intrusion Detection System for Internet of Vehicles”. In: *IEEE Internet of Things Journal* 9.1 (2022), pp. 616–632. DOI: [10.1109/JIOT.2021.3084796](https://doi.org/10.1109/JIOT.2021.3084796).
- [20] L. Yang, A. Shami, G. Stevens, và S. DeRusett. “LCCDE: A Decision-Based Ensemble Framework for Intrusion Detection in The Internet of Vehicles”. In: *2022 IEEE Global Communications Conference (GLOBECOM)*. 2022, pp. 1–6. DOI: [10.1109/GLOBECOM48099.2022.10001280](https://doi.org/10.1109/GLOBECOM48099.2022.10001280).
- [21] Jose Luis Hernandez-Ramos, Georgios Karopoulos, Efstratios Chatzoglou, Vasileios Kouliaridis, Enrique Marmol, Aurora Gonzalez-Vidal, và Georgios Kambourakis. “Intrusion Detection Based on Federated Learning: A Systematic Review”. In: *ACM Computing Surveys* 57.12 (2025), pp. 1–65. DOI: [10.1145/3731596](https://doi.org/10.1145/3731596).
- [22] R. Baidar, S. Maric, và R. Abbas. *Hybrid deep learning–federated learning powered intrusion detection system for IoT/5G advanced edge computing network*. <https://arxiv.org/abs/2509.15555>. arXiv. 2025.
- [23] B. Williams và L. Qian. “Semi-supervised learning for intrusion detection in large computer networks”. In: *Applied Sciences* 15.11 (2025), p. 5930. DOI: [10.3390/app15115930](https://doi.org/10.3390/app15115930).
- [24] N. Albanbay, Y. Tursynbek, K. Graffi, R. Uskenbayeva, Z. Kalpeyeva, Z. Abilkaiyr, và Y. Ayapov. “Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study”. In: *Journal of Sensor and Actuator Networks* 14.4 (2025), p. 78. DOI: [10.3390/jsan14040078](https://doi.org/10.3390/jsan14040078).
- [25] Thien Duc Nguyen, Samuel Marchal, Markus Miettinen, Hossein Fereidooni, N. Asokan, và Ahmad-Reza Sadeghi. “D²IoT: A Federated Self-learning Anomaly Detection System for IoT”. In: *2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS)*. 2019, pp. 756–767. DOI: [10.1109/ICDCS.2019.00080](https://doi.org/10.1109/ICDCS.2019.00080).

- [26] Lynda Boukela, Gongxuan Zhang, Mõziane Yacoub, và còng s. “A Near-Autonomous and Incremental Intrusion Detection System Through Active Learning of Known and Unknown Attacks”. In: *2021 International Conference on Security, Pattern Analysis, and Cybernetics (SPAC)*. 2021, pp. 374–379. DOI: [10.1109/SPAC53836.2021.9539947](https://doi.org/10.1109/SPAC53836.2021.9539947).
- [27] L. Atzori, A. Iera, và G. Morabito. “The Internet of Things: A survey”. In: *Computer Networks* 54.15 (2010), pp. 2787–2805. DOI: [10.1016/j.comnet.2010.05.010](https://doi.org/10.1016/j.comnet.2010.05.010).
- [28] Cisco. *Cisco Annual Internet Report (2018–2023) White Paper*. <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>. 2020.
- [29] R. Khan, S. U. Khan, R. Zaheer, và S. Khan. “Future Internet: The Internet of Things architecture, possible applications and key challenges”. In: *Proceedings of the 10th International Conference on Frontiers of Information Technology (FIT)*. 2012, pp. 257–260. DOI: [10.1109/FIT.2012.53](https://doi.org/10.1109/FIT.2012.53).
- [30] H. HaddadPajouh, A. Dehghantanha, R. M. Parizi, M. Aledhari, và H. Karimipour. “A survey on Internet of Things security: Requirements, challenges, and solutions”. In: *Internet of Things* 14 (2021), p. 100129. DOI: [10.1016/j.iot.2019.100129](https://doi.org/10.1016/j.iot.2019.100129).
- [31] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin, và K.-Y. Tung. “Intrusion detection system: A comprehensive review”. In: *Journal of Network and Computer Applications* 36.1 (2013), pp. 16–24. DOI: [10.1016/j.jnca.2012.09.004](https://doi.org/10.1016/j.jnca.2012.09.004).
- [32] Varun Chandola, Arindam Banerjee, và Vipin Kumar. “Anomaly detection: A survey”. In: *ACM Computing Surveys* 41.3 (2009), pp. 1–58. DOI: [10.1145/1541880.1541882](https://doi.org/10.1145/1541880.1541882).
- [33] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grõgoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, và Klaus-Robert Mõller. “A unifying review of deep and shallow anomaly detection”. In: *Proceedings of the IEEE* 109.5 (2021), pp. 756–795.

- [34] Manuel Lopez-Martin, Belen Carro, Antonio Sanchez-Esguevillas, và Jaime Lloret. “Conditional Variational Autoencoder for Prediction and Feature Recovery Applied to Intrusion Detection in IoT”. In: *Sensors* 17.9 (2017), p. 1967. DOI: [10.3390/s17091967](https://doi.org/10.3390/s17091967).
- [35] Khaled Alrawashdeh và Carla Purdy. “Toward an online anomaly intrusion detection system based on deep learning”. In: *Proc. 15th IEEE Int. Conf. on Machine Learning and Applications (ICMLA)*. 2016, pp. 195–200. DOI: [10.1109/ICMLA.2016.0040](https://doi.org/10.1109/ICMLA.2016.0040).
- [36] L. Husamaldin và N. Saeed. “Big Data Analytics Correlation Taxonomy”. In: *Information* 11.1 (2020), p. 17. DOI: [10.3390/info11010017](https://doi.org/10.3390/info11010017).
- [37] Matei Zaharia, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, Josh Rosen, Shivaram Venkataraman, Michael J. Franklin, Ali Ghodsi, Joseph Gonzalez, Scott Shenker, và Ion Stoica. “Apache Spark: A Unified Engine for Big Data Processing”. In: *Communications of the ACM* 59.11 (2016), pp. 56–65. DOI: [10.1145/2934664](https://doi.org/10.1145/2934664).
- [38] H. Karau, A. Konwinski, P. Wendell, và M. Zaharia. *Learning Spark: Lightning-fast big data analysis*. O’Reilly Media, 2015.
- [39] Xiangrui Meng, Joseph Bradley, Burak Yavuz, Evan Sparks, Shivaram Venkataraman, Davies Liu, Jeremy Freeman, DB Tsai, Manish Amde, Sean Owen, Doris Xin, Reynold Xin, Michael J. Franklin, Reza Zadeh, Matei Zaharia, và Ameet Talwalkar. “MLlib: Machine Learning in Apache Spark”. In: *Journal of Machine Learning Research* 17.34 (2016), pp. 1–7.
- [40] A. L. Buczak và E. Guven. “A survey of data mining and machine learning methods for cyber security intrusion detection”. In: *IEEE Communications Surveys & Tutorials* 18.2 (2016), pp. 1153–1176. DOI: [10.1109/COMST.2015.2494502](https://doi.org/10.1109/COMST.2015.2494502).
- [41] N. Koroniotis, N. Moustafa, E. Sitnikova, và B. Turnbull. “Towards the development of realistic botnet dataset in the Internet of Things for network forensic analytics: Bot-IoT dataset”. In: *Future Generation Computer Systems* 100 (2019), pp. 779–796. DOI: [10.1016/j.future.2019.05.041](https://doi.org/10.1016/j.future.2019.05.041).
- [42] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [43] Leo Breiman. “Random Forests”. In: *Machine Learning* 45.1 (2001), pp. 5–32.

- [44] D. R. Cox. “The regression analysis of binary sequences”. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 20.2 (1958), pp. 215–232.
- [45] Jerome H. Friedman. “Greedy function approximation: A gradient boosting machine”. In: *Annals of Statistics* 29.5 (2001), pp. 1189–1232.
- [46] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, và Tie-Yan Liu. “LightGBM: A highly efficient gradient boosting decision tree”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 3149–3157.
- [47] Andrew McCallum và Kamal Nigam. “A comparison of event models for naive Bayes text classification”. In: *AAAI Workshop on Learning for Text Categorization*. 1998.
- [48] Corinna Cortes và Vladimir Vapnik. “Support-vector networks”. In: *Machine learning* 20.3 (1995), pp. 273–297.
- [49] David E Rumelhart, Geoffrey E Hinton, và Ronald J Williams. “Learning representations by back-propagating errors”. In: *Nature* 323 (1986), pp. 533–536.
- [50] Tianqi Chen và Carlos Guestrin. “XGBoost: A scalable tree boosting system”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794.
- [51] Zhi-Hua Zhou. *Ensemble Methods: Foundations and Algorithms*. Chapman và Hall/CRC, 2012.
- [52] Patrik Goldschmidt và Daniela Chudò. “Network intrusion datasets: A survey, limitations, and recommendations”. In: *Computers & Security* 156 (2025), p. 104510.
- [53] Iman Sharafaldin, Arash Habibi Lashkari, và Ali A Ghorbani. “Toward generating a new intrusion detection dataset and intrusion traffic characterization”. In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*. 2018, pp. 108–116.
- [54] Canadian Institute for Cybersecurity and Communications Security Establishment. *CSE-CIC-IDS2018 dataset: A collaborative project between the Communications Security Establishment (CSE) and the Canadian Institute for Cybersecurity (CIC)*. <https://www.unb.ca/cic/datasets/ids-2018.html>. 2018.

- [55] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, và Konrad Rieck. “Dos and Don’ts of Machine Learning in Computer Security”. In: *31st USENIX Security Symposium (USENIX Security 22)*. 2022, pp. 3971–3988.
- [56] Maxime Lanvin, Pierre-François Gimenez, Yufei Han, Frédéric Majorczyk, Ludovic Mõ, và Öric Totel. “Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes”. In: *Risks and Security of Internet and Systems (CRiSIS 2022), Revised Selected Papers*. Springer, 2023, pp. 18–33. DOI: [10.1007/978-3-031-31108-6_2](https://doi.org/10.1007/978-3-031-31108-6_2).
- [57] Isabelle Guyon và André Elisseeff. “An introduction to variable and feature selection”. In: *Journal of Machine Learning Research* 3 (2003), pp. 1157–1182.
- [58] Ian T. Jolliffe. *Principal Component Analysis*. 2nd ed. Springer Series in Statistics. Springer, 2002. DOI: [10.1007/b98835](https://doi.org/10.1007/b98835).
- [59] Scott M. Lundberg và Su-In Lee. “A Unified Approach to Interpreting Model Predictions”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017, pp. 4765–4774.
- [60] Gints Engelen, Vera Rimmer, và Wouter Joosen. “Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study”. In: *2021 IEEE Security and Privacy Workshops (SPW)*. 2021, pp. 7–12. DOI: [10.1109/SPW53761.2021.00009](https://doi.org/10.1109/SPW53761.2021.00009).
- [61] Claude Nadeau và Yoshua Bengio. “Inference for the Generalization Error”. In: *Machine Learning* 52.3 (2003), pp. 239–281.
- [62] Laurens D’hooge, Tim Wauters, Bruno Volckaert, và Filip De Turck. “Inter-dataset generalization strength of supervised machine learning methods for intrusion detection”. In: *Journal of Information Security and Applications* 54 (2020), p. 102564.
- [63] Marta Cantone, Claudio Marrocco, và Alessandro Bria. “Machine Learning in Network Intrusion Detection: A Cross-Dataset Generalization Study”. In: *IEEE Access* 12 (2024).
- [64] Mohanad Sarhan, Siamak Layeghy, và Marius Portmann. “Evaluating standard feature sets towards increased generalisability and explainability of ML-based network intrusion detection”. In: *Big Data Research* 30 (2022), p. 100359. DOI: [10.1016/j.bdr.2022.100359](https://doi.org/10.1016/j.bdr.2022.100359).

- [65] NVIDIA Corporation. *Jetson Orin Nano Super Developer Kit*. <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-orin/nano-super-developer-kit/>. 2024.
- [66] Weisong Shi, Jie Cao, Quan Zhang, Youhuizi Li, và Lanyu Xu. “Edge computing: Vision and challenges”. In: *IEEE Internet of Things Journal* 3.5 (2016), pp. 637–646. DOI: [10.1109/JIOT.2016.2579198](https://doi.org/10.1109/JIOT.2016.2579198).
- [67] Salam Hamdan, Moussa Ayyash, và Sufyan Almajali. “Edge-Computing Architectures for Internet of Things Applications: A Survey”. In: *Sensors* 20.22 (2020), p. 6441. DOI: [10.3390/s20226441](https://doi.org/10.3390/s20226441).
- [68] Alessandro Sforzin, Fòlix Gúmez Mòrmol, Mauro Conti, và Jens-Matthias Bohli. “RPiDS: Raspberry Pi IDS — A Fruitful Intrusion Detection System for IoT”. In: *Proc. Int. IEEE Conf. on Ubiquitous Intelligence & Computing (UIC/ATC/ScalCom)*. 2016, pp. 440–448. DOI: [10.1109/UIC-ATC-ScalCom-CBDCom-IoP-SmartWorld.2016.0080](https://doi.org/10.1109/UIC-ATC-ScalCom-CBDCom-IoP-SmartWorld.2016.0080).
- [69] Jay Kreps, Neha Narkhede, và Jun Rao. “Kafka: a Distributed Messaging System for Log Processing”. In: *Proceedings of the NetDB Workshop*. 2011.
- [70] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, và W. Philip Kegelmeyer. “SMOTE: Synthetic Minority Over-sampling Technique”. In: *Journal of Artificial Intelligence Research* 16 (2002), pp. 321–357.
- [71] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, và Piotr Dollòr. “Focal Loss for Dense Object Detection”. In: *2017 IEEE International Conference on Computer Vision (ICCV)*. 2017, pp. 2999–3007. DOI: [10.1109/ICCV.2017.324](https://doi.org/10.1109/ICCV.2017.324).