

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN



BÙI VĂN DŨNG

LUẬN VĂN THẠC SĨ

PHÁT HIỆN XÂM NHẬP (IDS) DỰA TRÊN APACHE SPARK CHO
BẢO MẬT MẠNG IoT

INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY

THẠC SĨ NGÀNH CÔNG NGHỆ THÔNG TIN

TP. HỒ CHÍ MINH, 2026

**ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN**



BÙI VĂN DŨNG – 220201014

LUẬN VĂN THẠC SĨ

**PHÁT HIỆN XÂM NHẬP (IDS) DỰA TRÊN APACHE SPARK CHO
BẢO MẬT MẠNG IoT**

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THẠC SĨ NGÀNH CÔNG NGHỆ THÔNG TIN

GIẢNG VIÊN HƯỚNG DẪN

TS. NGUYỄN VĂN DŨ

TS. ĐỖ TRÍ NHỰT

TP. HỒ CHÍ MINH, 2026

LỜI CẢM ƠN

Lời đầu tiên, tôi xin gửi lời cảm ơn chân thành đến quý thầy cô của Trường Đại học Công nghệ Thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh đã tận tình chỉ dạy, giúp tôi tiếp thu được nhiều kiến thức quý báu trong suốt thời gian học tập tại trường, cũng như tạo điều kiện thuận lợi cho tôi thực hiện luận văn này. Kính chúc thầy cô luôn dồi dào sức khỏe và gặt hái được nhiều thành công trong tương lai.

Đặc biệt, tôi xin chân thành cảm ơn hai thầy TS. Nguyễn Văn Dũ và TS. Đỗ Trí Nhật đã tận tình giúp đỡ, hướng dẫn, cung cấp cho tôi những kiến thức, kỹ năng cần thiết để thực hiện nghiên cứu và hoàn thành đề tài này.

Tôi cũng xin gửi lời cảm ơn đến ThS. Nguyễn Vũ Thái đã đồng hành, hỗ trợ tôi trong quá trình thực nghiệm và công bố bài báo khoa học liên quan đến đề tài.

Mặc dù đã cố gắng trong quá trình nghiên cứu, nhưng do kiến thức còn hạn chế nên luận văn vẫn còn nhiều thiếu sót. Vì vậy, tôi rất mong nhận được sự đóng góp ý kiến của Quý Thầy Cô để đề tài của tôi được hoàn thiện hơn.

Tôi xin chân thành cảm ơn!

Bùi Văn Dũng

TÓM TẮT

Sự phát triển nhanh chóng của Internet of Things (IoT) đã mang lại nhiều tiện ích trong các lĩnh vực như nhà thông minh, công nghiệp, y tế và giao thông. Tuy nhiên, đi kèm là nguy cơ ngày càng gia tăng về các mối đe dọa an ninh mạng, đặc biệt khi thiết bị IoT thường hạn chế tài nguyên tính toán và bảo mật kém. Trong bối cảnh đó, Intrusion Detection Systems (IDS) là một hướng phòng thủ nhằm phát hiện và ngăn chặn các hành vi tấn công bất thường vào hệ thống mạng IoT.

Luận văn này tập trung nghiên cứu, thiết kế và triển khai một hệ thống IDS dựa trên nền tảng xử lý dữ liệu lớn Apache Spark. Spark có khả năng xử lý dữ liệu phân tán, tốc độ cao và hỗ trợ hiệu quả các thuật toán học máy qua thư viện MLlib. Hệ thống phát hiện hành vi xâm nhập trong dữ liệu mạng IoT bằng các mô hình học máy truyền thống, học tổ hợp và học sâu MLP (cùng một autoencoder đóng vai trò cổng phát hiện bất thường ở tầng biên).

Luận văn phân tích đặc điểm dữ liệu mạng IoT, xử lý dữ liệu đầu vào từ tập dữ liệu công khai CICIDS2017, huấn luyện và đánh giá mô hình theo các chỉ số độ chính xác (Accuracy), precision, recall và F1-score, đồng thời ghi nhận thời gian huấn luyện và kích thước mô hình. Quá trình đánh giá áp dụng quy trình loại trừ rõ ràng dữ liệu (loại đặc trưng rõ ràng, loại bỏ trùng lặp ở mức đặc trưng) nhằm bảo đảm kết quả phản ánh đúng hiệu năng mô hình. Bên cạnh đó, hệ thống được kiểm thử hiệu năng trên cụm thiết bị biên nhằm khảo sát khả năng mở rộng và tính khả thi triển khai thực tiễn.

Dưới cấu hình đánh giá loại trừ rõ ràng dữ liệu, lựa chọn đặc trưng SHAP Top-30 giữ được hiệu năng gần tương đương cấu hình đầy đủ trong khi giảm khoảng 60% số đặc trưng: Random Forest đạt F1 0,9955 và XGBoost (XGB) đạt 0,9970 trên CICIDS2017. Các khác biệt giữa phương pháp được kiểm chứng bằng kiểm định hoán vị ghép cặp và khoảng tin cậy hiệu chỉnh Nadeau–Bengio. Học tổ hợp (Hybrid Bagging 0,9966) không vượt được mô hình đơn tốt nhất, trong khi chi phí huấn luyện và dung lượng mô hình cao hơn nhiều lần. Trên cụm hai thiết bị biên Jetson Orin Nano Super, kiến trúc tách pipeline (cổng phát hiện bất thường + bộ phân loại PySpark) nâng thông lượng phán quyết từ 2,6 lên 62,5 luồng/giây (gấp ≈ 24 lần) với độ trễ p95 xấp xỉ 13 ms, trong đó cổng lọc 95,8% lưu lượng bình thường trước khi gọi suy luận Spark. Khía cạnh xử lý phân tán được kiểm chứng ở mức minh chứng khái niệm (proof-of-concept), chưa khẳng định quy mô dữ liệu lớn thực thụ. Kết quả cho thấy một quy trình phát hiện xâm nhập thời gian thực khả thi trên thiết bị biên, đồng thời là cơ sở để kết hợp học máy với nền tảng dữ liệu lớn cho bảo mật IoT.

MỤC LỤC

Lời cảm ơn	i
Tóm tắt	ii
Mục lục	iii
Danh mục các bảng	vi
Danh mục các hình vẽ và đồ thị	vii
Danh mục từ viết tắt	viii
Chương 1. Mở đầu	1
1.1 Lý do chọn đề tài	1
1.2 Các nghiên cứu liên quan	1
1.3 Mục tiêu, đối tượng và phạm vi nghiên cứu	4
1.3.1 Mục tiêu nghiên cứu	4
1.3.2 Đối tượng nghiên cứu	5
1.3.3 Phạm vi nghiên cứu	5
1.3.4 Câu hỏi nghiên cứu	6
1.4 Phương pháp nghiên cứu	6
1.5 Các đóng góp chính của đề tài	7
1.6 Công trình khoa học đã công bố	8
1.7 Cấu trúc của luận văn	8
Chương 2. Cơ sở lý thuyết	10
2.1 Tổng quan về IoT	10
2.2 Hệ thống phát hiện xâm nhập (IDS)	10
2.3 Apache Spark và xử lý dữ liệu lớn	11
2.3.1 Dữ liệu lớn	11
2.3.2 Các thành phần của Apache Spark	13
2.3.3 Kiến trúc của Apache Spark	14
2.4 Học máy trong phát hiện xâm nhập	15
2.4.1 Một số thuật toán học máy	16

2.4.2	Một số thuật toán học tổ hợp	20
Chương 3.	Phương pháp thực hiện	23
3.1	Thu thập dữ liệu và tiền xử lý	23
3.2	Lựa chọn đặc trưng và giảm chiều dữ liệu	28
3.3	Huấn luyện mô hình	30
3.3.1	Huấn luyện các mô hình cơ sở	30
3.3.2	Các phương pháp Ensemble Learning	31
3.4	Đánh giá mô hình	35
3.5	Tối ưu hóa siêu tham số và huấn luyện mô hình	37
3.6	Triển khai biên	39
Chương 4.	Thực nghiệm, đánh giá và thảo luận	40
4.1	Môi trường thực nghiệm	40
4.2	Kết quả thực nghiệm	41
4.2.1	Kịch bản 1: Đánh giá hiệu năng cơ sở (Baseline)	44
4.2.2	Kịch bản 2: So sánh chiến lược giảm chiều dữ liệu	44
4.2.3	Kịch bản 3: Tối ưu hóa siêu tham số	45
4.2.4	Phân tích khả năng giải thích với SHapley Additive exPlanations (SHAP)	46
4.2.5	Phân tích rò rỉ dữ liệu (data leakage)	47
4.2.6	Phân tích hiệu năng hệ thống	48
4.2.7	Kiểm định ý nghĩa thống kê	50
4.2.8	Kiểm tra độ ổn định trong-phân-phôi	51
4.2.9	Tổng quát hóa liên bộ dữ liệu	52
4.2.10	Đánh giá đa lớp theo loại tấn công	57
4.3	Thực nghiệm và đánh giá hiệu năng mô hình trên Jetson Orin Nano Super	62
4.3.1	Các công cụ sử dụng trong hệ thống	62
4.3.2	Mô hình hệ thống đề xuất	64
4.3.3	Lựa chọn mô hình cho thiết bị biên	66
4.3.4	Kết quả huấn luyện các mô hình ứng viên trên cụm Spark	71
4.3.5	Kết quả đo hiệu năng (benchmark) trên Jetson Orin Nano Super	71
4.3.6	So sánh engine suy luận: chi phí của việc đồng nhất stack	72
4.3.7	Kết quả ba chế độ triển khai phân tán	73

MỤC LỤC

4.3.8	Phân tích và lựa chọn mô hình	74
4.4	Thảo luận và so sánh tổng hợp	76
Chương 5.	Kết luận và hướng phát triển	77
5.1	Những đóng góp chính của luận văn	77
5.2	Hạn chế của đề tài	78
5.3	Hướng phát triển trong tương lai	79
Phụ lục A.	Công trình khoa học đã công bố	81
Tài liệu tham khảo		82

DANH MỤC CÁC BẢNG

3.1	Mô tả bộ dữ liệu CICIDS2017	24
3.2	Mô tả bộ dữ liệu CSE-CIC-IDS2018 (dùng cho thí nghiệm liên bộ dữ liệu) .	25
3.3	Tám bộ phân loại cơ sở được sử dụng trong pipeline	30
3.4	Các phương pháp học tổ hợp (ensemble) sử dụng trong luận văn	31
3.5	Các tiêu chí đánh giá mô hình	35
3.6	Ma trận nhầm lẫn của mô hình phát hiện xâm nhập	36
3.7	Thông số phần cứng thiết bị biên	39
4.1	Tham số tối ưu của các mô hình học máy	42
4.2	Hiệu năng phân loại kịch bản Baseline	44
4.3	So sánh hiệu năng tốt nhất của các phương pháp giảm chiều	45
4.4	So sánh lựa chọn đặc trưng: RF Importance vs SHAP (Top-30)	46
4.5	Kết quả hiệu năng phân loại kịch bản Tối ưu hóa siêu tham số	46
4.6	Phân tích loại bỏ (ablation) rõ ràng đặc trưng cổng đích	48
4.7	Ảnh hưởng của <code>destination_port</code> theo từng thuật toán	49
4.8	So sánh thời gian xử lý và kích thước mô hình kịch bản Baseline	49
4.9	Độ ổn định qua nhiều lần lấy mẫu và kiểm định ghép cặp	51
4.10	Kiểm tra độ ổn định trong-phân-phối trên mẫu con tập kiểm tra	51
4.11	Tổng quát hóa liên bộ dữ liệu CICIDS2017 và CSE-CIC-IDS2018	52
4.12	Thích ứng miền không giám sát trên tác vụ liên bộ dữ liệu	56
4.13	Ngân sách nhãn miền đích: 1% đủ để phục hồi hiệu năng	57
4.14	Hiệu năng theo từng lớp tấn công	58
4.15	Điểm vận hành của cổng bất thường theo ngưỡng quantile	67
4.16	Các mô hình ứng viên cho triển khai biên (SHAP Top-30)	71
4.17	So sánh hiệu năng triển khai trên Jetson Orin Nano Super	72
4.18	Chi phí suy luận một nút: Spark, sklearn và ONNX	73
4.19	So sánh ba chế độ triển khai phân tán trên cụm 2 Jetson Orin Nano Super .	74

DANH MỤC CÁC HÌNH VẼ VÀ ĐỒ THỊ

2.1	Mô hình 5V của dữ liệu lớn	12
2.2	Các thành phần của Apache Spark	13
2.3	Sơ đồ kiến trúc hệ thống Apache Spark	14
3.1	Quy trình tổng thể huấn luyện, đánh giá và triển khai mô hình đề xuất . . .	23
3.2	Sơ đồ phân chia dữ liệu CICIDS2017	26
4.1	Cụm huấn luyện phân tán Apache Spark Standalone	43
4.2	Top 30 đặc trưng quan trọng nhất theo SHAP (mô hình XGBoost)	59
4.3	Biểu đồ SHAP Summary (beeswarm)	60
4.4	Mức thổi phồng F1 do <code>destination_port</code> theo từng thuật toán	60
4.5	Ma trận nhầm lẫn đa lớp theo loại tấn công (chuẩn hóa theo hàng)	61
4.6	Kiến trúc hệ thống IDS phân tán trên cụm 2 Jetson Orin Nano Super	64
4.7	Giao diện terminal của pipeline IDS trên hai nút Jetson	68
4.8	Dashboard Grafana giám sát hiệu năng IDS theo thời gian thực	69
4.9	Dashboard Grafana chi tiết các cuộc tấn công được phát hiện	69
4.10	Dashboard Grafana tại thời điểm tải đỉnh của chế độ tách pipeline	70
4.11	Email cảnh báo tấn công gửi qua Mailtrap	70
4.12	Thông báo cảnh báo tấn công gửi qua Slack	71
4.13	Thông lượng và độ trễ p95 của bốn cấu hình triển khai	73
4.14	So sánh hiệu năng ba mô hình trên Jetson Orin Nano Super	74
4.15	Biểu đồ radar đánh đổi giữa các mô hình trên thiết bị biên	75
A.1	Thư chấp nhận đăng bài của Hội nghị FAIR 2026	81

DANH MỤC TỪ VIẾT TẮT

AC	accuracy
API	Application Programming Interface
BD	Big Data
CNN	Convolutional Neural Network
CPU	Central Processing Unit
CSV	Comma-Separated Values
CV	Cross-Validation
DDoS	Distributed Denial of Service
DoS	Denial of Service
DT	Decision Trees
EL	Ensemble Learning
FN	False Negative
FP	False Positive
FPR	False Positive Rate
FS	F1-score
FTP	File Transfer Protocol
GBT	Gradient Boosted Trees
GPU	Graphics Processing Unit
GS	Grid Search
HTTP	Hypertext Transfer Protocol
IDS	Intrusion Detection Systems
IoT	Internet of Things
IP	Internet Protocol
JVM	Java Virtual Machine
kNN	k-Nearest Neighbors
LGBM	LightGBM
LR	Logistic Regression
LSTM	Long Short-Term Memory
ML	Machine Learning
MLP	Multilayer Perceptron

NB	Naive Bayes
ONNX	Open Neural Network Exchange
PCA	Principal Component Analysis
PR	precision
RAM	Random Access Memory
RE	recall
RF	Random Forest
RFI	Random Forest Importance
RNN	Recurrent Neural Network
SCP	Secure Copy Protocol
SHAP	SHapley Additive exPlanations
SQL	Structured Query Language
SSH	Secure Shell
SVM	Support Vector Machine
TN	True Negative
TP	True Positive
XGB	XGBoost
XSS	Cross-Site Scripting

Chương 1. MỞ ĐẦU

1.1 Lý do chọn đề tài

IoT đang phát triển nhanh và được ứng dụng rộng rãi trong nhiều lĩnh vực như nhà thông minh, y tế, giao thông, công nghiệp thông minh... Sự bùng nổ về số lượng thiết bị IoT dẫn đến sự gia tăng đáng kể về lưu lượng và loại hình dữ liệu truyền trong mạng. Tuy nhiên, các thiết bị IoT thường có khả năng xử lý hạn chế và thiếu các cơ chế bảo mật mạnh, khiến chúng trở thành mục tiêu dễ bị tấn công bởi tin tặc.

Để đối phó với các mối đe dọa an ninh mạng, các hệ thống phát hiện xâm nhập (IDS) đang được nghiên cứu và phát triển rộng rãi. Đặc biệt, trong những năm gần đây, việc kết hợp học máy (Machine Learning (ML)) với các nền tảng xử lý dữ liệu lớn giúp hệ thống nâng cao độ chính xác phát hiện và thích nghi tốt hơn với môi trường mạng thay đổi liên tục. Cần lưu ý rằng bộ phân loại chính trong luận văn là mô hình học có giám sát trên CICIDS2017 nên chỉ phát hiện được các họ tấn công đã biết. Khả năng phát hiện hành vi bất thường chưa từng thấy (nếu có) đến từ cổng phát hiện bất thường (anomaly gate) học không giám sát, chứ không phải từ bộ phân loại. Tuy nhiên, phần lớn các nghiên cứu hiện nay tập trung vào việc xây dựng mô hình học máy trên tập dữ liệu tĩnh, dung lượng nhỏ và huấn luyện ngoại tuyến (offline).

Trong khi đó, mạng IoT hiện đại sinh ra lượng dữ liệu rất lớn, liên tục theo thời gian thực đòi hỏi các hệ thống IDS có khả năng xử lý dữ liệu lớn (Big Data (BD)) hiệu quả, có thể hoạt động trong môi trường phân tán và thời gian thực.

Apache Spark là một nền tảng xử lý dữ liệu lớn, với khả năng xử lý song song, phân tán và dễ dàng tích hợp với thư viện học máy Spark MLlib. Đây là một giải pháp tiềm năng để xây dựng hệ thống IDS hiện đại đáp ứng yêu cầu về quy mô và thời gian thực trong môi trường IoT.

1.2 Các nghiên cứu liên quan

Trong những năm gần đây, các hệ thống phát hiện xâm nhập (Intrusion Detection System – IDS) dựa trên học máy và học sâu đã thu hút nhiều sự quan tâm của cộng đồng nghiên cứu nhằm nâng cao độ chính xác và khả năng thích ứng trước các hình thức tấn công mạng ngày càng tinh vi [1, 2, 3]. Nhiều công trình tập trung khai thác các kiến trúc học sâu như autoencoder, mạng tích chập (Convolutional Neural Network (CNN)) và mạng nơ-ron hồi

quy (Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM)) để tự động trích xuất đặc trưng và phát hiện bất thường trong lưu lượng mạng. Tuy nhiên, phần lớn các nghiên cứu hiện nay vẫn được triển khai trong môi trường đơn máy, xử lý dữ liệu tĩnh với quy mô tương đối nhỏ, và chưa tích hợp các nền tảng xử lý dữ liệu lớn như Apache Spark hay Hadoop nhằm đáp ứng yêu cầu về khả năng mở rộng và xử lý thời gian thực trong các hệ thống mạng hiện đại.

Một số nghiên cứu đã đề xuất các mô hình IDS học sâu dựa trên các kiến trúc như autoencoder, CNN và LSTM nhằm nâng cao khả năng học đặc trưng và phát hiện xâm nhập mạng. Các mô hình này được đánh giá trên các tập dữ liệu chuẩn như NSL-KDD, CIC-DDoS2019 và CICIDS2017, cho thấy hiệu quả cao trong việc phát hiện bất thường. Tuy nhiên, quá trình huấn luyện và đánh giá vẫn chủ yếu được thực hiện trong môi trường cục bộ và theo cơ chế xử lý theo lô (batch) [4, 5]. Tương tự, các mô hình lai dựa trên LSTM (chẳng hạn CNN-LSTM, hay LSTM được tối ưu hóa siêu tham số) cho bài toán phát hiện bất thường trong mạng cũng đạt được kết quả khả quan, nhưng vẫn triển khai trên nền tảng đơn nút (single-node) và chưa khai thác được khả năng mở rộng của các hệ thống Big Data [6, 7]. Gần đây, một số nghiên cứu đã triển khai IDS học máy trực tiếp trên phần cứng biên NVIDIA Jetson [8, 9], hay trên môi trường biên mô phỏng ràng buộc tài nguyên [10]. Xu hướng này tiếp tục được mở rộng trong các công trình mới nhất: mô hình sinh (generative) được chạy trực tiếp trên Jetson Orin Nano để vừa phân loại lưu lượng vừa sinh dữ liệu huấn luyện tổng hợp [11], các mô hình rút gọn được thiết kế riêng cho lưu lượng điều khiển công nghiệp [12], và năng lượng tiêu thụ trên mỗi lần suy luận bắt đầu được xem là một chỉ số đánh giá hạng nhất bên cạnh độ chính xác [13]. Tuy vậy, điểm chung của các nghiên cứu này là vẫn dừng ở quy mô *đơn nút*: bộ phát hiện được đo trên một bo mạch duy nhất, nên câu hỏi phân bổ tải suy luận trên nhiều nút biên và lợi ích thực tế của việc bổ sung nút thứ hai vẫn còn bỏ ngỏ. Ở hướng ngược lại, việc ghép Kafka với Spark để phát hiện xâm nhập phân tán đã được nghiên cứu [14], nhưng chủ yếu trên hạ tầng máy chủ và hiếm khi công bố mức tiêu thụ tài nguyên (CPU, bộ nhớ, năng lượng) theo từng nút trên phần cứng ràng buộc.

Bên cạnh các phương pháp học sâu, các kỹ thuật học máy truyền thống như Support Vector Machine (Support Vector Machine (SVM)), k-Nearest Neighbors (k-Nearest Neighbors (kNN)) và Decision Tree vẫn được sử dụng rộng rãi trong các hệ thống IDS. Một số nghiên cứu đã tiến hành so sánh hiệu năng của các mô hình này trên các bộ dữ liệu phổ biến như NSL-KDD và UNSW-NB15, qua đó chỉ ra rằng các phương pháp học máy truyền

thống có tiềm năng ứng dụng thực tiễn cao. Tuy nhiên, các mô hình này chủ yếu hoạt động ở chế độ offline, xử lý dữ liệu theo từng đợt và chưa đáp ứng được yêu cầu về xử lý dữ liệu liên tục trong môi trường mạng động [15]. Ngoài ra, một số công trình so sánh nhiều mô hình học máy và học sâu cho IDS, ghi nhận các mô hình dựa trên cây như Random Forest cho kết quả tốt trên các bộ dữ liệu lớn, nhưng toàn bộ thực nghiệm vẫn được thực hiện trên một máy đơn [16].

Ngoài các kiến trúc nêu trên, nhiều mô hình học sâu khác như CNN, RNN và các mô hình lai CNN-LSTM cũng đã được nghiên cứu và đánh giá cho bài toán phát hiện xâm nhập mạng. Các nghiên cứu này cho thấy khả năng cải thiện đáng kể độ chính xác so với các phương pháp truyền thống khi thử nghiệm trên các bộ dữ liệu như CICIDS2018. Tuy nhiên, phần lớn các mô hình vẫn thiếu khả năng triển khai trong môi trường thời gian thực và chưa tận dụng được sức mạnh của các nền tảng xử lý dữ liệu lớn [17].

Trong bối cảnh Internet of Vehicles (IoV), một số nghiên cứu đã đề xuất các hệ thống IDS dựa trên học máy và học sâu nhằm bảo vệ các mạng phương tiện thông minh. Các phương pháp này bao gồm việc sử dụng các mô hình dựa trên cây (tree-based), các hệ thống phát hiện xâm nhập đa tầng, cũng như các mô hình ensemble để cải thiện độ chính xác phát hiện tấn công. Mặc dù đạt được kết quả khả quan trên các bộ dữ liệu thử nghiệm, các hệ thống này vẫn chủ yếu được huấn luyện và đánh giá trong môi trường ngoại tuyến, xử lý dữ liệu theo batch và chưa tích hợp các nền tảng xử lý dữ liệu lớn hoặc cơ chế xử lý dữ liệu theo luồng [18, 19, 20].

Bên cạnh đó, một số hướng tiếp cận gần đây đã nghiên cứu việc áp dụng học bán giám sát, học liên kết (federated learning) và học tăng dần (incremental/active learning) cho bài toán IDS nhằm nâng cao khả năng thích ứng của mô hình và bảo vệ quyền riêng tư dữ liệu. Các phương pháp này cho phép phân tán quá trình huấn luyện trên nhiều nút hoặc thiết bị IoT khác nhau. Một khảo sát hệ thống gần đây đã tổng hợp toàn cảnh hướng nghiên cứu IDS dựa trên học liên kết [21]. Tuy nhiên, cần lưu ý rằng việc phân tán ở đây diễn ra trong pha *huấn luyện*, còn suy luận vẫn thực hiện cục bộ trên từng nút. Ngoài ra, dữ liệu vẫn chủ yếu được xử lý theo từng đợt, thiếu cơ chế xử lý luồng tập trung và chưa khai thác đầy đủ khả năng mở rộng cũng như song song hóa của các nền tảng Big Data [22, 23, 24, 25, 26].

Từ tổng quan các công trình nghiên cứu nêu trên, có thể nhận thấy rằng phần lớn các hệ thống IDS hiện tại vẫn hoạt động trong môi trường ngoại tuyến, chưa hỗ trợ xử lý dữ liệu liên tục theo thời gian thực và chưa tận dụng được khả năng mở rộng của các nền tảng xử lý dữ liệu lớn. Do đó, luận văn này hướng đến việc tích hợp các mô hình học máy dựa trên

nền tảng Apache Spark nhằm xây dựng một hệ thống phát hiện xâm nhập có khả năng xử lý dữ liệu lớn, hỗ trợ thời gian thực và áp dụng hiệu quả trong môi trường mạng IoT hiện đại.

1.3 Mục tiêu, đối tượng và phạm vi nghiên cứu

1.3.1 Mục tiêu nghiên cứu

Mục tiêu của đề tài “PHÁT HIỆN XÂM NHẬP (IDS) DỰA TRÊN APACHE SPARK CHO BẢO MẬT MẠNG IoT” là xây dựng một hệ thống phát hiện xâm nhập có khả năng phân tích và phát hiện các hành vi bất thường hoặc tấn công mạng trong môi trường IoT bằng cách kết hợp các mô hình học máy với nền tảng xử lý dữ liệu lớn Apache Spark nhằm đạt được:

- Phát hiện hiệu quả các dạng tấn công mạng phổ biến (như DoS, probing, brute-force) trên các tập dữ liệu hiện đại như CICIDS2017.
- Thiết kế và triển khai pipeline xử lý dữ liệu phân tán và song song sử dụng Apache Spark, bao gồm các bước: tiền xử lý dữ liệu, trích xuất đặc trưng, huấn luyện mô hình và phát hiện thời gian thực.
- Khảo sát hiệu năng hệ thống, hướng tới khả năng mở rộng, độ trễ thấp và tính linh hoạt, đồng thời kiểm chứng khả năng xử lý phân tán ở mức minh chứng khái niệm (proof-of-concept) trên cụm thiết bị biên, làm tiền đề cho việc triển khai trên các hệ thống lớn hoặc mạng IoT nhiều thiết bị.
- So sánh và đánh giá các mô hình học máy phổ biến như Decision Tree, Support Vector Machine, Logistic Regression, Naive Bayes (NB), Random Forest, Gradient Boosted Trees (GBT), XGB, Multilayer Perceptron (MLP) và các thuật toán học tổ hợp (ensemble) trong môi trường xử lý phân tán, từ đó chọn ra mô hình phù hợp nhất.
- Áp dụng quy trình đánh giá chặt chẽ, loại trừ rò rỉ dữ liệu (loại đặc trưng rò rỉ nhãn, loại bỏ trùng lặp ở mức đặc trưng, kiểm định ý nghĩa thống kê) nhằm bảo đảm kết quả phản ánh đúng hiệu năng mô hình.
- Đề xuất giải pháp thực tiễn giúp phát hiện tấn công nhanh chóng và chính xác trong các hệ thống mạng hiện đại có yêu cầu xử lý dữ liệu lớn và liên tục.

1.3.2 Đối tượng nghiên cứu

Đề tài này tập trung nghiên cứu và triển khai phương pháp phát hiện xâm nhập trong lĩnh vực bảo mật mạng IoT trên nền tảng xử lý dữ liệu lớn Apache Spark. Với sự phát triển nhanh chóng của các thiết bị IoT, vấn đề bảo đảm an toàn và bảo mật cho hệ thống ngày càng trở nên cấp thiết, đặc biệt là trong việc phát hiện các hành vi bất thường hoặc tấn công mạng tiềm ẩn.

Apache Spark, với khả năng xử lý dữ liệu phân tán và tốc độ tính toán cao, cho phép xử lý khối lượng lớn dữ liệu sinh ra từ các thiết bị IoT trong thời gian thực. Trong khuôn khổ nghiên cứu này, luận văn sử dụng các tính năng của Spark như xử lý luồng dữ liệu (streaming), học máy phân tán (MLlib) và phân tích dữ liệu quy mô lớn để xây dựng mô hình phát hiện xâm nhập hiệu quả. Kết quả là một giải pháp kỹ thuật có thể áp dụng cho bài toán bảo mật IoT trong thực tiễn.

1.3.3 Phạm vi nghiên cứu

Đề tài tập trung vào việc nghiên cứu và áp dụng các kỹ thuật phân tích dữ liệu lớn nhằm phát hiện xâm nhập trong hệ thống mạng IoT với mục đích là sử dụng các khả năng của nền tảng Apache Spark để xử lý và phân tích dữ liệu hiệu quả. Cụ thể, phạm vi nghiên cứu bao gồm:

- **Dữ liệu đầu vào:** Dữ liệu được sử dụng là tập dữ liệu công khai CICIDS2017.
- **Công nghệ sử dụng:** Sử dụng Apache Spark làm nền tảng xử lý dữ liệu lớn, đặc biệt tập trung vào các thành phần như Spark Core, Spark SQL, Spark Streaming và Spark MLlib để hỗ trợ tiền xử lý dữ liệu, huấn luyện mô hình học máy và phát hiện xâm nhập theo thời gian thực.
- **Phương pháp phát hiện xâm nhập:** Áp dụng các thuật toán học máy được triển khai và tối ưu hóa trong môi trường Spark để bảo đảm khả năng mở rộng và hiệu năng cao.
- **Môi trường triển khai:** Thử nghiệm hệ thống trên một môi trường giả lập mạng IoT và bộ dữ liệu mô phỏng công khai (CICIDS2017) nhằm đánh giá khả năng phát hiện xâm nhập.

Lưu ý về phạm vi dữ liệu. CICIDS2017 là bộ dữ liệu lưu lượng mạng doanh nghiệp mô phỏng, không chứa lưu lượng đặc thù IoT (ví dụ các giao thức MQTT, CoAP) hay thiết

bị IoT thực. Tính chất “IoT” của đề tài do đó nằm ở *kịch bản triển khai*: toàn bộ pipeline suy luận được thiết kế, tối ưu và đo đạc trên thiết bị biên tài nguyên hạn chế (NVIDIA Jetson Orin Nano Super), vốn là lớp thiết bị làm gateway/biên trong kiến trúc IoT ba tầng, chứ không nằm ở bản chất lưu lượng của dữ liệu huấn luyện. CICIDS2017 được chọn vì là bộ chuẩn công khai, được cộng đồng sử dụng rộng rãi, có nhãn chi tiết và bao phủ các họ tấn công (DoS/DDoS, brute-force, web attack, botnet) vốn cũng xuất hiện phổ biến trong các mạng IoT. Các nguồn lỗi của bộ dữ liệu này cũng đã được nghiên cứu kỹ, cho phép áp dụng quy trình loại trừ rõ ràng một cách có căn cứ. Việc kiểm chứng trên các bộ dữ liệu IoT chuyên biệt (Bot-IoT, TON_IoT, CIC-IoT-2023) được xác định là hướng phát triển tiếp theo (Chương 5).

Mô hình mối đe dọa (threat model). Luận văn giả định kẻ tấn công nằm bên trong hoặc ở biên mạng IoT và tìm cách né tránh phát hiện. Phạm vi bảo vệ giới hạn ở việc phát hiện các tấn công đã biết theo kiểu CICIDS2017, dưới dạng phân loại nhị phân Benign/Attack. Các kịch bản đối kháng chủ động (adversarial/evasion) nhằm cố ý đánh lừa mô hình nằm ngoài phạm vi đánh giá của luận văn.

1.3.4 Câu hỏi nghiên cứu

Luận văn được định hướng bởi ba câu hỏi nghiên cứu:

- **RQ1:** Việc giảm chiều/lựa chọn đặc trưng (RF Importance, SHapley Additive exPlanations (SHAP), Principal Component Analysis (PCA)) có giữ được hiệu năng phát hiện gần với mức dùng toàn bộ đặc trưng hay không, khi số đặc trưng giảm hơn 60%?
- **RQ2:** Các mô hình học tổ hợp (Ensemble Learning (EL)) có mang lại lợi thế đáng kể so với mô hình đơn tốt nhất hay không, khi khác biệt được kiểm chứng bằng kiểm định thống kê thay vì so sánh một lần đo?
- **RQ3:** Một pipeline IDS dựa trên Spark có khả thi về thông lượng, độ trễ và năng lượng khi triển khai phân tán trên cụm thiết bị biên tài nguyên hạn chế (Jetson Orin Nano Super) hay không?

1.4 Phương pháp nghiên cứu

- **Thu thập, phân tích, xử lý dữ liệu:** Sử dụng bộ dữ liệu CICIDS2017, từ đó tiến hành phân tích, xử lý và trực quan hóa dữ liệu.

- **Nghiên cứu về phương pháp tối ưu hóa siêu tham số, các phương pháp giảm chiều dữ liệu:** Nghiên cứu các phương pháp giảm chiều dữ liệu như PCA, SHAP và Random Forest Importance nhằm giảm nhiễu và tăng độ chính xác, đồng thời tối ưu hóa siêu tham số thông qua tìm kiếm lưới (Grid Search) và kiểm định chéo (cross-validation) giúp nâng cao hiệu năng mô hình. Các bước này được triển khai trên nền tảng Apache Spark nhằm bảo đảm khả năng xử lý dữ liệu lớn hiệu quả và mở rộng.
- **Nghiên cứu và đề xuất mô hình học máy, học sâu (MLP và một autoencoder làm công phát hiện bất thường), học tổ hợp phát hiện xâm nhập sử dụng Spark Machine Learning:** Sử dụng nhiều thuật toán khác nhau như Decision Tree, Support Vector Machine, Logistic Regression, NB, Random Forest, GBT, XGB, MLP và các thuật toán học tổ hợp (ensemble) để xây dựng mô hình nhằm so sánh, đánh giá mô hình có hiệu năng tốt nhất.
- **Thực nghiệm và đánh giá hiệu năng mô hình trên cụm Jetson Orin Nano Super:** Xây dựng một hệ thống phát hiện xâm nhập mạng IDS *phân tán* triển khai trên cụm hai thiết bị biên Jetson Orin Nano Super (công phát hiện bất thường trên một nút, bộ phân loại PySpark trên nút còn lại) nhằm đánh giá khả năng hoạt động trong môi trường tài nguyên hạn chế. Hệ thống được thiết kế theo kiến trúc xử lý dữ liệu thời gian thực, tận dụng Apache Kafka cho cơ chế truyền tải thông điệp, Spark Streaming cho xử lý luồng dữ liệu, PostgreSQL để quản lý dữ liệu, InfluxDB để lưu trữ chỉ số hiệu năng theo thời gian, Grafana để trực quan hóa và Mailtrap phục vụ kiểm thử cơ chế cảnh báo qua email.

1.5 Các đóng góp chính của đề tài

- **Đề xuất giải pháp ứng dụng Apache Spark trong phát hiện xâm nhập cho hệ thống mạng IoT:** Đề tài đã xây dựng một mô hình phát hiện xâm nhập dựa trên nền tảng xử lý dữ liệu lớn Apache Spark, tận dụng khả năng xử lý phân tán và thời gian thực của Spark, hướng tới đáp ứng yêu cầu về hiệu năng và tính mở rộng trong môi trường IoT có khối lượng dữ liệu lớn và biến đổi liên tục. Khả năng xử lý phân tán được kiểm chứng ở mức minh chứng khái niệm (proof-of-concept) trên cụm thiết bị biên.
- **Xây dựng quy trình xử lý và phát hiện xâm nhập khép kín trên dữ liệu IoT:** Từ bước tiền xử lý dữ liệu, trích xuất đặc trưng, huấn luyện mô hình đến đánh giá kết

quả, đề tài đã thiết kế và hiện thực một quy trình phát hiện xâm nhập hoàn chỉnh có thể áp dụng cho các hệ thống thực tế.

- **Ứng dụng và đánh giá các thuật toán học máy trong môi trường phân tán:** Đề tài triển khai và so sánh hiệu quả của một số thuật toán học máy và mô hình học sâu MLP trên nền tảng Apache Spark MLlib (ngoài ra một autoencoder được dùng làm công phát hiện bất thường ở tầng biên), qua đó làm rõ ưu điểm và hạn chế của từng mô hình trong việc xử lý dữ liệu IoT.
- **Đánh giá hiệu năng hệ thống trong môi trường xử lý phân tán:** Ngoài độ chính xác của mô hình, đề tài còn phân tích hiệu năng xử lý (thời gian thực thi, khả năng mở rộng) của hệ thống nhằm khảo sát tính khả thi của giải pháp. Việc kiểm chứng được thực hiện ở mức minh chứng khái niệm (proof-of-concept) trên cụm thiết bị biên với bộ dữ liệu CICIDS2017, làm cơ sở cho việc mở rộng quy mô về sau.
- **Quy trình đánh giá loại trừ rò rỉ dữ liệu và có kiểm định thống kê:** Đề tài nhận diện và loại bỏ các nguồn rò rỉ dữ liệu thường gặp trên CICIDS2017 (đặc trưng `destination_port` rò rỉ nhãn, trùng lặp luồng ở mức đặc trưng), đồng thời áp dụng kiểm định ý nghĩa thống kê, giúp kết quả phản ánh đúng hiệu năng mô hình thay vì các con số bị thổi phồng.

1.6 Công trình khoa học đã công bố

Một phần kết quả của luận văn đã được công bố thành một bài báo khoa học (viết chung với ThS. Nguyễn Vũ Thái, TS. Đỗ Trí Nhựt và TS. Nguyễn Văn Dũ), bài báo đã được chấp nhận đăng:

1. Thai Nguyen Vu, **Dung Van Bui**, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.

1.7 Cấu trúc của luận văn

Luận văn với đề tài “PHÁT HIỆN XÂM NHẬP (IDS) DỰA TRÊN APACHE SPARK CHO BẢO MẬT MẠNG IoT” được trình bày bao gồm 5 chương. Nội dung tóm tắt từng chương được trình bày như sau:

- **Chương 1: Mở đầu:** Trình bày tổng quan về bối cảnh và lý do chọn đề tài, mục tiêu nghiên cứu, phạm vi nghiên cứu, câu hỏi nghiên cứu và phương pháp tiếp cận. Ngoài ra, chương này nêu ý nghĩa khoa học, thực tiễn và bố cục của luận văn.
- **Chương 2: Cơ sở lý thuyết:** Trình bày các khái niệm cơ bản và nền tảng lý thuyết phục vụ cho đề tài, bao gồm tổng quan về mạng IoT, các lỗ hổng và mối đe dọa bảo mật, phương pháp phát hiện xâm nhập (IDS), và kiến thức liên quan đến Apache Spark. Chương này cũng phân tích các thuật toán học máy thường dùng cho phát hiện xâm nhập.
- **Chương 3: Phương pháp thực hiện:** Trình bày chi tiết các bước xây dựng hệ thống phát hiện xâm nhập, bao gồm thu thập và tiền xử lý dữ liệu, thiết kế kiến trúc hệ thống sử dụng Apache Spark, lựa chọn và triển khai các thuật toán học máy, cùng quy trình huấn luyện và đánh giá mô hình.
- **Chương 4: Thực nghiệm, đánh giá và thảo luận:** Trình bày kết quả thực nghiệm trên bộ dữ liệu thực tế hoặc mô phỏng, đánh giá hiệu năng của các mô hình đã triển khai theo các tiêu chí như độ chính xác, Recall, F1-score, kích thước của mô hình và thời gian xử lý. Đồng thời, chương này phân tích, so sánh và thảo luận kết quả nhằm làm rõ hiệu quả của phương pháp đề xuất.
- **Chương 5: Kết luận và hướng phát triển:** Tổng kết những kết quả chính mà đề tài đạt được, trình bày những đóng góp chính, đồng thời chỉ ra những hạn chế còn tồn tại và đề xuất các hướng phát triển trong tương lai như tích hợp mô hình học sâu hoặc triển khai trên nền tảng đám mây.

Chương 2. CƠ SỞ LÝ THUYẾT

Chương này trình bày các nền tảng lý thuyết liên quan đến đề tài, bao gồm tổng quan về Internet vạn vật (IoT), các mối đe dọa an ninh trong hệ thống IoT, và vai trò của hệ thống phát hiện xâm nhập (IDS). Bên cạnh đó, trong chương này, luận văn cũng giới thiệu kiến trúc và khả năng của Apache Spark trong xử lý dữ liệu lớn, các kỹ thuật học máy ứng dụng trong phát hiện xâm nhập và cách Spark MLlib hỗ trợ xây dựng mô hình học máy phân tán. (Các nghiên cứu liên quan và khoảng trống nghiên cứu đã được khảo sát ở Chương 1.)

2.1 Tổng quan về IoT

Internet of Things (IoT) là mạng lưới các thiết bị vật lý được tích hợp cảm biến, phần mềm và khả năng kết nối mạng, cho phép thu thập và trao đổi dữ liệu qua Internet [27]. IoT bao gồm các thiết bị như cảm biến môi trường, thiết bị gia dụng thông minh và phương tiện giao thông tạo ra khối lượng dữ liệu lớn với đặc điểm đa dạng, tốc độ cao và yêu cầu xử lý thời gian thực. Theo báo cáo Cisco Annual Internet Report (2018–2023), tổng số thiết bị nối mạng toàn cầu được dự báo đạt khoảng 29,3 tỷ vào năm 2023, trong đó khoảng một nửa là kết nối máy-với-máy (M2M/IoT) [28]. Kiến trúc IoT thường được chia thành ba tầng:

- **Tầng cảm biến (Perception Layer):** Thu thập dữ liệu từ cảm biến và thiết bị.
- **Tầng mạng (Network Layer):** Truyền tải dữ liệu qua các giao thức như MQTT, CoAP hoặc HTTP.
- **Tầng ứng dụng (Application Layer):** Phân tích dữ liệu để cung cấp dịch vụ [29].

Tuy nhiên, các thiết bị IoT thường có tài nguyên hạn chế (bộ nhớ, năng lượng, khả năng tính toán), dẫn đến thách thức trong việc triển khai các giải pháp bảo mật truyền thống. Các mối đe dọa như tấn công từ chối dịch vụ (DDoS), tấn công giả mạo và khai thác lỗ hổng giao thức đòi hỏi các giải pháp bảo mật chuyên biệt như IDS [30].

2.2 Hệ thống phát hiện xâm nhập (IDS)

Hệ thống phát hiện xâm nhập (IDS) giám sát và phân tích hoạt động mạng hoặc hệ thống để phát hiện các hành vi bất thường hoặc đáng ngờ, nhằm bảo vệ hệ thống khỏi các cuộc tấn công mạng [31]. Mục tiêu là duy trì tính bảo mật, toàn vẹn và sẵn sàng của hệ thống IoT. IDS được phân loại như sau:

Dựa trên vị trí triển khai:

- **Network-based IDS (NIDS):** Giám sát lưu lượng mạng để phát hiện các mẫu tấn công.
- **Host-based IDS (HIDS):** Tập trung vào hoạt động của một thiết bị cụ thể.

Dựa trên phương pháp phát hiện:

- **Signature-based IDS:** Sử dụng các mẫu tấn công đã biết, hiệu quả với các mối đe dọa quen thuộc nhưng hạn chế với các tấn công mới.
- **Anomaly-based IDS:** Phát hiện hành vi bất thường dựa trên mô hình hoạt động bình thường, phù hợp với các cuộc tấn công chưa biết [32, 33]. Các bộ phát hiện dựa trên học sâu như autoencoder [34] hay mạng niềm tin sâu (Deep Belief Network) [35] là một hướng phổ biến của nhóm này.
- **Hybrid IDS:** Kết hợp cả hai phương pháp để tăng độ chính xác [31].

Trong IoT, IDS phải xử lý khối lượng dữ liệu lớn và đáp ứng yêu cầu thời gian thực, đồng thời phù hợp với tài nguyên hạn chế của thiết bị. Các giải pháp IDS dựa trên dữ liệu lớn và học máy, như sử dụng Apache Spark, là hướng đi tiềm năng để giải quyết các thách thức này [30].


2.3 Apache Spark và xử lý dữ liệu lớn

2.3.1 Dữ liệu lớn

Dữ liệu lớn (*Big Data*) là một thuật ngữ được sử dụng để mô tả tập hợp dữ liệu có quy mô lớn, phức tạp và đa dạng đến mức không thể xử lý hiệu quả bằng các công cụ và phương pháp truyền thống, bao gồm dữ liệu có cấu trúc, dữ liệu không có cấu trúc và dữ liệu bán cấu trúc.

Ngày nay, kích thước của các tập dữ liệu có thể được coi là dữ liệu lớn dao động từ **terabyte**, **petabyte** đến **exabyte**. Khái niệm về dữ liệu lớn sẽ phụ thuộc vào ngành công nghiệp, cách dữ liệu được sử dụng, lượng dữ liệu lịch sử liên quan và nhiều đặc điểm khác.

Dữ liệu lớn thường được nhận diện thông qua năm đặc điểm cốt lõi: **Khối lượng** (*Volume*), **Tốc độ** (*Velocity*), **Tính đa dạng** (*Variety*), **Tính xác thực** (*Veracity*) và **Giá trị**



Hình 2.1. Mô hình 5V của dữ liệu lớn (Nguồn: [36])

(Value) (Hình 2.1). Năm đặc điểm này là cơ sở để phân biệt dữ liệu lớn với các loại dữ liệu thông thường.

- **Khối lượng (Volume):** Đề cập đến quy mô dữ liệu cực lớn.
- **Tốc độ (Velocity):** Tốc độ dữ liệu được tạo ra, truyền tải và xử lý.
- **Tính đa dạng (Variety):** Nguồn và định dạng dữ liệu đa dạng như văn bản, hình ảnh, video, v.v.
- **Tính xác thực (Veracity):** Mức độ đáng tin cậy và chất lượng của dữ liệu.
- **Giá trị (Value):** Tiềm năng khai thác thông tin hữu ích từ dữ liệu.

Dữ liệu sinh ra từ các thiết bị IoT được xem là một trong những nguồn tạo ra dữ liệu lớn (BD) quan trọng và phát triển nhanh chóng hiện nay. Với hàng tỷ thiết bị cảm biến, máy móc, thiết bị đeo tay và phương tiện kết nối Internet, lượng dữ liệu được tạo ra mỗi ngày rất lớn, đa dạng về định dạng và tốc độ phát sinh liên tục theo thời gian thực. Dữ liệu IoT mang đầy đủ các đặc điểm của dữ liệu lớn như: khối lượng (volume) lớn, tốc độ (velocity) cao, tính đa dạng (variety) về loại dữ liệu, mức độ xác thực (veracity) không đồng đều và tiềm năng mang lại giá trị (value) lớn nếu được khai thác hiệu quả. Dữ liệu IoT do đó vừa là một phần của dữ liệu lớn, vừa là một trong những nguồn thúc đẩy nhu cầu phát triển các nền tảng xử lý dữ liệu lớn hiện đại.

2.3.2 Các thành phần của Apache Spark

Trong những năm gần đây, các nền tảng xử lý dữ liệu lớn như Apache Spark đã thu hút sự quan tâm rộng rãi từ cộng đồng nghiên cứu và công nghiệp. Apache Spark là một hệ thống xử lý dữ liệu phân tán quy mô lớn, có khả năng thực thi nhanh các tác vụ trên các cụm máy tính. So với Hadoop MapReduce, Spark có thể đạt tốc độ xử lý nhanh hơn khoảng 100 lần trong một số trường hợp nhờ vào khả năng xử lý trong bộ nhớ (*in-memory processing*) [37, 38].

Bên cạnh đó, Spark cung cấp giao diện lập trình linh hoạt thông qua các API hỗ trợ nhiều ngôn ngữ phổ biến như Java, Scala, Python và R, giúp việc phát triển và triển khai ứng dụng trở nên thuận tiện hơn.

Apache Spark bao gồm nhiều thành phần chính tạo thành một hệ sinh thái hoàn chỉnh, hỗ trợ đa dạng các tác vụ phân tích dữ liệu như xử lý dữ liệu theo lô (batch), truy vấn SQL, phân tích luồng dữ liệu thời gian thực, học máy và xử lý đồ thị (Hình 2.2).



Hình 2.2. Các thành phần của Apache Spark (Nguồn: [38])


Apache Spark bao gồm nhiều thành phần cốt lõi, mỗi thành phần đảm nhận một chức năng cụ thể trong quá trình xử lý dữ liệu lớn:

- **Spark Core:** Thành phần trung tâm của Spark, chịu trách nhiệm quản lý bộ nhớ, lập lịch, xử lý lỗi, phân phối tác vụ và giao tiếp với các hệ thống lưu trữ. Nó cung cấp các API cấp cao cho Java, Scala, Python và R, giúp đơn giản hóa việc xử lý phân tán.
- **MLlib:** Thư viện học máy tích hợp sẵn trong Spark [39], hỗ trợ huấn luyện và triển khai các mô hình học máy trên quy mô lớn. MLlib cung cấp các thuật toán như phân loại, hồi quy, phân cụm, khai thác mẫu và lọc cộng tác.

- **Spark Streaming:** Công cụ xử lý dữ liệu thời gian thực bằng cách chia luồng dữ liệu thành các lô nhỏ để xử lý tương tự như dữ liệu theo lô. Công cụ này cho phép sử dụng lại mã nguồn và hỗ trợ nhiều nguồn dữ liệu như Kafka, Flume, Twitter, HDFS.
- **Spark SQL:** Thành phần truy vấn dữ liệu phân tán, hỗ trợ ngôn ngữ SQL tiêu chuẩn và HiveQL với hiệu năng cao nhờ tối ưu hóa Catalyst và định dạng cột. Nó hỗ trợ nhiều nguồn dữ liệu như JSON, Hive, Parquet, JDBC, MongoDB, Cassandra.
- **GraphX:** Thư viện xử lý đồ thị phân tán, hỗ trợ biểu diễn, chuyển đổi và phân tích dữ liệu đồ thị. GraphX đi kèm với các thuật toán đồ thị phổ biến như PageRank, Connected Components và nhiều thuật toán phân tích khác.

2.3.3 Kiến trúc của Apache Spark

Kiến trúc của Apache Spark được xây dựng theo mô hình master-worker trên nền tảng xử lý phân tán. Thành phần trung tâm là **Spark Driver**, chịu trách nhiệm điều phối quá trình thực thi ứng dụng, bao gồm việc lên lịch, phân phối tác vụ và giám sát tiến trình. Driver xây dựng một đồ thị phi chu trình có hướng (*DAG* – Directed Acyclic Graph) để xác định luồng thực thi công việc. Tổng quan kiến trúc master-worker được minh họa ở Hình 2.3.



Hình 2.3. Sơ đồ kiến trúc hệ thống Apache Spark (Nguồn: [37])

Các tác vụ được phân phối tới các **Worker Nodes**, nơi chứa các **Executor**, tức các tiến trình thực thi thực tế. Mỗi Executor chịu trách nhiệm thực thi các tác vụ (task) và lưu trữ dữ liệu trong bộ nhớ hoặc ổ đĩa nếu cần. Spark sử dụng **Cluster Manager** (như YARN, Mesos hoặc Standalone) để quản lý tài nguyên trên cụm. Dữ liệu được lưu trữ trên các hệ thống như HDFS, S3, hoặc các cơ sở dữ liệu quan hệ.

2.4 Học máy trong phát hiện xâm nhập

Học máy (ML) đã trở thành một công cụ thiết yếu trong việc phát hiện các mẫu tấn công và hành vi bất thường trong lưu lượng mạng IoT, nhờ khả năng tự động học và thích ứng từ dữ liệu lịch sử [40]. Các kỹ thuật học máy phổ biến bao gồm:

- **Học có giám sát (Supervised Learning):** Sử dụng dữ liệu đã được gán nhãn để huấn luyện mô hình phân loại. Một số thuật toán điển hình gồm Random Forest (RF), SVM và mạng nơ-ron nhân tạo (Neural Networks).
- **Học không giám sát (Unsupervised Learning):** Áp dụng cho các tình huống không có nhãn, tập trung vào việc phát hiện các mẫu bất thường. K-Means là một thuật toán phổ biến trong nhóm này.
- **Học tăng cường (Reinforcement Learning):** Mô hình học dựa trên phản hồi từ môi trường nhằm tối ưu hóa hành vi hoặc quyết định của hệ thống theo thời gian. Hướng này không thuộc phạm vi thực nghiệm của luận văn và chỉ được nêu cho đủ ba nhóm phương pháp.

Trong bối cảnh mạng IoT, học máy được ứng dụng rộng rãi để phân tích lưu lượng dữ liệu và nhận diện các loại tấn công như DDoS, botnet hay giả mạo gói tin. Chẳng hạn, Koroniotis và cộng sự (2019) xây dựng bộ dữ liệu Bot-IoT và báo cáo các mô hình học máy, học sâu đạt độ chính xác gần tuyệt đối khi phát hiện các tấn công DoS/DDoS trong môi trường IoT [41]. Tuy nhiên, các kết quả gần như tuyệt đối (xấp xỉ 100%) trên các tập dữ liệu công khai cần được xem xét thận trọng, vì chúng thường là dấu hiệu của rò rỉ dữ liệu (data leakage) hơn là hiệu năng thực sự của mô hình. *Rò rỉ dữ liệu* là tình huống trong đó thông tin lẽ ra không sẵn có ở thời điểm triển khai thực tế lại lọt vào quá trình huấn luyện hoặc đánh giá, khiến điểm số bị thổi phồng và không phản ánh đúng khả năng tổng quát hóa của mô hình. Luận văn này nhận diện và xử lý vấn đề đó một cách tường minh ở Chương 4.

Tuy nhiên, việc ứng dụng học máy trong hệ thống IoT vẫn còn gặp nhiều thách thức vì yêu cầu xử lý theo thời gian thực và hạn chế về tài nguyên tính toán. Việc tích hợp học máy với các nền tảng xử lý dữ liệu lớn như Apache Spark cho phép xử lý khối lượng dữ liệu lớn với tốc độ cao và triển khai các thuật toán học máy trong môi trường phân tán.

2.4.1 Một số thuật toán học máy

- **Cây quyết định (Decision Trees (DT))** là một trong những thuật toán học máy có giám sát phổ biến, được áp dụng rộng rãi trong các bài toán phân loại. Cấu trúc cơ bản của một cây quyết định bao gồm ba thành phần chính: **nút gốc**, **nút quyết định** và **nút lá**. Cây quyết định có ưu điểm là dễ hiểu, dễ diễn giải, có thể trực quan hóa và không yêu cầu giả định về phân phối dữ liệu. Tuy nhiên, DT cũng dễ bị quá khớp (*overfitting*) nếu không chọn được các tham số hợp lý hoặc xử lý trên dữ liệu nhiễu [42].
- **Rừng ngẫu nhiên (RF)** là một thuật toán học máy được sử dụng phổ biến trong cả hai bài toán phân loại và hồi quy. Đây là một kỹ thuật học tổ hợp (*ensemble learning*) dựa trên việc xây dựng và tổng hợp nhiều cây quyết định độc lập nhằm nâng cao độ chính xác và độ ổn định của mô hình. Thuật toán hoạt động bằng cách tạo ra nhiều cây quyết định trên các tập con khác nhau được chọn ngẫu nhiên từ tập dữ liệu huấn luyện. Mỗi cây được xây dựng dựa trên một mẫu bootstrap (lấy mẫu có hoàn lại), đồng thời tại mỗi nút chia, một tập con ngẫu nhiên của các đặc trưng được chọn để tìm điểm chia tốt nhất, thay vì sử dụng toàn bộ đặc trưng như trong cây quyết định truyền thống [43].

Kết quả cuối cùng được xác định bằng cách:

- ◇ Trong bài toán phân loại: lấy kết quả theo nguyên tắc đa số phiếu (*majority voting*) từ các cây.
- ◇ Trong bài toán hồi quy: lấy giá trị trung bình từ các dự đoán của từng cây.

Việc kết hợp nhiều cây giúp RF giảm thiểu hiện tượng quá khớp (*overfitting*) vốn là một nhược điểm thường gặp của các cây quyết định đơn lẻ. Khi số lượng cây trong rừng tăng lên, hiệu năng dự đoán của mô hình có xu hướng ổn định và cải thiện hơn.

- **Hồi quy logistic (Logistic Regression (LR))** là một phương pháp thống kê được giới thiệu bởi David Cox vào cuối thập niên 1950. Đây là một kỹ thuật học máy có giám sát thường được sử dụng để giải quyết các bài toán phân loại nhị phân, trong đó biến đầu ra (phản hồi) là một biến định tính, nhận giá trị 0 hoặc 1. Mô hình hồi quy logistic cho phép ước tính xác suất xảy ra của một sự kiện cụ thể dựa trên một hoặc nhiều biến đầu vào (độc lập). Một trong những điểm mạnh của phương pháp này là

khả năng xác định mức độ ảnh hưởng của từng yếu tố đến xác suất xuất hiện của kết quả, giúp các nhà phân tích hiểu rõ hơn mối quan hệ giữa biến đầu vào và đầu ra [44].

Về mặt toán học, hàm hồi quy logistic được biểu diễn dưới dạng tuyến tính như sau:

$$z_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_n x_{i,n} \quad (2.1)$$

Trong đó:

- ◇ $x_{i,j}$ là giá trị của biến độc lập thứ j tại quan sát thứ i
- ◇ β_0 là hệ số chặn (bias), β_j là hệ số hồi quy ứng với biến x_j
- ◇ z_i là đầu ra tuyến tính trước khi đưa qua hàm kích hoạt (sigmoid)

Sau đó, xác suất xảy ra của sự kiện được tính thông qua hàm logistic (sigmoid):

$$P(Y_i = 1 \mid \mathbf{x}_i) = \frac{1}{1 + e^{-z_i}} \quad (2.2)$$

Trong quá trình huấn luyện, mô hình tìm các hệ số β_j tối ưu sao cho hàm mất mát (cross-entropy loss) được tối thiểu hóa.

- **GBT** là một phương pháp *boosting* (kết hợp tuần tự các mô hình học yếu, cần phân biệt với “học tăng cường” – reinforcement learning) sử dụng các cây quyết định như mô hình học yếu (weak learners). Ý tưởng chính của boosting là xây dựng một mô hình mạnh bằng cách kết hợp nhiều mô hình học yếu được huấn luyện theo trình tự tuần tự. Ở mỗi bước, thuật toán cố gắng giảm thiểu lỗi của mô hình trước bằng cách học từ phần dư (residual) hoặc gradient của hàm mất mát [45]. Quá trình huấn luyện GBT gồm các bước:

- ◇ Bắt đầu với một mô hình dự đoán ban đầu (thường là giá trị trung bình với bài toán hồi quy).
- ◇ Tính toán sai số còn lại giữa nhãn thực và dự đoán.
- ◇ Huấn luyện một cây quyết định để dự đoán phần dư.
- ◇ Cập nhật mô hình tổng bằng cách cộng mô hình hiện tại với mô hình mới nhân với một hệ số học η (learning rate).

Giả sử $F_0(x)$ là mô hình khởi tạo ban đầu, mô hình tổng tại bước m được cập nhật theo công thức:

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \quad (2.3)$$

Trong đó:

- ◇ $h_m(x)$ là cây quyết định thứ m học theo gradient của hàm mất mát.
- ◇ η là hệ số học (learning rate), thường $\eta \in (0, 1)$.
- **LightGBM (LGBM)** là một framework triển khai thuật toán GBT, được phát triển nhằm tối ưu hóa tốc độ huấn luyện và khả năng mở rộng trên các tập dữ liệu lớn [46], với cùng sơ đồ cập nhật boosting theo gradient đã trình bày ở mục GBT phía trên. Khác với GBT truyền thống, LGBM sử dụng cơ chế phát triển cây theo hướng leaf-wise thay vì level-wise, đồng thời áp dụng thuật toán histogram-based splitting và kỹ thuật Gradient-based One-Side Sampling (GOSS) nhằm giảm chi phí tính toán và tăng tốc độ huấn luyện. Tuy nhiên, LGBM *không* được đưa vào bộ thuật toán so sánh thực nghiệm vì lý do tương thích phần cứng trình bày ở Chương 3. XGBoost và GBT đại diện cho họ gradient boosting.
- **NB** là một phương pháp phân loại xác suất dựa trên định lý Bayes với giả định độc lập có điều kiện giữa các đặc trưng [47]. Mặc dù giả định này thường không hoàn toàn đúng trong thực tế, mô hình vẫn cho hiệu quả tốt trong nhiều bài toán phân loại dữ liệu nhiều chiều.

Theo định lý Bayes:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)} \quad (2.4)$$

Với giả định độc lập giữa các đặc trưng:

$$P(x|y) = \prod_{i=1}^n P(x_i|y) \quad (2.5)$$

Mô hình lựa chọn lớp có xác suất hậu nghiệm lớn nhất:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y) \quad (2.6)$$

Ưu điểm của NB là đơn giản, tốc độ huấn luyện nhanh và phù hợp với dữ liệu kích thước lớn. Tuy nhiên, hạn chế chính nằm ở giả định độc lập giữa các đặc trưng.

- **Support Vector Machine (SVM)** là một thuật toán học có giám sát được đề xuất bởi Cortes và Vapnik [48], nhằm tìm siêu phẳng tối ưu phân tách dữ liệu với khoảng cách biên (margin) lớn nhất.

Trong trường hợp dữ liệu tuyến tính, bài toán tối ưu được biểu diễn như sau:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (2.7)$$

với điều kiện:

$$y_i(w \cdot x_i + b) \geq 1, \quad \forall i = 1, \dots, N \quad (2.8)$$

Trong trường hợp dữ liệu không tuyến tính, SVM sử dụng kỹ thuật *kernel trick* để ánh xạ dữ liệu sang không gian nhiều chiều hơn, cho phép phân tách tuyến tính trong không gian mới. Nhờ cơ chế tối ưu hóa chặt chẽ, SVM thường đạt hiệu năng cao trong các bài toán phân loại với dữ liệu nhiều chiều.

- **Multilayer Perceptron – MLP** là một mô hình học sâu cơ bản gồm nhiều lớp ẩn, có khả năng mô hình hóa các mối quan hệ phi tuyến giữa các đặc trưng [49].

Mỗi nơ-ron trong mạng thực hiện phép biến đổi tuyến tính:

$$z = w^T x + b \quad (2.9)$$

sau đó áp dụng hàm kích hoạt phi tuyến:

$$a = \sigma(z) \quad (2.10)$$

Trong đó $\sigma(\cdot)$ có thể là các hàm kích hoạt như sigmoid, tanh hoặc ReLU. Quá trình huấn luyện sử dụng thuật toán lan truyền ngược (*backpropagation*) nhằm cập nhật trọng số thông qua tối thiểu hóa hàm mất mát bằng gradient descent. MLP có khả năng biểu diễn mạnh nhưng yêu cầu dữ liệu huấn luyện đủ lớn và quá trình điều chỉnh siêu tham số cần thận để tránh hiện tượng quá khớp.

- **XGB** là một phiên bản cải tiến của thuật toán GBT truyền thống, được đề xuất bởi Chen và Guestrin vào năm 2016. XGB được thiết kế để tối ưu hóa tốc độ huấn luyện, hiệu năng mô hình, và khả năng xử lý dữ liệu quy mô lớn trong các hệ thống tính toán phân tán [50]. XGB sử dụng các chiến lược sau để cải thiện hiệu năng:

- ◇ Khai thác gradient và Hessian để tối ưu hóa hiệu quả (second-order optimization).
- ◇ Cắt tỉa cây (pruning) theo độ phức tạp thay vì độ sâu cố định.
- ◇ Tính song song trong việc tìm điểm chia tối ưu (split finding).
- ◇ Hỗ trợ xử lý thiếu giá trị (missing values) tự động.

Mô hình XGB đã được ứng dụng thành công trong nhiều bài toán học máy thực tế như dự báo tài chính, chẩn đoán y tế, phát hiện gian lận và phân tích hành vi khách hàng, nhờ độ chính xác cao và hiệu quả tính toán tốt.

2.4.2 Một số thuật toán học tổ hợp

Học tổ hợp (Ensemble Learning, EL) là một kỹ thuật trong học máy nhằm kết hợp nhiều mô hình riêng lẻ để nâng cao độ chính xác và độ ổn định trong dự đoán. Thay vì chỉ dựa vào một mô hình đơn lẻ, phương pháp EL kết hợp dự đoán của nhiều mô hình (ví dụ DT, RF, LR) để xây dựng một hệ thống dự đoán chính xác hơn. Nguyên lý của EL là: mỗi mô hình riêng lẻ có thể chỉ đạt độ chính xác thấp hoặc dự đoán sai ở một số trường hợp, nhưng sự kết hợp hợp lý của chúng có thể giảm thiểu sai số, tăng độ chính xác nhờ tận dụng điểm mạnh và khắc phục điểm yếu của từng mô hình thành phần [51].

Kỹ thuật EL được sử dụng rộng rãi trong nhiều lĩnh vực yêu cầu độ chính xác cao như: phát hiện gian lận, phân tích dữ liệu lớn, nhận diện hình ảnh và xử lý ngôn ngữ tự nhiên. Trong lĩnh vực bảo mật mạng IoT, EL cũng được ứng dụng để cải thiện khả năng phát hiện bất thường hoặc xâm nhập dựa trên nhiều mô hình học máy được huấn luyện song song hoặc tuần tự.

Một số phương pháp phổ biến của EL bao gồm:

- **Voting:** Với bài toán phân loại, mỗi mô hình con bỏ phiếu cho một lớp và lớp có số phiếu cao nhất sẽ là đầu ra cuối cùng (đa số phiếu hoặc trung bình xác suất). Các bước của voting được mô tả chi tiết ở Thuật toán 2.1.

- **Boosting:** Huấn luyện các mô hình tuần tự, trong đó mỗi mô hình mới tập trung vào các mẫu mà mô hình trước đã dự đoán sai (ví dụ: GBT, AdaBoost, XGB). Các bước của boosting được mô tả chi tiết ở Thuật toán 2.2.
- **Bagging (Bootstrap Aggregating):** Huấn luyện nhiều mô hình trên các tập con ngẫu nhiên (lấy mẫu có hoàn lại) của tập dữ liệu gốc, sau đó tổng hợp kết quả dự đoán (ví dụ: Random Forest). Các bước của bagging được mô tả chi tiết ở Thuật toán 2.3.

EL đặc biệt hữu ích trong các hệ thống phát hiện xâm nhập (IDS) vì cần phân tích lượng lớn dữ liệu phức tạp, và việc kết hợp nhiều mô hình có thể giúp tăng khả năng phát hiện các gói tin bất thường mà một mô hình đơn lẻ có thể bỏ sót.

Thuật toán 2.1. Voting: Kết hợp dự đoán từ nhiều mô hình phân loại

Đầu vào: Tập huấn luyện $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$

Tập mô hình phân loại cơ sở $M_1, M_2, \dots, M_K$

Kiểu voting: HARD hoặc SOFT

Đầu ra: Nhân dự đoán cuối cùng y_{vote} cho điểm dữ liệu x

- 1: **Khởi tạo:** danh sách $S = \{\}$ ▷ Lưu dự đoán hoặc xác suất
 - 2: **if** voting = HARD **then**
 - 3: **for** $j = 1$ to K **do**
 - 4: $y_j \leftarrow M_j(x)$ ▷ Dự đoán nhãn của mô hình thứ j
 - 5: Thêm y_j vào S
 - 6: **end for**
 - 7: $y_{\text{vote}} \leftarrow$ nhãn xuất hiện nhiều nhất trong S
 - 8: **else if** voting = SOFT **then**
 - 9: Khởi tạo xác suất tổng $P_{\text{sum}}[c] = 0, \forall c \in \{1, \dots, C\}$
 - 10: **for** $j = 1$ to K **do**
 - 11: Lấy xác suất $P_j(y = c | x)$ từ mô hình M_j
 - 12: **for** mỗi lớp $c = 1$ to C **do**
 - 13: $P_{\text{sum}}[c] \leftarrow P_{\text{sum}}[c] + P_j(y = c | x)$
 - 14: **end for**
 - 15: **end for**
 - 16: $y_{\text{vote}} \leftarrow \arg \max_c P_{\text{sum}}[c]$
 - 17: **end if**
 - 18: **return** y_{vote}
-

Thuật toán 2.2. Boosting: Kết hợp tuần tự các mô hình học yếu

Đầu vào: Tập dữ liệu huấn luyện $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
 Số lượng vòng lặp (mô hình yếu): T

Đầu ra: Mô hình boosting $F_T(x)$

- 1: **Khởi tạo:** $F_0(x) \leftarrow 0$ $\triangleright$ Mô hình khởi đầu có thể là 0 hoặc dự đoán trung bình
 - 2: **for** $t = 1$ to T **do**
 - 3: Tính giả-phần-dư (pseudo-residuals) theo gradient âm của hàm mất mát: $r_i^{(t)} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{t-1}}$ $\triangleright$ Với mất mát bình phương (hồi quy), rút gọn thành $y_i - F_{t-1}(x_i)$; với phân loại dùng log-loss
 - 4: Huấn luyện mô hình yếu $h_t(x)$ trên các giả-phần-dư $r_i^{(t)}$
 - 5: Cập nhật mô hình: $F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$
 - 6: **end for**
 - 7: **return** $F_T(x)$
-

Thuật toán 2.3. Bagging: Bootstrap Aggregating


Đầu vào: Tập huấn luyện $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, với $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (tổng quát: C lớp)
 Số lượng mô hình cơ sở: K

Đầu ra: Dự đoán cuối cùng y_{bag} cho một điểm dữ liệu x

- 1: **Khởi tạo:** Danh sách mô hình $M_1, M_2, \dots, M_K$
 - 2: **for** $k = 1$ to K **do**
 - 3: Tạo mẫu bootstrap $\mathcal{D}^{(k)}$ từ $\mathcal{D}$ (lấy mẫu ngẫu nhiên có hoàn lại)
 - 4: Huấn luyện mô hình $M_k \leftarrow \text{Train}(\mathcal{D}^{(k)})$
 - 5: **end for**
 - 6: **Khởi tạo:** Danh sách dự đoán $Y = \{\}$
 - 7: **for** $k = 1$ to K **do**
 - 8: Thực hiện dự đoán $y_k \leftarrow M_k(x)$
 - 9: Thêm y_k vào Y
 - 10: **end for**
 - 11: Tính $y_{\text{bag}} \leftarrow \text{Voting}(Y)$ $\triangleright$ Hard voting hoặc trung bình xác suất nếu dùng soft
 - 12: **return** y_{bag}
-

Chương 3. PHƯƠNG PHÁP THỰC HIỆN

Trong chương này, luận văn sẽ trình bày phương pháp đề xuất để xây dựng mô hình phát hiện xâm nhập dựa trên Apache Spark cho bảo mật mạng IoT. Quá trình thực hiện bao gồm 6 bước chính, được thể hiện qua Hình 3.1: (1) Thu thập dữ liệu và tiền xử lý; (2) Xây dựng đặc trưng và lựa chọn đặc trưng; (3) Huấn luyện mô hình; (4) Đánh giá mô hình; (5) Tối ưu siêu tham số và (6) Triển khai biên thời gian thực. Các bước (1)–(5) được lặp lại tương ứng với từng phương pháp lựa chọn đặc trưng (Random Forest Importance (RFI), SHAP, PCA), sau đó lựa chọn mô hình tốt nhất để triển khai trên thiết bị biên.



Hình 3.1. Quy trình tổng thể huấn luyện, đánh giá và triển khai mô hình đề xuất

3.1 Thu thập dữ liệu và tiền xử lý

Trong nghiên cứu này, tập dữ liệu được sử dụng là CICIDS2017 được phát hành bởi Viện An ninh mạng Canada (CIC). Tập dữ liệu này được xây dựng nhằm mô phỏng lưu lượng mạng thực tế kết hợp với nhiều loại tấn công mạng hiện đại, phục vụ cho việc huấn luyện và đánh giá các mô hình phát hiện xâm nhập. Tập dữ liệu CICIDS2017 tập trung vào các kịch bản tấn công đơn lẻ trong môi trường kiểm soát. Các bộ dữ liệu phát hiện xâm nhập mạng công khai, bao gồm CICIDS2017, có những giới hạn đã được khảo sát một cách hệ thống (lỗi gán nhãn, tạo tác khi sinh lưu lượng, và khả năng tổng quát hóa hạn chế) [52].

CHƯƠNG 3. PHƯƠNG PHÁP THỰC HIỆN

Đây là lý do luận văn áp dụng quy trình loại trừ rõ ràng ở bước tiền xử lý và bổ sung đánh giá liên bộ dữ liệu ở Chương 4. Thông tin chi tiết về tập dữ liệu được trình bày trong Bảng 3.1.

Bảng 3.1. Mô tả bộ dữ liệu CICIDS2017

Thuộc tính	Giá trị
Tổ chức phát hành	Canadian Institute for Cybersecurity (CIC)
Thời gian phát hành	2017
Giao thức mạng	HTTP, HTTPS, FTP, SSH, DNS, ...
Số lượng bản ghi (CSV)	Hơn 2.8 triệu bản ghi
Thời gian thu thập	03/07/2017 – 07/07/2017
Loại tấn công mô phỏng	DoS, DDoS, PortScan, Brute-force, Infiltration, Botnet, ...
Số loại nhãn	15 (1 nhãn bình thường + 14 loại tấn công)
Định dạng dữ liệu	CSV
Mục đích	Phát hiện xâm nhập mạng trong môi trường thực tế giả lập
Nguồn dữ liệu	[53]

Bên cạnh CICIDS2017 (bộ dữ liệu chính cho toàn bộ các thí nghiệm), luận văn sử dụng thêm **CSE-CIC-IDS2018** cho thí nghiệm *tổng quát hóa liên bộ dữ liệu* (Mục 4.2.9): huấn luyện trên một bộ, kiểm tra trên bộ kia và ngược lại. Đây là bộ kế nhiệm của CICIDS2017, do CIC phối hợp với Cơ quan An ninh Truyền thông Canada (CSE) thu thập trên hạ tầng AWS quy mô lớn hơn nhiều. Đặc trưng luồng được trích xuất bằng CICFlowMeter phiên bản mới hơn nên tên cột được ánh xạ về danh mục tên cột chuẩn của CICIDS2017 qua bảng bí danh tường minh trong mã nguồn. Thông tin chi tiết ở Bảng 3.2.

CHƯƠNG 3. PHƯƠNG PHÁP THỰC HIỆN

Bảng 3.2. Mô tả bộ dữ liệu CSE-CIC-IDS2018 (dùng cho thí nghiệm liên bộ dữ liệu)

Thuộc tính	Giá trị
Tổ chức phát hành	CIC phối hợp CSE (Communications Security Establishment)
Thời gian phát hành	2018
Hạ tầng thu thập	Testbed trên AWS (~450 máy nạn nhân, 50 máy tấn công)
Số lượng bản ghi (CSV)	~16,2 triệu luồng (10 tệp CSV theo ngày)
Thời gian thu thập	14/02/2018 – 02/03/2018
Loại tấn công mô phỏng	DDoS (HOIC, LOIC-HTTP/UDP), DoS (Hulk, GoldenEye, Slowloris, SlowHTTPTest), Bot, Brute-force (SSH, FTP, Web, XSS), SQL Injection, Infiltration
Số loại nhãn	15 (1 nhãn bình thường + 14 loại tấn công)
Phân bố nhị phân (sau làm sạch)	~13,35 triệu Benign / ~2,35 triệu Attack
Phần dùng trong luận văn	Mẫu phân tầng theo nhãn 20% ($seed=42$), còn ~2,39 triệu luồng sau khử trùng lặp mức đặc trưng
Định dạng dữ liệu	CSV (CICFlowMeter v3, tên cột ánh xạ về chuẩn CICIDS2017)
Nguồn dữ liệu	[54]

Tiền xử lý dữ liệu Việc tiền xử lý dữ liệu nhằm loại bỏ nhiễu, giá trị ngoại lệ và giá trị bị thiếu được thực hiện trước khi đưa dữ liệu vào huấn luyện mô hình. Các kỹ thuật được áp dụng gồm chuẩn hóa tên cột, căn chỉnh lược đồ giữa các tệp, thay thế giá trị vô cùng, loại bỏ bản ghi trùng lặp/thiếu, và gán nhãn nhị phân (BENIGN = 0, Attack = 1).

Bên cạnh đó, để bảo đảm kết quả đánh giá phản ánh đúng hiệu năng mô hình, luận văn áp dụng thêm hai bước *loại trừ rò rỉ dữ liệu* (loại cấm bẫy “data snooping” được xem là phổ biến nhất của học máy trong an ninh [55]) ngay trong giai đoạn tiền xử lý, trước khi phân chia tập: (i) **loại đặc trưng rò rỉ nhãn** `destination_port` (và `source_port` nếu có): trong CICIDS2017, mỗi loại tấn công được sinh nhằm vào những cổng dịch vụ cố định nên cổng đích gần như mã hóa trực tiếp nhãn, khiến mô hình “ghi nhớ” ánh xạ cổng–nhãn thay vì học hành vi luồng (cột `protocol` cũng được loại với lý do tương tự: đây là biến phân loại có ít mức giá trị, tương quan mạnh với cổng dịch vụ nên mang cùng nguy cơ “lỗi tắt” định danh dịch vụ thay vì hành vi) và (ii) **loại bỏ trùng lặp ở mức đặc trưng theo cơ chế tắt định**: các luồng được gom nhóm theo toàn bộ vector đặc trưng. Với nhóm có nhãn nhất quán, giữ lại đúng một đại diện; với nhóm trùng đặc trưng nhưng *mâu thuẫn nhãn* (cùng vector đặc trưng, nhãn vừa Benign vừa Attack, một lỗi gán nhãn đã được ghi nhận của CICIDS2017 [56]), *toàn bộ nhóm bị loại* vì không thể xác định nhãn đúng, thay vì giữ lại một hàng tùy ý theo phân mảnh dữ liệu (vốn không tái lập được giữa các lần chạy). Số nhóm và số hàng xung đột nhãn được ghi log tường minh (270 nhóm, 44.260 hàng). Cơ

CHƯƠNG 3. PHƯƠNG PHÁP THỰC HIỆN

chế này tránh việc cùng một mẫu xuất hiện ở cả tập huấn luyện lẫn kiểm tra khi phân chia ngẫu nhiên. Đối với bộ dữ liệu CICIDS2017, quá trình tiền xử lý dữ liệu được thể hiện chi tiết ở Thuật toán 3.1. Bước loại bỏ trùng lặp ở mức đặc trưng làm *thay đổi phân bố lớp*: do các luồng benign trùng lặp nhiều hơn nên bị loại nhiều hơn, khiến tỷ lệ benign/attack sau khi xử lý khác với tỷ lệ ban đầu. Vì vậy, phân bố lớp trước và sau khi loại trùng lặp được báo cáo tường minh để bảo đảm minh bạch.

Phân chia tập dữ liệu

Tập dữ liệu CICIDS2017 được phân chia theo tỷ lệ 80/20 cho huấn luyện và kiểm tra bằng phép chia ngẫu nhiên (random split) với seed cố định ($=42$) để bảo đảm tái lập. Các chỉ số hiệu năng được **công bố trên tập kiểm tra** (tập giữ lại cuối cùng, không tham gia huấn luyện, xếp hạng đặc trưng hay tinh chỉnh siêu tham số). Kết quả trên tập huấn luyện chỉ được dùng để chẩn đoán hiện tượng quá khớp (overfitting) hoặc thiếu khớp (underfitting). Ngoài ra, `StandardScaler`, PCA và việc xếp hạng đặc trưng (RF Importance, SHAP) đều được *fit chỉ trên tập huấn luyện* D_{train} rồi *transform* lên tập kiểm tra, nhằm tránh rò rỉ thông tin từ tập kiểm tra vào quá trình huấn luyện. Riêng việc **chọn Top-3 mô hình thành phần** cho các ensemble (cũng như việc chọn mô hình đại diện mỗi phương pháp và cặp phương pháp đưa vào kiểm định thống kê, Chương 4) được thực hiện trên một *tập kiểm định* (*validation*) tách từ tập huấn luyện (theo tỷ lệ 80/20, $seed=42$, các mô hình cơ sở huấn luyện trên phần còn lại). Nhờ vậy, tập kiểm tra hoàn toàn không tham gia vào khâu lựa chọn mô hình, khép kín nguy cơ rò rỉ chọn lọc. Tương tự, ngưỡng của cổng phát hiện bất thường (Chương 4) cũng chỉ được chọn trên 10% lưu lượng benign tách từ tập huấn luyện ($seed=42$), không sử dụng tập kiểm tra. Toàn bộ quy trình phân chia được minh họa ở Hình 3.2.



Hình 3.2. Sơ đồ phân chia dữ liệu CICIDS2017 (train/test 80/20, $seed=42$, trong đó train tách tiếp 80/20 thành base-train/validation)

Thuật toán 3.1. Tiền xử lý dữ liệu CICIDS2017

Đầu vào: Tập N tệp CSV từ bộ dữ liệu CICIDS2017: $\{F_1, F_2, \dots, F_N\}$

Tỷ lệ phân chia huấn luyện/kiểm tra $\alpha = 0,8$

Đầu ra: Tập huấn luyện D_{train} và tập kiểm tra D_{test} ở định dạng Parquet

```

1: Bước 1: Gộp dữ liệu từ nhiều tệp CSV
2:  $D \leftarrow \emptyset$ 
3: for  $i = 1$  to  $N$  do
4:   Đọc tệp  $F_i$  thành DataFrame  $df_i$  với lược đồ suy luận tự động
5:    $\text{CLEANCOLUMNAMES}(df_i)$   $\triangleright$  Chuẩn hóa tên cột: xóa khoảng trắng, chuyển chữ thường
6:    $\text{HANDLEINFINITYVALUES}(df_i)$   $\triangleright$  Thay thế  $\pm\infty$  bằng giá trị NaN
7:   if  $D = \emptyset$  then
8:      $S \leftarrow \text{Schema}(df_i)$   $\triangleright$  Lưu lược đồ chuẩn từ tệp đầu tiên
9:      $D \leftarrow df_i$ 
10:  else
11:     $\text{ALIGNSCHEMA}(df_i, S)$   $\triangleright$  Căn chỉnh lược đồ về chuẩn  $S$ 
12:     $D \leftarrow D \cup df_i$   $\triangleright$  Gộp theo tên cột (unionByName)
13:  end if
14: end for
15: Bước 2: Làm sạch dữ liệu
16:  $D \leftarrow \text{RemoveDuplicates}(D)$   $\triangleright$  Loại bỏ các bản ghi trùng lặp hoàn toàn (giống hệt trên mọi cột)
17:  $D \leftarrow \text{RemoveNulls}(D)$   $\triangleright$  Loại bỏ các bản ghi chứa giá trị null/NaN
18: Bước 3: Tạo nhãn nhị phân
19:  $\forall (x_i, \text{label}_i) \in D : y_i \leftarrow \begin{cases} 0 & \text{nếu label}_i = \text{"BENIGN"} \\ 1 & \text{ngược lại (Attack)} \end{cases}$ 
     $\rightarrow$  Hai bước loại trừ rò rỉ dữ liệu (data leakage): Bước 4 và Bước 4b
20: Bước 4 [loại rò rỉ – I]: Xác định các đặc trưng số (đã loại trừ rò rỉ)
21:  $C_{\text{exclude}} \leftarrow \{\text{label, label\_binary, source\_ip, destination\_ip, flow\_id, timestamp, protocol,}$   

       $\text{destination\_port, source\_port}\}$   $\triangleright$  Loại bỏ đặc trưng gây rò rỉ nhãn
22:  $\mathcal{F} \leftarrow \{c \in \text{columns}(D) \mid c \notin C_{\text{exclude}} \wedge \text{dtype}(c) \in \{\text{double, float, int, bigint}\}\}$ 
23: Bước 4b [loại rò rỉ – II]: Loại bỏ trùng lặp ở mức đặc trưng (tắt định)
24:  $G \leftarrow \text{GroupBy}(D, \mathcal{F})$   $\triangleright$  Gom nhóm theo toàn bộ vector đặc trưng
25: for mỗi nhóm  $g \in G$  do
26:   if  $|\{y_i : (x_i, y_i) \in g\}| > 1$  then  $\triangleright$  Nhóm mâu thuẫn nhãn (Benign lẫn Attack)
27:     Loại toàn bộ nhóm  $g$  khỏi  $D$ ; ghi log số nhóm/hàng xung đột
28:   else
29:     Giữ lại đúng một đại diện của  $g$  (thứ tự tắt định theo nhãn)
30:   end if
31: end for
32: Bước 5: Phân chia và lưu trữ
33:  $D_{\text{train}}, D_{\text{test}} \leftarrow \text{RandomSplit}(D, [\alpha, 1 - \alpha], \text{seed} = 42)$ 
34: Lưu  $D_{\text{train}}, D_{\text{test}}$  dưới định dạng Parquet
35: return  $D_{\text{train}}, D_{\text{test}}$ 

```

3.2 Lựa chọn đặc trưng và giảm chiều dữ liệu

Trong quá trình tiền xử lý dữ liệu cho bài toán phát hiện xâm nhập mạng, lựa chọn đặc trưng bao gồm **chọn đặc trưng** và **trích xuất đặc trưng** là một bước quan trọng nhằm giảm chiều dữ liệu, loại bỏ những đặc trưng không cần thiết, và cải thiện hiệu năng của mô hình học máy [57]. Dữ liệu số được gom vào vector đặc trưng bằng `VectorAssembler` (khoảng 78 đặc trưng số trước khi loại cổng, chính xác là 77 đặc trưng sau khi loại `destination_port/source_port`) và được chuẩn hóa bằng `StandardScaler` (chuẩn hóa Z-score). Ba phương pháp được sử dụng trong luận văn là *RF*, *SHAP* và *PCA*.

- a) **Principal Component Analysis (PCA)**: Là phương pháp giảm chiều dữ liệu không giám sát, nhằm biến đổi tập đặc trưng ban đầu thành một tập các thành phần chính (principal components) mới không tương quan tuyến tính với nhau và giữ lại phần lớn phương sai của dữ liệu. PCA thực hiện bằng cách tính ma trận hiệp phương sai và tìm các vector riêng (eigenvectors) tương ứng với các giá trị riêng (eigenvalues). Các thành phần chính được xác định bằng cách giải bài toán:

$$Cv = \lambda v \quad (3.1)$$

Trong đó:

- C là ma trận hiệp phương sai của dữ liệu.
- v là vector riêng (principal component).
- λ là giá trị riêng, biểu thị lượng phương sai được giải thích.

Các thành phần chính có giá trị riêng lớn nhất sẽ được lựa chọn để tạo thành không gian đặc trưng mới với số chiều thấp hơn nhưng vẫn giữ được phần lớn thông tin của dữ liệu. Đây là phương pháp được sử dụng phổ biến trong phân tích dữ liệu đa biến và học máy để giảm chiều, loại bỏ nhiễu và trực quan hóa dữ liệu [58].

- b) **SHapley Additive exPlanations (SHAP)**: Là phương pháp giải thích mô hình dựa trên lý thuyết trò chơi, dùng để đo lường mức độ đóng góp của từng đặc trưng vào dự đoán của mô hình. SHAP tính giá trị Shapley cho mỗi đặc trưng bằng cách xét trung bình đóng góp biên của đặc trưng đó trên tất cả các tập con có thể:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)] \quad (3.2)$$

Trong đó:

- F là tập tất cả các đặc trưng.
- S là tập con của các đặc trưng không chứa i .
- $f(S)$ là giá trị dự đoán của mô hình khi chỉ sử dụng tập đặc trưng S .
- ϕ_i là mức độ đóng góp của đặc trưng i vào kết quả dự đoán.

Các đặc trưng có giá trị SHAP lớn (theo độ lớn tuyệt đối) được xem là có ảnh hưởng quan trọng hơn đến quyết định của mô hình. Phương pháp này được ứng dụng rộng rãi trong giải thích mô hình phức tạp như XGBoost, Random Forest, và mạng nơ-ron [59].

- c) **Random Forest Feature Importance:** Thuật toán RF có khả năng đánh giá tầm quan trọng của từng đặc trưng dựa trên mức độ đóng góp vào việc giảm độ bất thuần (impurity) tại các nút phân chia của cây quyết định. Độ quan trọng $I(f_j)$ của đặc trưng f_j được tính như sau:

$$I(f_j) = \frac{1}{T} \sum_{t=1}^T \sum_{n \in N_t(f_j)} \Delta i(n) \quad (3.3)$$

Trong đó:

- T là số lượng cây trong rừng.
- $N_t(f_j)$ là tập các nút trong cây t sử dụng đặc trưng f_j để phân chia.
- $\Delta i(n)$ là lượng giảm độ bất thuần (ví dụ: Gini hoặc Entropy) tại nút n .

Các đặc trưng có độ quan trọng cao hơn sẽ được ưu tiên lựa chọn để đưa vào mô hình huấn luyện. Sau khi huấn luyện mô hình RF, các đặc trưng có giá trị quan trọng thấp hơn một ngưỡng định trước sẽ bị loại bỏ, giữ lại những đặc trưng có ảnh hưởng lớn đến việc phân loại.

3.3 Huấn luyện mô hình

3.3.1 Huấn luyện các mô hình cơ sở

Tám thuật toán phân loại có giám sát được huấn luyện độc lập trên tập đặc trưng đã qua bước xây dựng và lựa chọn đặc trưng. Bảng 3.3 liệt kê các thuật toán cùng thông tin chi tiết về biến thể và phương pháp học.

Bảng 3.3. Tám bộ phân loại cơ sở được sử dụng trong pipeline

Thuật toán	Biến thể / Ghi chú	Phương pháp học
Decision Tree	CART	Phân chia đệ quy theo Gini / Entropy
Logistic Regression	Chuẩn hóa L2	Tối ưu hàm mất mát logistic
Linear SVM	SVC tuyến tính	Tối đa hóa biên phân loại
Naive Bayes	Phân phối Gaussian	Ước lượng xác suất hậu nghiệm
Random Forest	Bagging	Tổ hợp cây quyết định ngẫu nhiên
GBT	Gradient Boosting	Tối thiểu hóa hàm mất mát theo gradient
XGBoost	Gradient Boosting tối ưu	Regularised Gradient Boosting
MLP	Mạng nơ-ron nhân tạo	Lan truyền ngược (Backpropagation)

Đáng lưu ý, LightGBM (một thư viện gradient boosting phổ biến) *không* được đưa vào danh sách trên vì thư viện gốc (native, thông qua SynapseML) chỉ hỗ trợ kiến trúc x86_64, không chạy được trên thiết bị biên Jetson Orin Nano Super (ARM64), vốn là mục tiêu triển khai của nghiên cứu. XGBoost và GBT đã đại diện đầy đủ cho họ gradient boosting.

Xử lý mất cân bằng lớp. Do tỷ lệ Benign/Attack lệch nhau đáng kể, sáu mô hình MLlib (Decision Tree, Logistic Regression, Linear SVC, Random Forest, GBT, Naive Bayes) được huấn luyện với trọng số lớp (`weightCol`) đặt theo tỷ lệ nghịch của tần suất lớp benign/attack. XGBoost dùng tham số `scale_pos_weight` với vai trò tương đương. Riêng MLP là ngoại lệ không áp trọng số lớp do API `MultilayerPerceptronClassifier` của Spark MLlib không hỗ trợ `weightCol`.

Sau khi huấn luyện, tám mô hình được xếp hạng theo chiều giảm dần của F1-Score trên tập kiểm định (validation, tách từ tập huấn luyện, xem mục Phân chia tập dữ liệu) để xác định top-3 mô hình tốt nhất phục vụ bước kết hợp ensemble tiếp theo. Tập kiểm tra hoàn toàn không được sử dụng ở bước chọn mô hình này nhằm tránh rò rỉ chọn lọc (selection leakage).

3.3.2 Các phương pháp Ensemble Learning

Bảng 3.4. Các phương pháp học tổ hợp (ensemble) sử dụng trong luận văn

Phương pháp	Mô tả chi tiết
Hybrid Bagging	Top-3 mô hình kết hợp theo sơ đồ (3-2-2) sub-samples với <i>Weighted Soft Voting</i> : dự đoán xác suất có trọng số
Soft Voting	Trung bình xác suất Top-3 mô hình theo F1-Score Nhãn <i>Attack</i> nếu xác suất trung bình $\geq 0,5$

a) Áp dụng Voting

Sau khi hoàn tất giai đoạn huấn luyện đơn mô hình, luận văn tiến hành xây dựng mô hình ensemble dựa trên kỹ thuật Voting để nâng cao độ chính xác và tính ổn định của hệ thống phân loại. Hai phương pháp tổ hợp được sử dụng được tóm tắt trong Bảng 3.4. Cụ thể, ba mô hình phân loại nhị phân có chỉ số F1-Score cao nhất ở giai đoạn trước sẽ được lựa chọn để tham gia vào quá trình ensemble.

Mỗi mô hình trong tập được chọn sẽ đưa ra dự đoán độc lập cho từng mẫu trong tập kiểm tra. Các dự đoán này sau đó được tổng hợp thông qua cơ chế bầu chọn. Trong trường hợp Soft Voting, xác suất dự đoán lớp *Attack* của các mô hình thành phần được lấy trung bình. Mẫu được gán nhãn *Attack* nếu xác suất trung bình đạt từ 0,5 trở lên, ngược lại được gán nhãn *Benign*.

Việc áp dụng kỹ thuật Voting cho phép khai thác sự đa dạng giữa các mô hình học cơ sở, từ đó giảm sai số do thiên lệch của từng mô hình riêng lẻ và cải thiện khả năng tổng quát hóa trên dữ liệu chưa từng thấy. Quy trình chi tiết được trình bày trong Thuật toán 3.2.

Thuật toán 3.2. Soft Voting Ensemble

Đầu vào: Tập dữ liệu huấn luyện $D = \{(x_i, y_i)\}_{i=1}^n$ với $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$
 Tập kiểm định D_{val} (tách từ D , dùng để xếp hạng và chọn mô hình thành phần)
 Tập dữ liệu kiểm tra $D_{\text{test}} = \{(x_j)\}_{j=1}^m$
 Tập K thuật toán học cơ sở khác loại $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

Đầu ra: Nhân dự đoán cuối cùng $y_{\text{vote}} \in \{0, 1\}$ cho mỗi mẫu

- 1: **Bước 1: Huấn luyện và đánh giá K mô hình cơ sở**
- 2: **for** $k = 1$ to K **do**
- 3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Huấn luyện trên phần train lỗi, tách khỏi D_{val}
- 4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tính điểm F1 trên tập kiểm định (validation), không chạm tập kiểm tra
- 5: **end for**
- 6: **Bước 2: Chọn Top-3 mô hình có F1 cao nhất**
- 7: Sắp xếp $\{M_1, \dots, M_K\}$ theo F_k giảm dần
- 8: Chọn 3 mô hình tốt nhất: $\mathcal{S} = \{M^{(1)}, M^{(2)}, M^{(3)}\}$ với $F^{(1)} \geq F^{(2)} \geq F^{(3)}$
- 9: **Bước 3: Thu thập xác suất dự đoán từ 3 mô hình được chọn**
- 10: **for** mỗi mẫu $x_j \in D_{\text{test}}$ **do**
- 11: **for** mỗi $M^{(s)} \in \mathcal{S}$, $s = 1, 2, 3$ **do**
- 12: $p_s^{(j)} \leftarrow P^{(s)}(y = 1 \mid x_j)$ ▷ Xác suất lớp Attack từ mô hình $M^{(s)}$
- 13: **end for**
- 14: **end for**
- 15: **Bước 4: Kết hợp bằng bầu chọn mềm (Soft Voting)**
- 16: **for** mỗi mẫu $x_j \in D_{\text{test}}$ **do**
- 17: $\bar{p}_j \leftarrow \frac{1}{3} \sum_{s=1}^3 p_s^{(j)}$ ▷ Trung bình xác suất lớp Attack
- 18: **if** $\bar{p}_j \geq 0,5$ **then**
- 19: $y_{\text{vote}}^{(j)} \leftarrow 1$ ▷ Dự đoán: Attack
- 20: **else**
- 21: $y_{\text{vote}}^{(j)} \leftarrow 0$ ▷ Dự đoán: Benign
- 22: **end if**
- 23: **end for**
- 24: **return** $\{y_{\text{vote}}^{(j)}\}_{j=1}^m$

b) Áp dụng Bagging

Để áp dụng kỹ thuật học tổ hợp Bagging, luận văn đề xuất xây dựng một mô hình ensemble lai (Hybrid Bagging Ensemble) dựa trên các mô hình cơ sở có hiệu năng cao nhất (đã huấn luyện và xếp hạng ở bước trước). Cụ thể, thay vì chỉ sử dụng một mô hình đơn lẻ, quy trình bắt đầu bằng việc huấn luyện và đánh giá K thuật toán học cơ sở trên tập dữ liệu huấn luyện D . Hiệu năng của từng mô hình được đo lường thông qua chỉ số F1-Score, từ đó lựa chọn ba mô hình có kết quả tốt nhất để đưa vào giai đoạn kết hợp.

Sau khi xác định Top-3 mô hình, phương pháp Bagging được áp dụng theo phân bố số bản sao (3, 2, 2). Đối với mỗi mô hình trong ba mô hình được chọn, nhiều tập dữ liệu bootstrap được tạo ra bằng cách lấy mẫu ngẫu nhiên có hoàn lại từ tập huấn luyện ban đầu. Trên mỗi tập bootstrap này, một bản sao của mô hình tương ứng được huấn luyện độc lập, tạo thành các *bộ học cơ sở* (*base learners*) trong ensemble. Mỗi base learner được gán trọng số tỷ lệ với F1-Score của mô hình gốc nhằm phản ánh mức độ tin cậy tương đối của nó trong quá trình tổng hợp. Việc phân bố bất đối xứng (3, 2, 2), tức cấp nhiều bản sao bootstrap hơn cho mô hình hạng cao, là một lựa chọn thiết kế thực nghiệm nhằm thiên ensemble về phía các bộ học mạnh hơn trong khi vẫn giữ tính đa dạng từ ba thuật toán khác loại. Đây là một heuristic, không phải kết quả của tối ưu hóa lý thuyết, và các tỷ lệ khác (chẳng hạn 3-3-3) có thể được khảo sát trong nghiên cứu tiếp theo.

Trong giai đoạn dự đoán, toàn bộ các mô hình trong ensemble đưa ra phân phối xác suất dự đoán cho mẫu đầu vào mới. Kết quả cuối cùng được xác định thông qua cơ chế Soft Voting có trọng số, trong đó xác suất của từng lớp được tính bằng tổng có trọng số của các xác suất thành phần. Nhân dự đoán cuối cùng được chọn là lớp có xác suất tổng hợp lớn nhất.

Cách tiếp cận này cho phép giảm phương sai của các mô hình cơ sở nhờ cơ chế lấy mẫu bootstrap, đồng thời duy trì khả năng học biểu diễn của từng thuật toán riêng lẻ. Việc chọn lọc các mô hình có hiệu năng cao nhất trước khi áp dụng Bagging nhằm cân bằng giữa độ chính xác và tính ổn định của hệ thống. Chi tiết quy trình được trình bày trong Thuật toán 3.3.

Thuật toán 3.3. Hybrid Bagging Ensemble Learning

Đầu vào: Tập dữ liệu huấn luyện $D = \{(x_i, y_i)\}_{i=1}^n$ với $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (BENIGN = 0, Attack = 1)

Tập kiểm định D_{val} (tách từ D , dùng để xếp hạng và chọn Top-3)

Tập K thuật toán học cơ sở $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

Phân bố số bản sao $\mathbf{r} = (r_1, r_2, r_3) = (3, 2, 2)$

Đầu ra: Nhãn dự đoán cuối cùng $y_{\text{bag}} \in \{0, 1\}$

1: **Bước 1: Huấn luyện và đánh giá K mô hình cơ sở**

2: **for** $k = 1$ to K **do**

3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Huấn luyện trên phần train lỗi, tách khỏi D_{val}

4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tính điểm F1 trên tập kiểm định (validation), không chạm tập kiểm tra

5: **end for**

6: **Bước 2: Chọn Top-3 mô hình có F1 cao nhất**

7: Sắp xếp $\{M_1, \dots, M_K\}$ theo F_k giảm dần

8: Chọn 3 mô hình tốt nhất: $M^{(1)}, M^{(2)}, M^{(3)}$ với $F^{(1)} \geq F^{(2)} \geq F^{(3)}$

9: **Bước 3: Tạo ensemble theo phân bố 3-2-2**

10: $\mathcal{E} \leftarrow \emptyset$ ▷ Tập ensemble gồm 7 mô hình

11: **for** $j = 1$ to 3 **do**

12: **for** $i = 1$ to r_j **do**

13: Tạo tập bootstrap $D_{j,i}$ bằng cách lấy ngẫu nhiên n mẫu từ $D \setminus D_{\text{val}}$ **có hoàn lại**

14: $h_{j,i} \leftarrow \text{Train}(\mathcal{L}^{(j)}, D_{j,i})$ ▷ Huấn luyện bản sao thứ i của mô hình hạng j

15: Gán trọng số $w_{j,i} \leftarrow F^{(j)}$ ▷ Trọng số dựa trên F1-Score

16: Thêm $(h_{j,i}, w_{j,i})$ vào $\mathcal{E}$

17: **end for**

18: **end for**

19: Chuẩn hóa trọng số: $w_{j,i} \leftarrow \frac{w_{j,i}}{\sum_{(h,w) \in \mathcal{E}} w}$

20: **Bước 4: Dự đoán cho mẫu mới x (Soft Voting có trọng số)**

21: $T \leftarrow |\mathcal{E}| = 7$ ▷ Tổng số mô hình trong ensemble

22: **for** mỗi $(h_t, w_t) \in \mathcal{E}$, $t = 1, \dots, T$ **do**

23: $\mathbf{p}_t \leftarrow h_t(x)$ ▷ Lấy vector xác suất dự đoán

24: **end for**

25: Tính xác suất có trọng số: $\bar{p}(c | x) = \sum_{t=1}^T w_t \cdot P_t(c | x), \quad \forall c \in \{0, 1\}$

26: $y_{\text{bag}} \leftarrow \arg \max_{c \in \{0,1\}} \bar{p}(c | x)$

27: **return** y_{bag}

3.4 Đánh giá mô hình

Mỗi mô hình (cơ sở và ensemble) được đánh giá trên bốn chiều:

Bảng 3.5. Các tiêu chí đánh giá mô hình

Tiêu chí	Mô tả
Độ chính xác (Accuracy)	Tỷ lệ dự đoán đúng trên toàn bộ mẫu kiểm tra
Precision	Tỷ lệ cảnh báo đúng trong tổng số cảnh báo được phát ra
Recall	Tỷ lệ phát hiện đúng trong tổng số mẫu tấn công thực tế
F1-Score	Trung bình điều hòa của Precision và Recall
Area Under the Curve – Receiver Operating Characteristic	Diện tích dưới đường cong ROC, đo hiệu năng phân biệt lớp
Area Under the Curve – PR	Diện tích dưới đường cong Precision-Recall
Chi phí tính toán	Thời gian huấn luyện, thời gian dự đoán và kích thước mô hình
Khả năng giải thích (Explainable Artificial Intelligence)	Biểu đồ SHAP: summary plot, bar chart và waterfall plot

Hiệu năng của mô hình được đánh giá thông qua các chỉ số phân loại phổ biến như Accuracy, Precision, Recall và F1-Score, kết hợp với phân tích đường cong AUC (ROC và PR), chi phí tính toán (thời gian huấn luyện và suy luận), cũng như khả năng giải thích của mô hình (ví dụ: biểu đồ tổng quan SHAP). Các tiêu chí đánh giá được tổng hợp trong Bảng 3.5. Để kiểm chứng mô hình phát hiện xâm nhập, tập dữ liệu kiểm tra được sử dụng nhằm đánh giá khả năng tổng quát hóa của mô hình đã huấn luyện, trong đó kết quả dự đoán được đối chiếu với nhãn thực tế và đo lường bằng các thước đo đánh giá. Các chỉ số như accuracy (AC), precision (PR), recall (RE), F1-score (FS) được tính toán theo các công thức (3.4), (3.5), (3.6) và (3.7). Những kết quả này là cơ sở để so sánh giữa các phương pháp lựa chọn đặc trưng và lựa chọn mô hình phù hợp cho triển khai thực tế.

$$\text{Accuracy (AC)} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.4)$$

$$\text{Precision (PR)} = \frac{TP}{TP + FP} \quad (3.5)$$

$$\text{Recall (RE)} = \frac{TP}{TP + FN} \quad (3.6)$$

$$\text{F1-Score (FS)} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.7)$$

Các đại lượng TP, FP, FN, TN dùng trong các công thức trên được minh họa qua ma trận nhầm lẫn ở Bảng 3.6.

Bảng 3.6. Ma trận nhầm lẫn của mô hình phát hiện xâm nhập

	Dự đoán: Positive	Dự đoán: Negative
Thực tế: Positive	TP (True Positive)	FN (False Negative)
Thực tế: Negative	FP (False Positive)	TN (True Negative)

Trong đó, TP (True Positive) là số lượng lưu lượng mạng hoặc phiên kết nối thực sự là tấn công và được hệ thống IDS phát hiện đúng là xâm nhập. TN (True Negative) là những lưu lượng bình thường (không phải tấn công) và được mô hình phân loại chính xác là hợp lệ. FP (False Positive) là các lưu lượng bình thường nhưng bị hệ thống nhận diện nhầm là tấn công. Ngược lại, FN (False Negative) là những cuộc tấn công thực sự xảy ra nhưng không được hệ thống phát hiện và bị phân loại nhầm là lưu lượng bình thường.

3.5 Tối ưu hóa siêu tham số và huấn luyện mô hình

Trong quá trình xây dựng mô hình học máy, việc lựa chọn các siêu tham số (hyperparameters) phù hợp là một yếu tố quan trọng ảnh hưởng đến hiệu năng của mô hình. Để tối ưu hóa các siêu tham số này, phương pháp **Tìm kiếm theo lưới** (Grid Search (GS)) kết hợp với **Cross-Validation (CV)** đã được sử dụng trong môi trường phân tán của Apache Spark. Các mô hình phân loại được huấn luyện và so sánh gồm: Decision Tree, Logistic Regression, Linear SVC, Naive Bayes, Random Forest, GBT, XGBoost và MLP, sau đó xếp hạng theo F1-Score để chọn Top-3 mô hình cho các phương pháp ensemble.

- **GS**: Là phương pháp thử nghiệm tất cả các tổ hợp có thể của các siêu tham số được định nghĩa trước. Ví dụ, với một mô hình Random Forest, các tham số có thể bao gồm số lượng cây (numTrees), độ sâu tối đa (maxDepth), và chiến lược chọn tập con đặc trưng tại mỗi nút (featureSubsetStrategy). Spark MLlib hỗ trợ đối tượng `ParamGridBuilder` để xây dựng lưới các tham số.
- **CV**: Là phương pháp đánh giá mô hình bằng cách chia dữ liệu huấn luyện thành k phần, sau đó huấn luyện và đánh giá mô hình k lần, mỗi lần sử dụng một phần khác nhau làm dữ liệu kiểm tra và các phần còn lại làm dữ liệu huấn luyện. Trong Spark, đối tượng `CrossValidator` được sử dụng để thực hiện quy trình này.

Quy trình tối ưu hóa được thực hiện như sau:

1. Xây dựng pipeline gồm các bước tiền xử lý dữ liệu (ví dụ: chuẩn hóa, biến đổi đặc trưng) và mô hình học máy.
2. Sử dụng `ParamGridBuilder` để định nghĩa tập lưới các siêu tham số cần tìm kiếm.
3. Khởi tạo `CrossValidator` với pipeline, lưới các tham số, và bộ đánh giá hiệu năng (ví dụ: `BinaryClassificationEvaluator`).
4. Huấn luyện mô hình bằng cách gọi phương thức `fit()` của `CrossValidator` trên tập dữ liệu huấn luyện.
5. Chọn mô hình tốt nhất dựa trên điểm đánh giá trung bình trên các fold.

Ví dụ đoạn mã sử dụng Spark MLlib:

```
from pyspark.ml.classification import RandomForestClassifier
from pyspark.ml.evaluation import BinaryClassificationEvaluator
from pyspark.ml.tuning import CrossValidator, ParamGridBuilder
from pyspark.ml import Pipeline

rf = RandomForestClassifier(labelCol="label", featuresCol="
    features")

pipeline = Pipeline(stages=[rf])

paramGrid = ParamGridBuilder() \
    .addGrid(rf.numTrees, [10, 20, 50]) \
    .addGrid(rf.maxDepth, [5, 10, 15]) \
    .build()

evaluator = BinaryClassificationEvaluator(labelCol="label",
    metricName="areaUnderPR")

cv = CrossValidator(estimator=pipeline,
                    estimatorParamMaps=paramGrid,
                    evaluator=evaluator,
                    numFolds=5)

cvModel = cv.fit(trainingData)
```

Quy trình này bảo đảm chọn được tổ hợp siêu tham số tốt nhất trong lưới đã định nghĩa, và Spark rút ngắn thời gian tìm kiếm nhờ xử lý phân tán, song song hóa trên cụm máy.

3.6 Triển khai biên

Mô hình tốt nhất sau đánh giá được đóng gói thành `PipelineModel` và triển khai trên một cụm *hai* thiết bị biên NVIDIA Jetson Orin Nano Super (CPU ARM 64-bit + GPU NVIDIA), tách vai trò: Jetson #1 chạy cổng phát hiện bất thường (autoencoder) để lọc lưu lượng bình thường, Jetson #2 chạy bộ phân loại PySpark trên các luồng nghi vấn. Mô hình sau khi huấn luyện trên cụm được chuyển sang thiết bị biên bằng Secure Copy Protocol (SCP). Quy trình suy luận thời gian thực theo chuỗi: Kafka Consumer nhận dữ liệu mạng (topic `ids-network-flow`), cổng bất thường chuyển tiếp luồng nghi vấn sang `ids-suspicious-flow`, PySpark Streaming (micro-batch) xử lý và trích xuất đặc trưng, kết quả dự đoán ghi vào PostgreSQL phục vụ trực quan hóa trên Grafana và kích hoạt cảnh báo khi phát hiện bất thường. Hệ thống hỗ trợ ba chế độ: tách pipeline (pipeline split), mở rộng theo chiều ngang (horizontal scaling) và cụm Spark (Spark cluster). Thông số phần cứng chi tiết của thiết bị biên được trình bày trong Bảng 3.7.

Bảng 3.7. Thông số phần cứng thiết bị biên

Thuộc tính	Giá trị
Nền tảng	NVIDIA Jetson Orin Nano Super Developer Kit ($\times 2$)
CPU	6 nhân Arm Cortex-A78AE, 1,7 GHz
GPU	NVIDIA Ampere, 1024 nhân CUDA + 32 Tensor Core
RAM	8 GB LPDDR5 (102 GB/s)
Lưu trữ	SSD NVMe 256 GB
Hiệu năng AI	tới ~ 67 TOPS (khung 25 W)
Hệ điều hành	Ubuntu (NVIDIA JetPack / L4T)
Vai trò	Worker huấn luyện (Spark) & thiết bị suy luận biên

Chương 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Trong chương này, luận văn trình bày kết quả đạt được khi áp dụng kỹ thuật lựa chọn đặc trưng để huấn luyện các mô hình học máy. Bên cạnh đó, quy trình tinh chỉnh siêu tham số bằng tìm kiếm lưới kết hợp kiểm định chéo (cross-validation) cũng được trình bày, cùng với đánh giá kết quả thực nghiệm khi áp dụng các thuật toán học máy như SVM, LR, NB, RF, DT, GBT, XGB và MLP cả trong trường hợp có và không sử dụng kỹ thuật giảm chiều dữ liệu. Ngoài ra, luận văn cũng xác định và trình bày các giá trị tham số tối ưu cho từng thuật toán thông qua phương pháp tìm kiếm theo lưới kết hợp với kiểm định chéo (cross-validation). Dựa trên các kết quả thu được, luận văn sẽ làm rõ vấn đề liệu việc giảm chiều dữ liệu có thực sự cần thiết hay không. Cuối cùng, luận văn đánh giá hiệu quả của các mô hình EL, sau đó so sánh với các thuật toán học máy truyền thống, từ đó trả lời câu hỏi: *Liệu có nên sử dụng EL so với các mô hình học máy truyền thống khi làm việc với dữ liệu IoT hay không?*

4.1 Môi trường thực nghiệm

Việc huấn luyện mô hình được thực hiện trên một **cụm Apache Spark Standalone phân tán** gồm một máy chủ và **hai thiết bị biên NVIDIA Jetson Orin Nano Super Developer Kit**. Cùng một cặp Jetson vừa đóng vai trò worker của cụm Spark trong pha huấn luyện, vừa là thiết bị triển khai trong pha suy luận thời gian thực (Hình 4.6), nhờ đó toàn bộ pipeline được kiểm chứng trên đúng phần cứng mục tiêu.

- **Máy chủ (Spark master):** máy tính xách tay MacBook Air, vi xử lý Apple M3, RAM 16 GB, macOS Sonoma 14.3. Máy này đảm nhận điều phối cụm (master), tiền xử lý dữ liệu thô (từ CSV sang Parquet) và chạy hạ tầng Docker (Kafka, PostgreSQL, InfluxDB, Grafana).
- **Hai nút worker: NVIDIA Jetson Orin Nano Super Developer Kit**, hệ điều hành Ubuntu (NVIDIA JetPack/L4T). Cấu hình chi tiết (CPU/GPU/RAM/lưu trữ) được nêu tại Bảng 3.7, Chương 3. Jetson #1 đồng thời chạy tiến trình *driver* của Spark (driver là tiến trình điều khiển ứng dụng, khác với vai trò *master* điều phối cụm của MacBook).
- **Phần mềm:** Python 3, Apache Spark / PySpark 3.4.1, MLlib. Cấu hình cụm tiêu biểu: `executor.memory=3 GB`, `executor.cores=4`,

`driver.memory=3 GB, shuffle.partitions=32`. Mỗi Jetson được cấp 8 GB swap trên ổ NVMe để tránh tràn bộ nhớ khi cao điểm (xem `cluster/spark_cluster.env, cluster/setup_swap_jetson.sh`).

Các thuật toán học máy, phương pháp giảm chiều và các bước đánh giá đều được triển khai bằng PySpark và thực thi phân tán trên hai nút Jetson. Tập dữ liệu Parquet được đồng bộ sang cả hai worker trước khi huấn luyện. Kiến trúc cụm huấn luyện phân tán (gồm vai trò *master* điều phối trên MacBook và hai *worker/executor* trên Jetson) được minh họa ở Hình 4.1. Cần phân biệt rõ với Hình 4.6 (pha suy luận): cùng một cặp Jetson nhưng ở pha huấn luyện đóng vai trò worker của cụm Spark, còn ở pha suy luận đóng vai trò cổng lọc (gate) và bộ phân loại.

Máy chủ MacBook chỉ đảm nhận vai trò *master* điều phối cụm cùng tiền xử lý và hạ tầng dịch vụ, không tham gia tính toán huấn luyện (không chạy *executor*). Đây là một lựa chọn có chủ đích: số liệu hiệu năng báo cáo trong luận văn phải phản ánh đúng khả năng huấn luyện phân tán ngay trên phần cứng biên Jetson. Nếu đưa MacBook (vi xử lý Apple M3, mạnh hơn đáng kể) vào làm nút tính toán, phần lớn khối lượng công việc sẽ dồn về máy chủ, gây mất cân bằng tải (hiện tượng *straggler*) và làm sai lệch các phép đo thời gian/thông lượng, khiến kết quả không còn phản ánh đúng hiệu năng của cụm biên. Vì vậy, cụm đo đạc được giữ đồng nhất gồm hai nút Jetson, còn máy chủ chỉ được dùng để phát triển và kiểm thử nhanh trong giai đoạn xây dựng pipeline.

4.2 Kết quả thực nghiệm

Bảng 4.1 tóm tắt thiết lập tham số của các mô hình học máy được sử dụng trong nghiên cứu này. Trong đó, XGB và MLP được tinh chỉnh bằng Grid Search kết hợp kiểm định chéo (Kịch bản 3). Các mô hình còn lại dùng bộ tham số cố định từ trước, lựa chọn dựa trên các nghiên cứu gần đây và thực nghiệm sơ bộ, nhằm bảo đảm rằng khác biệt quan sát được giữa các phương pháp giảm chiều phản ánh đúng bản thân phương pháp, thay vì mức độ tinh chỉnh riêng từng mô hình.

Bảng 4.1. Tham số tối ưu của các mô hình học máy

Mô hình	Tham số	Giá trị	Ý nghĩa/Mô tả
Decision Tree	maxDepth	15	Bắt các mẫu tần công phức tạp.
	impurity	entropy	Tiêu chí chia nhánh tối ưu.
	minInstancesPerNode	5	Số mẫu tối thiểu tại mỗi nút lá.
Logistic Reg.	maxIter	200	Bảo đảm hội tụ trên tập dữ liệu lớn.
	regParam	0,001	Kiểm soát mức điều chuẩn (regularization).
	elasticNetParam threshold	0,0 0,5	Sử dụng Ridge (L2) ổn định hơn. Ngưỡng quyết định nhị phân.
SVM (LinearSVC)	maxIter	200	Số lần lặp tối ưu hóa biên.
	regParam	0,001	Tham số điều chuẩn biên quyết định.
NB	modelType	gaussian	Phù hợp cho đặc trưng liên tục.
	smoothing	1,0	Làm mượt Laplace.
Random Forest	numTrees	200	Bảo đảm độ ổn định kết quả.
	maxDepth	15	Chiều sâu tối đa của cây trong rừng.
	featureSubsetStrategy	sqrt	Chọn đặc trưng ngẫu nhiên mỗi nút.
GBT	maxIter	150	Số vòng boosting tối đa.
	maxDepth	6	Chiều sâu của các cây yếu.
	stepSize	0,05	Tốc độ học (learning rate) của boosting.
	subsamplingRate	0,8	Tỷ lệ lấy mẫu dữ liệu mỗi vòng boosting.
XGB	n_estimators	300	Số lượng cây boost trong mô hình.
	max_depth	8	Chiều sâu tối đa mỗi cây.
	learning_rate	0,05	Kiểm soát mức độ học của cây mới.
	subsample	0,8	Tỷ lệ lấy mẫu dữ liệu mỗi cây.
	colsample_bytree	0,8	Tỷ lệ lấy mẫu đặc trưng mỗi cây.
MLP	layers	[d , 64, 32, 2]	Mạng nơ-ron 2 lớp ẩn (d = số đặc trưng đầu vào).
	maxIter	150	Số vòng lặp huấn luyện tối đa.
	stepSize	0,01	Tốc độ học của mạng nơ-ron.



Hình 4.1. Cụm huấn luyện phân tán Apache Spark Standalone: máy chủ điều phối (master) và hai Jetson worker/executor

4.2.1 Kịch bản 1: Đánh giá hiệu năng cơ sở (Baseline)

Trong kịch bản này, toàn bộ tập đặc trưng số (khoảng 78 đặc trưng trước khi loại cổng, chính xác là 77 đặc trưng sau khi loại `destination_port/source_port`) được đưa vào mô hình mà chưa qua bất kỳ bước lựa chọn đặc trưng hay giảm chiều nào. Mục tiêu là thiết lập một mức hiệu năng tham chiếu cho các thử nghiệm tiếp theo.

Kết quả hiệu năng của các thuật toán ML đơn lẻ và phương pháp Ensemble được trình bày trong Bảng 4.2.

Bảng 4.2. Kết quả hiệu năng phân loại kịch bản Baseline (toàn bộ đặc trưng số, ≈ 78 trước khi loại cổng)

Thuật toán	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9986	0,9925	0,9983	0,9954	0,9994	0,9988
Logistic Regression	0,9288	0,6937	0,9422	0,7991	0,9859	0,9509
SVM (LinearSVC)	0,9199	0,6650	0,9395	0,7788	0,9843	0,9485
NB	0,3163	0,1793	0,9933	0,3038	0,8829	0,6364
Random Forest	0,9985	0,9939	0,9960	0,9949	0,9999	0,9997
GBT	0,9980	0,9900	0,9965	0,9932	0,9998	0,9991
XGB	0,9991	0,9950	0,9993	0,9971	1,0000	0,9999
MLP	0,9900	0,9844	0,9487	0,9662	0,9984	0,9936
Hybrid Bagging	0,9990	0,9950	0,9984	0,9967	1,0000	0,9999
Soft Voting	0,9991	0,9952	0,9985	0,9969	1,0000	0,9999

Với cấu hình đã loại trừ rò rỉ dữ liệu, nhóm mô hình dựa trên cây (Random Forest, XGB, GBT) được kỳ vọng dẫn đầu, với F1 thấp hơn mức gần-tuyệt-đối của các cấu hình có rò rỉ và phản ánh đúng độ khó thực của bài toán. Kết luận “mô hình nào tốt nhất” chỉ được đưa ra khi chênh lệch vượt khoảng tin cậy (xem mục kiểm định thống kê). Do dữ liệu mất cân bằng mạnh, AUC-PR và recall trên lớp tấn công được ưu tiên hơn Accuracy khi diễn giải, vì Accuracy có thể gây lạc quan giả tạo (một mô hình luôn đoán lớp benign chiếm đa số vẫn đạt Accuracy cao).

4.2.2 Kịch bản 2: So sánh chiến lược giảm chiều dữ liệu

Luận văn thực hiện so sánh 3 chiến lược chính nhằm giảm số lượng đặc trưng nhưng vẫn bảo đảm hiệu năng:

1. **RF Feature Importance:** Trích xuất 30 đặc trưng có độ quan trọng cao nhất từ Random Forest.
2. **SHAP Importance:** Sử dụng giá trị Shapley từ mô hình XGB để chọn ra 30 đặc trưng có ảnh hưởng lớn nhất.

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

3. **PCA ($k=40$)**: Giảm chiều dữ liệu từ không gian đặc trưng gốc (≈ 78 chiều trước khi loại cổng) xuống 40 thành phần chính.

Lưu ý rằng PCA dùng $k = 40$, nhiều hơn 30 đặc trưng của RF/SHAP, vì đây là phép trích xuất chứ không phải chọn lọc: mỗi thành phần chính chỉ là một tổ hợp tuyến tính mang một phần phương sai, nên cần nhiều thành phần hơn để giữ lượng thông tin (phương sai tích lũy) tương đương với tập 30 đặc trưng gốc. Trong dải quét chung $\{20, 30, 40\}$, $k = 40$ là mức giữ phương sai cao nhất, nên là điểm vận hành đại diện công bằng nhất cho PCA. Ép $k = 30$ sẽ làm PCA mất thêm phương sai và bất lợi khi so sánh.

Bảng 4.3 tóm tắt sự khác biệt giữa các phương pháp. Mô hình đại diện (cột *Mô hình tốt nhất*) của mỗi phương pháp được chọn theo F1 trên tập kiểm định (validation) tách từ tập huấn luyện. Tập kiểm tra không tham gia khâu chọn lọc này. Mục tiêu là kiểm chứng giả thuyết: lựa chọn đặc trưng (RF/SHAP Top-30) giữ được hiệu năng gần với baseline trong khi giảm hơn 60% số đặc trưng, qua đó phù hợp cho triển khai biên.

Bảng 4.3. So sánh hiệu năng tốt nhất của các phương pháp lựa chọn đặc trưng và giảm chiều

Phương pháp	Số đặc trưng	Mô hình tốt nhất	F1-Score	Huấn luyện (s)	Dung lượng (MB)
Baseline (Toàn bộ)	77	XGB	0,9971	4615,5	2,32
RF Importance	30	XGB	0,9922	1295,1	2,52
SHAP Importance	30	XGB	0,9970	1226,1	0,003 [†]
PCA ($k=40$)	40	XGB	0,9939	1444,8	3,82

Baseline dùng toàn bộ 77 đặc trưng số (≈ 78 trước khi loại cổng). [†]Kích thước đo bằng cách tuần tự hóa mô hình *trên cụm huấn luyện phân tán*: bước lưu mô hình phân tán ghi các phân vùng dữ liệu rừng cây trên executor đang giữ chúng, nên giá trị cỡ KB chỉ bắt được metadata cục bộ trên driver và *thấp hơn thực tế*. Vì dung lượng ensemble cây phụ thuộc số cây và số nút (không phụ thuộc số đặc trưng đầu vào), mô hình XGB SHAP Top-30 thực tế tương đương bản RF Top-30 ($\approx 2,5$ MB). Cũng vì vậy, tập đặc trưng rút gọn có thể cho mô hình *lớn hơn* baseline một chút (2,52 so với 2,32 MB): ít ứng viên tách hơn khiến cây cần nhiều nút hơn để đạt cùng độ tinh khiết. Phép đo tin cậy là bản mô hình xuất ra ở chế độ đơn nút của pipeline triển khai (Mục kết quả biên).

Ngoài ra, việc so sánh trực tiếp giữa hai phương pháp lựa chọn đặc trưng dựa trên độ quan trọng của RF và SHAP được trình bày chi tiết trong Bảng 4.4.

4.2.3 Kịch bản 3: Tối ưu hóa siêu tham số

Sau khi chọn được bộ đặc trưng tối ưu từ SHAP, bốn mô hình Spark ML gốc (Random Forest, Decision Tree, GBT, Logistic Regression) được tinh chỉnh tham số thông qua Grid Search kết hợp Cross-validation trên tập đặc trưng SHAP Top-30. Các mô hình còn lại (XGB, MLP, SVM, NB) giữ nguyên bộ tham số cố định ở Bảng 4.1 (xem lý do ở đầu mục).

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Bảng 4.4. So sánh hiệu năng lựa chọn đặc trưng: RF Importance vs SHAP Importance (Top-30)

Thuật toán	F1 (RF Top-30)	F1 (SHAP Top-30)	Chênh lệch tương đối (%)
Random Forest	0,9879	0,9955	+0,77
XGB	0,9922	0,9970	+0,48
GBT	0,9844	0,9918	+0,75
Decision Tree	0,9835	0,9948	+1,15

Việc tinh chỉnh giúp các mô hình cây đạt F1 quanh mức 0,995 (Bảng 4.5). Mức cải thiện so với cấu hình cố định là nhỏ do bài toán nhị phân trong-miền đã gần bão hòa, phù hợp với nhận định ở mục kiểm định thống kê.

Kết quả hiệu năng của phương pháp Tối ưu hóa siêu tham số được trình bày trong Bảng 4.5.

Bảng 4.5. Kết quả hiệu năng phân loại kịch bản Tối ưu hóa siêu tham số

Thuật toán	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9987	0,9977	0,9936	0,9957	0,9994	0,9980
Logistic Regression	0,9541	0,9787	0,7094	0,8226	0,9749	0,9371
SVM (LinearSVC)	giữ cấu hình cố định (xem Bảng 4.2)					
NB	giữ cấu hình cố định (xem Bảng 4.2)					
Random Forest	0,9986	0,9985	0,9922	0,9953	0,9999	0,9997
GBT	0,9985	0,9979	0,9924	0,9951	0,9999	0,9993
XGB	giữ cấu hình cố định (xem Bảng 4.2)					
MLP	giữ cấu hình cố định (xem Bảng 4.2)					
Hybrid Bagging	0,9986	0,9956	0,9949	0,9953	0,9999	0,9998
Soft Voting	0,9988	0,9985	0,9932	0,9958	1,0000	0,9998

4.2.4 Phân tích khả năng giải thích với SHAP

Tính giải thích (explainability) là một yêu cầu của hệ thống IDS, làm cơ sở để tin tưởng và vận hành mô hình trong thực tế. Trong nghiên cứu này, phương pháp SHAP (SHapley Additive exPlanations) được sử dụng để phân tích mức độ quan trọng của từng đặc trưng đối với quyết định phân loại của mô hình XGB.

Hình 4.2 xếp hạng 30 đặc trưng quan trọng nhất theo giá trị trung bình tuyệt đối của SHAP (mean $|\text{SHAP}|$): thanh càng dài, đặc trưng càng ảnh hưởng lớn đến quyết định phân loại xét trên toàn bộ mẫu. Để tránh rò rỉ, giá trị SHAP được tính trên một mẫu phân tầng theo lớp lấy từ tập huấn luyện (không phải tập kiểm tra). Mẫu này được biến đổi qua đúng bộ chuẩn hóa (StandardScaler) đã fit trên tập huấn luyện trước khi tính SHAP, bảo đảm

không gian đầu vào của phép giải thích trùng khớp với không gian đầu vào mà mô hình đã học.

Bổ sung cho xếp hạng tổng thể, Hình 4.3 trình bày biểu đồ SHAP Summary dạng beeswarm: mỗi điểm đại diện cho một quan sát; trục hoành thể hiện giá trị SHAP (dương đẩy dự đoán về lớp tấn công, âm đẩy về lớp bình thường); màu sắc biểu diễn giá trị đặc trưng từ thấp đến cao. Độ phân tán theo trục hoành phản ánh mức độ ảnh hưởng của đặc trưng, độ tập trung thể hiện tính ổn định của tác động.

Bên cạnh đó, giá trị trung bình tuyệt đối của SHAP ($\text{mean } |\text{SHAP}|$) được dùng để xếp hạng mức quan trọng tổng thể. Trên tập đặc trưng đã loại trừ rò rỉ, các đặc trưng có $\text{mean } |\text{SHAP}|$ lớn nhất là: `bwd_packet_length_std`, `init_win_bytes_backward`, `init_win_bytes_forward` và `bwd_packet_length_mean`.

Các đặc trưng như `init_win_bytes_forward`, `init_win_bytes_backward` (kích thước cửa sổ TCP giai đoạn khởi tạo) và `bwd_packet_length_std`, `packet_length_std` (sự biến thiên độ dài gói tin) phản ánh đặc tính phân phối lưu lượng, tức các tín hiệu mạng có ý nghĩa và không phụ thuộc vào định danh dịch vụ. Việc loại `destination_port` buộc mô hình dựa vào các đặc trưng hành vi này thay vì ghi nhớ ánh xạ cổng $\rightarrow$ nhãn.

4.2.5 Phân tích rò rỉ dữ liệu (data leakage)

Đặc trưng `destination_port` là một nguồn rò rỉ nhãn tiềm tàng trên CICIDS2017: mỗi loại tấn công được sinh nhằm vào những cổng dịch vụ cố định nên cổng đích tương quan mạnh với nhãn, khiến mô hình dễ “ghi nhớ” ánh xạ cổng–nhãn thay vì học hành vi luồng. Engelen và cộng sự [60] xếp hiện tượng này vào nhóm *shortcut learning* của CICIDS2017: các thuộc tính định danh (Flow ID, địa chỉ IP, cổng nguồn, nhãn thời gian) phải bị loại khỏi biểu diễn đặc trưng, còn riêng việc dùng cổng đích làm đặc trưng cho IDS thì các tác giả xem là *còn gây tranh cãi*. Để định lượng ảnh hưởng, luận văn thực hiện phân tích loại bỏ (ablation) giữ/loại cổng với cùng một cấu hình Random Forest cố định a priori (`numTrees=200`, `maxDepth=15`, có trọng số lớp, bài toán nhị phân), kết quả ở Bảng 4.6. Với bài toán nhị phân trong-miền, sau khi đã loại trùng lặp luồng ở mức đặc trưng, ảnh hưởng riêng của `destination_port` lên F1 chỉ còn nhỏ (chênh khoảng 0,001 điểm F1), bởi tác vụ nhị phân trên CICIDS2017 vốn gần mức bão hòa và nguồn rò rỉ chi phối (các luồng trùng lặp) đã được xử lý trước bằng bước loại bỏ trùng lặp. Điều này không có nghĩa rò rỉ vô hại: giá trị của quy trình loại-trừ-rò-rỉ thể hiện rõ hơn ở đánh giá đa

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

lớp với các lớp tấn công hiểm (Mục 4.2.10) và ở tổng quát hóa liên bộ dữ liệu (Mục 4.2.9), nơi các “lỗi tắt” rò rỉ không còn giúp mô hình. Pipeline loại bỏ cả `destination_port` lẫn `source_port`, còn phân tích ablation tập trung vào `destination_port` vì đây là cổng chi phối.

Bảng 4.6. Phân tích loại bỏ (ablation) rò rỉ đặc trưng `destination_port` với cấu hình Random Forest cố định

Cấu hình	F1	Recall (Attack)	AUC-PR
Giữ <code>destination_port</code> (rò rỉ)	0,9965	0,9988	0,9999
Loại <code>destination_port</code> (đề xuất)	0,9955	0,9961	0,9997

Cả hai lượt dùng cùng một cấu hình Random Forest cố định từ trước (200 cây, độ sâu 15, trọng số lớp, khớp Bảng 4.1) để cô lập đúng ảnh hưởng của đặc trưng rò rỉ. Mức chênh lệch F1 giữa hai hàng phản ánh phần hiệu năng bị thổi phồng do đặc trưng rò rỉ. Ở đây mức chênh nhỏ vì đã loại trùng lặp trước và tác vụ nhị phân gần bão hòa, nhưng chiều hướng (giữ cổng cho F1/recall cao hơn) vẫn nhất quán với hiện tượng rò rỉ. Mọi kết quả khác trong luận văn dùng cấu hình đã loại cổng.

Ảnh hưởng của cổng đích thay đổi theo họ mô hình. Con số $\approx 0,001$ ở trên là đặc tính của họ cây chứ không phải của bộ dữ liệu. Khi lặp lại đúng hai lượt đó trên cùng một phép chia cho cả tám thuật toán (Bảng 4.7, Hình 4.4), mức thổi phồng trải trên gần hai bậc độ lớn: các mô hình cây chỉ được lợi +0,0007 đến +0,0017 điểm F1, trong khi SVM và Logistic Regression được lợi tới +0,0415 và +0,0395, tức gấp khoảng 40 lần. Thứ tự này bám theo năng lực biểu diễn của mô hình: các ensemble cây dựng lại được cùng một biên quyết định từ các thống kê hành vi của luồng nên gần như không cần đến cổng, còn mô hình tuyến tính không đủ năng lực làm vậy nên bám vào cổng như một chỉ báo định danh dịch vụ. Hệ quả về phương pháp luận: *không thể suy ra mức rò rỉ của một lớp mô hình từ phép đo trên một mô hình đại diện khác*, và con số nhỏ báo cáo ở Bảng 4.6 là con số trung thực cho cấu hình được triển khai, không phải bằng chứng rằng đặc trưng này vô hại nói chung.

4.2.6 Phân tích hiệu năng hệ thống

Bên cạnh độ chính xác, hiệu năng hệ thống về thời gian và tài nguyên là yếu tố quyết định khả năng triển khai thực tế. Kết quả trong Bảng 4.8 cho thấy:

- **Thời gian huấn luyện:** Các mô hình Gradient Boosting (GBT, XGB) có thời gian

Bảng 4.7. Mức thời phòng F1 do `destination_port` theo từng thuật toán; hai lượt huấn luyện trên cùng một phép chia

Thuật toán	F1 (loại cổng)	F1 (giữ cổng)	$\Delta F1$
SVM (LinearSVC)	0,7859	0,8274	+0,0415
Logistic Regression	0,7986	0,8381	+0,0395
NB	0,2985	0,3093	+0,0108
MLP	0,9660	0,9711	+0,0052
GBT	0,9924	0,9941	+0,0017
Decision Tree	0,9953	0,9966	+0,0014
Random Forest	0,9954	0,9964	+0,0010
XGB	0,9972	0,9979	+0,0007

Đây là một lượt chạy độc lập với Bảng 4.6: hàng Random Forest lệch khoảng 1×10^{-4} so với bảng đó do dao động giữa các lần chạy Spark (phân vùng dữ liệu và thứ tự cộng dồn số thực), không phải do khác phương pháp; kết luận về mức chênh $\approx 0,001$ không đổi.

Bảng 4.8. So sánh thời gian xử lý và kích thước mô hình kịch bản Baseline

Thuật toán	Huấn luyện (s)	Dự đoán (s)	Kích thước (MB)
Decision Tree	33,4	6,1	0,0004
Logistic Regression	49,2	5,4	0,009
SVM (LinearSVC)	224,3	5,4	0,002
NB	8,2	5,2	0,012
Random Forest	610,3	18,6	3,69
GBT	1346,8	8,9	0,92
XGB	4615,5	9,0	2,32
MLP	314,7	8,0	0,0004
Hybrid Bagging	11934,5	36,4	7,24
Soft Voting	–	25,6	–

huấn luyện dài nhất nhưng đạt kết quả phân loại cao.

- **Thời gian dự báo:** XGB có thời gian dự báo nhanh (khoảng 9 giây cho toàn tập kiểm tra), Random Forest chậm hơn (khoảng 19 giây). Cả hai đều phù hợp cho giám sát theo lô gần thời gian thực.
- **Kích thước mô hình:** các mô hình cây chiếm dung lượng lớn hơn hẳn mô hình tuyến tính (LR, SVM, NB chỉ vài KB). RF khoảng 3,7 MB và ensemble Hybrid Bagging lớn nhất ($\sim 7,2$ MB) do gộp nhiều bộ học cơ sở. *Lưu ý: kích thước được đo bằng cách tuần tự hóa (serialize) PipelineModel của Spark ra đĩa. Giá trị này có thể biến thiên theo cách phân mảnh/partition khi lưu nên chỉ mang tính tham khảo tương đối, không dùng làm tiêu chí quyết định lựa chọn mô hình.*

4.2.7 Kiểm định ý nghĩa thống kê

Do các con số F1 giữa những phương pháp/thuật toán hàng đầu rất sát nhau, luận văn không kết luận “mô hình tốt nhất” chỉ dựa trên một lần đo. Mô hình đại diện của mỗi phương pháp, cũng như cặp phương pháp dẫn đầu được đưa vào kiểm định, đều được chọn theo F1 trên tập kiểm định (validation, 20% tách từ tập huấn luyện, $\text{seed}=42$). Tập kiểm tra không tham gia khâu chọn lọc. Hai phương pháp này sau đó được huấn luyện lại trên N lần lấy mẫu lại tập huấn luyện/kiểm tra (mặc định $N=6$, ghép cặp trên cùng một phép chia ở mỗi vòng), tính F1 trung bình kèm hai loại khoảng tin cậy 95%: khoảng tin cậy t thông thường và khoảng tin cậy hiệu chỉnh *Nadeau–Bengio* [61], trong đó phương sai nhân hệ số $(1/N + n_{\text{test}}/n_{\text{train}})$ để bù tương quan giữa các lần lấy mẫu lại chồng lấn. Khoảng *Nadeau–Bengio* được dùng làm căn cứ kết luận chính. Ý nghĩa thống kê được kiểm bằng permutation test ghép cặp hai phía, liệt kê đầy đủ toàn bộ $2^N = 64$ hoán vị đổi dấu (kiểm định chính xác, không xấp xỉ Monte Carlo), do đó p nhỏ nhất khả dĩ là $2/64 \approx 0,031$. Độ lớn hiệu ứng được báo cáo bằng Cohen’s d ghép cặp (Bảng 4.9). Chênh lệch F1 giữa Baseline và SHAP Top-30 có ý nghĩa thống kê ở mức sàn của độ phân giải kiểm định ($p \approx 0,031$, $d \approx 1,94$), nhưng khác biệt tuyệt đối rất nhỏ ($\approx 0,0001$ điểm F1) nên hai phương pháp tương đương về mặt thực dụng. Khi đó, tiêu chí phụ (khả năng giải thích, kích thước, chi phí biên) mới là căn cứ lựa chọn. Với $N=6$, kiểm định có lực thống kê thấp. Vì vậy, một giá trị p không có ý nghĩa thống kê tự nó chỉ là bằng chứng yếu cho “tương đương”, và kết luận được căn cứ đồng thời vào khoảng tin cậy *Nadeau–Bengio* và Cohen’s d .

Kiểm định tương đương (TOST). Kiểm định ý nghĩa thông thường chỉ có thể *bác bỏ*

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

giả thuyết “không khác biệt”, không bao giờ *chứng minh* được hai cấu hình tương đương; đó là lý do lập luận “ p sát sà nên coi như tương đương” ở trên vẫn còn yếu. Luận văn do đó bổ sung kiểm định hai phía một đuôi (two one-sided tests, TOST [62]) với biên tương đương *khai báo trước* là 0,001 điểm F1 — mức chênh lệch còn lại không có ý nghĩa vận hành cho IDS, và lớn hơn một bậc so với khoảng cách thực tế giữa hai cấu hình. Dùng chính sai số chuẩn đã hiệu chỉnh Nadeau–Bengio ($4,58 \times 10^{-5}$) để các lần lấy mẫu lại chồng lấn không làm kết luận đẹp lên giả tạo, kết quả là $p_{\text{TOST}} = 3,9 \times 10^{-6}$: hai cấu hình *tương đương* theo nghĩa khẳng định, chứ không chỉ là “chưa phân biệt được”. Chặt hơn nữa, biên nhỏ nhất mà dữ liệu sáu lần lấy mẫu lại này chứng minh được ở mức $\alpha = 0,05$ là $\pm 2,30 \times 10^{-4}$ điểm F1 — tức chênh lệch thật giữa Baseline và SHAP Top-30 chắc chắn nhỏ hơn ngưỡng đó. Tăng N (kèm kiểm định chéo lồng) vẫn là hướng củng cố tiếp theo, nhưng kết luận tương đương không còn phụ thuộc vào một giá trị p nằm sát sà phân giải.

Bảng 4.9. Độ ổn định qua nhiều lần lấy mẫu và kiểm định ghép cặp (từ `statistical_validity_multiseed.csv`)

Phương pháp	Mô hình	F1 (mean $\pm$ CI95 t)	CI95 Nadeau–Bengio	p (ghép cặp)	Cohen’s d
Baseline (toàn bộ)	XGB	0,99734 $\pm$ 0,00007	[0,99722; 0,99746]	0,031	1,94
SHAP Top-30	XGB	0,99720 $\pm$ 0,00009	[0,99705; 0,99735]		

4.2.8 Kiểm tra độ ổn định trong-phân-phối

Mô hình đại diện của mỗi phương pháp được đánh giá lại trên một mẫu con của tập kiểm tra (không giao với tập huấn luyện, xem Bảng 4.10). Đây chỉ là phép kiểm tra độ ổn định cùng phân phối (in-distribution), không phải kiểm thử dịch chuyển phân phối. Đánh giá tổng quát hóa thực sự nằm ở thí nghiệm liên bộ dữ liệu (Mục 4.2.9).

Bảng 4.10. Kiểm tra độ ổn định trong-phân-phối trên mẫu con tập kiểm tra (từ `robustness_holdout_summary.csv`)

Phương pháp	Mô hình	F1 (holdout)	AUC-PR
Baseline	XGB	0,9971	0,9999
RF Top-30	XGB	0,9921	0,9998
SHAP Top-30	XGB	0,9969	0,9999
PCA	XGB	0,9939	0,9998

4.2.9 Tổng quát hóa liên bộ dữ liệu

Đánh giá trên tập giữ lại ở trên là phép thử cùng bộ (in-domain, cùng phân phối). Để kiểm chứng khả năng tổng quát hóa thực sự, mô hình được huấn luyện trên một bộ dữ liệu và kiểm tra trên bộ còn lại, chạy theo cả hai chiều (đánh giá khác bộ, cross-dataset), trên tập đặc trưng đã loại trừ rò rỉ dùng chung cho hai bộ. Do hai bộ dữ liệu đặt tên cột khác nhau (CSE-CIC-IDS2018 dùng tên viết tắt kiểu CICFlowMeter v3), tên cột của CSE-CIC-IDS2018 được ánh xạ về tên chuẩn của CICIDS2017 qua một bảng bí danh (alias) tường minh trong mã nguồn. Danh sách đặc trưng chung sau ánh xạ được lưu tại `common_features.txt` để bảo đảm tái lập. Mô hình dùng cho thí nghiệm là Random Forest có trọng số lớp (`weightCol`), nhất quán với cơ chế xử lý mất cân bằng ở Chương 3. Khoảng cách giữa F1 cùng bộ và F1 khác bộ (Bảng 4.11) định lượng mức suy giảm khi gặp dịch chuyển phân phối, một thước đo độ ổn định chặt chẽ hơn holdout cùng phân phối.

Do CSE-CIC-IDS2018 [54] có quy mô rất lớn (~ 16 triệu luồng, ~ 6 GB), vượt quá khả năng xử lý thoải mái của thiết bị biên Jetson (8 GB), thí nghiệm này dùng mẫu phân tầng theo nhãn của CSE-CIC-IDS2018 (tỷ lệ 0,2, $\sim 3,14$ triệu luồng lấy mẫu, còn $\sim 2,39$ triệu sau khử trùng lặp mức đặc trưng, `seed=42`, công tắc `IDS_SAMPLE_FRAC`) nhằm bảo toàn tỷ lệ các lớp trong khi vừa với phần cứng, còn CICIDS2017 dùng $\sim 2,23$ triệu luồng. Toàn bộ quy trình tiền xử lý và căn chỉnh CSE-CIC-IDS2018 cho thí nghiệm liên bộ dữ liệu được trình bày ở Thuật toán 4.1. Các bước loại trừ rò rỉ (giao đặc trưng chung không chứa cổng/IP, khử trùng lặp mức đặc trưng) hoàn toàn nhất quán với quy trình cho CICIDS2017 (Thuật toán 3.1). Các con số mẫu được báo cáo tường minh để bảo đảm tính tái lập. Việc mở rộng lên toàn bộ CSE-CIC-IDS2018 là hướng phát triển tiếp theo.

Bảng 4.11. Tổng quát hóa liên bộ dữ liệu giữa CICIDS2017 và CSE-CIC-IDS2018 (trung bình qua 12 lượt chạy độc lập)

Huấn luyện	Kiểm tra	Loại	F1	AUC-PR
CICIDS2017	CICIDS2017	cùng bộ	0,9952	0,9997
CICIDS2017	CSE-CIC-IDS2018	khác bộ	$0,1321 \pm 0,0715$	0,4862
CSE-CIC-IDS2018	CSE-CIC-IDS2018	cùng bộ	0,9246	0,9676
CSE-CIC-IDS2018	CICIDS2017	khác bộ	$0,0539 \pm 0,0022$	0,2072

Mười hai lượt chạy trên cùng mã nguồn và cùng dữ liệu, dùng bảy hạt giống rừng ngẫu nhiên, trong đó năm hạt giống được lặp lại hai lượt. F1 khác bộ ghi kèm khoảng tin cậy 95% (Student- t , $n = 12$) vì đại lượng này *không* tái lập được giữa các lượt chạy. Riêng ở chiều 2017 $\rightarrow$ 2018, mười hai giá trị tách thành hai chế độ rời nhau (bảy lượt trong khoảng 0,029–0,084 và năm lượt trong khoảng 0,185–0,301, không có giá trị nào ở giữa), nên trung bình 0,1321 nằm đúng vào khoảng trống và không lượt nào thực sự cho giá trị đó — xem thảo luận dưới đây. Các đại lượng cùng bộ (hệ số biến thiên $\leq 0,1\%$) và AUC-PR chiều 2017 $\rightarrow$ 2018 (0,453–0,536, hệ số biến thiên 4,9%) thì ổn định.

Thuật toán 4.1. Tiền xử lý và căn chỉnh CSE-CIC-IDS2018 cho đánh giá liên bộ dữ liệu

Đầu vào: Tập tệp CSV của CSE-CIC-IDS2018; lược đồ tên cột chuẩn của CICIDS2017 $\mathcal{S}_{2017}$;

bảng bí danh tên cột $\mathcal{A}$ ($2018 \rightarrow 2017$); tỷ lệ lấy mẫu $r = 0.2$; $seed = 42$

Đầu ra: Bộ dữ liệu D_{2018} trên tập đặc trưng chung đã loại rò rỉ $\mathcal{F}_{\text{chung}}$, sẵn sàng cho thí nghiệm khác bộ

- 1: **Bước 1: Nạp và làm sạch** (giống Thuật toán 3.1)
 - 2: Đọc các tệp CSV; CLEANCOLUMNAMES; HANDLEINFINITYVALUES; loại null và bản ghi trùng lặp hoàn toàn
 - 3: **Bước 2: Căn chỉnh tên cột**
 - 4: $\forall c \in \text{columns}(D) : c \leftarrow \mathcal{A}(c)$ $\triangleright$ ánh xạ tên cột CICFlowMeter v3 về tên chuẩn của CICIDS2017
 - 5: **Bước 3: Tạo nhãn nhị phân (không phân biệt hoa/thường)**
 - 6: $y_i \leftarrow 0$ nếu LOWER(label_{*i*}) = “benign”, ngược lại $y_i \leftarrow 1$ $\triangleright$ 2018 ghi “Benign”; so khớp không phân biệt hoa/thường
 $\rightarrow$ **Loại trừ rò rỉ dữ liệu: Bước 4 và Bước 6**
 - 7: **Bước 4 [loại rò rỉ – I]: Giao đặc trưng chung, đã loại trừ rò rỉ**
 - 8: $\mathcal{F}_{\text{chung}} \leftarrow (\mathcal{F}_{2017} \cap \mathcal{F}_{2018}) \setminus \mathcal{C}_{\text{exclude}}$ $\triangleright \mathcal{C}_{\text{exclude}}$: destination_port, source_port, protocol, IP, timestamp, flow_id
 - 9: Lưu $\mathcal{F}_{\text{chung}}$ vào common_features.txt $\triangleright$ cố định cho cả hai chiều huấn luyện/kiểm tra
 - 10: **Bước 5: Lấy mẫu phân tầng theo nhãn**
 - 11: $D \leftarrow \text{STRATIFIEDSAMPLE}(D, r, seed = 42)$ $\triangleright$ bảo toàn tỷ lệ lớp; còn $\sim 3,14$ triệu luồng
 - 12: **Bước 6 [loại rò rỉ – II]: Loại trùng lặp ở mức đặc trưng** (tắt định, như Bước 4b của Thuật toán 3.1)
 - 13: Gom nhóm theo $\mathcal{F}_{\text{chung}}$; loại toàn bộ nhóm mâu thuẫn nhãn; giữ đúng một đại diện của mỗi nhóm nhất quán $\triangleright$ còn $\sim 2,39$ triệu luồng
 - 14: **return** D_{2018} trên tập đặc trưng $\mathcal{F}_{\text{chung}}$
-

Diễn giải. Kết quả cho thấy một tương phản rõ rệt: hiệu năng cùng bộ cao và ổn định ở cả hai chiều (F1 0,9952 và 0,9246, hệ số biến thiên dưới 0,1% qua 12 lượt chạy), còn hiệu năng khác bộ rơi xuống mức không dùng được. AUC-PR cho thấy mức rơi này rõ nhất, vì nó không phụ thuộc ngưỡng quyết định và ổn định giữa các lượt chạy: từ 0,9997 xuống 0,4862 ở chiều 2017→2018 và từ 0,9676 xuống 0,2072 ở chiều ngược lại, tức mất một nửa đến bốn phần năm khả năng xếp hạng luồng độc hại. F1 khác bộ trung bình 0,1321 (khoảng 0,0291–0,3009) và 0,0539 (khoảng 0,0484–0,0587); mức thấp này đến từ recall rất nhỏ (trung bình 0,075 và 0,030) trong khi precision vẫn còn khá (0,764 và 0,270), tức mô hình gần như không nhận ra tấn công của bộ dữ liệu kia, chứ không tạo ra cảnh báo sai tràn lan. Nguyên nhân là dịch chuyển phân phối đặc trưng giữa hai testbed: khác phiên bản CICFlowMeter (thang đo và cách tính một số đặc trưng thay đổi), khác hạ tầng mạng và cấu hình dịch vụ, khác tổ hợp loại tấn công (HOIC/LOIC-HTTP của 2018 không có trong 2017). Sự sụt giảm này nhất quán với các nghiên cứu cross-dataset trên IDS dựa trên đặc trưng luồng [63, 64, 65], và củng cố luận điểm trung tâm của luận văn: con số trong-miền gần hoàn hảo, kể cả khi đã loại rò rỉ, không bảo đảm khả năng triển khai sang môi trường khác. Đánh giá liên bộ dữ liệu phải là một phần bắt buộc của quy trình kiểm định IDS [52], và các hướng thích ứng miền (chuẩn hóa theo miền, huấn luyện liên bộ, cập nhật theo drift) là điều kiện tiên quyết cho triển khai thực tế.

F1 khác bộ không phải một con số tái lập được. Mười hai lượt chạy ở Bảng 4.11 dùng cùng mã nguồn, cùng tệp parquet và cùng danh sách đặc trưng; chỉ hạt giống của rừng ngẫu nhiên thay đổi, và năm hạt giống được chạy hai lượt để đo riêng phần dao động *trong cùng một cấu hình*. Kết quả ở chiều 2017→2018 không phải nhiễu quanh một giá trị trung tâm mà là *hai chế độ rời nhau*: bảy lượt cho F1 0,029–0,084 với recall 0,015–0,045, năm lượt cho F1 0,185–0,301 với recall 0,104–0,178, và không một lượt nào rơi vào khoảng giữa 0,084 và 0,185.

Điều quyết định một lượt thuộc chế độ nào *không phải* hạt giống. Trong năm hạt giống được lặp, ba hạt giống cho hai lượt cùng chế độ và lệch nhau rất ít (seed 42: 0,3009 và 0,2936; seed 23: 0,0411 và 0,0434; seed 31: 0,0291 và 0,0303), nhưng *hai hạt giống đổi hẳn chế độ giữa hai lượt*: seed 5 cho 0,0495 rồi 0,1854, seed 11 cho 0,0843 rồi 0,2606. Nghĩa là cùng một hạt giống, cùng một tệp dữ liệu vẫn có thể cho hai kết quả cách nhau gấp bốn lần; nguồn dao động nằm ở chính quá trình huấn luyện phân tán, nơi thứ tự gộp các phân vùng khi Spark tính biểu đồ tần suất chia nút không cố định giữa các lượt, nên một vài ngưỡng chia nút được chọn khác đi.

Cơ chế khuếch đại sai lệch nhỏ đó thành hai chế độ là vị trí của ngưỡng quyết định 0,5. Xác suất dự đoán của gần như toàn bộ luồng tấn công miền đích nằm *sát ngay* ngưỡng này, mà các luồng đó lại rất giống nhau (cùng vài họ tấn công, cùng bộ công cụ sinh ra), nên chúng không vượt ngưỡng một cách rời rạc: cả một cụm lớn cùng lật qua hoặc cùng tụt xuống dưới ngưỡng, đưa recall nhảy thẳng từ $\approx 0,03$ lên $\approx 0,15$ mà không đi qua các giá trị trung gian. Bằng chứng quyết định cho lời giải thích này là AUC-PR: đại lượng không dùng ngưỡng *ấy như nhau ở cả hai chế độ* (0,459–0,516 ở chế độ thấp so với 0,453–0,536 ở chế độ cao, hai khoảng trùm lên nhau hoàn toàn). Khả năng xếp hạng của mô hình không hề đổi giữa các lượt; chỉ vị trí của ngưỡng 0,5 so với cụm luồng đó là đổi.

Hệ quả về phương pháp đánh giá khá nặng. Thứ nhất, trung bình không phải một cách mô tả tốt cho phân phối hai chế độ: con số 0,1321 ở Bảng 4.11 nằm đúng vào khoảng trống giữa hai chế độ, tức *không lượt chạy nào* cho giá trị ấy. Thứ hai, một con số F1 khác bộ từ một lượt chạy duy nhất không mang thông tin về mô hình mà chủ yếu cho biết lượt đó rơi vào chế độ nào — mẫu 0,0423 từng được ghi trong các bản thảo trước của luận văn và của bài báo, lưu tại `cross_dataset_results.published.bak`, là một mẫu thuộc chế độ thấp. Vì vậy luận văn báo cáo cả phân phối (số lượt mỗi chế độ và khoảng giá trị) và dùng AUC-PR làm đại lượng chính khi so sánh khác bộ. Kết luận định tính không đổi: kể cả ở chế độ cao, F1 khác bộ 0,30 và AUC-PR 0,49 vẫn cách rất xa mức cùng bộ 0,99 và 0,9997, và khoảng cách đó không cấu hình nào lấp được.

Thứ hai kỹ thuật thích ứng miền không giám sát. Câu hỏi tự nhiên tiếp theo là phần sụt giảm đó có phải chỉ do lệch thang đo giữa hai testbed hay không — nếu đúng vậy thì một phép căn chỉnh tuyến tính là đủ để khắc phục. Luận văn kiểm chứng bằng hai kỹ thuật kinh điển, cả hai đều *không dùng bất kỳ nhãn nào của miền đích và không huấn luyện lại bộ phân loại*, tức đúng tình huống của một hệ đã triển khai gặp mạng mới: (i) *chuẩn hóa theo miền* — giữ nguyên rừng cây, chỉ fit lại `StandardScaler` trên phần đặc trưng (không nhãn) của tập huấn luyện miền đích; (ii) *CORAL* [66] — làm trắng miền đích bằng hiệp phương sai của chính nó rồi “tô” lại bằng hiệp phương sai miền nguồn, tức căn khớp cả moment bậc hai. Kết quả ở Bảng 4.12.

Cả hai kỹ thuật đều *không* khôi phục được F1: sau khi căn chỉnh, mô hình gần như ngừng báo tấn công nên F1 về 0. Điều này bác bỏ giả thuyết “chỉ lệch thang đo”: nếu dịch chuyển nằm ở moment bậc một và bậc hai thì hai phép căn chỉnh này đã đủ, nhưng thực tế phần khác biệt nằm ở *phân phối có điều kiện* — cái gì làm một luồng trở thành độc hại — cùng với việc hai testbed dùng bộ công cụ tấn công không trùng nhau. Tuy vậy có một

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Bảng 4.12. Hai kỹ thuật thích ứng miền không giám sát trên tác vụ liên bộ dữ liệu (bộ phân loại giữ nguyên, không dùng nhãn miền đích)

Chiều	Cấu hình	F1	AUC-PR
2017 → 2018	Không thích ứng	0,2978	0,5261
	Chuẩn hóa theo miền	0,0000	0,3169
	CORAL	0,0000	0,2015
2018 → 2017	Không thích ứng	0,0575	0,1791
	Chuẩn hóa theo miền	0,0000	0,1068
	CORAL	0,0000	0,2496

Ba dòng của mỗi chiều đến từ *cùng một lượt chạy* nên so sánh được với nhau. Dữ liệu thô của bảng này là `cross_dataset_adaptation_high_regime.csv` (hạt giống 42). Kết quả F1 về 0 được kiểm chứng trên *ba* lượt chạy độc lập có mức cơ sở 0,2939–0,3000, tức đều thuộc chế độ cao của phân phối đã mô tả ở trên; mức cơ sở của Bảng 4.13 (0,2939) cũng thuộc chế độ này nên hai bảng nhất quán với nhau. Trường hợp mức cơ sở thuộc chế độ thấp chưa đo được, và không thể chỉ định trước vì chế độ không do hạt giống quyết định — đây là hạn chế của thí nghiệm thích ứng, không phải của kết luận về sự bất ổn. Ánh xạ CORAL được kiểm chứng giải tích: sau khi ánh xạ, trung bình và hiệp phương sai của miền đích khớp miền nguồn với sai số tương đối 4×10^{-12} .

chi tiết đáng chú ý: ở chiều 2018→2017, CORAL *cải thiện* AUC-PR từ 0,1791 lên 0,2496 trong khi F1 vẫn bằng 0. Nghĩa là phép căn chỉnh có làm *thứ tự xếp hạng* tốt lên, nhưng ngưỡng quyết định 0,5 học từ miền nguồn không còn hiệu lực trong không gian đặc trưng đã đổi. Bài học rút ra cho triển khai thực tế: thích ứng miền cho IDS không thể dừng ở căn chỉnh đặc trưng mà phải kèm *hiệu chỉnh lại ngưỡng* trên miền đích.

Cái giá của việc gán nhãn: 1% dữ liệu miền đích. Nếu không kỹ thuật không giám sát nào hiệu quả, câu hỏi thực tế tiếp theo là *phải gán nhãn bao nhiêu* lưu lượng của mạng mới để có bộ phát hiện dùng được. Luận văn đo trực tiếp: lấy ngẫu nhiên 1% tập huấn luyện của miền đích *kèm nhãn* (giữ tỷ lệ tấn công tự nhiên, không phải mẫu cân bằng 50/50, vì kịch bản là gán nhãn những gì đi qua mạng), huấn luyện lại mô hình từ đầu, rồi đánh giá trên tập kiểm tra miền đích chưa hề đụng tới. Hai cấu hình được so sánh: (i) *gộp* dữ liệu nguồn với 1% nhãn đích và (ii) *chỉ dùng* 1% nhãn đích, bỏ hẳn dữ liệu nguồn — cấu hình thứ hai đóng vai trò đối chứng để trả lời câu hỏi dữ liệu nguồn có đóng góp gì không. Kết quả ở Bảng 4.13.

Hai điều rút ra, điều thứ hai là bất ngờ. Thứ nhất, **khoảng 19 nghìn luồng có nhãn là đủ**: F1 chiều 2017→2018 tăng từ 0,29 lên 0,92 và chiều ngược lại từ 0,06 lên 0,99. Nghĩa là mạng mới *không* khó phát hiện — cái không chuyển được là kiến thức của mô hình cũ. Thứ hai, **dữ liệu miền nguồn không những vô ích mà còn có hại**: chỉ dùng 19 nghìn dòng nhãn đích cho F1 0,9223, trong khi gộp thêm 1,79 triệu dòng có nhãn của miền nguồn lại kéo xuống 0,8034 (recall rơi từ 0,92 xuống 0,68); chiều ngược lại cũng cùng xu hướng

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Bảng 4.13. Ngân sách nhãn miền đích: huấn luyện lại với 1% dữ liệu có nhãn của miền đích

Chiều	Cấu hình	Nhãn đích	F1	Recall
2017 → 2018	Không thích ứng	0	0,2939	0,1749
	Nguồn + 1% nhãn đích	19.276	0,8034	0,6750
	Chỉ 1% nhãn đích	19.276	0,9223	0,9198
2018 → 2017	Không thích ứng	0	0,0574	0,0322
	Nguồn + 1% nhãn đích	18.011	0,9607	0,9853
	Chỉ 1% nhãn đích	18.011	0,9897	0,9849

1% được lấy từ *tập huấn luyện* của miền đích, không bao giờ từ tập kiểm tra. Dòng “không thích ứng” lấy từ chính lượt chạy này để ba dòng so sánh được với nhau; mức cơ sở 0,2939 vì vậy là một lượt thuộc *chế độ cao* của phân phối F1 khác bộ nói trên, cùng chế độ với lượt dùng ở Bảng 4.12 (0,2978). Kết luận rút ra dưới đây không phụ thuộc vào mức cơ sở cụ thể: kể cả khi so với mẫu cao nhất quan sát được (0,3009), mức tăng do 1% nhãn vẫn là hơn một bậc độ lớn ở cả hai chiều.

(0,9897 so với 0,9607). Khối lượng áp đảo của dữ liệu nguồn kéo mô hình về những mẫu hình đặc thù của testbed cũ, lấn át tín hiệu từ phần dữ liệu đích ít ỏi nhưng đúng phân phối.

Khuyến nghị triển khai rút ra từ đây rất cụ thể: khi đưa hệ thống sang một mạng mới, *đừng* tái sử dụng mô hình cũ hay gộp dữ liệu cũ vào; hãy gán nhãn một lượng nhỏ lưu lượng tại chỗ (cỡ 1%, tương đương vài giờ công của một phân tích viên) rồi huấn luyện lại từ đầu. Đây cũng là lời giải thích vì sao các kỹ thuật thích ứng không giám sát ở trên thất bại: khoảng cách giữa hai miền không nằm ở phép biến đổi tuyến tính của không gian đặc trưng mà ở chính ranh giới quyết định, và ranh giới đó chỉ học được từ nhãn của miền đích.

4.2.10 Đánh giá đa lớp theo loại tấn công


Phân loại nhị phân (Benign/Attack) trên CICIDS2017 vốn dễ tách. Để bộc lộ điểm yếu thực sự, luận văn bổ sung đánh giá đa lớp theo từng loại tấn công gốc (precision/recall/F1 từng lớp, macro-F1, weighted-F1 và ma trận nhầm lẫn), gồm lớp Benign và 14 loại tấn công của CICIDS2017. Kết quả cho thấy tương phản rất rõ giữa hai chỉ số tổng hợp: weighted-F1 $\approx 0,998$ (bị chi phối bởi các lớp đa số) nhưng macro-F1 chỉ $\approx 0,806$. Đây là bằng chứng cho thấy độ chính xác nhị phân gần hoàn hảo đã che giấu hiệu năng phát hiện kém ở các lớp hiếm. Cụ thể, các lớp đa số (Benign, DoS Hulk, DDoS, PortScan) đạt F1 rất cao ($\geq 0,97$), trong khi các lớp cực hiếm suy giảm nghiêm trọng: Web Attack – XSS recall chỉ 0,027, Web Attack – SQL Injection F1 = 0 (chỉ 6 mẫu), Bot recall 0,46. Đây là nơi khác biệt giữa các phương pháp lựa chọn đặc trưng thể hiện rõ nhất và cũng là hướng cần cải thiện (xử lý mất cân bằng, tăng cường dữ liệu lớp hiếm). Kết quả chi tiết theo từng lớp được trình bày trong Bảng 4.14, và ma trận nhầm lẫn đa lớp tương ứng được minh họa ở Hình 4.5.

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN


Bảng 4.14. Hiệu năng theo từng lớp tấn công (từ `per_class_metrics.csv`)

Lớp	Support	Precision	Recall	F1
Benign	380.119	0,9981	0,9997	0,9989
DoS Hulk	34.446	0,9990	0,9904	0,9947
DDoS	25.694	0,9996	0,9992	0,9994
DoS GoldenEye	2.020	1,0000	0,9757	0,9877
FTP-Patator	1.147	0,9965	0,9965	0,9965
DoS slowloris	1.068	0,9953	0,9925	0,9939
DoS Slowhttptest	1.023	0,9286	0,9912	0,9589
SSH-Patator	642	1,0000	0,9346	0,9662
PortScan	383	1,0000	0,9530	0,9759
Web Attack – Brute Force	311	0,7346	0,7299	0,7323
Bot	290	1,0000	0,4552	0,6256
Web Attack – XSS	111	1,0000	0,0270	0,0526
Infiltration	12	1,0000	0,6667	0,8000
Web Attack – SQL Injection	6	0,0000	0,0000	0,0000
Heartbleed	3	1,0000	1,0000	1,0000
macro-F1 / weighted-F1			0,806 / 0,998	


Phân tích hướng nhầm lẫn giữa các lớp hiếm. Đọc ma trận nhầm lẫn theo *đích đến* của các dự đoán sai cho thấy các lớp hiếm suy giảm theo hai kiểu khác nhau. Kiểu thứ nhất là *nhầm loại nhưng vẫn bị phát hiện*: 81/111 mẫu Web Attack – XSS bị gán thành Web Attack – Brute Force, tức ở bài toán nhị phân triển khai trên biên, các luồng này *vẫn bị gán cờ tấn công* (76% XSS vẫn bị chặn), chỉ sai ở khâu định danh loại. Kiểu thứ hai nguy hiểm hơn là *lọt hẳn thành Benign*: toàn bộ 6/6 mẫu SQL Injection, 158/290 mẫu Bot (54%) và 84/311 mẫu Web Brute Force bị dự đoán là lưu lượng bình thường. Ba cơ chế giải thích hiện tượng này: (i) *mất cân bằng cực đoan* (6–311 mẫu so với 380.119 mẫu Benign) khiến các lớp hiếm gần như không có vùng quyết định riêng; (ii) việc *loại destination_port* ảnh hưởng nặng nhất đến nhóm tấn công web: khi mất “lõi tắt” cổng 80, các luồng HTTP tấn công (request/response ngắn) có đặc trưng hành vi rất gần lưu lượng duyệt web thường và gần lẫn nhau, do đó giá trị recall 0,027 của XSS là con số trung thực thay cho con số đẹp nhờ rò rỉ; (iii) *Bot lẫn Benign do bản chất*: các luồng beaconing C&C nhỏ, đều đặn, giống lưu lượng nền khi không còn định danh cổng/dịch vụ. Nhận diện này dẫn thẳng tới các hướng phát triển: xử lý mất cân bằng có chủ đích (tăng cường/oversampling lớp hiếm), bổ sung đặc trưng chuỗi thời gian cho hành vi beaconing, và kiểm chứng liên bộ dữ liệu (Mục 4.2.9).




Hình 4.2. Top 30 đặc trưng quan trọng theo giá trị trung bình tuyệt đối SHAP của mô hình XGB



Hình 4.3. Biểu đồ SHAP Summary (beeswarm): phân bố và hướng tác động của từng đặc trưng



Hình 4.4. Mức thổi phồng F1 do destination_port theo từng thuật toán: mô hình tuyến tính phụ thuộc cổng nặng hơn hẳn các ensemble cây



Hình 4.5. Ma trận nhầm lẫn đa lớp theo loại tấn công (chuẩn hóa theo hàng)

4.3 Thực nghiệm và đánh giá hiệu năng mô hình trên Jetson Orin Nano Super

Trong phần này, luận văn đề xuất xây dựng một hệ thống phát hiện xâm nhập mạng IDS phân tán triển khai trên một cụm **hai thiết bị biên NVIDIA Jetson Orin Nano Super** [67] nhằm đánh giá khả năng hoạt động trong môi trường tài nguyên hạn chế. Đây là hướng tiếp cận điện toán biên đưa phân tích về gần nguồn dữ liệu để giảm băng thông và thời gian phản hồi [68, 69], trong khi các nghiên cứu IDS biên trước đây chủ yếu đánh giá suy luận đơn nút [70]. Hệ thống được thiết kế theo kiến trúc xử lý dữ liệu thời gian thực hai tầng: một cổng phát hiện bất thường (anomaly gate) bằng autoencoder nhẹ lọc bớt lưu lượng bình thường trên Jetson #1, và một bộ phân loại PySpark PipelineModel chỉ xử lý các luồng nghi vấn trên Jetson #2. Hạ tầng trung tâm (Apache Kafka cho truyền tải thông điệp, PostgreSQL để quản lý dữ liệu, InfluxDB để lưu chỉ số hiệu năng theo thời gian, Grafana để trực quan hóa và Mailtrap để kiểm thử cảnh báo qua email) chạy trên một máy chủ điều phối.

NVIDIA Jetson Orin Nano Super là một máy tính nhúng (single-board computer) tích hợp CPU kiến trúc ARM 64-bit và GPU NVIDIA, hỗ trợ tăng tốc suy luận học máy ngay tại biên. Cấu hình chi tiết đã nêu tại Bảng 3.7 (Chương 3) và mục Môi trường thực nghiệm. Do hạn chế về tài nguyên tính toán so với máy chủ truyền thống, việc triển khai trên Jetson Orin Nano Super cho phép đánh giá khả năng tối ưu hóa mô hình và hiệu năng suy luận trong điều kiện phần cứng nhúng (edge computing).

Mô hình có hiệu năng tối ưu được xác định ở phần đánh giá hiệu năng phân loại phía trên sẽ được tích hợp vào pipeline xử lý nhằm thực hiện nhiệm vụ phát hiện và phân loại lưu lượng mạng thành hai nhóm: *Benign* và *Attack*. Các chỉ số đánh giá bao gồm độ chính xác (Accuracy), Precision, Recall, F1-Score, thời gian dự đoán trung bình cho mỗi mẫu, thông lượng xử lý (throughput) và mức tiêu thụ tài nguyên hệ thống (CPU, RAM). Kết quả thực nghiệm cho phép phân tích tính khả thi của việc triển khai hệ thống IDS dựa trên học máy trong môi trường thiết bị biên có tài nguyên giới hạn.

4.3.1 Các công cụ sử dụng trong hệ thống


Trong hệ thống phát hiện xâm nhập mạng IDS được đề xuất, ngoài các công nghệ xử lý dữ liệu lớn đã trình bày ở Chương 2, luận văn sử dụng thêm một số công cụ và nền tảng mã nguồn mở nhằm hỗ trợ truyền tải dữ liệu, lưu trữ, giám sát hiệu năng và cảnh báo theo thời gian thực. Cụ thể:

- **Apache Kafka** [71] – Là nền tảng truyền tải thông điệp phân tán (distributed event streaming platform), được sử dụng để tiếp nhận và phân phối dữ liệu luồng theo cơ chế publish-subscribe. Trong hệ thống, Kafka đóng vai trò trung gian giữa nguồn dữ liệu (CICIDS2017 được mô phỏng bằng Python script) và thiết bị Jetson Orin Nano Super, bảo đảm khả năng truyền tải bất đồng bộ, chịu lỗi và mở rộng linh hoạt.
- **Apache Spark Streaming** – Là thành phần xử lý dữ liệu luồng thời gian thực. Spark Streaming nhận dữ liệu từ Kafka Consumer, thực hiện các bước tiền xử lý đặc trưng và chuyển dữ liệu đến mô hình học máy đã được huấn luyện để thực hiện suy luận.
- **PostgreSQL** – Là hệ quản trị cơ sở dữ liệu quan hệ mã nguồn mở có độ ổn định và khả năng mở rộng cao. Trong hệ thống, PostgreSQL được sử dụng để lưu trữ kết quả dự đoán, thông tin cảnh báo và các bản ghi phục vụ báo cáo tổng hợp.
- **InfluxDB** – Là cơ sở dữ liệu chuỗi thời gian (Time-Series Database), tối ưu cho việc lưu trữ và truy vấn các chỉ số theo thời gian. Hệ thống sử dụng InfluxDB để ghi nhận các thông số hiệu năng như thời gian suy luận, mức sử dụng CPU, bộ nhớ và thông lượng xử lý.
- **Grafana** – Là nền tảng trực quan hóa dữ liệu mã nguồn mở, cho phép xây dựng các dashboard theo thời gian thực. Grafana kết nối với InfluxDB và PostgreSQL để hiển thị tình trạng hoạt động của hệ thống IDS cũng như thống kê các sự kiện tấn công.
- **Mailtrap** – Là công cụ kiểm thử email trong môi trường giả lập. Trong giai đoạn thực nghiệm, Mailtrap được sử dụng để kiểm tra cơ chế gửi cảnh báo khi hệ thống phát hiện lưu lượng mạng bất thường trước khi triển khai môi trường thực tế.

Các công nghệ trên bao phủ đủ bốn nhu cầu vận hành của hệ thống: truyền tải luồng, lưu trữ, giám sát hiệu năng và cảnh báo.

4.3.2 Mô hình hệ thống đề xuất

Hệ thống phát hiện xâm nhập được thiết kế theo kiến trúc xử lý dữ liệu luồng như minh họa ở Hình 4.6. Luồng xử lý tổng thể bao gồm các bước sau:



Hình 4.6. Kiến trúc hệ thống phát hiện xâm nhập phân tán thời gian thực trên cụm 2 Jetson Orin Nano Super

1. **Nguồn dữ liệu:** Dữ liệu từ bộ CICIDS2017 được mô phỏng theo thời gian thực thông qua một Python script và gửi vào Kafka Producer trên topic `ids-network-flow`.
2. **Cổng phát hiện bất thường (Jetson #1):** Jetson #1 đảm nhận vai trò `anomaly_gate`: một autoencoder nhẹ (huấn luyện chỉ trên lưu lượng bình thường) tính sai số tái tạo (reconstruction error) cho từng luồng. Các luồng có sai số dưới ngưỡng được coi là bình thường và bị lọc bỏ. Chỉ các luồng nghi vấn mới được chuyển tiếp sang topic `ids-suspicious-flow`. Cơ chế này giảm đáng kể khối lượng phải đưa vào suy luận Spark.
3. **Bộ phân loại (Jetson #2):** Jetson #2 đảm nhận vai trò `classifier`: tải mô hình PySpark PipelineModel (với tập đặc trưng SHAP Top-30 đã chọn) và phân loại các luồng nghi vấn thành *Benign* hoặc *Attack*. Vector đầu vào khi triển khai gồm 29 đặc trưng: trong Top-30 theo xếp hạng SHAP có `destination_port`, nhưng đặc trưng này bị loại khỏi mô hình xuất ra để triển khai vì là kênh rò rỉ nhãn trên CICIDS2017 (Mục 4.2.5), nhất quán với giao thức chống rò rỉ ở pha huấn luyện.
4. **Ghi nhận hiệu năng:** Mỗi nút ghi nhận thời gian dự đoán/mẫu, mức sử dụng CPU/RAM/nhiệt độ và thông lượng (gắn nhãn theo `EDGE_NODE_ID`) và lưu các chỉ số này vào InfluxDB.
5. **Lưu trữ và cảnh báo:** Kết quả dự đoán và sự kiện tấn công được lưu vào PostgreSQL. Khi phát hiện lưu lượng bất thường, hệ thống kích hoạt cảnh báo qua Email/Webhook (Mailtrap, Slack trong môi trường kiểm thử) từ một nút chính được chỉ định để tránh trùng lặp.
6. **Trực quan hóa và giám sát:** Grafana truy xuất dữ liệu từ InfluxDB và PostgreSQL để xây dựng dashboard theo thời gian thực, giám sát trạng thái hệ thống và thống kê các sự kiện tấn công.

Ba chế độ triển khai phân tán. Cụm hai Jetson hỗ trợ ba chế độ, lựa chọn theo ràng buộc tải và độ trễ:

- **Chế độ A – Pipeline split** (khuyến nghị): Jetson #1 = cổng bất thường (anomaly gate), Jetson #2 = bộ phân loại (classifier) (như mô tả trên), giúp giảm tải Spark nhờ lọc lưu lượng bình thường sớm.

- **Chế độ B – Mở rộng theo chiều ngang (Horizontal scaling):** cả hai Jetson chạy pipeline đầy đủ trong cùng một nhóm tiêu thụ (consumer group) của Kafka nhằm tăng thông lượng.
- **Chế độ C – Spark cluster:** máy chủ MacBook làm Spark master, hai Jetson làm worker, phân tán suy luận Spark trên cụm. Nhất quán với nguyên tắc ở mục Môi trường thực nghiệm, MacBook chỉ đảm nhận điều phối (master), không chạy executor. Toàn bộ tính toán suy luận vẫn nằm trên hai Jetson.

Kiến trúc này tách các thành phần xử lý thành những mô-đun độc lập, phù hợp với triển khai phân tán trên thiết bị biên tài nguyên hạn chế như Jetson Orin Nano Super.

Đặc tả cổng bắt thường (operating point). Cổng autoencoder là một bộ lọc điều chỉnh được chứ không phải một điểm vận hành cố định: nâng ngưỡng giúp giảm tải (offload) nhiều lưu lượng bình thường hơn khỏi Spark (tăng tỷ lệ bỏ qua tại cổng, gate-skip) nhưng có thể giảm recall trên lớp tấn công. Ngưỡng của cổng được chọn theo phân vị (quantile) của sai số tái tạo tính trên một tập kiểm định benign gồm 10% tách từ phần lưu lượng bình thường của tập huấn luyện ($seed=42$). Tập kiểm tra không tham gia việc chọn ngưỡng, tránh rò rỉ kiểu “ngưỡng oracle”. Bảng 4.15 trình bày đường đánh đổi giữa recall và mức giảm tải (recall–offload) khi quét các mức quantile trên tập kiểm định này. Điểm vận hành được chọn theo ngân sách độ trễ/độ chính xác của triển khai. FPR trong bảng là tỷ lệ luồng benign bị cổng chuyển nhầm sang bộ phân loại, không phải FPR của toàn hệ thống. Cần lưu ý phạm vi tính toán: tỷ lệ bỏ qua trong Bảng 4.15 được tính trên tập kiểm tra đã loại trùng lặp ở mức đặc trưng (380.119 benign / 67.156 attack, tức khoảng 85% benign), còn tỷ lệ bỏ qua thực đo khi triển khai (95,8% ở chế độ A và 97,9% ở chế độ C, Bảng 4.19) được tính trên luồng phát lại tuần tự từ các tệp CSV gốc của CICIDS2017, vốn còn nguyên các luồng trùng lặp (phần lớn là benign) nên tỷ lệ benign trong cửa sổ đo cao hơn. Cùng một ngưỡng nhưng khác thành phần lưu lượng thì cho tỷ lệ bỏ qua khác nhau, vì vậy con số thực đo không phải là một điểm nằm trên đường đánh đổi của bảng này và hai giá trị không so sánh trực tiếp được.

4.3.3 Lựa chọn mô hình cho thiết bị biên

Triển khai trên thiết bị biên đặt ra các ràng buộc về tài nguyên: RAM 8 GB chia sẻ giữa CPU và GPU (trong đó PySpark JVM chiếm một phần đáng kể), CPU ARM, cùng ràng buộc về nhiệt độ/băng thông tại biên. Việc chọn Apache Spark trên Jetson 8 GB phải chịu

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Bảng 4.15. Điểm vận hành của cổng bất thường theo ngưỡng quantile trên tập kiểm định benign

Quantile (validation)	Ngưỡng	Recall (Attack)	FPR	Tỷ lệ bỏ qua tại cổng (%)
0,90	0,0023	0,7589	0,1003	80,08
0,95	0,0052	0,7552	0,0506	84,36
0,99	0,0192	0,7420	0,0101	88,00
0,995	0,0317	0,7229	0,0053	88,70

chi phí JVM/Spark đáng kể. Spark được dùng ở đây nhằm nhất quán với pha huấn luyện phân tán, chứ không nhằm tối ưu độ trễ suy luận trên một nút. Chi phí đánh đổi này được định lượng qua so sánh với scikit-learn và ONNX Runtime ở mục 4.3.6, còn tăng tốc bằng TensorRT là hướng nghiên cứu tương lai. Ba mô hình đại diện cho ba thử nghiệm khác nhau được chọn để đánh giá:

1. **Decision Tree** – Mô hình cây đơn lẻ, đại diện cho cách tiếp cận đơn giản nhất.
2. **GBT (Gradient-Boosted Trees)** – Đại diện cho phương pháp Boosting, sử dụng nhiều cây yếu kết hợp tuần tự.
3. **Random Forest** – Đại diện cho phương pháp Bagging, sử dụng ensemble 200 cây song song.

Cả ba mô hình đều được huấn luyện trên tập SHAP Top-30 đặc trưng và triển khai dưới dạng PySpark PipelineModel.

Hình 4.7 minh họa giao diện terminal thực tế khi pipeline IDS đang xử lý dữ liệu trên Jetson Orin Nano Super, bao gồm thông tin về thông lượng, độ trễ và số lượng tấn công phát hiện được. Hai dashboard Grafana (Hình 4.8 và Hình 4.9) cho phép giám sát hiệu năng hệ thống và chi tiết các cuộc tấn công theo thời gian thực. Hình 4.10 ghi lại thời điểm tải đỉnh, cho thấy rõ sự phân bố tải lệch đặc trưng của chế độ tách pipeline: nút cổng chỉ sử dụng khoảng 5% CPU trong khi nút phân loại PySpark đạt tới 91%, xác nhận bộ phân loại là thành phần chiếm tài nguyên chủ đạo và là căn cứ cho các phân tích năng lượng–thông lượng ở phần sau. Khi phát hiện tấn công, hệ thống tự động gửi cảnh báo qua nhiều kênh: email thông qua Mailtrap SMTP (Hình 4.11) và tin nhắn Slack (Hình 4.12). Hai ảnh cảnh báo này chụp từ giai đoạn thử nghiệm sớm của hệ thống. Mô-đun cảnh báo và định dạng thông điệp giữ nguyên khi triển khai trên cụm Jetson.

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

```
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- -zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- -zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.150 +
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (729.4MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.0 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.1 C

[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.2 C

[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.4 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.7 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.5 C

[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (730.5MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.8 C

[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.6 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C

[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 53.6 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C

[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C

[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C

[MONITOR:jetson-nano-1] CPU: 17.2% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.1 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.2 C

[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C

[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.0 C

[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.1 C

[MONITOR:jetson-nano-1] CPU: 17.6% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.3 C

[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.1MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0
Temp: 54.2 C
```

(a) Jetson #1 (jetson-nano-1): cổng phát hiện bất thường, giám sát tài nguyên theo node


```
thainguyenvu -- bvdung@ubuntu: ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 -- 208x63
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- -zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- -zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.150 ... +
[MONITOR:jetson-nano-2] CPU: 72.4% | MEM: 58.6% (4196.0MB) | Throughput: 6.88 rps | Latency: 3.833ms | Attacks: 32
Temp: 56.7 C
[Stage 984:] (0 + 0) / 63
[MONITOR:jetson-nano-2] CPU: 17.6% | MEM: 49.6% (3512.9MB) | Throughput: 6.87 rps | Latency: 3.968ms | Attacks: 32
Temp: 56.2 C
[MONITOR:jetson-nano-2] CPU: 17.3% | MEM: 57.5% (4111.0MB) | Throughput: 6.84 rps | Latency: 4.472ms | Attacks: 32
Temp: 56.1 C
[Stage 1089:] (0 + 63) / 63
[MONITOR:jetson-nano-2] CPU: 97.7% | MEM: 54.7% (3980.9MB) | Throughput: 3.83 rps | Latency: 4.514ms | Attacks: 16
Temp: 57.3 C
[MONITOR:jetson-nano-2] CPU: 21.4% | MEM: 46.7% (3298.0MB) | Throughput: 6.88 rps | Latency: 4.334ms | Attacks: 32
Temp: 56.2 C
[MONITOR:jetson-nano-2] CPU: 67.8% | MEM: 55.8% (3927.0MB) | Throughput: 6.86 rps | Latency: 3.638ms | Attacks: 32
Temp: 56.7 C
[Stage 1047:] (0 + 63) / 63
[MONITOR:jetson-nano-2] CPU: 68.2% | MEM: 58.9% (3611.9MB) | Throughput: 6.88 rps | Latency: 4.156ms | Attacks: 32
Temp: 57.0 C
[MONITOR:jetson-nano-2] CPU: 16.9% | MEM: 59.6% (4274.3MB) | Throughput: 6.88 rps | Latency: 4.483ms | Attacks: 32
Temp: 55.9 C
[jetson-nano-2 2.408] Batch: 187ms | Attacks: 2373/2480 | Avg: 9.7ms
[MONITOR:jetson-nano-2] CPU: 85.5% | MEM: 49.1% (3474.0MB) | Throughput: 6.88 rps | Latency: 3.256ms | Attacks: 32
Temp: 56.5 C
[Stage 1080:] (0 + 83) / 63
[MONITOR:jetson-nano-2] CPU: 66.6% | MEM: 51.7% (3673.5MB) | Throughput: 3.84 rps | Latency: 3.737ms | Attacks: 16
Temp: 56.9 C
[MONITOR:jetson-nano-2] CPU: 28.7% | MEM: 56.8% (4082.1MB) | Throughput: 6.88 rps | Latency: 4.399ms | Attacks: 32
Temp: 56.1 C
[MONITOR:jetson-nano-2] CPU: 74.4% | MEM: 54.8% (3968.1MB) | Throughput: 6.88 rps | Latency: 3.923ms | Attacks: 32
Temp: 56.9 C
[MONITOR:jetson-nano-2] CPU: 34.2% | MEM: 56.8% (4063.0MB) | Throughput: 5.88 rps | Latency: 4.574ms | Attacks: 31
Temp: 56.8 C
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 55.8% (3924.2MB) | Throughput: 6.88 rps | Latency: 4.42ms | Attacks: 32
Temp: 56.1 C
[Stage 1149:] (1 + 53) / 63
[MONITOR:jetson-nano-2] CPU: 98.8% | MEM: 59.1% (4234.9MB) | Throughput: 3.84 rps | Latency: 3.157ms | Attacks: 16
Temp: 57.2 C
[MONITOR:jetson-nano-2] CPU: 16.8% | MEM: 52.5% (3733.5MB) | Throughput: 6.88 rps | Latency: 3.994ms | Attacks: 32
Temp: 56.9 C
[MONITOR:jetson-nano-2] CPU: 18.8% | MEM: 57.8% (4077.7MB) | Throughput: 5.98 rps | Latency: 4.577ms | Attacks: 31
Temp: 56.1 C
[Stage 1187:] (0 + 63) / 63
[MONITOR:jetson-nano-2] CPU: 45.8% | MEM: 60.6% (4351.7MB) | Throughput: 5.98 rps | Latency: 4.121ms | Attacks: 31
Temp: 56.7 C
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 52.7% (3758.0MB) | Throughput: 5.99 rps | Latency: 3.338ms | Attacks: 31
Temp: 55.9 C
[Stage 1212:] (3 + 33) / 63
```

(b) Jetson #2 (jetson-nano-2): bộ phân loại PySpark, thông lượng ~6 luồng/giây, độ trễ suy luận ~4 ms, đếm tấn công theo lô


Hình 4.7. Giao diện terminal của pipeline IDS trên hai nút Jetson: (a) cổng lọc bất thường, (b) bộ phân loại PySpark




Hình 4.8. Dashboard Grafana giám sát hiệu năng IDS theo thời gian thực




Hình 4.9. Dashboard Grafana hiển thị chi tiết các cuộc tấn công được phát hiện và phân loại theo thời gian



Hình 4.10. Dashboard Grafana tại thời điểm tải đỉnh của chế độ tách pipeline



Hình 4.11. Email cảnh báo tấn công gửi qua Mailtrap trong môi trường kiểm thử



Hình 4.12. Thông báo cảnh báo tấn công gửi qua Slack Incoming Webhook

4.3.4 Kết quả huấn luyện các mô hình ứng viên trên cụm Spark

Bảng 4.16 trình bày kết quả huấn luyện và đánh giá ba mô hình ứng viên trên cụm Spark (mô tả ở mục Môi trường thực nghiệm) trước khi triển khai xuống thiết bị biên.

Bảng 4.16. Kết quả huấn luyện các mô hình ứng viên cho triển khai biên (SHAP Top-30)

Mô hình	F1-Score	Accuracy	Thời gian huấn luyện (s)	Kích thước (MB)
Decision Tree	0,9814	0,9943	24,4	0,046
GBT	0,9753	0,9925	341,8	0,865
Random Forest	0,9826	0,9947	687,3	4,427

Về tiêu chí nhận biết ràng buộc biên (edge-aware), ba mô hình ứng viên đánh đổi khác nhau: Decision Tree có kích thước nhỏ nhất (0,046 MB, nhỏ hơn Random Forest khoảng 96 lần) và huấn luyện nhanh hơn khoảng 28 lần, trong khi Random Forest đạt F1 cao nhất. Riêng F1/Accuracy chưa đủ để kết luận: quyết định cuối cùng dựa trên số đo vận hành thực tế trên thiết bị (thông lượng, độ trễ, CPU, RAM) ở mục tiếp theo. (Các mô hình ứng viên biên được huấn luyện trên mẫu con phân tầng khi xuất để vừa bộ nhớ một nút, nên F1 thấp hơn chút ít so với kết quả huấn luyện phân tán đầy đủ ở Bảng 4.3. Độ chính xác chính thức lấy từ pha huấn luyện đầy đủ.)

4.3.5 Kết quả đo hiệu năng (benchmark) trên Jetson Orin Nano Super

Bảng 4.17 trình bày kết quả đo hiệu năng (benchmark) thực tế trên Jetson Orin Nano Super. Mỗi cấu hình được đo lặp lại 5 lần. Trước mỗi cửa sổ đo có giai đoạn khởi động (warm-up)

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN


bằng chính lưu lượng thật để làm nóng JVM/JIT, và dữ liệu warm-up bị loại khỏi cửa sổ đo. Kết quả báo cáo là trung bình $\pm$ độ lệch chuẩn qua các lần chạy. Hai loại độ trễ được ghi nhận: (i) *độ trễ suy luận* (tiền xử lý + dự đoán) trên từng nút, và (ii) *độ trễ đầu cuối* (từ thời điểm producer gửi đến khi có phán quyết) tính từ nhân thời gian của producer. Giá trị tuyệt đối của loại (ii) chỉ có ý nghĩa khi các máy đồng bộ đồng hồ NTP. Các phân vị độ trễ (p50/p95/p99) được tính ở mức từng lần chạy từ log thô theo từng luồng trong đúng cửa sổ tải. Với cụm nhiều nút, p95 báo cáo là p95 của nút xấu nhất (không lấy phân vị của các giá trị trung bình theo nút).

Bảng 4.17. So sánh hiệu năng triển khai trên Jetson Orin Nano Super

Mô hình	Thông lượng (mẫu/giây)	Độ trễ suy luận (ms) p50 / p95 / p99	CPU (%)	RAM (%)	Kích thước (MB)
Decision Tree	22,0	441 / 537 / –	46,4	21,9	0,046
GBT	24,3	414 / 439 / –	40,9	24,0	0,865
Random Forest	26,8	378 / 397 / –	35,2	27,5	4,427

4.3.6 So sánh engine suy luận: chi phí của việc đồng nhất stack

Luận văn triển khai mô hình dưới dạng `PipelineModel` của Spark để đồng nhất với pha huấn luyện phân tán: cùng một stack vừa huấn luyện trên cụm vừa suy luận trên thiết bị. Để định lượng chi phí đánh đổi của sự đồng nhất này, luận văn đo lại cùng một mô hình Random Forest (cùng siêu tham số) trên cùng tập đặc trưng SHAP đã chọn để triển khai nhưng qua các engine nhẹ hơn ở chế độ một nút: scikit-learn (CPU, không JVM) và ONNX Runtime (CPU execution provider, xem Bảng 4.18, sinh từ `benchmark_engines.py`). Cả ba engine được đo trên nút phân loại với batch 10. Năng lượng báo cáo là phần hoạt động, đã trừ nền idle. Vì cùng thuật toán và đặc trưng nên độ chính xác tương đương. Phép so sánh vì vậy tập trung vào chi phí suy luận. (Cả ba dòng của Bảng 4.18 được đo lại trong cùng một phiên trên cùng trạng thái bo mạch để so sánh công bằng, nên dòng PySpark chênh lệch nhỏ so với Bảng 4.17 đo ở phiên trước: 22,6 so với 26,8 luồng/giây, do khác phiên đo và xung CPU.) Kết quả đo (Bảng 4.18) cho thấy stack JVM/Spark chịu chi phí suy luận cao hơn đáng kể so với scikit-learn trên bo mạch ARM 8 GB: thông lượng thấp hơn khoảng 9 lần, độ trễ p95 cao hơn khoảng 11 lần, tỷ lệ RAM gần gấp đôi và năng lượng mỗi suy luận cao hơn khoảng 25 lần. Biên dịch cùng mô hình rừng ngẫu nhiên sang ONNX Runtime còn nới rộng khoảng cách này đáng kể: $\approx 7\,900$ luồng/giây với p95 1,1 ms, tức gấp



Hình 4.13. Thông lượng và độ trễ p95 của bốn cấu hình (một nút cơ sở + ba chế độ phân tán) trên cụm 2 Jetson

≈ 348 lần thông lượng của Spark đã triển khai, ở mức năng lượng chỉ $\approx 2\%$ so với scikit-learn. Khoảng cách đó là cơ sở cho hướng phát triển xuất mô hình sang ONNX/TensorRT để suy luận trong khi vẫn giữ Spark cho huấn luyện (việc tích hợp phiên ONNX vào pipeline streaming và khai thác GPU qua TensorRT thuộc hướng phát triển).

Bảng 4.18. Chi phí suy luận một nút trên cùng mô hình và tập đặc trưng: Spark, sklearn và ONNX

Engine	Thông lượng (luồng/giây)	Độ trễ p95 (ms)	RAM (%)	Năng lượng /suy luận (mJ)
PySpark (triển khai)	22,6	532	24,3	71,6
scikit-learn	204,4	49,8	13,3	2,91
ONNX Runtime	7870,8	1,1	15,7	0,06

4.3.7 Kết quả ba chế độ triển khai phân tán

Ngoài việc so sánh các mô hình trên một nút, luận văn đánh giá ba chế độ triển khai phân tán trên cụm hai Jetson Orin Nano Super (Bảng 4.19). Chỉ số chính gồm thông lượng, độ trễ p95 (ms), tỷ lệ bỏ qua tại cổng (gate-skip: % lưu lượng bình thường được cổng lọc khỏi suy luận Spark) và F1 trên lớp tấn công. *Thông lượng* được định nghĩa là số phán quyết cuối cùng ghi vào PostgreSQL trên giây (một luồng nhận phán quyết hoặc tại cổng (nếu bị bỏ qua là benign) hoặc tại bộ phân loại), không cộng dồn đầu ra của hai tầng để tránh đếm trùng luồng được chuyển tiếp ở chế độ pipeline split.

Kết quả thực đo (Hình 4.13) cho thấy: chế độ *pipeline split* tách cổng khỏi bộ phân loại Spark giúp thông lượng phán quyết tăng từ 2,6 lên 62,5 luồng/giây (gấp ≈ 24 lần) với p95 gần như không đổi, nhờ cổng lọc 95,8% lưu lượng bình thường và không còn bị Spark chặn vòng xử lý (tỷ lệ này tính trên luồng phát lại, không so sánh trực tiếp với Bảng 4.15).

CHƯƠNG 4. THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Bảng 4.19. So sánh ba chế độ triển khai phân tán trên cụm 2 Jetson Orin Nano Super


Chế độ	Thông lượng (luồng/giây)	Độ trễ p95 (ms)	Bỏ qua tại cổng (%)	Năng lượng /suy luận (mJ)	F1 (Attack)
Một nút (single)	$2,60 \pm 0,41$	$12,3 \pm 3,0$	(nội tuyến)	2490	†
A: Pipeline split	$62,5 \pm 0,6$	$13,1 \pm 2,6$	95,8	178	†
B: Horizontal scaling	$5,9 \pm 1,4$	$21,6 \pm 19,2$	(nội tuyến)	2250	†
C: Spark cluster	$90,0 \pm 25,6$	$23,9 \pm 17,8$	97,9	119	†

Phát lại CICIDS2017 ở 100 luồng/giây; trung bình $\pm$ độ lệch chuẩn trên ≥ 3 lần lặp; p95 tính từ log thô từng luồng (nút xấu nhất). “(nội tuyến)”: ở vai trò `full`, cổng chạy trong cùng tiến trình và các luồng bị bỏ qua vẫn được ghi phán quyết nên không có tỷ lệ bỏ qua riêng. †: chất lượng phát hiện không phụ thuộc chế độ (các chế độ dùng cùng một mô hình xuất ra). F1 lớp tấn công ngoại tuyến xem Bảng 4.6.

Mở rộng theo chiều ngang chỉ tăng xấp xỉ gấp đôi một nút (5,9 so với 2,6) vì mỗi nút vẫn chạy trọn bộ phân loại Spark trong tiến trình. *Spark cluster* (cổng + bộ phân loại nối cụm Spark standalone) đạt thông lượng trung bình cao nhất (90,0) nhưng dao động lớn giữa các lần chạy (± 26) và phụ thuộc thêm nút chủ (master) trên máy điều phối, nên pipeline split vẫn là khuyến nghị mặc định. Năng lượng mỗi suy luận đo bằng `tegrastats` (nền idle 30 giây trước mỗi cửa sổ tải, chế độ hai nút cộng công suất cả hai bo mạch): ở mức tải 100 luồng/giây, phần công suất hoạt động (đã trừ idle) nằm dưới ngưỡng nhiễu lấy mẫu ($< 0,15$ W mỗi nút), do đó bảng báo cáo năng lượng toàn bo mạch trên mỗi phán quyết, tức thước đo mức dàn trải công suất bo mạch theo thông lượng ở cấp triển khai (không phải chi phí riêng của mô hình): các chế độ dùng cổng (A, C) dàn trải công suất hai bo mạch trên số phán quyết lớn gấp 24–35 lần, giảm năng lượng mỗi phán quyết từ $\approx 2,5$ J xuống 0,12–0,18 J.

4.3.8 Phân tích và lựa chọn mô hình


Hình 4.14 minh họa trực quan sự khác biệt giữa ba mô hình về thông lượng, độ trễ và mức sử dụng RAM trên Jetson Orin Nano Super.



Hình 4.14. So sánh hiệu năng ba mô hình trên Jetson Orin Nano Super

Kết quả benchmark cho thấy sự đánh đổi rõ ràng giữa các chỉ số:

Đánh đổi giữa các mô hình trên Jetson Orin Nano Super
(chuẩn hoá min-max, càng ra ngoài càng tốt)



Hình 4.15. Biểu đồ radar thể hiện sự đánh đổi (trade-off) giữa các mô hình trên thiết bị biên

- **Random Forest** thắng ở cả ba chỉ số vận hành quan trọng nhất đối với phát hiện xâm nhập thời gian thực: thông lượng cao nhất (26,8 mẫu/giây), độ trễ p95 thấp nhất (397 ms) và CPU thấp nhất (35,2%), nhờ Spark song song hóa tốt trên nhiều cây. Cái giá phải trả là RAM cao nhất (27,5%) và mô hình lớn nhất ($\approx 4,4$ MB).
- **GBT** có hiệu năng trung bình ở tất cả các chỉ số, đóng vai trò cầu nối giữa Decision Tree và Random Forest.
- **Decision Tree** nhẹ nhất về bộ nhớ (RAM 21,9%, mô hình $\approx 0,05$ MB) nhưng chậm nhất: thông lượng 22,0 mẫu/giây và độ trễ p95 537 ms, cao hơn Random Forest khoảng 35%.

Hình 4.15 thể hiện sự đánh đổi đa chiều giữa các tiêu chí lựa chọn mô hình: Decision Tree chiếm ưu thế về bộ nhớ, còn Random Forest chiếm ưu thế về tốc độ xử lý và tải CPU.

Random Forest được chọn làm mô hình triển khai chính trên thiết bị biên dựa trên ba tiêu chí:

1. **Hiệu năng xử lý thời gian thực:** thông lượng cao nhất (26,8 mẫu/giây) và độ trễ p95

thấp nhất (397 ms). Với IDS, độ trễ phán quyết là ràng buộc trực tiếp: một mô hình nhỏ nhưng chậm hơn 35% về p95 sẽ kéo dài cửa sổ mà tấn công chưa bị chặn.

2. **Chất lượng phát hiện:** cao nhất trong ba mô hình ứng viên ở cả hai phép đo: F1 0,9955 trên đánh giá ngoại tuyến đầy đủ (Bảng 4.3) và 0,9826 ở bản xuất huấn luyện trên mẫu con để vừa bộ nhớ một nút (Bảng 4.16).
3. **Tương thích nền tảng:** Random Forest là estimator gốc của Spark ML nên `PipelineModel` xuất ra nạp được trực tiếp trên bo mạch ARM64, không cần các thư viện native mà tích hợp XGB của Spark đòi hỏi.

Đánh đổi được chấp nhận là mức tiêu thụ bộ nhớ: Random Forest dùng 27,5% RAM so với 21,9% của Decision Tree và mô hình nặng $\approx 4,4$ MB so với 0,05 MB. Trên bo mạch 8 GB, khoảng chênh lệch này vẫn còn dư địa lớn, nên bộ nhớ không phải là ràng buộc quyết định. Decision Tree vẫn là phương án dự phòng hợp lý nếu triển khai xuống các thiết bị IoT eo hẹp bộ nhớ hơn.

4.4 Thảo luận và so sánh tổng hợp

Kết quả thực nghiệm cho thấy lựa chọn đặc trưng dựa trên SHAP là hướng tiếp cận phù hợp cho hệ thống IDS trên bộ dữ liệu CICIDS2017: dưới cấu hình đánh giá loại trừ rò rỉ dữ liệu, SHAP Top-30 giữ được hiệu năng gần như nguyên vẹn trong khi cắt khoảng 60% số đặc trưng. Ngược lại, học tổ hợp không mang lại lợi thế trên chính cấu hình này: Hybrid Bagging đạt F1 0,9966 và Soft Voting đạt 0,9967, đều thấp hơn XGB đơn lẻ (0,9970). Học tổ hợp chỉ vượt mô hình đơn ở những cấu hình mà mô hình đơn yếu hơn (RF Top-30: 0,9938 so với 0,9922; PCA $k=40$: 0,9940 so với 0,9939), nghĩa là nó bù cho bộ đặc trưng kém chứ không tạo thêm hiệu năng phân loại. Chi phí đi kèm lại lớn: trên SHAP Top-30, Hybrid Bagging cần 4909 giây huấn luyện (so với 1226 giây của XGB), 46,6 giây dự đoán (so với 7,1 giây) và mô hình nặng 7,15 MB, lớn nhất trong tất cả các cấu hình đã thử. Vì vậy cấu hình được chọn để triển khai lên thiết bị biên là một *mô hình đơn* trên tập đặc trưng SHAP Top-30, không phải mô hình học tổ hợp.

Khi triển khai trên thiết bị biên Jetson Orin Nano Super, Random Forest với SHAP Top-30 đặc trưng đạt F1-Score 0,9955 ngoại tuyến (đã loại trừ rò rỉ), thông lượng 26,8 mẫu/giây, độ trễ p95 397 ms và sử dụng 27,5% RAM. Các số liệu này cho thấy việc triển khai hệ thống IDS dựa trên học máy trên thiết bị biên tài nguyên giới hạn là khả thi, và là cơ sở cho hướng giám sát an ninh mạng phân tán trong thực tế.

Chương 5. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

Trong chương này, luận văn sẽ trình bày những kết quả mà luận văn đã đạt được so với mục tiêu đặt ra ban đầu. Bên cạnh đó, luận văn cũng trình bày những hạn chế và đưa ra hướng phát triển trong tương lai của nghiên cứu.

5.1 Những đóng góp chính của luận văn

Sau khi thực hiện luận văn với đề tài “*Phát hiện xâm nhập (IDS) dựa trên Apache Spark cho bảo mật mạng IoT*”, luận văn đã đạt được một số kết quả chính tương ứng với các mục tiêu đề ra ban đầu:

- **Xây dựng nền tảng xử lý dữ liệu lớn:** Đề xuất và triển khai thành công hệ thống IDS trên nền tảng Apache Spark. Giải pháp này tận dụng khả năng tính toán song song để xử lý các luồng dữ liệu mạng từ môi trường IoT, hướng tới khả năng mở rộng trong việc giám sát bảo mật. Khả năng xử lý phân tán được kiểm chứng ở mức minh chứng khái niệm (proof-of-concept) trên cụm thiết bị biên.
- **Đánh giá học tổ hợp dựa trên bằng chứng thay vì kỳ vọng:** Xây dựng mô hình Hybrid Bagging Ensemble kết hợp Top-3 thuật toán có F1 cao nhất trên tập kiểm định (xác định ở chương thực nghiệm, không cố định trước), rồi so sánh trực tiếp với các mô hình đơn lẻ kèm kiểm định ý nghĩa thống kê. Dưới quy trình đánh giá loại trừ rò rỉ dữ liệu, học tổ hợp *không* mang lại lợi thế trên cấu hình tốt nhất: Hybrid Bagging đạt F1 0,9966 so với 0,9970 của XGB đơn lẻ, trong khi chi phí huấn luyện và dung lượng mô hình cao hơn nhiều lần. Đây là một kết quả âm tính nhưng có giá trị: trên bài toán nhị phân đã gần bão hòa, việc ghép mô hình không bù lại được chi phí, và mô hình đơn mới là lựa chọn phù hợp cho thiết bị biên.
- **Đánh giá trung thực, loại trừ rò rỉ dữ liệu:** Nhận diện và xử lý các nguồn rò rỉ thường gặp trên CICIDS2017 (đặc trưng `destination_port` rò rỉ nhãn và trùng lặp luồng ở mức đặc trưng), đồng thời định lượng mức thổi phồng hiệu năng do rò rỉ, nhờ đó kết quả phản ánh đúng hiệu năng thực của mô hình.
- **Tối ưu hóa và giải thích mô hình:** Ứng dụng kỹ thuật SHAP để lựa chọn các đặc trưng quan trọng nhất, giúp giảm số lượng đặc trưng (khoảng 60%) mà vẫn giữ nguyên hiệu năng phân loại: dưới cấu hình loại trừ rò rỉ dữ liệu, Random Forest với

SHAP Top-30 đạt F1 0,9955, tương đương cấu hình dùng toàn bộ đặc trưng (0,9949). Đồng thời, SHAP cung cấp giải thích chi tiết cho từng quyết định của mô hình, điều cần thiết khi vận hành trong trung tâm giám sát an ninh.

5.2 Hạn chế của đề tài

Mặc dù đã đạt được các kết quả nêu trên, luận văn vẫn còn một số hạn chế cần được khắc phục trong các giai đoạn tiếp theo:

- **Phạm vi phân loại:** Hệ thống chính được triển khai dựa trên bài toán phân loại nhị phân (Tấn công so với Bình thường). Luận văn đã bổ sung đánh giá đa lớp theo từng loại tấn công (Mục 4.2.10) để phân tích điểm yếu ở các lớp hiếm, nhưng việc xây dựng một bộ phân loại đa lớp hoàn chỉnh cho triển khai thời gian thực vẫn là hướng phát triển tiếp theo.
- **Phạm vi bộ dữ liệu:** Luận văn đã thiết lập quy trình đánh giá tổng quát hóa liên bộ dữ liệu (huấn luyện trên một bộ, kiểm tra trên bộ khác, Mục 4.2.9) trên cặp CICIDS2017 và CSE-CIC-IDS2018. Việc mở rộng sang nhiều bộ mới hơn (CIC-IoT, RoEduNet) để củng cố kết luận về tổng quát hóa vẫn là hướng tiếp theo. Ngoài ra, thí nghiệm này cho thấy bản thân F1 khác bộ là một đại lượng *không tất định* giữa các lượt chạy: do xác suất dự đoán của cụm luồng tấn công miền đích nằm sát ngưỡng quyết định 0,5, cùng một cấu hình và cùng một tệp dữ liệu cho hai chế độ kết quả rời nhau, F1 quanh 0,03–0,08 hoặc quanh 0,19–0,30 (Mục 4.2.9). Vì vậy kết quả khác bộ ở đây được báo cáo qua 12 lượt chạy kèm phân phối hai chế độ thay vì một lượt duy nhất, và lấy AUC-PR làm đại lượng so sánh chính. Mọi so sánh khác bộ về sau — kể cả khi so với công trình khác — cũng cần được lặp lại nhiều lượt mới có ý nghĩa, và hướng khắc phục căn bản là *hiệu chỉnh lại ngưỡng* trên miền đích thay vì giữ ngưỡng 0,5 học từ miền nguồn.
- **Quy mô dữ liệu và phần cứng biên:** Khía cạnh xử lý phân tán mới được kiểm chứng ở mức minh chứng khái niệm (proof-of-concept) trên cụm hai thiết bị Jetson (8 GB) với khối lượng dữ liệu cỡ vài triệu luồng của CICIDS2017, chứ chưa phải ở quy mô dữ liệu lớn thực thụ (terabyte trở lên) hay trên cụm tính toán nhiều nút mạnh. Việc đánh giá khả năng mở rộng ở quy mô lớn hơn vẫn là hướng tiếp theo.
- **Chưa đánh giá trước lưu lượng đối kháng:** Hệ thống chưa được kiểm thử trước các tấn công đối kháng/né tránh (adversarial/evasion) và giả định phân bố tấn công xấp

xỉ CICIDS2017. Do đó, độ bền vững trước kẻ tấn công cố ý đánh lừa mô hình vẫn là câu hỏi mở.

5.3 Hướng phát triển trong tương lai

Dựa trên những kết quả đã đạt được và các hạn chế đã nhận diện, luận văn đề xuất một số hướng phát triển trong tương lai, mỗi hướng tương ứng với một hạn chế đã nêu:

- **Cải thiện độ nhạy cho các lớp tấn công hiểm:** Phân tích hướng nhằm lẫn giữa các lớp (Mục 4.2.10) cho thấy các lớp hiểm suy giảm theo hai kiểu: nhầm loại trong cùng họ (XSS bị nhận thành Brute Force) và lọt hẳn thành Benign (SQL Injection, 54% Bot). Bốn hướng khắc phục tương ứng: (i) *xử lý mất cân bằng có chủ đích* ở pha huấn luyện đa lớp: undersampling lớp Benign, oversampling/SMOTE [72] cho lớp hiểm (áp dụng *sau* khi chia tập để tránh rò rỉ), hoặc gộp các biến thể cùng họ (gộp ba biến thể Web Attack thành một lớp) để đổi độ mịn định danh lấy recall; (ii) *điều chỉnh thuật toán*: trọng số lớp cho bài toán đa lớp, focal loss [73] với XGBoost, và hạ ngưỡng quyết định theo lớp (chấp nhận thêm false positive ở lớp hiểm vì với IDS, báo nhầm rẻ hơn bỏ sót); (iii) *kiến trúc phân tầng*: tận dụng chính thiết kế cổng hai tầng của đề tài: tầng nhị phân trên biên giữ recall tổng, còn bộ định danh loại huấn luyện *chỉ trên các luồng tấn công* (không phải cạnh tranh với 380 nghìn mẫu Benign) và có thể huấn luyện lại ngoại tuyến với cân bằng lớp mà không đung hệ thống đang chạy; (iv) *đặc trưng chuỗi thời gian theo host* (chu kỳ kết nối lặp, entropy kích thước gói qua cửa sổ trượt), nhằm trị đúng bệnh của hành vi beaconing C&C khiến 54% Bot lọt lưới, vốn không bộc lộ qua thống kê từng luồng độc lập.
- **Kiểm chứng trên bộ dữ liệu IoT chuyên biệt:** Đánh giá quy trình trên các bộ dữ liệu chứa lưu lượng IoT thực thụ (Bot-IoT, TON_IoT, CIC-IoT-2023) và mở rộng thí nghiệm liên bộ dữ liệu lên toàn bộ CSE-CIC-IDS2018, nhằm thu hẹp khoảng cách giữa phạm vi “IoT” của đề tài và dữ liệu CICIDS2017 hiện dùng.
- **Tối ưu suy luận biên bằng ONNX/TensorRT:** Tích hợp phiên suy luận ONNX vào pipeline streaming và tăng tốc bằng TensorRT trên GPU Jetson để giảm chi phí JVM/Spark ở pha suy luận (trong khi vẫn giữ Spark cho huấn luyện phân tán): kết quả đo ngoại tuyến ở Bảng 4.18 cho thấy cùng mô hình rừng ngẫu nhiên chạy qua ONNX Runtime đạt thông lượng gấp ≈ 348 lần bản PySpark đã triển khai, xác nhận

dữ liệu rất lớn của hướng này, đồng thời đo độ trễ đầu cuối đầy đủ (từ Kafka đến phân quyết rồi ghi cơ sở dữ liệu).


- **Độ bền vững trước tấn công đối kháng:** Đánh giá và gia cố hệ thống trước lưu lượng né tránh (adversarial/evasion), đặc biệt là hai bề mặt tấn công mới do cổng bất thường tạo ra: giả dạng lưu lượng bình thường để vượt cổng và cố ý tạo sai số tái tạo cao để dồn tải lên nút phân loại.

Phụ lục A. CÔNG TRÌNH KHOA HỌC ĐÃ CÔNG BỐ

Phần này liệt kê bài báo khoa học liên quan đến đề tài luận văn (viết chung với ThS. Nguyễn Vũ Thái, TS. Đỗ Trí Nhựt và TS. Nguyễn Văn Dũ), bài báo đã được chấp nhận đăng:

1. Thai Nguyen Vu, **Dung Van Bui**, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.

Hình A.1 là thư thông báo chấp nhận đăng bài của Ban tổ chức Hội nghị FAIR 2026.



Hình A.1. Thư thông báo chấp nhận đăng bài (paper #1571327230) của Ban tổ chức Hội nghị FAIR 2026

Bản PDF đầy đủ của bài báo được đính kèm ở cuối luận văn, sau phần Tài liệu tham khảo.

TÀI LIỆU THAM KHẢO

- [1] Ansam Khraisat, Iqbal Gondal, Peter Vamplew, và Joarder Kamruzzaman. “Survey of intrusion detection systems: techniques, datasets and challenges”. In: *Cybersecurity* 2.1 (2019), pp. 1–22.
- [2] Mohamed Amine Ferrag, Leandros Maglaras, Sotiris Moschoyiannis, và Helge Janicke. “Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study”. In: *Journal of Information Security and Applications* 50 (2020), p. 102419.
- [3] R. Vinayakumar, Mamoun Alazab, K. P. Soman, Prabakaran Poornachandran, Ameer Al-Nemrat, và Sitalakshmi Venkatraman. “Deep learning approach for intelligent intrusion detection system”. In: *IEEE Access* 7 (2019), pp. 41525–41550.
- [4] Amardeep Singh và Julian Jang-Jaccard. *Autoencoder-based Unsupervised Intrusion Detection using Multi-Scale Convolutional Recurrent Networks*. 2022. arXiv: [2204.03779](https://arxiv.org/abs/2204.03779) [cs.CR].
- [5] Pengfei Sun, Pengju Liu, Qi Li, Chenxi Liu, Xiangling Lu, Ruochen Hao, và Jinpeng Chen. “DL-IDS: Extracting features using CNN-LSTM hybrid network for intrusion detection system”. In: *Security and Communication Networks* 2020 (2020), p. 8890306. DOI: [10.1155/2020/8890306](https://doi.org/10.1155/2020/8890306).
- [6] N. Dash, S. Chakravarty, A. K. Rath, và các cộng sự. “An optimized LSTM-based deep learning model for anomaly network intrusion detection”. In: *Scientific Reports* 15 (2025), p. 1554. DOI: [10.1038/s41598-025-85248-z](https://doi.org/10.1038/s41598-025-85248-z).
- [7] Sukhvinder Singh Bamber, Aditya Vardhan Reddy Katkuri, Shubham Sharma, và Mohit Angurala. “A hybrid CNN-LSTM approach for intelligent cyber intrusion detection system”. In: *Computers & Security* 148 (2025), p. 104146. DOI: [10.1016/j.cose.2024.104146](https://doi.org/10.1016/j.cose.2024.104146).
- [8] Tasnimul Hasan, Abrar Hossain, Mufakir Qamar Ansari, và Talha Hussain Syed. *Enhanced Intrusion Detection in IIoT Networks: A Lightweight Approach with Autoencoder-Based Feature Learning*. 2025. arXiv: [2501.15266](https://arxiv.org/abs/2501.15266).
- [9] P. R. Chithra Rani và K. Baalaji. “Deep learning-based ensemble stacking for enhanced intrusion detection in IoT-edge platforms”. In: *Discover Applied Sciences* 7 (2025), p. 928. DOI: [10.1007/s42452-025-06871-z](https://doi.org/10.1007/s42452-025-06871-z).

- [10] Kushboo Nasir, Sahar K. Badri, Daniyal M. Alghazzawi, Mohammed Yahya Alghamdi, Mona Alkhozae, Abeer Almakky, Rania M. Alhazmi, và Muhammad Zubair Asghar. “HED-ID: an edge-deployable and explainable intrusion detection system optimized via metaheuristic learning”. In: *Scientific Reports* 16 (2026), p. 2313. DOI: [10.1038/s41598-025-32183-8](https://doi.org/10.1038/s41598-025-32183-8).
- [11] Jackson Diaz-Gorriñ, Candido Caballero-Gil, và Ljiljana Brankovic. “Enhancing Network Security with Generative AI on Jetson Orin Nano”. In: *Applied Sciences* 16.3 (2026), p. 1442. DOI: [10.3390/app16031442](https://doi.org/10.3390/app16031442).
- [12] Zhenxiong Zhang, Lei Zhang, Jialong Xu, Zhengze Chen, và Peng Wang. “An Edge-Deployable Lightweight Intrusion Detection System for Industrial Control”. In: *Electronics* 15.3 (2026), p. 644. DOI: [10.3390/electronics15030644](https://doi.org/10.3390/electronics15030644).
- [13] Laila Nassef, Mohammed Ibrahim Alghamdi, Slim Ben Chaabane, Qaisar Abbas, Wedad M. Alawad, Omar H. Albalawi, Osamah I. Alqaisi, và Bahjat Fakieh. “Lightweight and Energy-Aware Intrusion Detection for Industrial IoT Using TinyML and Edge AI”. In: *Scientific Reports* 16.1 (2026), p. 18524. DOI: [10.1038/s41598-026-50690-0](https://doi.org/10.1038/s41598-026-50690-0).
- [14] Kotyada Mohan Kiran Kumar, Mokshith Sreekar, Karthik Ullas, và M. Supriya. “Distributed Intrusion Detection System using Kafka and Spark Streaming”. In: *2025 International Conference on Visual Analytics and Data Visualization (ICVADV)*. IEEE, 2025, pp. 302–309. DOI: [10.1109/ICVADV63329.2025.10961691](https://doi.org/10.1109/ICVADV63329.2025.10961691).
- [15] İlhan Firat Kilincer, Fatih Ertam, và Abdulkadir Sengur. “Machine learning methods for cyber security intrusion detection: Datasets and comparative study”. In: *Computer Networks* 188 (2021), p. 107840. DOI: [10.1016/j.comnet.2021.107840](https://doi.org/10.1016/j.comnet.2021.107840).
- [16] M. Al Lail, A. Garcia, và S. Olivo. “Machine learning for network intrusion detection—A comparative study”. In: *Future Internet* 15.7 (2023), p. 243. DOI: [10.3390/fi15070243](https://doi.org/10.3390/fi15070243).
- [17] Yung-Chung Wang, Yi-Chun Houn, Han-Xuan Chen, và Shu-Ming Tseng. “Network Anomaly Intrusion Detection Based on Deep Learning Approach”. In: *Sensors* 23.4 (2023), p. 2171. DOI: [10.3390/s23042171](https://doi.org/10.3390/s23042171).

- [18] L. Yang, A. Moubayed, I. Hamieh, và A. Shami. “Tree-Based Intelligent Intrusion Detection System in Internet of Vehicles”. In: *2019 IEEE Global Communications Conference (GLOBECOM)*. 2019, pp. 1–6. DOI: [10.1109/GLOBECOM38437.2019.9013892](https://doi.org/10.1109/GLOBECOM38437.2019.9013892).
- [19] L. Yang, A. Moubayed, và A. Shami. “MTH-IDS: A Multi-Tiered Hybrid Intrusion Detection System for Internet of Vehicles”. In: *IEEE Internet of Things Journal* 9.1 (2022), pp. 616–632. DOI: [10.1109/JIOT.2021.3084796](https://doi.org/10.1109/JIOT.2021.3084796).
- [20] L. Yang, A. Shami, G. Stevens, và S. DeRusett. “LCCDE: A Decision-Based Ensemble Framework for Intrusion Detection in The Internet of Vehicles”. In: *2022 IEEE Global Communications Conference (GLOBECOM)*. 2022, pp. 1–6. DOI: [10.1109/GLOBECOM48099.2022.10001280](https://doi.org/10.1109/GLOBECOM48099.2022.10001280).
- [21] Jose Luis Hernandez-Ramos, Georgios Karopoulos, Efstratios Chatzoglou, Vasileios Kouliaridis, Enrique Marmol, Aurora Gonzalez-Vidal, và Georgios Kambourakis. “Intrusion Detection Based on Federated Learning: A Systematic Review”. In: *ACM Computing Surveys* 57.12 (2025), pp. 1–65. DOI: [10.1145/3731596](https://doi.org/10.1145/3731596).
- [22] R. Baidar, S. Maric, và R. Abbas. *Hybrid deep learning–federated learning powered intrusion detection system for IoT/5G advanced edge computing network*. <https://arxiv.org/abs/2509.15555>. arXiv:2509.15555. 2025.
- [23] B. Williams và L. Qian. “Semi-supervised learning for intrusion detection in large computer networks”. In: *Applied Sciences* 15.11 (2025), p. 5930. DOI: [10.3390/app15115930](https://doi.org/10.3390/app15115930).
- [24] N. Albanbay, Y. Tursynbek, K. Graffi, R. Uskenbayeva, Z. Kalpeyeva, Z. Abilkaiyr, và Y. Ayapov. “Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study”. In: *Journal of Sensor and Actuator Networks* 14.4 (2025), p. 78. DOI: [10.3390/jsan14040078](https://doi.org/10.3390/jsan14040078).
- [25] Thien Duc Nguyen, Samuel Marchal, Markus Miettinen, Hossein Fereidooni, N. Asokan, và Ahmad-Reza Sadeghi. “D²IoT: A Federated Self-learning Anomaly Detection System for IoT”. In: *2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS)*. 2019, pp. 756–767. DOI: [10.1109/ICDCS.2019.00080](https://doi.org/10.1109/ICDCS.2019.00080).

- [26] Lynda Boukela, Gongxuan Zhang, Méziane Yacoub, và các cộng sự. “A Near-Autonomous and Incremental Intrusion Detection System Through Active Learning of Known and Unknown Attacks”. In: *2021 International Conference on Security, Pattern Analysis, and Cybernetics (SPAC)*. 2021, pp. 374–379. DOI: [10.1109/SPAC53836.2021.9539947](https://doi.org/10.1109/SPAC53836.2021.9539947).
- [27] L. Atzori, A. Iera, và G. Morabito. “The Internet of Things: A survey”. In: *Computer Networks* 54.15 (2010), pp. 2787–2805. DOI: [10.1016/j.comnet.2010.05.010](https://doi.org/10.1016/j.comnet.2010.05.010).
- [28] Cisco. *Cisco Annual Internet Report (2018–2023) White Paper*. <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>. 2020.
- [29] R. Khan, S. U. Khan, R. Zaheer, và S. Khan. “Future Internet: The Internet of Things architecture, possible applications and key challenges”. In: *Proceedings of the 10th International Conference on Frontiers of Information Technology (FIT)*. 2012, pp. 257–260. DOI: [10.1109/FIT.2012.53](https://doi.org/10.1109/FIT.2012.53).
- [30] H. HaddadPajouh, A. Dehghantanha, R. M. Parizi, M. Aledhari, và H. Karimipour. “A survey on Internet of Things security: Requirements, challenges, and solutions”. In: *Internet of Things* 14 (2021), p. 100129. DOI: [10.1016/j.iot.2019.100129](https://doi.org/10.1016/j.iot.2019.100129).
- [31] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin, và K.-Y. Tung. “Intrusion detection system: A comprehensive review”. In: *Journal of Network and Computer Applications* 36.1 (2013), pp. 16–24. DOI: [10.1016/j.jnca.2012.09.004](https://doi.org/10.1016/j.jnca.2012.09.004).
- [32] Varun Chandola, Arindam Banerjee, và Vipin Kumar. “Anomaly detection: A survey”. In: *ACM Computing Surveys* 41.3 (2009), pp. 1–58. DOI: [10.1145/1541880.1541882](https://doi.org/10.1145/1541880.1541882).
- [33] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, và Klaus-Robert Müller. “A unifying review of deep and shallow anomaly detection”. In: *Proceedings of the IEEE* 109.5 (2021), pp. 756–795.

- [34] Manuel Lopez-Martin, Belen Carro, Antonio Sanchez-Esguevillas, và Jaime Lloret. “Conditional Variational Autoencoder for Prediction and Feature Recovery Applied to Intrusion Detection in IoT”. In: *Sensors* 17.9 (2017), p. 1967. DOI: [10.3390/s17091967](https://doi.org/10.3390/s17091967).
- [35] Khaled Alrawashdeh và Carla Purdy. “Toward an online anomaly intrusion detection system based on deep learning”. In: *Proc. 15th IEEE Int. Conf. on Machine Learning and Applications (ICMLA)*. 2016, pp. 195–200. DOI: [10.1109/ICMLA.2016.0040](https://doi.org/10.1109/ICMLA.2016.0040).
- [36] L. Husamaldin và N. Saeed. “Big Data Analytics Correlation Taxonomy”. In: *Information* 11.1 (2020), p. 17. DOI: [10.3390/info11010017](https://doi.org/10.3390/info11010017).
- [37] Matei Zaharia, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, Josh Rosen, Shivaram Venkataraman, Michael J. Franklin, Ali Ghodsi, Joseph Gonzalez, Scott Shenker, và Ion Stoica. “Apache Spark: A Unified Engine for Big Data Processing”. In: *Communications of the ACM* 59.11 (2016), pp. 56–65. DOI: [10.1145/2934664](https://doi.org/10.1145/2934664).
- [38] H. Karau, A. Konwinski, P. Wendell, và M. Zaharia. *Learning Spark: Lightning-fast big data analysis*. O’Reilly Media, 2015.
- [39] Xiangrui Meng, Joseph Bradley, Burak Yavuz, Evan Sparks, Shivaram Venkataraman, Davies Liu, Jeremy Freeman, DB Tsai, Manish Amde, Sean Owen, Doris Xin, Reynold Xin, Michael J. Franklin, Reza Zadeh, Matei Zaharia, và Ameet Talwalkar. “MLlib: Machine Learning in Apache Spark”. In: *Journal of Machine Learning Research* 17.34 (2016), pp. 1–7.
- [40] A. L. Buczak và E. Guven. “A survey of data mining and machine learning methods for cyber security intrusion detection”. In: *IEEE Communications Surveys & Tutorials* 18.2 (2016), pp. 1153–1176. DOI: [10.1109/COMST.2015.2494502](https://doi.org/10.1109/COMST.2015.2494502).
- [41] N. Koroniotis, N. Moustafa, E. Sitnikova, và B. Turnbull. “Towards the development of realistic botnet dataset in the Internet of Things for network forensic analytics: Bot-IoT dataset”. In: *Future Generation Computer Systems* 100 (2019), pp. 779–796. DOI: [10.1016/j.future.2019.05.041](https://doi.org/10.1016/j.future.2019.05.041).
- [42] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [43] Leo Breiman. “Random Forests”. In: *Machine Learning* 45.1 (2001), pp. 5–32.

- [44] D. R. Cox. “The regression analysis of binary sequences”. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 20.2 (1958), pp. 215–232.
- [45] Jerome H. Friedman. “Greedy function approximation: A gradient boosting machine”. In: *Annals of Statistics* 29.5 (2001), pp. 1189–1232.
- [46] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, và Tie-Yan Liu. “LightGBM: A highly efficient gradient boosting decision tree”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 3149–3157.
- [47] Andrew McCallum và Kamal Nigam. “A comparison of event models for naive Bayes text classification”. In: *AAAI Workshop on Learning for Text Categorization*. 1998.
- [48] Corinna Cortes và Vladimir Vapnik. “Support-vector networks”. In: *Machine learning* 20.3 (1995), pp. 273–297.
- [49] David E Rumelhart, Geoffrey E Hinton, và Ronald J Williams. “Learning representations by back-propagating errors”. In: *Nature* 323 (1986), pp. 533–536.
- [50] Tianqi Chen và Carlos Guestrin. “XGBoost: A scalable tree boosting system”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794.
- [51] Zhi-Hua Zhou. *Ensemble Methods: Foundations and Algorithms*. Chapman và Hall/CRC, 2012.
- [52] Patrik Goldschmidt và Daniela Chudá. “Network intrusion datasets: A survey, limitations, and recommendations”. In: *Computers & Security* 156 (2025), p. 104510. DOI: [10.1016/j.cose.2025.104510](https://doi.org/10.1016/j.cose.2025.104510).
- [53] Iman Sharafaldin, Arash Habibi Lashkari, và Ali A Ghorbani. “Toward generating a new intrusion detection dataset and intrusion traffic characterization”. In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*. 2018, pp. 108–116.
- [54] Canadian Institute for Cybersecurity and Communications Security Establishment. *CSE-CIC-IDS2018 dataset: A collaborative project between the Communications Security Establishment (CSE) and the Canadian Institute for Cybersecurity (CIC)*. <https://www.unb.ca/cic/datasets/ids-2018.html>. 2018.

- [55] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, và Konrad Rieck. “Dos and Don’ts of Machine Learning in Computer Security”. In: *31st USENIX Security Symposium (USENIX Security 22)*. 2022, pp. 3971–3988.
- [56] Maxime Lanvin, Pierre-François Gimenez, Yufei Han, Frédéric Majorczyk, Ludovic Mé, và Éric Totel. “Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes”. In: *Risks and Security of Internet and Systems (CRISIS 2022), Revised Selected Papers*. Springer, 2023, pp. 18–33. DOI: [10.1007/978-3-031-31108-6_2](https://doi.org/10.1007/978-3-031-31108-6_2).
- [57] Isabelle Guyon và André Elisseeff. “An introduction to variable and feature selection”. In: *Journal of Machine Learning Research* 3 (2003), pp. 1157–1182.
- [58] Ian T. Jolliffe. *Principal Component Analysis*. 2nd ed. Springer Series in Statistics. Springer, 2002. DOI: [10.1007/b98835](https://doi.org/10.1007/b98835).
- [59] Scott M. Lundberg và Su-In Lee. “A Unified Approach to Interpreting Model Predictions”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017, pp. 4765–4774.
- [60] Gints Engelen, Vera Rimmer, và Wouter Joosen. “Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study”. In: *2021 IEEE Security and Privacy Workshops (SPW)*. 2021, pp. 7–12. DOI: [10.1109/SPW53761.2021.00009](https://doi.org/10.1109/SPW53761.2021.00009).
- [61] Claude Nadeau và Yoshua Bengio. “Inference for the Generalization Error”. In: *Machine Learning* 52.3 (2003), pp. 239–281.
- [62] Donald J. Schuirmann. “A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability”. In: *Journal of Pharmacokinetics and Biopharmaceutics* 15.6 (1987), pp. 657–680. DOI: [10.1007/BF01068419](https://doi.org/10.1007/BF01068419).
- [63] Laurens D’hooge, Tim Wauters, Bruno Volckaert, và Filip De Turck. “Inter-dataset generalization strength of supervised machine learning methods for intrusion detection”. In: *Journal of Information Security and Applications* 54 (2020), p. 102564.
- [64] Marco Cantone, Claudio Marrocco, và Alessandro Bria. “Machine Learning in Network Intrusion Detection: A Cross-Dataset Generalization Study”. In: *IEEE Access* 12 (2024), pp. 144489–144508. DOI: [10.1109/ACCESS.2024.3472907](https://doi.org/10.1109/ACCESS.2024.3472907).

- [65] Mohanad Sarhan, Siamak Layeghy, và Marius Portmann. “Evaluating standard feature sets towards increased generalisability and explainability of ML-based network intrusion detection”. In: *Big Data Research* 30 (2022), p. 100359. DOI: [10.1016/j.bdr.2022.100359](https://doi.org/10.1016/j.bdr.2022.100359).
- [66] Baochen Sun, Jiashi Feng, và Kate Saenko. “Return of Frustratingly Easy Domain Adaptation”. In: *Proceedings of the 30th AAAI Conference on Artificial Intelligence (AAAI)*. 2016. DOI: [10.1609/aaai.v30i1.10306](https://doi.org/10.1609/aaai.v30i1.10306).
- [67] NVIDIA Corporation. *Jetson Orin Nano Super Developer Kit*. <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-orin/nano-super-developer-kit/>. 2024.
- [68] Weisong Shi, Jie Cao, Quan Zhang, Youhuizi Li, và Lanyu Xu. “Edge computing: Vision and challenges”. In: *IEEE Internet of Things Journal* 3.5 (2016), pp. 637–646. DOI: [10.1109/JIOT.2016.2579198](https://doi.org/10.1109/JIOT.2016.2579198).
- [69] Salam Hamdan, Moussa Ayyash, và Sufyan Almajali. “Edge-Computing Architectures for Internet of Things Applications: A Survey”. In: *Sensors* 20.22 (2020), p. 6441. DOI: [10.3390/s20226441](https://doi.org/10.3390/s20226441).
- [70] Alessandro Sforzin, Félix Gómez Mármol, Mauro Conti, và Jens-Matthias Bohli. “RPIIDS: Raspberry Pi IDS — A Fruitful Intrusion Detection System for IoT”. In: *Proc. Int. IEEE Conf. on Ubiquitous Intelligence & Computing (UIC/ATC/ScalCom)*. 2016, pp. 440–448. DOI: [10.1109/UIC-ATC-ScalCom-CBDCom-IoP-SmartWorld.2016.0080](https://doi.org/10.1109/UIC-ATC-ScalCom-CBDCom-IoP-SmartWorld.2016.0080).
- [71] Jay Kreps, Neha Narkhede, và Jun Rao. “Kafka: a Distributed Messaging System for Log Processing”. In: *Proceedings of the NetDB Workshop*. 2011.
- [72] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, và W. Philip Kegelmeyer. “SMOTE: Synthetic Minority Over-sampling Technique”. In: *Journal of Artificial Intelligence Research* 16 (2002), pp. 321–357.
- [73] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, và Piotr Dollár. “Focal Loss for Dense Object Detection”. In: *2017 IEEE International Conference on Computer Vision (ICCV)*. 2017, pp. 2999–3007. DOI: [10.1109/ICCV.2017.324](https://doi.org/10.1109/ICCV.2017.324).

A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline

Thai Nguyen Vu	Dung Van Bui	Nhut Tri Do	Van Du Nguyen
<i>Campus in Ho Chi Minh City, University of Transport and Communications, Ho Chi Minh City, Vietnam</i>	<i>University of Information Technology VNU-HCM, Ho Chi Minh City, Vietnam</i>	<i>University of Information Technology VNU-HCM, Ho Chi Minh City, Vietnam</i>	<i>Faculty of Information Technology Nong Lam University, Ho Chi Minh City, Vietnam</i>
thaivn_ph@utc.edu.vn	dungbv.17@grad.uit.edu.vn	trinhutdo@uit.edu.vn	nvdu@hcmuaf.edu.vn

Abstract—Machine-learning-based network intrusion detection systems (IDS) typically process hundreds of network-flow features, which is computationally expensive and hard to deploy at the edge. This paper presents a systematic comparative study of four dimensionality-reduction strategies on Apache Spark ML: a baseline using all features, selection by Random Forest Importance, selection by SHAP, and PCA. Each strategy is evaluated across eight classification algorithms together with two ensemble methods on the CICIDS2017 dataset. Unlike most prior work, our emphasis falls on the rigor of the evaluation pipeline: (i) we remove the label-leaking feature `destination_port` and deduplicate flows at the feature level before splitting the data; (ii) we fix the comparison configuration *a priori* to avoid selection bias; (iii) we select models on a validation set held out from the training set, together with an in-distribution stability check and a cross-dataset generalization evaluation (between CICIDS2017 and CSE-CIC-IDS2018); (iv) we assess statistical significance using a paired permutation test over multiple resampled training/test splits, together with Nadeau–Bengio corrected confidence intervals and effect sizes; and (v) we add a per-attack-type multiclass evaluation. We ask whether feature selection retains most of the classification performance while cutting the number of features by about 60%, and whether SHAP Top-30 balances accuracy, explainability, and cost well enough to be exported to the Jetson Orin Nano Super edge device (deployed in a companion systems paper); the experimental section reports the quantitative results.

Index Terms—Intrusion detection, Apache Spark, Feature selection, SHAP, Data leakage

I. INTRODUCTION

Cyberattacks are growing in scale and sophistication, demanding IDS that are both accurate and scalable on large data [1], [2]. Machine learning has become the dominant approach for anomaly-based IDS, but modern network-flow datasets such as CICIDS2017 [3] provide nearly 80 features per flow, which increases training, inference, and memory cost; that cost is hardest to absorb on an edge device. However, different strategies such as embedded, unsupervised, or explanation-based ones measure “importance” in non-equivalent ways, and they are rarely compared under the same distributed pipeline.

A second issue, discussed less often but no less serious, is whether the evaluation pipeline can be trusted. Many reports on CICIDS2017 achieve near-perfect binary F1; this is usually a sign of data leakage rather than of model capability. *Data leakage* is information unavailable at deployment time entering training or evaluation, inflating scores so they no longer reflect generalization. Labeling errors and duplicate flows in CICIDS2017 are documented and substantially affect evaluation [4]. There are two common sources of leakage. First, `destination_port` encodes the attacked service, since CICIDS2017 aims its attacks at fixed ports, giving the model a port-to-label shortcut. Second, feature-level duplicate flows are not removed by full-duplicate removal, so a random split places the same sample into both the training and test sets. This paper handles both before comparing methods.

Main contributions. (1) A uniform comparison of RF Importance, SHAP, and PCA over the same eight

Spark ML algorithms and two ensembles; (2) Integration of SHAP-based explanation [5] with a direct contrast against RF Importance [6]; (3) A leakage-aware and statistically tested evaluation pipeline: removing the leaking feature, deterministic feature-level deduplication (label-conflicting groups are removed entirely), model selection on a validation set held out from the training set, and a paired permutation test (exact enumeration) over multiple resamplings with Nadeau–Bengio correction and effect size; (4) A per-attack-type multiclass evaluation, clarifying where the methods truly differ; (5) An edge-aware model-selection recommendation: jointly considering F1, the number of features, and model size for the Jetson Orin Nano Super.

II. RELATED WORK

IDS surveys [1], [2], [7] show that both traditional machine learning and deep learning are widely applied on standard benchmarks such as CICIDS2017 [3]. Many works focus on a single algorithm, for instance online deep learning [8] or deep networks [9], without a uniform comparison of multiple dimensionality-reduction strategies on the same distributed pipeline. Apache Spark ML [10], [11] supports large-scale processing, but few studies combine feature selection, model explanation, and statistical testing in a single unified experimental framework. Recent edge IDS studies target resource-constrained platforms, for instance ensemble stacking deployed on an NVIDIA Jetson Nano GPU [12] and a metaheuristic-optimized, SHAP-explained detector evaluated under edge-like resource budgets [13].

Feature selection. Variable-selection theory [14] distinguishes three groups: filter, wrapper, and embedded. Random Forest Importance [6] (embedded) and PCA [15] (unsupervised) are two popular directions for IDS but measure different quantities. SHAP [5] provides consistent local explanations and has been used for IDS [16], but is rarely contrasted directly with RF Importance on the same Spark training set.

Concept drift, anomaly, and evaluation. Concept drift [17] affects IDS stability over time; anomaly-detection surveys [18], [19] systematize unsupervised detectors that are trained on normal data alone, and such detectors, autoencoders in particular, are used both as a pre-filter ahead of a supervised classifier and to reduce feature dimensionality for IDS on edge devices [20], [21]. However, data leakage (“data snooping”) and statistical-significance testing (identified as among the most common pitfalls of ML in security [22]) are rarely




Figure 1. Leakage-aware evaluation pipeline: from raw CICIDS2017 flows to the statistically validated, edge-ready model.

handled explicitly on CICIDS2017; we handle both here. Table I summarizes the comparison.

III. METHOD

A. Overview of the Spark ML pipeline

The offline pipeline consists of sequential steps: data cleaning, deduplication, VectorAssembler, StandardScaler, an (optional) dimensionality-reduction transform, and then the classifier. Binary labels: Benign (0) and Attack (1). The fit of StandardScaler/PCA and the feature ranking use the training set alone; the test set serves as the final holdout.

B. Leakage-aware data preparation

We merge the eight CICIDS2017 CSV files, normalize column names, replace infinite/missing values, and then apply two leakage-removal steps *before* splitting the data:

- **Removing the label-leaking feature.** `destination_port` (and `source_port` if present) is removed because it directly encodes the target service of the attack; keeping it would let the model memorize the port-to-label mapping instead of learning flow behavior. An ablation (keep vs. remove the port) quantifies the impact.
- **Feature-level deduplication (deterministic).** Beyond removing fully duplicate records, we remove flows that are identical across all feature columns before splitting, preventing the same sample from appearing in both the training and test sets. For groups of flows that are feature-identical but have conflicting labels (Benign and Attack, a known error in CICIDS2017 [4]), the entire group is removed rather than arbitrarily keeping one row depending on data partitioning; the numbers of removed groups

Table I
CAPABILITY COMPARISON WITH RELATED IDS STUDIES ON CICIDS2017 AND SPARK/EDGE (“—”: NOT ADDRESSED OR NOT REPORTED).

Reference	Dataset	Feature reduction / explainability	Leakage-aware	Statistical testing	Cross-dataset	Multi-class
Khraisat et al. [2]	Multiple (survey)	General	—	—	—	—
Vinayakumar et al. [9]	CICIDS2017	None	—	—	—	Yes
Ferrag et al. [7]	Multiple	None	—	—	—	Yes
Alrawashdeh & Purdy [8]	NSL-KDD	None	—	—	—	—
Sarhan et al. [16]	NetFlow (NF-*)	SHAP	—	—	Yes	—
Chithra Rani et al. [12]	Multiple (IoT-edge)	None	—	—	—	Yes
Nasir et al. [13]	Multiple	GWO + SHAP	—	—	—	—
Hasan et al. [21]	IIoT	Autoencoder	—	—	—	—
The proposed method	CICIDS2017, CSE-CIC-IDS2018	RF/SHAP/PCA	Yes	Yes	Yes	Yes

Algorithm 1 Leakage-aware preparation of CICIDS2017

Input: CSV files $\{F_1, \dots, F_N\}$; split ratio $\alpha=0.8$
Output: $D_{\text{train}}, D_{\text{test}}$ (Parquet)

- 1: $D \leftarrow \bigcup_i F_i$ ▷ normalize names; $\pm\infty \rightarrow \text{NaN}$
- 2: $D \leftarrow \text{DROPDUPLICATES}(D)$; $D \leftarrow \text{DROPNAN}(D)$
- 3: $y_i \leftarrow 0$ if $\text{UPPER}(\text{label}_i) = \text{BENIGN}$ else 1
- 4: $\mathcal{F} \leftarrow \text{numeric columns} \setminus \{\text{destination_port}, \text{source_port}, \text{protocol}, \text{identifiers}\}$
- 5: **for all** groups g of rows identical on all of $\mathcal{F}$ **do**
- 6: **if** labels within g conflict (Benign and Attack) **then**
- 7: drop g entirely ▷ contradictory ground truth; logged
- 8: **else** keep one deterministic representative of g
- 9: split $D \rightarrow D_{\text{train}}/D_{\text{test}}$ (α , fixed seed); write Parquet

and rows are reported (270 groups, 44,260 rows), so the deduplication result is deterministic and reproducible.

Algorithm 1 summarizes the procedure, and Figure 1 places it in the full evaluation pipeline. After processing, the data are split into **80% training / 20% test** (with a fixed seed), stored in Parquet format, and reused throughout the experiments. The number of remaining numeric features is 77, and the number of samples after deduplication is 1,785,349/447,275 (2,232,624 total after feature-level dedup).

C. Classifiers and the four dimensionality-reduction strategies

Eight algorithms: Decision Tree, Logistic Regression, SVM (LinearSVC), Naive Bayes, Random Forest, GBT, XGBoost, MLP; together with two ensembles (weighted Hybrid Bagging Top-3 and Soft Voting). LightGBM is excluded because its native library (via SynapseML) supports only x86_64 and cannot run on the Jetson Orin Nano Super edge device (ARM64), the deployment target of this study. Within the gradient-boosting family, XGBoost and GBT act as representatives. The four strategies: **Baseline** (all features); **RF Top- K** ($K \in \{20, 30, 40\}$); **SHAP Top- K** ; **PCA** ($k \in \{20, 30, 40\}$). The RF and SHAP rankings use the training set alone;

SHAP is computed on a class-stratified sample so that both benign and attack traffic are represented. PCA is fixed at $k=40$, more than the Top-30 of the selection methods, because PCA extracts rather than selects: each principal component is a linear combination carrying only part of the variance, so more components are needed to retain an equivalent amount of variance. Within the range $\{20, 30, 40\}$, $k=40$ retains the most variance and is therefore the fairest representative point for PCA.

D. Hyperparameters and class-imbalance handling

The hyperparameters (Table II) are fixed a priori and shared across all dimensionality-reduction methods, so that the observed differences reflect the feature-selection method rather than per-model tuning; hyperparameter tuning is separated into a distinct stage (grid search with cross-validation) and applied only to the selected configuration. The stochastic models (RF, GBT, XGBoost, MLP) fix the seed for reproducibility. Class imbalance is handled the same way throughout. Every model that supports per-sample weighting, namely Decision Tree, Logistic Regression, SVM, Naive Bayes, Random Forest, and GBT, is assigned class weights according to the benign/attack ratio, equivalent to XGBoost’s `scale_pos_weight` mechanism. MLP alone does not support sample weights in Spark ML and is therefore trained without weights, as noted in the limitations.

E. Two-stage comparison design

To avoid selection bias from trying many configurations on the same test set, we separate the *exploration stage* (sweeping K , fully reported per K) from the *confirmation stage* (four configurations fixed a priori: Baseline, RF Top-30, SHAP Top-30, PCA $k=40$), on which the comparative conclusions rest; no configuration is chosen for its test F1. Within each configuration,

Table II
MAIN HYPERPARAMETERS OF THE EIGHT CLASSIFIERS (FIXED A PRIORI).

Model	Main hyperparameters
Decision Tree	maxDepth=15, minInstancesPerNode=5, impurity=entropy
Logistic Regression	maxIter=200, regParam=0.001, L2, threshold=0.5
SVM (LinearSVC)	maxIter=200, regParam=0.001
Naive Bayes	gaussian, smoothing=1.0
Random Forest	numTrees=200, maxDepth=15, featureSubset=sqrt
GBT	maxIter=150, maxDepth=6, stepSize=0.05, subsample=0.8
XGBoost	n_estimators=300, max_depth=8, lr=0.05, subsample=0.8, colsample=0.8
MLP	layers=[d,64,32,2], maxIter=150, stepSize=0.01
Class balancing: per-sample class weights (6 models) / positive-class weight scaling (XGBoost); MLP unweighted.	

the representative model and the tested method pair are chosen by F1 on a validation set (20% held out from the training set, fixed seed), so the test set never participates in selection.

F. Rigorous evaluation pipeline

Metrics. Accuracy, Precision, Recall, F1, AUC-ROC, AUC-PR; training/prediction time; model size. Because the data are imbalanced, AUC-PR and attack-class recall are prioritized over accuracy.

In-distribution stability check. Each method’s representative model is re-evaluated on a test subset; distribution shift itself is assessed by the cross-dataset experiment (Section IV).

Statistical-significance testing. The two top methods are trained on N independent resamplings of the training/test split (default $N=6$), and in each round both use the same split so that the comparison is paired. As a result, the variance reflects the effect of data sampling rather than only of model initialization. The 95% confidence interval is computed using the t distribution ($t_{0.975, N-1}$, not the value 1.96); because the resamplings overlap in training data, we report alongside it the Nadeau–Bengio [23] corrected confidence interval, with the variance multiplied by $(1/N + n_{\text{test}}/n_{\text{train}})$, and take the corrected interval as the basis for conclusions. Significance is tested by a two-sided paired permutation test on the per-round F1 difference, enumerating all 2^N sign patterns exactly rather than sampling them; its floor is $p = 2/2^N$, so $N \geq 6$ is needed to reach below 0.05 at all. We report the paired Cohen’s d alongside p , and test equivalence directly with a TOST, since a non-significant p is by itself weak evidence for it.

Multiclass evaluation. Because binary classification on CICIDS2017 is almost perfectly separable, we add a per-attack-type multiclass evaluation, comprising per-class precision/recall/F1, macro-F1, and a confusion

matrix. The rare classes, Heartbleed, Infiltration, Web Attack, and Bot, are where the methods actually differ.

IV. EXPERIMENTS AND RESULTS

A. Setup

CICIDS2017; an 80/20 training/test split after leakage removal (Section III-B); Apache Spark 3.4.1, Java 17; hardware: a cluster of $2 \times$ Jetson Orin Nano Super (8 GB) and a coordinator host. The host acts as Spark *master* only and runs no executor, so every training time reported here reflects compute on the two homogeneous Jetson workers rather than the stronger host CPU. Every script logs the run configuration (seed, environment variables, library versions) to ensure reproducibility. The full source code, configuration, and feature lists are publicly available at https://github.com/vuthainguyen1602/Thesis_IDS (branch `develop`); the pipeline can be reproduced on a single machine and does not require an edge-device cluster.

B. Port-feature ablation

Table III quantifies the impact of `destination_port`, using a Random Forest fixed a priori per the Table II configuration (class-weighted; binary task). After feature-level deduplication, the port’s isolated effect is small: binary F1 is 0.9965 with the port and 0.9955 without it (a ≈ 0.001 gap; recall 0.9988 vs. 0.9961, AUC-PR 0.9999 vs. 0.9997): the in-domain binary task is near saturation and the dominant leakage source (duplicate flows) is already handled; the direction (keeping the port yields slightly higher F1/recall) is nonetheless consistent with leakage. All subsequent results use the port-removed configuration.

That ≈ 0.001 gap belongs to the tree family, not to the dataset: across all eight classifiers (Table III) the inflation spans $+0.0007$ (XGBoost) to $+0.0415$ (SVM), because the linear models lean on the port as a service identifier

where the tree ensembles recover the same boundary from behavioural statistics. An ablation on one model does not bound the leak for another model class.

Table III
F1 INFLATION FROM DESTINATION_PORT PER CLASSIFIER; BOTH ARMS
TRAINED ON THE SAME SPLIT (BINARY TASK).

Model	F1 (no port)	F1 (port)	Δ F1
SVM (LinearSVC)	0.7859	0.8274	+0.0415
Logistic Regression	0.7986	0.8381	+0.0395
Naive Bayes	0.2985	0.3093	+0.0108
MLP	0.9660	0.9711	+0.0052
GBT	0.9924	0.9941	+0.0017
Decision Tree	0.9953	0.9966	+0.0014
Random Forest	0.9954	0.9964	+0.0010
XGBoost	0.9972	0.9979	+0.0007

C. Comparison of the four dimensionality-reduction methods

Table IV summarizes the best model per method, and Figure 2 visualizes F1 for each method $\times$ algorithm pair. The comparison design aims to verify whether feature selection (RF/SHAP Top-30) retains near-baseline performance while cutting $\approx 60\%$ of the features; PCA $k=40$ reduces dimensionality in an unsupervised manner at the cost of explainability. All quantitative values are taken directly from the released pipeline outputs.

D. Statistical testing (paired resampling)

Table V reports the mean F1 $\pm$ 95% CI (t distribution) over $N=6$ resamplings for the two top methods, together with the paired permutation-test p -value. The two methods differ significantly only at the floor of the test’s resolution ($p \approx 0.031$, Cohen’s $d \approx 1.94$), yet the absolute F1 gap is about 0.0001. A significance test cannot establish equivalence, so we add two one-sided tests (TOST [24]) against a 0.001 F1 margin fixed in advance, on the Nadeau–Bengio error: $p_{\text{TOST}} = 3.9 \times 10^{-6}$, the tightest margin these six splits support at $\alpha = 0.05$ being $\pm 2.3 \times 10^{-4}$ F1 — equivalence in the positive sense, not mere indistinguishability.

E. Robustness and multiclass evaluation

In the in-distribution stability check (a subset of the test set), the ranking of the methods is preserved (XGBoost leads in all four methods). The multiclass evaluation (Figure 4, Table VI) shows a wide gap between weighted-F1 (≈ 0.998) and macro-F1 (≈ 0.806): the rare classes carry the loss. Reading the confusion matrix by where the errors land separates two failure modes. XSS

is mostly mislabeled but still detected: 81/111 samples are predicted as Web Brute Force, so at the binary (deployment) level 76% of XSS flows are still flagged as attacks. The damaging mode is leakage into Benign: all 6 SQL Injection samples, 54% of Bot (158/290), and 27% of Web Brute Force are predicted benign. Three mechanisms drive this: extreme imbalance (6–311 samples vs. 380k benign); removing `destination_port` hits web attacks hardest, since without the port-80 shortcut their short HTTP flows resemble ordinary browsing, so the 0.027 recall here replaces a leakage-inflated one; and Bot C&C beaconing resembles background traffic once service identity is gone.

F. Cross-dataset generalization

To go beyond *in-domain* evaluation, we train on one dataset and test on the other (cross-dataset evaluation, run in both directions) on the leakage-free feature set shared by the two datasets. Because CSE-CIC-IDS2018 [25] is very large ($\sim 16\text{M}$ flows) we use a label-stratified sample (fraction 0.2, fixed seed): $\sim 3.14\text{M}$ flows, $\sim 2.39\text{M}$ after feature-level deduplication, against $\sim 2.23\text{M}$ for CICIDS2017.

The contrast is the sharpest result in the paper: in-domain F1 is high and stable in both directions (0.9952 and 0.9246, CV $< 0.1\%$), yet cross-dataset performance collapses — most clearly in the threshold-free AUC-PR, 0.9997 to 0.4862 and 0.9676 to 0.2072. Cross-dataset F1 averages 0.1321 and 0.0539 at very low recall (0.075 and 0.030) but still-usable precision (0.764 and 0.270): the model misses the other testbed’s attacks rather than alarming indiscriminately. For 2017 $\rightarrow$ 2018 that F1 is not even single-valued: the 12 runs split into two disjoint regimes, seven at 0.029–0.084 and five at 0.185–0.301, nothing in between, so the mean falls in the empty gap. Of five seeds run twice, three stayed in their regime (within 0.007) and two switched (0.0495 $\rightarrow$ 0.1854, 0.0843 $\rightarrow$ 0.2606): the regime is settled by the distributed fit, not the seed. AUC-PR is the same in both (0.459–0.516 against 0.453–0.536), so the ranking never changes, only where the 0.5 threshold falls against a cluster of near-identical target flows that crosses it as a block. A single-run cross-dataset F1 thus reports which regime the run landed in, so we report the distribution and compare on AUC-PR. The causes are concrete: a different CICFlowMeter version (changed feature scales), a different network configuration, and non-overlapping attack tooling (HOIC/LOIC-HTTP exist only in 2018). Is it merely a scale mismatch? Two classic unsupervised adaptations — refitting the scaler on the




Figure 2. F1 heatmap by method and algorithm (binary, port removed).

Table IV
SUMMARY OF THE BEST MODEL PER METHOD (VALUES FROM THE RELEASED EXPERIMENT OUTPUTS).

Method	Model	F1	AUC-PR	Train (s)	Size (MB)
Baseline	XGBoost	0.9971	0.9999	4615.5	2.32
RF Top-30	XGBoost	0.9922	0.9998	1295.1	2.52
SHAP Top-30	XGBoost	0.9970	0.9999	1226.1	0.003 [†]
PCA $k=40$	XGBoost	0.9939	0.9998	1444.8	3.82

[†]Sizes are obtained by serializing each fitted model *on the training cluster*; the distributed model-saving step writes the tree-ensemble data partitions on whichever executor holds them, so entries in the KB range (here 0.003 MB) capture only the driver-local metadata and *under-report* the true size. Since the size of a tree ensemble is governed by the number of trees and nodes rather than by the number of input features, the SHAP Top-30 XGBoost model is in reality comparable to its RF Top-30 counterpart (≈ 2.5 MB). For the same reason, a reduced feature set can even yield a slightly *larger* model than the baseline (2.52 vs. 2.32 MB); with fewer split candidates the trees need more nodes to reach comparable purity. The single-node export of the deployed pipeline measures model sizes reliably.




Figure 3. Training and inference time of each method’s representative model on the training Spark cluster (Section IV).

Table V
MULTI-RESAMPLING STABILITY AND PAIRED TESTING (VALUES FROM THE RELEASED EXPERIMENT OUTPUTS).

Method	Model	F1 (mean $\pm$ CI95)	p (paired)
Baseline	XGBoost	0.99734 $\pm$ 0.00007	0.031
SHAP Top-30	XGBoost	0.99720 $\pm$ 0.00009	

target, and CORAL [26], both without target labels or retraining — recover no F1 (0.000 either direction, from a low-regime run), so the shift sits in the conditional distribution, not the first two moments. CORAL does lift AUC-PR for 2018 $\rightarrow$ 2017 (0.199 to 0.258) with F1 still zero: the ranking improves, the source-fitted 0.5

Table VI
PER-CLASS PRECISION/RECALL/F1 (FROM THE RELEASED EXPERIMENT OUTPUTS).

Class	Support	Precision	Recall	F1
Benign	380,119	0.9981	0.9997	0.9989
DoS Hulk	34,446	0.9990	0.9904	0.9947
PortScan	383	1.0000	0.9530	0.9759
Web Attack – Brute Force	311	0.7346	0.7299	0.7323
Bot	290	1.0000	0.4552	0.6256
Web Attack – XSS	111	1.0000	0.0270	0.0526
Infiltration	12	1.0000	0.6667	0.8000
Web Attack – SQL Injection	6	0.0000	0.0000	0.0000
7 remaining classes, all F1 $\geq$ 0.95; see released outputs				
macro-F1 = 0.806		weighted-F1 = 0.998		

Table VII
CROSS-DATASET GENERALIZATION (2017 = CICIDS2017, 2018 = CSE-CIC-IDS2018): MEAN OF 12 RUNS DIFFERING ONLY IN THE FOREST SEED; 95% INTERVAL ON CROSS-DATASET F1.

Train $\rightarrow$ Test	F1	AUC-PR
2017 $\rightarrow$ 2017 (in-domain)	0.9952	0.9997
2017 $\rightarrow$ 2018 (cross)	0.1321 $\pm$ 0.0715	0.4862
2018 $\rightarrow$ 2018 (in-domain)	0.9246	0.9676
2018 $\rightarrow$ 2017 (cross)	0.0539 $\pm$ 0.0022	0.2072




Figure 4. Multiclass confusion matrix (row-normalized).

threshold does not survive, and adaptation here has to recalibrate the threshold as well as the features. Labelling a little of the new network works immediately: retraining on 1% of the target’s training split (19k flows) reaches F1 0.92 and 0.99, and pooling them with the 1.79M source flows is worse (0.80, 0.96) than dropping the source data. This collapse is consistent with prior cross-dataset IDS studies [27], [28] and reinforces the central claim of this paper: near-perfect in-domain scores (even leakage-free ones) do not certify deployability under distribution shift, so cross-dataset evaluation must be a mandatory part of IDS validation, and domain adaptation is a prerequisite for practical transfer.

V. DISCUSSION

Method comparison. Baseline and SHAP Top-30 are equivalent within $\pm 2.3 \times 10^{-4}$ F1 (Table V), so secondary criteria — explainability, size, stability, feature count — decide the deployment choice. RF Top-30 trails SHAP Top-30 by ≈ 0.005 F1 at the same feature count, and SHAP Top-30 also yields consistent local explanations for SOC operations.

Bridge to the edge device. Cutting $\approx 60\%$ of the features reduces vector-assembly cost and model footprint on the Jetson Orin Nano Super, so the selection criterion has to weigh feature count, model size and training/prediction time (Figure 3) alongside F1. Latency and throughput on the Jetson appear in a companion systems paper.

Limitations of the binary evaluation. Removing the port and deduplicating brings binary F1 down to a realistic level, but binary classification remains a relatively easy task. Only under multiclass evaluation do the weaknesses on rare attack classes emerge, and this is also a more reliable metric for distinguishing methods.

VI. THREATS TO VALIDITY

Internal validity. The RF/SHAP rankings are derived from the original training set and kept fixed across resamplings, which follows the “a priori configuration” design but lets the ranking see flows that a later resampling puts in its test split. Re-ranking SHAP inside a resampling is expensive, so we did it for two of the six: F1 moved by at most 7.4×10^{-5} , in opposite directions, and 25–26 of the 30 features were reselected. The fixed ranking is not inflating F1. The Top-3 component models of the ensemble are selected on that same held-out validation set, at the cost of training the base models on less data. Class balancing applies to all models except MLP (Spark ML offers no sample weights for it), so the MLP result carries that caveat.

External validity. CICIDS2017 (2017) may not reflect current traffic, and benchmark NIDS datasets carry documented quality limitations [29]; verification on newer datasets (CSE-CIC-IDS2018, CIC-IoT) is needed. The default random split shuffles time; a time-based split is also supported. The cross-dataset conclusion (Section IV-F) rests on a stratified sample of CSE-CIC-IDS2018, not the whole set. The model assumes an attack distribution approximating CICIDS2017 and has not been tested against deliberately evasive traffic, and feature-level deduplication itself shifts the benign/attack ratio.

Statistical validity. Cross-dataset F1 is not deterministic across runs and is bimodal (Section IV-F), so it is reported over $n=12$ runs and each adaptation figure is compared within its own run. The small sample size ($N=6$) gives the equivalence test low power: because the permutation test is two-sided, the smallest attainable p is only $2/2^N$, so $N=6$ just barely reaches the 0.05 threshold and can hardly detect small effects. The equivalence claim does not rest on that p -value, however: the TOST of Section III-F tests it directly, against the same Nadeau–Bengio error that accounts for the overlap between resamplings. Increasing N by nested cross-validation is the next step.

VII. CONCLUSION

This paper compares four dimensionality-reduction strategies for IDS on Spark ML under a leakage-aware and statistically tested evaluation pipeline. The contribution lies as much in how to evaluate reliably as in which method wins: removing the leaking feature, deterministic feature-level deduplication, model selection on a validation set, exact-enumeration paired testing with Nadeau–Bengio correction, multiclass evaluation,

and cross-dataset generalization between CICIDS2017 and CSE-CIC-IDS2018 (Section IV-F). Future directions: an ablation of the deduplication step itself, the second leakage source; the full CSE-CIC-IDS2018 and newer datasets (RoEduNet, CIC-IoT); transferability of the SHAP Top-30 set between datasets; and real-time edge deployment.

ACKNOWLEDGMENT

The authors declare no conflict of interest.
Opt plus .5pt Opt

REFERENCES

- [1] M. Ring, S. Wunderlich, D. Grödl, D. Landes, and A. Hotho, "A survey of network-based intrusion detection data sets," *Computers & Security*, vol. 86, pp. 147–167, 2019.
- [2] A. Khraisat, I. Gondal, P. Vamplew, and J. Kamruzzaman, "Survey of intrusion detection systems: techniques, datasets and challenges," *Cybersecurity*, vol. 2, no. 1, pp. 1–22, 2019.
- [3] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward generating a new intrusion detection dataset and intrusion traffic characterization," in *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*, pp. 108–116, 2018.
- [4] M. Lanvin, P.-F. Gimenez, Y. Han, F. Majorczyk, L. Mé, and É. Totel, "Errors in the CICIDS2017 dataset and the significant differences in detection performances it makes," in *Risks and Security of Internet and Systems (CRiSIS 2022), Revised Selected Papers*, pp. 18–33, Springer, 2023.
- [5] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [6] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [7] M. A. Ferrag, L. Maglaras, S. Moschogiannis, and H. Janicke, "Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study," *Journal of Information Security and Applications*, vol. 50, p. 102419, 2020.
- [8] K. Alrawashdeh and C. Purdy, "Toward an online anomaly intrusion detection system based on deep learning," in *Proc. 15th IEEE Int. Conf. on Machine Learning and Applications (ICMLA)*, pp. 195–200, 2016.
- [9] R. Vinayakumar, M. Alazab, K. P. Soman, P. Poornachandran, A. Al-Nemrat, and S. Venkatraman, "Deep learning approach for intelligent intrusion detection system," *IEEE Access*, vol. 7, pp. 41525–41550, 2019.
- [10] M. Zaharia, M. Chowdhury, M. J. Franklin, S. Shenker, and I. Stoica, "Spark: Cluster computing with working sets," in *Proceedings of the 2nd USENIX Workshop on Hot Topics in Cloud Computing (HotCloud'10)*, 2010.
- [11] X. Meng, J. Bradley, B. Yavuz, E. Sparks, S. Venkatraman, D. Liu, J. Freeman, D. Tsai, M. Amde, S. Owen, D. Xin, R. Xin, M. J. Franklin, R. Zadeh, M. Zaharia, and A. Talwalkar, "MLlib: Machine learning in Apache Spark," *Journal of Machine Learning Research*, vol. 17, no. 34, pp. 1–7, 2016.
- [12] P. R. Chithra Rani and K. Baalaji, "Deep learning-based ensemble stacking for enhanced intrusion detection in IoT-edge platforms," *Discover Applied Sciences*, vol. 7, p. 928, 2025.
- [13] K. Nasir, S. K. Badri, D. M. Alghazzawi, M. Y. Alghamdi, M. Alkhozai, A. Almakky, R. M. Alhazmi, and M. Z. Asghar, "HED-ID: an edge-deployable and explainable intrusion detection system optimized via metaheuristic learning," *Scientific Reports*, vol. 16, p. 2313, 2026.
- [14] I. Guyon and A. Elisseeff, "An introduction to variable and feature selection," *Journal of Machine Learning Research*, vol. 3, pp. 1157–1182, 2003.
- [15] I. T. Jolliffe, *Principal Component Analysis*. Springer Series in Statistics, Springer, 2nd ed., 2002.
- [16] M. Sarhan, S. Layeghy, and M. Portmann, "Evaluating standard feature sets towards increased generalisability and explainability of ml-based network intrusion detection," *Big Data Research*, vol. 30, p. 100359, 2022.
- [17] J. Gama, I. Zliobaitė, A. Bifet, M. Pechenizkiy, and A. Bouchachia, "A survey on concept drift adaptation," *ACM Computing Surveys*, vol. 46, no. 4, pp. 1–37, 2014.
- [18] V. Chandola, A. Banerjee, and V. Kumar, "Anomaly detection: A survey," *ACM Computing Surveys*, vol. 41, no. 3, pp. 1–58, 2009.
- [19] L. Ruff, J. R. Kauffmann, R. A. Vandermeulen, G. Montavon, W. Samek, M. Kloft, T. G. Dietterich, and K.-R. Müller, "A unifying review of deep and shallow anomaly detection," *Proceedings of the IEEE*, vol. 109, no. 5, pp. 756–795, 2021.
- [20] M. Lopez-Martin, B. Carro, A. Sanchez-Esguevillas, and J. Lloret, "Conditional variational autoencoder for prediction and feature recovery applied to intrusion detection in iot," *Sensors*, vol. 17, no. 9, p. 1967, 2017.
- [21] T. Hasan, A. Hossain, M. Q. Ansari, and T. H. Syed, "Enhanced intrusion detection in IIoT networks: A lightweight approach with autoencoder-based feature learning," 2025. arXiv:2501.15266.
- [22] D. Arp, E. Quiring, F. Pendlebury, A. Warnecke, F. Pierazzi, C. Wressnegger, L. Cavallaro, and K. Rieck, "Dos and don'ts of machine learning in computer security," in *31st USENIX Security Symposium (USENIX Security 22)*, pp. 3971–3988, 2022.
- [23] C. Nadeau and Y. Bengio, "Inference for the generalization error," *Machine Learning*, vol. 52, no. 3, pp. 239–281, 2003.
- [24] D. J. Schuurman, "A comparison of the two one-sided tests procedure and the power approach for assessing the equivalence of average bioavailability," *Journal of Pharmacokinetics and Biopharmaceutics*, vol. 15, no. 6, pp. 657–680, 1987.
- [25] Canadian Institute for Cybersecurity and Communications Security Establishment, "CSE-CIC-IDS2018 dataset: A collaborative project between the Communications Security Establishment (CSE) and the Canadian Institute for Cybersecurity (CIC)." <https://www.unb.ca/cic/datasets/ids-2018.html>, 2018.
- [26] B. Sun, J. Feng, and K. Saenko, "Return of frustratingly easy domain adaptation," in *Proceedings of the 30th AAAI Conference on Artificial Intelligence (AAAI)*, 2016.
- [27] L. D'hooge, T. Wauters, B. Volckaert, and F. De Turck, "Inter-dataset generalization strength of supervised machine learning methods for intrusion detection," *Journal of Information Security and Applications*, vol. 54, p. 102564, 2020.
- [28] M. Cantone, C. Marrocco, and A. Bria, "Machine learning in network intrusion detection: A cross-dataset generalization study," *IEEE Access*, vol. 12, pp. 144489–144508, 2024.
- [29] P. Goldschmidt and D. Chudá, "Network intrusion datasets: A survey, limitations, and recommendations," *Computers & Security*, vol. 156, p. 104510, 2025.