

Hệ thống phát hiện xâm nhập phân tán thời gian thực trên cụm thiết bị biên Jetson Orin Nano Super với Kafka và PySpark

Nguyễn Vũ Thái¹ Bùi Văn Dũng² Đỗ Trí Nhựt² Nguyễn Văn Dũ³

SOICT 2026

¹Phân hiệu tại TP. Hồ Chí Minh, Trường Đại học Giao thông Vận tải, TP. Hồ Chí Minh, Việt Nam

²Trường Đại học Công nghệ Thông tin, ĐHQG-HCM, TP. Hồ Chí Minh, Việt Nam

³Khoa Công nghệ Thông tin, Trường Đại học Nông Lâm, TP. Hồ Chí Minh, Việt Nam

I. VẤN ĐỀ VÀ ĐÓNG GÓP

Phát hiện xâm nhập ngay tại thiết bị biên: còn ba khoảng trống

Mô hình phát hiện xâm nhập nay đã *chạy được* trên bo mạch nhỏ, nhưng nếu một bo phải xét **mọi** luồng thì nó quá tải rất nhanh.

Nghiên cứu trước còn thiếu

1. Chỉ đo trên **một thiết bị**, không chia việc cho nhiều bo.
2. Hiếm khi báo **cùng lúc** tốc độ, độ trễ và năng lượng.
3. Điểm số offline lấy từ quy trình **rò rỉ dữ liệu**.

Câu hỏi

Có hai bo Jetson thì nên *đặt* việc phát hiện lên chúng thế nào?


Cách làm

Tách làm hai: **cổng lọc** rẻ trên bo #1, **bộ phân loại** nặng trên bo #2, nối bằng Kafka.

1. Hệ thống phát hiện xâm nhập **hai tầng, phân tán**: cổng lọc và bộ phân loại Spark đặt trên hai bo khác nhau.
2. **Ba cách triển khai** trên cụm hai Jetson: tách tầng, nhân bản ngang, cụm Spark.
3. **Đo đầu cuối**: tốc độ, độ trễ, CPU/RAM từng bo và năng lượng mỗi phán quyết.
4. Mã nguồn, cấu hình và kịch bản đo **công khai**, chạy lại được.

II. HỆ THỐNG VÀ CÁCH ĐO

Kiến trúc: tách công lọc và bộ phân loại ra hai bo



Chỉ các luồng đáng ngờ mới đi qua Kafka sang bo #2.

Tầng 1 — cổng lọc (autoencoder)

- Học cách *tái tạo* lưu lượng bình thường.
- Luồng tái tạo tốt (sai số nhỏ) → coi là bình thường, **dừng luôn**.
- Luồng tái tạo kém → đáng ngờ, chuyển sang tầng 2.
- Ngưỡng sai số chọn *trước* trên 10% dữ liệu bình thường, không nhìn tập kiểm tra.

Tầng 2 — bộ phân loại (PySpark)

- Random Forest trên **30 đặc trưng** được SHAP chọn (bài FAIR), không có cổng đích; F1 0,9959.
- Chỉ phải xét số ít luồng mà cổng chuyển sang.

Vì sao bộ phân loại là Random Forest trên Spark

- **Random Forest có sẵn trong Spark ML**, nên mô hình xuất ra chạy được trên Jetson (ARM64) mà không cần thư viện native như XGBoost.
- **Ít đặc trưng** (30 thay vì 77) thì dựng vector và suy luận nhanh hơn trên bo 8 GB.
- **Cùng một bộ công cụ** (Spark) vừa huấn luyện trên cụm vừa chạy trên thiết bị — cái giá của lựa chọn này ở Kết quả 5.

Các cách triển khai và cách đo

Một bo làm hết mọi việc, tắt hoặc bật cổng lọc.

A: Tách tầng cổng trên #1, phân loại trên #2.

B: Nhân bản mỗi bo làm đủ cả hai việc (tắt cổng).

C: Cụm Spark PC làm master, hai bo làm worker.

Theo dõi **từng luồng từ lúc gửi tới lúc có phán quyết**, tính cả thời gian chờ. **Chịu được**: mức tải cao nhất mà mọi luồng có phán quyết trong vòng 10 giây sau khi ngừng tải.

Thiết lập đo

2× Jetson Orin Nano Super: CPU 6 nhân, 8 GB RAM

PySpark 3.4.1, Kafka 3.5, mạng Wi-Fi
10.000 luồng từ tập kiểm tra, 15% tấn công

Quét mức tải 1–40 luồng/giây, mỗi mức 2 lần

Năng lượng đo bằng tegrastats

III. KẾT QUẢ VÀ KẾT LUẬN

Kết quả 1: tách tầng chịu được tải gấp 9 lần


Cách triển khai	Chịu được (luồng/giây)	p95 (giây)
Một bo	2,5	11,3
Một bo + cổng	1,9	7,8
B: Nhân bản	3,3	8,2
C: Cụm Spark	8,7	5,2
A: Tách tầng	22,4	7,1

p95: 95% số luồng có phán quyết nhanh hơn mức này, tính từ lúc gửi, gồm cả thời gian chờ.

- **Tách tầng: gấp 9 lần** một bo.
- **Cùng cổng mà để chung một bo thì không nhanh hơn:** lợi ích đến từ bo thứ hai.
- Độ trễ vài giây vì mỗi lô Spark mất vài giây.

Nên dùng tách tầng: chịu được tải cao nhất.

Kết quả 2: nhìn trực tiếp thấy bo nào đang gánh việc



Lúc tải cao nhất, chế độ tách tầng

(lần đo trước, mô hình cũ):

- bo cổng lọc: **4,6% CPU**
- bo phân loại: **90,8% CPU**

Bộ phân loại chiếm gần hết sức tính — nên tách nó ra khỏi đường nhận dữ liệu là đáng.

Kết quả 3: năng lượng mỗi phán quyết giảm 5 lần

Cách triển khai	Mức tải	J / phán quyết
Một bo	2,0/giây	3,04
Một bo + cổng	2,0/giây	3,04
B: Nhân bản	3,9/giây	3,20
C: Cụm Spark	9,5/giây	1,15
A: Tách tầng	18,4/giây	0,60

- Đo ở đúng mức tải mà mỗi chế độ chịu được.
- J mỗi phán quyết = công suất của các bo chia cho số phán quyết mỗi giây.
- Tách tầng dùng hai bo (11 W) nhưng ra nhiều phán quyết hơn hẳn, nên mỗi phán quyết tốn ít hơn.

Tách tầng: **3,0 J** → **0,60 J** mỗi phán quyết.

Kết quả 4: công lọc cho lọt bao nhiêu tấn công

Ngưỡng cổng (phân vị)	Tấn công chuyển tiếp	Báo nhầm	Luồng bỏ qua
0,99	72,4%	0,99%	88,3%
0,995 (đang dùng)	68,1%	0,49%	89,4%
0,999	39,8%	0,09%	94,0%

Offline trên tập kiểm tra; cổng dùng đủ 77 đặc trưng. Chạy thật: bắt được 69,6% trong 1.261 luồng tấn công.

- Luồng bị cổng bỏ qua là *chốt luôn*: **khoảng 30% luồng tấn công** không tới được bộ phân loại.
- Nếu cổng chỉ dùng 30 đặc trưng của bộ phân loại thì chỉ chuyển tiếp được 44,8%.
- Người vận hành chọn điểm hợp với sức máy.

Tải gấp 9 lần phải trả bằng recall: cổng là một **sự đánh đổi có thể chỉnh**, không phải bộ lọc miễn phí.

Kết quả 5: cái giá của việc dùng Spark để suy luận

Đúng khu rừng đang triển khai, xuất sang các bộ máy chạy khác, cùng một bo:

Bộ máy chạy	Luồng/giây	p95 mỗi lô (ms)	mJ mỗi luồng
PySpark (đang dùng)	1,4	7515	1506
NumPy	54,8	194	11,3
ONNX Runtime	10.092	1,2	0,087

Ba bộ máy cho dự đoán giống nhau 100%. mJ mỗi luồng: năng lượng tăng thêm so với lúc bo nghỉ.

ONNX nhanh gấp **khoảng 7.200 lần** PySpark. Hướng tiếp theo: **huấn luyện bằng Spark, suy luận bằng ONNX/TensorRT**.

Những gì đã chỉ ra

- Tách cổng lọc và bộ phân loại ra hai bo: **2,5** → **22,4 luồng/giây**, p95 $\approx$ 7 giây.
- Năng lượng mỗi phán quyết: **3,0 J** → **0,60 J**.
- Đổi lại, cổng cho lọt $\approx$ **30%** luồng tấn công ở ngưỡng đang dùng.
- Spark là nút thắt suy luận: ONNX nhanh gấp khoảng 7.200 lần.

Hạn chế

- Hai bo, mạng Wi-Fi, dữ liệu phát lại.
- GPU chưa dùng; chưa thử tấn công né tránh.

Hướng tiếp theo


- Suy luận bằng ONNX/TensorRT.
- Lưu lượng thật; huấn luyện lại khi dữ liệu trôi.

Xin cảm ơn — kính mời câu hỏi

- [1] Sharafaldin, I., Lashkari, A. H. & Ghorbani, A. A. *Toward generating a new intrusion detection dataset and intrusion traffic characterization*. ICISSP 2018. **CICIDS2017**
- [2] Shi, W. et al. *Edge computing: Vision and challenges*. IEEE Internet of Things Journal 3(5), 2016. **điện toán biên**
- [3] Chandola, V., Banerjee, A. & Kumar, V. *Anomaly detection: A survey*. ACM Computing Surveys 41(3), 2009. **cổng lọc**
- [4] Lundberg, S. M. & Lee, S.-I. *A unified approach to interpreting model predictions*. NeurIPS 2017. **SHAP**
- [5] Zaharia, M. et al. *Spark: Cluster computing with working sets*. HotCloud 2010. **Spark**
- [6] Kreps, J., Narkhede, N. & Rao, J. *Kafka: a Distributed Messaging System for Log Processing*. NetDB 2011. **Kafka**
- [7] Mohan Kiran Kumar, K. et al. *Distributed Intrusion Detection System using Kafka and Spark Streaming*. ICVADV 2025. **hệ thống gần nhất**
- [8] Arp, D. et al. *Dos and Don'ts of Machine Learning in Computer Security*. USENIX Security 2022. **chống rò rỉ**


Slide dự phòng

Dự phòng: mức tải chịu được và năng lượng



Số phán quyết mỗi giây chịu được, mọi luồng xong trong 10 giây (trái); năng lượng mỗi phán quyết ở mức tải đó (phải).

Dự phòng: đường cong vận hành của cổng lọc



Recall tấn công (trái) và tỷ lệ báo nhầm (phải) theo tỷ lệ luồng bị bỏ qua. Bỏ qua nhiều hơn thì Spark nhẹ hơn nhưng lọt nhiều tấn công hơn.

Dự phòng: bảng điều khiển giám sát đầy đủ



Tốc độ tăng bo, số tấn công phát hiện, độ trễ suy luận, CPU/RAM hai bo, cảnh báo lưu trong PostgreSQL.

Dự phòng: quy trình đo

- Máy chủ khởi động các vai trò trên Jetson qua SSH, tạo tải, thu mọi phán quyết.
- Mỗi phán quyết lưu thời điểm gửi và số dòng của luồng: độ trễ tính từ lúc gửi, *gồm cả thời gian chờ*; tỷ lệ bỏ qua và tỷ lệ bắt tấn công tính từ chính các luồng.
- Quét mức tải cho từng chế độ; một mức được coi là chịu được khi mọi luồng gửi trong 45 giây đều có phán quyết trong vòng 10 giây sau đó.
- Mỗi lần chạy một consumer group Kafka riêng; mỗi tầng xử lý lô 20 luồng hoặc sau 1 giây.
- Năng lượng: tegrastats, 30 giây nền rồi cửa sổ tải ở mức chịu được; chế độ hai bo cộng cả hai bo.