

HỆ THỐNG PHÁT HIỆN XÂM NHẬP MẠNG SỬ DỤNG HỌC MÁY TRÊN APACHE SPARK VÀ TRIỂN KHAI PHÂN TÁN TRÊN THIẾT BỊ BIÊN

Nguyễn Vũ Thái

Sinh viên thực hiện

Trường Đại học Giao thông Vận tải, Phân hiệu tại TP. Hồ Chí Minh

`nvthai@utc2.edu.vn`

Bùi Văn Dũng

Giảng viên hướng dẫn

Trường Đại học Công nghệ Thông tin, ĐHQG TP. Hồ Chí Minh

`dungbv.17@grad.uit.edu.vn`

Năm 2026

Tóm tắt nội dung

Luận văn nghiên cứu xây dựng hệ thống phát hiện xâm nhập mạng (IDS) nhị phân trên dataset CICIDS2017, sử dụng Apache Spark ML với chín thuật toán phân loại và phương pháp ensemble. So sánh bốn chiến lược giảm chiều: baseline, RF Importance, SHAP và PCA, kèm đánh giá robustness, concept drift và kiểm định thống kê. Triển khai edge realtime trên Raspberry Pi và cụm hai Jetson Nano với Kafka, PySpark và anomaly gate autoencoder. Kết quả cho thấy [TODO: tóm tắt kết quả chính].

Mục lục

1	Giới thiệu	5
1.1	Bối cảnh và động lực	5
1.2	Mục tiêu nghiên cứu	5
1.3	Phạm vi và giới hạn	5
1.4	Cấu trúc luận văn	5
1.5	Công trình liên quan đã công bố	5
2	Cơ sở lý thuyết	6
2.1	Phát hiện xâm nhập mạng	6
2.2	Học máy trên Apache Spark	6
2.3	Lựa chọn đặc trưng và giảm chiều	6
2.3.1	Random Forest Feature Importance	6
2.3.2	SHAP — SHapley Additive exPlanations [1]	6
2.3.3	Phân tích thành phần chính (PCA)	6
2.4	Ensemble Learning	6
2.5	Edge computing và stream processing	6
2.6	Phát hiện bất thường bằng Autoencoder	6
3	Phương pháp đề xuất	7
3.1	Tổng quan hệ thống	7
3.2	Chuẩn bị dữ liệu	7
3.3	Pipeline huấn luyện Spark ML	7
3.4	Bộ thí nghiệm (Exp 0–8)	7
3.5	Kiến trúc edge phân tán	7
3.6	Chỉ số đánh giá	8
4	Thí nghiệm và kết quả huấn luyện ML	9
4.1	Môi trường thí nghiệm	9
4.2	Kết quả baseline (Exp 0)	9
4.3	So sánh giảm chiều (Exp 1, 3, 6, 7)	9
4.4	SHAP explainability (Exp 5)	9
4.5	Grid Search (Exp 2)	9
4.6	Robustness, drift và kiểm định thống kê	9
4.7	Thảo luận	9
5	Triển khai edge và đánh giá phân tán	10
5.1	Kiến trúc split deployment	10
5.2	Xuất mô hình	10
5.3	Triển khai Raspberry Pi	10

5.4	Triển khai phân tán trên 2 Jetson Nano	10
5.4.1	Chế độ pipeline split	10
5.4.2	Chế độ horizontal scaling	10
5.4.3	Chế độ Spark cluster	10
5.5	Kết quả benchmark edge	10
5.6	Giám sát và cảnh báo	10
5.7	Thảo luận	10
6	Kết luận và hướng phát triển	11
6.1	Tóm tắt kết quả	11
6.2	Đóng góp chính	11
6.3	Hạn chế	11
6.4	Hướng phát triển	11
6.5	Công trình công bố	11

Danh sách hình vẽ

4.1	Heatmap F1 theo phương pháp và thuật toán.	9
-----	--	---

Danh sách bảng

3.1	Mapping thí nghiệm và mục tiêu.	7
-----	---	---

Chương 1

Giới thiệu

1.1 Bối cảnh và động lực

1.2 Mục tiêu nghiên cứu

1. So sánh hiệu quả các phương pháp giảm chiều và lựa chọn đặc trưng trên Spark ML.
2. Ứng dụng SHAP cho giải thích và lựa chọn đặc trưng IDS.
3. Đánh giá robustness và concept drift trên CICIDS2017.
4. Thiết kế và triển khai IDS phân tán trên thiết bị biên (Jetson Nano).

1.3 Phạm vi và giới hạn

1.4 Cấu trúc luận văn

Chương 2 trình bày cơ sở lý thuyết; Chương 3 mô tả phương pháp; Chương 4 báo cáo thí nghiệm ML; Chương 5 trình bày triển khai edge; Chương 6 kết luận.

1.5 Công trình liên quan đã công bố

Hai bài báo rút gọn từ luận văn:

- FAIR'2026: so sánh giảm chiều và lựa chọn đặc trưng (Chương 3–4).
- SOICT 2026: triển khai phân tán trên Jetson Nano (Chương 5).

Chương 2

Cơ sở lý thuyết

2.1 Phát hiện xâm nhập mạng

2.2 Học máy trên Apache Spark

2.3 Lựa chọn đặc trưng và giảm chiều

2.3.1 Random Forest Feature Importance

2.3.2 SHAP — SHapley Additive exPlanations [1]

2.3.3 Phân tích thành phần chính (PCA)

2.4 Ensemble Learning

2.5 Edge computing và stream processing

2.6 Phát hiện bất thường bằng Autoencoder

Chương 3

Phương pháp đề xuất

3.1 Tổng quan hệ thống

Luận văn gồm hai pha: (1) huấn luyện và đánh giá offline trên PC với PySpark; (2) suy luận realtime trên edge qua Kafka.

3.2 Chuẩn bị dữ liệu

Script `data_preparation.py`: gộp 8 file CSV CICIDS2017, làm sạch, nhãn nhị phân, chia 80/20, lưu Parquet.

3.3 Pipeline huấn luyện Spark ML

VectorAssembler → StandardScaler → Classifier / PCA.

3.4 Bộ thí nghiệm (Exp 0–8)

Bảng 3.1: Mapping thí nghiệm và mục tiêu.

Exp	Mục tiêu
0	Baseline toàn bộ đặc trưng
1	RF Feature Importance (Top 20/30/40)
2	Grid Search + Cross-Validation
3	PCA ($k = 20/30/40$)
5	SHAP explainability (XGBoost)
6	SHAP feature selection
7	So sánh chéo + drift + robustness
8	Autoencoder anomaly gate

3.5 Kiến trúc edge phân tán

Ba chế độ: pipeline split, horizontal scaling, Spark cluster (xem `raspberry/JETSON_DISTRIBUTED.md`).

3.6 Chỉ số đánh giá

Accuracy, Precision, Recall, F1, AUC-ROC, AUC-PR; thời gian huấn luyện/dự đoán; throughput và latency edge.

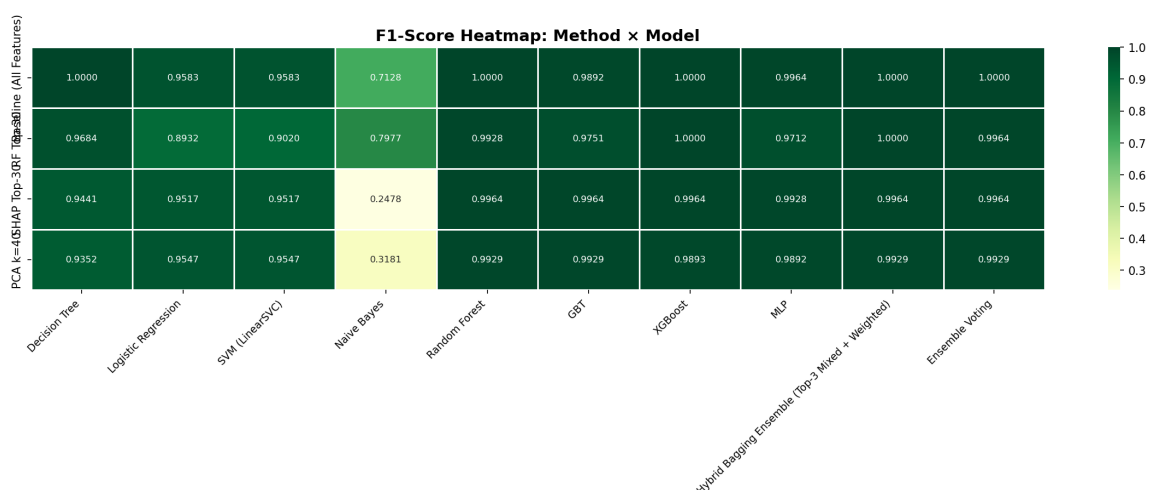
Chương 4

Thí nghiệm và kết quả huấn luyện ML

4.1 Môi trường thí nghiệm

4.2 Kết quả baseline (Exp 0)

4.3 So sánh giảm chiều (Exp 1, 3, 6, 7)



Hình 4.1: Heatmap F1 theo phương pháp và thuật toán.

4.4 SHAP explainability (Exp 5)

4.5 Grid Search (Exp 2)

4.6 Robustness, drift và kiểm định thống kê

4.7 Thảo luận

Chương 5

Triển khai edge và đánh giá phân tán

5.1 Kiến trúc split deployment

PC: Kafka, PostgreSQL, InfluxDB, Grafana. Edge: PySpark inference + tùy chọn anomaly gate.

5.2 Xuất mô hình

`raspberrypi/scripts/save_model.py`, `exp8_autoencoder_anomaly.py`.

5.3 Triển khai Raspberry Pi

5.4 Triển khai phân tán trên 2 Jetson Nano

5.4.1 Chế độ pipeline split

5.4.2 Chế độ horizontal scaling

5.4.3 Chế độ Spark cluster

5.5 Kết quả benchmark edge

5.6 Giám sát và cảnh báo

InfluxDB metrics theo `EDGE_NODE_ID`; alert Email/Slack/Telegram.

5.7 Thảo luận

So sánh với bài báo SOICT 2026; hạn chế phần cứng Nano 4GB.

Chương 6

Kết luận và hướng phát triển

6.1 Tóm tắt kết quả

6.2 Đóng góp chính

1. Pipeline Spark ML đánh giá toàn diện IDS trên CICIDS2017.
2. So sánh RF, SHAP, PCA với drift và robustness.
3. Hệ thống edge phân tán trên Jetson Nano với Kafka.
4. Anomaly gate giảm tải suy luận Spark.

6.3 Hạn chế

6.4 Hướng phát triển

TensorRT, federated learning, mở rộng RoEduNet, tích hợp SOC.

6.5 Công trình công bố

- FAIR'2026 — so sánh giảm chiều (Chương 3–4).
- SOICT 2026 — edge phân tán Jetson Nano (Chương 5).

Tài liệu tham khảo

- [1] Lundberg, S.M., Lee, S.I.: A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems **30** (2017)