

I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC CŨNG NGH THŨNG TIN
KHOA KHOA HC VỊ K THUT MỖY TỒNH



BŨI VN DNG

LUN VN THC S

PHÒT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO
MT MNG IoT

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THC S NGỊNH CŨNG NGH THŨNG TIN

TP. H CHỜ MINH, 2026

**I HC QUC GIA THỊNH PH H CHỜ MINH
TRNG I HC CŨNG NGH THŨNG TIN
KHOA KHOA HC VỊ K THUT MỖY TỜNH**



BÚI VN DNG 220201014

LUN VN THC S

**PHỜT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO
MT MNG IoT**

**INTRUSION DETECTION (IDS) BASED ON APACHE SPARK FOR IoT
NETWORK SECURITY**

THC S NGHỊNH CŨNG NGH THŨNG TIN

GING VIỎN HNG DN

TS. NGUYN VN D

TS. TRỜ NHT

TP. H CHỜ MINH, 2026

THŨNG TIN HI NG BO V LUN VN THC S

Hi ng chm lun vn thc s, thnh lp theo Quy t nh s ngiy ca Hiu
trng Trng i hc Cũg ngh Thũg tin.

1. Ch tch:

2. Th kỳ:

3. y viõn:

L I C M N

Li u ti3n, tui xin gi li cm n ch3n thnh n quỳ thy cũ ca Trng i hc Cũng Ngh Thũng Tin, i hc Quc gia Thnh Ph H Chờ Minh 3 tn t3nh ch dy, giúp tui tip thu c nhieu kin thc quỳ b3u trong sut thi gian hc tp ti trng, cng nh to iu kin thun li cho tui thc hin lun vn ngy. K3nh chũc thy cũ luũn di d3o sc kho v3 gt h3i c nhieu thnh cũng trong tng lai.

c bit, tui xin ch3n thnh cm n thy TS. Nguy3n Vn D v3 TS. Trờ Nht 3 tn t3nh giúp , hng dn, cung cp cho tui nhng kin thc, k nng cn thit thc hin nghi3n cu v3 ho3n thnh t3i ngy.

Mc dũ 3 c gng trong qu3 tr3nh nghi3n cu, do kin thc cũn hn ch n3n vn cũn nhieu thiú sút. V3 vy, tui rt mong nhn c s úng giúp ý ca Quỳ Thy Cũ t3i ca tui c ho3n thnh hn.

Tui xin ch3n thnh cm n!

Búi Vn Dng

TÓM TẮT

Sự phát triển nhanh chóng của Internet of Things (IoT) đã mang lại nhiều tin tức trong các lĩnh vực như nông nghiệp, công nghiệp, y tế và giao thông. Tuy nhiên, cũng vì sự phát triển này lại nảy sinh các nguy cơ gia tăng về các mối đe dọa an ninh mạng, đặc biệt là khi các thiết bị IoT thường có mặt tại nguồn tấn công toàn diện về mặt kỹ thuật. Trong bối cảnh này, Intrusion Detection Systems (IDS) cần xem xét một giải pháp quan trọng nhằm phát hiện và ngăn chặn các hình thức tấn công bất thường vào hệ thống mạng IoT.

Lưu ý rằng việc tập trung nghiên cứu, thiết kế và triển khai một hệ thống IDS dựa trên nền tảng xử lý dữ liệu lớn Apache Spark. Spark có khả năng xử lý dữ liệu phân tán, tốc độ cao và hiệu quả xử lý toàn bộ dữ liệu thông qua thư viện MLlib. Hệ thống có ý định nhằm phát hiện các hình thức xâm nhập trong dữ liệu mạng IoT thông qua việc ứng dụng các mô hình học máy truyền thống, các mô hình học tập và các mô hình học sâu MLP (cũng như autoencoder đóng vai trò trong phát hiện bất thường - tấn công biến đổi).

Trong quá trình thực hiện, lưu ý rằng tin hình phân tích các dữ liệu mạng IoT, là chọn vị trí xử lý dữ liệu và việc tập trung dữ liệu cũng khai thác CICIDS2017, sau đó tin hình huấn luyện mô hình, đánh giá hiệu quả hệ thống theo các chỉ số chính xác (Accuracy), precision, recall và F1-score, đồng thời ghi lại thời gian huấn luyện và kích thước mô hình. Quá trình đánh giá tập trung quy trình loại bỏ dữ liệu (loại các trường dữ liệu nhiễu, loại bỏ trùng lặp các trường) nhằm bảo mật quá trình đánh giá và ngăn ngừa các mô hình. Bối cảnh này, hệ thống cần kiểm tra hiệu năng trong mỗi trường xử lý phân tán (proof-of-concept trên các thiết bị biến đổi) nhằm khảo sát khả năng mở rộng và triển khai thực tiễn.

Để cụ thể hơn về việc loại bỏ dữ liệu, là chọn các trường SHAP Top-30 để có hiệu năng gần tương đương với mô hình y trong khi giảm khoảng 60% số các trường: Random Forest đạt F1 0,9955 và mô hình học tập Hybrid Bagging đạt F1 0,9966 trên CICIDS2017; các khối bit gia tăng phép kiểm tra bằng kiểm tra hoàn toàn và ghép cặp vị trí không tin cậy hiệu chỉnh Nadeau–Bengio. Trên các thiết bị Jetson Orin Nano Super, kiến trúc tích hợp pipeline (cung cấp phát hiện bất thường + bộ phân loại PySpark) nóng thông qua phần quyết định 2,6 lần 62,5 lần/giây (gấp ≈ 24 lần) và thời gian xử lý 13 ms, trong đó cũng đạt 95,8% lưu lượng băng thông trước khi gửi suy luận Spark. Khả năng xử lý phân tán cần kiểm tra các mô hình minh chứng khả năng (proof-of-concept) trên các thiết bị biến đổi, thay vì không như quy mô dữ liệu lớn thực tế. Lưu ý rằng chúng tôi giúp phần việc xây dựng quy trình phát hiện xâm nhập theo thời gian thực mà còn mở ra các hướng nghiên cứu tìm kiếm trong việc kết hợp học máy và các nền tảng xử lý dữ liệu lớn phục vụ bảo mật hệ thống IoT.

MC LC

Thông tin hi ng bo v lun vn	i
Li cm n	ii
Tóm tt	iii
Mc lc	iv
Danh mc còc bng	vii
Danh mc còc hnh v vị th	ix
Danh mc t vit tt	x
Chng 1. M u	1
1.1 Lý do chn tị	1
1.2 Còc nghiõn cu liõn quan	1
1.3 Mc tiõu, i tng vị phm vi nghiõn cu	3
1.3.1 Mc tiõu nghiõn cu	3
1.3.2 i tng nghiõn cu	4
1.3.3 Phm vi nghiõn cu	4
1.3.4 Còu hi nghiõn cu	5
1.4 Phng phòp nghiõn cu	5
1.5 Còc úng gúp chõnh ca tị	6
1.6 Cũng trõnh ang chun b cũng b	7
1.7 Cu trũc ca lun vn	7
Chng 2. C s lý thuyt	9
2.1 Tng quan v IoT	9
2.2 H thng phòt hìn xóm nhp (IDS)	9
2.3 Apache Spark vị x lý d liu ln	10
2.3.1 D liu ln	10
2.3.2 Còc thnh phn ca Apache Spark	11
2.3.3 Kin trũc ca Apache Spark	13

2.4	Học mờ trong phân hình xấp xỉ	13
2.4.1	Một số thuật toán học mờ	14
2.4.2	Một số thuật toán học tập	18
Chương 3.	Phương pháp phân hình	21
3.1	Thu thập dữ liệu vị trí	21
3.2	Lựa chọn các trạng vị trí để phân hình	25
3.3	Học phân hình mờ	26
3.3.1	Học phân hình mờ các	26
3.3.2	Các phương pháp Ensemble Learning	28
a)	Ôp phân hình Voting	28
b)	Ôp phân hình Bagging	30
3.4	Đánh giá phân hình mờ	32
3.5	Tìm hiểu tham số học phân hình mờ	34
3.6	Trình bày	36
Chương 4.	Thực nghiệm, đánh giá vị trí	37
4.1	Môi trường thực nghiệm	37
4.2	Kết quả thực nghiệm	38
4.2.1	Kịch bản 1: Đánh giá hiệu năng cơ sở (Baseline)	40
4.2.2	Kịch bản 2: So sánh chín loại phân hình mờ	40
4.2.3	Kịch bản 3: Tìm hiểu tham số	41
4.2.4	Phân tích khả năng giải thích vị trí SHapley Additive exPlanations (SHAP)	42
4.2.5	Phân tích rò rỉ dữ liệu (data leakage)	43
4.2.6	Phân tích hiệu năng hệ thống	44
4.2.7	Kim nghiệm nghĩa thống kê	44
4.2.8	Kim tra nghiệm trong-phân-phí	45
4.2.8.1	Tổng quát hóa liên biến dữ liệu	46
4.2.9	Đánh giá áp dụng theo lợi ích cũng	47
4.3	Thực nghiệm vị trí đánh giá hiệu năng phân hình mờ trên Jetson Orin Nano Super	51
4.3.1	Các cũng cơ sở dùng trong hệ thống	51
4.3.2	Mô hình hệ thống xuất	53
4.3.3	Lựa chọn mô hình cho thiết bị biến	55
4.3.4	Kết quả học phân hình mờ các mô hình ngôn ngữ biến trên cm Spark	59

4.3.5	Kt qu o hieu nng (benchmark) trồn Jetson Orin Nano Super	60
4.3.6	So sòn engine suy lun: chi phờ ca vic ng nht stack	60
4.3.7	Kt qu ba ch trin khai phón tòn	61
4.3.8	Phón tồch vị la chn mũ hnh	63
4.4	Tho lun vị So sòn tng hp	64
Chng 5.	Kt lun vị hng phòt trin	65
5.1	Nhng úng gúp chờnh ca lun vn	65
5.2	Hn ch ca tị	65
5.3	Hng phòt trin trong tng lai	67
Ph lc A.	Cũng trnh ang chun b cũng b	69
	Tị liu tham kho	76

DANH MỤC CỜC BNG

3.1	Mũ t b d liu CICIDS2017	22
3.2	Mũ t b d liu CSE-CIC-IDS2018 (dững cho thờ ngihm liễn b d liu)	22
3.3	Tòm b phón loi c s c s dng trong pipeline	27
3.4	Cờc phng phòp hc t hp (ensemble) s dng trong lun vn	28
3.5	Cờc tiũ chờ ònh giò mũ hnh	32
3.6	Ma trn nhm ln ca mũ hnh phòt hin xóm nhp	33
3.7	Thũng s phn cng thit b biễn	36
4.1	Tham s ti u ca cõc mũ hnh hc mỳy	39
4.2	Kt qu hũ nng phón lp kch bn Baseline (toịn b c trng s, ≈ 78 trc khi loi cng) .	40
4.3	So sòn hũ nng tt nht ca cõc phng phòp la chn c trng vị gim chũ	41
4.4	So sòn hũ nng la chn c trng: Random Forest (RF) Importance vs SHapley Additive exPlanations (SHAP) Importance (Top-30)	41
4.5	Kt qu hũ nng phón lp kch bn Ti u hũa tham s	42
4.6	Phón tồch loi b (ablation) rừ r: nh hng ca c trng destination_port (Random Forest c nh a priori: numTrees=200, maxDepth=15, cú trng s lp; nh phón)	43
4.7	So sòn thi gian x lý vị kồch thc mũ hnh kch bn Baseline	44
4.8	n nh qua nhiũ ln ly mu vị kim nh gổp cp (t statistical_valid- ity_multiseed.csv)	45
4.9	Kim tra n nh trong-phón-phi trổn mu con tp kim tra (t robustness_- holdout_summary.csv)	45
4.10	Tng quòt hũa liễn b d liu gia CICIDS2017 vị CSE-CIC-IDS2018 (CSE- CIC-IDS2018: mu phón tng seed=42; t cross_dataset_results.csv) 46	
4.11	Hũ nng theo tng lp tn cũg (t per_class_metrics.csv)	47
4.12	im vn hnh ca cng bt thng khi quổt quantile trổn tp kim nh benign (10% benign train, seed=42; t gate_operating_points.csv). FPR óy lị t l lung benign b cng chũn nhm sang b phón loi, khũng phi FPR ca toịn h thng.	55
4.13	Kt qu hun lũn cõc mũ hnh ng viỗn cho trin khai biễn (SHAP Top-30) . .	59
4.14	So sòn hũ nng trin khai trổn Jetson Orin Nano Super	60

4.15	Chi phí suy luận một nút triển khai mã hình/c (Spark vs sklearn vs ONNX), o triển khai phân loại trong cùng iu kin bo mch (batch 10; nng lng lị phn <i>hot ng</i> , ò tr <i>idle</i>)	61
4.16	So sánh ba ch trìn khai phân tòn triển cm 2 Jetson Orin Nano Super	61

DANH MỤC CỜ HÌNH VÀ VỊ TH

2.1	Mũ hình 5V ca d liu ln [31]	11
2.2	Cờ thịnh phn ca Apache Spark [33]	12
2.3	S kin trúc h thng Apache Spark [32]	13
3.1	Quy trình tng th hun luyn, ònh giò vị trin khai mũ hình xut	21
4.1	Cm hun luyn phón tồn Apache Spark Standalone: MacBook gi vai trò <i>master</i> iu phi (khũng chy executor), hai Jetson Orin Nano Super lị <i>worker/executor</i> thc thi tòn tò; d liu Parquet c phón vúng vị ng b sang c hai nũt, kt qu c gom v qua shuffle/collect.	38
4.2	Top 30 c trng quan trng theo giò tr trung bnh tuyt i SHAP ca mũ hình XGBoost (XGB)	49
4.3	Biu SHAP Summary (beeswarm): phón b vị hng tộc ng ca tng c trng	50
4.4	Ma trn nhm ln a lp theo loi tn cũg (chun hóa theo hng)	50
4.5	Kin trúc h thng phòt hin xóm nhp phón tồn thi gian thc trón cm 2 Jetson Orin Nano Super	53
4.6	Giao din terminal khi pipeline IDS hot ng trón hai node Jetson Orin Nano Super: (a) node cng lc bt thng vị (b) node phón loi PySpark	56
4.7	Dashboard Grafana giòm sòt hieu nng IDS theo thi gian thc	57
4.8	Email cnh bào tn cũg c gi qua Mailtrap trong mũi trng kim th (nh chp t giai on th nghim sm ca h thng; mũ-un cnh bào vị nh dng thũng ip gi nguỷn khi trin khai trón cm Jetson)	57
4.9	Dashboard Grafana hin th chi tit còc cuc tn cũg c phòt hin vị phón loi theo thi gian	58
4.10	Dashboard Grafana ti thi im ti nh ca ch tòch pipeline: nũt cng (jetson-nano-1) ch s dng khong 5 % CPU trong khi nũt phón loi PySpark (jetson-nano-2) t ti 91 %	58
4.11	Thũng bào cnh bào tn cũg c gi qua Slack Incoming Webhook (nh chp t giai on th nghim sm; nh dng thũng ip gi nguỷn khi trin khai trón cm Jetson)	59
4.12	Thũng lng vị tr p95 ca bn ch trin khai trón cm 2 Jetson	62
4.13	So sòn hieu nng ba mũ hình trón Jetson Orin Nano Super	63
4.14	Biu radar th hin s ònh i (trade-off) gia còc mũ hình trón thit b biõn	64

DANH MỤC T VIẾT TẮT

AC	accuracy
BD	Big Data
CNN	Convolutional Neural Network
CV	Cross-Validation
DT	Decision Trees
EL	Ensemble Learning
FS	F1-score
GBT	Gradient Boosted Trees
GS	Grid Search
IDS	Intrusion Detection Systems
IoT	Internet of Things
kNN	k-Nearest Neighbors
LGBM	LightGBM
LR	Logistic Regression
LSTM	Long Short-Term Memory
ML	Machine Learning
MLP	Multilayer Perceptron
NB	Naive Bayes
PCA	Principal Component Analysis
PR	precision
RE	recall
RF	Random Forest
RFI	Random Forest Importance
RNN	Recurrent Neural Network
SCP	Secure Copy Protocol
SHAP	SHapley Additive exPlanations
SVM	Support Vector Machine
XGB	XGBoost

Chng 1. M U

1.1 Lý do chn tii

Trong k nguyên ca Còch mng Cũng nghip 4.0, IoT ang phòt trin nhanh vị c ng dng rng ròi trong nhieu lnh vc nh nhậi thũng minh, y t, giao thũng, cũng nghip thũng minh,... S bứng n v s lng thit b IoT dn n s gia tng òng k v lu lng vị loi hnh d liu truyn trong mng. Tuy nhiên, còch thit b IoT thng cú kh nng x lý hn ch vị thi u còc c ch bo mt mn, khin chũng tr thnh mc tiều d b tn cũng bi tin tc.

i phú vì còc mi e đa an ninh mng, còc h thng phòt hin xóm nhp (IDS) ang c nghiỏn cu vị phòt trin rng ròi. c bit, trong nhng nm gn óy, vic kt hp hc mỳy (Machine Learning (ML)) vị còc nn tng x lý d liu ln giúp h thng nóng cao chỏnh xỏc phòt hin vị thờch nghi tt hn vì mũ trng mng thay i liỏn tc. Cn lu ý rng b phón loi chỏnh trong lun vn lý mũ hnh hc cú giỏm sỏt trỏn CICIDS2017 nỏn ch phòt hin c còc h tn cũng ỏ bit; kh nng phòt hin hnh vi bt thng cha tng thy (nu cú) n t cng phòt hin bt thng (anomaly gate) hc khũng giỏm sỏt, ch khũng phi t b phón loi. Tuy nhiên, phn ln còc nghiỏn cu hin nay tp trung vớo vic xỏy dng mũ hnh hc mỳy trỏn tp d liu tnh, dung lng nh vị hun luy n goi tuyn (offline).

Trong khi ú, mng IoT hin i sinh ra lng d liu rt ln, liỏn tc theo thi gian thc ùi hi còc h thng IDS cú kh nng x lý d liu ln (Big Data (BD)) hieu qu, cú th hot ng trong mũ trng phón tòn vị thi gian thc.

Apache Spark lị mt nn tng x lý d liu ln, vị kh nng x lý song song, phón tòn vị d dng tỏch hp vị th vin hc mỳy Spark MLlib lị mt gii phỏp tìm nng xỏy dng h thng IDS hin i ỏp ng yỏu cu v quy mũ vị thi gian thc trong mũ trng IoT.

1.2 Còc nghiỏn cu liỏn quan

Trong nhng nm gn óy, còc h thng phòt hin xóm nhp (Intrusion Detection System – IDS) đa trỏn hc mỳy vị hc sỏu ỏ thu hũt nhieu s quan tótm ca cng ng nghiỏn cu nhm nóng cao chỏnh xỏc vị kh nng thờch ng trc còc hnh thc tn cũng mng ngậi cựng tinh vị [1, 2, 3]. Nhieu cũng trớnh tp trung khai thờc còc kin trũc hc sỏu nh autoencoder, mng tỏch chp (Convolutional Neural Network (CNN)) vị mng n-ron hi quy (Recurrent Neural Network (RNN), Long Short-Term Memory (LSTM)) t ng trỏch xut c trng vị phòt hin bt thng trong lu lng mng. Tuy nhiên, phn ln còc nghiỏn cu hin nay vn c trin khai trong mũ trng n mỳy, x lý d liu tnh vị quy mũ tng i nh, vị cha tỏch hp còc nn tng x lý d liu ln nh Apache Spark hay Hadoop

nhm òp ng yểu cu v kh nng m rng vị x lý thi gian thc trong còc h thng mng hin i.

Mt s nghiỏn cu ò xut còc mũ hnh IDS hc sỏu da trỏn còc kin trũc nh autoencoder, CNN v LSTM nhm nỏng cao kh nng hc c trng vị phòt hin xỏm nhp mng. Còc mũ hnh nỳ c ònh giò trỏn còc tp d liu chun nh NSL-KDD, CIC-DDoS2019 v CICIDS2017, cho thy hieu qu cao trong vic phòt hin bt thng. Tuy nhiỏn, quò trỏnh hun luyn vị ònh giò vn ch yu c thc hin trong mũ trng cc b vị theo c ch x lý theo lũ (batch) [4, 5]. Tng t, còc mũ hnh lai da trỏn LSTM (chng hn CNN-LSTM, hay LSTM c ti u húa siỏu tham s) cho bỳ toỏn phòt hin bt thng trong mng cng t c kt qu kh quan, nhng vn trin khai trỏn nn tng n nũt (single-node) vị cha khai thỏc c kh nng m rng ca còc h thng Big Data [6, 7]. Gn óy, mt s nghiỏn cu ò trin khai IDS hc mỳy trc tip trỏn phn cng biỏn NVIDIA Jetson [8, 9], hay trỏn mũ trng biỏn mũ phng rỳng buc tỳ nguyỏn [10], nhng vn quy mũ n nũt vị cha tỏch hp c ch x lý lung phỏn tòn.

Bỏn cnh còc phng phỏp hc sỏu, còc k thut hc mỳy trun thng nh Support Vector Machine (Support Vector Machine (SVM)), k-Nearest Neighbors (k-Nearest Neighbors (kNN)) v Decision Tree vn c s dng rng rỏi trong còc h thng IDS. Mt s nghiỏn cu ò tin hnh so sỏnh hieu nng ca còc mũ hnh nỳ trỏn còc b d liu ph bin nh NSL-KDD v UNSW-NB15, qua ú ch ra rng còc phng phỏp hc mỳy trun thng cú tim nng ng dng thc tin cao. Tuy nhiỏn, còc mũ hnh nỳ ch yu hot ng ch offline, x lý d liu theo tng t vị cha òp ng c yểu cu v x lý d liu liỏn tc trong mũ trng mng ng [11]. Ngoỳ ra, mt s cũng trỏnh so sỏnh nhiu mũ hnh hc mỳy vị hc sỏu cho IDS, ghi nhn còc mũ hnh da trỏn cỳ nh Random Forest cho kt qu tt trỏn còc b d liu ln, nhng toỏn b thc nghiỏm vn c thc hin trỏn mt mỳy n [12].

Ngoỳ còc kin trũc nỏu trỏn, nhiu mũ hnh hc sỏu khỏc nh CNN, RNN v còc mũ hnh lai CNN-LSTM cng ò c nghiỏn cu vị ònh giò cho bỳ toỏn phòt hin xỏm nhp mng. Còc nghiỏn cu nỳ cho thy kh nng ci thỳn òng k chỏnh xỏc so vị còc phng phỏp trun thng khi th nghiỏm trỏn còc b d liu nh CICIDS2018. Tuy nhiỏn, phn ln còc mũ hnh vn thiu kh nng trin khai trong mũ trng thi gian thc vị cha tn dng c sc mnh ca còc nn tng x lý d liu ln [13].

Trong bi cnh Internet of Vehicles (IoV), mt s nghiỏn cu ò xut còc h thng IDS da trỏn hc mỳy vị hc sỏu nhm bo v còc mng phng tin thũng minh. Còc phng phỏp nỳ bao gm vic s dng còc mũ hnh da trỏn cỳ (tree-based), còc h thng phòt hin xỏm nhp a tng, cng nh còc mũ hnh ensemble ci thỳn chỏnh xỏc phòt hin tn cũng. Mc dũ t c kt qu kh quan trỏn còc b d liu th nghiỏm, còc h thng nỳ vn ch yu c hun luyn vị ònh giò trong mũ trng ngoi tuyn, x lý d liu theo batch vị cha tỏch hp còc nn tng x lý d liu ln hoc c ch x lý d liu theo lung [14, 15, 16].

Bổn cnh ú, mt s hng tip cn gn óy ã nghiõn cu vic òp dng hc bõn giõm sòt, hc liõn kt (federated learning) vï hc tng dn (incremental/active learning) cho bïi toànn IDS nhm nõng cao kh nng thờch ng ca mĩ hõnh vï bo v quyn riõng t d liu. Cõc phng phõp nïy cho phõp phõn tòn quõ trõnh hun luyn trõn nhiu nũt hoc thit b IoT khõc nhau. Tuy nhiõn, d liu vn ch yu c x lý theo tng t, thiu c ch x lý lung tp trung vï cha khai thờc y kh nng m rng cng nh song song húa ca cõc nn tng Big Data [17, 18, 19, 20, 21].

T tng quan cõc cõng trõnh nghiõn cu nõu trõn, cú th nhn thy rng phn ln cõc h thng IDS hin ti vn hot ng trong mĩi trng ngoi tuyn, cha h tr x lý d liu liõn tc theo thi gian thc vï cha tn dng c kh nng m rng ca cõc nn tng x lý d liu ln. Do ú, lun vn nïy hng n vic tõch hp cõc mĩ hõnh hc mỳy da trõn nn tng Apache Spark nhm xõy dng mt h thng phõt hin xõm nhp cú kh nng x lý d liu ln, h tr thi gian thc vï òp dng hïu qu trong mĩi trng mng IoT hin i.

1.3 Mc tiõu, i tng vï phm vi nghiõn cu

1.3.1 Mc tiõu nghiõn cu

Mc tiõu ca tị PHÒT HIN XÕM NHP (IDS) DA TRÕN APACHE SPARK CHO BO MT MNG IoT lị xõy dng mt h thng phõt hin xõm nhp cú kh nng phõn tõch vï phõt hin cõc hïnh vi bt thng hoc tn cõng mng trong mĩi trng IoT bng cõch kt hp cõc mĩ hõnh hc mỳy vi nn tng x lý d liu ln Apache Spark nhm t c:

- Phõt hin hïu qu cõc dng tn cõng mng ph bin (nh DoS, probing, brute-force) trõn cõc tp d liu hin i nh CICIDS2017.
- Thit k vï trin khai pipeline x lý d liu phõn tòn vï song song s dng Apache Spark, bao gm cõc bc: tin x lý d liu, trõch xut c trng, hun luyn mĩ hõnh vï phõt hin thi gian thc.
- Kho sòt hïu nng h thng, hng ti kh nng m rng, tr thp vï tõnh linh hot; kim chng kh nng x lý phõn tòn mc minh chng khõì nim (proof-of-concept) trõn cm thit b biõn, lịm tin cho vic trin khai trõn cõc h thng ln hoc mng IoT nhiu thit b.
- So sõnh vï ònh giõ cõc mĩ hõnh hc mỳy ph bin nh Decision Tree, Support Vector Machine, Logistic Regression, Naive Bayes (NB), Random Forest, Gradient Boosted Trees (GBT), XGBoost (XGB), Multilayer Perceptron (MLP) vï cõc thut toànn hc t hp (ensemble) trong mĩi trng x lý phõn tòn, t ú chn ra mĩ hõnh phứ hp nht.
- Òp dng quy trõnh ònh giõ cht ch, loi tr rừ r d liu (loi c trng rừ r nhõn, loi b trng lp mc c trng, kim nh ý ngha thng kõ) nhm m bo kt qu phn ònh ỹng nng lc mĩ hõnh.

- xut gii phòp the tin giũp phòt hin tn cũng nhanh chúng vị chònh xòc trong còc h thng mng hin i cú yỏu cu x lý d liu ln vị liỏn tc.

1.3.2 i tng nghiỏn cu

tị tịp trung nghiỏn cu vị trin khai phng phòp phòt hin xỏm nhp trong lnh vc bo mt mng IoT bng còch tn dng sc mnh ca nn tng x lý d liu ln Apache Spark. Vì s phòt trin nhanh chúng ca còc thit b IoT, vn m bo an toạn vị bo mt cho h thng ngiỳ cựng tr nỏn cp thit, c bit lị trong vic phòt hin còc hnh vi bt thng hoc tn cũng mng tim n.

Apache Spark, vị kh nng x lý d liu phỏn tòn vị tc tỏnh toỏn cao, cho phỏp x lý khi lng ln d liu sinh ra t còc thit b IoT trong thi gian thc. Trong khuỷn kh nghiỏn cu nịy, lun vn s dng còc tỏnh nng ca Spark nh x lý lung d liu (streaming), hc mỳy phỏn tòn (MLlib) vị phỏn tỏch d liu quy mũ ln xỏy dng mũ hỏnh phòt hin xỏm nhp hiu qu. Qua ú, tị khũng ch xut mt gii phòp k thut cú tỏnh ng dng cao mị cùn gúp phn nỏng cao hiu qu bo mt cho còc h thng IoT trong thc tin.

1.3.3 Phm vi nghiỏn cu

tị tịp trung vộ vic nghiỏn cu vị ỏp dng còc k thut phỏn tỏch d liu ln nhm phòt hin xỏm nhp trong h thng mng IoT vị mc ỏch lị khai thỏc nhng im mnh ca nn tng Apache Spark x lý vị phỏn tỏch d liu hiu qu. C th, phm vi nghiỏn cu bao gm:

- **D liu u vộ:** D liu c s dng lị tịp d liu cũng khai CICIDS2017.
- **Cũng ngh s dng:** S dng Apache Spark lịm nn tng x lý d liu ln, c bit tịp trung vộ còc thnh phn nh Spark Core, Spark SQL, Spark Streaming vị Spark MLlib h tr tin x lý d liu, hun luy n mũ hỏnh hc mỳy vị phòt hin xỏm nhp theo thi gian thc.
- **Phng phòp phòt hin xỏm nhp:** ỏp dng còc thut toỏn hc mỳy c trin khai vị tị u húa trong mũ trng Spark m bo kh nng m ng vị hiu nng cao.
- **Mũ trng trin khai:** Th nghi m h thng trỏn mt mũ trng gị lp mng IoT vị b d liu mũ phng cũng khai (CICIDS2017) nhm ònh giỏ kh nng phòt hin xỏm nhp.

Lu ý v phm vi d liu. Cn nhn mnh rng CICIDS2017 lị b d liu lu lng mng doanh nghi p mũ phng, khũng cha lu lng c thứ IoT (vừ d còc giao thc MQTT, CoAP) hay thit b IoT thc. Tỏnh cht “IoT” ca tị do ú nm *kch bn trin khai*: toạ b pipeline suy lun c thit k, tị u vị o c trỏn thit b biỏn tị nguyỏn hn ch (NVIDIA Jetson Orin Nano Super), lp thit b úng vai

trừ gateway/biến trong kin trúc IoT ba tng — thay vớ bn cht lu lng ca d liu hun luyn. CICIDS2017 c chn vớ lị b chun cũng khai, c cng ng s dng rng rãi, cú nhõn chỉ tit vị bao ph còc h tn cũng (DoS/DDoS, brute-force, web attack, botnet) cng xut hin ph bin trong còc mng IoT; còc ngun li ca b d liu nịy ò c nghiõn cu k, cho phõp òp dng quy trõnh loi tr rù r mt còch cú cn c. Vic kim chng trõn còc b d liu IoT chuyển bit (Bot-IoT, TON_IoT, CIC-IoT-2023) c xòc nh lị hng phòt trin tip theo (Chng 5).

Mũ hõnh mĩ e da (threat model). Lun vn gi nh k tn cũng nm bốn trong hoc biõn mng IoT vị tởm còch nõ trõnh phòt hin; phm vi bo v giĩ hn vic phòt hin còc tn cũng ò bit theo kiu CICIDS2017, di dng phón loi nh phón Benign/Attack. Còc kch bn i khõng ch ng (adversarial/evasion) nhm c ý ònh la mũ hõnh nm ngoịi phm vi ònh giò ca lun vn.

1.3.4 Cúu hi nghiõn cu

Lun vn c nh hng bi ba cúu hi nghiõn cu:

- **RQ1:** Vic gim chiu/la chn c trng (RF Importance, SHapley Additive exPlanations (SHAP), Principal Component Analysis (PCA)) cú gi c hieu nng phòt hin gn vi mc đứng toịn b c trng hay khũng, khi s c trng gim hn 60%?
- **RQ2:** Còc mũ hõnh hc t hp (Ensemble Learning (EL)) cú mang li li th òng k so vi mũ hõnh n tt nht hay khũng, khi khòc bit c kim chng bng kim nh thng kỏ thay vớ so sònh mt ln o?
- **RQ3:** Mt pipeline IDS da trõn Spark cú kh thi v thũng lng, tr vị nng lng khi trin khai phón tòn trõn cm thit b biõn tị nguyễn hn ch (Jetson Orin Nano Super) hay khũng?

1.4 Phng phòp nghiõn cu

- **Thu thp, phón tỏch, x lý d liu:** S dng tp d liu CICIDS2017, t ú tin hịnh phón tỏch, x lý vị trc quan húa d liu.
- **Nghiõn cu v phng phòp tĩ u húa siỏu tham s, còc phng phòp gim chiu d liu:** Nghiõn cu còc phng phòp gim chiu d liu nh PCA, SHAP vị Random Forest Importance nhm gim nhieu vị tng chõnh xòc, ng thi tĩ u húa siỏu tham s thũng qua tởm kim li (Grid Search) vị kim nh chỏo (cross-validation) giũp nỏng cao hieu nng mũ hõnh. Còc bc nịy c trin khai trõn nn tng Apache Spark nhm m bo kh nng x lý d liu ln hieu qu vị m rng.

- **Nghiên cứu vị xuất mô hình học máy, học sâu (MLP; vị mô autoencoder lịm cng phòt hìn bt thng), học tập phòt hìn xóm nhp s dng Spark Machine Learning:** S dng nhieu thut toàn khòc nhau nh Decision Tree, Support Vector Machine, Logistic Regression, NB, Random Forest, GBT, XGB, MLP vị còc thut toàn học tập (ensemble) xóy dng mô hình nhm so sònh, ònh giò mô hình cú hieu nng tt nht.
- **Thực nghiệm vị ònh giò hieu nng mô hình trởc cm Jetson Orin Nano Super:** Xóy dng mô h thng phòt hìn xóm nhp mng IDS *phón tòn* trin khai trởc cm hai thit b biổn Jetson Orin Nano Super (cng phòt hìn bt thng trởc mô nửt, b phón loi PySpark trởc nửt cùn li) nhm ònh giò kh nng hot ng trong mủi trng tị nguyổn hn ch. H thng c thit k theo kin trúc x lý d liu thi gian thc, tn dng Apache Kafka cho c ch truy n ti thũng ip, Spark Streaming cho x lý lung d liu, PostgreSQL qun lý d liu, InfluxDB lu tr ch s hieu nng theo thi gian, Grafana trc quan hóa vị Mailtrap phc v kim th c ch cnh bòa qua email.

1.5 Còc ứng gúp chờnh ca tị

- **xuất gii phòp ng dng Apache Spark trong phòt hìn xóm nhp cho h thng mng IoT:** tị ò xóy dng mô mô hình phòt hìn xóm nhp đa trởc nn tng x lý d liu ln Apache Spark, tn dng kh nng x lý phón tòn vị thi gian thc ca Spark, hng ti òp ng yổu cu v hieu nng vị tòn h m rng trong mủi trng IoT cú khi lng d liu ln vị bin i liổn tc; kh nng x lý phón tòn c kim chng mc minh chng khòl nim (proof-of-concept) trởc cm thit b biổn.
- **Xóy dng quy trnh x lý vị phòt hìn xóm nhp toịn đin trởc d liu IoT:** T bc tin x lý d liu, trỏch xu t c trng, hun luy n mô hình ònh giò kt qu, tị ò thit k vị hìn thc mô quy trnh phòt hìn xóm nhp hoị n chnh cú th òp dng cho còc h thng thc t.
- **ng dng vị ònh giò còc thut toàn học máy trong mủi trng phón tòn:** tị trin khai vị so sònh hieu qu ca mô s thut toàn học máy vị mô hình học sâu MLP trởc nn tng Apache Spark MLlib (ngoị ra mô autoencoder c đứg lịm cng phòt hìn bt thng tng biổn), qua ú lịm rử u im vị hn ch ca tng mô hình trong vic x lý d liu IoT.
- **ònh giò hieu nng h thng trong mủi trng x lý phón tòn:** Khũng ch ònh giò chờnh xòc ca mô hình, tị cùn phón tòch hieu nng x lý (thi gian thc thi, kh nng m rng) ca h thng nhm kho sòt tòn h kh thi ca gii phòp; vic kim chng c thc hìn mc minh chng khòl

nim (proof-of-concept) trốn cm thit b biến vì b d liu CICIDS2017, lịm c s cho vic m rng quy mũ v sau.

- **Quy trình ònh giò loi tr rừ r d liu vị cú kim nh thng kổ:** tị nhn din vị loi b còc ngun rừ r d liu thng gp trốn CICIDS2017 (c trng `destination_port` rừ r nhõn, trúng lp lung mc c trng), ng thi òp dng kim nh ì ngha thng kổ, giúp kt qu phn ònh ững nng lc mũ hnh thay vớ còc con s b thi phng.

1.6 Cũng trnh ang chun b cũng b

Mt phn kt qu ca lun vn c phòt trin thnh hai bn tho khoa hc (vit chung vì Nguyn V Thòi, Trờ Nht vị TS. Nguyn Vn D), hin ang c hoịn thìn gi ng (cha np ti thi im hoịn thnh lun vn):

1. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.
2. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Distributed Real-Time Intrusion Detection System on a Jetson Orin Nano Super Edge Cluster using Kafka and PySpark,” Symposium on Information and Communication Technology (SOICT), 2026.

1.7 Cu trũc ca lun vn

Lun vn vì tị “PHÒT HIN XÓM NHP (IDS) DA TRỎN APACHE SPARK CHO BO MT MNG IoT” c trnh bịy bao gm 5 chng. Ni dung tóm tt tng chng c trnh bịy nh sau:

- **Chng 1: M u:** Trnh bịy tng quan v bi cnh vị lý do chn tị, mc tiổu nghiổn cu, phm vị nghiổn cu, cớu hi nghiổn cu vị phng phòp tip cn. Ngoịi ra, chng nịy cng nỏu rũ ì ngha thc tin vị khoa hc ca tị, cng nh b cc tng th ca lun vn.
- **Chng 2: C s lý thuyt:** Trnh bịy còc khòl nim c bn vị nn tng lý thuyt phc v cho tị, bao gm tng quan v mng IoT, còc l hng vị mi e da bo mt, phng phòp phòt hin xóm nhp (IDS), vị kin thc liổn quan n Apache Spark. Ngoịi ra, chng nịy cng phón tồch còc thut toòn hc mỳy thng c s dng phòt hin xóm nhp.

- **Chng 3: Phng phòp thc hin:** Trnh bỳ chi tit còc bc xóy dng h thng phòt hin xóm nhp, bao gm thu thp vỹ tin x lý d liu, thit k kin trũc h thng s dng Apache Spark, la chn vỹ trin khai còc thut toòn hc mòy, cũng quy trnh hun lun vỹ ònh giò mũ hõnh.
- **Chng 4: Thc nghim, ònh giò vỹ tho lun:** Trnh bỳ kt qu thc nghim trõn b d liu thc t hoc mũ phng, ònh giò hũu nng ca còc mũ hõnh ò trin khai theo còc tiõu chõ nh chõnh xòc, Recall, F1-score, kòch thc ca mũ hõnh vỹ thi gian x lý. ng thi, chng nỹ cng phón tòch, so sònh vỹ tho lun v còc kt qu t c nhm lĩm rũ hũu qu ca phng phòp xut.
- **Chng 5: Kt lun vỹ hng phòt trin:** Tng kt nhng kt qu chõnh mĩ tĩ t c, nõu bt nhng úng gúp chõnh, ng thi ch ra nhng hn ch cùn tn ti vỹ xut còc hng phòt trin trong tng lai, nh vỹc tòch hp còc mũ hõnh hc sỏu hoc trin khai h thng trõn nn tng òm mỏy nõng cao tòngh kh dng vỹ kh nng m rng.

Chng 2. C S LÝ THUYT

Chng này trnh bày ccc nn tng lý thuyt lión quan n tị, bao gm tng quan v Internet vn vt (IoT), ccc mi e đa an ninh trong h thng IoT, vị vai trò ca h thng phòt hin xóm nhp (IDS). Bón cnh ú, trong chng này, lun vn cng gii thiú kin trúc vị kh nng ca Apache Spark trong x lý d liú ln, ccc k thut hc mỳy ng dng trong phòt hin xóm nhp vị ccc Spark MLlib h tr xý dng mỳ hnh hc mỳy phón tòn. (Ccc nghión cu lión quan vị khong trng nghión cu ò c kho sòt Chng 1.)

2.1 Tng quan v IoT

Internet of Things (IoT) lị mng li ccc thit b vt lý c tồch hp cm bin, phn mm vị kh nng kt ni mng, cho phỏp thu thp vị trao i d liú qua Internet [22]. IoT bao gm ccc thit b nh cm bin mũi trng, thit b gia dng thũng minh vị phng tin giao thũng to ra khi lng d liú ln vị c im a dng, tc cao vị yỏu cu x lý thi gian thc. Theo bcc ccc Cisco Annual Internet Report (2018–2023), tng s thit b ni mng toin cu c d bcc t khong 29,3 t vộ nm 2023, trong ú khong mt na lị kt ni mỳy-vi-mỳy (M2M/IoT), nhn minh tm quan trng ca bo mt trong lnh vc này [23]. Kin trúc IoT thng c chia thnh ba tng:

- **Tng cm nhn:** Thu thp d liú t cm bin vị thit b.
- **Tng mng:** Truyn ti d liú qua ccc giao thc nh MQTT, CoAP hoc HTTP.
- **Tng ng dng:** Phón tồch d liú cung cp dch v [24].

Tuy nhión, ccc thit b IoT thng cú tị nguyón hn ch (b nh, nng lng, kh nng tòn h toón), dn n thcc thc trong vic trin khai ccc gii phỏp bo mt truyn thng. Ccc mi e đa nh tn cũng t chỉ dch v (DDoS), tn cũng gi mo vị khai thcc l hng giao thc ùi hi ccc gii phỏp bo mt tiỏn tin nh IDS [25].

2.2 H thng phòt hin xóm nhp (IDS)

H thng phòt hin xóm nhp (IDS) gióm sòt vị phón tồch hot ng mng hoc h thng phòt hin ccc hnh vi bt thng hoc òng ng, nhm bo v h thng khi ccc cuc tn cũng mng [26]. IDS úng vai trò quan trng trong vic m bo tòn h bo mt, toin vn vị sn sng ca h thng IoT. IDS c phón loi nh sau:

Đa trở v trở trin khai:

- **Network-based IDS (NIDS):** Giòm sòt lu lng mng phòt hin còc mu tn cũng.
- **Host-based IDS (HIDS):** Tp trung vjo hot ng ca mt thit b c th.

Da trổn phng phòp phòt hin:

- **Signature-based IDS:** S dng còc mu tn cũng ò bit, hieu qu vi còc mi e da quen thuc nhng hn ch vi còc tn cũng mi.
- **Anomaly-based IDS:** Phòt hin hnh vi bt thng da trổn mũ hnh hot ng bnh thng, phứ hp vi còc cuc tn cũng cha bit [27, 28]; còc b phòt hin da trổn hc sỏu nh autoencoder [29] hay mng nim tin sỏu (Deep Belief Network) [30] li mt hng ph bin ca nhúm nỳ.
- **Hybrid IDS:** Kt hp c hai phng phòp tng chỏnh xỏc [26].

Trong IoT, IDS phi x lý khi lng d liu ln vi ỏp ng yỏu cu thi gian thc, ng thi phứ hp vi tỳ nguyỏn hn ch ca thit b. Còc gii phòp IDS da trổn d liu ln vi hc mỳy, nh s dng Apache Spark, li hng i tim nng gii quyỏt còc thỏch thc nỳ [25].

2.3 Apache Spark vi x lý d liu ln


2.3.1 D liu ln

D liu ln (*Big Data*) li mt thut ng c s dng mũ t tp hp d liu cú quy mũ ln, phc tp vi a dng, bao gm d liu cú cu trức, d liu khũng cú cu trức vi d liu bòn cu trức n mc khũng th x lý hieu qu bng còc cũng c vi phng phòp truyn thng.

Ngỳ nay, kỏch thc ca còc tp d liu cú th c coi li d liu ln dao ng t **terabyte**, **petabyte** n **exabyte**. Khỏi nim v d liu ln s ph thuc vjo ngnh cũng nghip, cỏch d liu c s dng, lng d liu lch s liỏn quan vi nhieu c im khỏc.

D liu ln thng c nhn din thũng qua nm c im ct lủi: **Khi lng** (*Volume*), **Tc** (*Velocity*), **Tỏnh a dng** (*Variety*), **Tỏnh xỏc thc** (*Veracity*) vi **Giỏ tr** (*Value*) (Hỏnh 2.1). ỏy li nhng yu t quan trng giứp phỏn bit d liu ln vi còc loi d liu thũng thng, phn ỏnh quy mũ, tc phỏt sinh, s phong phữ v nh dng, tin cy vi tim nng khai thỏc thũng tin t d liu.

- **Khi lng (Volume):** ỏp n quy mũ d liu cc ln.
- **Tc (Velocity):** Tc d liu c to ra, truyn ti vi x lý.
- **Tỏnh a dng (Variety):** Ngun vi nh dng d liu a dng nh vn bn, hnh nh, video, v.v.



Hành 2.1. Mũ hình 5V ca d liu ln [31]

- **Tồnh xóc thc (Veracity):** Mc òng tin cy vị cht lng ca d liu.
- **Giò tr (Value):** Tim nng khai thóc thũng tin hu òch t d liu.


D liu sinh ra t còc thit b IoT c xem lị mt trong nhng ngun to ra d liu ln (BD) quan trng vị phòt trin nhanh chóng hin nay. Vì hịng t thit b cm bin, mỳ mỳc, thit b eo tay vị phng tin kt ni Internet, lng d liu c to ra mị ngịy rt ln, a dng v nh dng vị tc phòt sinh liỏn tc theo thi gian thc. D liu IoT mang y còc c im ca d liu ln nh: khi lng (volume) ln, tc (velocity) cao, tồnh a dng (variety) v loi d liu, mc xóc thc (veracity) khũng ng u vị tim nng mang li giò tr (value) ln nu c khai thóc hiu qu. Chờnh vớ vỹ, d liu IoT khũng ch lị mt phn ca d liu ln mị cùn úng vai trò quan trng trong vic thũc y nhu cu phòt trin còc nn tng x lý d liu ln hin i.

2.3.2 Còc thnh phn ca Apache Spark

Trong nhng nm gn óy, còc nn tng x lý d liu ln nh Apache Spark ò thu hũt s quan tòm rng rỏi t cng ng nghiỏn cu vị cũng nghip. Apache Spark lị mt h thng x lý d liu phón tòn quy mũ ln, cú kh nng thc thi nhanh còc tỳc v trỏn còc cm d liu ln. So vị Hadoop MapReduce, Spark cú th t tc x lý nhanh hn khong 100 ln trong mt s trng hp nh vớ kh nng x lý trong b nh (*in-memory processing*) [32, 33].

Bổn cnh ú, Spark cung cp giao đin lp trỏnh linh hot thũng qua còc API h tr nhiu ngũn ng ph bin nh Java, Scala, Python vị R, giúp vic phòt trin vị trin khai ng dng tr nõn thun tin hn.

Apache Spark bao gm nhiều thịnh phn chõnh to thịnh mt h sinh thời hoịn chnh, h tr a dng cõc tõc v phõn tõch d liu nh x lý d liu theo lũ (batch), truy vn SQL, phõn tõch lung d liu thi gian thc, hc mỳy vỹ x lý th (Hõnh 2.2).




Hõnh 2.2. Cõc thịnh phn ca Apache Spark [33]

Apache Spark bao gm nhiều thịnh phn ct lõi, mĩ thịnh phn m nhn mt chc nng c th trong quõ trõnh x lý d liu ln:

- **Spark Core:** Thịnh phn trung tõm ca Spark, chu trõch nhim qun lý b nh, lp lch, x lý li, phõn phi tõc v vỹ giao tip vỹ cõc h thng lu tr. Nũ cung cp cõc API cp cao cho Java, Scala, Python vỹ R, giữp n gin húa vỹc x lý phõn tòn.
- **MLlib:** Th vin hc mỳy tõch hp sn trong Spark [34], h tr hun luyn vỹ trin khai cõc mũ hõnh hc mỳy trõn quy mũ ln. MLlib cung cp cõc thut toõn nh phõn loi, hi quy, phõn cm, khai thõc mu vỹ lc cng tõc.
- **Spark Streaming:** Cũng c x lý d liu thi gian thc bng cõch chia lung d liu thịnh cõc lũ nh x lý tng t nh d liu theo lũ. Cũng c nỹy cho phõp s dng li mũ ngun vỹ h tr nhiu ngun d liu nh Kafka, Flume, Twitter, HDFS.
- **Spark SQL:** Thịnh phn truy vn d liu phõn tòn, h tr ngũn ng SQL tiõu chun vỹ HiveQL vỹ hiu sut cao nh ti u húa Catalyst vỹ nh dng ct. Nũ h tr nhiu ngun d liu nh JSON, Hive, Parquet, JDBC, MongoDB, Cassandra.
- **GraphX:** Th vin x lý th phõn tòn, h tr biu din, chuyn i vỹ phõn tõch d liu th. GraphX i kõm vỹ cõc thut toõn th ph bin nh PageRank, Connected Components vỹ nhiu thut toõn phõn tõch khõc.

2.3.3 Kiến trúc của Apache Spark

Kiến trúc của Apache Spark có thể được mô tả theo mô hình master-worker trở nên quen thuộc và dễ hiểu. Thành phần trung tâm là **Spark Driver**, chịu trách nhiệm điều phối và quản lý các tác vụ, bao gồm việc phân chia, phân phối và vị trí giám sát tiến trình. Driver có thể gửi các tác vụ dưới dạng đồ thị có hướng không chu trình (*DAG – Directed Acyclic Graph*) xuống các node để thực hiện; trong đó kiến trúc master-worker được minh họa trong Hình 2.3.



Hình 2.3. Sơ đồ kiến trúc hệ thống Apache Spark [32]

Các tác vụ và phân phối tài nguyên được thực hiện bởi các **Worker Nodes**, nơi chứa các **Executor** để thực hiện tiến trình thực thi. Mỗi Executor chịu trách nhiệm thực thi các tác vụ (task) và lưu trữ dữ liệu trong bộ nhớ hoặc lưu trữ. Spark sử dụng **Cluster Manager** (như YARN, Mesos hoặc Standalone) để quản lý tài nguyên và nguồn tài nguyên. Dữ liệu lưu trữ có thể là hệ thống như HDFS, S3, hoặc các dịch vụ lưu trữ khác.

2.4 Học máy trong phân tích dữ liệu

Học máy (ML) là một lĩnh vực nghiên cứu quan trọng trong việc phân tích dữ liệu để tìm kiếm các mô hình và dự đoán kết quả. Học máy được ứng dụng rộng rãi trong nhiều lĩnh vực, bao gồm IoT, xử lý ngôn ngữ tự nhiên và thị trường tài chính [35]. Các kỹ thuật học máy phổ biến bao gồm:

- **Học có giám sát (Supervised Learning):** Sử dụng dữ liệu đã được gán nhãn để huấn luyện mô hình dự đoán. Một số thuật toán phổ biến bao gồm Random Forest (RF), SVM và Mạng nơ-ron nhân tạo (Neural Networks).
- **Học không giám sát (Unsupervised Learning):** Được sử dụng để khám phá các mẫu ẩn trong dữ liệu không có nhãn, thường được áp dụng trong việc phân tích dữ liệu thị trường. K-Means là một thuật toán phổ biến trong nhóm này.

- **Hc tng cng (Reinforcement Learning):** Mũ hnh hc đa trổn phn hi t mĩ trng nhm ti u hóa hnh vi hoc quy t nh ca h thng theo thi gian; hng nịy khũng thuc phm vi thc nghim ca lun vn v i ch c nũu ho i n chnh bc tranh phn loi.

Trong bi cnh mng IoT, hc mỳy c ng dng rng rĩi phn tồch lu lng d liu v i nhn đin còc loi tn cũng nh DDoS, botnet hay gi mo gúi tin. Chng hn, Koroniotis v i cng s (2019) xóy dng b d liu Bot-IoT v i bào còc còc mũ hnh hc mỳy, hc sỏu t chỏnh xỏc gn tuyt i khi phỏt hìn còc tn cũng DoS/DDoS trong mĩ trng IoT [36]. Tuy nhiỏn, còc kt qu gn nh tuyt i (xp x 100%) trổn còc tp d liu cũng khai cn c xem xỏt thn trng, vớ chũng thng l i du hiu ca rừ r d liu (data leakage) hn l i nng lc thc s ca mũ hnh. Rừ r d liu l i tỏnh hung trong ú thũng tin l ra khũng sn cú thi im trin khai thc t l i lt v iỏ quỏ trỏnh hun luy n hoc ònh giỏ, khin im s b thi phng v i khũng phn ònh ửng kh nng tng quỏt hóa ca mũ hnh. Lun vn nịy nhn đin v i x lý vn ú mt còch tng minh Chng 4.

Tuy nhiỏn, vic ng dng hc mỳy trong h thng IoT vn cũn gp nhiu thỏch thc vớ yỏu cu x lý theo thi gian thc v i hn ch v i t i nguyỏn tỏnh toỏn. Vic tồch hp hc mỳy v i còc nn tng x lý d liu ln nh Apache Spark mang l i l i th òng k, giúp x lý khi lng d liu ln v i tc cao v i h tr trin khai còc thut toỏn hc mỳy hiu qu trong mĩ trng phn tòn.

2.4.1 Mt s thut toỏn hc mỳy

- **Cóy quy t nh (Decision Trees (DT))** l i mt trong nhng thut toỏn hc mỳy cú giỏm sỏt ph bin, c òp dng rng rĩi trong còc b i toỏn phn loi. Cu trũc c bn ca mt cóy quy t nh bao gm ba thnh phn chỏnh: **nũt gc**, **nũt quy t nh** v i **nũt lò**. Cóy quy t nh cú u im l i d hiu, d đin gii, cú th trc quan hóa v i khũng yỏu cu gi nh v phn phi d liu. Tuy nhiỏn, DT cng d b quỏ khp (*overfitting*) nu khũng chn c còc tham s hp lý hoc x lý trổn d liu nhiu [37].
- **Rng ngu nhiỏn (RF)** l i mt thut toỏn hc mỳy c s dng ph bin trong c hai b i toỏn phn loi v i hi quy. óy l i mt k thut hc t hp (*ensemble learning*) đa trổn vic xóy dng v i tng hp nhiu cóy quy t nh c lp nhm nỏng cao chỏnh xỏc v i n nh ca mũ hnh. Thut toỏn hot ng bng còch to ra nhiu cóy quy t nh trổn còc tp con khỏc nhau c chn ngu nhiỏn t tp d liu hun luy n. Mi cóy c xóy dng đa trổn mt mu bootstrap (ly mu cú ho i n l i), ng thi ti mi nũt chia, mt tp con ngu nhiỏn ca còc c trng c chn tỏm im chia tt nht, thay vớ s dng to i n b c trng nh trong cóy quy t nh truy n thng [38].

Kt qu cui cũng c xỏc nh bng còch:

- ◊ Trong bii toàn phón loi: ly kt qu theo nguyên tc a s phiu (*majority voting*) t còc cóy.
- ◊ Trong bii toàn hi quy: ly giò tr trung bnh t còc d oòn ca tng cóy.

Vic kt hp nhieu cóy giúp RF gim thiu hin tng quò khp (*overfitting*) vn li mt nhc im thng gp ca còc cóy quy t nh n l. Khi s lng cóy trong rng tng lón, hiu nng d oòn ca mĩ hnh cú xu hng n nh vị ci thín hn.

- **Hi quy logistic (Logistic Regression (LR))** li mt phng phòp thng kổ c gii thiu bi David Cox vò cui thp niõn 1950. óy li mt k thut hc mỳ cú giòm sòt thng c s dng gii quy t còc bii toàn phón loi nh phón, trong ú bin u ra (phn hi) li mt bin nh tòn, nhn giò tr 0 hoc 1. Mĩ hnh hi quy logistic cho phõp c tòn xòc sut xy ra ca mt s kin c th da trõn mt hoc nhieu bin u vò (c lp). Mt trong nhng im mn nh ca phng phòp nìy li kh nng xòc nh mc nh hng ca tng yu t n xòc sut xut hin ca kt qu, giúp còc nhì phón tòn hiu rũ hn mi quan h gia bin u vò vị u ra [39].

V mt toàn hc, hìmh hi quy logistic c biu din di dng tuyn tòn nh sau:

$$z_i = \beta_0 + \beta_1 x_{i,1} + \beta_2 x_{i,2} + \cdots + \beta_n x_{i,n} \quad (2.1)$$

Trong ú:

- ◊ $x_{i,j}$ li giò tr ca bin c lp th j ti quan sòt th i
- ◊ β_0 li h s chn (bias), β_j li h s hi quy ng vì bin x_j
- ◊ z_i li u ra tuyn tòn trc khi a qua hìmh kòch hot (sigmoid)

Sau ú, xòc sut xy ra ca s kin c tòn thũng qua hìmh logistic (sigmoid):

$$P(Y_i = 1 \mid \mathbf{x}_i) = \frac{1}{1 + e^{-z_i}} \quad (2.2)$$

Trong quò trnh hun luy, mĩ hnh tòm còc h s β_j ti u sao cho hìmh mt mòt (cross-entropy loss) c ti thiu hóa.

- **GBT** li mt phng phòp *boosting* (kt hp tun t còc mĩ hnh hc yu; lu ý phón bit vì “hc tng cng” – reinforcement learning) s dng còc cóy quy t nh nh mĩ hnh hc yu (weak learners). Ý tng chònh ca boosting li xóy dng mt mĩ hnh mn nh bng còch kt hp nhieu

mũ hnh hc yu c hun luyt theo trnh t tun t. mĩ bc, thut toũn c gng gĩm thiu li ca mũ hnh trc bng cõch hc t phn d (residual) hoc gradient ca hĩm mt mĩt [40]. Quũ trnh hun luyt GBT gm cõc bc:

- ◊ Bt u vi mt mũ hnh d oũn ban u (thng lĩ giũ tr trung bũnh vi bĩi toũn hi quy).
- ◊ Tũnh toũn sai s cũn li gia nhũn thc vi d oũn.
- ◊ Hun luyt mt cĩy quyť nh d oũn phn d.
- ◊ Cp nht mũ hnh tng bng cõch cng mũ hnh hĩn ti vi mũ hnh mĩ nhũn vi mt h s hc η (learning rate).

Gi s $F_0(x)$ lĩ mũ hnh khi to ban u, mũ hnh tng ti bc m c cp nht theo cũng thc:

$$F_m(x) = F_{m-1}(x) + \eta \cdot h_m(x) \quad (2.3)$$

Trong ỳ:

- ◊ $h_m(x)$ lĩ cĩy quyť nh th m hc theo gradient ca hĩm mt mĩt.
 - ◊ η lĩ h s hc (learning rate), thng $\eta \in (0, 1)$.
- **LightGBM (LGBM)** lĩ mt framework trin khai thut toũn GBT, c phĩt trin nhĩm ti u hĩa tc hun luyt vi kh nng m rng trũn cõc tĩp d liũ ln [41], vi cũng s cp nht boosting theo gradient õ trnh bĩi mc GBT phĩa trũn. Khũc vi GBT truyn thng, LGBM s dng c ch phĩt trin cĩy theo hng leaf-wise thay vĩ level-wise, ng thi òp dng thut toũn histogram-based splitting vi k thut Gradient-based One-Side Sampling (GOSS) nhĩm gĩm chi phĩ tũnh toũn vi tng tc hun luyt. Tuy nhiũn, LGBM *khũng* c a vĩo b thut toũn so sũnh thc nghiĩm vĩ lý do tng thũch phn cng trnh bĩi Chng 3; XGBoost vi GBT i dĩn cho h gradient boosting.
 - **NB** lĩ mt phng phĩp phĩn loi xũc sut da trũn nh lý Bayes vi gĩ nh c lp cú iũ kin gia cõc c trng [42]. Mc dĩĩ gĩ nh nĩy thng khũng hoĩn toĩn ỹĩng trong thc t, mũ hnh vĩn cho hĩu qu tĩt trong nhiũ bĩi toũn phĩn loi d liũ nhiũ chiũ.

Theo nh lý Bayes:

$$P(y|x) = \frac{P(x|y)P(y)}{P(x)} \quad (2.4)$$

Vì giả định độc lập giữa các biến:

$$P(x|y) = \prod_{i=1}^n P(x_i|y) \quad (2.5)$$

Mô hình lựa chọn lập luận xác suất hợp lý nhất:

$$\hat{y} = \arg \max_y P(y) \prod_{i=1}^n P(x_i|y) \quad (2.6)$$

Ưu điểm của NB là tính đơn giản, tốc độ huấn luyện nhanh và phù hợp với dữ liệu kích thước lớn; tuy nhiên, hạn chế chính là mô hình giả định độc lập giữa các biến.

- **Support Vector Machine (SVM)** là một thuật toán học có giám sát do Cortes và Vapnik [43], nhằm tìm siêu phẳng tối ưu phân tách dữ liệu và không có biên (margin) nhỏ nhất.

Trong trường hợp dữ liệu tuyến tính, bài toán tối ưu có thể diễn tả như sau:

$$\min_{w,b} \frac{1}{2} \|w\|^2 \quad (2.7)$$

với điều kiện:

$$y_i(w \cdot x_i + b) \geq 1 \quad (2.8)$$

Trong trường hợp dữ liệu không tuyến tính, SVM sử dụng kỹ thuật *kernel trick* để ánh xạ dữ liệu sang không gian nhiều chiều hơn, cho phép phân tách tuyến tính trong không gian mới. Nhờ cách tối ưu hóa chặt chẽ, SVM thường đạt hiệu suất cao trong các bài toán phân loại dữ liệu nhiều chiều.

- **Multilayer Perceptron - MLP** là một mô hình học sâu có cấu trúc gồm nhiều lớp nơ-ron, có khả năng mô hình hóa các mối quan hệ phi tuyến giữa các biến [44].

Mô-đun trong mạng thần kinh phổ biến nhất là:

$$z = w^T x + b \quad (2.9)$$

sau đó áp dụng hàm kích hoạt phi tuyến:

$$a = \sigma(z) \quad (2.10)$$

Trong ú $\sigma(\cdot)$ cú th lị còc hịm kòch hot nh sigmoid, tanh hoc ReLU. Quò tróh hun luyn s dng thut toòn lan truyn ngc (*backpropagation*) nhm cp nht trng s thũng qua ti thiú hóa hịm mt mòt bng gradient descent. MLP cú kh nng biu đin mnh nhng yỏu cu đ liú hun luyn ln vị quò tróh iú chnh siỏu tham s cn thn trỏh hìn tng quò khp.

- **XGB** lị mt phiỏn bn ci tin ca thut toòn GBT truyn thng, c xut bi Chen vị Guestrin vịo nm 2016. XGB c thit k ti ú hóa tc hun luyn, hiu nng mũ hỏnh, vị kh nng x lý đ liú quy mũ ln trong còc h thng tỏnh toòn phỏn tòn [45]. XGB s dng còc chin lc sau ci thfin hiu nng:

- ◇ Khai thỏc gradient vị Hessian ti ú hóa hiu qu (second-order optimization).
- ◇ Ct ta cóy (pruning) theo phc tp thay vớ sỏu c nh.
- ◇ Tỏnh song song trong vớic tỏm im chia ti ú (split finding).
- ◇ H tr x lý thiú giò tr (missing values) t ng.

Mũ hỏnh XGB ỏ c ng dng thfin cũng trong nhiú bậi toòn hc mỳy thc t nh đ bởo tậi chỏnh, chn oỏn y t, phỏt hìn gian ln vị phỏn tỏch hịnh vị khỏch hịng, nh chỏnh xỏc cao vị hiu qu tỏnh toòn tt.

2.4.2 Mt s thut toòn hc t hp

Hc t hp (Ensemble Learning, EL) lị mt k thut trong hc mỳy nhm kt hp nhiú mũ hỏnh riỏng l nỏng cao chỏnh xỏc vị n nh trong đ oỏn. Thay vớ ch đa vịo mt mũ hỏnh n l, phng phỏp EL tn dng sc mnh tng hp ca nhiú mũ hỏnh (vớ đ DT, RF, LR) xỏy dng mt h thng đ oỏn chỏnh xỏc hn. Nguyỏn lý ct lủi ca EL lị: mĩ mũ hỏnh riỏng l cú th ch t chỏnh xỏc thp hoc đ oỏn sai mt s trng hp, nhng s kt hp hp lý ca cũng cú th gim thiú sai s, tng chỏnh xỏc nh tn dng im mnh vị khc phc im yu ca tng mũ hỏnh thfin phn [46].

K thut EL ỏ chng mnh c tỏnh hiu qu cao trong nhiú lnh vc yỏu cu chỏnh xỏc cao nh: phỏt hìn gian ln, phỏn tỏch đ liú ln, nhn đin hỏnh nh vị x lý ngũn ng t nhiỏn. Trong lnh vc bo mt mng IoT, EL cng c ng dng ci thfin kh nng phỏt hìn bt thng hoc xỏm nhp đa trỏn nhiú mũ hỏnh hc mỳy c hun luyn song song hoc tun t.

Mt s phng phỏp ph bin ca EL bao gm:

- **Voting:** Vì bị toàn phần lỗi, mô hình con bỏ phiếu cho một lớp vị lớp cụ thể phiếu cao nhất sẽ ra cuối cùng (a sẽ phiếu học trung bình xấp xỉ). Các bước của voting có mô tả chi tiết Thuật toán 1.
- **Boosting:** Huấn luyện các mô hình tuần tự, trong đó mô hình mới tập trung vào các mẫu mà mô hình trước đã đoán sai (ví dụ: GBT, AdaBoost, XGB). Các bước của boosting có mô tả chi tiết Thuật toán 2.
- **Bagging (Bootstrap Aggregating):** Huấn luyện nhiều mô hình trên các tập con ngẫu nhiên (lấy mẫu có hoàn lại) của tập dữ liệu gốc, sau đó tổng hợp kết quả đoán (ví dụ: Random Forest). Các bước của bagging có mô tả chi tiết Thuật toán 3.

EL có thể được sử dụng trong các hệ thống phát hiện xâm nhập (IDS) với các phần tử học để phân tích dữ liệu phức tạp, việc kết hợp nhiều mô hình có thể giúp tăng khả năng phát hiện các gói tin bất thường mà mô hình đơn lẻ có thể bỏ sót.

Thuật toán 1. Voting: Kết hợp đoán từ nhiều mô hình phần lỗi

u vào:

- Tập huấn luyện $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- Tập mô hình phần lỗi có $M_1, M_2, \dots, M_K$
- Kiểu voting: HARD hoặc SOFT

u ra: Nhãn đoán cuối cùng y_{vote} cho dữ liệu x

```

1: Khi to: danh sách  $S = \{\}$  ▷ Lu đoán học xấp xỉ
2: if voting = HARD then
3:   for  $j = 1$  to  $K$  do
4:      $y_j \leftarrow M_j(x)$  ▷ D đoán nhãn của mô hình thứ  $j$ 
5:     Thêm  $y_j$  vào  $S$ 
6:   end for
7:    $y_{\text{vote}} \leftarrow$  nhãn xuất hiện nhiều nhất trong  $S$ 
8: else if voting = SOFT then
9:   Khi nào xấp xỉ tng  $P_{\text{sum}}[c] = 0, \forall c \in \{1, \dots, C\}$ 
10:  for  $j = 1$  to  $K$  do
11:    Ly xấp xỉ  $P_j(y = c | x)$  t mô hình  $M_j$ 
12:    for mỗi  $c = 1$  to  $C$  do
13:       $P_{\text{sum}}[c] \leftarrow P_{\text{sum}}[c] + P_j(y = c | x)$ 
14:    end for
15:  end for
16:   $y_{\text{vote}} \leftarrow \arg \max_c P_{\text{sum}}[c]$ 
17: end if
18: return  $y_{\text{vote}}$ 

```

Thut toàn 2. Boosting: Kt hp tun t còc mũ hnh hc yu

u vïo:

- Tp d liu hun luy $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$
- S lng vùng lp (mũ hnh yu): T

u ra: Mũ hnh boosting $F_T(x)$

- 1: **Khi to:** $F_0(x) \leftarrow 0$ ▷ Mũ hnh khi u cú th lị 0 hoc d oòn trung bnh
 - 2: **for** $t = 1$ to T **do**
 - 3: Tõnh gi-phn-d (pseudo-residuals) theo gradient óm ca hịm mt môt: $r_i^{(t)} = - \left[\frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F=F_{t-1}}$ ▷ Vi mt môt bnh phng (hì quy), rĩt gn thnh $y_i - F_{t-1}(x_i)$;
vi phón loi dũng log-loss
 - 4: Hun luy mũ hnh yu $h_t(x)$ trở còc gi-phn-d $r_i^{(t)}$
 - 5: Cp nht mũ hnh: $F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$
 - 6: **end for**
 - 7: **return** $F_T(x)$
-

Thut toàn 3. Bagging: Bootstrap Aggregating

u vïo:


- Tp hun luy $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$, vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (tng quòt: C lp)
- S lng mũ hnh c s: K

u ra: D oòn cui cũng y_{bag} cho mt im d liu x

- 1: **Khi to:** Danh sòch mũ hnh $M_1, M_2, \dots, M_K$
 - 2: **for** $k = 1$ to K **do**
 - 3: To mu bootstrap $\mathcal{D}^{(k)}$ t $\mathcal{D}$ (ly mu ngu nhiõn cú hoịn li)
 - 4: Hun luy mũ hnh $M_k \leftarrow \text{Train}(\mathcal{D}^{(k)})$
 - 5: **end for**
 - 6: **Khi to:** Danh sòch d oòn $Y = \{\}$
 - 7: **for** $k = 1$ to K **do**
 - 8: Thc hìn d oòn $y_k \leftarrow M_k(x)$
 - 9: Thõm y_k vïo Y
 - 10: **end for**
 - 11: Tõnh $y_{\text{bag}} \leftarrow \text{Voting}(Y)$ ▷ Hard voting hoc trung bnh xòc sut nu dũng soft
 - 12: **return** y_{bag}
-

Chng 3. PHNG PHÒP THC HIN

Trong chng nỳ, lun vn s trnh bỳ phng phòp xut xóy dng mũ hnh phòt hin xóm nhp da trón Apache Spark cho bo mt mng IoT. Quò trnh thc hin bao gm 6 bc chònh, c th hin qua Hnh 3.1: (1) Thu thp d liu v tin x lý; (2) Xóy dng c trng v la chn c trng; (3) Hun luy n mũ hnh; (4) ònh giò mũ hnh; (5) Ti u sióu tham s; v (6) Trin khai bióu thi gian thc. Còc bc (1)(5) c lp li tng ng v tng phng phòp la chn c trng (Random Forest Importance (RFI), SHAP, PCA), sau ú la chn mũ hnh tt nht trin khai trón thit b bióu.



Hnh 3.1. Quy trnh tng th hun luy n, ònh giò v trin khai mũ hnh xut

3.1 Thu thp d liu v tin x lý

Trong nghióu cu nỳ, tp d liu c s dng l CICIDS2017 c phòt hnh bi Vin An ninh mng Canada (CIC). Tp d liu nỳ c xóy dng nhm mũ phng lu lng mng thc t kt hp v nhieu loi tn cũng mng hin i, phc v cho vic hun luy n v ònh giò còc mũ hnh phòt hin xóm nhp. Tp d liu CICIDS2017 tp trung vò còc kch bn tn cũng n l trong mũi trng kim soòt. Thũng tin chi tit v tp d liu c trnh bỳ trong Bng 3.1.

Bổn cnh CICIDS2017 (b d liu chònh cho toón b còc thờ nghióu), lun vn s dng thỏm **CSE-CIC-IDS2018** cho thờ nghióu *tng quòt hóa lióu b d liu* (Mc 4.2.8.1): hun luy n trón mt b, kim tra trón b kia v ngc li. óy l b k nhim ca CICIDS2017, do CIC phi hp v C quan

Bng 3.1. Mũ t b d liu CICIDS2017

Thuc tòn	Giò tr
T chc phòt hình	Canadian Institute for Cybersecurity (CIC)
Thi gian phòt hình	2017
Giao thc mng	HTTP, HTTPS, FTP, SSH, DNS, ...
S lng bn ghi (CSV)	Hn 2.8 triu bn ghi
Thi gian thu thp	03/07/2017 07/07/2017
Loi tn cũng mũ phng	DoS, DDoS, PortScan, Brute-force, Infiltration, Botnet, ...
S loi nhõn	15 (1 nhõn bõnh thng + 14 loi tn cũng)
nh dng d liu	CSV
Mc òch	Phòt hìn xóm nhp mng trong mũi trng thc t gi lp
Ngun d liu	[47]

An ninh Truyền thữg Canada (CSE) thu thp trõn h tng AWS quy mũ ln hn nhiu; c trng lung c trõch bng CICFlowMeter phiõn bn mi hn nõn tõn ct c ònh x v danh mc tõn ct chun ca CICIDS2017 qua bng bờ danh tng minh trong mũ ngun. Thữg tin chi tit Bng 3.2.

Bng 3.2. Mũ t b d liu CSE-CIC-IDS2018 (dữg cho thờ ngừim liõn b d liu)

Thuc tòn	Giò tr
T chc phòt hình	CIC phi hp CSE (Communications Security Establishment)
Thi gian phòt hình	2018
H tng thu thp	Testbed trõn AWS (~450 mỳ nn nhõn, 50 mỳ tn cũng)
S lng bn ghi (CSV)	~16,2 triu lung (10 tp CSV theo ngỳ)
Thi gian thu thp	14/02/2018 – 02/03/2018
Loi tn cũng mũ phng	DDoS (HOIC, LOIC-HTTP/UDP), DoS (Hulk, GoldenEye, Slowloris, SlowHTTPTest), Bot, Brute-force (SSH, FTP, Web, XSS), SQL Injection, Infiltration
S loi nhõn	15 (1 nhõn bõnh thng + 14 loi tn cũng)
Phõn b nh phõn (sau lịm sch)	~13,35 triu Benign / ~2,35 triu Attack
Phn dửg trong lun vn	Mu phõn tng theo nhõn 20% (seed=42), cùn ~2,39 triu lung sau kh trửg lp mc c trng
nh dng d liu	CSV (CICFlowMeter v3; tõn ct ònh x v chun CICIDS2017)
Ngun d liu	[48]

Tin x lý d liu Vic tin x lý d liu nhm loi b nhieu, giò tr ngoi l vị giò tr b thiu c thc hin trc khi a d liu vjo hun luyn mĩ hnh. Còc k thut c òp dng gm chun hóa tổn ct, cn chnh lc gia còc tp, thay th giò tr vũ cứng, loi b bn ghi trứng lp/thiu, vị gòn nhõn nh phón (BENIGN = 0, Attack = 1).

Bổn cnh ú, bo m kt qu ònh giò phn ònh ững nng lc mĩ hnh, lun vn òp dng thõm hai bc *loi tr rừ r d liu* (loi cm by “data snooping” c xem li ph bin nht ca hc mỳy trong an ninh [49]) ngay trong giai on tin x lý, trc khi phón chia tp: (i) **loi c trng rừ r nhõn** destination_port (vị source_port nu cú) vớ trong CICIDS2017, mi loi tn cũng c sinh nhm vjo nhng cng dch v c nh nỏn cng òch gn nh mĩ hóa trc tip nhõn, khin mĩ hnh “ghi nh” ònh x cng–nhõn thay vớ hc hnh vi lung (ct protocol cng c loi vi lý do tng t: óy li bin phón loi cú òt mc giò tr, tng quan mn nh vi cng dch v nỏn mang cứng nguy c “li tt” nh danh dch v thay vớ hnh vi); vị (ii) **loi b trứng lp mc c trng theo c ch tt nh** còc lung c gom nhúm theo tojñ b vector c trng; vị nhúm cú nhõn nht quòn, gi li ững mt i ðin; vị nhúm trứng c trng nhng *móu thun nhõn* (cứng vector c trng, nhõn va Benign va Attack, mt li gòn nhõn ò c ghi nhn ca CICIDS2017 [50]), *tojñ b nhúm b loi* vớ khũng th xòc nh nhõn ững, thay vớ gi li mt hịng tũy ý theo phón mn nh d liu (vn khũng tòi lp c gia còc ln chy); s nhúm vị s hịng xung t nhõn c ghi log tng mn nh (270 nhúm, 44.260 hịng). C ch nịy trờnh vic cứng mt mu xut hin c tp hun luyn ln kim tra khi phón chia ngu nhõn. i vị tp d liu CICIDS2017, quò trờnh tin x lý d liu c th hin chi tit Thut toòn 4. Cn tha nhn rng bc loi b trứng lp mc c trng lịm thay i *phón b lp*: do còc lung benign trứng lp nhieu hn nỏn b loi nhieu hn, khin t l benign/attack sau khi x lý khòc vị t l ban u; vớ vy phón b lp trc vị sau khi loi trứng lp c bõo cào tng mn nh bo m mn nh bch.

Phón chia tp d liu

Tp d liu CICIDS2017 c phón chia theo t l 80/20 cho hun luyn vị kim tra bng phỏp chia ngu nhõn (random split) vị seed c nh (=42) m bo tòi lp. Còc ch s hiu nng c **cũng b trởn tp kim tra** (tp gi li cui cứng, khũng tham gia hun luyn, xp hng c trng hay tnh chnh siỏu tham s); kt qu trởn tp hun luyn ch c ðứng chn oòn hin tng quò khp (overfitting) hoc thiu khp (underfitting). òng lu ý, StandardScaler, PCA vị vic xp hng c trng (RF Importance, SHAP) u c *fit ch trởn tp hun luyn* D_{train} ri *transform* lỏn tp kim tra, nhm trờnh rừ r thũng tin t tp kim tra vjo quò trờnh hun luyn. Riỏng vic **chn Top-3 mĩ hnh thnh phn** cho còc ensemble (cng nh vic chn mĩ hnh i ðin mi phng phỏp vị cp phng phỏp a vjo kim nh thng kỏ, Chng 4) c thc hin trởn mt *tp kim nh (validation)* tỏch t tp hun luyn (theo t l 80/20, seed=42, còc mĩ hnh c s hun luyn trởn phn cùn li); nh vy tp kim tra hojñ tojñ khũng

Thut toà 4. Thut toà Tin x lý D liu CICIDS2017

u vò: Tp N tp CSV t b d liu CICIDS2017: $\{F_1, F_2, \dots, F_N\}$

T l phón chia hun luy/kim tra $\alpha = 0.8$

u ra: Tp hun luy D_{train} vị tp kim tra D_{test} nh dng Parquet

```

1: Bc 1: Gp d liu t nhiu tp CSV
2:  $D \leftarrow \emptyset$ 
3: for  $i = 1$  to  $N$  do
4:   c tp  $F_i$  thịnh DataFrame  $df_i$  vì lc suy lun t ng
5:   CLEANCOLUMNAMES( $df_i$ )    ▷ Chun hóa tổn ct: xóa khong trng, chuy ch thng
6:   HANDLEINFINITYVALUES( $df_i$ )    ▷ Thay th  $\pm\infty$  bng giò tr NaN
7:   if  $D = \emptyset$  then
8:      $\mathcal{S} \leftarrow \text{Schema}(df_i)$     ▷ Lu lc chun t tp u tổn
9:      $D \leftarrow df_i$ 
10:  else
11:    ALIGNSCHEMA( $df_i, \mathcal{S}$ )    ▷ Cn chnh lc v chun  $\mathcal{S}$ 
12:     $D \leftarrow D \cup df_i$     ▷ Gp theo tổn ct (unionByName)
13:  end if
14: end for
15: Bc 2: Lm sch d liu
16:  $D \leftarrow \text{RemoveDuplicates}(D)$  ▷ Loi b còc bn ghi trng lp hoìn toìn (gìng ht trỏn mĩ ct)
17:  $D \leftarrow \text{RemoveNulls}(D)$     ▷ Loi b còc bn ghi cha giò tr null/NaN
18: Bc 3: To nhõn nh phón
19:  $\forall (x_i, \text{label}_i) \in D : y_i \leftarrow \begin{cases} 0 & \text{nu } \text{label}_i = \text{"BENIGN"} \\ 1 & \text{ngc li (Attack)} \end{cases}$ 
20: Bc 4: Xòc nh còc c trng s (õ loi tr rù r)
21:  $\mathcal{C}_{\text{exclude}} \leftarrow \{\text{label, label\_binary, source\_ip, destination\_ip, flow\_id, timestamp, protocol,}$ 
    $\text{destination\_port, source\_port}\}$     ▷ Loi b c trng góy rù r nhõn
22:  $\mathcal{F} \leftarrow \{c \in \text{columns}(D) \mid c \notin \mathcal{C}_{\text{exclude}} \wedge \text{dtype}(c) \in \{\text{double, float, int, bigint}\}\}$ 
23: Bc 4b: Loi b trng lp mc c trng (tt nh)
24:  $G \leftarrow \text{GroupBy}(D, \mathcal{F})$     ▷ Gom nhúm theo toìn b vector c trng
25: for mĩ nhúm  $g \in G$  do
26:   if  $|\{y_i : (x_i, y_i) \in g\}| > 1$  then    ▷ Nhúm móu thun nhõn (Benign ln Attack)
27:     Loi toìn b nhúm  $g$  khi  $D$ ; ghi log s nhúm/hìng xung t
28:   else
29:     Gi li ỹng mĩ i ãin ca  $g$  (th t tt nh theo nhõn)
30:   end if
31: end for
32: Bc 5: Phón chia vị lu tr
33:  $D_{\text{train}}, D_{\text{test}} \leftarrow \text{RandomSplit}(D, [\alpha, 1 - \alpha], \text{seed} = 42)$ 
34: Lu  $D_{\text{train}}, D_{\text{test}}$  ãi nh dng Parquet
35: return  $D_{\text{train}}, D_{\text{test}}$ 

```

tham gia vïo khóu la chn mĩ hnh, khĩp kờn nguy c rừ r chn lc.

3.2 La chn c trng vï gim chiu d liu

Trong quỏ trnh tin x lý d liu cho bị toỏn phỏt hin xỏm nhp mng, la chn c trng bao gm **chn c trng vï trỏch xut c trng** lĩ mt bc quan trng nhm gim chiu d liu, loi b nhng c trng khĩng ỏn thit, vï ci thĩn hĩu nng ca mĩ hnh hc mỳy [51]. D liu s c gom vïo vector c trng bng `VectorAssembler` (khong 78 c trng s trc khi loi ỏng; s c trng chờnh xỏc sau khi loi `destination_port/source_port` lĩ 77) vï c chun hĩa bng `StandardScaler` (chun hĩa Z-score). Ba phng phỏp c s ỏng trong lun vn lĩ *RF*, *SHAP* vĩ *PCA*.

- a) **Principal Component Analysis (PCA)**: Lĩ phng phỏp gim chiu d liu khĩng giỏm sỏt, nhm bin i tĩp c trng ban u thĩnh mt tĩp cỏc thĩnh phn chờnh (principal components) mi khĩng tng quan tuyn tờnh vi nhau vĩ gi lĩ phn ln phng sai ca d liu. PCA thc hin bng cỏch tỏnh ma trũn hip phng sai vĩ tỏm cỏc vector riỏng (eigenvectors) tng ng vĩ cỏc giỏ tr riỏng (eigenvalues). Cỏc thĩnh phn chờnh c xỏc nh bng cỏch giũ bị toỏn:

$$Cv = \lambda v \quad (3.1)$$

Trong ú:

- C lĩ ma trũn hip phng sai ca d liu.
- v lĩ vector riỏng (principal component).
- λ lĩ giỏ tr riỏng, biu th lng phng sai c giũ thờch.

Cỏc thĩnh phn chờnh cú giỏ tr riỏng ln nht s c la chn to thĩnh khĩng gian c trng mi vĩ s chiu thp hn nhng vn gi c phn ln thũng tin ca d liu. óy lĩ phng phỏp c s ỏng ph bin trong phỏn tỏch d liu a bin vĩ hc mỳy gim chiu, loi b nhĩu vĩ trc quan hĩa d liu [52].

- b) **SHapley Additive exPlanations (SHAP)**: Lĩ phng phỏp giũ thờch mĩ hnh da trỏn lĩ thuyt trũ chi, đũng o lng mc úng gúp ca tng c trng vïo d oỏn ca mĩ hnh. SHAP tỏnh giỏ tr Shapley cho mi c trng bng cỏch xỏt trung bnh úng gúp biỏn ca c trng ú trỏn tt c cỏc tĩp con cú th:

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f(S \cup \{i\}) - f(S)] \quad (3.2)$$

Trong ú:

- F lị tp tt c còc c trng.
- S lị tp con ca còc c trng khũng cha i .
- $f(S)$ lị giò tr d oòn ca mĩ hnh khi ch s dng tp c trng S .
- ϕ_i lị mc úng gúp ca c trng i vjo kt qu d oòn.

Còc c trng cú giò tr SHAP ln (theo ln tuyt i) c xem lị cú nh hng quan trng hn n quytnh ca mĩ hnh. Phng phòp nịy c ng dng rng rũi trong gii thờch mĩ hnh phc tp nh XGBoost, Random Forest, vj mng n-ron [53].

- c) **Random Forest Feature Importance:** Thut toòn RF cú kh nng ònh giò tm quan trng ca tng c trng da trũn mc úng gúp vjo vic gim bt thun (impurity) ti còc nũt phón chia ca cóy quytnh. quan trng $I(f_j)$ ca c trng f_j c tòn nh sau:

$$I(f_j) = \frac{1}{T} \sum_{t=1}^T \sum_{n \in N_t(f_j)} \Delta i(n) \quad (3.3)$$

Trong ú:

- T lị s lng cóy trong rng.
- $N_t(f_j)$ lị tp còc nũt trong cóy t s dng c trng f_j phón chia.
- $\Delta i(n)$ lị lng gim bt thun (vở d: Gini hoc Entropy) ti nũt n .

Còc c trng cú quan trng cao hn s c u tiỏn la chn a vjo mĩ hnh hun luytn. Sau khi hun luytn mĩ hnh RF, còc c trng cú giò tr quan trng thp hn mt ngng nh trc s b loi b, gi li nhng c trng cú nh hng ln n vic phón loi.

3.3 Hun luytn mĩ hnh

3.3.1 Hun luytn còc mĩ hnh c s

Tòm thut toòn phón loi cú giòm sỏt c hun luytn c lp trũn tp c trng ò qua bc xóy dng vj la chn c trng. Bng 3.3 lit kỏ còc thut toòn cũng thũng tin chi tit v bin th vj phng phòp hc.

òng lu ý, LightGBM (mt th vin gradient boosting ph bin) *khũng* c a vjo danh sỏch trũn vò th vin gc (native, thũng qua SynapseML) ch h tr kin trũc x86_64, khũng chy c trũn thit b

Bng 3.3. Tòm b phón loi c s c s dng trong pipeline

Thut toàn	Bìn th / Ghi chữ	Phng phòp hc
Decision Tree	CART	Phón chia quy theo Gini / Entropy
Logistic Regression	Chun hóa L2	Ti u hịm mt môt logistic
Linear SVM	SVC tuyn tồnh	Ti a hóa biổn phón loi
Naive Bayes	Phón phi Gaussian	c lng xóc sut hu nghim
Random Forest	Bagging	T hp cóy quy nh ngu nhiổn
GBT	Gradient Boosting	Ti thiu hóa hịm mt môt theo gradient
XGBoost	Gradient Boosting ti u	Regularised Gradient Boosting
MLP	Mng n-ron nhón to	Lan trun ngc (Backpropagation)

biổn Jetson Orin Nano Super (ARM64), vn lị mc tiổ trìn khai ca nghiổn cu; XGBoost v GBT ỗ i din y cho h gradient boosting.

X lý mt cón bng lp. Do t l Benign/Attack lch nhau ồng k, sòu mữ hnh MLlib (Decision Tree, Logistic Regression, Linear SVC, Random Forest, GBT, Naive Bayes) c hun luyn vi trng s lp (`weightCol`) t theo t l nghch ca tn sut lp benign/attack; XGBoost dúng tham s `scale_pos_weight` vi vai trù tng ng. Riổng MLP lị ngoi l khũng ồp trng s lp do API `MultilayerPerceptronClassifier` ca Spark MLlib khũng h tr `weightCol`. Sau khi hun luyn, tòm mữ hnh c xp hng theo chiu gim dn ca F1-Score trổn tp kim nh (validation, tồch t tp hun luyn, xem mc Phón chia tp d liu) xóc nh top-3 mữ hnh tt nht phc v bc kt hp ensemble tip theo; tp kim tra hoịn toịn khũng c s dng bc chn mữ hnh nịy nhm trồnh rù r chn lc (selection leakage).

3.3.2 Còc phng phòp Ensemble Learning

Bng 3.4. Còc phng phòp hc t hp (ensemble) s dng trong lun vn

Phng phòp	Mũ t chỉ tit
Hybrid Bagging	Top-3 mũ hnh kt hp theo s (3-2-2) sub-samples vì <i>Weighted Soft Voting</i> d oòn xòc sut cú trng s
Soft Voting	Trung bnh xòc sut Top-3 mũ hnh theo F1-Score Nhõn <i>Attack</i> nu xòc sut trung bnh $\geq 0,5$

a) Òp dng Voting

Sau khi hoịn tt giai on hun luy n mũ hnh, lun vn tin hnh xóy dng mũ hnh ensemble da trõn k thut Voting nóng cao chõnh xòc vị tõnh n nh ca h thng phón loi; hai phng phòp t hp c s dng c túm tt trong Bng 3.4. C th, ba mũ hnh phón loi nh phón cú ch s F1-Score cao nh t giai on trc s c la chn tham gia vò quò trõnh ensemble.

Mi mũ hnh trong tp c chn s a ra d oòn c lp cho tng mu trong tp kim tra. Còc d oòn nìy sau ú c tng hp thũng qua c ch bu chn. Trong trng hp Soft Voting, xòc sut d oòn lp *Attack* ca còc mũ hnh thnh phn c ly trung bnh; mu c gòn nhõn *Attack* nu xòc sut trung bnh t t 0,5 tr lõn, ngc li c gòn nhõn *Benign*.

Vic òp dng k thut Voting cho phõp khai thòc s a dng gia còc mũ hnh hc c s, t ú gim sai s do thiõn lch ca tng mũ hnh riõng l vị ci thìn kh nng tng quò húa trõn d liu cha tng thy. Nh c ch kt hp nìy, h thng cú th nóng cao hìu nng tng th trong vic phòt hìn vị phón loi chõnh xòc còc hình vì xóm nhp mng. Quy trõnh chỉ tit c trõnh bìy trong Thut toà 5.

Thut toòn 5. Thut toòn Soft Voting Ensemble

u vò: Tp d liu hun luy $D = \{(x_i, y_i)\}_{i=1}^n$ vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$
 Tp kim nh D_{val} (tòch t D , đứng xp hng vị chn mũ hnh thnh phn)
 Tp d liu kim tra $D_{\text{test}} = \{(x_j)\}_{j=1}^m$
 Tp K thut toòn hc c s khòc loi $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

u ra: Nhòn d oòn cui cng $y_{\text{vote}} \in \{0, 1\}$ cho mi mu

- 1: **Bc 1: Hun luy vị ònh giò K mũ hnh c s**
- 2: **for** $k = 1$ to K **do**
- 3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Hun luy trón phn train lủ, tòch khi D_{val}
- 4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tònh im F1 trón tp kim nh (validation), khng chm tp kim tra
- 5: **end for**
- 6: **Bc 2: Chn Top-3 mũ hnh cú F1 cao nht**
- 7: Sp xp $\{M_1, \dots, M_K\}$ theo F_k gim dn
- 8: Chn 3 mũ hnh tt nht: $\mathcal{S} = \{M^{(1)}, M^{(2)}, M^{(3)}\}$ vi $F^{(1)} \geq F^{(2)} \geq F^{(3)}$
- 9: **Bc 3: Thu thp xòc sut d oòn t 3 mũ hnh c chn**
- 10: **for** mi mu $x_j \in D_{\text{test}}$ **do**
- 11: **for** mi $M^{(s)} \in \mathcal{S}$, $s = 1, 2, 3$ **do**
- 12: $p_s^{(j)} \leftarrow P^{(s)}(y = 1 \mid x_j)$ ▷ Xòc sut lp Attack t mũ hnh $M^{(s)}$
- 13: **end for**
- 14: **end for**
- 15: **Bc 4: Kt hp bng bu chn mm (Soft Voting)**
- 16: **for** mi mu $x_j \in D_{\text{test}}$ **do**
- 17: $\bar{p}_j \leftarrow \frac{1}{3} \sum_{s=1}^3 p_s^{(j)}$ ▷ Trung bnh xòc sut lp Attack
- 18: **if** $\bar{p}_j \geq 0.5$ **then**
- 19: $y_{\text{vote}}^{(j)} \leftarrow 1$ ▷ D oòn: Attack
- 20: **else**
- 21: $y_{\text{vote}}^{(j)} \leftarrow 0$ ▷ D oòn: Benign
- 22: **end if**
- 23: **end for**
- 24: **return** $\{y_{\text{vote}}^{(j)}\}_{j=1}^m$

b) Òp dng Bagging

khai thác hieu qu sc mn h ca k thut hc t hp Bagging, lun vn xut xóy dng mt mĩ hnh ensemble lai (Hybrid Bagging Ensemble) da trón còc mĩ hnh c s cú hieu nng cao nht (õ hun luyn vị xp hng bc trc). C th, thay vớ ch s dng mt mĩ hnh n l, quy trnh bt u bng vic hun luyn vị ònh giò K thut toàn hc c s trón tp d liu hun luyn D . Hieu nng ca tng mĩ hnh c o lng thng qua ch s F1-Score, t ú la chn ba mĩ hnh cú kt qu tt nht a vïo giai on kt hp.

Sau khi xóc nh Top-3 mĩ hnh, phng phòp Bagging c òp dng theo phón b s bn sao (3, 2, 2). i vì mi mĩ hnh trong ba mĩ hnh c chn, nhiu tp d liu bootstrap c to ra bng còch ly mu ngu nhĩn cú hoĩn li t tp hun luyn ban u. Trón mi tp bootstrap nìy, mt bn sao ca mĩ hnh tng ng c hun luyn c lp, to thnh còc *b hc c s* (*base learners*) trong ensemble. Mi base learner c gòn trng s t l vì F1-Score ca mĩ hnh gc nhm phn ònh mc tin cy tng i ca nú trong quò trnh tng hp. Vic phón b bt i xng (3, 2, 2), tc cp nhiu bn sao bootstrap hn cho mĩ hnh hng cao, lị mt la chn thit k thc nghim nhm thĩn ensemble v phòc còc b hc mn h hn trong khi vn gi tòn h a dng t ba thut toàn khòc loi; óy lị mt heuristic, khũng phi kt qu ca tì u hóa lý thuyt, vị còc t l khòc (chng hn 3-3-3) cú th c kho sòt trong nghiõn cu tip theo.

Trong giai on d oòn, toĩn b còc mĩ hnh trong ensemble a ra phón phi xóc sut d oòn cho mu u vïo mi. Kt qu cui cĩng c xóc nh thũng qua c ch Soft Voting cú trng s, trong ú xóc sut ca tng lp c tòn h bng tng cú trng s ca còc xóc sut thnh phn. Nhõn d oòn cui cĩng c chn lị lp cú xóc sut tng hp ln nht.

Còch tip cn nìy cho phỏp gim phng sai ca còc mĩ hnh c s nh c ch ly mu bootstrap, ng thi duy trớ kh nng hc biu ãn ca tng thut toàn riõng l. Vic kt hp chn lc còc mĩ hnh cú hieu nng cao nht trc khi òp dng Bagging giúp tì u hóa c chònh xóc vị tòn h n nh ca h thng. Chi tit quy trnh c trnh bĩy trong Thut toàn 6.

Thut toàon 6. Thut toàon Hybrid Bagging Ensemble Learning

u vò: Tp d liu hun luy n $D = \{(x_i, y_i)\}_{i=1}^n$ vi $x_i \in \mathbb{R}^d$, $y_i \in \{0, 1\}$ (BENIGN = 0, Attack = 1)

 Tp kim nh D_{val} (tòch t D , dúng xp hng vị chn Top-3)

 Tp K thut toàon hc c s $\{\mathcal{L}_1, \mathcal{L}_2, \dots, \mathcal{L}_K\}$

 Phón b s bn sao $\mathbf{r} = (r_1, r_2, r_3) = (3, 2, 2)$

u ra: Nhón d oòn cui cúng $y_{\text{bag}} \in \{0, 1\}$

1: **Bc 1: Hun luy n vị ònh giò K mữ hnh c s**

2: **for** $k = 1$ to K **do**

3: $M_k \leftarrow \text{Train}(\mathcal{L}_k, D \setminus D_{\text{val}})$ ▷ Hun luy n trón phn train lủi, tòch khi D_{val}

4: $F_k \leftarrow \text{F1-Score}(M_k, D_{\text{val}})$ ▷ Tònh im F1 trón tp kim nh (validation), khũng chm tp kim tra

5: **end for**

6: **Bc 2: Chn Top-3 mữ hnh cú F1 cao nh**

7: Sp xp $\{M_1, \dots, M_K\}$ theo F_k gim dn

8: Chn 3 mữ hnh tt nh: $M^{(1)}, M^{(2)}, M^{(3)}$ vi $F^{(1)} \geq F^{(2)} \geq F^{(3)}$

9: **Bc 3: To ensemble theo phón b 3-2-2**

10: $\mathcal{E} \leftarrow \emptyset$ ▷ Tp ensemble gm 7 mữ hnh

11: **for** $j = 1$ to 3 **do**

12: **for** $i = 1$ to r_j **do**

13: To tp bootstrap $D_{j,i}$ bng còch ly ngu nhĩn n mu t $D \setminus D_{\text{val}}$ **cú hoị li**

14: $h_{j,i} \leftarrow \text{Train}(\mathcal{L}^{(j)}, D_{j,i})$ ▷ Hun luy n bn sao th i ca mữ hnh hng j

15: Gòn trng s $w_{j,i} \leftarrow F^{(j)}$ ▷ Trng s da trón F1-Score

16: Thỏm $(h_{j,i}, w_{j,i})$ vò $\mathcal{E}$

17: **end for**

18: **end for**

19: Chun húa trng s: $w_{j,i} \leftarrow \frac{w_{j,i}}{\sum_{(h,w) \in \mathcal{E}} w}$

20: **Bc 4: D oòn cho mu mĩ x (Soft Voting cú trng s)**

21: $T \leftarrow |\mathcal{E}| = 7$ ▷ Tng s mữ hnh trong ensemble

22: **for** mĩ $(h_t, w_t) \in \mathcal{E}$, $t = 1, \dots, T$ **do**

23: $\mathbf{p}_t \leftarrow h_t(x)$ ▷ Ly vector xòc sut d oòn

24: **end for**

25: Tònh xòc sut cú trng s: $\bar{p}(c | x) = \sum_{t=1}^T w_t \cdot P_t(c | x), \quad \forall c \in \{0, 1\}$

26: $y_{\text{bag}} \leftarrow \arg \max_{c \in \{0,1\}} \bar{p}(c | x)$

27: **return** y_{bag}

3.4 ònh giò mũ hnh

Mi mũ hnh (c s vị ensemble) c ònh giò toin din trón bn chiu:

Bng 3.5. Còc tiúu chò ònh giò mũ hnh

Tiúu chò	Mũ t
chònh xòc (Accuracy)	T l d oòn ỹng trón toin b mu kim tra
Precision	T l cnh bòa ỹng trong tng s cnh bòa c phòt ra
Recall	T l phòt hin ỹng trong tng s mu tn cũng thc t
F1-Score	Trung bnh iu hũa ca Precision vị Recall
Area Under the Curve Receiver Operating Characteristic	Din tồch dĩ ng cong ROC o hũu nng phón bit lp
Area Under the Curve PR	Din tồch dĩ ng cong Precision-Recall
Chi phò tồnh toòn	Thi gian hun luy, thi gian d oòn vị kòch thc mũ hnh
Kh nng gii thòch (Explainable Artificial Intelligence)	Biu SHAP: summary plot, bar chart vị waterfall plot

Hũu nng ca mũ hnh c ònh giò thũng qua còc ch s phón loi ph bin nh Accuracy, Precision, Recall vị F1-Score, kt hp vị phón tồch ng cong AUC (ROC vị PR), chi phò tồnh toòn (thi gian hun luy vị suy lun), cng nh kh nng gii thòch ca mũ hnh (vò dĩ: biu tng quan SHAP); còc tiúu chò ònh giò c tng hp trong Bng 3.5. kim chng mũ hnh phòt hin xóm nhp, tp dĩ liu kim tra c s dng nhm ònh giò kh nng tng quòt hũa ca mũ hnh ò hun luy, trong ú kt qu dĩ oòn c i chiu vị nhõn thc t vị o lng bng còc thc o ònh giò. Còc ch s nh accuracy (AC), precision (PR), recall (RE), F1-score (FS) c tồnh toòn theo còc cũng thc (3.4), (3.5), (3.6) vị (3.7). Nhng kt qu nỳy lĩ c s quan trng so sònh gia còc phng phòp la chn c trng vị la chn mũ hnh phứ hp cho trin khai thc t.

$$\text{Accuracy (AC)} = \frac{TP + TN}{TP + TN + FP + FN} \quad (3.4)$$

$$\text{Precision (PR)} = \frac{TP}{TP + FP} \quad (3.5)$$

$$\text{Recall (RE)} = \frac{TP}{TP + FN} \quad (3.6)$$

$$F1\text{-Score (FS)} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3.7)$$

Còc i lng TP, FP, FN, TN đứng trong còc cũng thc trỏn c minh ha qua ma trn nhm ln Bng 3.6.

Bng 3.6. Ma trn nhm ln ca mũ hnh phòt hin xóm nhp

	D oàn: Positive	D oàn: Negative
Thc t: Positive	TP (True Positive)	FN (False Negative)
Thc t: Negative	FP (False Positive)	TN (True Negative)

Trong ú, TP (True Positive) l s lng lu lng mng hoc phiỏn kt ni thc s l t n cũng v i c h thng IDS phòt hin ửng l i xóm nhp. TN (True Negative) l nhng lu lng bớnh thng (khũng phi t n cũng) v i c mũ hnh phỏn loi chớnh xỏc l i hp l. FP (False Positive) l còc lu lng bớnh thng nhng b h thng nhn din nhm l i t n cũng. Ngc li, FN (False Negative) l nhng cuc t n cũng thc s xy ra nhng khũng c h thng phòt hin v i b phỏn loi nhm l i lu lng bớnh thng.

3.5 Tí u hóa tham s vị hun luyn mĩ hnh

Trong quò trnh xóy dng mĩ hnh hc mỳ, vic la chn còc siỏu tham s (hyperparameters) phứ hp li mt yu t quan trng nh hng n hiu nng ca mĩ hnh. tí u hóa còc siỏu tham s nỳ, phng phòp **Tỏm kim theo li** (Grid Search (GS)) kt hp vi **Cross-Validation (CV)** ỏ c s dng trong mũ trng phón tòn ca Apache Spark. Còc mĩ hnh phón loi c hun luyn vị so sòngh gm: Decision Tree, Logistic Regression, Linear SVC, Naive Bayes, Random Forest, GBT, XGBoost vị MLP; sau ú xp hng theo F1-Score chn Top-3 mĩ hnh cho còc phng phòp ensemble.

- **GS**: Li phng phòp th nghim tt c còc t hp cú th ca còc siỏu tham s c nh ngha trc. Vở d, vị mt mĩ hnh Random Forest, còc tham s cú th bao gm s lng cóy (numTrees), sỏu ti a (maxDepth), vị chin lc chn tp con c trng ti mi nũt (featureSubsetStrategy). Spark MLlib h tr i tng ParamGridBuilder xóy dng li còc tham s.
- **CV**: Li phng phòp ònh giò mĩ hnh bng còch chia d liu hun luyn thnh k phn, sau ú hun luyn vị ònh giò mĩ hnh k ln, mi ln s dng mt phn khỏc nhau lỳm d liu kim tra vị còc phn cùn li lỳm d liu hun luyn. Trong Spark, i tng CrossValidator c s dng thc hìn quy trnh nỳ.

Quy trnh tí u hóa c thc hìn nh sau:

1. Xóy dng pipeline gm còc bc tin x lý d liu (vở d: chun hóa, bin i c trng) vị mĩ hnh hc mỳ.
2. S dng ParamGridBuilder nh ngha tp li còc siỏu tham s cn tỏm kim.
3. Khi to CrossValidator vị pipeline, li còc tham s, vị b ònh giò hiu nng (vở d: BinaryClassificationEvaluator).
4. Hun luyn mĩ hnh bng còch gĩ phng thc fit() ca CrossValidator trỏn tp d liu hun luyn.
5. Chn mĩ hnh tt nht da trỏn im ònh giò trung bnh trỏn còc folds.

Vở d on mỗ s dng Spark MLlib:

```
from pyspark.ml.classification import RandomForestClassifier
from pyspark.ml.evaluation import BinaryClassificationEvaluator
```

```
from pyspark.ml.tuning import CrossValidator, ParamGridBuilder
from pyspark.ml import Pipeline

rf = RandomForestClassifier(labelCol="label", featuresCol="
    features")

pipeline = Pipeline(stages=[rf])

paramGrid = ParamGridBuilder() \
    .addGrid(rf.numTrees, [10, 20, 50]) \
    .addGrid(rf.maxDepth, [5, 10, 15]) \
    .build()

evaluator = BinaryClassificationEvaluator(labelCol="label",
    metricName="areaUnderPR")

cv = CrossValidator(estimator=pipeline,
                    estimatorParamMaps=paramGrid,
                    evaluator=evaluator,
                    numFolds=5)

cvModel = cv.fit(trainingData)
```

Quy trnh nỳ giúp m bo la chn c t hp siu tham s ti u, ng thi giúp ti u thi gian hun lun.
Spark giúp tng tc quò trnh nỳ nh kh nng x lý phón tòn vị song song hóa trón cm mỳ.

3.6 Trin khai biễn

Mũ hnh tt nht sau ònh giò c úng gúi thnh `PipelineModel` vị trin khai trởn mt cm hai thit b biễn NVIDIA Jetson Orin Nano Super (CPU ARM 64-bit + GPU NVIDIA), tòch vai trò: Jetson #1 chy cng phòt hìn bt thng (autoencoder) lc lu lng bnh thng, Jetson #2 chy b phón loi PySpark trởn còc lung nghi vn. Mũ hnh sau khi hun luyt trởn cm c chuyn sang thit b biễn bng Secure Copy Protocol (SCP). Quy trnh suy lun thi gian thc theo chui: Kafka Consumer nhn d liu mng (topic `ids-network-flow`), cng bt thng chuyn tip lung nghi vn sang `ids-suspicious-flow`, PySpark Streaming (micro-batch) x lý vị trỏch xut c trng, kt qu d òn ghi vño PostgreSQL phc v trc quan hóa trởn Grafana vị kỏch hot cnh bòa khi phòt hìn bt thng. H thng h tr ba ch : tòch pipeline (pipeline split), m rng theo chiu ngang (horizontal scaling) vị cm Spark (Spark cluster). Thũng s phn cng chi tit ca thit b biễn c trnh bñ trong Bng 3.7.

Bng 3.7. Thũng s phn cng thit b biễn

Thuc tỏnh	Giò tr
Nn tng	NVIDIA Jetson Orin Nano Super Developer Kit (×2)
CPU	6 nhón Arm Cortex-A78AE, 1,7 GHz
GPU	NVIDIA Ampere, 1024 nhón CUDA + 32 Tensor Core
RAM	8 GB LPDDR5 (102 GB/s)
Lu tr	SSD NVMe 256 GB
Hiu nng AI	ti ~67 TOPS (khung 25 W)
H iu hnh	Ubuntu (NVIDIA JetPack / L4T)
Vai trò	Worker hun luyt (Spark) & thit b suy lun biễn

Chng 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Trong chng nìy, lun vn trnh bñ kt qu t c khi òp dng k thut la chn c trng hun luyñ còc mĩ hnh hc mỳ. Bõn cnh ú, quy trnh tinh chnh siõu tham s bng tòm kim li kt hp kim nh chõo (cross-validation) cng c trnh bñ, cũng vi ònh giò kt qu thc nghim khi òp dng còc thut toøn hc mỳ nh SVM, LR, NB, RF, DT, GBT, XGB vñ MLP c trong trng hp cú vñ khũng s dng k thut gim chiu d liu. Ngoi ra, lun vn cng xòc nh vñ trnh bñ còc giò tr tham s ti u cho tng thut toøn thũng qua phng phòp tòm kim theo li kt hp vi kim nh chõo (cross-validation). Da trõn còc kt qu thu c, lun vn s lĩm rũ vn liu vic gim chiu d liu cú thc s cn thit hay khũng. Cui cũng, lun vn ònh giò hñu qu ca còc mĩ hnh EL, sau ú so sònh vi còc thut toøn hc mỳ truyñ thng, t ú tr li cóu hi: *Liu cú nõn s dng EL so vi còc mĩ hnh hc mỳ truyñ thng khi lĩm vic vi d liu IoT hay khũng?*


4.1 Mũ trng thc nghim

Vic hun luyñ mĩ hnh c thc hñn trõn mt cm **Apache Spark Standalone** phõn tòn gm mt mỳ ch vñ **hai thit b biõn NVIDIA Jetson Orin Nano Super Developer Kit**. im ònh cũũ y li cũng mt cp Jetson va úng vai trũ *worker* ca cm Spark trong pha hun luyñ, va li thit b *trĩn khai* trong pha suy lun thi gian thc (Hõnh 4.5), giữp kim chng tõnh kh thi ca toĩn b pipeline trõn ỹng phñ cng mc tiõu.

- **Mỳ ch (Spark master):** mỳ tõnh xòch tay MacBook Air, vi x lý Apple M3, RAM 16 GB, macOS Sonoma 14.3; m nhñ iu phi cm (master), tin x lý d liu thũ (t CSV sang Parquet) vñ chy h tng Docker (Kafka, PostgreSQL, InfluxDB, Grafana).
- **Hai nũt worker:** **NVIDIA Jetson Orin Nano Super Developer Kit**; cu hõnh chi tit (CPU/GPU/RAM/lu tr) nõu ti Bng 3.7, Chng 3; h iu hñnh Ubuntu (NVIDIA JetPack/L4T). Jetson #1 ng thi chy tin trnh *driver* ca Spark (driver li tin trnh iu khĩn ng dng, khòc vi vai trũ *master* iu phi cm ca MacBook).
- **Phñ mm:** Python 3, Apache Spark / PySpark 3.4.1, MLlib; cu hõnh cm tiõu biu: `executor.memory=3 GB, executor.cores=4, driver.memory=3 GB, shuffle.file.partitions=32`; mi Jetson c cp 8 GB swap trõn NVMe trõnh trĩn b nh khi cao im (xem `cluster/spark_cluster.env`, `cluster/setup_swap_jetson.sh`).

Cộc thut toàn hc mỳ, phng phỏp gim chiu vị cộc bc ònh giò u c trin khai bng PySpark vị thc thi phón tòn trỏn hai nũt Jetson; tp d liu Parquet c ng b sang c hai worker trc khi hun luyn. Kin trũc cm hun luyn phón tòn (gm vai trũ *master* iu phi trỏn MacBook vị hai *worker/executor* trỏn Jetson) c minh ha Hỡnh 4.1. Cn phón bit rũ vị Hỡnh 4.5 (pha suy lun): cũng mt cp Jetson nhng pha hun luyn úng vai trũ worker ca cm Spark, cùn pha suy lun úng vai trũ cng lc (gate) vị b phón loi.

Cn nhn mn nhng mỳ ch MacBook *ch m nhn* vai trũ *master* iu phi cm cũng tin x lý vị h tng dch v, mị *khũng* tham gia tỡnh toàn hun luyn (khũng chy *executor*). La chn nỳ lị cú ch ờch: toịn b s liu hui nng c bõo cõo nhm phn ònh trung thc kh nng *hun luyn phón tòn ngay trỏn phn cng biõn* Jetson, ũng vị mc tiõu ct lũi ca lun vn. Nu a MacBook (vị x lý Apple M3, mn nh òng k) vị ọ lịm nũt tỡnh toàn, phn ln khi lng cũng vic s dn v mỳ ch, góy mt cón bng ti (hin tng *straggler*) vị lịm sai lch cộc phỏp o thi gian/thũng lng, khin kt qu khũng cùn phn ònh ũng nng lc ca cm biõn. Vớ vỹ, cm o c c gi *ng nht* gm hai nũt Jetson; mỳ ch ch c dũng phỏt trin vị kim th nhanh trong giai on xóy dng pipeline.



Hỡnh 4.1. Cm hun luyn phón tòn Apache Spark Standalone: MacBook gi vai trũ *master* iu phi (khũng chy *executor*), hai Jetson Orin Nano Super lị *worker/executor* thc thi tỡnh toàn; d liu Parquet c phón vũng vị ng b sang c hai nũt, kt qu c gom v qua shuffle/collect.

4.2 Kt qu thc nghi

Bng 4.1 tũm tt thit lp tham s ca cộc mũ hỡnh hc mỳ c s dng trong nghiõn cu nỳ. Trong ú, XGB vị MLP c tnh chnh bng Grid Search kt hp kim nh chõo (Kch bn 3); cộc mũ hỡnh cùn

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

li đứng b tham s c nh t trc, la chn da trồn còc nghiỏn cu gn óy vị thc nghiim s b, nhm bo m khỏc bit quan sỏt c gia còc phng phỏp gim chiu phn ònh ỳng phng phỏp thay vớ mc tnh chnh riỏng tng mũ hnh.

Bng 4.1. Tham s ti u ca còc mũ hnh hc mỳy

Mũ hnh	Tham s	Giỏ tr	Ý ngha/Mũ t
Decision Tree	maxDepth	15	Bt còc mu tn cỳng phc tp.
	impurity	entropy	Tiỏu chỏ chĩa nhỏnh ti u.
	minInstancesPerNode	5	S mu ti thiủ ti mi nũt lỏ.
Logistic Reg.	maxIter	200	m bo hi t trồn tp d liủ ln.
	regParam	0,001	Kim sỏt mc iủ chun (regularization).
	elasticNetParam threshold	0,0 0,5	S dng Ridge (L2) n nh hn. Ngng quyỏt nh nh phỏn.
SVM (LinearSVC)	maxIter	200	S ln lp ti u hũa biỏn.
	regParam	0,001	Tham s iủ chun biỏn quyỏt nh.
NB	modelType smoothing	gaussian 1,0	Phứ hp cho c trng liỏn tc. Lỳm mt Laplace.
Random Forest	numTrees	200	m bo n nh kt qu.
	maxDepth	15	Chiu sỏu ti a ca cỏy rng.
	featureSubsetStrategy	sqrt	Chn c trng ngu nhiỏn mi nũt.
GBT	maxIter	150	S vũng boosting ti a.
	maxDepth	6	Chiu sỏu ca cỏc cỏy yu.
	stepSize	0,05	Tc hc (learning rate) ca boosting.
	subsamplingRate	0,8	T l lý mu d liủ mi vũng boosting.
XGB	n_estimators	300	S lng cỏy boost trong mũ hnh.
	max_depth	8	Chiu sỏu ti a mi cỏy.
	learning_rate	0,05	Kim sỏt mc hc ca cỏy mi.
	subsample	0,8	T l lý mu d liủ mi cỏy.
	colsample_bytree	0,8	T l lý mu c trng mi cỏy.
MLP	layers	[d, 64, 32, 2]	Mng n-ron 2 lp n (d = s c trng u vủ).
	maxIter	150	S vũng lp hun luyủ ti a.
	stepSize	0,01	Tc hc ca mng n-ron.

4.2.1 Kch bn 1: ònh giò hui nng c s (Baseline)

Trong kch bn này, toin b tp c trng s (khong 78 c trng trc khi loi cng; s chõnh xõc sau khi loi `destination_port/source_port` lĩ 77) c a vĩa mĩ hõnh mĩ cha qua bt k bc la chn c trng hay gim chiu nĩa. Mc tiõu lĩ thĩt lp mt mc hui nng tham chiu cho cõc th nghĩm tĩp theo.

Kt qu hui nng ca cõc thut toin ML n l vĩa phng phõp Ensemble c trõnh bĩa trong Bng 4.2.

Bng 4.2. Kt qu hui nng phõn lp kch bn Baseline (toin b c trng s, ≈ 78 trc khi loi cng)

Thut toin	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9986	0,9925	0,9983	0,9954	0,9994	0,9988
Logistic Regression	0,9288	0,6937	0,9422	0,7991	0,9859	0,9509
SVM (LinearSVC)	0,9199	0,6650	0,9395	0,7788	0,9843	0,9485
NB	0,3163	0,1793	0,9933	0,3038	0,8829	0,6364
Random Forest	0,9985	0,9939	0,9960	0,9949	0,9999	0,9997
GBT	0,9980	0,9900	0,9965	0,9932	0,9998	0,9991
XGB	0,9991	0,9950	0,9993	0,9971	1,0000	0,9999
MLP	0,9900	0,9844	0,9487	0,9662	0,9984	0,9936
Hybrid Bagging	0,9990	0,9950	0,9984	0,9967	1,0000	0,9999
Soft Voting	0,9991	0,9952	0,9985	0,9969	1,0000	0,9999

Vĩ cu hõnh õ loi tr rừ r d liũ, nhũm mĩ hõnh da trõn cõy (Random Forest, XGB, GBT) c k vng dn u, vĩa F1 thp hn mc gn-tuyt-i ca cõc cu hõnh cú rừ r vĩa phn ònh ỹng khũ thc ca bĩa toin; kt lun “mĩ hõnh nĩa tt nht” ch c a ra khi chõnh lch vt khong tin cy (xem mc kim nh thng kõ). Do d liũ mt cõn bng mn, AUC-PR vĩa recall trõn lp tn cũng c u tiõn hn Accuracy khi din gĩa, vĩa Accuracy cú th gĩa lc quan gĩa to (mt mĩ hõnh luĩn oĩn lp benign chim a s vn t Accuracy cao).

4.2.2 Kch bn 2: So sõnh chin lc gim chiu d liũ

Chũng tũĩ thc hĩn so sõnh 3 chin lc chõnh nhm gim s lng c trng nhng vn m bo hui nng:

1. **RF Feature Importance:** Trõch xut 30 c trng cú im s quan trng cao nht t Random Forest.
2. **SHAP Importance:** S dng giò tr Shapley t mĩ hõnh XGB chn ra 30 c trng cú nh hng ln nht.
3. **PCA (k=40):** Gim chiu d liũ t khũng gian c trng gc (≈ 78 chiu trc khi loi cng) xung 40 thĩnh phn chõnh.

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Lu ý rng PCA đứng $k = 40$ — nhieu hn 30 c trng ca RF/SHAP, vớ óy lị phỏp *trờch xut* ch khũng phi *chn lc*: mi thnh phn chờnh ch lị mt t hp tyn tờnh mang mt phn phng sai, nỏn cn nhieu thnh phn hn gi lng thũng tin (phng sai tờch ly) tng ng vi tp 30 c trng gc. Trong di quỏt chung $\{20, 30, 40\}$, $k = 40$ lị mc gi phng sai cao nht, nỏn lị im vn hnh i din cũng bng nht cho PCA; ỏp $k = 30$ s lịm PCA mt thỏm phng sai vị bt li khi so sỏnh.

Bng 4.3 tũm tt s khỏc bit gia còc phng phỏp. Mũ hnh i din (ct *Mũ hnh tt nht*) ca mi phng phỏp c chn theo F1 trỏn tp kim nh (validation) tỏch t tp hun lun; tp kim tra khũng tham gia khỏu chn lc nỳy. Mc tiỏu lị kim chng gi thuyt: la chn c trng (RF/SHAP Top-30) gi c hieu nng gn vi baseline trong khi gim hn 60% s c trng, qua ú phứ hp cho trin khai biỏn.

Bng 4.3. So sỏnh hieu nng tt nht ca còc phng phỏp la chn c trng vị gim chiu

Phng phỏp	S c trng	Mũ hnh tt nht	F1-Score	Hun lun (s)	Dung lng (MB)
Baseline (Toịn b)	77	XGB	0,9971	4615,5	2,32
RF Importance	30	XGB	0,9922	1295,1	2,52
SHAP Importance	30	XGB	0,9970	1226,1	0,003 [†]
PCA (k=40)	40	XGB	0,9939	1444,8	3,82

Baseline đứng toịn b 77 c trng s (≈ 78 trc khi loi cng). [†]Kỏch the o bng còch tun t húa mũ hnh *trỏn cm hun lun phỏn tòn*: bc lu mũ hnh phỏn tòn ghi còc phỏn vũng d liu rng cớ trỏn executor ang gi chũng, nỏn giờ tr c KB ch bt c metadata cc b trỏn driver vị *thp hn the t*. Vớ dung lng ensemble cớ ph thuc s cớ vị s nũt (khũng ph thuc s c trng u vị), mũ hnh XGB SHAP Top-30 the t tng ng bn RF Top-30 ($\approx 2,5$ MB). Cng vớ vy, tp c trng rũt gn cú th cho mũ hnh *ln hn* baseline mt chũt (2,52 so vi 2,32 MB): ỏt ng viỏn tỏch hn khin cớ cn nhieu nũt hn t cũng tnh khit. Phỏp o tin cy lị bn mũ hnh xut ra ch n nũt ca pipeline trin khai (Mc kt qu biỏn).

Ngoii ra, s so sỏnh trc tip gia hai phng phỏp la chn c trng đa trỏn quan trng ca RF vị SHAP c trnh bỳ chi tit trong Bng 4.4.

Bng 4.4. So sỏnh hieu nng la chn c trng: RF Importance vs SHAP Importance (Top-30)

Thut toản	F1 (RF Top-30)	F1 (SHAP Top-30)	Chỏnh lch (%)
Random Forest	0,9879	0,9955	+0,77
XGB	0,9922	0,9970	+0,48
GBT	0,9844	0,9918	+0,75
Decision Tree	0,9835	0,9948	+1,15

4.2.3 Kch bn 3: Ti u húa tham s

Sau khi chn c b c trng ti u t SHAP, bn mũ hnh Spark ML gc (Random Forest, Decision Tree, GBT, Logistic Regression) c tnh chnh tham s thũng qua Grid Search kt hp Cross-validation trỏn tp c trng SHAP Top-30; còc mũ hnh cũn li (XGB, MLP, SVM, NB) gi

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

nguồn b tham s c nh Bng 4.1 (xem lý do u mc). Vic tính chnh giúp còc mữ hnh cóy t F1 quanh mc 0,995 (Bng 4.5); mc ci thín so vì cu hnh c nh lĩ nh do bị toản nh phón trong-min ò gn bão hòa, phứ hp vì nhn nh mc kim nh thng kỏ.

Kt qu hiu nng ca phng phỏp Ti u hóa tham s c trnh bịy trong Bng 4.5.

Bng 4.5. Kt qu hiu nng phón lp kch bn Ti u hóa tham s

Thut toản	Accuracy	Precision	Recall	F1-Score	AUC-ROC	AUC-PR
Decision Tree	0,9987	0,9977	0,9936	0,9957	0,9994	0,9980
Logistic Regression	0,9541	0,9787	0,7094	0,8226	0,9749	0,9371
SVM (LinearSVC)	gi cu hnh c nh (xem Bng 4.2)					
NB	gi cu hnh c nh (xem Bng 4.2)					
Random Forest	0,9986	0,9985	0,9922	0,9953	0,9999	0,9997
GBT	0,9985	0,9979	0,9924	0,9951	0,9999	0,9993
XGB	gi cu hnh c nh (xem Bng 4.2)					
MLP	gi cu hnh c nh (xem Bng 4.2)					
Hybrid Bagging	0,9986	0,9956	0,9949	0,9953	0,9999	0,9998
Soft Voting	0,9988	0,9985	0,9932	0,9958	1,0000	0,9998

4.2.4 Phón tồch kh nng gii thờch vì SHAP

Tồnh gii thờch (explainability) lĩ mt thnh phn thit yu trong h thng IDS, nhm cung cp c s cho vic xóy dng nim tin vị h tr vn hnh thc t. Trong nghiỏn cu nỳy, phng phỏp SHAP (SHapley Additive exPlanations) c s dng phón tồch mc quan trng ca tng c trng i vì quyt nh phón loi ca mữ hnh XGB.

Hnh 4.2 xp hng 30 c trng quan trng nht theo giò tr trung bnh tuyt i ca SHAP (mean |SHAP|): thanh cng dũ, c trng cng nh hng ln n quyt nh phón loi xỏt trỏn toĩn b mu. trỏnh rừ r, giò tr SHAP c tồnh trỏn mt *mu phón tng theo lp ly t tp hun luyn* (khũng phi tp kim tra); mu nỳy c bin i qua ỹng b chun hóa (StandardScaler) ò fit trỏn tp hun luyn trc khi tồnh SHAP, bo m khũng gian u vọ ca phỏp gii thờch trũng khp vì khũng gian u vọ mĩ mữ hnh ò hc.

B sung cho xp hng tng th, Hnh 4.3 trnh bịy biu SHAP Summary dng beeswarm: mĩ im i din cho mt quan sỏt; trc hoĩnh th hĩn giò tr SHAP (dũng y d oỏn v lp tn cũng, óm y v lp bnh thng); mũu sc biu din giò tr c trng t thp n cao. phón tỏn theo trc hoĩnh phn ònh mc nh hng ca c trng, tp trung th hĩn tồnh n nh ca tỏc ng.

Bỏn cnh ú, giò tr trung bnh tuyt i ca SHAP (mean |SHAP|) c dũng xp hng mc quan

trng tng th. Trón tp c trng ò loi tr rù r, còc c trng cú mean|SHAP| ln nht l: bwd_packet_length_std, init_win_bytes_backward, init_win_bytes_forward vị bwd_packet_length_mean.

Còc c trng nh init_win_bytes_forward, init_win_bytes_backward (kòch thc ca s TCP giai on khi to) vị bwd_packet_length_std, packet_length_std (s bin thiỏn ãi gúi tin) phn ònh c tòn phón phi lu lng l còc tòn hiu mng cú ý ngha, khũng ph thuc vị nh danh dch v. Vic loi destination_port buc mũ hnh ãa vị còc c trng hnh vi nịy thay vớ ghi nh ònh x cng → nhõn.

4.2.5 Phón tồch rù r d liu (data leakage)

c trng destination_port lị mt ngun rù r nhõn ò c ghi nhn trón CICIDS2017 [54]: mi loi tn cũng c sinh nhm vị nhng cng dch v c nh nõn cng òch tng quan mn nh nhõn, khin mũ hnh ã “ghi nh” ònh x cng–nhõn thay vớ hc hnh vi lung (Engelen vị cng s cho thy b phón loi cú th t chõnh xỏc cao ch ãa vị cng òch). nh lng nh hng, lun vn thc hnh phón tồch loi b (ablation) gi/loi cng vi cũng mt cu hnh Random Forest c nh (Bng 4.6). iu òng lu ý lị vi bị toàn nh phón trong-min, sau khi ò loi trúng lp lung mc c trng, nh hng riỏng ca destination_port lỏn F1 ch cũn nh (chỏnh khong 0,001 im F1), bi tỏc v nh phón trón CICIDS2017 vn gn mc bõo hũa vị ngun rù r *chi phi* (còc lung trúng lp) ò c x lý trc bng bc loi b trúng lp. iu nịy *khũng* cú ngha rù r vũ hi: giò tr ca quy trõnh loi-tr-rù-r th hnh rũ hn ònh giò ã lp vi còc lp tn cũng him (Mc 4.2.9) vị *tng quòt hũa liỏn b d liu* (Mc 4.2.8.1), ni còc “lị tt” rù r khũng cũn giúp mũ hnh. Pipeline loi b c destination_port ln source_port; phón tồch ablation tp trung vị destination_port vớ óy lị cng chi phi.

Bng 4.6. Phón tồch loi b (ablation) rù r: nh hng ca c trng destination_port (Random Forest c nh a priori: numTrees=200, maxDepth=15, cú trng s lp; nh phón)

Cu hnh	F1	Recall (Attack)	AUC-PR
Gi destination_port (rù r)	0,9965	0,9988	0,9999
Loi destination_port (xut)	0,9955	0,9961	0,9997

C hai lt ãng cũng mt cu hnh Random Forest c nh t trc (200 cóy, sỏu 15, trng s lp, khp Bng 4.1) cũ lp ỹng nh hng ca c trng rù r. Mc chỏnh lch F1 gia hai hịng phn ònh phn hiu nng b thi phng do c trng rù r; óy mc chỏnh nh vớ ò loi trúng lp trc vị tỏc v nh phón gn bõo hũa, nhng chiu hng (gi cng cho F1/recall cao hn) vn nht quòn vi hnh tng rù r. Mi kt qu khỏc trong lun vn ãng cu hnh ò loi cng.

4.2.6 Phón tồch hiu nng h thng

Bổn cnh chồnh xóc, hiu nng h thng v thi gian vị tị nguỷn lị yu t then cht cho vic trin khai thc t. Kt qu trong Bng 4.7 cho thy:

Bng 4.7. So sònh thi gian x lý vị kồch thc mữ hnh kch bn Baseline

Thut toòn	Hun luyn (s)	D oòn (s)	Kồch thc (MB)
Decision Tree	33,4	6,1	0,0004
Logistic Regression	49,2	5,4	0,009
SVM (LinearSVC)	224,3	5,4	0,002
NB	8,2	5,2	0,012
Random Forest	610,3	18,6	3,69
GBT	1346,8	8,9	0,92
XGB	4615,5	9,0	2,32
MLP	314,7	8,0	0,0004
Hybrid Bagging	11934,5	36,4	7,24
Soft Voting	–	25,6	–

- **Thi gian hun luyn:** Còc mữ hnh Gradient Boosting (GBT, XGB) cú thi gian hun luyn dị nht nhng t kt qu phón loi cao.
- **Thi gian d bèo:** XGB cú thi gian d bèo nhanh (khong 9 gióy cho toịn tp kim tra), Random Forest chm hn (khong 19 gióy); c hai phứ hp cho giòm sòt theo lữ gn thi gian thc.
- **Kồch thc mữ hnh:** còc mữ hnh cóy chim dung lng ln hn hn mữ hnh tuyt tồnh (LR, SVM, NB ch vị KB); RF khong 3,7 MB vị ensemble Hybrid Bagging ln nht (~7,2 MB) do gp nhieu b hc c s. *Lu ý: kồch thc c o bng còch tun t hóa (serialize) PipelineModel ca Spark ra a; giò tr nịy cú th bin thiỏn theo còch phón mnh/partition khi lu nỏn ch mang tồnh tham kho tng i, khũng đứg lịm tiỏu chờ quyt nh la chn mữ hnh.*

4.2.7 Kim nh ý ngha thng kỏ

Do còc con s F1 gia nhng phng phòp/thut toòn hịng u rt sòt nhau, lun vn khũng kt lun “mữ hnh tt nht” ch da trỏn mt ln o. Mữ hnh i đin ca mi phng phòp, cng nh *cp phng phòp dn u c* a vịo kim nh, u c chn theo F1 trỏn tp kim nh (validation, 20% tồch t tp hun luyn, seed=42); tp kim tra khũng tham gia khou chn lc. Hai phng phòp nịy sau ú c hun luyn li trỏn N ln *ly mu li* tp hun luyn/kim tra (mc nh $N=6$, gỏp cp trỏn cúg mt phỏp chia mi vùg), tồnh

F1 trung bình k m hai loi kh ng tin c y 95%: kh ng tin c y t th ng th ng v i kh ng tin c y h u ch nh *Nadeau–Bengio* [55], trong   ph ng sai nh n h s $(1/N + n_{\text{test}}/n_{\text{train}})$ b t t ng quan gia c c ln ly mu li ch ng ln; kh ng *Nadeau–Bengio* c  d ng l m c n c  kt lun ch  nh.   ngha th ng k  c  kim b ng *permutation test g  p c p hai ph ra*, lit k   y to n b  $2^N = 64$ ho n v i du (kim nh  ch  nh x c, kh ng xp  x Monte Carlo), do   p nh  nh t kh  d  l  $2/64 \approx 0,031$; ln h u ng  c  b o c o b ng Cohen’s d g  p c p (B ng 4.8). K t lun: ch  nh l ch F1 gia Baseline v i SHAP Top-30 c    ngha th ng k  mc s n ($p \approx 0,031$, $d \approx 1,94$), nh ng kh c bit tuy t i t nh  ($\approx 0,0001$ im F1) n  n hai ph ng ph p *t ng ng  v  mt th c d ng*; khi   ti u ch   ph  (kh  n ng g i th  ch, k  ch th c, chi ph   bi  n) mi  l  c n c  la ch n. C n tha nh n r ng v i $N=6$, kim nh  c  *lc th ng k   th p*; v  v y mt gi  tr  p kh ng c    ngha t  n  ch  l  b ng ch ng y  cho “t ng ng ”, v i kt lun c  c n c  ng  thi v i kh ng tin c y *Nadeau–Bengio* v i Cohen’s d ; t ng N (k  m kim nh  ch  o lng) l  h ng c ng c  tip theo.

B ng 4.8.  n nh  qua nh u ln ly mu v i kim nh  g  p c p (t `statistical_validity_multiseed.csv`)

Ph�ng ph�p	M� h�nh	F1 (mean $\pm$ CI95 t)	CI95 <i>Nadeau–Bengio</i>	p (g��p c�p)	Cohen’s d
Baseline (to�n b�)	XGB	0,99734 $\pm$ 0,00007	[0,99722; 0,99746]	0,031	1,94
SHAP Top-30	XGB	0,99720 $\pm$ 0,00009	[0,99705; 0,99735]		

4.2.8 Kim tra  n nh  trong-ph n-phi

M  h nh i  din ca mi  ph ng ph p c   nh gi  li tr  n mt mu con ca tp kim tra (kh ng giao v i tp hun lu n; B ng 4.9). C n n i r  :  y ch  l  ph  p kim tra *n nh  c  ng ph  n phi* (in-distribution), kh ng phi kim th ch chu n ph  n phi;  nh gi  t ng qu t h a th c s  nm  th  r ngh m li  n b  d  li u (Mc 4.2.8.1).

B ng 4.9. Kim tra  n nh  trong-ph  n-phi tr  n mu con tp kim tra (t `robustness_holdout_summary.csv`)

Ph�ng ph�p	M� h�nh	F1 (holdout)	AUC-PR
Baseline	XGB	0,9971	0,9999
RF Top-30	XGB	0,9921	0,9998
SHAP Top-30	XGB	0,9969	0,9999
PCA	XGB	0,9939	0,9998

4.2.8.1 Tng quò húa lión b d liu

ònh giò trón tp gi li trón lị phỗp th *cúng b* (in-domain, cúng phón phi). kim chng kh nng *tng quò húa* the s, mữ hnh c hun luyn trón mt b d liu vị kim tra trón b *khòc* (ònh giò *khòc b*, cross-dataset; vị ngc li) trón tp c trng ò loi tr rù r *chung* ca hai b. Do hai b d liu t tón ct khòc nhau (CSE-CIC-IDS2018 đứg tón vit tt kiu CICFlowMeter v3), tón ct ca CSE-CIC-IDS2018 c ònh x v tón chun ca CICIDS2017 qua mt bng bờ danh (alias) tng minh trong mỗ ngun; danh sòch c trng chung sau ònh x c lu ti `common_features.txt` bo m tòi lp. Mữ hnh đứg cho thờ nghim lị Random Forest cú trng s lp (`weightCol`), nht quòn vị c ch x lý mt cón bng Chng 3. Khong còch gia F1 cúng b vị F1 khòc b (Bng 4.10) nh lng mc suy gim khi gp dch chuyn phón phi, mt thc o n nh cht ch hn holdout cúng phón phi.

Do CSE-CIC-IDS2018 [48] cú quy mữ rt ln (~16 triu lung, ~6 GB), vt kh nng x lý thoi mòi ca thit b biỏn Jetson (8 GB), thờ nghim nịy đứg *mu phón tng theo nhõn* ca CSE-CIC-IDS2018 (t l 0,2, ~3,14 triu lung ly mu, cùn ~2,39 triu sau kh trứg lp mc c trng, `seed=42`, cừg tc `IDS_SAMPLE_FRAC`) nhm bo toịn t l còc lp trong khi va vị phn cng; CICIDS2017 đứg ~2,23 triu lung. Còc con s mu c bòa còc tng minh bo m tòn h tòi lp; vic m rng lión toịn b CSE-CIC-IDS2018 lị hng phòt trin tip theo.

Bng 4.10. Tng quò húa lión b d liu gia CICIDS2017 vị CSE-CIC-IDS2018 (CSE-CIC-IDS2018: mu phón tng `seed=42`; t `cross_dataset_results.csv`)

Hun luyn	Kim tra	Loi	F1
CICIDS2017	CICIDS2017	cúng b	0,9952
CICIDS2017	CSE-CIC-IDS2018	khòc b	0,0423
CSE-CIC-IDS2018	CSE-CIC-IDS2018	cúng b	0,9245
CSE-CIC-IDS2018	CICIDS2017	khòc b	0,0535

Đin gii. Kt qu cho thy mt tng phn rử rt vị *trung thc*: F1 cúng b rt cao c hai chiu (0,9952 vị 0,9245) nhng F1 khòc b gim mn h xung 0,04–0,05, ch yu do recall gn bng khũng (0,022 vị 0,030) trong khi precision chiu 2017 sang 2018 vn t 0,596, tc mữ hnh gn nh khũng nhn ra tn cũg ca b d liu kia, ch khũng to ra cnh bòa sai trịn lan. Nguyỏn nhón lị *dch chuyn phón phi* c trng gia hai testbed: khòc phiỏn bn CICFlowMeter (thang o vị còch tòn h mt s c trng thay i), khòc h tng mng vị cu hnh dch v, khòc t hp loi tn cũg (HOIC/LOIC-HTTP ca 2018 khũng cú trong 2017). S st gim nịy nht quòn vị còc nghiỏn cu cross-dataset trón IDS da trón c trng lung [56, 57, 58], vị chònh lị lun c mn h nht ca lun vn: *con s trong-min gn hoịn ho* (k c khi ò loi trù r) khũng bo m kh nng trin khai sang mữ trng khòc; ònh giò lión b d liu phi lị mt phn bt buc ca quy trnh kim nh IDS, vị còc hng thờch ng min (chun húa

theo min, hun luyn lión b, cp nht theo drift) l iu kin tiốn quy t cho trin khai thc t.

4.2.9 ònh giò a lp theo loi tn cũg


Phón loi nh phón (Benign/Attack) trón CICIDS2017 vn d tòch; bc l im yu thc s, lun vn b sung ònh giò a lp theo tng loi tn cũg gc (precision/recall/F1 tng lp, macro-F1, weighted-F1 vị ma trin nhm ln), gm lp Benign vị 14 loi tn cũg ca CICIDS2017. Kt qu cho thy tng phn rt rủ gia hai ch s tng hp: $weighted-F1 \approx 0,998$ (b chi phi bi còc lp a s) nhng $macro-F1$ ch $\approx 0,806$, chónh l bng chng cho thy chónh xóc nh phón gn hoìn ho ò che giu nng lc phòt hin kỏm còc lp him. C th, còc lp a s (Benign, DoS Hulk, DDoS, PortScan) t F1 rt cao ($\geq 0,97$), trong khi còc lp cc him suy gim nghiỏm trng: Web Attack – XSS recall ch 0,027, Web Attack – SQL Injection F1 = 0 (ch 6 mu), Bot recall 0,46. óy l ni khỏc bit gia còc phng phòp la chn c trng th hin rủ nht vị cng l hng cn ci thin (x lý mt cón bng, tng cng d liu lp him). Kt qu chi tit theo tng lp c trnh bỳ trong Bng 4.11, vị ma trin nhm ln a lp tng ng c minh ha Hnh 4.4.

Bng 4.11. Hiu nng theo tng lp tn cũg (t per_class_metrics.csv)


Lp	Support	Precision	Recall	F1
Benign	380.119	0,9981	0,9997	0,9989
DoS Hulk	34.446	0,9990	0,9904	0,9947
DDoS	25.694	0,9996	0,9992	0,9994
DoS GoldenEye	2.020	1,0000	0,9757	0,9877
FTP-Patator	1.147	0,9965	0,9965	0,9965
DoS slowloris	1.068	0,9953	0,9925	0,9939
DoS Slowhttptest	1.023	0,9286	0,9912	0,9589
SSH-Patator	642	1,0000	0,9346	0,9662
PortScan	383	1,0000	0,9530	0,9759
Web Attack – Brute Force	311	0,7346	0,7299	0,7323
Bot	290	1,0000	0,4552	0,6256
Web Attack – XSS	111	1,0000	0,0270	0,0526
Infiltration	12	1,0000	0,6667	0,8000
Web Attack – SQL Injection	6	0,0000	0,0000	0,0000
Heartbleed	3	1,0000	1,0000	1,0000
macro-F1 / weighted-F1			0,806 / 0,998	

Phón tòch hng nhm ln gia còc lp him. c ma trin nhm ln theo òch n ca còc d oòn sai cho thy còc lp him suy gim theo hai kiu khỏc nhau. Kiu th nht l *nhm loi nhng vn b phòt hin*: 81/111 mu Web Attack – XSS b gòn thịnh Web Attack – Brute Force, tc bị toòn nh phón trin khai trón bión, còc lung nỳ vn b gn c tn cũg (76% XSS vn b chn), ch sai khỏu nh danh loi. Kiu th hai nguy him hn: *lt hn thịnh Benign*: toìn b 6/6 mu SQL Injection,


158/290 mu Bot (54%) vị 84/311 mu Web Brute Force b d oòn lị lu lng bnh thng. Ba c ch gii thờch hin tng nịy: (i) *mt cón bng cc oan* (6–311 mu so vị 380.119 mu Benign) khin còc lp him gn nh khũng cú vúng quy t nh riỏng; (ii) *vic loi destination_port* nh hng nng nht n nhúm tn cũng web: khi mt “lị tt” cng 80, còc lung HTTP tn cũng (request/response ngn) cú c trng hịnh vi rt gn lu lng duy t web thng vị gn ln nhau; giò tr recall 0,027 ca XSS lị con s *trung thc* thay cho con s p nh rừ r; (iii) *Bot ln Benign do bn cht*: còc lung beaconing C&C nh, u n, gịng lu lng nn khi khũng cùn nh danh cng/dch v. Nhn đin nịy nh hng trc tịp cho hng phòt trin: x lị mt cón bng cú ch òch (tng cng/oversampling lp him), b sung c trng chui thi gian cho hịnh vi beaconing, vị kim chng liỏn b d liu (Mc 4.2.8.1).



Hình 4.2. Top 30 c trng quan trng theo giò tr trung bình tuyt i SHAP ca mĩ hnh XGB



Hnh 4.3. Biu SHAP Summary (beeswarm): phn b vị hng tnc ng ca tng c trng



Hnh 4.4. Ma trn nhm ln a lp theo loi tn cũg (chun hóa theo hng)

4.3 Thc nghim vị ònh giò hiu nng mũ hnh trón Jetson Orin Nano Super

Trong phn này, lun vn xut xóy dng mt h thng phòt hin xóm nhp mng IDS *phón tồn* trin khai trón mt cm **hai thít b biể NVIDIA Jetson Orin Nano Super** [59] nhm ònh giò kh nng hot ng trong mũ trng tị nguyể hn ch; óy lị hng tip cn in toàn biể a phón tồch v gn ngun d liu gim bng thũng vị thi gian phn hi [60, 61], trong khi còc nghiể cu IDS biể trc óy ch yu ònh giò suy lun n nũt [62]. H thng c thít k theo kin trũc x lý d liu thi gian thc hai tng: mt *cng phòt hin bt thng* (anomaly gate) bng autoencoder nh lc bt lu lng bnh thng trón Jetson #1, vị mt *b phón loi* PySpark PipelineModel ch x lý còc lung nghi vn trón Jetson #2. H tng trung tóm (Apache Kafka cho trun ti thũng ip, PostgreSQL qun lý d liu, InfluxDB lu ch s hiu nng theo thi gian, Grafana trc quan hóa vị Mailtrap kim th cnh bõ qua email) chy trón mt mỳ ch iu phi.

NVIDIA Jetson Orin Nano Super lị mt mỳ tồnh nhũng (single-board computer) tồch hp CPU kin trũc ARM 64-bit vị GPU NVIDIA, h tr tng tc suy lun hc mỳ ngay tị biể; cu hnh chi tit õ nõu tị Bng 3.7 (Chng 3) vị mc Mũ trng thc nghim. Do hn ch v tị nguyể tồnh toàn so vị mỳ ch trun thng, vic trin khai trón Jetson Orin Nano Super cho phỏp ònh giò kh nng tị u hóa mũ hnh vị hiu nng suy lun trong iu kin phn cng nhũng (edge computing).

Mũ hnh cú hiu nng tị u c xỏc nh phn ònh giò hiu nng phón lp phõa trón s c tồch hp v iõ pipeline x lý nhm thc hin nhim v phòt hin vị phón loi lu lng mng thnh hai nhũm: *Benign* vị *Attack*. Còc ch s ònh giò bao gm chõnh xỏc (Accuracy), Precision, Recall, F1-Score, thi gian d oòn trung bnh cho mi mu, thũng lng x lý (throughput) vị mc tiểu th tị nguyể h thng (CPU, RAM). Kt qu thc nghim cho phỏp phón tồch tồnh kh thi ca vic trin khai h thng IDS da trón hc mỳ trong mũ trng thít b biể cú tị nguyể gii hn.

4.3.1 Còc cũng c s dng trong h thng

Trong h thng phòt hin xóm nhp mng IDS c xut, ngoi còc cũng ngh x lý d liu ln õ trõnh bị Chng 2, lun vn s dng thỏm mt s cũng c vị nn tng mỗ ngun m nhm h tr trun ti d liu, lu tr, giõm sỏt hiu nng vị cnh bõ theo thi gian thc. C th:


- **Apache Kafka** [63] – Lị nn tng trun ti thũng ip phón tồn (distributed event streaming platform), c s dng tip nhn vị phón phi d liu lung theo c ch publish-subscribe. Trong h thng, Kafka úg vai trũ trung gian gia ngun d liu (CICIDS2017 c mũ phng bng Python script) vị thít b Jetson Orin Nano Super, m bõ kh nng trun ti bt ng b, chu li vị m rng linh hot.

- **Apache Spark Streaming** – Lì thịnh phn x lý d liu lung thi gian thc. Spark Streaming nhn d liu t Kafka Consumer, thc hin còc bc tin x lý c trng vị chuyn d liu n mĩ hnh hc mỳ ò c hun luyn thc hin suy lun.
- **PostgreSQL** – Lì h qun tr c s d liu quan h mĩ ngun m cú n nh vị kh nng m rng cao. Trong h thng, PostgreSQL c s dng lu tr kt qu d oàn, thũng tin cnh bào vị còc bn ghi phc v bào cò tng hp.
- **InfluxDB** – Lì c s d liu chui thi gian (Time-Series Database), ti u cho vic lu tr vị truy vn còc ch s theo thi gian. H thng s dng InfluxDB ghi nhn còc thũng s hieu nng nh thi gian suy lun, mc s dng CPU, b nh vị thũng lng x lý.
- **Grafana** – Lì nn tng trc quan húa d liu mĩ ngun m, cho phõp xóy dng còc dashboard theo thi gian thc. Grafana kt ni vị InfluxDB vị PostgreSQL hin th tnh trng hot ng ca h thng IDS cng nh thng kổ còc s kin tn cũg.
- **Mailtrap** – Lì cũg c kim th email trong mĩ trng gi lp. Trong giai on thc nghim, Mailtrap c s dng kim tra c ch gi cnh bào khi h thng phòt hin lu lng mng bt thng trc khi trin khai mĩ trng thc t.

Vic tồch hp còc cũg ngh trổn giũp h thng m bo kh nng x lý d liu thi gian thc, lu tr an toìn, giòm sòt hieu nng liổn tc vị kờch hot cnh bào kp thi khi phòt hin hnh vị xóm nhp.

4.3.2 Mũ hnh h thng xut

H thng phòt hìn xóm nhp c thit k theo kin trũc x lý d liu lung nh minh ha Hnh 4.5. Lung x lý tng th bao gm còc bc sau:



Hnh 4.5. Kin trũc h thng phòt hìn xóm nhp phón tòn thi gian thc trũn cm 2 Jetson Orin Nano Super

1. **Ngun d liu:** D liu t b CICIDS2017 c mũ phng theo thi gian thc thng qua mt Python script vị gi vị Kafka Producer trón topic `ids-network-flow`.
2. **Cng phòt hin bt thng (Jetson #1):** Jetson #1 m nhn vai trò `anomaly_gate`: mt autoencoder nh (hun luyn ch trón lu lng bnh thng) tòngh sai s tòi to (reconstruction error) cho tng lung. Còc lung cú sai s di ngng c coi lị bnh thng vị *c lc b*; ch còc lung *ngghi vn* mi c chuyn tip sang topic `ids-suspicious-flow`. C ch nịy gim òng k khi lng phi a vị suy lun Spark.
3. **B phón loi (Jetson #2):** Jetson #2 m nhn vai trò `classifier`: ti mũ hnh PySpark `PipelineModel` (vị tp c trng SHAP Top-30 ò chn) vị phón loi còc lung ngghi vn thnh *Benign* hoc *Attack*. Vector `u` vị khi trin khai gm 29 c trng: trong Top-30 theo xp hng SHAP cú `destination_port`, nhng c trng nịy b loi khi mũ hnh xut ra trin khai vớ lị kỏnh rừ r nhõn trón CICIDS2017 (Mc 4.2.5), nht quòn vị giao thc chng rừ r pha hun luyn.
4. **Ghi nhn hiu nng:** Mi nũt ghi nhn thi gian d oòn/mu, mc s dng CPU/RAM/nhit vị thng lng (gn nhõn theo `EDGE_NODE_ID`); còc ch s c lu vị InfluxDB.
5. **Lu tr vị cnh bõo:** Kt qu d oòn vị s kin tn cũng c lu vị PostgreSQL; khi phòt hin lu lng bt thng, h thng kỏch hot cnh bõo qua Email/Webhook (Mailtrap, Slack trong mũ trng kim th) t mt nũt chõnh c ch nh trõnh trng lp.
6. **Trc quan húa vị giõm sòt:** Grafana truy xut d liu t InfluxDB vị PostgreSQL xóy dng dashboard theo thi gian thc, giõm sòt trng thòi h thng vị thng kỏ còc s kin tn cũng.

Ba ch trin khai phón tòn. Cm hai Jetson h tr ba ch , la chn theo rịng buc ti vị tr:

- **Ch A – Pipeline split** (khuy n gh): Jetson #1 = cng bt thng (anomaly gate), Jetson #2 = b phón loi (classifier) (nh mũ t trón), giúp gim ti Spark nh lc lu lng bnh thng sm.
- **Ch B – M rng theo chiu ngang (Horizontal scaling):** c hai Jetson chy pipeline y trong cũng mt nhúm tiõu th (consumer group) ca Kafka nhm tng thng lng.
- **Ch C – Spark cluster:** mỳy ch MacBook lịm Spark master, hai Jetson lịm worker, phón tòn suy lun Spark trón cm. Nht quòn vị nguỷn tc mc Mũ trng thc nghim, MacBook ch m nhn iu phi (master), khũng chy executor; toịn b tòngh toòn suy lun vn nm trón hai Jetson.

Kin trũc nìy m bo tònñ mũ-un, tòch bit còc thính phn x lý, ng thi phứ hp vì mũ hính trin khai phón tòn trổn còc thit b biổn cú tị nguyổn hn ch nh Jetson Orin Nano Super.

c t cng bt thng (operating point). Cng autoencoder lị mt b lc *iu chnh c* ch khũng phi mt im c nh: nóng ngng giúp gim ti (offload) nhieu lu lng bõnh thng hn khi Spark (tng t l b qua ti cng, gate-skip) nhng cú th gim recall trổn lp tn cũng. Ngng ca cng c chn theo phón v (quantile) ca sai s tòi to tònñ trổn mt *tp kim nh benign*, gm 10% tòch t phn lu lng bõnh thng ca tp hun luy (seed=42); tp kim tra khũng tham gia vic chn ngng, trõnh rừ r kiu “ngng oracle”. Bng 4.12 trõnh bậ ng ònh i gia recall vị mc gim ti (recall–offload) khi quố còc mc quantile trổn tp kim nh nìy; im vn hính c chn theo ngón sòch tr/ chõnh xòc ca trin khai.

Bng 4.12. im vn hính ca cng bt thng khi quố quantile trổn tp kim nh benign (10% benign train, seed=42; t `gate_operating_points.csv`). FPR óy lị t l lung benign b cng chuyñ nhm sang b phón loi, khũng phi FPR ca toịn h thng.

Quantile (validation)	Ngng	Recall (Attack)	FPR	T l b qua ti cng (%)
0,90	0,0023	0,7589	0,1003	80,08
0,95	0,0052	0,7552	0,0506	84,36
0,99	0,0192	0,7420	0,0101	88,00
0,995	0,0317	0,7229	0,0053	88,70

4.3.3 La chn mũ hính cho thit b biổn

Trin khai trổn thit b biổn t ra còc rịng buc v tị nguyổn: RAM 8 GB chia s gia CPU vị GPU (trong ú PySpark JVM chim mt phn òng k), CPU ARM, cứg rịng buc v nhit /bng thũng ti biổn. Cng cn nhn mnñ rng vic chn Apache Spark trổn Jetson 8 GB phi chu chỉ phờ JVM/Spark òng k; Spark c dứg óy nhm *nht quòn* vì pha hun luy phón tòn, ch khũng nhm ti u tr suy lun trổn mt nữ; chỉ phờ ònh i nìy c nh lng qua so sònñ vì scikit-learn vị ONNX Runtime mc 4.3.6, cùn tng tc bng TensorRT lị hng nghiổn cu tng lai. Ba mũ hính i din cho ba th nghim khòc nhau c chn ònh giò:

1. **Decision Tree** – Mũ hính cóy n l, i din cho còch tip cn n gin nht.
2. **GBT (Gradient-Boosted Trees)** – i din cho phng phòp Boosting, s dng nhieu cóy yu kt hp tun t.
3. **Random Forest** – i din cho phng phòp Bagging, s dng ensemble 200 cóy song song.

C ba mũ hính u c hun luy trổn tp SHAP Top-30 c trng vị trin khai di dng PySpark PipelineModel.

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

```
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.50 +  
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (729.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.0 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.1 C  
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.2 C  
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.4 C  
[MONITOR:jetson-nano-1] CPU: 17.0% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.7 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (729.9MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.5 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (730.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.8 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (730.6MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.8 C  
[MONITOR:jetson-nano-1] CPU: 16.9% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.6 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 53.6 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 16.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 17.2% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.1 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.2 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 16.7% | MEM: 12.9% (731.3MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.0 C  
[MONITOR:jetson-nano-1] CPU: 17.8% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.1 C  
[MONITOR:jetson-nano-1] CPU: 17.6% | MEM: 12.9% (731.2MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.3 C  
[MONITOR:jetson-nano-1] CPU: 17.3% | MEM: 12.9% (731.1MB) | Throughput: 0.0 rps | Latency: 0ms | Attacks: 0  
Temp: 54.2 C
```

(a) Jetson #1 (jetson-nano-1): cng phòt hìn bt thng, giồm sòt tị nguyễn theo node


```
thainguyenvu -- bvdung@ubuntu: ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 -- 208x63  
~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.205 ... ~/Desktop/Thesis_IDS/jetson -- zsh - caffeineate ... ~/Desktop/Thesis_IDS/jetson -- zsh ... ~/Thesis_IDS/jetson -- ssh bvdung@192.168.1.50 ... +  
[MONITOR:jetson-nano-2] CPU: 72.4% | MEM: 58.6% (4196.6MB) | Throughput: 6.88 rps | Latency: 3.833ms | Attacks: 32  
Temp: 56.7 C  
[Stage 984:] (0 + 0) / 63  
[MONITOR:jetson-nano-2] CPU: 17.6% | MEM: 49.6% (3512.9MB) | Throughput: 6.07 rps | Latency: 3.968ms | Attacks: 32  
Temp: 56.2 C  
[MONITOR:jetson-nano-2] CPU: 17.3% | MEM: 57.5% (4111.6MB) | Throughput: 6.04 rps | Latency: 4.472ms | Attacks: 32  
Temp: 56.1 C  
[Stage 1889:] (0 + 6) / 63  
[MONITOR:jetson-nano-2] CPU: 97.7% | MEM: 54.7% (3980.9MB) | Throughput: 3.83 rps | Latency: 4.514ms | Attacks: 16  
Temp: 57.3 C  
[MONITOR:jetson-nano-2] CPU: 21.4% | MEM: 46.7% (3290.8MB) | Throughput: 6.88 rps | Latency: 4.334ms | Attacks: 32  
Temp: 56.2 C  
[MONITOR:jetson-nano-2] CPU: 67.8% | MEM: 55.0% (3927.6MB) | Throughput: 6.06 rps | Latency: 3.638ms | Attacks: 32  
Temp: 56.7 C  
[Stage 1847:] (0 + 6) / 63  
[MONITOR:jetson-nano-2] CPU: 68.2% | MEM: 58.9% (3611.9MB) | Throughput: 6.00 rps | Latency: 4.156ms | Attacks: 32  
Temp: 57.0 C  
[MONITOR:jetson-nano-2] CPU: 16.9% | MEM: 59.6% (4274.3MB) | Throughput: 6.88 rps | Latency: 4.483ms | Attacks: 32  
Temp: 55.9 C  
[jetson-nano-2 2,488] Batch: 187ms | Attacks: 2373/2488 | Avg: 9.7ms  
[MONITOR:jetson-nano-2] CPU: 85.5% | MEM: 49.1% (3474.6MB) | Throughput: 6.88 rps | Latency: 3.256ms | Attacks: 32  
Temp: 56.5 C  
[Stage 1886:] (0 + 0) / 63  
[MONITOR:jetson-nano-2] CPU: 66.6% | MEM: 51.7% (3673.5MB) | Throughput: 3.04 rps | Latency: 3.737ms | Attacks: 16  
Temp: 56.9 C  
[MONITOR:jetson-nano-2] CPU: 28.7% | MEM: 56.8% (4882.1MB) | Throughput: 6.88 rps | Latency: 4.399ms | Attacks: 32  
Temp: 56.1 C  
[MONITOR:jetson-nano-2] CPU: 74.4% | MEM: 54.8% (3988.1MB) | Throughput: 6.88 rps | Latency: 3.923ms | Attacks: 32  
Temp: 55.9 C  
[MONITOR:jetson-nano-2] CPU: 34.2% | MEM: 56.8% (4863.8MB) | Throughput: 5.88 rps | Latency: 4.574ms | Attacks: 31  
Temp: 56.8 C  
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 55.8% (3924.2MB) | Throughput: 6.88 rps | Latency: 4.42ms | Attacks: 32  
Temp: 56.1 C  
[Stage 1149:] (1 + 5) / 63  
[MONITOR:jetson-nano-2] CPU: 98.8% | MEM: 59.1% (4234.9MB) | Throughput: 3.04 rps | Latency: 3.157ms | Attacks: 16  
Temp: 57.2 C  
[MONITOR:jetson-nano-2] CPU: 16.8% | MEM: 52.5% (3733.5MB) | Throughput: 6.88 rps | Latency: 3.994ms | Attacks: 32  
Temp: 55.9 C  
[MONITOR:jetson-nano-2] CPU: 18.8% | MEM: 57.8% (4877.7MB) | Throughput: 5.98 rps | Latency: 4.577ms | Attacks: 31  
Temp: 56.1 C  
[Stage 1187:] (0 + 6) / 63  
[MONITOR:jetson-nano-2] CPU: 45.8% | MEM: 68.6% (4351.7MB) | Throughput: 5.98 rps | Latency: 4.121ms | Attacks: 31  
Temp: 56.7 C  
[MONITOR:jetson-nano-2] CPU: 16.7% | MEM: 52.7% (3758.8MB) | Throughput: 5.99 rps | Latency: 3.338ms | Attacks: 31  
Temp: 55.9 C  
[Stage 1212:] (3 + 3) / 63
```

(b) Jetson #2 (jetson-nano-2): b phón loi PySpark, thng lng ~6 lung/giớy, tr suy lun ~4 ms, m tn cũng theo lữ


Hình 4.6. Giao din terminal khi pipeline IDS hot ng trở hai node Jetson Orin Nano Super:
(a) node cng lc bt thng vị (b) node phón loi PySpark




Hình 4.7. Dashboard Grafana ghi nhận hiệu năng IDS theo thời gian thực




Hình 4.8. Email cảnh báo tấn công gửi qua Mailtrap trong môi trường kiểm thử (nhằm chấp thuận giai đoạn thử nghiệm sản phẩm; mã nguồn cảnh báo vị trí đang thử nghiệm ip gốc nguồn khi triển khai trở về Jetson)



Hình 4.9. Dashboard Grafana hin th chỉ tit còc cuc tn cũng c phòt hin vị phón loi theo thi gian



Hình 4.10. Dashboard Grafana ti thi im ti nh ca ch tòch pipeline: nửt cng (jetson-nano-1) ch s dng khong 5 % CPU trong khi nửt phón loi PySpark (jetson-nano-2) t ti 91 %



Hình 4.11. Thông báo cảnh báo tấn công gửi qua Slack Incoming Webhook (nhập tập giao diện thử nghiệm; nội dung thông báo gửi nguồn khi triển khai trên Jetson)

Hình 4.6 minh họa giao diện terminal thực thi pipeline IDS đang xử lý dữ liệu từ Jetson Orin Nano Super, bao gồm thông tin về thông tin, trạng thái thông tin cũng như hình ảnh. Hai dashboard Grafana (Hình 4.7 và Hình 4.9) cho phép giám sát hiệu suất hệ thống và chỉ số cục bộ theo thời gian thực. Hình 4.10 ghi lại thời gian thực, cho thấy mức phân bổ tài nguyên của hệ thống pipeline: mức tiêu thụ CPU không quá 5% trong khi mức phân bổ PySpark đạt 91%, xác nhận mức phân bổ tài nguyên phân bổ hợp lý và nguồn cung cấp cho các phân tích năng lượng thông tin phân bổ. Khi phân bổ tài nguyên cũng, hệ thống thông tin gửi cảnh báo qua nhiều kênh: email thông qua Mailtrap SMTP (Hình 4.8) và tin nhắn Slack (Hình 4.11).

4.3.4 Kiểm tra huấn luyện các mô hình mạng vi mô triển khai Spark

Bảng 4.13 trình bày kiểm tra huấn luyện vị trí ba mô hình mạng vi mô triển khai Spark (mô hình mô hình trung thực nghiệm) trước khi triển khai xung đột biến.

Bảng 4.13. Kiểm tra huấn luyện các mô hình mạng vi mô cho triển khai biến (SHAP Top-30)

Mô hình	F1-Score	Accuracy	Thời gian huấn luyện (s)	Kích thước (MB)
Decision Tree	0,9814	0,9943	24,4	0,046
GBT	0,9753	0,9925	341,8	0,865
Random Forest	0,9826	0,9947	687,3	4,427

Với tiêu chí nhận biết biến (edge-aware), Decision Tree có kích thước mô hình nhỏ nhất (0,046 MB), nhỏ hơn Random Forest khoảng 96 lần về thời gian huấn luyện nhanh hơn khoảng 28 lần; F1/Accuracy còn có thể củng cố chỉ số phân tích chọn mô hình triển khai. (Các mô

hình ng viồn biể c hun luyn trổn mu con phón tng khi xut va b nh mt nũt, nỏn F1 thp hn chũt ờt so vi kt qu hun luyn phón tòn y Bng 4.3; chờnh xỏc chờnh thc ly t pha hun luyn y .)

4.3.5 Kt qu o hiu nng (benchmark) trổn Jetson Orin Nano Super

Bng 4.14 trờnh bỳ kt qu o hiu nng (benchmark) thc t trổn Jetson Orin Nano Super. Mi cu hnh c o lp li 5 ln; trc mi ca s o cú giai on khi ng (warm-up) bng chờnh lu lng tht lỳm nũng JVM/JIT, vị d liu warm-up b loi khi ca s o; kt qu bõo cõo lỳ trung bõnh $\pm$ lch chun qua cõc ln chy. Hai loi tr c ghi nhn: (i) *tr suy lun* (tin x lý + d õn) trổn tng nũt, vị (ii) *tr u cui* (t thi im producer gĩ n khi cú phõn quyết) tõnh t nhõn thi gian ca producer; giò tr tuyt i ca loi (ii) ch cú ý ngha khi cõc mỳy ng b ng h NTP. Cõc phón v tr (p50/p95/p99) c tõnh mc tng ln chy t *log thũ theo tng lung* trong ỹng ca s ti; vi cm nhiu nũt, p95 bõo cõo lỳ p95 ca nũt xu nht (khũng ly phón v ca cõc giò tr trung bõnh theo nũt).

Bng 4.14. So sõnh hiu nng trin khai trổn Jetson Orin Nano Super

Mũ hnh	Thũng lng (mu/giõy)	tr suy lun (ms) p50 / p95 / p99	CPU (%)	RAM (%)	Kõch thc (MB)
Decision Tree	22,0	441 / 537 / –	46,4	21,9	0,046
GBT	24,3	414 / 439 / –	40,9	24,0	0,865
Random Forest	26,8	378 / 397 / –	35,2	27,5	4,427

4.3.6 So sõnh engine suy lun: chi phõ ca vic ng nht stack

Lun vn trin khai mũ hnh dĩ dng PipelineModel ca Spark *ng nht vi pha hun luyn phón tòn*: cũng mt stack va hun luyn trổn cm va suy lun trổn thĩt b. *nh lng chi phõ ònh i ca s ng nht nỳ*, lun vn o li *cũng mt* mũ hnh Random Forest (cũng siõu tham s) trổn *cũng tp c trng SHAP õ chn* trin khai nhng qua cõc engine nh hn ch mt nũt: scikit-learn (CPU, khũng JVM) vị ONNX Runtime (CPU execution provider; Bng 4.15, sinh t benchmark_engines.py). Vớ cũng thut toõn vị c trng nỏn chờnh xỏc tng ng; phõp so sõnh tp trung vị *chi phõ suy lun*. (C ba dũng ca Bng 4.15 c o li trong *cũng mt phiõn* trổn cũng trng thõi bo mch so sõnh cũng bng, nỏn dũng PySpark chõnh lch nh so vi Bng 4.14 o phiõn trc: 22,6 so vi 26,8 lung/giõy, do khõc phiõn o vị xung CPU.) Kt qu o (Bng 4.15) cho thy stack JVM/Spark chu chi phõ suy lun cao hn õng k so vi scikit-learn trổn bo mch ARM 8 GB: thũng lng thp hn khõng 9 ln, tr p95 cao hn khõng 11 ln, t l RAM gn gp ỹi vị nng lng mi suy lun cao hn khõng 25 ln. Biõn dch cũng mũ hnh rng ngu nhiõn sang ONNX

CHNG 4. THC NGHIM, ÒNH GIÒ VỊ THO LUN

Runtime cũn ni rng khong còch nịy òng k: $\approx 7\,900$ lung/gióy vì p95 1,1 ms, tc gp ≈ 348 ln thũng lng ca Spark ò trin khai, mc nng lng ch $\approx 2\%$ so vì scikit-learn; vic nõu rử iu nịy lị c s cho hng phòt trin *xut mữ hơnh sang ONNX/TensorRT suy lun* trong khi vn gị Spark cho hun luyn (vic tồch hp phiổn ONNX vịo pipeline streaming vị khai thồc GPU qua TensorRT thuc hng phòt trin).

Bng 4.15. Chi phờ suy lun mt nửt trổn cững mữ hơnh/c trng (Spark vs sklearn vs ONNX), o trổn nửt phón loi trong cững iu kin bo mch (batch 10; nng lng lị phn *hot ng*, ò tr *idle*)

Engine	Thũng lng (lung/gióy)	tr p95 (ms)	RAM (%)	Nng lng /suy lun (mJ)
PySpark (trin khai)	22,6	532	24,3	71,6
scikit-learn	204,4	49,8	13,3	2,91
ONNX Runtime	7870,8	1,1	15,7	0,06

4.3.7 Kt qu ba ch trin khai phón tòn


Ngoi vic so sònh còc mữ hơnh trổn mt nửt, lun vn ònh giò ba ch trin khai phón tòn trổn cm hai Jetson Orin Nano Super (Bng 4.16). Ch s chònh gm thũng lng, tr p95 (ms), t l b qua ti cng (gate-skip: % lu lng bõnh thng c cng lc khi suy lun Spark) vị F1 trổn lp tn cững. *Thũng lng* c nh ngha lị s *phòn quyt cui cững* ghi vịo PostgreSQL trổn gióy (mt lung nhn phòn quyt hoc ti cng (nu b b qua lị benign) hoc ti b phón loi), khũng cng dn u ra ca hai tng trờnh m trũng lung c chuyñ tip ch pipeline split.

Bng 4.16. So sònh ba ch trin khai phón tòn trổn cm 2 Jetson Orin Nano Super

Ch	Thũng lng (lung/gióy)	tr p95 (ms)	B qua ti cng (%)	Nng lng /suy lun (mJ)	F1 (Attack)
Mt nửt (single)	2,60 $\pm$ 0,41	12,3 $\pm$ 3,0	(ni tuyñ)	2490	†
A: Pipeline split	62,5 $\pm$ 0,6	13,1 $\pm$ 2,6	95,8	178	†
B: Horizontal scaling	5,9 $\pm$ 1,4	21,6 $\pm$ 19,2	(ni tuyñ)	2250	†
C: Spark cluster	90,0 $\pm$ 25,6	23,9 $\pm$ 17,8	97,9	119	†

Phòt lị CICIDS2017 100 lung/gióy; trung bõnh $\pm$ lch chun trổn ≥ 3 ln lp; p95 tờnh t log thũ tng lung (nửt xu nht). “(ni tuyñ)”: vai trờ *full*, cng chy trong cững tin trờnh vị còc lung b b qua vn c ghi phòn quyt nõn khũng cú t l b qua riổng. †: cht lng phòt hìn khũng ph thuc ch (còc ch đũng cững mt mữ hơnh xut ra); F1 lp tn cững ngoi tuyñ xem Bng 4.6.

Kt qu thc o cho thy: ch *pipeline split* tồch cng khi b phón loi Spark giữp thũng lng phòn quyt tng t 2,6 lỏn 62,5 lung/gióy (gp ≈ 24 ln) vì p95 gn nh khũng i, nh cng lc 95,8% lu lng bõnh thng vị khũng cũn b Spark chn vùng x lị. *M rng theo chiu ngang* ch tng xp x gp ùi mt nửt (5,9 so vì 2,6) vớ mi nửt vn chy trn b phón loi Spark trong tin trờnh. *Spark cluster* (cng




Hình 4.12. Thũng lng vị tr p95 ca bn ch trìn khai trởm cm 2 Jetson

+ b phón loi ni cm Spark standalone) t thũng lng trung bnh cao nht (90,0) nhng dao ng ln gia cò ln chy (± 26) vị ph thuc thỏm nũt ch (master) trởm mỳ iu phi, nỏn pipeline split vn lị khuy n ngh mc nh. *Nng lng mi suy lun* o bng tegrastats (nn idle 30 gióy trc mi ca s ti; ch hai nũt cng cũng sut c hai bo mch): mc ti 100 lung/gióy, phn cũng sut *hot ng* (õ tr idle) nm di ngng nhiu ly mu ($< 0,15$ W mi nũt), do ú bng bào cò nng lng *toin bo mch* trởm mi phòn quy t, tc thc o mc dịn tri cũng sut bo mch theo thũng lng cp trìn khai (khũng phi chi phờ riỏng ca mũ hỏnh): cò ch dũng cng (A, C) dịn tri cũng sut hai bo mch trởm s phòn quy t ln gp 24–35 ln, gim nng lng mi phòn quy t $\approx 2,5$ J xug 0,12–0,18 J.

4.3.8 Phón tórch vị la chn mĩ hnh

Hnh 4.13 minh ha trc quan s khòc bit gia ba mĩ hnh v thng lng, tr vị mc s dng RAM trn Jetson Orin Nano Super.



Hnh 4.13. So sònh hiu nng ba mĩ hnh trn Jetson Orin Nano Super

Kt qu benchmark cho th y s ònh i rủ rìng gia còc ch s:


- **Random Forest** t thng lng cao nht (26,8 mu/giý) nh Spark ti u hóa song song trn nhiu cý, nhng s dng RAM nhiu nht (27,5%) vị kòch thc mĩ hnh ln nht ($\approx 4,4$ MB).
- **GBT** cú hiu nng trung bnh tt c còc ch s, úng vai trò cu ni gia Decision Tree vị Random Forest.
- **Decision Tree** cú F1-Score 0,9948 (SHAP Top-30, ngoi tyn), s dng RAM thp nht (21,9%), vị mĩ hnh cú kòch thc rt nh ($\approx 0,05$ MB). Mc dù thng lng thp nht (22,0 mu/giý), giò tr nì y vn òp ng yóu cu giòm sòt thì gian thc cho mng quy mĩ va vị nh.

Hnh 4.14 th hin s ònh i a chiu gia còc tiỏu chò la chn mĩ hnh. Decision Tree chim u th hai tiỏu chò quan trng nht cho thit b biỏn: RAM thp vị kòch thc mĩ hnh nh.

Decision Tree c chn lĩm mĩ hnh trin khai chònh trn thit b biỏn đa trn ba tiỏu chò:

1. **Cht lng phòt hin:** F1-Score 0,9948 – vì tp c trng SHAP Top-30 ò c la chn (õ loi tr rừ r), mt cý quy nh n l vn nm bt c còc mu phón loi, ch kỏm Random Forest 0,0007 im F1.
2. **Hiu qu tị nguyỏn:** Ch s dng 21,9% RAM, gim òp lc lớn garbage collector ca JVM vị m bo tòn n nh lóu dị trn thit b gii hn tị nguyỏn.
3. **Tòn kh chuyn:** Kòch thc mĩ hnh $\approx 0,05$ MB cho phỏp trin khai trn còc thit b IoT cú b nh hn ch hn.

Đánh đổi giữa các mô hình trên Jetson Orin Nano Super
(chuẩn hoá min-max, càng ra ngoài càng tốt)



Hình 4.14. Biểu đồ radar thể hiện sự đánh đổi (trade-off) giữa các mô hình trên thiết bị

4.4 Tho luận vị So sánh tng hp

Kết quả thực nghiệm cho thấy việc kết hợp các mô hình đã được tối ưu hóa bằng SHAP và phương pháp ensemble (Hybrid Bagging) là một hướng tiếp cận phù hợp cho hệ thống IDS trên bộ dữ liệu CICIDS2017. Đặc biệt, mô hình đã loại bỏ được nhiễu, đạt được F1-Score 0,9966 (Hybrid Bagging, SHAP Top-30) trong bài toán phân loại, giảm thiểu sai sót và tăng độ chính xác, phù hợp với yêu cầu của bài toán.

Cụ thể, khi triển khai trên thiết bị Jetson Orin Nano Super, Decision Tree và SHAP Top-30 đạt được F1-Score 0,9948 ngoại tuyến (loại bỏ nhiễu; bộ mô hình xuất ra kết quả, huấn luyện trên mẫu phân loại 20%, t 0,981), tổng lượng 22,0 MB/giây, sử dụng 21,9% RAM. Các số liệu này cho thấy mô hình đã được tối ưu hóa và phù hợp cho việc triển khai hệ thống IDS đã được tối ưu hóa để giảm thiểu sai sót và tăng độ chính xác của bài toán phân loại, giảm thiểu sai sót và tăng độ chính xác của bài toán.

Chng 5. KT LUN VỊ HNG PHÒT TRIN

Trong chng nỳ, lun vn s trnh bỳ nhng kt qu mỳ lun vn ã t c so vĩ mc tiõu c t ra t ban u khi bt u thc hin. Bõn cnh ú, lun vn cng trnh bỳ nhng hn ch vĩa ra hng phòt trin trong tng lai ca nghiõn cu.

5.1 Nhng úng gúp chõnh ca lun vn

Sau khi thc hin lun vn vĩ tỳi “*Phòt hin xõm nhp (IDS) da trõn Apache Spark cho bo mt mng IoT*”, lun vn ã t c mt s kt qu chõnh tng ng vĩ cõc mc tiõu ra ban u:

- **Xõy dng nn tng x lý d liu ln:** xut vị trin khai thnh cõng h thng IDS trõn nn tng Apache Spark. Gii phõp nỳ t n dng kh nng tõnh tõn song song x lý cõc lung d liu mng t mĩi trng IoT, hng ti kh nng m rng trong vic giõm sõt bo mt; kh nng x lý phõn tõn c kim chng mc minh chng khõì nim (proof-of-concept) trõn cm thit b biõn.
- **Ci thĩn hĩu nng phòt hin vĩ mĩ hõnh hc t hp:** Phòt trin mĩ hõnh Hybrid Bagging Ensemble kt hp Top-3 thut tõn cú F1 cao nht trõn t p kim nh (xõc nh chng thc nghiĩm, khũng c nh trc). Di quy trnh ònh giõ loi tr rừ r d liu, mĩ hõnh t F1-score 0,9966 vĩ c so sõnh vĩ cõc mĩ hõnh n l kõm kim nh ý ngha thng kõ khng nh khõc bit (nu cú) lĩ òng k.
- **ònh giõ trung thc, loi tr rừ r d liu:** Nhn din vị x lý cõc ngun rừ r thng gp trõn CICIDS2017 (c trng `destination_port` rừ r nhõn vị trũng lp lung mc c trng), ng thi nh lng mc thi phng hĩu nng do rừ r giũp kt qu phn ònh ỹng nng lc thc ca mĩ hõnh.
- **Ti u hĩa vị Gii thờch mĩ hõnh:** ng dng k thut SHAP la chn cõc c trng quan trng nht, giũp gim s lng c trng (khong 60%) mĩ vn gi nguyõn hĩu nng phõn loi: di cu hõnh loi tr rừ r d liu, Random Forest vĩ SHAP Top-30 t F1 0,9955, tng ng cu hõnh dũng toĩn b c trng (0,9949). ng thi, SHAP cung cp kh nng gii thờch chi tit v quyĩt nh ca mĩ hõnh, tng cng tin cy vĩ kh nng ng dng thc t.

5.2 Hn ch ca tỳi

Mc dũ ã t c cõc kt qu nõu trõn, lun vn vn cùn mt s hn ch cn c khc phc trong cõc giai õn tĩp theo:

- **Phm vi phón loi:** H thng trin khai chõnh đa trõn bị toàn phón loi nh phón (Tn cũng so vì Bõnh thng); lun vn õ b sung ònh giò a lp theo tng loi tn cũng (Mc 4.2.9) phón tõch im yu cõc lp him, nhng vic xõy dng mt b phón loi a lp hoĩn chnh cho trin khai thi gian thc vn lĩ hng phòt trin tip theo.
- **Mũ trng trin khai:** H thng c hun luyn phón tòn trõn cm Spark gm mỳy ch Mac vì hai nũt Jetson Orin Nano Super Developer Kit (8 GB), vị chõnh hai thĩt b nĩy cng c dũng trin khai, o hĩu nng thc t pha suy lun; tuy nhiõn vic kim chng trõn h tng mng IoT thc t vì hĩng nghõn thĩt b u cui vị lu lng trc tuyõn vn lĩ thõch thc cn thc hin.
- **Phm vi b d liu:** Lun vn õ thĩt lp quy trõnh ònh giò tng quòt hóa liõn b d liu (hun luyn trõn mt b, kim tra trõn b khõc, Mc 4.2.8.1) trõn cp CICIDS2017 vị CSE-CIC-IDS2018; vic m rng sang nhĩu b mĩ hn (CIC-IoT, RoEduNet) cng c kt lun v tng quòt hóa vn lĩ hng tip theo.
- **Quy trõnh chn mũ hõnh thĩnh phn cho ensemble:** Top-3 mũ hõnh thĩnh phn c la chn đa trõn F1-Score o trõn mt *tp kim nh (validation)* tõch riõng t tp hun luyn, nõn tp kim tra hoĩn toĩn khũng tham gia vĩa khõu chn mũ hõnh. ònh i ca cõch lĩm nĩy lĩ cõc mũ hõnh c s c hun luyn trõn phn d liu nh hn (sau khi trõch ra tp kim nh), vị vic xp hng c trng RF/SHAP vn c rũt t tp hun luyn gc vị gi c nh xp hng li theo tng ln lĩ mu lĩ s cht ch hn nhng tn kõm hn.
- **Quy mũ d liu vị phn cng biõn:** Khõa cnh x lĩ phón tòn mĩ c kim chng mc minh chng khõĩ nim (proof-of-concept) trõn cm hai thĩt b Jetson (8 GB) vị khi lng d liu c vị triu lung ca CICIDS2017, ch cha phi quy mũ d liu ln thc th (terabyte tr liõn) hay trõn cm tõnh toàn nhĩu nũt mnh; vic ònh giò kh nng m rng quy mũ ln hn vn lĩ hng tip theo.
- **Gi nh phng phõp lun:** Tp gi li (holdout) dũng kim tra n nh thc cht cũng phón phi vị tp kim tra (in-distribution), nõn vic ònh giò tng quòt hóa thc s phi đa vĩa thờ nghĩm khõc b (cross-dataset, Mc 4.2.8.1); ngoĩi ra, s Hybrid Bagging (3, 2, 2) cú trng s theo F1 lĩ mt heuristic thiõn v cõc b hc mnh, khũng phi bagging gim phng sai kinh in.
- **Cha ònh giò trc lu lng i khõng:** H thng cha c kim th trc cõc tn cũng i khõng/nõ trõnh (adversarial/evasion) vị gi nh phón b tn cũng xp x CICIDS2017; do ú bn vng trc k tn cũng c ý ònh la mũ hõnh vn lĩ cõu hi m.

- **Trn recall do cng bt thng vị mc hoịi thin ca h tng:** Vic t cng phòt hin bt thng (anomaly gate) trc b phón loi to mt trn cng cho recall: còc tn cũng b cng b sút (false-negative ca cng) s b loi trc khi ti b phón loi, óy lị mt rì ro an ninh ch khũng ch lị ònh i ti; bốn cnh ú, h tng i kòm (Kafka, Grafana, PostgreSQL, InfluxDB...) hin mi mc minh chng khòì nim trong phùng lab, cha bt c ch xòc thc vị mỗ hóa.

5.3 Hng phòt trin trong tng lai

Da trổn nhng kt qu ò t c vị nhn ðin còc hn ch hin cú, lun vn xut mt s hng phòt trin trong tng lai, mi hng tng ng vị mt hn ch ò nõu:

- **Nóng cp kh nng nhn ðin a lp:** M rng mỗ hnh cú th phón loi chỉ tit còc loi tn cũng ph bin trong mng IoT nh DoS/DDoS, Botnet (Mirai), Infiltration vị Heartbleed, tin ti b phón loi a lp hoịi chnh cho trin khai thi gian thc.
- **Ci thin nhỹ cho còc lp tn cũng him:** Phón tòch hng nhm ln gia còc lp (Mc 4.2.9) cho thy còc lp him suy gim theo hai kiu: nhm loi trong cùng h (XSS b nhn thnh Brute Force) vị lt hn thnh Benign (SQL Injection, 54% Bot). Bn hng khc phc tng ng: (i) *x lý mt cón bng cú ch òch* pha hun luy n a lp: undersampling lp Benign, oversampling/SMOTE [64] cho lp him (òp dng *sau* khi chia tp trònh rù r), hoc gp còc bin th cùng h (gp ba bin th Web Attack thnh mt lp) i mn nh danh ly recall; (ii) *iũ chnh thut toòn:* trng s lp cho bị a lp, focal loss [65] vị XGBoost, vị h ngng quy t nh theo lp (chp nhn thỏm false positive lp him vớ vị IDS, bõo nhm r hn b sút); (iii) *kin trũc phón tng:* tn dng chònh thit k cng hai tng ca tị: tng nh phón trổn biổn gi recall tng, cùn b nh danh loi hun luy n *ch trổn còc lung tn cũng* (khũng phi cnh tranh vị 380 nghơn mu Benign) vị cú th hun luy n li ngoi tuy n vị cón bng lp mị khũng ng h thng ang chy; (iv) *c trng chui thi gian theo host* (chu k kt ni lp, entropy kòch thc gúi qua ca s trt), nhm tr ỹng bnh ca hnh vị beaconing C&C khin 54% Bot lt li, vn khũng th hin hnh qua thng kổ tng lung c lp.
- **Kim chng trổn b d liu IoT chuyổn bit:** ònh giò quy trnh trổn còc b d liu cha lu lng IoT thc th (Bot-IoT, TON_IoT, CIC-IoT-2023) vị m rng thờ nghim liổn b d liu lổn toịn b CSE-CIC-IDS2018, nhm thu hp khong còch gia phm vị “IoT” ca tị vị d liu CICIDS2017 hin ðứng.
- **Ti u suy lun biổn bng ONNX/TensorRT:** Tòch hp phiổn suy lun ONNX vộ pipeline streaming vị tng tc bng TensorRT trổn GPU Jetson gim chi phò JVM/Spark pha suy

lun (trong khi vn gi Spark cho hun luyn phón tòn): kt qu o ngoi tuyt Bng 4.15 cho thy cng mũ hnh rng ngu nhĩn chy qua ONNX Runtime t thũng lng gp ≈ 348 ln bn PySpark ò trin khai, xóc nhn d a rt ln ca hng nịy; ng thi o tr u cui y (t Kafka n phòn quyrt ri ghi c s d liu).

- **Cng c kim nh thng kổ:** Tng s ln ly mu li N (kổm kim nh chổo lng) vị xp hng li c trng RF/SHAP theo tng ln ly mu li loi nt phn rừ r chn lc cùn sút ca vic gi c nh bng xp hng c trng.
- **bn vng trc tn cũng i khòng:** ònh giò vị gia c h thng trc lu lng nõ trờnh (adversarial/evasion), c bit lị hai b mt tn cũng mi do cng bt thng to ra: gi dng lu lng bnh thng vt cng vị c ý to sai s tòi to cao dn ti lỏn nũt phón loi.
- **Cng c h tng vn hnh:** Bt xóc thc vị mĩ húa (TLS/SASL) cho Kafka, PostgreSQL, InfluxDB; b sung c ch tòi hiu chnh ngng cng bt thng theo lu lng trc tuyt; vị trin khai th nghim trỏn nn tng òm mý lai nóg tờnh kh dng.
- **Tỏch hp hc mỳy trc tuyt (Online Learning):** Nghiỏn cu còc gii phòp cp nht tham s mũ hnh theo thi gian thc (real-time stream processing) mị khũng cn hun luyn li toịn b d liu, giũp h thng thờch ng nhanh vì còc bin th tn cũng mi vị hin tng trũi khỏi nìm (concept drift) [66].

Ph 1c A. CŨNG TRŒNH ANG CHUN B CŨNG B

Phn n1y lit k1c c1c bn tho khoa hc li1n quan n 1t1 lun vn (v1t chung vi Nguy1n V Th1i, Tr1 Nh1 v1 TS. Nguy1n Vn D), hin ang c ho1n th1n gi ng:

1. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Comparison of Dimensionality Reduction and Feature Selection for Network Intrusion Detection on Apache Spark ML with a Leakage-Aware Evaluation Pipeline,” National Conference on Fundamental and Applied Information Technology Research (FAIR), 2026.
2. Thai Vu Nguyen, Dung Van Bui, Nhut Tri Do, Van Du Nguyen, “A Distributed Real-Time Intrusion Detection System on a Jetson Orin Nano Super Edge Cluster using Kafka and PySpark,” Symposium on Information and Communication Technology (SOICT), 2026.

TÌ LIU THAM KHO

- [1] Ansam Khraisat, Iqbal Gondal, Peter Vamplew, và Joarder Kamruzzaman. “Survey of intrusion detection systems: techniques, datasets and challenges”. In: *Cybersecurity 2.1* (2019), pp. 1–22.
- [2] Mohamed Amine Ferrag, Leandros Maglaras, Helge Janicke, Jianhua Jiang, và Lei Shu. “Deep learning for cyber security intrusion detection: Approaches, datasets, and comparative study”. In: *Journal of Information Security and Applications* 50 (2020), p. 102419.
- [3] R Vinayakumar, Mamoun Alazab, K P Soman, Prabakaran Poornachandran, Ameer Al-Nemrat, và Sitalakshmi Venkatraman. “Deep learning approach for intelligent intrusion detection system”. In: *IEEE Access* 7 (2019), pp. 41525–41550.
- [4] Amardeep Singh và Julian Jang-Jaccard. *Autoencoder-based Unsupervised Intrusion Detection using Multi-Scale Convolutional Recurrent Networks*. 2022. arXiv: [2204.03779 \[cs.CR\]](https://arxiv.org/abs/2204.03779).
- [5] Pengfei Sun, Pengju Liu, Qi Li, Chenxi Liu, Xiangling Lu, Ruochen Hao, và Jinpeng Chen. “DL-IDS: Extracting features using CNN-LSTM hybrid network for intrusion detection system”. In: *Security and Communication Networks* 2020 (2020), p. 8890306. DOI: [10.1155/2020/8890306](https://doi.org/10.1155/2020/8890306).
- [6] N. Dash, S. Chakravarty, A. K. Rath, và còc cng s. “An optimized LSTM-based deep learning model for anomaly network intrusion detection”. In: *Scientific Reports* 15 (2025), p. 1554. DOI: [10.1038/s41598-025-85248-z](https://doi.org/10.1038/s41598-025-85248-z).
- [7] Sukhvinder Singh Bamber, Aditya Vardhan Reddy Katkuri, Shubham Sharma, và Mohit Angurala. “A hybrid CNN-LSTM approach for intelligent cyber intrusion detection system”. In: *Computers & Security* 148 (2024), p. 104146. DOI: [10.1016/j.cose.2024.104146](https://doi.org/10.1016/j.cose.2024.104146).
- [8] Tasnimul Hasan, Abrar Hossain, Mufakir Qamar Ansari, và Talha Hussain Syed. *Enhanced Intrusion Detection in IIoT Networks: A Lightweight Approach with Autoencoder-Based Feature Learning*. arXiv:2501.15266. 2025.
- [9] K. Baalaji và còc cng s. “Deep learning-based ensemble stacking for enhanced intrusion detection in IoT-edge platforms”. In: *Discover Applied Sciences* 7 (2025), p. 928. DOI: [10.1007/s42452-025-06871-z](https://doi.org/10.1007/s42452-025-06871-z).

- [10] Muhammad Zubair Asghar và cộng sự. “HED-ID: an edge-deployable and explainable intrusion detection system optimized via metaheuristic learning”. In: *Scientific Reports* 16 (2026), p. 2313. DOI: [10.1038/s41598-025-32183-8](https://doi.org/10.1038/s41598-025-32183-8).
- [11] İlhan Firat Kilincer, Fatih Ertam, và Abdulkadir Sengur. “Machine learning methods for cyber security intrusion detection: Datasets and comparative study”. In: *Computer Networks* 188 (2021), p. 107840. DOI: [10.1016/j.comnet.2021.107840](https://doi.org/10.1016/j.comnet.2021.107840).
- [12] M. Al Lail, A. Garcia, và S. Olivo. “Machine learning for network intrusion detection—A comparative study”. In: *Future Internet* 15.7 (2023), p. 243. DOI: [10.3390/fi15070243](https://doi.org/10.3390/fi15070243).
- [13] Yung-Chung Wang, Yi-Chun Hwang, Han-Xuan Chen, và Shu-Ming Tseng. “Network Anomaly Intrusion Detection Based on Deep Learning Approach”. In: *Sensors* 23.4 (2023), p. 2171. DOI: [10.3390/s23042171](https://doi.org/10.3390/s23042171).
- [14] L. Yang, A. Moubayed, I. Hamieh, và A. Shami. “Tree-Based Intelligent Intrusion Detection System in Internet of Vehicles”. In: *2019 IEEE Global Communications Conference (GLOBECOM)*. 2019, pp. 1–6. DOI: [10.1109/GLOBECOM38437.2019.9013892](https://doi.org/10.1109/GLOBECOM38437.2019.9013892).
- [15] L. Yang, A. Moubayed, và A. Shami. “MTH-IDS: A Multi-Tiered Hybrid Intrusion Detection System for Internet of Vehicles”. In: *IEEE Internet of Things Journal* 9.1 (2022), pp. 616–632. DOI: [10.1109/JIOT.2021.3084796](https://doi.org/10.1109/JIOT.2021.3084796).
- [16] L. Yang, A. Shami, G. Stevens, và S. DeRusett. “LCCDE: A Decision-Based Ensemble Framework for Intrusion Detection in The Internet of Vehicles”. In: *2022 IEEE Global Communications Conference (GLOBECOM)*. 2022, pp. 1–6. DOI: [10.1109/GLOBECOM48099.2022.10001280](https://doi.org/10.1109/GLOBECOM48099.2022.10001280).
- [17] R. Baidar, S. Maric, và R. Abbas. *Hybrid deep learning–federated learning powered intrusion detection system for IoT/5G advanced edge computing network*. <https://arxiv.org/abs/2509.15555>. arXiv. 2025.
- [18] B. Williams và L. Qian. “Semi-supervised learning for intrusion detection in large computer networks”. In: *Applied Sciences* 15.11 (2025), p. 5930. DOI: [10.3390/app15115930](https://doi.org/10.3390/app15115930).

- [19] N. Albanbay, Y. Tursynbek, K. Graffi, R. Uskenbayeva, Z. Kalpeyeva, Z. Abilkaiyr, và Y. Ayapov. “Federated learning-based intrusion detection in IoT networks: Performance evaluation and data scaling study”. In: *Journal of Sensor and Actuator Networks* 14.4 (2025), p. 78. DOI: [10.3390/jsan14040078](https://doi.org/10.3390/jsan14040078).
- [20] Thien Duc Nguyen, Samuel Marchal, Markus Miettinen, Hossein Fereidooni, N. Asokan, và Ahmad-Reza Sadeghi. “D²IoT: A Federated Self-learning Anomaly Detection System for IoT”. In: *2019 IEEE 39th International Conference on Distributed Computing Systems (ICDCS)*. 2019, pp. 756–767. DOI: [10.1109/ICDCS.2019.00080](https://doi.org/10.1109/ICDCS.2019.00080).
- [21] Lynda Boukela, Gongxuan Zhang, Mõziane Yacoub, và còc cng s. “A Near-Autonomous and Incremental Intrusion Detection System Through Active Learning of Known and Unknown Attacks”. In: *2021 International Conference on Security, Pattern Analysis, and Cybernetics (SPAC)*. 2021, pp. 374–379. DOI: [10.1109/SPAC53836.2021.9539947](https://doi.org/10.1109/SPAC53836.2021.9539947).
- [22] L. Atzori, A. Iera, và G. Morabito. “The Internet of Things: A survey”. In: *Computer Networks* 54.15 (2010), pp. 2787–2805. DOI: [10.1016/j.comnet.2010.05.010](https://doi.org/10.1016/j.comnet.2010.05.010).
- [23] Cisco. *Cisco annual Internet report (20182023)*. <https://www.cisco.com/c/en/us/solutions/collateral/executive-perspectives/annual-internet-report/white-paper-c11-741490.html>. 2023.
- [24] R. Khan, S. U. Khan, R. Zaheer, và S. Khan. “Future Internet: The Internet of Things architecture, possible applications and key challenges”. In: *Proceedings of the 10th International Conference on Frontiers of Information Technology (FIT)*. 2012, pp. 257–260. DOI: [10.1109/FIT.2012.53](https://doi.org/10.1109/FIT.2012.53).
- [25] H. HaddadPajouh, A. Dehghantanha, R. M. Parizi, M. Aledhari, và H. Karimipour. “A survey on Internet of Things security: Requirements, challenges, and solutions”. In: *Internet of Things* 14 (2021), p. 100129. DOI: [10.1016/j.iot.2020.100129](https://doi.org/10.1016/j.iot.2020.100129).
- [26] H.-J. Liao, C.-H. R. Lin, Y.-C. Lin, và K.-Y. Tung. “Intrusion detection system: A comprehensive review”. In: *Journal of Network and Computer Applications* 36.1 (2013), pp. 16–24. DOI: [10.1016/j.jnca.2012.09.004](https://doi.org/10.1016/j.jnca.2012.09.004).

- [27] Varun Chandola, Arindam Banerjee, và Vipin Kumar. “Anomaly detection: A survey”. In: *ACM Computing Surveys* 41.3 (2009), pp. 1–58. DOI: [10.1145/1541880.1541882](https://doi.org/10.1145/1541880.1541882).
- [28] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, và Klaus-Robert Müller. “A unifying review of deep and shallow anomaly detection”. In: *Proceedings of the IEEE* 109.5 (2021), pp. 756–795.
- [29] Manuel Lopez-Martin, Belen Carro, Antonio Sanchez-Esguevillas, và Jaime Lloret. “Conditional Variational Autoencoder for Prediction and Feature Recovery Applied to Intrusion Detection in IoT”. In: *Sensors* 17.9 (2017), p. 1967. DOI: [10.3390/s17091967](https://doi.org/10.3390/s17091967).
- [30] Khaled Alrawashdeh và Carla Purdy. “Toward an online anomaly intrusion detection system based on deep learning”. In: *Proc. 15th IEEE Int. Conf. on Machine Learning and Applications (ICMLA)*. 2016, pp. 195–200. DOI: [10.1109/ICMLA.2016.0040](https://doi.org/10.1109/ICMLA.2016.0040).
- [31] L. Husamaldin và N. Saeed. “Big Data Analytics Correlation Taxonomy”. In: *Information* 11.1 (2020), p. 17. DOI: [10.3390/info11010017](https://doi.org/10.3390/info11010017).
- [32] Matei Zaharia, Reynold S. Xin, Patrick Wendell, Tathagata Das, Michael Armbrust, Ankur Dave, Xiangrui Meng, Josh Rosen, Shivaram Venkataraman, Michael J. Franklin, Ali Ghodsi, Joseph Gonzalez, Scott Shenker, và Ion Stoica. “Apache Spark: A Unified Engine for Big Data Processing”. In: *Communications of the ACM* 59.11 (2016), pp. 56–65. DOI: [10.1145/2934664](https://doi.org/10.1145/2934664).
- [33] H. Karau, A. Konwinski, P. Wendell, và M. Zaharia. *Learning Spark: Lightning-fast big data analysis*. O’Reilly Media, 2015.
- [34] Xiangrui Meng, Joseph Bradley, Burak Yavuz, Evan Sparks, Shivaram Venkataraman, Davies Liu, Jeremy Freeman, DB Tsai, Manish Amde, Sean Owen, Doris Xin, Reynold Xin, Michael J. Franklin, Reza Zadeh, Matei Zaharia, và Ameet Talwalkar. “MLlib: Machine Learning in Apache Spark”. In: *Journal of Machine Learning Research* 17.34 (2016), pp. 1–7.
- [35] A. L. Buczak và E. Guven. “A survey of data mining and machine learning methods for cyber security intrusion detection”. In: *IEEE Communications Surveys & Tutorials* 18.2 (2016), pp. 1153–1176. DOI: [10.1109/COMST.2015.2494502](https://doi.org/10.1109/COMST.2015.2494502).

- [36] N. Koroniotis, N. Moustafa, E. Sitnikova, và B. Turnbull. “Towards the development of realistic botnet dataset in the Internet of Things for network forensic analytics: Bot-IoT dataset”. In: *Future Generation Computer Systems* 100 (2019), pp. 779–796. DOI: [10.1016/j.future.2019.05.041](https://doi.org/10.1016/j.future.2019.05.041).
- [37] Tom M. Mitchell. *Machine Learning*. McGraw-Hill, 1997.
- [38] Leo Breiman. “Random Forests”. In: *Machine Learning* 45.1 (2001), pp. 5–32.
- [39] D. R. Cox. “The regression analysis of binary sequences”. In: *Journal of the Royal Statistical Society. Series B (Methodological)* 20.2 (1958), pp. 215–242.
- [40] Jerome H. Friedman. “Greedy function approximation: A gradient boosting machine”. In: *Annals of Statistics* 29.5 (2001), pp. 1189–1232.
- [41] Guolin Ke, Qi Meng, Thomas Finley, Taifeng Wang, Wei Chen, Weidong Ma, Qiwei Ye, và Tie-Yan Liu. “LightGBM: A highly efficient gradient boosting decision tree”. In: *Advances in Neural Information Processing Systems*. Vol. 30. 2017, pp. 3149–3157.
- [42] Andrew McCallum và Kamal Nigam. “A comparison of event models for naive Bayes text classification”. In: *AAAI Workshop on Learning for Text Categorization*. 1998.
- [43] Corinna Cortes và Vladimir Vapnik. “Support-vector networks”. In: *Machine learning* 20.3 (1995), pp. 273–297.
- [44] David E Rumelhart, Geoffrey E Hinton, và Ronald J Williams. “Learning representations by back-propagating errors”. In: *Nature* 323 (1986), pp. 533–536.
- [45] Tianqi Chen và Carlos Guestrin. “XGBoost: A scalable tree boosting system”. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. 2016, pp. 785–794.
- [46] Zhi-Hua Zhou. *Ensemble Methods: Foundations and Algorithms*. Chapman và Hall/CRC, 2012.
- [47] Iman Sharafaldin, Arash Habibi Lashkari, và Ali A Ghorbani. “Toward generating a new intrusion detection dataset and intrusion traffic characterization”. In: *Proceedings of the 4th International Conference on Information Systems Security and Privacy (ICISSP)*. 2018, pp. 108–116.

- [48] Canadian Institute for Cybersecurity and Communications Security Establishment. *CSE-CIC-IDS2018 dataset: A collaborative project between the Communications Security Establishment (CSE) and the Canadian Institute for Cybersecurity (CIC)*. <https://www.unb.ca/cic/datasets/ids-2018.html>. 2018.
- [49] Daniel Arp, Erwin Quiring, Feargus Pendlebury, Alexander Warnecke, Fabio Pierazzi, Christian Wressnegger, Lorenzo Cavallaro, và Konrad Rieck. “Dos and Don’ts of Machine Learning in Computer Security”. In: *31st USENIX Security Symposium (USENIX Security 22)*. 2022, pp. 3971–3988.
- [50] Maxime Lanvin, Pierre-François Gimenez, Yufei Han, Frédéric Majorczyk, Ludovic Mũ, và Õric Totel. “Errors in the CICIDS2017 Dataset and the Significant Differences in Detection Performances It Makes”. In: *Risks and Security of Internet and Systems (CRiSIS 2022), Revised Selected Papers*. Springer, 2023, pp. 18–33. DOI: [10.1007/978-3-031-31108-6_2](https://doi.org/10.1007/978-3-031-31108-6_2).
- [51] Isabelle Guyon và Andrõ Elisseeff. “An introduction to variable and feature selection”. In: *Journal of Machine Learning Research* 3 (2003), pp. 1157–1182.
- [52] Ian T. Jolliffe. *Principal Component Analysis*. 2nd ed. Springer Series in Statistics. Springer, 2002. DOI: [10.1007/b98835](https://doi.org/10.1007/b98835).
- [53] Scott M. Lundberg và Su-In Lee. “A Unified Approach to Interpreting Model Predictions”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. 2017, pp. 4765–4774.
- [54] Gints Engelen, Vera Rimmer, và Wouter Joosen. “Troubleshooting an Intrusion Detection Dataset: the CICIDS2017 Case Study”. In: *2021 IEEE Security and Privacy Workshops (SPW)*. 2021, pp. 7–12. DOI: [10.1109/SPW53761.2021.00009](https://doi.org/10.1109/SPW53761.2021.00009).
- [55] Claude Nadeau và Yoshua Bengio. “Inference for the Generalization Error”. In: *Machine Learning* 52.3 (2003), pp. 239–281.
- [56] Laurens D’hooge, Tim Wauters, Bruno Volckaert, và Filip De Turck. “Inter-dataset generalization strength of supervised machine learning methods for intrusion detection”. In: *Journal of Information Security and Applications* 54 (2020), p. 102564.
- [57] Marta Cantone, Claudio Marrocco, và Alessandro Bria. “Machine Learning in Network Intrusion Detection: A Cross-Dataset Generalization Study”. In: *IEEE Access* 12 (2024).

- [58] Mohanad Sarhan, Siamak Layeghy, và Marius Portmann. “Evaluating standard feature sets towards increased generalisability and explainability of ML-based network intrusion detection”. In: *Big Data Research* 30 (2022), p. 100359. DOI: [10.1016/j.bdr.2022.100359](https://doi.org/10.1016/j.bdr.2022.100359).
- [59] NVIDIA Corporation. *Jetson Orin Nano Super Developer Kit*. <https://www.nvidia.com/en-us/autonomous-machines/embedded-systems/jetson-orin/nano-super-developer-kit/>. 2024.
- [60] Weisong Shi, Jie Cao, Quan Zhang, Youhuizi Li, và Lanyu Xu. “Edge computing: Vision and challenges”. In: *IEEE Internet of Things Journal* 3.5 (2016), pp. 637–646. DOI: [10.1109/JIOT.2016.2579198](https://doi.org/10.1109/JIOT.2016.2579198).
- [61] Salam Hamdan, Moussa Ayyash, và Sufyan Almajali. “Edge-Computing Architectures for Internet of Things Applications: A Survey”. In: *Sensors* 20.22 (2020), p. 6441. DOI: [10.3390/s20226441](https://doi.org/10.3390/s20226441).
- [62] Alessandro Sforzin, F lix G mez M rmol, Mauro Conti, và Jens-Matthias Bohli. “RPiDS: Raspberry Pi IDS — A Fruitful Intrusion Detection System for IoT”. In: *Proc. Int. IEEE Conf. on Ubiquitous Intelligence & Computing (UIC/ATC/ScalCom)*. 2016, pp. 440–448. DOI: [10.1109/UIC-ATC-ScalCom-CBDCCom-IoP-SmartWorld.2016.0080](https://doi.org/10.1109/UIC-ATC-ScalCom-CBDCCom-IoP-SmartWorld.2016.0080).
- [63] Jay Kreps, Neha Narkhede, và Jun Rao. “Kafka: a Distributed Messaging System for Log Processing”. In: *Proceedings of the NetDB Workshop*. 2011.
- [64] Nitesh V. Chawla, Kevin W. Bowyer, Lawrence O. Hall, và W. Philip Kegelmeyer. “SMOTE: Synthetic Minority Over-sampling Technique”. In: *Journal of Artificial Intelligence Research* 16 (2002), pp. 321–357.
- [65] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, và Piotr Doll r. “Focal Loss for Dense Object Detection”. In: *IEEE International Conference on Computer Vision (ICCV)*. 2017, pp. 2980–2988.
- [66] Jo o Gama, Andr  liobait, Albert Bifet, Mykola Pechenizkiy, và Abdelhamid Bouchachia. “A survey on concept drift adaptation”. In: *ACM Computing Surveys* 46.4 (2014), pp. 1–37.